


ANÁLISIS ESTADÍSTICO MULTIVARIANTE

Un enfoque teórico y práctico



Jorge de la Garza García
Blanca Nieves Morales Serrano
Beatriz Adriana González Cavazos



ANÁLISIS ESTADÍSTICO MULTIVARIANTE

ANÁLISIS ESTADÍSTICO MULTIVARIANTE

Jorge de la Garza García

*Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Monterrey*

Blanca Nieves Morales Serrano

*Instituto Tecnológico y de Estudios Superiores de Monterrey
Universidad Virtual*

Beatriz Adriana González Cavazos

*Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Monterrey*

Revisión técnica

Filadelfo León Cázares

*Centro Universitario de Ciencias Administrativas (CUCEA)
Universidad de Guadalajara*



MÉXICO • BOGOTÁ • BUENOS AIRES • CARACAS • GUATEMALA • MADRID • NUEVA YORK
SAN JUAN • SANTIAGO • SAO PAULO • AUCKLAND • LONDRES • MILÁN • MONTREAL
NUEVA DELHI • SAN FRANCISCO • SINGAPUR • SAN LUIS • SIDNEY • TORONTO

Director General México: Miguel Ángel Toledo Castellanos

Editor sponsor: Jesús Mares Chacón

Coordinadora editorial: Marcela Rocha Martínez

Editora de desarrollo: Karen Estrada Arriaga

Supervisor de producción: Zeferino García García

ANÁLISIS ESTADÍSTICO MULTIVARIANTE

Primera edición

Prohibida la reproducción total o parcial de esta obra,
por cualquier medio, sin la autorización escrita del editor.



Educación

DERECHOS RESERVADOS © 2013, respecto a la primera edición por
McGRAW-HILL/INTERAMERICANA EDITORES, S.A. DE C.V.

A Subsidiary of The McGraw-Hill Companies, Inc.

Prolongación Paseo de la Reforma 1015, Torre A

Pisos 16 y 17, Colonia Desarrollo Santa Fe

Delegación Álvaro Obregón

C.P. 01376, México, D.F.

Miembro de la Cámara Nacional de la Industria Editorial Mexicana, Reg. Núm. 736

ISBN: 978-607-15-0817-1

All rights reserved

1234567890

1245678903

Impreso en México

Printed in Mexico

Contenido



Acerca de los autores	xiii
Agradecimientos	xv
Prólogo	xvi

Capítulo 1	Introducción al análisis multivariante	1
1.1	Antecedentes	1
1.2	Pasos para realizar una investigación	3
1.3	Diseño, estructura y medición de la información	3
1.3.1	Variables cualitativas o no métricas	4
1.3.2	Variables cuantitativas o métricas	6
1.3.3	Propiedades y comparación entre las escalas	10
1.4	Técnicas del análisis multivariante	11
1.4.1	Técnicas funcionales o dependientes	11
1.4.2	Técnicas estructurales o interdependientes	21
1.5	Clasificación de las técnicas multivariantes	33
1.5.1	Clasificación con base en sus usos	33
1.5.2	Clasificación con base en el tipo de variables	33
1.5.3	Clasificación con base en el número y el tipo de variables	34
1.6	Ejercicios de repaso	36
	Cuestionario sobre el consumo de cigarros	36
	Tipos de escalas en situaciones especiales	38
	Variables, tipos y escala	38
	Objetivos y técnica a utilizar	38
Capítulo 2	Análisis de regresión múltiple	41
2.1	Antecedentes	42
2.2	Áreas de aplicación	42
2.3	Definición	42
2.4	Etapas del análisis de regresión múltiple	42
2.4.1	Identificar el área de oportunidad o el problema a resolver	44
2.4.2	Análisis descriptivo del tipo de relación entre las variables	45
2.4.3	Ecuación de regresión	51
2.4.4	Mínimos cuadrados ordinarios (MCO) para regresión	53
2.4.5	Colinealidad o multicolinealidad	60
2.4.6	Correlación entre variables independientes	60
2.4.7	Factor de inflación de varianzas	70
2.4.8	¿Cómo evitar la multicolinealidad?	77
2.4.9	Prueba de hipótesis global	83
2.4.10	Pruebas de hipótesis individuales	94
2.5	Evaluación del modelo	106
2.5.1	Coeficiente de determinación	106

2.5.2	Coeficiente de determinación corregido	109
2.5.3	Coeficiente de correlación de múltiple	112
2.5.4	Error estándar del estimado	113
2.5.5	Varianza de los errores	116
2.6	Supuestos en los errores	118
2.7	Normalidad	120
2.7.1	Histograma	121
2.7.2	Regla empírica	122
2.7.3	Prueba de bondad de ajuste por la χ^2 cuadrada	127
2.7.4	Prueba de Shapiro-Wilk	135
2.7.5	Prueba de Kolmogorov-Smirnov-Lilliefors	141
2.7.6	Gráfica P-P y Q-Q	150
2.7.7	Prueba de Bowman-Shelton	154
2.8	Detección de valores atípicos	160
2.8.1	Histograma	160
2.8.2	Regla empírica	161
2.8.3	Gráfica de los residuales	162
2.9	Independencia de los errores	164
2.9.1	Gráfica para probar independencia	165
2.9.2	Prueba de Durbin-Watson	168
2.9.3	Prueba de Bartlett	172
2.10	Media cero	176
2.11	Homoscedasticidad	179
2.11.1	Prueba de Levene	183
2.11.2	Prueba M de Box transformada a una F	193
2.12	Pronósticos o estimaciones puntuales	202
2.13	Pronósticos puntuales del modelo exponencial	204
2.14	Pronósticos del intervalo	205
2.14.1	Intervalo de confianza para la media	205
2.14.2	Intervalo de confianza para la predicción individual	208
2.15	Estrategias	212
2.16	Ejercicios de análisis de regresión	215
Anexo 2.1	Regresión lineal simple	225
A2.1.1	Detectar el problema o área de oportunidad	225
A2.1.2	Graficar la variable dependiente contra la variable independiente	225
A2.1.3	Estimar los coeficientes del modelo	229
A2.1.4	Prueba global del modelo de regresión	234
A2.1.5	Prueba individual para cada coeficiente	242
A2.1.6	Prueba individual para la pendiente	243
A2.1.7	Prueba individual para la constante	248
A2.1.8	Coeficiente de determinación	256
A2.1.9	Error estándar del estimado	257
A2.1.10	Supuestos de los errores	259
A2.1.11	Independencia en los errores	265
A2.1.12	Media cero	269

A2.1.13 Homoscedasticidad	270
A2.1.14 Pronósticos puntuales	273
Anexo 2.2 Tabla t	281
Anexo 2.3 Tabla F	285
Anexo 2.4 Tabla normal estándar.....	292
Anexo 2.5 Tabla Durbin-Watson.....	296
Anexo 2.6 Coeficientes Shapiro-Wilk.....	306
Anexo 2.7 Tabla Shapiro-Wilk	308
Anexo 2.8 Tabla Kolmogorov-Smirnov-Lilliefors.....	310
Anexo 2.9 Manejo de matrices	313
A2.9.1 Matrices	313
A2.9.2 Escalar	314
A2.9.3 Vector.....	314
A2.9.4 Tipos	314
A2.9.5 Operaciones con matrices.....	318
A2.9.6 Operaciones con matrices en Excel	326

Capítulo 3	Análisis de factores	331
3.1	Antecedentes.....	331
3.2	Áreas de aplicación	332
3.3	Definición	332
3.4	Objetivos específicos del análisis de factores.....	334
3.5	Pasos generales para llevar a cabo un análisis de factores	335
3.5.1	Diseño del análisis de factores	337
3.5.2	Estandarización o tipificación de las variables.....	341
3.5.3	Generar la matriz de correlación	341
3.5.4	Seleccionar el modelo de factores	348
3.5.5	Descomposición espectral, singular o única.....	351
3.5.6	Seleccionar un criterio para determinar qué características deberán estar presentes en los factores	353
3.5.7	Obtener una matriz de factores no rotada	354
3.5.8	Obtención de la matriz de factores rotada	359
3.5.9	Obtención de puntajes de factores.....	365
3.6	Análisis posteriores	369
3.7	Ejercicios de análisis de factores.....	370
Anexo 3.1	Tabla ji cuadrada	382
Anexo 3.2	Descomposición espectral	384

Capítulo 4	Análisis de conglomerados	395
4.1	Antecedentes.....	395
4.2	Áreas de aplicación	396
4.3	Decisiones a tomar	396
4.4	Pasos a seguir en un análisis de conglomerados	396
4.4.1	Observación de lo que rodea a los posibles grupos	397
4.4.2	Selección de las variables	397

4.4.3	Definir la medida de proximidad	398
4.4.4	Medidas de distancia, disimilaridad o desemejanza	399
4.4.5	Medidas de similitud, similaridad o semejanza	404
4.4.6	Selección del criterio para reunir a individuos en grupos	407
4.5	Métodos jerárquicos	408
4.5.1	Método jerárquico aglomerativo	408
4.5.2	Método jerárquico divisional	409
4.6	Criterios de eslabonamiento	410
4.6.1	Promedio entre grupos (<i>between-groups linkage</i>)	410
4.6.2	Promedios intragrupos (<i>withing-groups linkage</i>)	411
4.6.3	Simple o distancias mínimas (<i>single linkage</i>)	411
4.6.4	Completo o distancias máximas (<i>complete linkage</i>)	412
4.6.5	Método de Ward	412
4.6.6	Método del centroide (<i>centroid method</i>)	412
4.6.7	Método de la mediana (<i>median method</i>)	413
4.7	Pasos del agrupamiento jerárquico aglomerativo	413
4.8	Problemas de distancia	414
4.8.1	Estandarización de las variables	415
4.8.2	Número de distancias a encontrar,	415
4.8.3	Cálculo de las distancias a encontrar	416
4.9	Vinculación o eslabonamiento	417
4.9.1	Vinculación o eslabonamiento simple	417
4.9.2	Vinculación o eslabonamiento completo	430
4.9.3	Eslabonamiento promedio entre grupos	435
4.10	Problema de similitud	440
4.10.1	Codificación de variables	440
4.10.2	Número de similitudes a encontrar	441
4.10.3	Cálculo de las similitudes a encontrar	441
4.10.4	Vinculación o eslabonamiento simple	445
4.10.5	Vinculación o <i>eslabonamiento completo</i>	455
4.10.6	Eslabonamiento promedio entre grupos	460
4.11	Métodos de agrupamiento no jerárquico	464
4.11.1	Método de reasignación o basados en el centroide	465
4.11.2	Método de búsqueda de la densidad	465
4.11.3	Método de reducción de dimensiones	465
4.12	Técnicas de k-promedios	465
4.12.1	Estandarizar las variables	467
4.12.2	Promedios de los grupos	467
4.12.3	Encontrar las distancias	470
4.12.4	Buscar el perfil de los conglomerados	471
4.12.5	Número de conglomerados a dejar como solución	472
4.12.6	Etiquetar los conglomerados	472
4.13	Análisis posteriores	472
4.13.1	Probar la segmentación	472
4.13.2	Conocer los perfiles	472
4.14	Ejercicios de análisis de agrupamiento	473

Capítulo 5	Análisis discriminante.....	479
5.1	Antecedentes.....	479
5.2	Áreas de aplicación.....	480
5.3	Definición	480
5.4	Diferencia entre el análisis discriminante y otras técnicas	482
5.5	Requerimientos estadísticos para llevar a cabo un análisis discriminante	483
5.6	Etapas para realizar un análisis discriminante.....	484
5.6.1	Formulación del problema o detección de áreas de oportunidad	484
5.6.2	Selección de las variables independientes y dependientes	486
5.6.3	Consideraciones sobre el tamaño de la muestra	486
5.6.4	Tipos de análisis discriminante	487
5.6.5	Prueba de igualdad de las medias.....	495
5.6.6	Prueba del modelo.....	499
5.6.7	Indicadores del ajuste del modelo	506
5.6.8	Obtención de las constantes del modelo	508
5.6.9	Contribución de las variables	513
5.6.10	Valoración predictiva del modelo.....	516
5.6.11	Interpretación de los resultados y estrategias	531
5.7	Análisis discriminante múltiple	532
5.7.1	Prueba de igualdad de las medias.....	538
5.7.2	Prueba del modelo.....	541
5.7.3	Indicadores del ajuste del modelo	546
5.7.4	Obtención de las constantes de los modelos.....	548
5.7.5	Contribución de las variables	555
5.7.6	Valoración predictiva del modelo.....	557
5.8	Prueba M de Box transformada a una F	568
5.9	Interpretación de los resultados	577
5.10	Mapa territorial.....	580
5.11	Ejercicios de análisis discriminante	587
Capítulo 6	Análisis de varianza	599
6.1	Antecedentes.....	600
6.2	Áreas de aplicación.....	600
6.3	Definición	600
6.4	Diferenciación	600
6.5	Etapas del análisis de varianza.....	601
6.6	Experimentación	602
6.7	Terminología	602
6.8	Tipos de modelos de análisis de varianza	603
6.8.1	Análisis de varianza de un factor.....	603
6.8.2	Diseño factorial o de dos factores.....	603
6.8.3	Diseño aleatorizado por bloques.....	603
6.8.4	Diseño de tres factores.....	604
6.8.5	Cuadrados latinos	604
6.8.6	Cuadrados grecolatinos	604

6.8.7	Diseño por bloques incompletos.....	604
6.8.8	Cuadrados de Youden.....	604
6.8.9	Diseño reticular.....	604
6.8.10	Diseño factorial 2^2	604
6.8.11	Diseño factorial 2^k en dos bloques	605
6.8.12	Diseño factorial fraccionario de dos niveles	605
6.8.13	Diseño jerárquico o anidado.....	605
6.8.14	Diseño factorial $3k$	605
6.9	Supuestos del análisis de varianza	605
6.10	ANOVA de un solo factor	606
6.10.1	Coeficiente de determinación.....	612
6.10.2	Modelo general de ANOVA de un factor.....	613
6.10.3	Seguimiento de la variable dependiente a través de otra técnica funcional.....	613
6.11	Pruebas post-hoc	615
6.11.1	Prueba de intervalos múltiples de Duncan	615
6.11.2	Prueba de Tukey.....	616
6.11.3	Mínimas diferencias significativas	616
6.11.4	Prueba de Newman-Keuls	616
6.11.5	Método Bonferroni	616
6.11.6	Método Sidak.....	616
6.11.7	Método de R-E-G-W F	616
6.11.8	Método de R-E-G-W Q.....	617
6.11.9	Método de GT2 de Hochberg	617
6.11.10	Método Gabriel.....	617
6.11.11	Método Waller-Duncan	617
6.11.12	Método Dunnett.....	617
6.11.13	Prueba de Scheffé	617
6.11.14	Método T2 de Tamhane	617
6.11.15	Método T3 de Dunnett	617
6.11.16	Método Games-Howell.....	617
6.11.17	Método C de Dunnett	618
6.12	Prueba de Scheffé	618
6.13	ANOVA de 2 factores	624
6.13.1	Nomenclatura.....	625
6.13.2	Modelo general de la técnica factorial	625
6.14	Cuadrados latinos	637
6.14.1	Modelo general de los cuadrados latinos	638
6.15	Bloques al azar	647
6.15.1	Modelo general de bloques al azar	647
6.16	Análisis de covarianza	654
6.16.1	Modelo general de covarianza	655
6.17	Análisis de varianza multivariado	663
6.17.1	MANOVA de un solo factor (caso balanceado)	663
6.17.2	Coeficiente eta parcial al cuadrado	673
6.18	Ejercicios de análisis de varianza	674

Capítulo 7	Análisis conjunto	681
7.1	Antecedentes	682
7.2	Áreas de aplicación	682
7.3	Definición	682
7.4	Usos y diferenciación	683
7.5	Etapas del análisis conjunto	683
7.5.1	Formulación del problema	683
7.5.2	Selección de atributos	683
7.5.3	Decisión de la forma de recolección de los datos	685
7.5.4	Selección del tipo de análisis conjunto	686
7.5.5	Interpretación de resultados	688
7.6	Segmentación	692
7.7	Ejercicios	692
Glosario		693
Bibliografía		699
Índice analítico		703

Acerca de los autores

Jorge de la Garza García es ingeniero químico administrador por el Instituto Tecnológico y de Estudios Superiores de Monterrey (ITESM), campus Monterrey, y cuenta con estudios de maestría en Administración. Ha sido docente durante 32 años en la Escuela de Negocios, Ciencias Sociales y Humanidades de dicha institución donde ha ocupado la Dirección del Departamento Académico de Ciencias Administrativas. Actualmente es profesor asociado de tiempo completo en el Departamento Académico de Mercadotecnia y Negocios Internacionales de la Escuela de Negocios, Ciencias Sociales y Humanidades.

Ha escrito cinco artículos en el área de la responsabilidad social de las empresas, así como el libro *Análisis de la información mercadológica a través de la estadística multivariante*.

Blanca Nieves Morales Serrano es ingeniera bioquímica con especialidad en tecnología de alimentos por el ITESM, campus Guaymas, y tiene maestría en Estadística Aplicada con especialidad en técnicas multivariadas y maestría en Administración con especialidad en Mercadotecnia en el campus Monterrey de dicha institución.

Ha fungido como académica y consejera de varias tesis y proyectos doctorales en Estados Unidos, México y Europa, además de dirigir, diseñar y ejecutar investigaciones como analista estadística y tomadora de decisiones. Cuenta con una trayectoria de más de 20 años en el Tecnológico de Monterrey impartiendo clases de estadística univariada y multivariada. Adicionalmente colabora con organizaciones no gubernamentales en favor de la educación desempeñando posiciones directivas en investigación y evaluación en la última Alianza Educativa Ciudadana por Nuevo León y es profesora titular de diversas materias de la Universidad Virtual del Tecnológico de Monterrey.

Además es fundadora y directora general de la agencia de investigación de mercados Morales Inteligencia de Mercados, S.A. de C.V.

Beatriz Adriana González Cavazos es licenciada en Mercadotecnia por el ITESM, campus Monterrey, y cuenta con estudios de maestría en Administración en dicho instituto. Durante 13 años ha sido docente de estadística multivariante; actualmente es profesora del departamento de Mercadotecnia y Negocios del ITESM, campus Monterrey.

Ha escrito diferentes artículos en torno a la investigación de mercados; los más recientes son: “¿Nuevos estilos de vida? Conoce a tu consumidor”, publicado en *El Financiero*; Francke, González, Guerrero y Peña, “La percepción de los jóvenes sobre la felicidad: desarrollo de una escala factorial”; Rodríguez, Cárdenas, González y Manrique, “Percepción del uso de las competencias tecnológicas en docentes universitarios”; González, Ocañas y Manrique, “La motivación para aprender: estudiantes universitarios del área de negocios”, los tres últimos fueron publicados en *Memorias del V Congreso de Investigación, Innovación y Gestión Educativa*.

Agradecimientos

Gracias a Dios, a mi esposa, Rosy, y a mi hijo, Jorge.

Jorge de la Garza García

Agradezco a Dios por permitirme terminar esta obra; a mis hijos, David y Nieves; así como a mis papás, Raúl y Nieves, quienes siempre me han dado su ejemplo. A mis sobrinos, Raúl, Luis, Adriana, Jorge, Fernando, Rafael, Nayeli. A todas ellas les doy mi gratitud porque la realización de este texto requirió tiempo que pude haber compartido con ellos. Asimismo, mis compañeros, alumnos y ex alumnos por enseñarme mucho de lo que sé y por animarme a realizar este libro.

Blanca Nieves Morales Serrano

Le agradezco principalmente a Dios por todas sus bendiciones; a mi esposo José Luis, por su amor y comprensión; a mis hijas Valeria e Isabella, por ser los motores que impulsan mi vida; a mis papás, Rosa Blanca y Oziel, por su ejemplo de vida; a mis hermanos, Rosy, Oziel y Cecy, por caminar siempre a mi lado; a mis compañeros maestros, por su gran apoyo y, sobre todo, gracias a mis alumnos, a quienes también les dedico este libro pues son el motivo principal de esta obra.

Beatriz Adriana González Cavazos

Prólogo

Con sumo agrado recibí la noticia de la publicación del libro que ahora presento. Esta obra es resultado del trabajo y talento de un equipo de profesores de investigación de mercados que ha demostrado sobradamente sus capacidades, las cuales se plasman en este libro tan esperado. Esta obra es a la vez un libro universitario, un manual de consulta y una guía analítica necesaria en el acervo del profesional de marketing, en particular de la investigación de mercados. Las técnicas, su enfoque y apreciación tienen una clara aplicación en la psicología organizacional, la psicometría, la investigación y la divulgación académica de la teoría de administración de empresas y organizaciones, lo cual permite lograr un dominio natural de los principios que fundamentan el proceso de investigación de consumidores, empleados y organizaciones.

Aunque la base fundamental del libro se encuentra en las técnicas de análisis univariado y multivariado, en realidad su contenido debe verse como la culminación de un proceso de estudio de la investigación de mercados y empresas.

Tanto el estudiante de asignatura como el profesional del marketing podrán ampliar su capacidad de análisis e interpretación de la información a través de los conceptos y técnicas que aquí se presentan. El enfoque general de este libro permite al lector y usuario entender la investigación en dos grandes dimensiones: una con capacidades descriptivas, es decir, que sirve para describir y explicar el presente, y otra prescriptiva, que ayuda a pronosticar y modelar el comportamiento de las variables en un estudio. Ambas dimensiones se desarrollan de forma exhaustiva en esta obra.

El punto culminante en la carrera de un profesional del marketing es el descubrimiento del fundamento básico que está detrás de la disciplina: el estudio de la naturaleza humana. Sus actitudes, percepciones, referencias e intenciones son la base de su conducta, tanto general como de consumo. Poco podremos entender de estos patrones si no logramos hacer una medición y evaluación empírica confiable de ellos. Este libro representa la combinación de contenido y enfoque que permite el entendimiento, planteamiento y solución de estrategias de análisis de datos e información para alcanzar dichos fines.

En una época en que la tecnología y el acceso a la información provocan cambios significativos en las personas y en las sociedades, el estudio de los patrones de conducta que dichas variaciones ocasionan, se vuelve imperativo. El profesional del marketing y del estudio de las organizaciones que maneje con confianza los conceptos que presenta este libro podrá entender y sacar ventaja de estos cambios.

Recomiendo esta obra no sólo como libro de texto sino como fuente permanente de consulta en el tema.

Dr. Salvador Treviño Martínez

Profesor de Mercadotecnia y
Estrategia de Empresa,
Instituto Tecnológico y de
Estudios Superiores de Monterrey

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 1

Introducción al análisis multivariante

Objetivo general:

Proporcionar una perspectiva de lo que involucra el análisis multivariante.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Explicar en qué consiste el análisis multivariante.
- Diferenciar la estadística univariada de la multivariante.
- Saber cuándo es apropiado aplicar el análisis multivariante.
- Conocer en qué consiste una investigación estadística, ya sea mercadológica, política, o de otro tema.
- Distinguir las variables cualitativas de las cuantitativas.
- Precisar la naturaleza de las escalas de medición y su relación con las técnicas multivariantes.
- Definir y discutir las técnicas específicas que incluye el análisis multivariante.
- Determinar la técnica del análisis multivariante apropiada para un problema específico o un área de oportunidad.

1.1 Antecedentes

En los últimos años, la importancia del análisis multivariante se ha acrecentado en gran medida debido a que se utiliza comúnmente en diversos campos como la industria, el gobierno, centros universitarios y de investigación. El análisis multivariante permite la resolución de problemas y la toma de decisiones con un enfoque analítico sobre todas las variables que influyen en el o los problemas en cuestión.

Por otra parte, el análisis multivariante representa una herramienta que tendrá gran trascendencia a futuro, ya que admite al análisis de datos en situaciones donde las relaciones entre las variables son más complejas. Aunado a lo anterior, los avances tan acelerados que día tras día se dan en el campo computacional facilitan cada vez más el manejo de las técnicas multivariantes.

Estadística. Conjunto de teorías y métodos desarrollados para la recolección, manejo y análisis de datos.

Dato. Colección de observaciones numéricas o no numéricas con una característica común.

Variable. Símbolo que puede tomar un valor cualquiera y representar a un conjunto determinado de datos.

Análisis multivariante. Métodos o técnicas de análisis e interpretación de un conjunto de variables que conservan su grado de interacción.

El término *multivariate analysis* se puede traducir en tres formas distintas y todas son correctas, según el campo de conocimiento en el que se apliquen: *análisis multivariable* se utiliza generalmente en psicología, sociología y economía; *análisis multivariante* se emplea en estadística, biología y economía; por último, se maneja *análisis multivariado* en psicología y educación.

Se usará el término *análisis multivariante* porque proviene del área estadística; antes de proporcionar su definición es importante establecer de forma clara que la **estadística** es un conjunto de teorías y métodos que han sido desarrollados para recolectar datos, manejarlos, analizarlos, encontrar medidas que permitan describir e interpretar la información, con el fin de concluir y poder tomar decisiones.

A la información recabada se le llama *dato*; un **dato** es una colección de observaciones numéricas o no numéricas con una característica en común. Ahora bien una **variable** es un símbolo que puede tomar un valor cualquiera y representar a un conjunto determinado de datos.

Cuando se tiene una variable se busca información que describa su comportamiento, el cual puede ser descrito por diferentes medidas:

- Indicadores de posición, tendencia o mayoría como: mediana, media, moda, etcétera.
- Indicadores de variabilidad como: rango, varianza, desviación estándar, coeficiente de variación, cuantiles, etcétera.
- Indicadores de forma como: asimetría y curtosis.
- Representaciones de los datos como: histograma, *box plot*, diagrama de tallos y hojas, etcétera.

Cuando se tienen dos variables, éstas se pueden manejar separadas y realizar con ellas las mismas pruebas como si se tuviera una sola variable; también se podrían comparar las dos, por ejemplo:

- Con pruebas de hipótesis (de dos medias, de dos proporciones y de independencia).
- Encontrar si están relacionadas o correlacionadas.

A este análisis se le denomina *bivariado* y está comprendido dentro del análisis multivariante.

Entonces, el **análisis multivariante** puede definirse como el conjunto de métodos o técnicas diseñados para el análisis e interpretación de la información contenida en un conjunto de variables sin perder la interacción o grado en que se afectan unas con otras. En la actualidad cualquier investigación o estudio que se realiza contiene múltiples variables, por eso es muy importante tener bien claros los conceptos y la aplicación de los métodos estadísticos multivariantes.

Algún empresario o investigador de mercados desearía saber cuál es el mejor precio para vender su producto, más aún conocer cómo sus clientes visualizan o posicionan su artículo con respecto a la competencia. También sería interesante conocer los segmentos de mercado que están adquiriendo el producto para así dirigir una campaña publicitaria más acertada, así como encontrar estrategias de mercado que permitan ganar nuevos clientes.

Una aplicación en política podría ser cuando se contraste algún partido con el partido ideal, es decir el partido que las personas desean tener como gobernante. También se pueden realizar comparaciones de candidatos para la percepción que ciudadanos tienen de ellos, así como las características que tienen a favor y en contra. Cualquier candidato desearía saber cuáles son las fallas de su campaña, así como qué le falta a ésta o qué le sobra.

Los sociólogos podrían interesarse en estudiar el comportamiento de los adolescentes con respecto a las actitudes y valores que los padres poseen, así como tratar de saber cuáles son sus fortalezas y debilidades.

En recursos humanos se pueden realizar programas para conocer el tipo de liderazgo de sus diferentes ejecutivos y escoger entre varios candidatos al mejor para un puesto en particular, según sus aptitudes.

Las empresas manufactureras pueden tener una nueva visión sobre las características o atributos que los consumidores desean de un artículo para mejorarlo, para fabricar uno nuevo o para encontrarle nuevos usos al producto existente.

Existen infinidad de ejemplos en los que pueden aprovecharse las técnicas multivariantes para llegar a un mejor entendimiento de ellas; empezaremos por lo más básico.

1.2 Pasos para realizar una investigación

Los pasos para realizar una investigación se pueden resumir en el siguiente diagrama:




Figura 1-1 Pasos para realizar una investigación.

1.3 Diseño, estructura y medición de la información

Seguramente el lector aprendió, en otras materias relacionadas con el tema que abarca este libro, las diferentes escalas de medición, por lo que no las explicaremos de forma amplia sino que sólo haremos un breve repaso ya que se requiere entender de qué manera se miden las variables para determinar cuáles técnicas multivariantes pueden aplicarse a la(s) investigación(es).

Como se muestra en la figura 1-2, existen dos tipos de variables:




Figura 1-2 Tipos de variables.

A continuación se describirán cuáles son las diferencias entre los dos tipos de variables.

Variables cualitativas o no métricas. Miden cualidades que no se pueden medir porque las observaciones sobre ellas sólo se pueden clasificar o enumerar.

1.3.1 Variables cualitativas o no métricas

Este tipo de variables miden cualidades de las personas u objetos de las cuales no es posible hacer mediciones numéricas puesto que las observaciones no se pueden ordenar o medir, sólo se pueden clasificar o enumerar, debido a que éstas describen o identifican a un objeto al tomar un atributo, una característica o una propiedad categórica, mas no numérica.

Un ejemplo de ésta es el color de ojos, tipo de experiencia laboral, género, complexión corporal, estado civil, etc. Sin embargo, hay que tener cuidado con aquellos datos numéricos que son etiquetas que sólo representan el código de identificación, como una matrícula, el número de seguro social, la placa de un automóvil, éstos son también datos cualitativos, porque en realidad identifican a un individuo, artículo u objeto. Las variables cualitativas se pueden medir a través de dos tipos de escalas:




Figura 1-3 Tipos de escalas no métricas.

1. **Nominal o clasificatoria.** Se emplea para referirse a los datos que sólo pueden clasificarse en categorías, cada una de éstas se considera como mutuamente excluyente (dos o más observaciones no podrán pertenecer a varias categorías) y colectivamente exhaustiva (todos los valores deberán estar contenidos en alguna categoría) con respecto a las demás.

Con el fin de procesar datos de este tipo, con frecuencia las categorías se codifican como 1, 2, 3, 4, etc. Esto facilita el conteo cuando se utiliza una computadora u otro dispositivo. La estadística más apropiada para describir la tendencia central en este tipo de escala es la moda. Las pruebas aplicadas a los datos en escala nominal no implican ninguna consideración en lo que se refiere a la distribución básica de la población a partir de la cual se seleccionó la muestra; por tanto, se les denomina *pruebas libres de distribución o no paramétricas*.



Ejemplo

- Género: Femenino ☐ Masculino ☐

En el caso de la variable “género”, los valores que se toman son cualitativos (femenino y masculino) y se puede obtener por un conteo el porcentaje de mujeres y de hombres, la moda, etcétera.

Para manejarlas se asigna un número, por ejemplo, el 1 a femenino y el 2 a masculino. Se puede obtener la moda, que indica el valor más repetitivo; sin embargo, obtener algunas medidas como la media de los datos en las variables medidas en escala nominal no tendría sentido; por ejemplo, una media de 1.5 indica algo ilógico acerca del género de los entrevistados, lo único que

se podría concluir de este valor es que existen igual número de mujeres como de hombres, información que se puede encontrar más fácilmente con simples frecuencias.

- Estado civil: Soltero ☐ Casado ☐ Viudo ☐ Divorciado ☐ Unión libre ☐
- Cuando un médico diagnostica una persona como: Esquizofrénica ☐ Paranoica ☐
Maniaco-depresiva ☐ Psiconeurótica ☐
- Posee experiencia en el trabajo: Sí ☐ No ☐

A esta última se le denomina *dicotómica dummy*, con la que se mide la ausencia (con el no) o la presencia (con el sí) del atributo y es el nivel más bajo de medición.

- ¿Qué marca de champú recuerda? Marque sólo una opción. K&Z ☐
F&H ☐ P&J ☐ D&L ☐ Otro ☐

Especifique _____

- Cuando se responde a la pregunta con una sola marca se le denomina *top of mind*, si dicha pregunta se extiende a “¿recuerda alguna otra marca?” se le llama *multirrespuesta*, a la primera mención se le conoce como *top of mind* y a las restantes *share of mind*; se codifican como primera mención, segunda mención, etc. El único análisis que se les puede hacer a este tipo de variables son las tablas de frecuencia de multirrespuestas, en las que se obtiene una frecuencia múltiple; si se relaciona con otras variables, el análisis permitido son las tablas cruzadas de multirrespuesta.
- Otro tipo sería cuando se tienen clases de igual o diferente amplitud, donde cada una se codifica con un número dándole una etiqueta, pero al momento de interpretar se hace como etiqueta; ejemplos de este tipo serían:
- ¿Qué ingreso percibe?
☐ Menos de \$4 000
☐ De \$4 001 a \$7 000
☐ De \$7 001 a \$20 000
☐ De \$20 001 en adelante
- ¿Qué edad tiene?
☐ De 26 a 35 años
☐ De 36 a 45 años
☐ De 46 a más años
- ¿Cuál es su peso?
☐ De 45 a 55 kilos ☐ De 56 a 65 kilos
☐ De 66 a 75 kilos ☐ De 76 en adelante



Nota: Muchos autores no saben dónde poner la escala dicotómica, algunos de ellos la dejan fuera de esta clasificación, otros la ponen aparte y la gran mayoría la clasifica en nominales.

2. Ordinal o de rango. En este tipo de escala cada categoría es mayor que la siguiente; sin embargo, no puede decirse qué tanto una categoría es mayor o menor que las demás. La principal diferencia entre un nivel de medición nominal y uno ordinal es la *relación mayor que* entre las categorías de nivel ordinal. Por otra parte, la escala de medición ordinal tiene las mismas características que la escala nominal, es decir, las categorías son mutuamente excluyentes y exhaustivas, además esta escala se puede convertir en la anterior.

La estadística más apropiada para describir la tendencia central en este tipo de escala es la mediana. Con el escalamiento ordinal las hipótesis pueden probarse con numerosos recursos estadísticos no paramétricos.



Ejemplo

- Enumere la siguiente lista de sabores en refrescos del 1 al 6, dando el número 1 al de mayor preferencia y el 6 al de menor:

Fresa ☐ Mandarina ☐ Naranja ☐ Manzana ☐ Uva ☐ Cola ☐

Para manejarlas se le asigna a cada variable un lugar; por ejemplo, el 1 a la fresa, lo cual indicaría que fue preferida en el primer lugar, un 2 indicaría que fue ordenada en segundo lugar, eso significa que la persona tiene como preferido otro sabor.

En este tipo de pregunta, cada opción genera una variable, los valores son cualitativos (primer lugar, segundo lugar, etc.) y se pueden obtener por un conteo el porcentaje de las veces que eligieron a la fresa en primer lugar, etc. Cada sabor es más importante que el siguiente, por lo que la moda indicaría cuál es el que tiene más menciones en primer lugar, la mediana indicaría cuál es el lugar que abarca 50% arriba o debajo del lugar asignado, es decir si la marca tiene la mediana en el lugar 2 indica que 50% de las personas la prefieren en primero y segundo lugar.

Si la codificación se llevó a cabo de otra manera, es decir, poniendo en la primera variable siempre el sabor que fue codificado como primer lugar y en la segunda variable el que fue el más nombrado en segundo lugar, el significado de la mediana nos indicaría en orden de 50% hacia el primer lugar y 50% hacia el último lugar.

Se enumera la siguiente lista de bebidas del 1 al 6, dando el número 1 al de mayor preferencia y el 6 al de menor:

- ☐ Café
- ☐ Té
- ☐ Leche
- ☐ Limonada
- ☐ Agua de frutas
- ☐ Refresco

Nota: Es necesario recordar que la mente humana sólo puede jerarquizar cuando mucho 7 objetos, productos o servicios; si es necesario que se ordenen más categorías, pueden ponerse en un círculo todos los objetos a clasificar para no sesgar la información.

Nota: Las opciones “siempre” y “nunca prefiero” obligan a las personas a realizar una jerarquización mental, por eso son ordinales.

Nota: A estos últimos dos ejemplos se les conoce mejor como escala de Likert, y se le puede considerar como ordinales cuando tenga menos de 5 categorías.

- Siempre prefiero el sabor: ☐
- Nunca prefiero la marca de pantalones: ☐
- El sabor de las frituras Tostaditos es:
Excelente ☐ Bueno ☐ Regular ☐ Malo ☐
- ¿Con qué frecuencia consume refrescos?
Muy frecuente ☐ Frecuente ☐
Poco frecuente ☐ Nada frecuente ☐

Variables cuantitativas o métricas. Identifican a un objeto o persona en forma cuantitativa o numérica, pues es diferente de otro en cantidad o grado.

1.3.2 Variables cuantitativas o métricas

Estas variables identifican a un objeto o persona en forma cuantitativa o numérica, ya que se puede decir que es diferente de otro en cantidad o grado; son aquellas en las que las observaciones resultantes pueden medirse porque poseen un orden o rango natural.

Si se piensa en los siguientes colores: negro, blanco, ¿cuál color seguiría: el azul, el morado, el naranja, etc.? Difícilmente una persona coincidiría con la respuesta de otra, por lo que este tipo de variable es no métrica. Sin embargo, cuando se tienen variables métricas, las personas las acomodan de la misma manera; por ejemplo, si se dice 1, 2, ¿cuál es el valor que seguiría? Todos contestarían 3, luego el 4 y así sucesivamente; otro ejemplo puede ser: a “excelente” sigue “muy bueno”; ¿qué seguiría: “malo”, “bueno” o “pésimo”? La respuesta que se daría sería “bueno”, por ende este tipo de variable es métrica, siempre y cuando se vea la diferencia en la mentalidad de los encuestados.

1.3.2.1 Clasificación de las variables cuantitativas de acuerdo con su tipo

Las variables cuantitativas se clasifican en discretas y continuas de acuerdo con su tipo como muestra la tabla 1-1:

Tabla 1-1 Clasificación de las variables cuantitativas según su tipo

Clasificación	Definición	Ejemplos
Discreta	También llamada <i>discontinua</i> , es aquella en la cual los valores posibles no se pueden observar en una escala continua debido a la existencia de espacios entre estos posibles valores; se utiliza para llevar a cabo un conteo, y no existen números fraccionados.	• Número de pétalos de una flor • Número de alumnos en este salón • Número de carros estacionados en el estadio • número de objetos arriba de mi escritorio
Continua	Variable que puede presentar cualquier valor dentro de cierto intervalo (números fraccionados y enteros).	• La estatura y el peso de los seres humanos • La distancia que existe entre la universidad y el centro de la ciudad • La presión que aplica una máquina para producir cierto artículo • La temperatura ambiente

Ahora, en la siguiente figura se muestran cuáles son las escalas cuantitativas.




Figura 1-4 Tipos de escalas métricas.

1. Intervalo. Incluye todas las características de la escala ordinal, entonces también la escala de intervalo se puede convertir en las dos anteriores. A diferencia de la escala ordinal, permite diferenciar un objeto de otro en cantidad o grado, e indica que al pasar de un valor a otro de la escala el atributo cambia en la misma proporción; es decir, en este tipo de escala sabemos cuál categoría es más que la otra y en qué medida; por lo que se podría concluir que dicha escala se va moviendo gradual y proporcionalmente a lo largo de todos sus valores. Existe la misma diferencia psicológica del entrevistado de un grado a otro en la escala.

La escala de medición de intervalo tiene las propiedades de ser mutuamente excluyente y exhaustiva; aquí el cero no es absoluto, no significa ausencia de algo, por ello es necesario establecer un modelo de la numeración, al codificar y establecer el significado de cada número. Por ejemplo, se podría codificar con numeración del 1 al 5 desde completamente de acuerdo hasta completamente en desacuerdo; además, se tendría que definir en cada caso qué es lo favorable (1 o 5) o lo desfavorable (5 o 1). Cuando se define la forma de codificar y el significado de la numeración de cada variable se pueden comparar las escalas; mientras no se haga esto, no son comparables, porque cada una puede tener diferente significado.

Preferentemente se deben utilizar las escalas de intervalo para los cuestionarios porque permiten realizar análisis más completos; ya que en este tipo de escalas es posible obtener todas las estadísticas paramétricas comunes, además las no paramétricas también podrán obtenerse, aunque no se suele sacar provecho de toda la información contenida en la investigación, ya que al agrupar las respuestas en clase se pierde información que puede ser valiosa.



Ejemplo

- Reparta 10 puntos midiendo el servicio de las siguientes aerolíneas:

A&A ☐ B&B ☐ C&C ☐ T&T ☐



Nota: El lector se preguntará por qué este tipo de escala se repitió en las ordinales, a estos últimos ejemplos se les conoce mejor como escala de Likert, como se había indicado antes, y se le puede considerar como de intervalo cuando tenga de 5 a 7 categorías u ordinal, cuando tenga 4 o menos categorías. Es de intervalo porque al comparar las respuestas de los encuestados se notará la diferencia mental entre ellas, por lo que la escala viene siendo más que ordinal ya que se pueden encontrar distancias.

En este caso la calificación sería de 1 a 10 o de 0 a 10. Para poder calificarlas, la persona que va a contestar este tipo de pregunta primero ordena los nombres de las aerolíneas mentalmente y luego le asigna a cada una un puntaje, según el servicio que han recibido; esto implica que una categoría es más que la otra, además al comparar las respuestas de los encuestados se notará la diferencia mental entre las respuestas, por lo que la escala de este tipo de preguntas viene siendo más que ordinal; aunque la persona que está contestando le asigne un cero a cierta marca, ese cero no indica que hubo ausencia de servicio, sino que éste fue quizá pésimo.

- El sabor del dulce A&K me parece:

Excelente ☐ Bueno ☐ Regular ☐
Malo ☐ Pésimo ☐

- En la siguiente tabla acomode las bebidas (agua, té, café, jugo, refresco y leche) en cuanto a preferencia:

Muy preferida						Nada preferida					

En este tipo de escala al momento de acomodar las bebidas y compararlas con las respuestas de otras personas se nota la diferencia mental que los encuestados tienen en cuanto a la preferencia.

- ¿Cree usted que el partido político ZWA tiene las reformas adecuadas?

Totalmente de acuerdo ☐ Totalmente en desacuerdo ☐

Otro tipo sería cuando el cero no tiene un significado de ausencia absoluta, por ejemplo:

- La temperatura actual de la ciudad es ☐

En este tipo de escala el cero no tiene un significado de ausencia absoluta, es decir a 0° no existe ausencia de temperatura, sino todo lo contrario: hace frío.

- ¿En qué año sucedió la Segunda Guerra Mundial? ☐
- ¿A qué hora toma su primera comida? ☐

Otro tipo sería cuando se tienen clases de igual o diferente amplitud, por ejemplo:

- ¿Qué ingreso percibe?

- ☐ Menos de \$1 000
- ☐ De \$1 001 a \$4 000
- ☐ De \$4 001 a \$7 000
- ☐ De \$7 001 a \$20 000
- ☐ De \$20 001 a \$40 000

En este tipo de escala, si su forma de codificar es una etiqueta entonces sería nominal, pero para que se pueda manejar con técnicas que requieren información métrica se les puede codificar a cada clase como una *dummy*; sin embargo, otros autores efectúan la codificación en este tipo de intervalo poniendo el promedio de cada clase; por ejemplo, en la primera clase se calcula el promedio de \$0 y \$1 000, el cual sería \$500, ese valor de 500 es el que se almacena en el software; en la segunda se encuentra un promedio entre \$1 001 y \$4 000, el cual sería \$2 500.50 y ése es el número que se almacena; de igual manera se procede en los siguientes ejemplos:

- ¿Qué edad tiene?

- ☐ De 26 a 35 años
- ☐ De 36 a 45 años
- ☐ De 46 a 55 años
- ☐ De 56 a más años

- ¿Cuál es su peso?

- ☐ De 45 a 55 kilos
- ☐ De 56 a 65 kilos
- ☐ De 66 a 75 kilos
- ☐ De 76 a 85 kilos
- ☐ De 86 en adelante

2. Razón. Es el nivel de medición más alto.¹ Tiene todas las características del nivel de intervalo: las distancias entre los valores son de un tamaño conocido y constante, las categorías son mutuamente excluyentes y exhaustivas. Con este tipo de escala se pueden obtener todas las estadísticas paramétricas comunes, así como las no paramétricas, aunque no suelen sacar provecho de toda la información contenida en la investigación. Las principales diferencias entre los niveles de intervalo y de razón son:

- Los datos de nivel de razón tienen un punto cero significativo.
- La razón o cociente de dos números es significativo.
- Cuando se necesita un dato exacto hay que utilizar este tipo de escalas.



Ejemplo

- ¿Cuántas horas a la semana dedicas a actividades extraacadémicas? ☐
- ¿Qué ingreso percibes? ☐

¹ Es la escala más precisa de todas.

- El papá de X gana el triple que el de Y.
- ¿Cuál es tu edad?
- Bernardo tiene el doble de edad que María.
- ¿Presión arterial?
- ¿A cuántos grados Kelvin se congela el hidrógeno?
- ¿A qué distancia se encuentra la ciudad de Saltillo?
- En promedio, ¿cuántas horas duermes?

1.3.3 Propiedades y comparación entre las escalas

A manera de resumen, las propiedades de las escalas son las siguientes:

Tabla 1-2 Propiedades de las escalas de medición

		Niveles de medición			
		Nominal	Ordinal	Intervalo	Razón
Propiedades	Asigna y clasifica los datos	✓	✓	✓	✓
	Ordena los datos		✓	✓	✓
	Marca distancia entre los datos			✓	✓
	Tienen significado las diferencias entre los valores			✓	✓
	Tiene significado el cociente de los valores				✓
	Los datos tienen origen (el cero tiene significado)				✓

Como se puede ver en la tabla 1-2, la mayor cantidad de información la da la escala de razón, por lo que es conveniente saber manejarla, aunque es muy difícil que las personas contesten este tipo de variables. Las estadísticas más usuales, dependiendo del tipo de escala, serían:

Tabla 1-3 Muestra las gráficas y estadísticas posibles en cada escala de medición

		Niveles de medición			
		Nominal	Ordinal	Intervalo	Razón
Gráficas	Pay	✓	✓		
	Box plot		✓	✓	✓
	Histograma			✓	✓
	Ojiva			✓	✓

(continúa)


Tabla 1-3 Muestra las gráficas y estadísticas posibles en cada escala de medición (*continuación*)

		Niveles de medición			
		Nominal	Ordinal	Intervalo	Razón
Estadísticas descriptivas	Frecuencia	✓	✓	✓	✓
	Conteo	✓	✓	✓	✓
	Mínimo	✓	✓	✓	✓
	Máximo	✓	✓	✓	✓
	Moda	✓	✓	✓	✓
	Mediana		✓	✓	✓
	Media			✓	✓
	Rango			✓	✓
	Desviación estándar			✓	✓
	Varianza			✓	✓
	Cuantiles		✓	✓	✓
	Sesgo			✓	✓
	Curtosis			✓	✓

A grandes rasgos, éstas son las principales características y diferencias de las escalas de medición, las cuales se necesita comprender para poder definir qué técnicas multivariantes se van a aplicar a una investigación; a continuación se analizará su clasificación, de acuerdo con ciertos factores y se explicarán a grandes rasgos con ejemplos.

1.4 Técnicas del análisis multivariante

Dentro del análisis multivariante se tiene una gran variedad de técnicas que contribuyen al estudio e interpretación de la información. De acuerdo con la finalidad que se persiga, las técnicas multivariantes se dividen en dos grandes grupos:

**Figura 1-5** Técnicas multivariantes.

Técnicas funcionales o dependientes. Son técnicas que implican un modelo, ecuación o función formada por las variables involucradas. En ellos intervienen variables dependientes e independientes.

1.4.1 Técnicas funcionales o dependientes

El nombre *funcionales* se debe a que todas las técnicas que pertenecen a este grupo implican un modelo, ecuación o función formada por las variables involucradas. En estas técnicas intervienen variables dependientes e independientes.

El objetivo de las técnicas funcionales es pronosticar una o más variables dependientes a partir de cambios en las independientes, con base en que existe una relación de causa-efecto entre ambas.




Figura 1-6 Relación causa-efecto.

donde a:

Y se le denomina variable dependiente.

X_i se les denominan variables independientes con $i = 1, 2, 3, \dots, K$.




Figura 1-7 Ejemplos de relaciones causa-efecto.

De todas las causas anteriormente nombradas se busca aquella que le dé un mayor efecto a las ventas. Algunas de las principales técnicas funcionales son las siguientes:




Figura 1-8 División de las técnicas funcionales o dependientes.

Análisis de regresión.

Permite conocer la relación causa-efecto que hay entre varias variables independientes y una dependiente.

Análisis de correlación.

Cuantifica el grado de relación lineal que hay entre variables.

1.4.1.1 Análisis de regresión y correlación múltiple

El **análisis de regresión** permite conocer la relación causa-efecto que se presenta entre varias (o múltiples) variables independientes y una dependiente, a partir de los datos se obtiene la ecuación que da a conocer el tipo de relación entre las variables y qué tan fuerte es.

El **análisis de correlación** cuantifica el grado de relación lineal que existe entre variables.

Cabe mencionar que todas las variables que intervienen en ambas técnicas deberán ser de naturaleza cuantitativa; es decir, que puedan medirse o cuantificarse en forma numérica. Esta técnica permite que se ponga información no métrica, pero sólo por medio de variables dicotómicas.

Los problemas más comunes en este tipo de análisis son: cuando el número de datos de cada variable es pequeño, las relaciones no se representan adecuadamente; también sucede que cuando el número de datos en cada variable es muy grande tenderá a indicar que sí hay diferencia significativa, por lo que otra vez las relaciones no serán representadas adecuadamente; otro tipo de problema es la multicolinealidad entre variables, este tipo de problema hace que la fiabilidad del análisis baje.

Un ejemplo en el que se puede aplicar el análisis de regresión podría ser cuando se desea conocer qué tanto se ven afectadas las ventas de un producto por:

- Los gastos que se realizan en la publicidad.
- El número de vendedores que se tienen.

Las ventas sería la variable dependiente cuantitativa y es la variable que va a recibir el efecto de las dos variables independientes cuantitativas que son las variables causales (gastos en la publicidad y el número de vendedores).

La ecuación de regresión múltiple que se construiría por esta técnica sería de la siguiente forma:

Fórmula 1-1 Función de regresión múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

donde:

Y es la variable ventas que se desea pronosticar, es decir, la variable dependiente que recibe el efecto de las independientes.

X_1 serían los gastos de publicidad, es decir, una de las variables independientes o causales.

X_2 esta variable es el número de vendedores, es decir, la otra variable independiente o causal.

β_0 es la intersección con el eje, es decir, cuando X_1 y X_2 valen cero.

β_1 es el incremento o decremento en Y por cada unidad que se incrementa o decremента X_2 , mientras que X_2 no varíe o se mantenga fija.

β_2 es el incremento o decremento en Y por cada unidad que se incrementa o decremента X_1 , mientras que X_1 no varíe o se mantenga fija.

Si además se quisiera cuantificar el grado de influencia lineal entre las variables, entonces se utilizaría el análisis de correlación, que se calcula bivariado, es decir, entre dos variables.

Una aplicación de esto es saber si existe relación, de qué tipo y en qué grado entre el número de llamadas que realiza la fuerza de ventas de una compañía telefónica al mes y el número de contrataciones nuevas que se logran. La correlación métrica se puede calcular mediante el coeficiente de correlación de Pearson utilizando la siguiente fórmula:

Fórmula 1-2 Coeficiente de correlación de Pearson

$$R = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sqrt{\left(\sum_{i=1}^n X_i^2 - n \bar{X}^2 \right) \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right)}}$$

donde:

n es el número de parejas de datos u observaciones.

$\sum_{i=1}^n Y_i^2$ es la suma de cuadrados de la variable Y .

$\sum_{i=1}^n X_i^2$ es la suma de cuadrados de la variable X .

$\sum_{i=1}^n XY$ es el producto cruzado entre la variable X y la variable Y .

$\bar{Y}$ es el promedio de la variable Y .

$\bar{X}$ es el promedio de la variable X .

Análisis discriminante.

Técnica funcional que permite explicar las diferencias entre grupos de personas u objetos mediante variables independientes con el objetivo de pronosticar o clasificar nuevas observaciones entre los grupos.

1.4.1.2 Análisis discriminante

Esta técnica funcional permite explicar las diferencias que existen entre los grupos de personas u objetos, por medio de variables independientes, con el objetivo de pronosticar o de clasificar nuevas observaciones en los grupos preestablecidos (o formados *a priori*) a partir de determinados atributos que se conocen.

La clasificación de las nuevas observaciones se realiza mediante funciones, las cuales pueden ser lineales o cuadráticas, la ecuación o modelo que se obtiene de esta técnica representa las variables independientes por su correspondiente ponderación o peso, y como la relación entre éstas y la variable dependiente es lineal se suman los productos, dando a cada observación un valor, el cual permitirá:

1. Efectuar asignaciones.
2. Interpretar las razones de su agrupamiento.
3. Obtener pronósticos de su comportamiento en relación con su pertenencia o no a los grupos objeto de análisis.

El análisis discriminante maneja K número de variables independientes, todas ellas cuantitativas, y una variable dependiente cualitativa dicotómica, en este caso se le denomina ***análisis discriminante simple***; aunque también se puede manejar en una escala nominal que tenga más de dos clasificaciones, y entonces se le llamaría ***análisis discriminante múltiple***. Por ejemplo, distinguir, o discriminar, entre los compradores de una alberca y los no compradores, de acuerdo con variables como:

- El tamaño de lote en donde se desea construir la alberca.
- El número de hijos que tiene cada familia.
- La edad que tiene el menor de los hijos.
- El ingreso que cada familia percibe.

Esta técnica no se explicará con más detalle aquí, ya que más adelante se estudiará en el capítulo 5 “Análisis discriminante”.

1.4.1.3 Análisis de varianza y covarianza

El diseño de experimentos hace uso amplio de una parte de las técnicas de análisis de varianza (las cuales serán denominadas con las siglas ANOVA). Tradicionalmente estas técnicas, conjuntamente con las técnicas de regresión lineal múltiple, de las que prácticamente son una extensión, marcan el comienzo de las técnicas multivariantes.

En la técnica de **análisis de varianza** se desea determinar si las diferentes medias de las muestras provienen de una sola población o de poblaciones con diferentes medias; estas medias de las muestras se comparan a través de sus varianzas.

Aquí se puede manejar un conjunto de variables independientes de naturaleza cualitativa para explicar una variable dependiente o un conjunto de variables dependientes de naturaleza cuantitativa.

Determinar si la posición en que se puede colocar un producto en un estante (posición alta, media o baja) afecta sus ventas. La posición es la variable independiente cualitativa y las ventas la dependiente cuantitativa.

Por otra parte, el **análisis de covarianza** (conocido como ANCOVA) y el análisis de bloques al azar se aplican en conjunto con ANOVA en experimentos en los que existen variables que quedan fuera del control del investigador y que afectan directamente las mediciones de las variables dependientes.

Análisis de varianza.

Permite determinar si las medias de las muestras provienen de una sola población o de poblaciones con diferentes muestras.

Análisis de covarianza.

Busca cómo afecta la variable incontrolable (de naturaleza métrica) a la variable dependiente para aislar y controlar su efecto.

El ANCOVA trata de encontrar cómo afecta la variable incontrolable (de naturaleza métrica) a la variable dependiente, para aislar dicho efecto y controlarlo en cierto modo, después de realizado el experimento. Un ejemplo de una variable incontrolable es la temperatura o el tráfico que podrían estar influyendo en las ventas durante el desarrollo del experimento con el estante.

El **análisis de bloques al azar** es similar al ANCOVA sólo que la variable incontrolable es de naturaleza no métrica e influye en la variable dependiente; se utiliza para aislar el efecto después de realizado el experimento y controlarlo en cierto modo. Un ejemplo de una variable incontrolable podría ser el tipo de campaña que el competidor publicita de sus productos, y se piensa que podría estar influyendo en las ventas durante el desarrollo del experimento en el estante.

Cuando un conjunto de variables independientes de naturaleza cualitativa tratan de explicar a otro conjunto de variables dependientes de naturaleza cuantitativa se emplea el análisis de varianza multivariante (MANOVA), un ejemplo podría ser cuando se quieren pronosticar las ventas de champú, enjuague y gel con base en las diferentes campañas publicitarias que se están realizando. El MANOVA también puede tener variables incontrolables métricas, en este caso nos referimos a MANCOVA.

Estas técnicas no se explicarán con más detalle, ya que más adelante se estudiarán en el capítulo 6 “Análisis de varianza”.

Análisis de bloques al azar. Sirve para aislar el efecto después de realizado el experimento, pero su variable incontrolable es de naturaleza no métrica e influye en la variable dependiente.

1.4.1.4 Análisis de correlación canónica

Esta técnica es una generalización de la correlación, ya que consiste en determinar el grado de relación entre dos conjuntos de múltiples variables. Es similar al coeficiente de correlación y al coeficiente de determinación; la diferencia es que éstos se refieren a las relaciones de variables de “una a una” (correlación bivariada, es decir, de dos variables) y de “una a muchas” (correlación múltiple, es decir, de una a muchas variables); pero para muchas investigaciones, el interés puede no centrarse en una única variable dependiente, en su lugar el investigador puede estar interesado en relaciones entre dos conjuntos de múltiples variables dependientes métricas y múltiples variables independientes métricas, por lo que la correlación canónica busca la relación de “muchas a muchas”. Los objetivos de la correlación canónica son: predecir múltiples variables dependientes, cuantificar la validez de la relación entre el conjunto de las variables independientes y el conjunto de las variables dependientes, determinar y explicar el tipo de relación y el grado de ésta entre los conjuntos de variables.

Los problemas más comunes en este tipo de análisis son los mismos que en la regresión múltiple: número pequeño de datos de cada variable, número muy grande de datos en cada variable; otro tipo de problema es la multicolinealidad; recuerde que este tipo de problemas hace que la fiabilidad del análisis baje. Por ejemplo la predicción del número de tarjetas de crédito que las familias manejan y el monto gastado al mes en cada una de ellas, al usar el ingreso de los padres de familia, pagos de la colegiatura de los hijos y el número de hijos.

Análisis de correlación canónica. Consiste en determinar el grado de relación entre dos conjuntos de múltiples variables.



Figura 1-9 Ejemplo de relación causa-efecto múltiple.

Por lo que la relación buscada se presentaría de la siguiente forma:




Figura 1-10 Relación causa-efecto múltiple.

1.4.1.5 Análisis de conjunto o *conjoint analysis*

Análisis de conjunto.

Técnica que estudia el efecto que tienen diversas variables independientes no métricas o métricas sobre una variable dependiente no métrica (ordinal).

El **análisis de conjunto** es una técnica de dependencia que trae una nueva sofisticación a la evaluación de objetos, estudia el efecto que pueden ocasionar diversas variables independientes no métricas o métricas sobre una variable dependiente no métrica (ordinal). Su principal objetivo es determinar qué combinación de un número limitado de atributos es el preferido por los encuestados. El principal uso en mercadotecnia es el desarrollo de un nuevo producto.

Esta técnica es muy similar al análisis discriminante, ya que determina las variables independientes que ayudan a que las categorías de la dependiente se diferencien. La principal divergencia es que los valores de la variable dependiente se encuentran manejados en una escala jerárquica u ordinal.

El análisis de conjunto supone que los consumidores eligen ordenando combinaciones de atributos, basándose en las preferencias de los productos a evaluar. La técnica arroja la utilidad o valor global de los productos mismos, el cual se compone de utilidades específicas de cada característica o atributo.

Dentro de los usos que más se le pueden atribuir a este método está el de conocer cuáles son los gustos y las preferencias que tiene el consumidor que está siendo estudiado, debido a que la técnica indica por qué las personas prefieren más la combinación de ciertos atributos, lo cual deberá interpretarse como la combinación preferida de los encuestados. De igual manera, puede ser utilizado en el área de mercadotecnia al momento de desarrollar nuevos productos para conocer lo que el consumidor espera del artículo al ser lanzado y poder tener así mayor probabilidad de éxito. También se emplea para estudios comparativos de precios y marcas, otro de sus usos es determinar los productos potenciales en cuanto a su participación de mercado.

El análisis de conjunto puede utilizarse para encontrar el tipo de televisor más deseado por el consumidor, midiendo atributos como:

- Tamaño de pantalla (32, 37 y 42 pulgadas).
- Tipo de pantalla (plana y plasma).
- Resolución (852×480 , $1\,024 \times 1\,024$ y $1\,366 \times 768$ píxeles).
- Color del aparato (negro y plateado).

Para realizar esta técnica se le muestran a las personas tarjetas con los distintos atributos a medir y ellas van jerarquizando en cuanto a sus preferencias los atributos más deseados y menos deseados.

Esta técnica se explicará con más detalle en el capítulo 7 “Análisis conjunto”.



Nota: Es necesario recordar que la mente humana sólo puede jerarquizar cuando mucho 7 tarjetas; en este caso se tendrían 36 combinaciones posibles de las características que tendría cada posible televisor.

1.4.1.6 Regresión logística

Regresión logística.

Estudia si una variable binomial (o dicotómica) depende o no de una o varias variables métricas.

La técnica de **regresión logística** permite estudiar si una variable binomial (o dicotómica, con la que se mide la ausencia o presencia de lo que se desea medir) depende o no de una o más variables métricas. En otras palabras son esquemas de regresión que pretenden modelar la influencia de la probabilidad de aparición de un suceso cuando se encuentra en presencia o ausencia de diversos factores. Este método estadístico avanzado fue descrito alrededor de 1976 y ha sido utilizado en áreas como medicina y odontología, entre otros.

La principal diferencia con la regresión múltiple es que en ésta la variable dependiente es métrica, sin embargo, en el análisis de regresión logística la variable dependiente es dicotómica o *dummy*, mientras que en ambas técnicas las variables independientes generalmente son métricas continuas.

En ambos análisis se construye una ecuación, la regresión múltiple utiliza el método de mínimos cuadrados para encontrar los coeficientes de dicha ecuación, sin embargo la regresión logística utiliza el método de máxima verosimilitud para encontrar estos coeficientes; la ecuación de la regresión logística se utiliza para predecir la condición de éxito o fracaso a partir de una combinación lineal de variables, en la cual las probabilidades están limitadas entre 0 y 1.

La naturaleza de un modelo de regresión lineal y de regresión logística es que el primero predice el valor medio de la variable dependiente (Y) (ya que es métrica), a partir de una o más variables independientes ($X_1, X_2, X_3, \dots, X_k$); mientras que la regresión logística permite predecir la proporción o probabilidad de cada una de las dos categorías de la variable dependiente dicotómica ($Y =$

$1 = \text{si}$, $Y = 0 = \text{no}$), en función de una o más variables independientes ($X_1, X_2, X_3, \dots, X_k$), donde k es el número de variables independientes, según sea el caso. Por ejemplo, ciertos médicos tienen información de individuos que no han dejado de fumar y de quienes sí lo han hecho; conociendo el número de cigarros que se fumaban al día, años que tenían fumando y el género de las personas involucradas, pueden saber si un paciente dejará de fumar o no. Asumiendo que el proceso “dejar de fumar” sólo tiene dos resultados: sí o no, y que la probabilidad de dejar el cigarro es la misma para todos los fumadores, se trata de un proceso binomial. Lo importante sería ver si este proceso está asociado, o no, es decir, si la probabilidad de “dejar el hábito o no” depende del número de cigarros, el género y los años de fumador.

La ecuación de la regresión logística sería la siguiente:

Fórmula 1-3 Ecuación para encontrar probabilidades en la regresión logística

$$P(Y = 1|X) = \frac{e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3)}}$$

donde:

Y es la variable dependiente, en este caso sería si se va a dejar de fumar (1) o no (0).

$P(Y = 1|X)$ es la probabilidad de que se asigne al grupo 1 (uno va a dejar de fumar) dado que los valores de las X fueron dados.

e es la función exponencial.

X_1 es el número de cigarrillos que se fuman al día.

X_2 es el número de años que llevan fumando.

X_3 esta variable es el género, como es una variable nominal es necesario volverla dicotómica, por ejemplo asignar 1 (uno) cuando sea femenino y 0 (cero) cuando sea masculino.

β_0 es la intersección con el eje, es decir, cuándo X_1 y X_2 valen cero.

β_1 es el incremento o decremento en Y por cada unidad que se incrementa o decremента X_1 , mientras que X_2 y X_3 no varíen o se mantengan fijas.

β_2 es el incremento o decremento en Y por cada unidad que se incrementa o decremента X_2 , mientras que X_1 y X_3 no varíen o se mantengan fijas.

β_3 es el incremento o decremento en Y por cada unidad que se incrementa o decremента X_3 , mientras que X_1 y X_2 no varíen o se mantengan fijas.

El resultado de la ecuación nos indica la probabilidad de pertenencia del grupo 1, si la probabilidad es mayor a 0.5 se pronostica en el grupo 1 (sí) y si la probabilidad es menor a 0.5 se pronostica en el grupo 0 (no).

1.4.1.7 Detector automático de interacción

Es una de las técnicas del análisis multivariante que permite conocer la relación entre una variable dependiente en escala métrica (es decir, de intervalo o razón) y varias variables independientes en escala métricas o no métricas (es decir, nominales, de intervalo y de razón). Es de gran utilidad para los análisis de segmentación, ya que permite fragmentar un conjunto de individuos de acuerdo con sus comportamientos o actividades específicas, que serán utilizadas como criterio. Con esta técnica se hacen comparaciones al realizar particiones dicotómicas (o de dos) de la variable que se pretende explicar, dividiendo la muestra en dos grupos según la variable que explique mejor las diferencias, y se repite el proceso hasta que se encuentren diferencias significativas. Es de utilidad para casos de segmentación en los que el segmento no se conoce con anticipación.

Detector automático de interacción. Técnica del análisis multivariante que permite conocer la relación entre una variable dependiente en escala métrica (de intervalo o de razón) y varias variables independientes en escala métrica o no (nominales, de intervalos, de razón).

Se desea ver si las variables género y ciclo de vida familiar influyen en la cantidad de visitas que los clientes de una sucursal bancaria realizan al mes (variable dependiente métrica); las variables independientes en este caso son no métricas, pero se debe recordar que también pueden ser métricas.

El diagrama del análisis se presenta en la figura 1-11; al analizar ésta se puede notar que las personas casadas cuyos hijos no viven con ellos tienen menor promedio (2.44) por lo que tienden a ir menos que el resto de las personas, ya que estas últimas (recién casados, casados con hijos y solteros) tienen un promedio mayor, lo que indica que van más al banco 2.724 veces. De las personas casadas y sin hijos que vivan con ellos en promedio van más veces los que tienen estudios de preparatoria, secundaria, etc. (con una media de 2.612) que los que tienen estudios superiores a preparatoria, ya que éstas van menos veces en promedio (2.170) y del resto de las personas, es decir, los solteros, recién casados y matrimonios con hijos. En promedio van más seguido los hombres (con una media de 2.836) que las mujeres (con un promedio de 2.611).

Todo lo anterior se encuentra resumido en la figura 1-11, que también se le denomina *answer tree*.

1.4.1.8 Análisis de supervivencia

Análisis de supervivencia. Estudia el efecto de una variable independiente (tiempo, variable métrica) cuando la variable dependiente se expresa en tiempo que tarda en ocurrir un suceso.

El **análisis de supervivencia** tiene por objeto conocer el efecto de una variable independiente (el tiempo, variable métrica) cuando la variable dependiente puede expresarse en términos del tiempo que tarda en ocurrir un suceso, ya sea benéfico o perjudicial (falla o censura, variable no métrica).

El término *supervivencia* se debe a que en las primeras aplicaciones de este método se utilizaba como evento la muerte de un paciente, por lo que su mayor aplicación fue en el campo de la medicina, como en el estudio de enfermedades crónicas y en procedimientos muy agresivos, midiendo el tiempo transcurrido hasta que la muerte ocurra (o tiempo de supervivencia). En otros casos hasta que el paciente se cure o el tiempo que transcurre hasta que aparece la enfermedad que se está midiendo.

En otras áreas como en los procesos de control de calidad se estudia el tiempo hasta recibir un servicio (se le denomina *tiempo de espera*) o el tiempo hasta que el producto falla (llamado *tiempo de falla*). Por lo que esta medida no queda limitada a los términos de vida o muerte, sino a situaciones en las que se mide el tiempo que transcurre hasta que sucede un evento de interés, como puede ser tiempo de recurrencia, cuánto dura la eficacia de una intervención, cuánto tarda un aprendizaje determinado, cambio de un parámetro, etcétera.

El paciente objeto de estudio inicia al momento de diagnosticarle una enfermedad y continúa hasta su muerte o que el tiempo de seguimiento se termina, periodo en el que puede abandonar el estudio. Cuando el tiempo de seguimiento termina antes de producirse la muerte se habla de datos “censurados”.

Por lo que las observaciones se dividen en:




Figura 1-12 Tipos de datos en el análisis de supervivencia.

Los datos censurados se dividen en supervivientes, limitantes y abandonos. Supervivientes es cuando el evento terminal no se ha dado al concluir el periodo de observación, los limitantes es cuando el investigador decide fijar un número de fallas fijo en todos los pacientes y los abandonos o alea-




Figura 1-11 Ejemplo de detector automático de interacción.

torio pueden ser por diversas causas: el paciente decide no participar más en el estudio o el paciente muere por causas ajenas al estudio, como puede ser un accidente automovilístico.

Se denomina *tiempo de participación de los supervivientes* al intervalo comprendido entre el origen y el cierre. En los datos censurados el tiempo de participación comprende desde el origen hasta la última participación.

Los requisitos necesarios para disponer de datos adecuados un análisis de supervivencia son:

- Definir el origen o inicio del seguimiento.
- Determinar la escala del tiempo.
- Establecer el evento.

El estadístico de elección en este tipo de distribuciones es la función de probabilidad de supervivencia $S(t)$. Básicamente, proporciona la probabilidad o proporción de individuos que sobrevivirán hasta un tiempo dado. Funciones relacionadas con la supervivencia son la densidad $f(t)$ y el riesgo $h(t)$, esta última es la que en realidad le importa al paciente.

Otra característica del análisis de supervivencia es que todas sus funciones deben ser calculadas para cada tiempo dado, por lo que si los datos están agrupados en intervalos de tiempo se utiliza el método actuarial y si los datos contienen información incompleta se utiliza el método de Kaplan-Meier.



Ejemplo

Una compañía de ahorro para el retiro realizó un estudio para analizar el tiempo que transcurre hasta que se tengan que entregar los fondos de pensiones; aquí los posibles estados al final del periodo de observación son:

El pensionado...

1. sigue trabajando, llegó a la edad de jubilación y recibe el fondo; esto sería un dato de falla.
2. continúa trabajando, pero no llegó a la etapa de jubilación, ya que salió de la empresa o se quedó sin trabajo; esto sería un dato censurado.
3. llegó a la edad de jubilación, pero murió y queda el fondo que pasa a los herederos; esto sería un dato de falla.
4. no se jubiló, murió y no existen herederos; esto sería un dato censurado.

Los resultados se presentan a continuación en la gráfica de supervivencia:




Figura 1-13 Gráfica de supervivencia.

Podemos notar que cada corte se debe a datos censurados, en este caso sería la opción 2 y 4 antes mencionadas de la gráfica; también que ambos géneros están muy iguales al principio, pero al pasar los 20 años de antigüedad el hombre (línea más gruesa) muestra una caída de supervivencia más rápida que las mujeres, es decir existen más datos censurados en hombres que en mujeres; la línea delgada, que pertenece al género femenino, tiene periodos más largos en los que se mantiene constante.

1.4.2 Técnicas estructurales o interdependientes

El segundo conjunto de técnicas multivariantes son las denominadas **estructurales o interdependientes**. Su objetivo principal es resumir la información, por ejemplo, describir el comportamiento del mercado a través de un menor número de variables o describir el perfil de núcleos poblacionales al resumir opiniones de personas, características de objetos, productos o servicios.

En estas técnicas todas las variables se manejan como independientes, por lo que la principal diferencia con las funcionales es que las estructurales no tratan de encontrar relaciones de causa-efecto entre las variables, sino que buscan algo en común entre las variables o personas para unirlos y así reducir o resumir la información.

Algunas de las principales técnicas estructurales son las siguientes:




Figura 1-14 Tipos de técnicas estructurales o interdependientes.

Técnicas estructurales o interdependientes. A diferencia de las técnicas funcionales, que buscan relaciones causa-efecto entre las variables, éstas buscan algo común entre las variables o personas para unirlos y así poder resumir la información.

1.4.2.1 Análisis de componentes principales o factor común

A veces el investigador tiene una gran cantidad de información que pertenece a numerosas variables con diferentes correlaciones entre sí. Con ayuda del análisis de componentes principales o factor común tales variables pueden resumirse y las variaciones presentarse a través de sólo unos cuantos componentes o factores.

El objetivo de los componentes principales y el factor común es explicar la mayor variabilidad posible del conjunto de variables con el menor número de componentes viables, pero que éstas sean las principales (de ahí proviene el nombre de la primera).

Ambos análisis, **componentes principales y factor común**, se utilizan para encontrar la interdependencia (dependencia interna) entre variables; la diferencia estriba en la forma de calcular la variación total o el comportamiento de cada variable, esto se explicará con mayor detalle en el capítulo 3 “Análisis de factores”. Resumir los atributos que un producto tiene; sus características podrían ser: precio, calidad, sabores, envase, publicidad, promoción y consistencia. Y sus componentes principales quedarían expresados en términos de las componentes producto y promoción.

Componentes principales y factor común. Análisis que se usan para encontrar la interdependencia (dependencia interna) entre variables.

1.4.2.2 Modelos de variables latentes

Antes de introducir los modelos latentes, es importante definir qué es una **variable latente**: “es una variable que no puede ser medida u observada fácil o directamente, pero puede ser representada o medida por varias variables (que se denominan *indicadores*); dicha variable obtenida es latente, la cual puede ser métrica o puede ser clasificatoria, es decir, no métrica”.

Entonces, las variables latentes son aquellas que no se pueden observar fácilmente y que se obtienen por medio de otras que son observadas y que están interrelacionadas; normalmente tienen relaciones lineales específicas con las variables originales o las que se pueden observar.

El análisis de variables latentes sirve para reducir dimensionalidad, esto es, extrae variables latentes de variables observadas o medidas, e implica que de un espacio multidimensional (múltiples variables) se reducen a un número menor de dimensiones, existen muchas técnicas que logran reducir información, aquí sólo se hablará de unas cuantas, como son:

Variable latente. Variable que no puede ser medida u observada directamente, pero sí representada o medida por varias variables llamadas *indicadores*. Sirve para reducir a un número menor de variables.

- **Análisis de clases latentes.** Es cuando las variables medidas son no métricas y las variables latentes u obtenidas son no métricas, las cuales son clases o grupos.
- **Análisis de rasgos latentes.** Se utiliza cuando las variables observadas son no métricas (binarias) y las variables latentes son métricas.
- **Análisis de perfiles latentes.** Se realiza cuando las variables medidas son métricas y la variable latente o de salida es no métrica, la cual indica grupos o segmentos.
- **Análisis de factores.** Se lleva a cabo cuando las variables observadas son métricas y las variables latentes u obtenidas también son métricas.

La siguiente tabla resume lo anterior:

Tabla 1-4 Tipos de variables medidas, variables obtenidas y análisis que se puede llevar a cabo

		Variables obtenidas del análisis o variables latentes	
		No métricas	Métricas
Variables observadas o medidas	No métricas	Análisis de clases latentes	Análisis de rasgos latentes
	Métricas	Análisis de perfil latente	Análisis de factores

1.4.2.3 Análisis de clases latentes

Análisis de clases latentes o de segmentos latentes. Método para encontrar la variable no observada o latente, compuesta por subgrupos o segmentos, por lo que sus conglomerados son K distintas categorías de una variable latente nominal.

El **análisis de clases latentes**, también denominado *análisis de segmentos latentes*, es el método por el cual se logra encontrar la variable no observada o latente, la cual está compuesta por subgrupos o segmentos, por lo que esos conglomerados son K distintas categorías de una variable latente nominal; esta técnica, a diferencia del análisis de conglomerados, identifica un óptimo número de segmentos latentes; una vez que el método detecta las clases, construye las tablas de Lazarsfeld (principal autor de este método), que contienen probabilidades condicionales para cada combinación de la clase, por ejemplo calcula la probabilidad condicional de que un miembro de la clase K conteste “sí” a la pregunta 1 y el complemento sería que conteste “no”.

La mayoría de sus usos fueron en la milicia durante la Segunda Guerra Mundial; actualmente tiene muchas aplicaciones, entre ellos podría ser el identificar segmentos, basándose en opiniones y comportamientos en las áreas de educación, psicología y sociología; en medicina, puede identificar en función de varios síntomas (variables observadas) si la enfermedad está presente o ausente, otro uso sería encontrar categorías o subcategorías de algún diagnóstico para identificar subtipos de gripes o simplemente puede ser utilizado como herramienta para la reducción de dimensiones o variables.



Ejemplo

Preguntar a 3 000 estudiantes su opinión sobre la postura que tienen sus padres respecto a las salidas de los hijos a lugares de diversión; los adolescentes deberían responder sólo tres preguntas nominales dicotómicas, donde el más (+) representa una opinión positiva y el menos (–) una opinión negativa.

Una pregunta del cuestionario podría ser la siguiente: responda positiva o negativamente con base en la opinión que tiene de las decisiones que toman sus padres sobre:

- X_1 Las decisiones de permisos (es decir, dejarlo ir o no) a este tipo de diversiones.
- X_2 Los horarios de llegadas y de salida (a este tipo de diversiones).
- X_3 Los permisos de acompañante (es decir, con quien asiste o va a este tipo de diversiones).

Las respuestas de 3 000 adolescentes se encuentran resumidas en la siguiente tabla, en la que fueron clasificadas:

Tabla 1-5 Ejemplo de tabla de frecuencia por medio del análisis de clases latentes

X_1	X_2	X_3	Total
+	+	+	698
+	+	—	581
+	—	+	504
+	—	—	353
—	+	+	324
—	+	—	255
—	—	+	147
—	—	—	138
			3 000

Esta tabla demuestra que las respuestas positivas fueron más que las negativas, por lo que la mayoría de los adolescentes respondieron de manera positiva, también demuestra que existe una asociación positiva entre cada columna, ya que si un adolescente responde positivamente a una de las preguntas, lo más seguro es que responderá de manera positiva en las demás también. En la clasificación podría decirse, por ejemplo, que 698 alumnos están de acuerdo con los permisos de sus padres, la segunda clasificación sería de 581 adolescentes, quienes están de acuerdo con los permisos de los padres, aunque no están de acuerdo en que interfieran con los amigos que los acompañan, etcétera.

La siguiente tabla muestra las probabilidades encontradas:

Tabla 1-6 Tabla de probabilidades de Lazarsfeld

Frecuencias latentes de la clase	X_1	X_2	X_3
	Probabilidad +	Probabilidad +	Probabilidad +
2 106.4	0.9354	0.6452	0.5943
893.6	0.421	0.1695	0.0769

La tabla presenta que se segmentó la muestra en dos clases, la primera, que representa más de 70% de la muestra, tiene una probabilidad de 93.54% de que a la primera pregunta contesten positivamente, etcétera.

1.4.2.4 Análisis de rasgos latentes

El **análisis de rasgos latentes** es el método mediante el cual se encuentran variables no observadas o latentes, las cuales son métricas, esto es, se analizan datos categóricos de forma binaria; este análisis reduce un sistema múltiple de variables binarias a un menor número de factores llamados *rasgos latentes*.

La mayoría de sus usos, desde un principio, se han dado en educación, psicología, humanidades, sociología o simplemente para reducir o explorar datos, o bien para confirmar hipótesis.

Se podría retomar el ejemplo anteriormente mencionado en análisis de clases latentes, recuerde que el análisis de rasgos latentes requiere de variables dicotómicas *dummy* de entrada; sólo que la salida de esta técnica sería una variable métrica, la cual puede ser el dinero con el que los adolescentes cuentan para este tipo de permisos. Cabe mencionar que estas técnicas pueden obtener más de una variable de salida, si el estudio abarcara más variables o si así lo requiriera la investigación.

Análisis de rasgos latentes. Método por el cual se analizan datos categóricos de forma binaria para encontrar variables métricas no observadas o latentes.

Análisis de perfiles latentes. Método que sirve para encontrar variables no observadas o latentes no métricas. Reduce un sistema múltiple de variables métricas a un menor número de perfiles latentes.

1.4.2.5 Análisis de perfiles latentes

El **análisis de perfiles latentes** es el método mediante el cual se encuentran variables no observadas o latentes no métricas; este análisis reduce un sistema múltiple de variables métricas a un menor número de grupos llamados *perfiles latentes*. El análisis de perfil latente genera probabilidades y analiza la mejor calidad de ajuste, es decir, indica el número óptimo de grupos a dejar. Además, los primeros se agrupan en segmentos y se obtiene un perfil de éstos.

La mayoría de sus usos son en sociología, por ejemplo, en indicadores políticos y económicos de países para la construcción de tipología y diagnósticos; en psicología es un instrumento de diagnóstico en varias pruebas psicológicas; o simplemente se aprovecha para la reducción de datos, su exploración o para la confirmación de hipótesis. Se emplea análisis de perfiles latentes cuando se desea conocer el número de segmentos o grupos de personas que encontramos en un supermercado y el perfil de cada grupo, basándose en lo que compran, es decir, se pueden tener segmentos sensibles al servicio, la marca, la publicidad, las promociones, etcétera.

1.4.2.6 Análisis de factores

Análisis de factores. Método mediante el cual se encuentran variables no observadas o latentes. Reduce un sistema múltiple de variables métricas a un menor número llamado *componentes* o *factores*.

El **análisis de factores** es el método mediante el cual se encuentran variables no observadas o latentes, las cuales son métricas; este análisis reduce un sistema múltiple de variables métricas a un menor número llamado *componentes* o *factores*.

Esta técnica, conocida también como *análisis factorial*, se utiliza para analizar las relaciones entre un gran número de variables, todas ellas independientes y métricas, y explicarlas con un número más pequeño de factores (también llamados *atributos*, *características* o *dimensiones*). Es decir, pretende resumir la información de las variables originales por medio de características o factores en común que las representen lógicamente. Si se diera el caso, estos factores resultantes se utilizarían como variables en análisis posteriores, facilitando el manejo de la información ya resumida.

El análisis de factores generalmente utiliza la técnica de componentes principales o la de factor común para extraer los factores. La técnica de *componentes principales* reduce variables, esto hace que se convierta en un método descriptivo; sin embargo, el análisis de factores requiere de elaborar, formular y realizar hipótesis estadísticas, por lo que se podría decir que las técnicas de componentes principales y de factor común dan una solución *a priori*, mientras que la técnica de análisis de factores proporciona un resultado final.

El análisis de factores se puede realizar para explorar información si es que inicialmente no se sabe el número de factores a encontrar. También se utiliza para confirmar si de entrada se conoce el número de factores a extraer.

Cuando se trata de evaluar el desempeño en la operación de un restaurante donde se manejaron las variables: sabor, cantidad servida, rapidez, amabilidad, variedad de platillos, limpieza, iluminación, ambiente, temperatura y precio. Después de realizar la técnica de factores, tal vez la información quedaría resumida bajo las siguientes dimensiones:

- Primer factor: las variables agrupadas fueron rapidez y amabilidad; por lo que a este componente se le podría llamar “Servicio”.
- Segundo factor: las variables agrupadas fueron sabor, cantidad servida; a esta característica se le denominaría “Calidad del producto”.
- Tercer factor: las variables agrupadas fueron limpieza, iluminación, ambiente, temperatura y precio; por lo cual a esta dimensión se le nombraría “Local”.

Esta última técnica se explicará con más detalle en el capítulo 3 “Análisis de factores”.

1.4.2.7 Análisis de conglomerados

Esta técnica se usa principalmente en la segmentación de mercados; con base en similitudes, forma grupos que contienen elementos lo más parecidos posibles entre sí y lo más diferentes posible al compararse entre grupos. Puede servir como entrada al análisis discriminante porque los grupos se forman con el análisis de agrupamiento y la diferenciación entre ellos se comprueba con el discrimi-

Análisis de conglomerados. Técnica empleada en la segmentación de mercados, que se basa en formar grupos que contengan elementos lo más similares entre sí y diferentes al compararse entre grupos.

nante, o sea, que este último establece si en realidad se segmentó correctamente en el agrupamiento y el porqué de esa segmentación.

La diferencia de esta técnica con el análisis de factores consiste en que el análisis de conglomerados trata de agrupar objetos o individuos basándose en sus actitudes o comportamientos comunes, es decir, se busca agrupar a las personas a través de respuestas que demuestren comportamientos parecidos. Tiene como objetivo clasificar una muestra de entidades (objetos o sujetos a agruparse) en grupos mutuamente excluyentes con base en la similaridad de dichos segmentos.

Por otra parte, a diferencia del análisis discriminante, en el de conglomerados los grupos no se encuentran predefinidos, sino que busca formarlos e identificarlos.

El análisis de conglomerados generalmente involucra dos etapas:

- **Primera etapa.** Se busca medir la similaridad o asociación entre las entidades para determinar en cuántos grupos se hará la clasificación.
- **Segunda etapa.** Se trata de definir el perfil de las personas; esto se puede hacer al aplicar un análisis discriminante a los grupos formados por el análisis de conglomerados.

Si en esta técnica se utilizan variables métricas, al análisis se le denomina *análisis de conglomerados métrico*; pero si las variables a usar son independientes no métricas, se le llama *análisis de conglomerados no métrico*. Conocer el número de segmentos o grupos de personas que encontramos en un supermercado y el perfil de cada uno basándose en lo que buscan, es decir, tener segmentos sensibles al precio, a la marca, a las promociones, etcétera. Esta técnica se explicará con más detalle en el capítulo 4 “Análisis de conglomerados”.

1.4.2.8 Escalas multidimensionales

El objetivo principal de esta técnica consiste en transformar los juicios del consumidor en similaridad o preferencia por medio de distancias representadas en una gráfica (es decir espacialmente), la cual puede tener una, dos o más dimensiones que en la mayoría de los casos son atributos o características. De las escalas multidimensionales se obtienen los mapas de posicionamiento de marcas, de objetos o de personas, efectuando comparaciones pareadas entre ellas. De esta forma, las parejas de marcas más parecidas en cuanto a su preferencia, de acuerdo con determinados atributos, tendrán una menor distancia entre sí que con respecto a las marcas restantes.

Esta técnica construye un espacio gráfico con el menor número de dimensiones posibles, busca representar fiel y exactamente la percepción de las personas o de los objetos. Además de permitir sintetizar o resumir un conjunto muy grande de datos y variables.

La técnica de escalas multidimensionales puede ser aplicada en cualquier área del conocimiento, pero donde tiene su mayor aplicación es en:

- Psicología. En la clasificación de sujetos conforme a sus habilidades y capacidades.
- Sociología. En la diferenciación de tipos de grupos sociales o razas.
- Economía. En la clasificación de países conforme a sus indicadores económicos.
- Mercadotecnia. En la evaluación de productos o servicios por parte de los consumidores al tomar en cuenta diversos atributos y una de sus principales aplicaciones es el posicionamiento de nuevas marcas o las ya existentes.

Escalas multidimensionales. Técnica que traduce los juicios del consumidor en similaridad o preferencia mediante distancias representadas en una gráfica.



Ejemplo

En un estudio se les preguntó a 150 personas su opinión acerca de cinco playas: Mazatlán, Puerto Vallarta, Ixtapa, Cancún y Acapulco en función de diversos atributos como ambiente, disponibilidad hotelera, económica, juvenil y arena de las playas. Los atributos se midieron en una escala de intervalo (donde 1 era lo más positivo de cada atributo y 7 era lo más negativo), el mapa de posicionamiento resultante fue el siguiente:



Figura 1-15 Ejemplo de mapa perceptual realizado por escalamiento multidimensional.

Como observamos en el mapa anterior, se muestran sólo dos dimensiones para poder analizarlo de la mejor manera posible: están graficadas las cinco playas y los cinco atributos.

A manera de interpretación se deberá trazar o dibujar una línea o eje para cada uno de los atributos; por ejemplo, supóngase que se escoge el atributo “económica”. Entonces se trazará dicho eje que deberá empezar en las coordenadas del atributo y siempre deberá pasar por el origen estirándola hasta que termine en el cuadrante opuesto, la flecha del nuevo eje deberá dirigirse hacia lo más positivo del atributo.

Posteriormente, desde cada playa se trazan líneas que deberán dibujarse perpendicularmente al recién trazado eje del atributo; este procedimiento se tiene que realizar en cada uno.

Para que el lector entienda la explicación, sólo se trazará un eje en la siguiente figura que muestra el eje del atributo “económica” y cada una de las playas evaluadas con esa característica:




Figura 1-16 Análisis del mapa perceptual realizado por escalamiento multidimensional

El mapa muestra que las personas percibieron Mazatlán como la playa más económica, seguida de Puerto Vallarta, Ixtapa, Acapulco y, por último, Cancún, es decir, ésta es percibida como la playa más cara. De igual forma en que se analizó el atributo “económica” se deberán leer los otros cuatro; las playas quedarán en un orden diferente al anteriormente mencionado ya que eso depende del atributo analizado.

1.4.2.9 Análisis de correspondencia

El objetivo del **análisis de correspondencia** es establecer relaciones entre variables independientes cualitativas, enriqueciendo la información que ofrecen las tablas de contingencia, que sólo comprueban si existe alguna relación entre dos variables y la intensidad de dicha relación.

Puede ser similar a la prueba de ji cuadrada y al coeficiente de Kendall; sin embargo, el análisis de correspondencia, además de analizar la relación existente entre las variables, permite analizar cómo está estructurada esta asociación, describiendo proximidades para identificar categorías como causa de asociación. El análisis de correspondencia además nos indica en qué grado contribuyen a esa relación detectada los distintos valores de las variables; la información proporcionada se muestra en un gráfico.

Este tipo de análisis utiliza de entrada las tablas de frecuencia o de contingencia; existen dos tipos de análisis de correspondencia:

- **Simple:** utiliza dos variables cualitativas.
- **Múltiple:** más de dos variables cualitativas.

En el caso de correspondencias simples los datos de las dos variables cualitativas se almacenan en una tabla de contingencia. En el caso de las correspondencias múltiples, la tabla de contingencia de doble entrada se convierte en una hipertabla de tres o más dimensiones; este tipo de tablas son anidadas y difíciles de representar; se sintetizan en una tabla denominada *tabla de Burt*.

Análisis de correspondencia. Establece relaciones entre variables independientes cualitativas, enriqueciendo así la información de las tablas de contingencia.



Ejemplo

Cierto banco desea conocer qué servicios prefieren sus clientes con base en su ciclo de vida, para así crear estrategias y saber qué ofrecer a sus nuevos o posibles clientes; se tienen dos variables (no métricas), las cuales al momento de cruzarse forman una tabla de contingencia que sería la entrada del análisis de correspondencia; una vez utilizada esta técnica se presentan a continuación los resultados obtenidos:




Figura 1-17 Ejemplo de mapa perceptual por análisis de correspondencia simple.

En este mapa se puede ver que todos los solteros prefieren las tarjetas de crédito, mientras que la mayoría de los casados sin hijos, que son personas mayores, prefieren las afores y el ahorro; casi todos los casados con hijos prefieren el crédito y el ahorro; etcétera.

Un ejemplo de análisis de correspondencia múltiple sería el de la compañía que está interesada en saber cómo los jóvenes asocian las marcas de ropa como: A&B, C&D, E&F y G&H; pero además desean saber también la asociación de las marcas de celulares como: Z&1, X&2, Y&3 y U&4; comparando dichas marcas con base en los siguientes atributos: económica, diferente, moderna, novedosa,

divertida, juvenil, casual y elegante; los resultados se presentan en un mapa de posicionamiento como el que sigue:




Figura 1-18 Ejemplo de mapa perceptual realizado por análisis de correspondencia múltiple.

Lo que podemos observar es que las marcas U&4 y Y&3 casi se perciben como elegantes, la marca A&B se percibe algo moderna, la marca de ropa C&D es aproximadamente considerada como juvenil, E&F casi como poco novedosa, Z&1 y X&2 se consideran casi como económicas y poco diferentes, etcétera.

1.4.2.10 Otros modelos causales

Existen otras técnicas causales que se salen de la clasificación anteriormente mencionada (estructurales y funcionales), dentro de las más utilizadas se encuentran:




Figura 1-19 Otras técnicas multivariantes.

1.4.2.10.1 Redes neuronales

Redes neuronales o redes de neuronas. Dispositivos que representan propiedades de los sistemas neurológicos y se aplican al reconocimiento de esquemas.

Las **redes neuronales** o **redes de neuronas** forman parte de la inteligencia artificial, son dispositivos inspirados en el funcionamiento de las neuronas de los animales; representan propiedades que se observan en los sistemas neurológicos aplicadas al reconocimiento de esquemas, que a través de ecuaciones matemáticas se reproducen o simulan artificialmente; esto las convierte en idóneas para crear y efectuar predicciones en sistemas muy complejos.

El principal objetivo de las redes neuronales es conseguir que se den respuestas similares a las que el cerebro humano tendría.

Las redes neuronales son una manera totalmente diferente de analizar los datos respecto a cualquiera de las técnicas multivariantes; en lugar de conceptualizar el problema como matemático, éstas utilizan la estructura del cerebro humano para desarrollar una estrategia de procedimiento.

Una neurona consta de conexiones de entrada y de salida:




Figura 1-20 Diagrama de flujo de una neurona.

Las redes neuronales constan de varias neuronas artificiales que modelan, mediante perceptrones o unidades de proceso, cada una de las unidades; se componen de conexiones de entrada que están ponderadas por la fuerza o intensidad de la influencia; la función de red (o de propagación) se encarga de medir la entrada como la combinación lineal ponderada (suma ponderada) de todas las conexiones; si las ponderaciones o los pesos son positivos se les denomina *señales excitatorias*, pero si son negativos se consideran *señales inhibitorias*. Toda esta información se transmite a la función de activación, la cual modifica a la función de red; los cambios pueden no darse, es decir, puede quedar igual o modificarse de lineal a no lineal, además al terminar el valor de activación puede pasar a otras unidades.

Una unidad de procesos o perceptrón de dos entradas resumido se explica de la siguiente manera:




Figura 1-21 Perceptrón o unidad de proceso con dos entradas.

Al proceso anterior se le denomina *de una sola capa o nodo*, pero lo más común sería *de tres o más capas*. La primera capa se le denomina *nodo o capa de entrada* y a la última se le llama *capa o nodo de salida*, la cual almacena la respuesta de toda la red; a las capas intermedias se les llaman *nodos o capas ocultas o intermedias* y éstas se encargan de extraer y procesar toda la información de salida. Cada una de esas unidades efectúa un número de operaciones simples y transmite sus resultados a las unidades vecinas, un ejemplo de tres capas se ilustra en la siguiente figura:




Figura 1-22 Redes neuronales de tres capas.

donde:

K es el número de entradas

P es el número de capas ocultas.

Esta tecnología es muy útil en unos pocos y muy especiales problemas, entre ellos están el reconocimiento y predicción de patrones de la mayoría de los indicadores económicos; también el reconocimiento de caracteres y de patrones en la escritura, del lenguaje, de imágenes y en robótica; en estas aplicaciones se dispone de un registro de datos y nadie sabe exactamente la estructura y los parámetros que pudieran modelar el problema. En otras palabras, grandes cantidades de datos y mucha incertidumbre en cuanto a la manera como son producidos.

Esta técnica se aplica a problemas de clasificación y series de tiempo, ofrece el potencial de identificar conexiones que otras técnicas no pueden hacer porque:

- Representa o utiliza relaciones lineales y no lineales entre los datos.
- Modela cualquier tipo de distribución de datos (no solamente la normal).
- Maneja datos con redundancia e inconsistencia en la información.

Las redes aprenden a reconocer modelos por medio de un entrenamiento basado en varios ejemplos diferentes; ellas son eficientes en el reconocimiento de modelos en un conjunto de datos. También son efectivas en el aprendizaje de modelos a partir de datos no lineales, incompletos, con ruido y hasta compuestos por ejemplos contradictorios.

La habilidad de manipular estos datos imprecisos hace que las redes sean muy eficaces en el procesamiento de información sin reglas claras o que no puedan formularse fácilmente.

Se trata de una herramienta de análisis estadístico que permite la construcción de un modelo de comportamiento a partir de una determinada cantidad de ejemplos (constituidos por una cantidad de variables descriptivas) de dicho comportamiento. La red neuronal, completamente “ignorante” al principio, efectúa “aprendizaje” a partir de los ejemplos, para luego transformarse, a través de modificaciones sucesivas, en un modelo susceptible de rendir cuentas del comportamiento observado en función de las variables descriptivas.

En los softwares especializados que manejan esta técnica, la construcción del modelo es automática y directa desde los datos; no necesita intermediario especial o costoso, sea experto o “cognocitivo”. En todo caso, la red neuronal una vez construida constituye un verdadero modelo “a la medida” que actúa en función de lo que percibe: no va a repetir las experiencias pasadas de una manera aleatoria, tampoco se trata de ir a buscar dentro de una biblioteca un modelo más o menos adaptado.

Al construir una red neuronal de aprendizaje relacionada con descripciones de personas que piden préstamos (estado civil, profesión, etc.), aunado a su comportamiento adoptado frente al reintegro del dinero, nos encontramos en capacidad de construir un modelo del riesgo asociado con la descripción de los clientes. Si luego le pedimos a ese modelo predicciones sobre nuevos expedientes, podemos constatar que la red neuronal predice correctamente de 80 a 95% si el cliente pagará bien o no. Ésta es la operación de segmentación y clasificación.

Entre otros ejemplos de las aplicaciones de las redes neuronales (*artificial neural networks*) se pueden citar las variaciones en la bolsa de valores y de ciertas acciones, los riesgos en préstamos, el clima local, el reconocimiento de modelos (representados por medio de rostros) y en el *data mining* (en la minería de datos).

1.4.2.10.2 *Path analysis*

El *path analysis* es también conocido como *análisis de pautas*, *análisis del camino* o *análisis de recorrido*. En éste lo primero es determinar el orden de las dependencias, prioridades o de las variables, pero siempre según el tipo de escala de las variables, por ejemplo:

- Si las variables son no métricas se realizan tablas de contingencia, las cuales van a medir la relación existente entre variables.
- Si las variables son métricas se analizan con la matriz de correlación, cuyos valores miden el grado de relación entre las variables.

Por medio del *path analysis* se encontrarán valores esperados o reales y a partir de ellos se localizarán caminos críticos. El *path analysis* hace uso del análisis de regresión y de un diagrama de flujo de las interdependencias, es decir, involucra la inferencia estadística y la teoría de grafos.

Path analysis. Permite encontrar valores esperados o reales, a partir de los cuales se pueden determinar caminos críticos a través del análisis de regresión y de un diagrama de flujo de las interdependencias.

El análisis de regresión se utiliza para medir o cuantificar la magnitud de la relación y si ésta es directa o indirecta, con esto se podrá describir a las variables que se estudian en su relación de causa y efecto para representarse en un diagrama (o grafo) que ayuda a establecer los caminos de la causalidad y del efecto. Para lo anterior existen dos formas de representación:




Figura 1-23 Tipos de representaciones.

Es necesario que desde un principio se establezca el orden de las dependencias en toda la red de cada modelo causal, en caso de que la investigación no lo defina; otra forma en que también puede fallar es cuando se emplean variables que serían irrelevantes en el análisis y que no cumplen lo básico del modelo.

El *path analysis* tiene muchas aplicaciones; puede utilizarse para predecir una serie de indicadores económicos como: el PIB, la inflación, la devaluación del peso frente al dólar, la tasa de desempleo, etc. En mercadotecnia se puede utilizar para conocer la asociación entre el precio del producto, la distribución, la inversión en publicidad, la calidad de un producto, las ventas, etcétera.



Ejemplo

Se le preguntó a 100 estudiantes de preparatoria sobre los atributos más importantes que tomarían en cuenta al momento de escoger una universidad y los resultados después de ser procesados en un paquete estadístico arrojaron lo siguiente:




Figura 1-24 Diagrama de *path analysis*.

Como se puede observar debajo de cada uno de los rectángulos existe un número que representa el orden de importancia que los estudiantes le dieron a cada uno de los atributos, por ejemplo, el prestigio es lo primero que buscan en una universidad, seguido de maestros preparados, etc. Los números que se encuentran en los óvalos sobre las flechas es la correlación que existe entre los atributos, por ejemplo, el atributo maestros preparados, cuatro variables le están causando efecto, y la que mayor le afecta es la preparación continua de los maestros, etcétera.

Metaanálisis. Conjunto de técnicas que permite revisar y combinar diversos resultados experimentales de distintos estudios previos para contestar una misma pregunta científica o emitir una misma conclusión.

1.4.2.10.3 Metaanálisis

El **metaanálisis** es un conjunto de técnicas que permite la revisión y combinación de diversos resultados experimentales de distintos estudios previos para contestar una misma pregunta científica o emitir una misma conclusión. La diferencia con otros procedimientos que combinan información es que en la metodología del metaanálisis no existe ningún componente subjetivo, ya que se revisa en forma *sistemática y estructurada*, y analiza, evalúa y combina los resultados de dos o más investigaciones en forma estadística.

El metaanálisis es como una revisión bibliográfica, pero a diferencia del método tradicional en el que sólo se comenta, aquí se analiza y compara descriptivamente la información; por ejemplo, para estudiar con esta técnica ensayos clínicos individuales, en lugar de utilizar a los pacientes como unidades de prueba se usan los estudios, los cuales el metaanálisis relaciona en forma metódica, los cuantifica y reproduce una gran diversidad de resultados ofreciendo conclusiones cuantitativas y cualitativas sobre los aspectos que se están estudiando.

El metaanálisis requiere de los siguientes pasos:

1. Identificar los objetivos e hipótesis, y con base en ellos decir cuáles métodos serán utilizados.
2. Revisar información bibliográfica, primaria y secundaria.
3. Seleccionar ensayos clínicos similares realizados con anterioridad.
4. Clasificar, codificar y cuantificar la información obtenida.
5. Medir la calidad de la información.
6. Realizar los análisis estadísticos.
7. Analizar, interpretar y concluir los resultados obtenidos del metaanálisis.

Las mayores aplicaciones del metaanálisis han sido en psicología, física y biomedicina. Aunque algunas aplicaciones posibles consisten en valorar de forma objetiva la necesidad de realizar un nuevo ensayo clínico, ayudar a calcular el tamaño de la muestra para resolver el problema planteado y, en casos de estudios con resultados positivos, estimar el tamaño del efecto del tratamiento con mayor precisión.

Otra de las aplicaciones es cuando se realizan dos o más investigaciones y los resultados son contradictorios e inconclusos, el metaanálisis trata de solucionar esas diferencias, ya que maneja más eficientemente la información de dichos estudios.

El metaanálisis permite estudiar subgrupos; por ejemplo, generalmente en medicina se tienen muestras muy pequeñas y se desea realizar comparaciones de al menos dos o más tratamientos controlados o no controlados.

La gran mayoría de los ensayos clínicos que se publican tienen un tamaño muestral muy pequeño, debido a que los datos utilizados provienen de los estudios realizados; la idea de utilizar el metaanálisis es que al combinar los estudios aumente el tamaño de la muestra y crezca la potencia de las pruebas estadísticas. Además al realizar este análisis en distintos centros y diferentes lugares permite que los resultados obtenidos puedan ser más fácilmente generalizables a un grupo de pacientes más amplio.

El metaanálisis, con resultados de estudios previos, usaría como variables la heterogeneidad que pueda existir entre todos los estudios que están en el análisis; además calcularía un valor medio global de la cantidad o eficacia del tratamiento; por ejemplo, puede calcular las diferencias entre las proporciones de dos grupos, la diferencia en promedios de dos grupos, un riesgo relativo o la razón de probabilidades (*odds ratio*), etc., con todo lo anterior se obtendrá una estimación de un efecto global.



Ejemplo

Se desea valorar la eficacia de un nuevo medicamento para prevenir la presencia de síntomas secundarios del sida. Se realizó una recopilación de todos los estudios hechos al respecto y se encontraron 11 (de diferentes tamaños), por medio de metarregresión se realizó un metaanálisis o comparación de los 11 estudios.

Los resultados se presentan a continuación:




Figura 1-25 Típica gráfica realizada por metarregresión.

En la gráfica anterior se presenta el *ln odds ratio* (eficacia del medicamento) en relación con la edad de los individuos, los círculos representan los 11 estudios realizados en las edades correspondientes y el área de dichos círculos es inversamente proporcional a la varianza del *ln odds ratio*. En este caso se puede ver que es más probable que el riesgo de ineffectividad del medicamento se aumente cuando se tiene mayor edad, es decir, es más efectivo en personas de menores edades.

1.5 Clasificación de las técnicas multivariantes

Una vez que se mencionaron los objetivos y usos de las técnicas multivariantes se puede hacer a manera de resumen una clasificación de éstas; existen muchas maneras de agruparlas, aquí sólo se expondrán tres de ellas:

1.5.1 Clasificación con base en sus usos

La primera, que es la más sencilla, podría explicarse con base en lo que se desea obtener de cada técnica.

1. En primer lugar, debe verificarse si se busca describir o pronosticar.
2. Si se decide por describir, se está hablando de que la información será resumida y esto se puede efectuar con variables, personas u objetos, o quizá se deseen realizar mapas de posicionamiento semánticos o preferenciales.
3. Si se elige pronosticar es porque se buscan crear estrategias basándose en los efectos de una o más variables.

El lector podrá ver esto en la figura 1-26 de la página siguiente.

1.5.2 Clasificación con base en el tipo de variables

La segunda forma de clasificar una técnica y así saber cuál es factible para ser utilizada es considerar los siguientes aspectos:

1. En primer lugar, debe verificarse si de acuerdo con la naturaleza de la investigación el conjunto de variables puede dividirse en independientes y dependientes.




Figura 1-26 División de las técnicas multivariantes dependiendo de lo que se desea obtener.

2. En segundo lugar, si existe dependencia, deberá cuestionarse cuántas variables dependientes serán manejadas. De no existir dependencia se deberá ver el tipo de escala en la que están medidas las variables.
3. En tercer y último lugar, de existir dependencia, se deberá establecer el tipo de escala en la que están medidas tanto las variables dependientes como las independientes.

En la página siguiente se presenta un cuadro con la clasificación de las técnicas multivariantes, que toma en cuenta los tres aspectos explicados.

Esto podría no ser una regla constante ya que, por ejemplo, en regresión las variables independientes son métricas, pero también se puede tener información no métrica por medio de variables de tipo *dummy*; aparte de la regresión múltiple, está la regresión logística y también la regresión ordinal, en la cual la variable dependiente es nominal y ordinal, respectivamente.

Otro ejemplo podría ser el detector automático de interacción, en el que la variable dependiente es métrica, también se podría dar el caso de que ésta fuera no métrica y las independientes fueran no métricas o métricas.

Además, en el análisis de conjunto se requieren variables independientes nominales, pero también podrían ser ordinales o métricas.

Nota: En los cuadros donde se hace mención de la escala de intervalo, deberá entenderse que hace uso de ese tipo de escala, y además podría utilizar la escala de razón.

1.5.3 Clasificación con base en el número y el tipo de variables

La tercera forma de clasificar una técnica y así saber cuándo es factible utilizarla es considerar los siguientes aspectos:

1. En primer lugar, debe verificarse si de acuerdo con la naturaleza de la investigación, el conjunto de variables puede dividirse en independientes y dependientes.




Figura 1-27 División de las técnicas multivariantes dependiendo del tipo de escala que se tiene en la investigación.

- En segundo lugar, si existe dependencia (esto sería en las técnicas funcionales) se debe cuestionar cuántas variables dependientes serán manejadas; si no existe dependencia (lo cual sería en las técnicas estructurales) es necesario saber el tipo de escala en la que están medidas las variables.
- En tercer lugar, si se usan las técnicas funcionales se deberá establecer el tipo de escala en la que están medidas las variables dependientes.
- En cuarto lugar, si se utilizan las técnicas funcionales se deberá establecer qué tipo de información se tiene de las variables independientes (número de grupos, por ejemplo) y en qué escala están siendo medidas.

Al tomar en cuenta los cuatro aspectos explicados, en la página siguiente se presenta el cuadro en el que se muestra una manera diferente de clasificar las técnicas multivariantes y se exponen más técnicas que no han sido nombradas anteriormente.

Nota: En los cuadros se etiquetan la variable dependiente como VD y la variable independiente como VI.




Figura 1-28 División de las técnicas multivariantes en la que se muestran todas las ya explicadas y otras más.

1.6 Ejercicios de repaso


Este apartado tiene como objetivo que el lector repase de una manera más sencilla lo aprendido en este capítulo.

Cuestionario sobre el consumo de cigarros

De acuerdo con el siguiente cuestionario, indique para cada pregunta el tipo de variable y la escala de medición manejada en ella:

1. ¿Fuma usted? Sí _____ No _____

Si no es así, pregunte por alguien de la casa que lo haga; si no lo hay, dé por terminada la entrevista.



2. En qué año empezó a fumar _____

3. ¿Qué marcas fuma? Mencione la más frecuente y la menos frecuente.

Más frecuente

Menos frecuente

4. En promedio, ¿cuántos cigarros fuma al día?

____ Más de un paquete

____ 1/2 a un paquete

____ Menos de 1/2 paquete

5. Hablando de un porcentaje, ¿qué tanta lealtad le guarda a su marca? _____%

6. ¿Le gustan los cigarros mentolados? (Def. quiere decir "definitivamente").

Def. sí ____ Sí ____ Quizá si ____ Quizá no ____ No ____ Def. no ____

7. Ordene las siguientes marcas de cigarros basándose en su preferencia dando el valor de 1 al más preferido y 5 al menos preferido.

____ Bens

____ Marlboro

____ Kat

____ B&W

____ Camel

8. ¿Qué edad tiene? _____ años

9. ¿Género? _____

Tipos de escalas en situaciones especiales

Indique el tipo de escala de medición que usaría en los siguientes casos:

1. Los decibeles para medir el ruido.
2. La enumeración de los jugadores de un equipo de fútbol.
3. Las calorías que necesita una persona en su edad adulta.
4. La tarifa que paga una persona por viajar en el metro.
5. El número que identifica una ruta de transporte.
6. La posición u orden que ocupa el metro como medio de transporte, según los usuarios, por su eficiencia.
7. La evaluación que reciben las instalaciones del metro por parte de los usuarios en una escala de excelente a pésima.

Variables, tipos y escala

Para cada una de las siguientes frases, indique la variable o las variables usadas, el tipo o los tipos de variables y la escala o las escalas usadas.

1. El consumo promedio *per cápita* es de 4.2 botellas de refresco por mes.
2. A los consumidores de Roca clásica, Rockola, Pep y Fiesta Cola se les pidió que evaluaran cada uno de estos refrescos atendiendo a su preferencia. Pep obtuvo el doble de popularidad comparado con Fiesta Cola, ya que el promedio de la Pep fue 3.2 y el de Fiesta Cola fue 1.6.
3. Muchas mujeres arriba de 25 años necesitan calcio como complemento alimenticio. Dos cápsulas de Calmighit diarias corrigen las deficiencias en 80% de los casos.

Objetivos y técnica a utilizar

Para cada uno de los siguientes objetivos indique la técnica que usaría para contestar. Justifique su respuesta con base en las variables que usaría y su escala de medición.

1. A partir de una serie de preguntas usadas para medir los conceptos de enseñanza, motivación, exigencia y cumplimiento; se desea comprobar la validez de tal cuestionario para medir los conceptos anteriores.
2. Una empresa desea elevar el nivel de autoestima en sus empleados y piensa que a través de motivarlos lo logre. ¿Cómo podríamos estar seguros de que esta estrategia dará resultados?
3. Se realizará un *benchmarking* (un estudio para evaluar la posición relativa) de cadenas de ropa contra los estándares de la industria.

4. ¿Qué debemos hacer para que un maestro sea considerado como excelente?; se tienen como opciones apoyar la didáctica, los aspectos motivacionales utilizados, la exigencia en el salón de clases y el cumplimiento. ¿Qué aspectos debemos enfatizar?
5. Un estudio predictivo que nos lleve a diferenciar a un buen maestro de uno malo, al considerar aspectos como la enseñanza, la motivación, la exigencia y su cumplimiento.
6. Un estudio para medir verdaderamente los conceptos de ética, valores, moral y compromiso ciudadano.
7. Un estudio para detectar si los valores en un empleado tienen algún efecto en su ética.
8. Un estudio que permita visualizar cómo se perciben las estaciones de televisión comercial con base en características como: variedad en programación, programas actuales, credibilidad de noticieros, etcétera.
9. Estrategias que nos llevan a la mejora en el desempeño de la labor de un maestro (medida en una escala jerárquica) basada en aspectos como la enseñanza, la motivación, la exigencia y su cumplimiento.
10. Las diferentes percepciones que se podrían tener de los militantes de un partido político, al considerar los aspectos: compromiso ciudadano, ética, valor y moral.
11. La posición relativa de los partidos políticos con respecto a percepciones que se tengan de cada uno de ellos, al considerar características como: plataforma política, imagen, credibilidad de planes, etcétera.
12. Evaluar si la demanda de cigarros se ve afectada por la edad de los consumidores y su ingreso.
13. Un estudio descriptivo que muestre, con base en las características de los cigarros, la posición o lugar que ocupan las diferentes marcas que se encuentran en el mercado.
14. Un estudio tendente a incrementar las ventas de una marca en particular de cigarros a través de experimentar con diferentes presentaciones en las cajetillas.
15. La determinación de las características que el consumidor de cigarros percibe en este producto.
16. Bueiser desea conocer si las características de su cerveza satisfacen (o no) al consumidor.
17. Segmentación con base en las características del mercado doméstico y el internacional de la Budiser.
18. Un estudio que soporte la propuesta de que la cerveza deba ser servida a 48° F para que el consumidor la acepte y en caso de no tener esta temperatura, rechazarla.
19. Un estudio que compruebe la propuesta de llevar a cabo promoción a través de precio con la idea de lograr la venta de 15 000 botellas de cerveza.
20. Determinar qué eslogan publicitario deberá ser usado en la próxima campaña; se busca que el consumidor logre un cierto tiempo de recordación.
21. ITM desea saber cómo es percibida su marca en el mercado, así como otras marcas de la competencia y cuál es la computadora que los consumidores desean tener en el mercado.
22. Feliz desea conocer si existen segmentos de población que prefieran los cereales con fibra.
23. La Secretaría de Gobernación desea determinar a qué grupo social pertenece una persona mediante preguntas como número de hijos, sueldo, gasto mensual, etcétera.
24. ¿Qué estudio tengo que realizar para identificar las características de la cerveza que evalúa el consumidor?
25. La academia de baile desea determinar a qué grupo: avanzado, intermedio o principiantes pertenece una persona mediante preguntas como número de horas de práctica, cuántos años ha estudiado ballet, etcétera.
26. Pikis desea determinar qué tipo de platillos expondrá en su próxima muestra gastronómica; busca incrementar su número de clientes.

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 2

Análisis de regresión múltiple

Objetivo general:

Conocer y aplicar los métodos de regresión simple y múltiple; interpretar sus resultados, así como su confiabilidad para realizar pronósticos puntuales y por intervalos, con el fin de tomar decisiones en situaciones reales dentro del campo de los negocios.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Distinguir entre una variable dependiente y una independiente.
- Diferenciar entre una relación lineal o no lineal.
- Estimar e interpretar la ecuación de regresión lineal múltiple mediante el método de mínimos cuadrados ordinarios.
- Detectar y corregir problemas de colinealidad y multicolinealidad.
- Conocer los diferentes métodos de selección de variables.
- Describir en qué forma las variables cualitativas o ficticias pueden incluirse en un modelo de regresión múltiple.
- Verificar la significancia de la función de regresión múltiple.
- Realizar pruebas de hipótesis y construir intervalos de confianza para los coeficientes de la ecuación de regresión.
- Analizar e interpretar los coeficientes de correlación, determinación, determinación ajustado o corregido y el error estándar del estimado.
- Calcular y analizar los errores (residuales) para la verificación del cumplimiento de los supuestos en el análisis de regresión.
- Describir el problema de la autocorrelación en los errores y de la variable dependiente mediante la prueba de Durbin Watson.
- Calcular estimaciones puntuales y por intervalo de la variable respuesta.
- Utilizar el SPSS™ para aplicar el análisis de regresión múltiple con un ejemplo en la obtención de pronósticos.
- Interpretar los resultados del análisis de regresión múltiple y obtener las conclusiones y recomendaciones respecto a las estimaciones.

2.1 Antecedentes

La técnica de análisis de regresión múltiple empezó con el desarrollo del método de mínimos cuadrados ordinarios (MCO), publicado por Legendre en el año 1805 y luego por Gauss en 1809. La aplicación que ambos le dieron fue en observaciones astronómicas y aunque Euler había trabajado en 1748 en el mismo problema, no tuvo éxito. Gauss publicó en 1821 una teoría más avanzada sobre el método MCO, en la cual incluyó una versión del teorema de Gauss-Markov.

En el siglo XIX Francis Galton, quien fue primo de Charles Darwin, le puso el nombre de *regresión*, ya que él trató de explicar el fenómeno biológico de por qué las estaturas de los ancestros regresaban en sus descendientes una altura promedio normal. Pero fue con Udney Yule y Karl Pearson que el trabajo que realizó Galton se consolidó como un procedimiento estadístico.

2.2 Áreas de aplicación

El análisis de regresión es muy utilizado en el área de los pronósticos, ya que puede predecir los valores de una variable¹ basándose en los valores de una u otras variables² explicatorias. Sus usos y aplicaciones son muy diversos y pueden encontrarse en la psicología, física, química, biología, economía, administración y otras ciencias.

Entre las aplicaciones principales están: pronósticos de ventas, precios, producción, ganancia, inflación, mortalidad, nacimientos, etc. El análisis de regresión indica cuáles son las razones por las cuales la variable que se desea pronosticar se comporta de una manera determinada.

2.3 Definición

Análisis de regresión.
Es una técnica multivariada, cuyo objetivo es desarrollar un modelo matemático lineal.

El **análisis de regresión** es una técnica multivariada, cuyo objetivo es desarrollar un modelo matemático lineal³ que pueda describir la relación existente entre la variable a pronosticar (dependiente) y las variables (independientes) que el investigador crea conveniente relacionar con la primera.

Este modelo es lineal, es decir, aditivo en sus términos, como se muestra a continuación:

Ecuación 2-1 Modelo de regresión múltiple

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$$

Donde:

Y : es la variable dependiente, la cual también es denominada *variable respuesta*.

X_i : es la variable independiente i , la cual también se llama *explicatoria*.

β_i : es el coeficiente del modelo para la variable X_i .

Tanto la variable dependiente como las independientes deben ser métricas, aunque las independientes también pueden tener valores cualitativos, lo cual se explicará ampliamente después.

2.4 Etapas del análisis de regresión múltiple

A continuación se desglosan las etapas del análisis de regresión múltiple:

1. Formular el problema o área de oportunidad.
2. Seleccionar las variables, con una relación de causa-efecto.

¹ Esta variable se denomina *dependiente* y es la que se desea pronosticar, su naturaleza debe ser métrica; si es no métrica deberá ser nominal del tipo *dummy* pero en este caso la técnica que se utilizaría sería la regresión logística.

² También se llaman *independientes* y deben ser métricas, aunque la información no métrica o categórica puede ponerse como variables *dummy* única y exclusivamente de esa forma. Cuando sólo se tiene una variable dependiente y una independiente se le denomina *regresión simple* pero cuando hay una dependiente y dos o más independientes se le llama *regresión múltiple*.

³ Es un modelo lineal o aditivo, ya que los términos se suman.

Estas etapas se muestran en el siguiente diagrama:




Figura 2-1 Diagrama de las etapas del análisis de regresión.

3. Recolectar las variables.
4. Hacer un análisis descriptivo del tipo de relación.
5. Seleccionar el método; éste puede ser por mínimos cuadrados ordinarios (MCO) o mínimos cuadrados ponderados (MCP).
6. Calcular los coeficientes de la ecuación de regresión para construir la función.
7. Identificar los problemas de colinealidad o multicolinealidad.
8. Realizar la prueba global de la ecuación.
9. Efectuar las pruebas individuales de los coeficientes.
10. Probar el cumplimiento de los supuestos del análisis.
11. Interpretar los coeficientes de determinación, correlación, determinación ajustado y error estándar.
12. Interpretar los coeficientes de la ecuación de regresión.
13. Hacer pronósticos puntuales y por intervalo.

A continuación se verá cada etapa con un ejemplo.⁴

2.4.1 Identificar el área de oportunidad o el problema a resolver

Es muy importante detectar un problema o área de oportunidad porque con esto podría solucionarse. Supóngase, por ejemplo, que se desea desarrollar un modelo (ecuación o función) para predecir el precio que cobran de renta en casas que se encuentran cerca del Instituto Tecnológico y de Estudios Superiores de Monterrey (ITESM). Se poseen tres variables más: la distancia que existe de la casa al Tec, el número de cuartos que tiene cada vivienda y el número de estudiantes que vivirían en ellas.

Pensemos que entre más cerca esté una casa del Tec, la renta será más cara (relación inversa), entre más habitaciones tenga el precio aumentará (relación directa), entre más estudiantes renten una casa más grande deberá ser por lo que la renta sería más costosa (relación directa); también influye el área en que se ubique el inmueble, ya que en las zonas norte y sur sería más barata que si se localiza al este u oeste (esta última sería la zona más costosa, impactando de forma directa en el monto de la renta). Esto indica que podría tratarse de una relación causa-efecto de la siguiente manera:




Figura 2-2 Relación causa-efecto.

En regresión, el número de observaciones mínimas por cada variable deberá ser: el número de parámetros⁵ más 1;⁶ en este caso, se tienen 6 variables independientes más β_0 ; el cual es un parámetro; es decir, 7 parámetros ($6 + 1$), entonces se deben tener 8 datos. En este ejemplo se tienen 15 datos, por lo que sí aplica para regresión.

⁴ La información fue recabada en el semestre enero-mayo de 2010 por la Ing. Blanca Nieves Morales en el Instituto Tecnológico y de Estudios Superiores de Monterrey, campus Monterrey.







⁵ Los parámetros son los valores que se utilizan para describir las características poblacionales.

⁶ En este caso se tienen tres variables métricas (cuartos, distancia y estudiantes) y la variable "zona", que es no métrica, la cual tiene cuatro niveles o categorías (norte, sur, este y oeste); cuando se codifica dicha variable se deberá convertir a *dummy*; por lo que no se pueden poner todas las opciones, es decir, si el número de opciones son 4, sólo tres categorías se deberán convertir a $4 - 1$ variables.

2.4.2 Análisis descriptivo del tipo de relación entre las variables







La regresión exige que la relación entre las variables sea lineal, para ver si se cumple con esto lo indicado es graficar cada variable independiente con la dependiente; si la relación lineal no se cumple, se realizarán cambios matemáticos en cualquiera de las variables, ya sea en la dependiente o en cada una de las independientes. Conviene ver los tipos de relaciones más comunes que existen:

Tabla 2-1 Tipos de relaciones más comunes

	Relación lineal positiva perfecta o directa.
	Relación lineal negativa, indirecta o inversa perfecta.
	Relación lineal positiva o directa, pero imperfecta.
	Relación lineal negativa, indirecta o inversa, pero imperfecta.
	Relación curvilínea positiva; este tipo requiere de transformaciones logarítmicas; por ejemplo, podría ser un modelo logarítmico $Y = f(\ln X)$, uno de tipo exponencial $\ln(Y) = f(X)$ o bien un modelo potencia $\ln(Y) = f(\ln X)$.
	Relación curvilínea negativa; este tipo requiere de transformaciones logarítmicas. Podría ser un modelo logarítmico $Y = f(\ln X)$, exponencial $\ln(Y) = f(X)$ o potencia $\ln(Y) = f(\ln X)$.

(continúa)

Tabla 2-1 Tipos de relaciones más comunes (*continuación*)

	Relación cuadrática (note que es una parábola o polinomio de grado dos). Este tipo de relaciones requiere la transformación de una parábola: $\hat{Y} = b_0 + b_1 + b_2 X^2$ (polinomio de grado dos).
	Relación polinomial de grado mayor a dos; este tipo requiere una transformación de un polinomio de grado avanzado (3, es decir, una cúbica) $\hat{Y} = b_0 + b_1 + b_2 X^2 + b_3 X^3$.
	Si bien existe una relación lineal (en forma de abanico), este modelo requiere transformación (logarítmica, inversa o raíz, aunque es preferible utilizar regresión por medio de mínimos cuadrados ponderados).
	Si bien existe una relación lineal (en forma de abanico), este modelo requiere transformación (logarítmica, inversa o raíz, aunque es preferible utilizar regresión por medio de mínimos cuadrados ponderados).
	Si bien existe una relación lineal (en forma de rombo), este modelo requiere transformación (logarítmica, inversa o raíz, aunque es preferible utilizar regresión por medio de mínimos cuadrados ponderados).
	Si bien existe una relación lineal (en forma de rombo), este modelo requiere transformación (logarítmica, inversa o raíz, aunque es preferible utilizar regresión por medio de mínimos cuadrados ponderados).
	No existe relación ya que las variables son independientes. En este caso no se deberá realizar regresión.⁷

⁷ La regresión se debe utilizar cuando exista una relación lineal, pero cuando ésta no se dé, como en el caso de la última gráfica, no se deberá realizar este tipo de análisis.

Siguiendo con el ejemplo de la renta, los valores de las variables se encuentran en la siguiente tabla.

Tabla 2-2 Datos disponibles

Y	X_1	X_2	X_3	X_4
Renta	Distancia	Cuartos	Estudiantes	Norte
8 500	1	2	2	Sur
8 900	1	2	2	Norte
14 000	0.5	4	3	Norte
5 000	3	1	2	Este
11 000	0.5	4	4	Este
8 000	1	2	2	Oeste
8 500	1	2	2	Sur
12 000	3	4	4	Este
3 900	0.5	1	1	Este
12 000	1	4	3	Oeste
7 500	4	3	3	Oeste
8 700	3	3	3	Este
8 000	1	3	3	Oeste
3 800	4	1	1	Oeste
7 000	2	2	2	Norte
9 000	2	3	3	Sur
4 500	4	1	1	Este
4 800	4	1	2	Sur
7 900	1	2	2	Sur
5 000	4	1	2	Oeste
13 500	0.5	4	4	Este
13 500	0.5	4	4	Este
7 000	4	2	2	Oeste
14 000	4	4	4	Norte

Como puede verse, el ejemplo tiene una variable no métrica por lo que es necesario convertirla en variables que marquen la presencia y ausencia⁸ de cada zona, en este caso se tienen 4 zonas, por lo que al recodificar la variable zona quedarían 4 zonas,⁹ como se muestra a continuación:

⁸ La presencia está codificada con 1 y la ausencia con 0; a esta variable se le conoce como *categorica a dummy*.

⁹ Las cuales serían zona este, norte, oeste y sur.

Tabla 2-3 Datos recodificados

Y	X_1	X_2	X_3			X_4	X_5	X_6	X_7
Renta	Distancia	Cuartos	Estudiantes	Zona	Zona	Este	Norte	Oeste	Sur
8 500	1	2	2	Sur	2	0	0	0	1
8 900	1	2	2	Norte	1	0	1	0	0
14 000	0.5	4	3	Norte	1	0	1	0	0
5 000	3	1	2	Este	3	1	0	0	0
11 000	0.5	4	4	Este	3	1	0	0	0
8 000	1	2	2	Oeste	4	0	0	1	0
8 500	1	2	2	Sur	2	0	0	0	1
12 000	3	4	4	Este	3	1	0	0	0
3 900	0.5	1	1	Este	3	1	0	0	0
12 000	1	4	3	Oeste	4	0	0	1	0
7 500	4	3	3	Oeste	4	0	0	1	0
8 700	3	3	3	Este	3	1	0	0	0
8 000	1	3	3	Oeste	4	0	0	1	0
3 800	4	1	1	Oeste	4	0	0	1	0
7 000	2	2	2	Norte	1	0	1	0	0
9 000	2	3	3	Sur	2	0	0	0	1
4 500	4	1	1	Este	3	1	0	0	0
4 800	4	1	2	Sur	2	0	0	0	1
7 900	1	2	2	Sur	2	0	0	0	1
5 000	4	1	2	Oeste	4	0	0	1	0
13 500	0.5	4	4	Este	3	1	0	0	0
7 000	4	2	2	Oeste	4	0	0	1	0
14 000	4	4	4	Norte	1	0	1	0	0


Es necesario decidir cuál variable de la zona se eliminará para evitar problemas de multicolinealidad¹⁰ por la información repetida. Supongamos que se decidió quitar la zona norte.¹¹

A continuación se obtienen las gráficas del SPSS[™] de la variable dependiente con respecto a cada variable independiente;¹² la forma matricial del SPSS[™] muestra todas las combinaciones posibles de todas las variables. Es necesario que todas las variables independientes se encuentren en el eje X y la dependiente (en este caso la renta) en el eje Y. En la siguiente figura se muestra la gráfica matricial en la que está señalado el renglón que debería revisarse:

¹⁰ La multicolinealidad se define como la relación (lineal o no lineal) que existe entre las variables independientes; este problema se explicará más adelante.


¹¹ Preferiblemente esta decisión deberá tomarse después de este paso.

¹² En este paquete primero se le pidió obtener la forma matricial, se recomienda que primero se introduzcan las variables independientes y por último la variable dependiente; una vez obtenida la gráfica se podrá leer en la parte inferior cada gráfica de forma individual.




Gráfica 2-1 Gráfica matricial que presenta el SPSS™.

Las gráficas individuales que arroja el SPSS™ serían:



Gráfica 2-2 Gráficas individuales que presenta el SPSS™.

(continúa)



Gráfica 2-2 Gráficas individuales que presenta el SPSS™. (*continuación*)

Como se ve en las gráficas las variables sí tienen una relación, pero la mayoría de los datos se abre mucho y tiene abanicos por lo que es necesario cerrarlos y esto se puede lograr con transformaciones. Por ejemplo, la primera gráfica (distancia) tiene una relación indirecta, pero se puede apreciar un abanico, abriéndose hacia abajo y hacia arriba, si se realiza una transformación logarítmica, inversa o con raíz cuadrada, los abanicos deben cerrarse. Es necesario realizar transformaciones ya que si no se hacen hay consecuencias en los supuestos de los errores. Otra forma sería que en lugar de realizar MCO se hiciera MCP.

Parece que la segunda (cuartos) y tercera (estudiantes) gráficas tienen una relación directa pero no lineal; es decir, un poco exponencial o se podría pensar en un modelo de polinomio avanzado. La cuarta gráfica (este) parece no tener relación; por lo que sería ideal que dicha variable sea la que se quite del modelo. La quinta gráfica (norte) parece tener una relación directa pero abriéndose en abanico. La sexta gráfica (oeste) parece tener una relación indirecta pero abriéndose en abanico nuevamente y la séptima o última gráfica (sur) indirecta o inversa y abriéndose en abanico de nuevo.

Como en la mayoría de las gráficas se tiene mucha dispersión en la variable dependiente, lo más conveniente sería que la transformación se realizara en ésta, es decir, en la variable dependiente (Y) ahora se tendría el logaritmo natural de renta ($\ln$ renta). Es importante comentar que la transformación de la variable dependiente no es necesaria cuando no se tiene este tipo de problema.

Recuerde también que de las 4 variables relacionadas con la zona, la correspondiente al este es la que tiene menos relación con la variable dependiente, por lo que conviene sacarla de la regresión.¹³

¹³ La variable “zona” es no métrica y fue convertida en 4 nuevas variables, de las cuales sólo pueden estar 3 en la regresión para evitar que haya información repetida.

2.4.3 Ecuación de regresión


El problema se centra en cómo determinar los mejores estimadores de los betas, los cuales serían las β . Para poder hacer esto es necesario conocer el término del error, el cual se representará por una ε y es definido como la diferencia entre el dato real ($DR = Y_i$) y el dato pronosticado ($DP = \hat{Y}_i$), es decir:

Ecuación 2-2 Error y residual

$$\begin{aligned}\text{Error} &= \varepsilon_i = DR_i - DP_i = Y_i - \hat{Y}_i \\ \text{Residual} &= r_i = DR_i - DP_i = y_i - \hat{y}_i\end{aligned}$$


Donde: ε_i es el error de la observación i en la población, r_i sería el residual de la observación i en la muestra, $DR = Y_i$ es el dato real en la observación i , en la población sería con mayúsculas y las minúsculas son en la muestra, y por último $DP = \hat{Y}_i$ es el dato pronosticado en la observación i , en la población sería con mayúsculas y las minúsculas son en la muestra.

Se mostrará esto con una gráfica de varias dimensiones,¹⁴ si se tuvieran sólo tres, dicha gráfica con el modelo de regresión se vería de la siguiente manera:



Gráfica 2-3 El modelo de regresión en tres dimensiones.


En la gráfica anterior se muestra el modelo de regresión, ahora se verán los datos reales y el término del error.



Gráfica 2-4 El error en tres dimensiones.

¹⁴ Una dimensión la daría una sola línea, dos dimensiones son los ejes X y Y que son las abscisas y las ordenadas, respectivamente; en tres dimensiones son el eje con la Y, los dos ejes restantes son con una de las variables, supóngase que es con X_1 y el otro eje con X_2 ; por último una gráfica de cuatro o más dimensiones es prácticamente imposible de visualizar.

Es decir, el error es la diferencia o distancia que existe entre el dato real y el pronosticado. Ahora el error¹⁵ gráficamente en sólo dos dimensiones sería lo mismo, como lo muestra la siguiente gráfica:



Gráfica 2-5 Gráfica que muestra al error en dos dimensiones.

Los datos reales se encuentran de la siguiente manera:

Tabla 2-4 Datos

Y	X_1	X_2	...	X_k
Y_1	X_{11}	X_{12}	...	X_{1k}
Y_2	X_{21}	X_{22}	...	X_{2k}
Y_3	X_{31}	X_{32}	...	X_{3k}
...	...	...	...	...
Y_n	X_{n1}	X_{n2}	...	X_{nk}

En el primer renglón está el nombre de las variables y los siguientes son los datos de cada una de éstas; además los subíndices indican el lugar que ocupan en el renglón y la columna a la que pertenecen, es decir:

X_{ij} : indica que ocupa en el renglón el lugar “ i ” de la columna “ j ”.

X_{nk} : indica que ocupa el n ésimo lugar de la columna K ; por lo que “ n ” es el número de datos y “ k ” es el número de variables independientes.

Dichas variables serán arregladas en forma matricial, las cuales estarían acomodadas de la siguiente manera:

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \dots \\ Y_n \end{bmatrix} \quad (n \times 1) \quad X = \begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ 1 & X_{31} & X_{32} & \dots & X_{3k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix} \quad (n \times p) \quad b = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \dots \\ b_k \end{bmatrix} \quad (p \times 1)$$

Figura 2-3 Matrices.

¹⁵ Error en población y residual es en la muestra.

Donde Y es el vector con las observaciones de la variable dependiente, el cual tiene “ n ” renglones y una columna; X es la matriz que contiene una columna de unos¹⁶ y en las restantes a las variables independientes, b es el vector de los mejores estimadores de los betas (β) y los paréntesis están indicando la dimensión¹⁷ de cada vector o de la matriz; en donde $p = k + 1$.

Por ejemplo: X_{21} significa que es la observación dos de la variable 1, X_{32} es la observación 3 de la variable 2. Además, la expresión del paréntesis ($n \times 1$) es la dimensionalidad del vector “ Y ”, lo cual indica que tiene “ n ” renglones y una columna ($n \times p$), que es la de la matriz “ X ” significa que dicha matriz tiene “ n ” renglones y “ p ” columnas, en donde $p = k + 1$, indica que “ k ” es el número de variables independientes, por lo que “ p ” representa el número de betas que se tendrán en la ecuación de regresión.

Los estimadores puntuales de los betas, los cuales se representan por $\hat{\beta}$ en regresión múltiple, serán calculados matricialmente, a través de la siguiente expresión:

Ecuación 2-3 Ecuación para estimar los betas

$$\hat{\beta} = (X^T X)^{-1} (X^T Y)$$

Éstos representan los estimadores puntuales, los cuales fueron calculados por medio de mínimos cuadrados, que se explican a continuación.

2.4.4 Mínimos cuadrados ordinarios (MCO) para regresión

Dado que el error se definió como dato real u observado menos dato pronosticado o esperado, es decir en la población se tendría:

$$y - \hat{y} = e$$

Se sabe que una de las propiedades del valor esperado es:

$$\sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n (\varepsilon_i) = 0$$

Entonces lo que se desea es que la suma de los errores sea igual a cero, eso se logrará siempre y cuando se obtenga un valor mínimo:

$$\min \sum_{i=1}^n (\varepsilon_i) = \min \sum_{i=1}^n (y_i - \hat{y}_i)$$

Usando esa propiedad se tiene que al elevar al cuadrado ambos lados se obtendrá un valor mínimo, lo cual también es una propiedad del valor esperado:

$$\sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Donde por definición el dato real se obtiene de la siguiente forma:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \beta_K x_K + e$$

Y el pronóstico o la estimación de Y sería representado de la siguiente manera:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \beta_K x_K$$

Lo anterior sería el modelo de regresión que se desea estimar. Al sustituir la variable pronosticada dentro de la ecuación, se tiene que:

$$\sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots + \beta_K x_K)]^2$$

¹⁶ La columna de unos es para que en forma matricial encuentre a la beta subcero.

¹⁷ Para más información sobre las matrices consultar el anexo 2.9 “Manejo de matrices”.

De acuerdo con lo estipulado en el anexo 2-1 “Regresión lineal simple”, ahora se tiene que derivar para cada una de las $\beta \cdot s$ o para cada uno de los $K + 1$ parámetros, lo que indica que se obtendrán $K + 1$ ecuaciones normales, las cuales se presentan a continuación:

$$\begin{aligned} n\beta_0 + \beta_1 \sum_{i=1}^n x_{1,i} + \beta_2 \sum_{i=1}^n x_{2,i} + \beta_3 \sum_{i=1}^n x_{3,i} + \cdots + \beta_k \sum_{i=1}^n x_{k,i} &= \sum_{i=1}^n y_i \\ \beta_0 \sum_{i=1}^n x_{1,i} + \beta_1 \sum_{i=1}^n x_{1,i}^2 + \beta_2 \sum_{i=1}^n x_{1,i}x_{2,i} + \beta_3 \sum_{i=1}^n x_{1,i}x_{3,i} + \cdots + \beta_k \sum_{i=1}^n x_{1,i}x_{k,i} &= \sum_{i=1}^n x_{1,i}y_i \\ \beta_0 \sum_{i=1}^n x_{2,i} + \beta_1 \sum_{i=1}^n x_{1,i}x_{2,i} + \beta_2 \sum_{i=1}^n x_{2,i}^2 + \beta_3 \sum_{i=1}^n x_{2,i}x_{3,i} + \cdots + \beta_k \sum_{i=1}^n x_{2,i}x_{k,i} &= \sum_{i=1}^n x_{2,i}y_i \\ \beta_0 \sum_{i=1}^n x_{3,i} + \beta_1 \sum_{i=1}^n x_{1,i}x_{3,i} + \beta_2 \sum_{i=1}^n x_{2,i}x_{3,i} + \beta_3 \sum_{i=1}^n x_{3,i}^2 + \cdots + \beta_k \sum_{i=1}^n x_{3,i}x_{k,i} &= \sum_{i=1}^n x_{3,i}y_i \end{aligned}$$

Y así sucesivamente hasta:

$$\beta_0 \sum_{i=1}^n x_{K,i} + \beta_1 \sum_{i=1}^n x_{1,i}x_{K,i} + \beta_2 \sum_{i=1}^n x_{2,i}x_{K,i} + \beta_3 \sum_{i=1}^n x_{3,i}x_{K,i} + \cdots + \beta_k \sum_{i=1}^n x_{K,i}^2 = \sum_{i=1}^n x_{K,i}y_i$$

Donde:

K : es el número de variables independientes.

n : es el número de datos de las variables.

β_j : es el parámetro a ser estimado por medio de la ecuación de regresión de la variable j .

$x_{j,i}$: es la variable j en la observación i .

y_i : es la variable dependiente en la observación i .

Entonces el número de ecuaciones tiene que ver con el número de variables independientes, por ejemplo, si se tienen 10 variables independientes, entonces se tendrían 11 ecuaciones $K + 1 = 10 + 1 = 11$, esto ocasionaría que la solución de las 10 ecuaciones se tenga que realizar por medio del método de Gauss.¹⁸

Ahora bien, en la forma matricial se tendría lo mismo pero por medio de matrices. De nuevo, para encontrar los estimadores puntuales de los betas se deben minimizar los errores mediante las propiedades del valor esperado, dado que el error se definió como dato observado menos dato esperado, es decir en matrices, se tendría:

$$Y - \hat{Y} = \varepsilon$$

En la población es error y en la muestra se definirá como residual:

$$Y - \hat{Y} = e = r$$

En regresión múltiple es preferible realizarla en forma matricial, la minimización en los errores sería:

$$\min(\varepsilon) = \min(Y - \hat{Y})$$

Minimizar significa elevar al cuadrado cada término de la expresión anterior; en matrices se logra por medio de la premultiplicación de la transpuesta por la matriz original:

$$\varepsilon^T \varepsilon = (Y - \hat{Y})^T (Y - \hat{Y})$$

En donde ε denota el vector de los errores, la Y el de los datos de la variable dependiente, la $\hat{Y}$ sería el vector de pronósticos que se desean realizar para la variable dependiente, dichos pronósticos son los estimados. Al poner todo en forma matricial se tiene lo siguiente:

$$Y = X\beta + \varepsilon \text{ y además se sabe que } \hat{Y} = X\beta$$

¹⁸ Ver anexo 2.9 “Manejo de matrices”.

En donde la X es la matriz que contiene en sus columnas a las variables independientes,¹⁹ β sería el vector de los parámetros, los cuales es necesario conocer ya que ellos servirán para poder formar una ecuación que tendría como resultado los pronósticos de la variable dependiente y la $\hat{Y}$ es el vector de lo que se desea estimar de la variable dependiente, es decir los pronósticos. Ahora bien si se sustituye el vector de los pronósticos (ya que son desconocidos) se tiene que:

$$\varepsilon^T \varepsilon = (Y - X\beta)^T(Y - X\beta)$$

Al introducir el transpuesto adentro del paréntesis se tiene que:

$$L(\beta) = (Y^T - \beta^T X^T)(Y - X\beta)$$

Al elevar al cuadrado o multiplicar el primer paréntesis por el segundo da como resultado:

$$L(\beta) = (Y^T Y - Y^T X\beta - \beta^T X^T Y + \beta^T X^T X\beta)$$

El cual es un binomio al cuadrado y además $Y^T X\beta = \beta^T X^T Y$; al sustituir este término:

$$L(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X\beta$$

Ahora se debe escoger el mejor estimador para los parámetros, el método de MCO encuentra los mejores estimadores de las betas, los cuales deberán ser aquellos que minimicen la distancia entre los datos reales y los pronosticados;²⁰ es decir, de tal manera que la suma de los errores sea de cero,²¹ la minimización se puede realizar por medio de la primera derivada:

$$\frac{\delta L(\beta)}{\delta \beta} = 0 - 2X^T Y + 2X^T X\beta$$

El resultado anterior se tiene que igualar a cero y despejar el vector de betas, ya que eso es lo que se desea encontrar:

$$-2X^T Y + 2X^T X\beta = 0$$

El primer término del lado izquierdo se agrega en forma positiva de ambos lados, por lo que el resultado quedaría de la siguiente manera:

$$2X^T X\beta = 2X^T Y$$

Al eliminar el 2 de cada lado:

$$X^T X\beta = X^T Y$$

Al agregar en ambos lados el inverso de la matriz $X^T X$ se tiene que:

$$\beta = (X^T X)^{-1}(X^T Y)$$

Por lo que los mejores estimadores de los betas serían:

$$\hat{\beta} = b = (X^T X)^{-1}(X^T Y)$$

Siguiendo con el ejemplo,²² las matrices quedarían de la siguiente manera:

¹⁹ La matriz X contiene una columna con números 1 y las demás están formadas por las variables independientes.

²⁰ Es por eso que se debe elevar al cuadrado, lo cual es una propiedad del valor esperado.

²¹ La suma de las diferencias entre el dato real y el estimado (pronosticado) sea cero, otra propiedad del valor esperado.

²² Con anterioridad se decidió que la variable renta (dependiente) debería transformarse con el logaritmo natural, es decir: $Y = \text{Ln}(\text{renta})$; además también se decidió que la variable "Este" debería salir del análisis.

Tabla 2-5 Datos finales a usar

Y	X_1	X_2	X_3	X_4	X_5	X_6
Renta	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
9.048	1	2	2	0	0	1
9.094	1	2	2	1	0	0
9.547	0.5	4	3	1	0	0
8.517	3	1	2	0	0	0
9.306	0.5	4	4	0	0	0
8.987	1	2	2	0	1	0
9.048	1	2	2	0	0	1
9.393	3	4	4	0	0	0
8.269	0.5	1	1	0	0	0
9.393	1	4	3	0	1	0
8.923	4	3	3	0	1	0
9.071	3	3	3	0	0	0
8.987	1	3	3	0	1	0
8.243	4	1	1	0	1	0
8.854	2	2	2	1	0	0
9.105	2	3	3	0	0	1
8.412	4	1	1	0	0	0
8.476	4	1	2	0	0	1
8.975	1	2	2	0	0	1
8.517	4	1	2	0	1	0
9.51	0.5	4	4	0	0	0
9.51	0.5	4	4	0	0	0
8.854	4	2	2	0	1	0
9.547	4	4	4	1	0	0

El vector Y , así como la matriz X quedarían de la siguiente manera:

$Y =$	Renta	$X =$	bo	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
	9.048		1	1	2	2	0	0	1
	9.094		1	1	2	2	1	0	0
	9.547		1	0.5	4	3	1	0	0
	8.517		1	3	1	2	0	0	0
	9.306		1	0.5	4	4	0	0	0
	8.987		1	1	2	2	0	1	0
	9.048		1	1	2	2	0	0	1
	9.393		1	3	4	4	0	0	0
	8.269		1	0.5	1	1	0	0	0
	9.393		1	1	4	3	0	1	0

Figura 2-4 Matriz X y vector Y .

(continúa)

	Renta		bo	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
$Y =$	8.923	$X =$	1	4	3	3	0	1	0
	9.071		1	3	3	3	0	0	0
	8.987		1	1	3	3	0	1	0
	8.243		1	4	1	1	0	1	0
	8.854		1	2	2	2	1	0	0
	9.105		1	2	3	3	0	0	1
	8.412		1	4	1	1	0	0	0
	8.476		1	4	1	2	0	0	1
	8.975		1	1	2	2	0	0	1
	8.517		1	4	1	2	0	1	0
	9.510		1	0.5	4	4	0	0	0
	9.510		1	0.5	4	4	0	0	0
	8.854		1	4	2	2	0	1	0
	9.547		1	4	4	4	1	0	0

Figura 2-4 Matriz X y vector Y (continuación)

La matriz X^T quedaría como sigue:

$$X^T = \begin{pmatrix} 1 & 1 \\ 1 & 1 & 0.5 & 3 & 0.5 & 1 & 1 & 3 & 0.5 & 1 & 4 & 3 & 1 & 4 & 2 & 2 & 4 & 4 & 1 & 4 & 0.5 & 0.5 & 4 & 4 \\ 2 & 2 & 4 & 1 & 4 & 2 & 2 & 4 & 1 & 4 & 3 & 3 & 3 & 1 & 2 & 3 & 1 & 1 & 2 & 1 & 4 & 4 & 2 & 4 \\ 2 & 2 & 3 & 2 & 4 & 2 & 2 & 4 & 1 & 3 & 3 & 3 & 3 & 1 & 2 & 3 & 1 & 2 & 2 & 2 & 4 & 4 & 2 & 4 \\ 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Figura 2-5 Matriz X transpuesta.

La matriz $(X^T X)$ quedaría como sigue:

$$X^T * X = \begin{pmatrix} 24 & 50.5 & 60 & 61 & 4 & 7 & 5 \\ 50.5 & 155.25 & 111.5 & 121 & 7.5 & 19 & 9 \\ 60 & 111.5 & 182 & 177 & 12 & 16 & 10 \\ 61 & 121 & 177 & 177 & 11 & 16 & 11 \\ 4 & 7.5 & 12 & 11 & 4 & 0 & 0 \\ 7 & 19 & 16 & 16 & 0 & 7 & 0 \\ 5 & 9 & 10 & 11 & 0 & 0 & 5 \end{pmatrix}$$

Figura 2-6 Matriz X transpuesta X .

La matriz $(X^T X)^{-1}$ quedaría como sigue:

$$(X^T * X)^{-1} = \begin{bmatrix} 0.7142 & -0.0619 & 0.0068 & -0.1710 & -0.1481 & -0.1707 & -0.2400 \\ -0.0619 & 0.0316 & 0.0532 & -0.0499 & -0.0195 & -0.0312 & 0.0086 \\ 0.0068 & 0.0532 & 0.3305 & -0.3531 & -0.1268 & -0.0993 & 0.0135 \\ -0.1710 & -0.0499 & -0.3531 & 0.4298 & 0.1420 & 0.1312 & 0.0215 \\ -0.1481 & -0.0195 & -0.1268 & 0.1420 & 0.4244 & 0.1662 & 0.1243 \\ -0.1707 & -0.0312 & -0.0993 & 0.1312 & 0.1662 & 0.3253 & 0.1368 \\ -0.2400 & 0.0086 & 0.0135 & 0.0215 & 0.1243 & 0.1368 & 0.3503 \end{bmatrix}$$

Figura 2-7 Matriz X transpuesta X inversa.

El vector $(X^T Y)$ quedaría como sigue:

$$(X^T Y)^{-1} = \begin{bmatrix} 215.584 \\ 447.347 \\ 549.231 \\ 555.802 \\ 37.041 \\ 61.903 \\ 44.652 \end{bmatrix}$$

Figura 2-8 Vector X transpuesta Y.

El vector $(X^T X)^{-1}(X^T Y)$ quedaría como sigue:

$$\hat{\beta} = b = (X^T Y)^{-1} = \begin{bmatrix} 8.162 \\ -0.038 \\ 0.237 \\ 0.089 \\ 0.214 \\ 0.039 \\ 0.167 \end{bmatrix} = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \\ b_4 \\ b_5 \\ b_6 \end{bmatrix} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \\ \hat{\beta}_4 \\ \hat{\beta}_5 \\ \hat{\beta}_6 \end{bmatrix}$$

Figura 2-9 Vector final donde se indican los valores estimados.

Por lo que cada término encontrado es el coeficiente que corresponde a cada variable, es decir, el modelo de regresión múltiple es:

Ecuación 2-4 Modelo de regresión

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \beta_6 X_6$$

En donde los mejores estimadores de los β serían los valores encontrados, esto se representa de la siguiente manera en la función:

Ecuación 2-5 Función de regresión

$$\hat{Y} = b_0 + b_1 X_1 + b_2 X_2 + b_3 X_3 + b_4 X_4 + b_5 X_5 + b_6 X_6$$

Al sustituir los valores encontrados y para nombrar a las variables se les puso la primera letra de su nombre, así se tiene que la ecuación para estimar la renta es la siguiente:

Ecuación 2-6 Función final

$$\hat{R} = 8.162 - 0.038 * D + 0.237 * C + 0.089 * E + 0.214 * N + 0.039 * O + 0.167 * S$$

La interpretación de cada coeficiente (asumiendo que las demás variables son constantes) sería:

8.162	es donde la función corta el eje Y, es decir de la variable dependiente.
-0.038 * Distancia	por cada kilómetro más, el logaritmo natural de la renta bajará 0.038, es decir entre más lejos del TEC el logaritmo natural de la renta bajará.
0.237 * Cuartos	quiere decir que por cada cuarto extra, el logaritmo natural de la renta subirá 0.237, lo que significa que entre más cuartos el logaritmo natural de la renta sube.
0.089 * Estudiantes	significa que por cada estudiante extra, el logaritmo natural de la renta subirá 0.089, es decir entre más estudiantes el logaritmo natural de la renta sube.
0.214 * Norte	donde si se cambiara a la zona norte el logaritmo natural de la renta subiría 0.214.
0.039 * Oeste	significa que si se cambiara a la zona oeste el logaritmo natural de la renta subiría 0.039.
0.167 * Sur	quiere decir que si se cambiara a la zona sur el logaritmo natural de la renta subiría 0.167.

Es importante recordar que la variable dependiente fue transformada a logaritmo natural, por lo que los betas están también en forma logarítmica, si se desea ver el impacto real, es necesario quitarles esa transformación por medio del exponencial; a continuación se dan los valores transformados:

Además, cuando todas las variables $X \cdot s$ tienen el valor de cero Y (variable dependiente) tendrían el valor de β_0 , por lo que β_0 es el valor medio estimado de Y . A continuación se presentan los coeficientes sin la transformación logarítmica realizada:

Tabla 2-6 Coeficientes transformados

Distancia	0.963
Cuartos	1.268
Estudiantes	1.093
Norte	1.238
Oeste	1.040
Sur	1.181

Los resultados en el SPSS[™] se presentan en la tabla de coeficientes,²³ parte de ésta se muestra a continuación:

Tabla 2-7 Coeficientes

		Coeficientes no estandarizados	
Modelo		B	Error típ.
1	(Constante)	8.162	.105
	Distancia	-.038	.022
	Cuartos	.237	.071
	Estudiantes	.089	.081
	Norte	.214	.081
	Oeste	.039	.071
	Sur	.167	.074

²³ En el anexo 2.7 "Tabla Shapiro Wilk" se explica el procedimiento para realizar la regresión en el SPSS[™].

2.4.5 Colinealidad o multicolinealidad

Colinealidad. Surge cuando dos variables independientes se relacionan entre sí, ya sea linealmente o no.


Multicolinealidad. Es cuando dos o más de dos variables independientes están correlacionadas, es decir, no son independientes entre sí.

La **colinealidad** surge cuando 2 variables independientes están correlacionadas (ya sea linealmente o no); se llama **multicolinealidad** cuando dos o más de dos variables independientes ($X \cdot s$) están correlacionadas; es decir, no son independientes entre sí.

¿Qué problemas puede ocasionar la multicolinealidad?

- Imprecisión en los pronósticos cuando la función de regresión es utilizada.
- Los estimadores de los betas por el método de mínimos cuadrados ordinarios hacen que las varianzas y covarianzas de éstas sean grandes, por lo que dichas estimaciones son precisas.
- Por lo anterior, los errores estándar de los betas se vuelven muy grandes y como consecuencia las t_c se convierten en no significativas, es decir no se rechaza la hipótesis nula; también puede ocasionar en algunos casos o valores de la t sean grandes y otros pequeños.
- Por los dos anteriores, los intervalos de confianza de los betas se vuelven más amplios, lo que hace posible que se acepte la hipótesis nula.
- Puede ocasionar que los coeficientes de determinación estén inflados, es decir más altos de lo debido.
- Los signos de los betas cambian.
- Si la multicolinealidad es perfecta, entonces la matriz $X^T X$ es singular,²⁴ es decir que no se pueda invertir, ya que su determinante es cero; teniendo como consecuencia que los coeficientes de regresión no puedan ser calculados o si su determinante es cercano a cero dichos coeficientes son menos precisos y se vuelven inestables.

Existen muchas maneras de medir o detectar la multicolinealidad, todas miden la dependencia lineal, por lo tanto, no detectan problemas de multicolinealidad cuando la relación entre las variables sea no lineal. En este capítulo sólo se verán unas cuantas maneras de cómo detectar la multicolinealidad:



Dibujo 2-1 Formas de detectar la multicolinealidad.

2.4.6 Correlación entre variables independientes

La correlación entre las $X \cdot s$ se denota por:

$$R_{ij} = r_{ij}$$

Donde R_{ij} muestra la correlación bivariada²⁵ entre la variable X_i y la variable X_j . Entonces R_{ij} mide la dependencia lineal entre variables, en este caso se usa exclusivamente para las independientes. En los modelos de regresión múltiple se desea que no exista este tipo de problemas, por lo que el coeficiente de correlación puede ser usado para medir la multicolinealidad.

²⁴ La matriz $X^T X$ se tiene que invertir para encontrar los coeficientes de la ecuación y para poder encontrar la inversa se necesita el determinante, sobre el tema de matrices, se puede ver en el anexo 2.9 “Manejo de matrices” de este capítulo.

²⁵ Porque se está encontrando la relación entre dos variables.

La correlación oscila entre:

$$-1 \leq R_{ij} \leq 1$$

Entonces en términos absolutos tendríamos:

$$0 \leq |R_{ij}| \leq 1$$

Donde $|R_{ij}|$ denota el valor absoluto de cada correlación, si ésta la medimos en términos absolutos, ciertos criterios establecidos indican que existen problemas de multicolinealidad, si la correlación entre dos o más variables es mayor o igual a 70%, es decir:

$$|R_{ij}| \geq 0.7$$

Por lo que la correlación entre dos variables independientes no debe ser mayor a 0.7 en términos absolutos, esto es no interesa el signo.

El análisis de correlación es utilizado para medir la relación lineal bivariada²⁶ (o fuerza de asociación entre dos variables), dicho coeficiente indica en términos porcentuales qué tanto una variable está relacionada con otra variable linealmente, la fórmula para calcular la correlación es:

Ecuación 2-7 Coeficiente de correlación

$$r_{X_A, X_B} = R_{X_A, X_B} = \frac{SP_{X_A, X_B}}{\sqrt{SS_{X_A} SS_{X_B}}}$$

Donde:

R_{X_A, X_B} : es la correlación de Pearson y es bivariada, es decir entre la variable A y la variable B.

SP_{X_A, X_B} : es la suma de los productos cruzados entre la variable A y la variable B.

SS_{X_A} : es la suma de cuadrados de la variable A.

SS_{X_B} : es la suma de los cuadrados de la variable B.

Al sustituir las fórmulas en las covarianzas y en las varianzas, se tiene:


$$R_{X_A, X_B} = \frac{\sum_{i=1}^n (X_{Ai} - \bar{X}_A)(X_{Bi} - \bar{X}_B)}{\sqrt{\sum_{i=1}^n (X_{Ai} - \bar{X}_A)^2} \sqrt{\sum_{i=1}^n (X_{Bi} - \bar{X}_B)^2}}$$

Con las fórmulas reducidas sería:

$$R_{X_A, X_B} = \frac{\sum_{i=1}^n X_{Ai} X_{Bi} - n\bar{X}_A \bar{X}_B}{\sqrt{\sum_{i=1}^n X_{Ai}^2 - n\bar{X}_A^2} \sqrt{\sum_{i=1}^n X_{Bi}^2 - n\bar{X}_B^2}}$$

Valores cercanos a menos 1 (−1) indican que las dos variables tienen una relación inversa, un valor cercano a cero significa que las variables no están asociadas o que no tienen una relación, un valor cercano a 1 señala que hay una fuerte asociación o relación lineal entre las dos variables y que la relación es directa. Las siguientes gráficas muestran el tipo de relación:





Tabla 2-8 De correlaciones entre variables

	Existe una relación lineal perfecta entre la X_1 y la X_2, pero directa; lo que significa que la relación entre ambas es de 100%; por lo que su $R = 1$.
---	--

(continúa)

²⁶ Medir la fuerza de asociación lineal no significa que la relación no sea no lineal.

Tabla 2-8 De correlaciones entre variables (*continuación*)

	Existe una relación lineal perfecta entre la X_1 y la X_2 , pero inversa o indirecta; lo cual indica que la relación entre ambas es de 100%; por lo que su $R = -1$.
	Existe una relación lineal casi perfecta entre la X_1 y la X_2 , pero directa; lo que significa que ambas variables están relacionadas, pero menos de 100%; por lo que su $0 < R < 1$, pero es más cercano a 1 que a cero.
	Existe una relación lineal casi perfecta entre la X_1 y la X_2 , pero inversa o indirecta; lo cual indica que ambas variables están relacionadas pero menos de 100%; por lo que su $-1 < R < 0$, pero es más cercano a menos 1 que a cero.
	No existe una relación lineal entre la X_1 y la X_2 ; lo cual significa que la X_1 no tiene nada de relación con la X_2 ; por lo que su $R = 0$.

El coeficiente puede ser estimado hacia la población como $R = \hat{\rho}$.

Para calcular dicho coeficiente se usarán las primeras dos variables, es decir *distancia* y *cuartos*, la información necesaria de ellas es la siguiente:

Tabla 2-9 Datos

X_1	X_2	$X_1 * X_2$	X_1^2	X_2^2
Distancia	Cuartos	Distancia	Distancia	Cuartos
1	2	2	1	8
1	2	2	1	8
0.5	4	2	0.25	64
3	1	3	9	1
0.5	4	2	0.25	64
1	2	2	1	8
1	2	2	1	8
3	4	12	9	64
0.5	1	0.5	0.25	1

(*continúa*)

(continuación)

X_1	X_2	$X_1 * X_2$	X_1^2	X_2^2
Distancia	Cuartos	Distancia	Distancia	Cuartos
1	4	4	1	64
4	3	12	16	27
3	3	9	9	27
1	3	13	1	27
4	1	4	16	1
2	2	4	4	8
2	3	6	4	27
4	1	4	16	1
4	1	4	16	1
1	2	2	1	8
4	1	4	16	1
0.5	4	2	0.25	64
0.5	4	2	0.25	64
4	2	8	16	8
4	4	16	16	64
Suma =	50.5	60	111.5	155.25
Promedio =	2.104	2.500		

Al sustituir los valores en la fórmula se tiene que:

$$R_{X_A, X_B} = \frac{\sum_{i=1}^n X_{Ai} X_{Bi} - n \bar{X}_A \bar{X}_B}{\sqrt{\sum_{i=1}^n X_{Ai}^2 - n \bar{X}_A^2} \sqrt{\sum_{i=1}^n X_{Bi}^2 - n \bar{X}_B^2}}$$

Por lo que:

$$R_{X_1, X_2} = \frac{111.55 - 24 * 2.104 * 2.5}{\sqrt{155.25 - 10 * (2.104)^2} \sqrt{618 - 10 * (2.5)^2}}$$

Entonces:

$$R_{X_1, X_2} = -0.373$$

Note que el valor es negativo, lo cual significa que entre distancia y cuartos existe una relación inversa, además, como el coeficiente es cercano a cero, se podría indicar que dichas variables no se encuentran relacionadas, pero para poder afirmar esto es necesario realizar una prueba de hipótesis, la cual indicaría si la asociación lineal es bastante alta o no. A continuación se realizará un análisis de correlación:

Los resultados de las correlaciones que el SPSS™ da como resultados se presentan en la siguiente tabla:

Tabla 2-10 Correlaciones

		Ln renta	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Correlación de Pearson	Ln renta	1.000	-.461	.933	.862	.313	-.225	-.068
	Distancia	-.461	1.000	-.373	-.224	-.072	.274	-.109
	Cuartos	.933	-.373	1.000	.924	.194	-.119	-.222
	Estudiantes	.862	-.224	.924	1.000	.097	-.172	-.183
	Norte	.313	-.072	.194	.097	1.000	-.287	-.229
	Oeste	-.225	.274	-.119	-.172	-.287	1.000	-.329
	Sur	-.068	-.109	-.222	-.183	-.229	-.329	1.000
Sig. (unilateral)	Ln renta	—	.012	.000	.000	.069	.145	.377
	Distancia	.012	—	.037	.146	.370	.098	.306
	Cuartos	.000	.037	—	.000	.182	.290	.148
	Estudiantes	.000	.146	.000	—	.325	.211	.196
	Norte	.069	.370	.182	.325	—	.087	.140
	Oeste	.145	.098	.290	.211	.087	—	.058
	Sur	.377	.306	.148	.196	.140	.058	—
N	Ln renta	24	24	24	24	24	24	24
	Distancia	24	24	24	24	24	24	24
	Cuartos	24	24	24	24	24	24	24
	Estudiantes	24	24	24	24	24	24	24
	Norte	24	24	24	24	24	24	24
	Oeste	24	24	24	24	24	24	24
	Sur	24	24	24	24	24	24	24

Por lo que una vez encontrado el coeficiente es posible realizar una prueba de hipótesis con él, siempre y cuando la relación sea bivariada.

2.4.6.1 Prueba de hipótesis t relativa a ρ

Los requisitos para realizar la prueba de hipótesis son que las variables provengan de poblaciones bivariadas normales y que sean observables. La prueba de la correlación se realiza para probar si dos variables están correlacionadas linealmente o no; es decir, mide la fuerza de dicha asociación. Las hipótesis para realizar el análisis de correlación son las siguientes:

$$H_0: \rho = 0$$

$$H_1: \rho \neq 0$$

En donde a H_0 se le llama *hipótesis nula*, se dice que es H cero y que H_1 es la hipótesis alternativa o alterna y se dice que es $H 1$ o también se le puede representar por H_a . Siempre que se realiza una prueba de hipótesis debe tenerse un estadístico de prueba, el cual se compara contra el estadístico de tablas o teórico para tomar una decisión. Una vez que se tienen las hipótesis, lo siguiente sería contar con el estadístico de prueba, el cual es:

Ecuación 2-8 Estadístico de prueba de correlación

$$t_c = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$$

Donde:

$R_{j,i}$: es la correlación bivariada; es decir, entre dos variables, en este caso serían la variable j y la variable i .

n : es el número de datos de las variables.

La hipótesis nula indica que la correlación o la fuerza de asociación entre las dos variables es nula,²⁷ es decir no existe correlación; la hipótesis alterna indicaría que hay correlación lineal entre las dos variables, por lo que si esto es cierto existe colinealidad entre ellas. La prueba puede realizarse de dos extremos (bilateral) o de uno solo (unilateralmente), ya sea mayor que, si la correlación es positiva, y menor que, si la correlación es negativa. Dicha prueba consta de 5 pasos, enlistados a continuación:

El primero sería enunciar las hipótesis:

$$H_0 : \rho = 0$$

$$H_1 : \rho < 0$$

El segundo es encontrar el valor del estadístico calculado, lo cual implica que se sustituye la información en el estadístico de prueba; la información requerida se encuentra en la siguiente tabla:

Tabla 2-11 Correlaciones entre las variables

		Ln renta	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Correlación de Pearson	Ln renta	1.000	-.461	.933	.862	.313	-.225	-.068
	Distancia	-.461	1.000	-.373	-.224	-.072	.274	-.109
	Cuartos	.933	-.373	1.000	.924	.194	-.119	-.222
	Estudiantes	.862	-.224	.924	1.000	.097	-.172	-.183
	Norte	.313	-.072	.194	.097	1.000	-.287	-.229
	Oeste	-.225	.274	-.119	-.172	-.287	1.000	-.329
	Sur	-.068	-.109	-.222	-.183	-.229	-.329	1.000
Sig. (unilateral)	Ln renta	—	.012	.000	.000	.069	.145	.377
	Distancia	.012	—	.037	.146	.370	.098	.306
	Cuartos	.000	.037	—	.000	.182	.290	.148
	Estudiantes	.000	.146	.000	—	.325	.211	.196
	Norte	.069	.370	.182	.325	—	.087	.140
	Oeste	.145	.098	.290	.211	.087	—	.058
	Sur	.377	.306	.148	.196	.140	.058	—
N	Ln renta	24	24	24	24	24	24	24
	Distancia	24	24	24	24	24	24	24
	Cuartos	24	24	24	24	24	24	24
	Estudiantes	24	24	24	24	24	24	24
	Norte	24	24	24	24	24	24	24
	Oeste	24	24	24	24	24	24	24
	Sur	24	24	24	24	24	24	24

²⁷ Si no se rechaza la hipótesis nula, no existe correlación (lineal) entre las variables, pero puede que exista una relación no lineal o que no exista ningún tipo de relación entre ellas.

El procedimiento para calcular el estadístico de prueba se muestra a continuación.

$$t_c = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$$

Da como resultado:

$$t_c = \frac{-0.373\sqrt{2_{4-2}}}{\sqrt{1-(-0.373)^2}} = -1.88_3$$

El tercer paso sería buscar el valor del estadístico teórico. Al suponer que se realiza la prueba con 95% de confianza, el nivel de significancia es de 5%. El estadístico teórico sería:


$$t_{t,\alpha,n-p}$$

Entonces al sustituir el nivel de significancia y los grados de libertad en el estadístico teórico tendríamos:


$$t_{t,\alpha=0.05,n-p=2_4-2=2_2}$$

Pero con la prueba de un solo extremo, la significancia sería el doble ($2 * 0.05 = 0.10$), o bien al usar 0.05; es decir, en la tabla se puede buscar de dos maneras:

Tabla 2-12 Parte de la tabla t-student²⁸



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.706	31.821	63.657	127.321	318.309	636.619	1 273.239
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	14.089	22.327	31.599	44.705
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	7.453	10.215	12.924	16.326
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
22	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792	4.077
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.768	4.047
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745	4.021
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Por lo que si se busca el estadístico teórico por arriba de la tabla sería:

$$t_{t,\alpha=(20.05)=0.10,n-p=2_4-2=2_2} = 1.71_7$$


Si se busca el estadístico por la parte de abajo de la tabla sería:

$$t_{t,\alpha=0.05,n-p=2_4-2=2_2} = 1.71_7$$


²⁸ La tabla t se encuentra en el anexo 2.2 "Tabla t" de este capítulo.

Como es de un solo extremo sería doble, es decir:

Tabla 2-13 Parte de la tabla t-student²⁹



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.706	31.821	63.657	127.321	318.309	636.619	1 273.239
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	14.089	22.327	31.599	44.705
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	7.453	10.215	12.924	16.326
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
22	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792	4.077
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.768	4.047
24	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745	4.021
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



El cuarto paso de la prueba de hipótesis sería tomar una decisión:


Para rechazar la H_0 es necesario que,

$$|t_c| > t_{t,\alpha,n-p}$$

Por lo que:

$$1.883 > 1.717 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico calculado caiga en la zona de rechazo:



Ahora bien, note que la tabla de las correlaciones en la segunda parte contiene los p -valores, si se usan éstos se tendría que para rechazar la H_0 es necesario que:

$$p - \text{valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.037 < 0.05 \text{ se rechaza } H_0$$

²⁹ La tabla t se encuentra en el anexo 2.2 "Tabla t" de este capítulo.

El quinto y último paso de la prueba de hipótesis sería dar una conclusión de lo encontrado, la cual es: al rechazar la hipótesis nula se concluye que las variables distancia y cuartos están relacionadas significativamente, por lo que la asociación (o correlación) entre ellas es lineal; si distancia y cuartos tienen relación, esto indica que existe colinealidad entre ellas.

Ahora se realizará la misma prueba, pero entre todas las parejas de las variables independientes, esto se hará con los p -valores, los cuales se encuentran en la siguiente tabla:

Tabla 2-14 Correlaciones entre las variables

		Ln renta	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Correlación de Pearson	Ln renta	1.000	-.461	.933	.862	.313	-.225	-.068
	Distancia	-.461	1.000	-.373	-.224	-.072	.274	-.109
	Cuartos	.933	-.373	1.000	.924	.194	-.119	-.222
	Estudiantes	.862	-.224	.924	1.000	.097	-.172	-.183
	Norte	.313	-.072	.194	.097	1.000	-.287	-.229
	Oeste	-.225	.274	-.119	-.172	-.287	1.000	-.329
	Sur	-.068	-.109	-.222	-.183	-.229	-.329	1.000
	Sig. (unilateral)							
Sig. (unilateral)	Ln renta	—	.012	.000	.000	.069	.145	.377
	Distancia	.012	—	.037	.146	.370	.098	.306
	Cuartos	.000	.037	—	.000	.182	.290	.148
	Estudiantes	.000	.146	.000	—	.325	.211	.196
	Norte	.069	.370	.182	.325	—	.087	.140
	Oeste	.145	.098	.290	.211	.087	—	.058
	Sur	.377	.306	.148	.196	.140	.058	—
	N							
N	Ln renta	24	24	24	24	24	24	24
	Distancia	24	24	24	24	24	24	24
	Cuartos	24	24	24	24	24	24	24
	Estudiantes	24	24	24	24	24	24	24
	Norte	24	24	24	24	24	24	24
	Oeste	24	24	24	24	24	24	24
	Sur	24	24	24	24	24	24	24

Todo estadístico de prueba tiene una probabilidad, la cual es llamada *valor-p* o *p-valor*, al usar dicho valor se tendría que rechazar la H_0 si:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Valor- p entre distancia y estudiantes:

$0.146 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre distancia y norte:

$0.370 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre distancia y oeste:

$0.098 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre distancia y sur:

$0.306 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre cuartos y estudiantes:

$0.000 < 0.05$ sí se rechaza H_0 , ambas variables tienen colinealidad.

Valor- p entre cuartos y norte:

$0.182 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre cuartos y sur:

$0.148 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre estudiantes y norte:

$0.325 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre estudiantes y oeste:

$0.211 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre estudiantes y sur:

$0.196 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre norte y oeste:

$0.087 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre norte y sur:

$0.140 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

Valor- p entre oeste y sur:

$0.058 > 0.05$ no se rechaza H_0 , ambas variables no tienen colinealidad.

En resumen existe multicolinealidad entre cuartos y distancia, así como entre estudiantes y cuartos.

En el SPSS™ la matriz de correlación entre los betas también se puede usar para medir la correlación entre ellos y así saber cuáles tienen multicolinealidad.³⁰

Tabla 2-15 Correlaciones entre los coeficientes^a

Modelo			Sur	Distancia	Norte	Estudiantes	Oeste	Cuartos
1	Correlaciones	Sur	1.000	.081	.322	.056	.405	.040
		Distancia	.081	1.000	-.169	-.429	-.308	.521
		Norte	.322	-.169	1.000	.332	.447	-.338
		Estudiantes	.056	-.429	.332	1.000	.351	-.937
		Oeste	.405	-.308	.447	.351	1.000	-.303
		Cuartos	.040	.521	-.338	-.937	-.303	1.000
	Covarianzas	Sur	.005	.000	.002	.000	.002	.000
		Distancia	.000	.000	.000	-.001	.000	.001
		Norte	.002	.000	.007	.002	.000	.001
		Estudiantes	.000	-.001	.002	.007	.002	-.005
		Oeste	.002	.000	.003	.002	.005	-.002
		Cuartos	.000	.001	-.002	-.005	-.002	.005

^a Variable dependiente: Ln_renta.

³⁰ Si un beta está correlacionado con otro, entonces existe multicolinealidad entre esas variables, es decir, entre las variables que contienen esos betas.

2.4.7 Factor de inflación de varianzas

Factor de inflación de varianzas. Es un indicador de cuánto las varianzas de los β crecen y se vuelven imprecisas.

Al **factor de inflación de varianzas** también se le conoce como *FIV* o *VIF* (por sus siglas en inglés); es un indicador de cuánto las varianzas de los β crecen y se vuelven imprecisas. Este valor se puede encontrar por medio de la siguiente ecuación:

Ecuación 2-9 VIF

$$VIF_i = \frac{1}{1 - R_i^2}$$

Donde:

R_i : es la correlación múltiple al cuadrado³¹ de la regresión que se realizó con la X_i como variable dependiente y las demás variables como independientes.

VIF_i : es el factor de inflación de varianzas de la variable i y dichas variables deben ser las independientes.

Por ejemplo, supóngase que se realizó una regresión múltiple y se usó como variable dependiente a distancia y las demás variables como independientes; al tomar en cuenta que la variable renta no debe entrar en el proceso, la salida del SPSS[™] se muestra a continuación:

Tabla 2-16 Resumen del modelo; se usa al factor distancia como variable dependiente

Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación
1	.594 ^a	.353	.173	1.327

^a Variables predictoras: (constante), sur, estudiantes, norte, oeste, cuartos.

El *VIF* de la variable distancia sería:

$$VIF_{\text{Distancia}} = \frac{1}{1 - R_i^2} = \frac{1}{1 - (0.594)^2} = \frac{1}{1 - 0.353} = 1.546$$

También se pudo haber usado la R^2 que viene en la tabla anterior, ésta se llama *coeficiente de determinación*, del cual se hablará posteriormente en este capítulo. El proceso se vuelve repetitivo hasta obtener el *VIF* de cada una de las variables independientes, pero siempre recordando que para encontrar el *VIF* de alguna variable se debe realizar una regresión con esta variable como dependiente y las demás X como independientes.

El *VIF* oscila entre 1 e infinito. Un valor de 1 significa que la variable X es independiente, es decir, que no depende de ninguna otra que se encuentre en el análisis; un valor mayor a 1 significa que el coeficiente (β) que acompaña a la variable independiente se vuelve inestable ya que su varianza ha sido inflada por estar relacionada con otra variable X . Como máximo se deberá tener un valor menor a 3; es decir $1 \leq VIF < 3$. Un valor del $VIF \geq 10$ implica problemas severos de multicolinealidad, por lo tanto, con valores intermedios como $3 \leq VIF < 10$ se tienen problemas de multicolinealidad no tan severos o débiles.

Otra forma para encontrar el *VIF*, y más rápidamente, sería por la vía matricial, su fórmula se presenta a continuación:

Ecuación 2-10 VIF

$$VIF = (R)^{-1} = C_{jj}$$

³¹ Al coeficiente de correlación al cuadrado se le denomina *coeficiente de determinación* y es un estimador de la proporción de la variación que capta el modelo de regresión. Posteriormente en este capítulo se ilustrará la forma en que se puede calcular, así como su significado y su interpretación.

Donde R es la matriz de correlación, que se forma a partir de todas las correlaciones bivariadas entre todas las variables independientes. Al encontrar la inversa de dicha matriz se conoce el VIF , ya que la diagonal principal de ella, que serían los C_{jj} , son los factores de inflación de varianza.

Para encontrar el VIF sólo se necesitan las correlaciones entre las variables independientes, dichos valores se acomodaron en forma matricial, como lo muestra la siguiente tabla:

Tabla 2-17 Correlaciones

	Ln renta	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Ln renta	1	-0.461	0.933	0.862	0.313	-0.225	-0.068
Distancia	-0.461	1	-0.373	-0.224	-0.072	0.274	-0.109
Cuartos	0.933	-0.373	1	0.924	0.194	-0.119	-0.222
Estudiantes	0.862	-0.224	0.924	1	0.097	-0.172	-0.183
Norte	0.313	-0.072	0.194	0.097	1	-0.287	-0.229
Oeste	-0.225	0.274	-0.119	-0.172	-0.287	1	-0.329
Sur	-0.068	-0.109	-0.222	-0.183	-0.229	-0.329	1

Es importante que la variable dependiente no se tome en cuenta para encontrar la inversa de la matriz, la cual es la siguiente:

Tabla 2-18 Inversa de la matriz de correlación

	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Distancia	1.546	2.106	-1.637	-0.250	-0.486	0.119
Cuartos	2.106	10.575	-9.361	-1.309	-1.251	0.152
Estudiantes	-1.637	-9.361	9.438	1.215	1.369	0.201
Norte	-0.250	-1.309	1.215	1.415	0.676	0.452
Oeste	-0.486	-1.251	1.369	0.676	1.613	0.606
Sur	0.119	0.152	0.201	0.452	0.606	1.387

El VIF sale de la diagonal principal de esa matriz, esto es:

Tabla 2-19 Mostrando los VIF

	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
Distancia	1.546	2.106	-1.637	-0.250	-0.486	0.119
Cuartos	2.106	10.575	-9.361	-1.309	-1.251	0.152
Estudiantes	-1.637	-9.361	9.438	1.215	1.369	0.201
Norte	-0.250	-1.309	1.215	1.415	0.676	0.452
Oeste	-0.486	-1.251	1.369	0.676	1.613	0.606
Sur	0.119	0.152	0.201	0.452	0.606	1.387

Entonces existe multicolinealidad en las variables cuartos y estudiantes ya que son los únicos valores mayores o iguales a 3.

Otra forma de encontrar el VIF es en la matriz de correlación entre los parámetros,³² a esa matriz se le encuentra la inversa y en la diagonal estaría el VIF .

³² En la matriz de correlación entre los betas en el SPSS™ aparece en la tabla de *Coefficient correlations* o correlación de los coeficientes.

Tabla 2-20 Correlaciones de los betas

Correlaciones de los coeficientes ^a								
Modelo			Sur	Distancia	Norte	Estudiantes	Oeste	Cuartos
1	Correlaciones	Sur	1.000	.081	.322	.056	.405	.040
		Distancia	.081	1.000	-.169	-.429	-.308	.521
		Norte	.322	-.169	1.000	.332	.447	-.338
		Estudiantes	.056	-.429	.332	1.000	.351	-.937
		Oeste	.405	-.308	.447	.351	1.000	-.303
		Cuartos	.040	.521	-.338	-.937	-.303	1.000

^a Variable dependiente: Ln_renta.

En el SPSS™ el VIF^{33} se encuentra en la tabla de los coeficientes:

Tabla 2-21 VIF de cada variable

Coeficientes ^a									
Modelo		Coeficientes no estandarizados		Coeficientes estandarizados		Intervalo de confianza para B al 95%		Estadísticos de colinealidad	
		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia
1	(Constante)	8.162	.105		77.765	.000	7.940	8.383	
	Distancia	-.038	.022	-.135	-1.704	.107	-.084	.009	.647
	Cuartos	.237	.071	.690	3.324	.004	.087	.388	.095
	Estudiantes	.089	.081	.213	1.088	.292	-.083	.260	.106
	Norte	.214	.081	.200	2.639	.017	.043	.384	.707
	Oeste	.039	.071	.044	.547	.591	-.111	.188	.620
	Sur	.167	.074	.170	2.269	.037	.012	.322	.721

^a Variable dependiente: Ln_renta.

El VIF siempre viene acompañado de una tolerancia, la cual se define como la inversa del VIF :

Ecuación 2-11 Tolerancia

$$T_i = \frac{1}{VIF_i}$$

Donde:

T_i : es la tolerancia de la variable i .

VIF_i : es el factor de inflación de varianzas de la variable i y dichas variables deben ser independientes.

La tolerancia siempre toma valores entre $0 < T_i \leq 1$. Un valor cercano a 1 indicaría que la variable es tolerada y un valor cercano a 0 significaría lo contrario; como límite se considera que sea mayor a 1/3 por lo que un valor menor a éste y cercano a 0 indicaría que no es bueno que dicha variable se encuentre en el modelo de regresión.

Suponga que se desea saber la tolerancia de la variable cuartos, como ya se había visto con anterioridad, en el SPSS™ el VIF se encuentra en la tabla de los coeficientes:

³³ FIV o VIF , por sus siglas en inglés.

Tabla 2-22 VIF de cada variable

Coeficientes ^a										
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B al 95%		Estadísticos de colinealidad	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia	FIV
1	(Constante)	8.162	.105		77.765	.000	7.940	8.383		
	Distancia	−.038	.022	−.135	−1.704	.107	−.084	.009	.647	1.546
	Cuartos	.237	.071	.690	3.324	.004	.087	.388	.095	10.575
	Estudiantes	.089	.081	.213	1.088	.292	−.083	.260	.106	9.438
	Norte	.214	.081	.200	2.639	.017	.043	.384	.707	1.415
	Oeste	.039	.071	.044	.547	.591	−.111	.188	.620	1.613
	Sur	.167	.074	.170	2.269	.037	.012	.322	.721	1.387

^a Variable dependiente: Ln_renta.

Entonces el $VIF_{\text{Cuartos}} = 10.575$ por lo que la tolerancia de dicha variable sería:

$$T_{\text{Cuartos}} = \frac{1}{VIF_{\text{Cuartos}}} = \frac{1}{10.575} = 0.095$$

El valor anterior es menor a 1/3 por lo que tiene problemas de colinealidad. Al revisar los demás valores, se identifica que también hay problemas de colinealidad entre las variables cuartos y estudiantes.

2.4.7.1 Cambios en los signos de los coeficientes

Los cambios en los signos de los coeficientes se deberán verificar en cada beta en la tabla correspondiente; el modelo³⁴ no deberá perder la lógica.

Siguiendo el ejemplo de la renta de viviendas cercanas al Tec, se tienen los siguientes coeficientes:

Tabla 2-23 Tabla de los coeficientes

Coeficientes ^a		
		Coeficientes núm.
Modelo		B
1	(Constante)	8.162
	Distancia	-.038
	Cuartos	.237
	Estudiantes	.089
	Norte	.214
	Oeste	.039
	Sur	.167

^a Variable dependiente: Ln_renta.

Como la variable dependiente fue convertida a logaritmo, a los coeficientes se les debe quitar éste, así los datos serían los siguientes:

³⁴ Función o ecuación.

Tabla 2-24 Coeficientes sin logaritmo

Distancia	0.963
Cuartos	1.268
Estudiantes	1.093
Norte	1.238
Oeste	1.040
Sur	1.181

1. Entre más cerca del Tec esté la casa mayor será la renta y entre más lejos se ubique el costo bajará. En este caso se está proponiendo una relación inversa, por lo que la beta que acompañe a la variable distancia deberá tener signo negativo; al revisar la tabla de los coeficientes se ve que en efecto tiene signo negativo, pero en la tabla de coeficientes sin logaritmo la beta de esta variable es positiva, por lo que el modelo pierde lógica.
2. Entre más habitaciones tengan las casas, la renta aumentará y mientras menos cuartos haya disminuirá. Lo que indica que se está proponiendo una relación directa, por lo que la beta que acompañe a esa variable deberá tener signo positivo; al revisar las tablas los resultados coinciden.
3. Entre más estudiantes renten una casa, ésta deberá tener más recámaras, por lo que la renta sería más costosa y mientras menos estudiantes sean menos habitaciones necesitarán por lo que la renta será menor. En este caso se está proponiendo una relación directa, así la beta que acompañe a esa variable deberá tener signo positivo, lo cual es congruente con los resultados.
4. La zona donde esté ubicada la casa también influye; en las áreas norte, sur y este³⁵ serían más baratas que en el oeste (identificada como la zona más costosa, lo que impacta de manera directa el costo de la renta), pero las variables categóricas convertidas a *dummies* indican en este caso que la renta subirá si se cambian a dicha zona, por lo que se espera que sean positivas todas, lo cual concuerda con los resultados.

Podría pensarse que en la zona oeste las rentas serán más caras que en el norte o en el sur, por lo que sería conveniente revisar nuevamente este punto.

2.4.7.2 Análisis de componentes principales

Para este criterio es necesario que a la matriz $X^T X$ se le haga una descomposición singular,³⁶ de donde salen eigenvalores³⁷ y eigenvectores.

Cuando se realiza una combinación lineal de las variables originales y se convierten los valores en nuevas variables se denominan *componentes principales*.³⁸ Estas nuevas variables tienen tres propiedades:

1. Son independientes ya que no están correlacionadas³⁹ como las variables originales.
2. Contienen la información de las variables originales.
3. Poseen la máxima varianza posible de las variables originales.

El proceso de descomposición de la matriz arroja dos partes, la primera son los eigenvalores y la segunda los eigenvectores. A la varianza de cada componente principal se le denomina eigenvalor de la matriz de varianzas-covarianzas de las variables originales y a dichos valores se les representa con

³⁵ Aunque dicha variable no se ha tomado en cuenta para el análisis.

³⁶ El procedimiento para realizar una descomposición singular o espectral se aborda en el anexo 3-2 “Descomposición espectral”.

³⁷ Los términos eigenvalores, autovalores y valores propios son sinónimos. Cabe mencionar que el término eigenvectores también tiene sinónimos: vectores propios o autovectores.

³⁸ El tema componentes principales será tratado más ampliamente en el capítulo 3 “Análisis de factores”.

³⁹ Los términos *correlación* y *relación* son sinónimos y dependen de la forma en que los nuevos componentes son extraídos, para mayor información revise el capítulo 3 “Análisis de factores”.

la letra λ . A la descomposición de la varianza de los estimadores se le denomina vectores propios o eigenvector.

El proceso para encontrar los valores y vectores propios no se ilustrará aquí⁴⁰ por lo que el SPSSTM los pone en la siguiente tabla:

Tabla 2-25 Diagnóstico de colinealidad

Diagnóstico de colinealidad ^a										
Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de varianza						
				(Constante)	Distancia	Cuartos	Estudiantes	Norte	Oeste	Sur
1	1	4.214	1.000	.00	.01	.00	.00	.01	.01	.01
	2	1.035	2.018	.00	.01	.00	.00	.28	.19	.01
	3	1.005	2.047	.00	.00	.00	.00	.11	.04	.41
	4	.413	3.193	.00	.12	.01	.01	.27	.07	.12
	5	.278	3.893	.00	.35	.00	.00	.18	.50	.22
	6	.046	9.533	.96	.29	.04	.01	.03	.07	.23
	7	.007	23.783	.04	.23	.95	.98	.12	.12	.00

^a Variable dependiente: Ln_renta.

En la tabla existen 7 dimensiones que coinciden con el número de coeficientes y con las dimensiones de la matriz $X^T X$ (7×7). En la columna autovalor aparecen los eigenvalores y por cada uno hay un eigenvector, que están en las columnas proporciones de varianza,⁴¹ por último, entre la columna de autovalores y los vectores propios se encuentra la del índice de condición.

Para ver si en el modelo existe multicolinealidad es necesario revisar los autovalores, representados por la letra λ . Si los valores propios son cercanos a cero indican que dicho autovalor no debe encontrarse; es decir, el número de coeficientes o β debe ser menor, por lo que el número de variables independientes debe reducirse, ya que esto significa que algunas son combinación lineal de otras. Cuando los autovalores son cercanos a cero indican problemas graves de colinealidad.

Al ver los valores que se tienen en la tabla anterior, en la columna de los autovalores, hay dimensiones cercanas a cero; otra manera de análisis es revisar qué tanto disminuye un valor respecto al mayor encontrado; es decir, el mayor valor propio se dividirá entre el siguiente:

Ecuación 2-12 K

$$K_i = \frac{\lambda_{Mdx}}{\lambda_i}$$

Donde:

K_i : es el cociente del mayor autovalor entre el valor propio i .

λ_{Mdx} : es el mayor de los valores propios.

λ_i : es el autovalor de la dimensión i .

El primer cociente siempre dará 1, ya que se divide el mayor entre él mismo; el segundo cociente estaría dado por:

$$K_2 = \frac{\lambda_{Mdx}}{\lambda_2} = \frac{4.214}{1.035} = 4.072$$

⁴⁰ El procedimiento para encontrar los autovalores y los vectores propios se especifica en el anexo 3.2 "Descomposición espectral".

⁴¹ Las columnas de proporción de la varianza es la matriz en la cual se descompuso la varianza de cada coeficiente del modelo de la regresión.

Dicho número debe ser menor a 100 y como en este ejemplo lo es se concluye que no existen problemas; los valores con los que se pueden tener dificultades serían $100 \leq K \leq 1\,000$ y con valores $K > 1\,000$ se tendrían problemas severos de multicolinealidad.

A continuación se presentan los valores encontrados; se resume el proceso:

Tabla 2-26 Valores de K

Dimensión	Autovalor	K
1	4.214	1
2	1.035	4.072
3	1.005	4.191
4	0.413	10.195
5	0.278	15.159
6	0.046	90.879
7	0.007	565.611

Como se ve en la tabla anterior, la última dimensión indica que se tienen fuertes problemas, ya que el dato está entre 100 y 1 000; para saber qué variables tienen problemas es necesario ver el eigen-vector, el cual sería el último de ellos:

$$V_7 = [0.04, 0.23, 0.95, 0.98, 0.12, 0.12, 0.00]$$

De los valores anteriores se toman los que son mayores a 0.3, en este caso 0.95 y 0.98; que ambos sean muy parecidos indica que están repetidos o que uno de ellos es superfluo, ya que aportan casi la misma proporción de varianza. El siguiente paso es saber a qué variables pertenecen dichos valores, lo que se conoce al ver la tabla y revisar la columna correspondiente.

En este ejemplo las variables que tienen multicolinealidad son cuartos y estudiantes. El número de condición (representado por IC) se busca con base en K a continuación se muestra su fórmula:

Ecuación 2-13 Índice de condición

$$IC_1 = \sqrt{K_1}$$

El primer IC siempre dará 1; el segundo IC se obtiene de la siguiente manera:

$$IC_1 = \sqrt{K_1} = \sqrt{4.072} = 2.018$$

Dicho número debe ser menor a 10 y como en este caso lo es se concluye que no existen problemas; los valores con los que sí se pueden tener dificultades fuertes serían $10 \leq IC \leq 30$ y en un escenario de $IC > 30$ se tendrían problemas severos de multicolinealidad. A continuación se ponen los valores encontrados:

Tabla 2-27 Valores del índice de condición

Dimensión	IC
1	1
2	2.018
3	2.047
4	3.193
5	3.893
6	9.533
7	23.783

Como se ve en la tabla anterior, la última dimensión indica que se tienen fuertes problemas, ya que se encuentra entre 10 y 31; para saber en qué variables se tienen dificultades es necesario ver el eigenvector, el cual sería el último de ellos:

$$V_7 = [0.04, 0.23, 0.95, 0.98, 0.12, 0.12, 0.00]$$

Como ya se había encontrado, los dos valores mayores a 0.3 son 0.95 y 0.98; ahora es necesario saber a qué variables pertenecen; al ver la tabla se identifica que las variables con multicolinealidad son cuartos y estudiantes. Lo que se recomienda es usar el índice de condición, pues la mayoría del software estadístico lo muestra.

Si el valor mayor a 0.3 pertenece a β_0 indicaría que la variable con un valor mayor tiene problemas con la constante o la intersección con el eje Y; por ejemplo:

$$V_7 = [0.94, 0.23, 0.96, 0.18, 0.12, 0.12, 0.00]$$

El primer valor mayor a 0.3 pertenece a β_0 y el segundo a β_2 , el cual es 0.96, por lo tanto la variable X_2 es la que posiblemente tiene una relación no lineal o necesita que la constante pase por otro lado, lo que podría significar que dicha variable debe ser centrada, esto último se podría realizar restandole el promedio para volver a efectuar la regresión.

2.4.7.3 Prueba F y t se contradicen

Si se rechaza la hipótesis del análisis de varianza con la prueba F , en las pruebas de los betas individuales también se deberá rechazar en al menos una de las pruebas, que se realizan por medio de la t .

Pero si en la prueba F se rechaza la hipótesis nula y en las pruebas individuales se acepta, entonces la multicolinealidad puede estar presente, ya que ambas pruebas se están contradiciendo y esto no puede pasar; también puede suceder lo contrario; es decir, que en la F se acepte la hipótesis nula y en al menos una de las pruebas individuales se rechace.

2.4.8 ¿Cómo evitar la multicolinealidad?

Si ya se comprobó por medio de algún criterio que existe multicolinealidad, se podría tomar en cuenta alguna de las siguientes opciones:

1. Seleccionar variables independientes que no estén relacionadas.
2. Eliminar alguna variable que tenga problemas de multicolinealidad, el problema es saber cuál. Se recomienda elegir la más costosa de conseguir y volver a realizar la regresión con las variables que se quedarán y después volver a analizar por algún criterio de multicolinealidad; si el modelo vuelve a tener problemas eliminar otra variable y repetir el procedimiento.

En el ejemplo, la variable estudiantes sería la más costosa.

3. Realizar una pequeña transformación, es decir, aplicar el logaritmo a una de las dos variables independientes que tengan problemas de multicolinealidad, si ésta continúa se podría intentar la transformación de las dos variables que presenten la multicolinealidad a un cociente, es decir dividir una variable entre la otra, pero es necesario que la razón que se encuentre sea lógica. Otra forma sería estandarizar una de las dos variables problemáticas.

Si se vuelve al ejemplo, el cociente podría ser cuartos/estudiantes, la razón sería el número de cuartos por estudiantes o bien al revés estudiantes/cuartos, la razón sería el número de estudiantes por cuartos; el último cociente es el más lógico.

4. Utilizar la regresión de Ridge, con la que se obtienen indicadores para los verdaderos valores de los betas, que son los más estables y evitan problemas de multicolinealidad en el modelo o ecuación.
5. Manejar variables ortogonales; se podría utilizar la técnica de análisis de factores⁴² para obtener este tipo de variables, que pueden ser usadas como variables independientes de entrada para la regresión múltiple.

⁴² Esta técnica es el método estadístico multivariante que se verá más adelante.

6. Los economistas sugieren que se puede trabajar con la multicolinealidad, si el modelo (o función) no pierde lógica, es decir que las betas no cambien de signo; así que proponen eliminar la variable que cambie de signo.
7. Se podría realizar la regresión por medio de las rutinas del *stepwise*, *forward* o *backward*; es un modo más cómodo ya que seleccionan aquellas variables que son verdaderamente significativas y quitan las que no lo son.

A continuación se explican brevemente los tres métodos antes mencionados.

2.4.8.1 Selección de variables

Existen varios métodos que ayudan en la selección de variables, dentro de los cuales se encuentran:

1. *Forward* (hacia adelante).
2. *Backward* (hacia atrás).
3. *Stepwise* (paso a paso o pasos sucesivos; es una mezcla de los dos anteriores).

Los tres métodos utilizan la construcción de un estadístico denominado F parcial, el cual compara en dos modelos las F parciales⁴³ que sirven para hacer una selección de variables. Para esto es necesario que se tenga un modelo completo y uno reducido, el primero de ellos debe tener al menos una variable más que el segundo. La prueba de hipótesis que se puede aplicar en este estadístico, junto con sus hipótesis, se muestran a continuación:

$$H_0 : \beta_{m+1}, \beta_{m+2}, \dots, \beta_k = 0$$

$$H_1 : \text{al menos uno de los } \beta_{m+1}, \beta_{m+2}, \dots, \beta_k \text{ es } \neq 0$$

La hipótesis nula indica que el modelo reducido es el mejor y la hipótesis alterna dice que el modelo completo es el que debería de usarse.

Donde:

m : es el número de variables independientes que se tienen en el modelo reducido.

k : es el número de variables independiente que se tienen en el modelo completo.

El estadístico calculado, es decir, las fórmulas para obtener las F parciales son:

Ecuación 2-14 F parciales

$$F_{\text{Parcial}} = \frac{\frac{(SSE_{\text{Reducido}} - SSE_{\text{Completo}})}{(k - m)}}{\frac{(SSE_{\text{Completo}})}{(n - p)}}$$

o

$$F_{\text{Parcial}} = \frac{\frac{(R_{\text{Completo}}^2 - R_{\text{Reducido}}^2)}{(k - m)}}{\frac{(1 - R_{\text{Completo}}^2)}{(n - p)}}$$

Donde:

SSE_{Reducido} : es la suma de cuadrados del error del modelo reducido, es decir, del que tiene al menos una variable menos.

SSE_{Completo} : es la suma de cuadrados del error del modelo completo, el que tiene más variables.

m : es el número de variables extra que se tienen en el modelo completo.

⁴³ El SPSS utiliza una t -student, la cual se realiza con una F parcial con un grado de libertad que equivale a la t , al sacarle raíz cuadrada a la F .

k : es el número de variables independientes del modelo completo.

n : es el número de datos.

p : es el número de coeficientes a calcular, lo cual es $k + 1$.

R^2_{Reducido} : es el coeficiente de determinación del modelo reducido.

R^2_{Completo} : es el coeficiente de determinación del modelo completo.

Ahora se explicará cada uno de los métodos antes mencionados:

2.4.8.2 *Forward* o hacia adelante

A partir de la matriz de correlaciones entre las variables independientes, las cuales serán llamadas X_i y la variable dependiente, que es Y , el método selecciona aquella variable independiente que tiene la más alta correlación con Y , luego construye un modelo de regresión lineal simple y verifica si éste cumple el nivel de significancia definido por el investigador.

El método construye las F parciales de la variable actual con cada una de las otras variables independientes que en el siguiente paso pudieran ser seleccionadas.

Se elige la F parcial que sea significativa y más alta; el método checa a qué variable independiente pertenece esa F y la utiliza como variable de entrada en el siguiente paso. Una vez seleccionada la siguiente variable independiente a entrar, construye un modelo de regresión lineal múltiple (ya que ahora se tienen dos variables independientes).

El método verifica que el modelo de regresión múltiple sea significativo. Se repiten los pasos hasta que ya no existan variables de entrada que cumplan con la condición de que sean significativas.

2.4.8.3 *Backward* o hacia atrás

Este método parte de la construcción de un modelo de regresión múltiple que incluye a todas las variables independientes y a la dependiente.

Se construyen F parciales cuando compara el modelo completo contra el modelo reducido y elimina cada una de las p variables independientes involucradas. Se elimina a la variable X no significativa con la F parcial más pequeña.

Se construye un modelo múltiple, pero sin incluir la variable X seleccionada que se decidió eliminar y se verifica su significancia.

Se repiten los pasos hasta probar todas las variables o hasta que el modelo tenga sólo las variables significativas, es decir, sólo las que en realidad aportan para explicar el comportamiento de la variable dependiente.

2.4.8.4 *Stepwise* o pasos sucesivos

A partir de la matriz de correlaciones entre las variables independientes, las cuales serán llamadas X_i y la variable dependiente que es Y , el método selecciona aquella variable independiente que tiene la más alta correlación con Y , luego construye un modelo de regresión lineal simple y verifica si éste cumple el nivel de significancia definido por el investigador.

El método construye las F parciales de la variable actual con cada una de las otras variables independientes seleccionadas en el siguiente paso.

Se elige la F parcial que sea significativa y más alta; el método checa a qué variable independiente pertenece esa F y la utiliza como variable de entrada en el siguiente paso. Una vez seleccionada la siguiente variable independiente a entrar, construye un modelo de regresión lineal múltiple (ya que ahora se tienen dos variables independientes).

El método verifica que el modelo de regresión múltiple sea significativo. Hasta aquí es lo mismo que el método de *Forward*.

El método construye las F parciales del modelo con las dos variables actuales (el cual sería el modelo completo) y se compara con el modelo anterior, es decir, con el que tiene sólo una variable independiente (modelo reducido). Si el modelo completo es el mejor, el proceso continúa, pero si el modelo reducido es mejor, elimina del modelo completo aquella variable que tiene su F parcial más pequeña. En esta parte se está utilizando el *backward*.

Si el modelo completo es el mejor, se busca en las variables que están fuera de éste cuál de ellas tiene la mayor F parcial y que sea significativa, entra dicha variable y luego construye la nueva ecuación, vuelve a comparar para identificar si alguna de las que están en la ecuación no es significativa; el proceso continúa hasta que se comparen todas las variables o hasta que ya no queden variables de entrada o de salida, lo que significa que ninguna de las que quedan afuera ayuda a explicar el comportamiento de la variable dependiente.

Si el modelo reducido es mejor elimina a la variable que no fue significativa y compara las F parciales de aquellas variables que se encuentran fuera, entra la que tenga la mayor F parcial y que sea significativa; el proceso continúa (compara, elimina e introduce variables) hasta que se comparen todas o hasta que ya no existan variables de entrada o de salida.

2.4.8.5 Ejemplo de F parciales

En el ejemplo se encontró multicolinealidad entre las variables distancia, cuartos y estudiantes. Para aplicar F parciales, supóngase que se desea saber si el modelo que se encontró es mejor que el modelo sin la variable estudiantes,⁴⁴ o bien sin la variable cuartos. La información que el SPSS[™] arroja de los dos modelos⁴⁵ se muestra a continuación el modelo completo:

Tabla 2-28 Información del modelo completo

Resumen del modelo				
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación
1	.965 ^a	.931	.906	.12419

^a Variables predictoras: (constante), sur, distancia, norte, estudiantes, oeste, cuartos.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	3.525	6	.588	38.094	.000 ^a
	Residual	.262	17	.015		
	Total	3.787	23			

^a Variables predictoras: (constante), sur, distancia, norte, estudiantes, oeste, cuartos.

^b Variable dependiente: Ln_renta.

Modelo reducido:

Tabla 2-29 Información del modelo reducido

Resumen del modelo				
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación
1	.962 ^a	.926	.905	.12482

^a Variables predictoras: (constante), sur, distancia, norte, estudiantes, oeste, cuartos.

(continúa)

⁴⁴ O bien podría ser sin la variable cuartos o la distancia.

⁴⁵ Más adelante se muestra el proceso para sacar toda la información.

Tabla 2-29 Información del modelo reducido (continuación)

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	3.507	5	.701	45.016	.000 ^a
	Residual	.280	18	.016		
	Total	3.787	23			

^a Variables predictoras: (constante), sur, distancia, norte, estudiantes, oeste, cuartos.

^b Variable dependiente: Ln_renta.

Donde:

$$SSE_{\text{Reducido}} = 0.280 \text{ entonces, el } SSE_{\text{Completo}} = 0.262$$

$k = 6$ contabiliza a las variables sur, distancia, norte, estudiantes, oeste y cuartos. Además $m = 5$ sería el número de variables anteriores menos la variable estudiantes.

$n = 24$ es el número de datos en el análisis y $p = k + 1 = 6 + 1 = 7$ es el número de coeficientes a calcular.

$$R^2_{\text{Reducido}} = 0.926 \text{ entonces, la } R^2_{\text{Completo}} = 0.931$$

Como en este caso el modelo completo tiene 6 variables y el modelo reducido 5, las hipótesis serían:

$$H_0 : \beta_{m+1} = \beta_{m+2} = \dots = \beta_k = 0$$

$$H_1 : \text{al menos uno de los } \beta_{m+1}, \beta_{m+2}, \dots, \beta_k \text{ es } \neq 0$$

Donde $\beta_{m+1} = \beta_{5+1} = \beta_6$ y como $k = 6$ quedaría por comparar una sola variable, es decir, un solo coeficiente; las hipótesis serían:

$$H_0 : \beta_6 = 0$$

$$H_1 : \beta_6 \neq 0$$

La hipótesis nula dice que el modelo reducido es mejor, es decir, la variable estudiantes tiene que salir del análisis y la hipótesis alterna indica que el modelo completo es mejor, por lo que la variable estudiantes debe quedarse en la ecuación. Lo siguiente es encontrar la F parcial, la cual sería:

$$F_{\text{Parcial}} = \frac{\frac{(SSE_{\text{Reducido}} - SSE_{\text{Completo}})}{(k - m)}}{\frac{(SSE_{\text{Completo}})}{(n - p)}} = \frac{\frac{(0.280 - 0.262)}{(6 - 5)}}{\frac{(0.262)}{(24 - 7)}}$$

O bien pudo elegirse:

$$F_{\text{Parcial}} = \frac{\frac{(R^2_{\text{Completo}} - R^2_{\text{Reducido}})}{(k - m)}}{\frac{(1 - R^2_{\text{Completo}})}{(n - p)}} = \frac{\frac{(0.931 - 0.926)}{(6 - 5)}}{\frac{(1 - 0.931)}{(24 - 7)}}$$

Dando como resultado:


$$F_{\text{Parcial}} = 1.814$$

El valor anterior se compara con el estadístico teórico, el cual se obtiene en la tabla F; el estudio de este ejemplo tiene 95% de confianza, por lo que el nivel de significancia es de 5% y los grados de libertad en el estadístico teórico son los siguientes:

$$F_{t,\alpha=0.05,(k-m),(n-p)} = F_{t,\alpha=0.05,(6-5)=1,(24-7)=17}$$

La forma de buscar en la tabla F se muestra en la tabla 2-30 de la página siguiente.

Tabla 2-30 Tabla F⁴⁶



g\l	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
15	0.100	3.037	2.695	2.490	2.361	2.273	2.208	2.158	2.119	2.086	2.059	2.017	1.972	1.924	1.899	1.873	1.845	1.817	1.787	1.755
	0.050	4.543	3.682	3.287	3.056	3.901	2.790	2.707	2.641	2.588	2.544	2.475	2.403	2.328	2.288	2.247	2.204	2.160	2.114	2.066
	0.025	6.200	4.765	4.153	3.804	3.576	3.415	3.293	3.199	3.123	3.060	2.963	2.862	2.756	2.701	2.644	2.585	2.524	2.461	2.395
	0.010	8.683	6.359	5.417	4.893	4.556	4.318	4.142	4.004	3.895	3.805	3.666	3.522	3.372	3.294	3.214	3.132	3.047	2.959	2.868
	0.005	10.798	7.701	6.476	5.803	5.372	5.071	4.847	4.674	4.536	4.424	4.250	4.070	3.883	3.786	3.687	3.585	3.480	3.372	3.260
16	0.100	3.048	2.668	2.462	2.333	2.244	2.178	2.128	2.088	2.055	2.028	1.985	1.940	1.891	1.866	1.839	1.811	1.782	1.751	1.718
	0.050	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591	2.538	2.494	2.425	2.352	2.276	2.235	2.194	2.151	2.106	2.059	2.010
	0.025	6.115	4.687	4.077	3.729	3.502	3.341	3.219	3.125	3.049	2.986	2.889	2.788	2.681	2.625	2.568	2.509	2.447	2.383	2.316
	0.010	8.531	6.226	5.292	4.773	4.437	4.202	4.026	3.890	3.780	3.691	3.553	3.409	3.259	3.181	3.101	3.018	2.933	2.845	2.753
	0.005	10.575	7.514	6.303	5.638	5.212	4.913	4.962	4.521	4.384	4.272	4.099	3.920	3.734	3.638	3.539	3.437	3.332	3.224	3.112
17	0.100	3.026	2.645	2.437	2.308	2.218	2.152	2.102	2.061	2.028	2.001	1.958	1.912	1.862	1.836	1.809	1.781	1.751	1.719	1.686
	0.050	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.381	2.308	2.230	2.190	2.148	2.104	2.058	2.011	1.960
	0.025	6.042	4.619	4.011	3.665	3.438	3.277	3.156	3.061	2.985	2.922	2.825	2.723	2.616	2.560	2.502	2.442	2.380	2.315	2.247
	0.010	8.400	6.112	5.185	4.669	4.336	4.102	3.927	3.791	3.682	3.593	3.455	3.312	3.162	3.084	3.003	2.920	2.835	2.746	2.653
	0.005	10.384	7.354	6.156	5.497	5.075	4.779	4.559	4.389	4.254	4.142	3.971	3.793	3.607	3.511	3.412	3.311	3.206	3.097	2.984
18	0.100	3.007	2.624	2.416	2.286	2.196	2.130	2.079	2.038	2.005	1.977	1.933	1.887	1.837	1.810	1.783	1.754	1.723	1.691	1.657
	0.050	4.414	3.555	3.160	2.928	2.773	2.661	2.577	2.510	2.456	2.412	2.342	2.269	2.191	2.150	2.107	2.063	2.017	1.968	1.917

⁴⁶ La tabla F se encuentra en el anexo 29.

El estadístico teórico sería:

$$F_{t,\alpha=0.05,1,17} = 4.451$$


para rechazar la H_0 es necesario que:

$$F_C > F_{t,\alpha,k-m,n-p}$$

por lo que:

$$1.814 < 4.451 \text{ no se rechaza } H_0$$

o bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Como no se rechazó la H_0 se concluye que el mejor modelo es el reducido y que es necesario quitar la variable estudiantes del modelo.

Toma de decisiones. En la prueba de hipótesis que se acaba de realizar se encontró que la variable estudiantes no era significativa, por lo que es necesario eliminarla de la ecuación. Entonces se vuelve a construir la matriz X y se estiman las nuevas β ; la nueva función quedaría de la siguiente forma.

Tabla 2-31 Nueva ecuación sin la variable estudiantes

		Coeficientes no estandarizados	
Modelo		B	Error típ.
1	(Constante)	8.197	.100
	Distancia	-.027	.020
	Cuartos	.310	.025
	Norte	.184	.077
	Oeste	.012	.067
	Sur	.162	.074


^a Variable dependiente: Ln_renta.

2.4.9 Prueba de hipótesis global

Se le llama *prueba global* porque en ella se comprueban todas las variables juntas.


Al pronosticar la variable dependiente se trata de captar el comportamiento de ésta por medio de una ecuación, el cual debe seguir una distribución normal con variabilidad (o *variación total* o *SST*), esta última se puede descomponer en dos variaciones que se obtienen de las tres desviaciones posibles al comparar el dato real o Y , el dato pronosticado o $\hat{Y}$ y el promedio o $\bar{Y}$ de la variable dependiente. Las desviaciones se explican a continuación:

Con el modelo de regresión, una gráfica de tres dimensiones⁴⁷ se vería de la siguiente manera:




Gráfica 2-6 Tres dimensiones.

En la gráfica anterior se muestra el modelo de regresión, ahora se verán los datos reales y el término de error.



Gráfica 2-7 El error en tres dimensiones.


Ahora suponga que sólo se tienen dos dimensiones, con los datos observados o Y y los datos pronosticados o $\hat{Y}$, éstos se encuentran diferenciados, con puntos los primeros y con la línea de regresión, los segundos.



Gráfica 2-8 Datos observados y pronosticados.


⁴⁷ Una dimensión está conformada por una sola línea, dos dimensiones se forman con los ejes X y Y , los cuales son las abscisas y las ordenadas, respectivamente; si se tiene una gráfica de tres dimensiones, una sería con el eje Y , mientras que los dos ejes restantes contienen cada una de las variables, supóngase que el segundo eje es con X_1 y el otro eje con X_2 ; por último una gráfica de cuatro o más dimensiones es prácticamente imposible de visualizar.

A la gráfica anterior se le agregará una línea para indicar el promedio o $\bar{Y}$ de la variable dependiente:




Gráfica 2-9 Datos observados, pronosticados y promedio.

Ahora se borrarán todos los puntos exceptuando uno, supóngase que se escoge el más lejano, por lo que sólo se diferenciará un dato observado (Y) y se conservarán las líneas del promedio y de regresión; al escoger un valor para X , por ejemplo $X = 6$, se tienen tres posibles puntos para ese valor en Y , el primero es el dato real (Y), el segundo el pronóstico ($\hat{Y}$) y el tercero el promedio ($\bar{Y}$). La gráfica quedaría de la siguiente manera:



Gráfica 2-10 Una sola observación.

Note que se pueden diferenciar tres desviaciones como sigue:



Gráfica 2-11 Las tres desviaciones.

Las desviaciones elevadas al cuadrado y obtenidas en suma para todas las observaciones se convertirían en variaciones que indican la variación total,⁴⁸ la cual es $\sum_{i=1}^n (Y_i - \bar{Y})^2$; ésta se puede descomponer de dos partes: la explicada⁴⁹ por la regresión $\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ y la no explicada⁵⁰ por la regresión $\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$, ya que dicha variación no se logró captar por la regresión y se compone por el término del error $\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (\varepsilon_i)^2$ en la población y en la muestra por el residual $\sum_{i=1}^n (r_i)^2$; por lo que las tres variaciones serían:

Ecuación 2-15 Descomposición de la variación total

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Recuerde que dichas variaciones son identificadas como SS (*Sum of Square*⁵¹):

$$SSTotal = SSRegresión + SSError$$

Que por sus siglas serían:

$$SST = SSR + SSE$$

A continuación se describe la forma en que se calcula cada una de ellas:

La primera, que es la variación total o suma de cuadrados totales, se indica en seguida:

Ecuación 2-16 Variación total

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i)^2 - n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - \frac{(\sum_{i=1}^n Y_i)^2}{n}$$

La segunda, que es la variación explicada o suma de cuadrados debida a la regresión, es:

Ecuación 2-17 Variación explicada

$$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

O bien de la forma:

$$SSR = b_0 \sum_{i=1}^n Y_i + b_1 \sum_{i=1}^n X_{1,i} Y_i + b_2 \sum_{i=1}^n X_{2,i} Y_i + \dots + b_k \sum_{i=1}^n X_{k,i} Y_i - K \frac{(\sum_{i=1}^n Y_i)^2}{n}$$

Que también podría ser:

$$SSR = b_0 \sum_{i=1}^n Y_i + b_1 \sum_{i=1}^n X_{1,i} Y_i + b_2 \sum_{i=1}^n X_{2,i} Y_i + \dots + b_k \sum_{i=1}^n X_{k,i} Y_i - K\bar{Y}^2$$

Y por último sería la variación no-explicada o la suma de cuadrados debida al error:

Ecuación 2-18 Variación no explicada

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

⁴⁸ La cual da una medida de los valores de Y_i alrededor de su promedio, $\bar{Y}$.

⁴⁹ Es la variación que se le atribuye a la relación lineal que existe entre las variables X y la variable Y ; dicha relación se trata de explicar por medio de la ecuación que fue calculada por la regresión.

⁵⁰ Es la variación que no se le atribuye a la relación lineal y que existe entre las variables X y la variable Y ; es decir se puede atribuir a otros factores (o variables independientes) diferentes a los utilizados en la regresión.

⁵¹ Por las siglas en inglés del término *suma de cuadrados* ya que se eleva al cuadrado y al final se suma.


O bien de la forma:

$$SSE = \sum_{i=1}^n Y_i^2 - b_0 \sum_{i=1}^n Y_i - b_1 \sum_{i=1}^n X_{1,i} Y_i - b_2 \sum_{i=1}^n X_{2,i} Y_i - \dots - b_k \sum_{i=1}^n X_{k,i} Y_i$$

Es necesario probar si la variabilidad captada por la regresión es lo suficientemente grande para ser significativa;⁵² es decir la SST tiene un valor, el cual se descompone en SSR y en SSE ; y si la SSR , al tomar en cuenta los grados de libertad (gl Reg) es mucho más grande que la SSE (también con sus grados de libertad gl Error), entonces la variabilidad se considera significativa, ya que el MSR es más grande que el MSE . Para saber si es o no más grande se comparan con el objetivo de encontrar el siguiente cociente:

$$\frac{\frac{SSR}{\text{gl Reg}}}{\frac{SSE}{\text{gl Error}}} = \frac{MSR}{MSE}$$

Ahora es necesario saber qué tipo de distribución sigue ese cociente para elegir el estadístico que se usará en la prueba de hipótesis. Las propiedades estadísticas que posee la Y por herencia de los errores se pueden representar en la siguiente gráfica:



Gráfica 2-12 Propiedades estadísticas de la variable dependiente.

Nótese que en la gráfica anterior hay una relación inversa o indirecta y de sólo dos dimensiones, además σ_ε es la desviación estándar de los errores que siguen una distribución normal, cuyo promedio corresponde a un punto de la línea de regresión y su dispersión es la varianza de los errores.

El valor esperado de la variable dependiente es:

Ecuación 2-19 Valor esperado de la variable dependiente

$$E(Y|X_1, \dots, X_k) = E(\beta_2 + \beta_1 X + \dots + \beta_k X + \varepsilon) = \beta_2 + \beta_1 X + \dots + \beta_k X$$

Lo anterior indica que el valor que se espera de la variable dependiente, es decir de Y , dado que las X fueron dadas en la ecuación de regresión. La varianza sería:

Ecuación 2-20 Varianza de la variable dependiente

$$Var(Y|X_1, \dots, X_k) = Var(\beta_2 + \beta_1 X + \dots + \beta_k X + \varepsilon) = Var(\varepsilon) = \sigma_\varepsilon^2$$

⁵² Esto indica que debe realizarse una prueba de hipótesis.

Entonces la varianza de la Y es la varianza de los errores; con todo lo anterior se puede concluir que el comportamiento probabilístico de Y se puede resumir de la siguiente manera:

$$Y|X_1, \dots, X_k \sim N[(\beta_2 + \beta_1 X + \dots + \beta_k X), \sigma_\varepsilon^2]$$

La variable Y , puesto que las X fueron dadas, sigue una distribución normal, cuyo valor esperado es el modelo encontrado por regresión y con varianza igual a la de los errores. La distribución normal de la Y se representa de la siguiente manera:

$$Y \sim N$$

Y cuando se le resta su promedio sigue la misma distribución, ya que sólo se está cambiando de lugar a la variable.

$$Y - \bar{Y} \sim N$$

Entonces una distribución normal elevada al cuadrado da una ji cuadrada para el caso de la Variación Explicada Media (MSR), por lo tanto se tiene:

$$\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p - 1} \sim \chi^2$$

Donde p es el número de parámetros estimados, además se sabe que $p = k + 1$ grados de libertad, donde k es el número de variables independientes. En el caso de la Variación No Explicada Media (MSE) se tiene que:

$$\frac{\sum_{i=1}^n (Y_i - \hat{Y})^2}{n - p} \sim \chi^2$$

La cual también es una ji cuadrada con $n - p$ grados de libertad. Una ji cuadrada con $p - 1$ grados de libertad, dividida entre otra ji cuadrada con $n - p$ grados de libertad, da una distribución F con los grados de libertad $p - 1$ y $n - p$; es decir:

$$\frac{\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p - 1}}{\frac{\sum_{i=1}^n (Y_i - \hat{Y})^2}{n - p}} \sim F$$

De acuerdo con el ejemplo las tres variaciones se pueden calcular de la siguiente manera:⁵³

Tabla 2-32 Variaciones

Y	X_1	X_2	X_3	X_4	X_5	$\hat{Y}$			
Ln_renta	Distancia	Cuartos	Norte	Oeste	Sur	Estimación	$(Y \text{ Prom})^2$	$(\hat{Y} \text{ Prom})^2$	$(Y - \hat{Y})^2$
9.048	1.0	2	0	0	1	8.952	0.004	0.001	0.009
9.094	1.0	2	1	0	0	8.974	0.012	0.000	0.014
9.547	0.5	4	1	0	0	9.608	0.318	0.391	0.004
8.517	3.0	1	0	0	0	8.425	0.217	0.311	0.008
9.306	0.5	4	0	0	0	9.424	0.104	0.194	0.014
8.987	1.0	2	0	1	0	8.802	0.000	0.033	0.034
9.048	1.0	2	0	0	1	8.952	0.004	0.001	0.009

(continúa)

⁵³ A los datos originales hay que quitarles la variable estudiante porque tenía severos problemas de multicolinealidad con la variable cuartos.

Tabla 2-32 Variaciones (continuación)

Y	X_1	X_2	X_3	X_4	X_5	$\hat{Y}$			
Ln_renta	Distancia	Cuartos	Norte	Oeste	Sur	Estimación	$(Y \text{ Prom})^2$	$(\hat{Y} \text{ Prom})^2$	$(Y - \hat{Y})^2$
9.393	3.0	4	0	0	0	9.355	0.168	0.139	0.001
8.269	0.5	1	0	0	0	8.493	0.510	0.239	0.050
9.393	1.0	4	0	1	0	9.422	0.168	0.193	0.001
8.923	4.0	3	0	1	0	9.030	0.004	0.002	0.011
9.071	3.0	3	0	0	0	9.045	0.008	0.004	0.001
8.987	1.0	3	0	1	0	9.112	0.000	0.017	0.015
8.243	4.0	1	0	1	0	8.410	0.547	0.328	0.028
8.854	2.0	2	1	0	0	8.947	0.017	0.001	0.009
9.105	2.0	3	0	0	1	9.235	0.015	0.064	0.017
8.412	4.0	1	0	0	0	8.398	0.326	0.342	0.000
8.476	4.0	1	0	0	1	8.560	0.256	0.179	0.007
8.975	1.0	2	0	0	1	8.952	0.000	0.001	0.001
8.517	4.0	1	0	1	0	8.410	0.217	0.328	0.012
9.510	0.5	4	0	0	0	9.424	0.279	0.194	0.008
9.510	0.5	4	0	0	0	9.424	0.279	0.194	0.008
8.854	4.0	2	0	1	0	8.720	0.017	0.069	0.018
9.547	4.0	4	1	0	0	9.512	0.318	0.281	0.001
Prom=	8.983					Suma=	3.787	3.507	0.280
							SST	SSR	SSE

Con las tres variaciones⁵⁴ se empieza a construir la tabla del ANOVA, la cual se acomoda de la siguiente manera:

Tabla 2-33 Las tres variaciones

Fuente	SS
Regresión (R)	3.507
Residual o error (E)	0.280
Total (T)	3.787

Donde SS significa suma de cuadrados. Posteriormente se calculan los grados de libertad (df por sus siglas en inglés):

Para la variación total (SST) los grados de libertad son:

$$n - 1 = 24 - 1 = 23$$

Donde n es el número de datos en el análisis.

Para la variación explicada (SSR) son:

$$p - 1 = (k + 1) - 1 = k = 5$$

La p es el número de parámetros y k el número de variables independientes.

Para la variación no explicada (SSE) son:

$$n - p = n - (k + 1) = 24 - (5 + 1) = 18$$

⁵⁴ No es necesario obtener las tres variaciones, con dos de ellas se puede conocer la tercera, ya que $SST = SSR + SSE$.

Los grados de libertad⁵⁵ se acomodan en la siguiente columna de la tabla del ANOVA:

Tabla 2-34 Grados de libertad

Fuente	SS	df
Regresión (R)	3.507	5
Residual o error (E)	0.280	18
Total (T)	3.787	23

Para obtener la siguiente columna de la tabla del ANOVA, la cual se refiere a los cuadrados medios (por sus siglas en inglés *MS*), es necesario dividir la columna Suma de cuadrados entre sus grados de libertad; por ejemplo, para obtener el cuadrado medio de la regresión es necesario:

$$MSR = \frac{SSR}{p-1} = \frac{3.507}{6-1} = 0.701$$

Para obtener el cuadrado medio de los residuales:⁵⁶

$$MSR = \frac{SSE}{n-p} = \frac{0.280}{24-6} = 0.016$$

Dichos valores se acomodan en la siguiente columna de la tabla del ANOVA.

Tabla 2-35 Cuadrados medios

Fuente	SS	df	MS
Regresión (R)	3.507	5	0.701
Residual o error (E)	0.280	18	0.016
Total (T)	3.787	23	

Para obtener la siguiente columna de la tabla del ANOVA es necesario dividir los cuadrados medios de la regresión y del error, lo cual da el valor del estadístico calculado, es decir el valor de la *F*:

$$F = \frac{MSR}{MSE} = F \frac{0.701}{0.016} = 0.016$$

Tabla 2-36 Valor de *F*

Fuente	SS	gl	MS	F
Regresión (R)	3.507	5	0.701	45.016
Residual o error (E)	0.280	18	0.016	
Total (T)	3.787	23		

Y la última columna de la tabla del ANOVA sería el *p*-valor (sig) correspondiente a la *F* que se acaba de calcular, los resultados del SPSS[™] se muestran a continuación:

⁵⁵ No es necesario obtener los grados de libertad para las tres variaciones ya que la suma de los dos últimos dan el valor de los grados de libertad de la variación total.

⁵⁶ El valor obtenido es la varianza estimada de los errores.

Tabla 2-37 Tabla del ANOVA

ANOVA ^b					
Modelo	Suma de cuadrados	gl	Media cuadrática	F	Sig.
1 Regresión	3.507	5	.701	45.016	.000 ^a
Residual	.280	18	.016		
Total	3.787	23			

^a Variables predictoras: (constante), sur, distancia, norte, cuartos, oeste.

^b Variable dependiente: Ln_renta.

Cualquier paquete construye el estadístico F de la misma forma, los resultados del SPSSTM se mostraron en la figura pasada

Al resumir lo anterior, la tabla del ANOVA se calcula de la siguiente manera:

Tabla 2-38 Tabla de fórmulas del ANOVA

Fuente	SS	gl	MS	F
Regresión (R)	$\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = SSR$	$p - 1$	$\frac{SSR}{p - 1} = MSR$	$\frac{MSR}{MSE} = F$
Residual (E)	$\sum_{i=1}^n (Y_i - \hat{Y})^2 = SSE$	$n - p$	$\frac{SSE}{n - p} = MSE$	
Total (T)	$\sum_{i=1}^n (Y_i - \bar{Y})^2 = SST$	$n - 1$		

Entonces el estadístico F se calcula de la siguiente manera:

Ecuación 2-21 Estadístico F

$$F_C = \frac{\frac{SSR}{df \text{ Regresión}}}{\frac{SSE}{df \text{ Error}}} = \frac{MSR}{MSE}$$

Con los datos del ejemplo se tendría lo siguiente:

$$F_C = \frac{\frac{SSR}{df \text{ Regresión}}}{\frac{SSE}{df \text{ Error}}} = \frac{\frac{3.507}{6 - 1}}{\frac{0.280}{24 - 6}} = \frac{MSR}{MSE} = \frac{0.701}{0.016} = 45.016$$

Eso quiere decir que es necesario utilizar el estadístico F .⁵⁷ Esta prueba de hipótesis sirve para saber si el modelo es estadísticamente significativo, lo cual equivale a probar las siguientes hipótesis:

$$H_0: \beta_1 = \beta_2 = \beta_3 = \dots = \beta_k = 0$$

$$H_1: \text{al menos un } \beta_1, \beta_2, \beta_3, \dots, \beta_k \neq 0$$

En la hipótesis nula H_0 prueba que todas las β son iguales a cero; si dicha hipótesis es aceptada entonces cualquier valor que se le asigne a las variables independientes se nulificarán; es decir, como la ecuación de regresión es:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5$$

⁵⁷ La variación explicada (SSR) es la variabilidad que se capta por medio de la ecuación de regresión. MSR sería la variación media captada por regresión. La variación no explicada (SSE) es la variabilidad que no fue captada por regresión. El MSE es la variabilidad media que no fue captada por la regresión, también se le llama *varianza de los errores*.

Como se aceptó la hipótesis nula y se concluyó que todas las betas son cero, entonces:

$$\hat{Y} = \beta_0 + \beta_1(0) + \beta_2(0) + \beta_3(0) + \beta_4(0) = \beta_5(0)$$

Es decir, no importa qué valor se le asigne a las X , el término se volverá cero, eso quiere decir que ninguna X causa efecto en Y , por lo que todas las X deberán salir de la ecuación; así el análisis termina⁵⁸ y el mejor pronóstico de la variable dependiente es su promedio,⁵⁹ es decir:

$$\hat{Y} = \beta_0 = \bar{Y}$$

Caso contrario, si la hipótesis nula es rechazada se prueba que al menos un $\beta_i \neq 0$; si esto sucede entonces es necesario saber cuál es la beta diferente a cero, ya que cualquier valor que se le asigne a la variable independiente que acompaña a esa beta no se nulificará, sino que el pronóstico de la variable dependiente se incrementará o disminuirá según sea el caso, es decir depende del valor de beta y del valor de X , por lo que la variable que acompaña a esa beta deberá quedarse en la ecuación. Este tipo de pruebas se realiza en el siguiente apartado.

Todo lo anterior es verificable bajo el cumplimiento de H_0 por medio del estadístico F. Ahora se procederá a realizar la prueba de hipótesis del ejemplo:

Las hipótesis serían las siguientes:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$$

$$H_1 : \text{al menos un } \beta_1, \beta_2, \beta_3, \beta_4, \beta_5 \neq 0$$

Encontrar el estadístico calculado, en donde los resultados se sustituyen en la fórmula:

$$F_C = \frac{\frac{3.507}{6-1}}{\frac{0.280}{24-6}} = \frac{0.0071}{0.016} = 45.016$$

Sigue el estadístico teórico o de tablas, el cual se busca en la tabla F de la siguiente manera⁶⁰ (véase tabla 2-39):

$$F_{t,\alpha=0.05,p-1=6-1=5,n-p=24-6=18} = 2.773$$


Como el estudio se realiza con 5% de significancia, para rechazar la H_0 es necesario que

$$F_C > F_{t,\alpha,p-1,n-p}$$

Por lo que:

$$45.016 > 2.773 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:




⁵⁸ Podría ser que alguna otra variable que no esté contemplada en este ejemplo pueda tener o causar efecto en la variable renta, pero como no se tiene información al respecto la regresión se terminaría.

⁵⁹ La constante se calcula con el valor medio de Y .

⁶⁰ El número 5 proviene de los grados de libertad del numerador por lo que siempre deberá buscarse por arriba; el 18 se desprende de los grados de libertad del denominador, este valor siempre se deberá buscar por el lado izquierdo, posteriormente se busca el nivel de significancia; en este caso se decidió utilizar 95% de confianza, entonces la significancia es de 5% y por último deberá encontrarse el valor como lo indican las flechas.

Tabla 2-39 Tabla F⁶¹



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
17	0.100	3.026	2.645	2.437	2.308	2.218	2.152	2.102	2.061	2.028	2.001	1.958	1.912	1.862	1.836	1.809
	0.050	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.381	2.308	2.230	2.190	2.148
	0.025	6.042	4.619	4.011	3.665	3.438	3.277	3.156	3.061	2.985	2.922	2.825	2.723	2.616	2.560	2.502
	0.010	8.400	6.112	5.185	4.669	4.336	4.102	3.927	3.791	3.682	3.593	3.455	3.312	3.162	3.084	3.003
18	0.005	10.384	7.354	6.156	5.497	5.075	4.779	4.559	4.389	4.254	4.142	3.971	3.793	3.607	3.511	3.412
	0.100	3.007	2.624	2.416	2.286	2.196	2.130	2.079	2.038	2.005	1.977	1.933	1.887	1.837	1.810	1.783
	0.050	4.414	3.555	3.160	2.928	2.773	2.661	2.577	2.510	2.456	2.412	2.342	2.269	2.191	2.150	2.107
	0.025	5.978	4.560	3.954	3.608	3.382	3.221	3.100	3.005	2.929	2.866	2.769	2.667	2.559	2.503	2.445
19	0.010	8.285	6.013	5.092	4.579	4.248	4.015	3.841	3.705	3.597	3.508	3.371	3.227	3.077	2.999	2.919
	0.005	10.218	7.215	6.028	5.375	4.956	4.663	4.445	4.276	4.141	4.030	3.860	3.683	3.498	3.402	3.303
	0.100	2.990	2.606	2.397	2.266	2.176	2.109	2.058	2.017	1.984	1.956	1.912	1.865	1.814	1.787	1.759
	0.050	4.381	3.522	3.127	2.895	2.740	2.528	2.544	2.477	2.423	2.378	2.308	2.234	2.155	2.114	2.071
20	0.025	5.922	4.508	3.903	3.559	3.333	3.172	3.051	2.956	2.880	2.817	2.720	2.617	2.509	2.452	2.394
	0.010	8.185	5.926	5.010	4.500	4.171	3.939	3.765	3.631	3.523	3.434	3.297	3.153	3.003	2.925	2.844
	0.005	10.073	7.093	5.916	5.268	4.853	4.561	4.345	4.177	4.043	3.933	3.763	3.587	3.402	3.306	3.208
	0.100	2.975	2.589	2.380	2.249	2.158	2.091	2.040	1.999	1.965	1.937	1.892	1.845	1.794	1.767	1.738

⁶¹ La tabla F se encuentra en el anexo 2.9.

O para rechazar la H_0 es necesario que:⁶²

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.000 < 0.05 \text{ se rechaza } H_0$$

Toma de decisiones: como se rechazó la hipótesis nula entonces se concluye que al menos una de las $\beta_i \neq 0$, por lo que es necesario saber cuál beta es diferente a cero.

2.4.10 Pruebas de hipótesis individuales

En esta parte los contrastes o hipótesis se realizarán para cada β ; ya que con los resultados del punto anterior se tienen los elementos necesarios para probar estadísticamente cada uno de los parámetros estimados del modelo obtenido por medio de la regresión. Esta prueba de hipótesis es para corroborar si cada beta es o no estadísticamente significativa diferente a cero. Esto equivale a probar las siguientes hipótesis:

$$H_0 : \beta_i = 0 \text{ donde } i = 1, 2, 3, \dots k, 0$$

$$H_1 : \beta_i \neq 0 \text{ donde } i = 1, 2, 3, \dots k, 0$$

Estas pruebas de hipótesis se deberán realizar para cada β de la ecuación, es decir, se deberá hacer k veces y por último para β_0 .⁶³

En la hipótesis nula (H_0) se está probando una β en particular igual a cero, cualquier valor que se le asigne a la variable independiente que acompaña a la β se nulificarán; por ejemplo supóngase que se tiene la siguiente ecuación de regresión:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5$$

Ahora suponga que se está probando la β de la variable 2, es decir la X_2 y como se aceptó la hipótesis nula para esa β se concluye que $\beta_2 = 0$:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5$$

Entonces, no importa qué valor se le asigne a la X_2 , el término se volverá cero, eso significa que la variable X_2 no causa efecto en Y , por lo que la X_2 deberá salir de la ecuación, y por lo tanto la ecuación de regresión cambiaría y sería necesario volver a calcular sus coeficientes.

Caso contrario, si la hipótesis nula (H_0) es rechazada se prueba que esa $\beta_2 \neq 0$ por lo que la variable que acompaña a esa β se queda en la ecuación, y el pronóstico de la variable dependiente se incrementará o disminuirá según el valor de esa beta y del de esa X . Todo lo anterior es verificable bajo el cumplimiento de H_0 por medio del estadístico t-student.

Antes de empezar con el análisis es necesario estimar las varianzas de cada β , la cual se calcula de la matriz⁶⁴ $(X^T X)^{-1}$, como se muestra a continuación:

$(X^T X)^{-1} =$	0.0646	-0.082	-0.134	-0.092	-0.188	-0.231
	-0.082	0.026	0.012	-0.003	-0.016	0.011
	-0.134	0.012	0.040	-0.010	0.009	0.031
	-0.092	-0.003	-0.010	0.378	0.123	0.0117
	-0.188	-0.016	0.009	0.123	0.285	0.130
	-0.231	0.011	0.031	0.117	0.130	0.349

Figura 2-10 Matriz.

⁶² El SPSS™ reporta un p -valor de 0.000, aunque si la tabla se copia el valor es 1.489×10^{09} .

⁶³ Siempre y cuando tenga un significado realizar la prueba para β_0 .

⁶⁴ La matriz tuvo que encontrarse para calcular los coeficientes de regresión de la ecuación de regresión.

La matriz $(X^T X)^{-1}$ multiplicada por el MSE , que es el cuadrado medio del error, se encuentra en la tabla del ANOVA que se muestra a continuación:

Tabla 2-40 Valor de F

Fuente	SS	df	MS	F
Regresión (R)	3.507	5	0.701	45.016
Residual o error (E)	0.280	18	0.016	
Total (T)	3.787	23		

La matriz $(X^T X)^{-1} * MSE$ da como resultado otra denominada de varianzas y covarianzas de las β . La tabla anterior muestra que el MSE tiene un valor de 0.016. Los resultados de dicha operación se muestran a continuación:

$MSE * (X^T X)^{-1} =$	$0.016 * (X^T X)^{-1} =$	0.01007	-0.00127	-0.00208	-0.00143	-0.00185	-0.00361
		-0.00127	0.00040	0.00019	-0.00005	-0.00025	0.00017
		-0.00208	0.00019	0.00063	-0.00016	0.00013	0.00049
		-0.00143	-0.00005	-0.00016	0.00588	0.00191	0.00183
		-0.00185	-0.00025	0.00013	0.00191	0.00444	0.00203
		-0.00361	0.00017	0.00049	0.00183	0.00203	0.00544

Figura 2-11 Matriz de varianzas y covarianzas.

A la nueva matriz se le representa con la letra griega sigma, si las variables⁶⁵ se acomodan en orden se puede encontrar mucha información; la matriz con el nombre de las variables sería:

$\Sigma =$		Distancia	Cuartos	Norte	Oeste	Sur		
	β_0	β_1	β_2	β_3	β_4	β_5		
	0.01007	-0.00127	-0.00208	-0.00143	-0.00185	-0.00361	β_0	
	-0.00127	0.00040	0.00019	-0.00005	-0.00025	0.00017	β_1	Distancia
	-0.00208	0.00019	0.00063	-0.00016	0.00013	0.00049	β_2	Cuartos
	-0.00143	-0.00005	-0.00016	0.00588	0.00191	0.00183	β_3	Norte
	-0.00185	-0.00025	0.00013	0.00191	0.00444	0.00203	β_4	Oeste
	-0.00361	0.00017	0.00049	0.00183	0.00203	0.00544	β_5	Sur

Figura 2-12 Matriz sigma.

Por ejemplo, si se toma el valor de la variable cuartos con la variable norte, al analizar sólo la parte inferior de la matriz se tiene que el valor es de -0.00016, lo cual daría la covarianza entre β_2 y β_3 , que se representa con $Cov(\beta_2, \beta_3)$; la covarianza estimada sería $Cov(\hat{\beta}_2, \hat{\beta}_3)$, porque proviene de una muestra; como es negativo su valor esto indica que si se encuentra una relación entre la variable cuartos y norte sería inversa; sin embargo, la covarianza entre la zona sur y cuartos es positiva por lo que su relación sería directa. Cuando se analizan los valores de la diagonal se indica que es una variable consigo misma, por lo que en ese caso se interpreta como la varianza, aunque también se le puede llamar covarianza; por ejemplo: la varianza de la variable cuartos sería 0.00063, la cual se representa como $Var(\hat{\beta}_2)$, los valores de las varianzas siempre son positivos. El SPSSTM da el siguiente resultado:

⁶⁵ Es el orden en el cual fueron acomodadas para encontrar dicha matriz; además los valores de la diagonal para arriba son los mismos que de la diagonal para abajo.

Tabla 2-41 Matriz de correlaciones y covarianzas de los betas

Correlaciones de los coeficientes ^a			Sur	Distancia	Norte	Cuartos	Oeste
Modelo							
1	Correlaciones	Sur	1.000	.117	.323	.263	.413
		Distancia	.117	1.000	−.031	.378	−.186
		Norte	.323	−.031	1.000	−.082	.374
		Cuartos	.263	.378	−.082	1.000	.079
		Oeste	.413	−.186	.374	.079	1.000
	Covarianzas	Sur	.005	.000	.002	.000	.002
		Distancia	.000	.000	−4.7E−005	.000	.000
		Norte	.002	−4.7E−005	.006	.000	.002
		Cuartos	.000	.000	.000	.001	.000
		Oeste	.002	.000	.002	.000	.004

^aVariable dependiente: Ln_renta.

Le falta el primer renglón y la primera columna; los demás resultados se encuentran aunque no en el mismo orden, además sólo pone tres decimales, por eso muchos valores son ceros.

Si se obtiene la raíz cuadrada de la diagonal de estas varianzas, los valores resultantes se convierten en errores estándar, en este caso, de cada β . Dichos errores estándar serán utilizados para realizar la prueba de hipótesis de cada beta, los valores se presentan en la siguiente figura:

$\Sigma =$		Distancia	Cuartos	Norte	Oeste	Sur		
	β_0	β_1	β_2	β_3	β_4	β_5		
	0.10034						β_0	
		0.02003					β_1	Distancia
			0.02507				β_2	Cuartos
				0.07670			β_3	Norte
					0.06666		β_4	Oeste
						0.07376	β_5	Sur

Figura 2-13 Errores estándar.

A los errores estándar se les denominará $C_{i,i}$, a i se le asignará el número que tenga como subíndice la beta, por ejemplo la $C_{1,1}$ sería para el error estándar de la variable distancia. A continuación se realiza la prueba de hipótesis de la misma forma que la global: en la primera columna de la tabla que se formará se colocan los coeficientes y en la segunda los errores estándar; como se presenta en la siguiente tabla:

Tabla 2-42 Coeficientes y errores estándar

Variables	Coeficientes	Error estándar
Constante	8.197	0.100
Distancia	−0.027	0.020
Cuartos	0.310	0.025
Norte	0.184	0.077
Oeste	0.012	0.067
Sur	0.162	0.074

Se dividen los elementos de la columna de los coeficientes entre los de la columna de los errores estándar. Los resultados se muestran a continuación:

Tabla 2-43 Estadístico t-student

Variables	Coefficientes	Error estándar	t-student
Constante	8.197	0.100	81.695
Distancia	-0.027	0.020	-1.363
Cuartos	0.310	0.025	12.371
Norte	0.184	0.077	2.402
Oeste	0.012	0.067	0.176
Sur	0.162	0.074	2.201

Para encontrar el valor del estadístico calculado se deben seguir estas consideraciones:

$$b_i = \hat{\beta}_i \sim N(\beta_i, C_{i,i})$$

$$b_0 = \hat{\beta}_0 \sim N(\beta_0, \hat{C}_{0,0})$$

El estadístico de prueba sería construido con la siguiente fórmula:

Ecuación 2-22 Ecuación del estadístico t-student

$$t_{C_{x_i}} = \frac{b_i - \beta_{i \text{ Bajo } H_0}}{C_{i,i}} =$$

Si se desea calcular el estadístico para la variable X_1 sería de la siguiente forma:

$$t_{C_{x_1}} = \frac{b_1 - \beta_{1 \text{ Bajo } H_0}}{C_{1,1}} = \frac{-0.027 - 0}{0.020} = -1.363$$

El proceso para los demás estadísticos, para cada variable, sería el mismo.

La prueba de hipótesis también se puede realizar por medio de los intervalos de confianza para los β , por lo que se buscarán esos valores para posteriormente realizar las pruebas individuales para cada uno de los β .

Para los intervalos de confianza es necesario usar la siguiente fórmula:

Ecuación 2-23 Intervalos de confianza para los coeficientes


$$b_i \pm t_{t, \frac{\alpha}{2}, n-p} C_{i,i}$$

Para encontrar el estadístico teórico se necesita de $n - p$ grados de libertad y del nivel de significancia que es 5%; por lo que el estadístico de tablas sería:


$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p=24-6=18}$$

Al buscarlo en la tabla correspondiente, como se está construyendo el intervalo de confianza, hay dos extremos: al localizar los valores en la tabla por arriba serían con 0.05 y por abajo con 0.25, como se muestra a continuación:

Tabla 2-44 Parte de la tabla t-student



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
15	0.691	0.866	1.074	1.341	1.753	2.131	2.602	2.947	3.286	3.733	4.073	4.417
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015	4.346
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965	4.286
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.861	1.066	1.328	1.728	2.093	2.539	2.861	3.174	3.579	3.883	4.187
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850	4.146
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
df	0.25	0.20	1.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



El valor siempre coincide en la misma columna. Entonces el estadístico de tablas es:

$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p=18} = 2.101$$

Al utilizar la información de la siguiente tabla:

Tabla 2-45 Estadístico t-student

Variables	Coefficientes	Error estándar	t-student
Constante	8.197	0.100	81.695
Distancia	-0.027	0.020	-1.363
Cuartos	0.310	0.025	12.371
Norte	0.184	0.077	2.402
Oeste	0.012	0.067	0.176
Sur	0.162	0.074	2.201

Si desea encontrar el intervalo de confianza para la β de la variable distancia, en la fórmula se sustituirá así:

$$b_i \pm t_{t, \frac{\alpha}{2}, n-p} C_{i,i}$$

Entonces:

$$-0.027 \pm 2.101 \cdot 0.020$$

Al resolver la suma y luego la resta se obtuvieron los siguientes resultados:

$$-0.069 \leq \beta_1 \leq 0.015$$

Los resultados para las demás variables se acomodaron en la siguiente tabla:

Tabla 2-46 Intervalos de confianza

Variables	Coeficientes	Error estándar	T-student	Intervalo de confianza	
				Límite inferior	Límite superior
Constante	8.197	0.100	81.695	7.986	8.408
Distancia	-0.027	0.020	-1.363	-0.069	0.015
Cuartos	0.310	0.025	12.371	0.257	0.363
Norte	0.184	0.077	2.402	0.023	0.345
Oeste	0.012	0.067	0.176	-0.128	0.152
Sur	0.162	0.074	2.201	0.007	0.317

El SPSS™ acomoda los resultados de esta información en la tabla de los coeficientes de la siguiente manera.

Tabla 2-47 Coeficientes

Coeficientes ^a							
Modelo	Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B 95%	
	B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1 (Constante)	8.197	.100		81.695	.000	7.986	8.408
Distancia	-.027	.020	-.098	-1.363	.190	-.069	.015
Cuartos	.310	.025	.901	12.371	.000	.257	.363
Norte	.184	.077	.173	2.402	.027	.023	.345
Oeste	.012	.067	.013	.176	.862	-.128	.152
Sur	.162	.074	.166	2.201	.041	.007	.317

^aVariable dependiente: Ln_renta.

Ahora se realizarán las pruebas de hipótesis para cada coeficiente de la ecuación.

2.4.10.1 Pruebas de hipótesis de la variable distancia

Las hipótesis serían las siguientes:

$$H_0 : \beta_{x_1} = 0$$

$$H_1 : \beta_{x_1} \neq 0$$

Donde X_1 es la variable distancia. El estadístico calculado fue:

$$t_{C_{x_1}} = \frac{b_1 - \beta_{1 \text{ Bajo } H_0}}{C_{1,1}} = \frac{-0.027 - 0}{0.020} = -1.363$$

El estadístico teórico es:

$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p=18} = 2.101$$


Para rechazar la H_0 es necesario que,

$$|t_C| > t_{t, \frac{\alpha}{2}, n-p}$$

Si el valor estadístico calculado es de -1.363, su valor absoluto será 1.363; al comparar los valores se tiene.

$$1.363 < 2.101 \text{ no se rechaza } H_0$$

Para rechazar la H_0 es necesario que el estadístico calculado esté en la zona de rechazo:



También para rechazar la H_0 es necesario que en el intervalo de confianza no se encuentre el cero.

$$-0.069 \leq \beta_1 \leq 0.015$$

Si se incluye el cero se tiene:



Figura 2-14 Intervalo de confianza.

Si se incluye el cero en el intervalo no se rechaza la H_0 . Otra forma más de realizar la prueba de hipótesis es por el p-valor:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.190 > 0.05 \text{ no se rechaza } H_0$$

Al concluir que no se rechazó la hipótesis nula ($\beta_{x_1} = 0$), es claro que la variable distancia no logra explicar a la variable renta, por lo que es necesario quitarla de la ecuación.

De aquí en adelante el proceso se vuelve repetitivo para la prueba de hipótesis de cada β , por esta razón se llevará a cabo una sola vez, de diferentes maneras y no tan detallado como con la anterior. La variable siguiente es cuartos.

2.4.10.2 Pruebas de hipótesis de la variable cuartos

La variable cuartos es la segunda, sus hipótesis serían las siguientes:

$$H_0 : \beta_{x_2} = 0$$

$$H_1 : \beta_{x_2} \neq 0$$

Según la tabla que se muestra a continuación.

Tabla 2-48 Información para la prueba de hipótesis

Variables	Coeficientes	Error estándar	t-student	Intervalo de confianza	
				Límite inferior	Límite superior
Constante	8.197	0.100	81.695	7.986	8.408
Distancia	-0.027	0.020	-1.363	-0.069	0.015
Cuartos	0.310	0.025	12.371	0.257	0.363
Norte	0.184	0.077	2.402	0.023	0.345
Oeste	0.012	0.067	0.176	-0.128	0.152
Sur	0.162	0.074	2.201	0.007	0.317

Como se muestra en la siguiente figura, el intervalo de confianza no incluye el cero.




Figura 2-15 Intervalo de confianza.

Se concluye que se rechazó la hipótesis nula, por lo que $\beta_{x_2} \neq 0$, es decir, la variable cuartos sí explica la variable renta, por lo que es necesario dejarla en la ecuación.

2.4.10.3 Pruebas de hipótesis de la variable norte

La variable norte es la tercera, sus hipótesis serían las siguientes:

$$H_0 : \beta_{x_3} = 0$$

$$H_1 : \beta_{x_3} \neq 0$$

Según la tabla que se muestra a continuación.

Tabla 2-49 Información para la prueba de hipótesis

Variables	Coeficientes	Error estándar	t-student	Intervalo de confianza	
				Límite inferior	Límite superior
Constante	8.197	0.100	81.695	7.986	8.408
Distancia	-0.027	0.020	-1.363	-0.069	0.015
Cuartos	0.310	0.025	12.371	0.257	0.363
Norte	0.184	0.077	2.402	0.023	0.345
Oeste	0.012	0.067	0.176	-0.128	0.152
Sur	0.162	0.074	2.201	0.007	0.317

Para rechazar la H_0 es necesario que:

$$|t_C| > t_{t, \frac{\alpha}{2}, n-p}$$

Si el valor del estadístico calculado es de 2.402, al comparar los valores se tiene.

$$2.402 > 2.101 \text{ se rechaza } H_0$$

Como se rechazó la hipótesis nula ($\beta_{x_3} \neq 0$) se sabe que la variable norte sí explica a la variable renta, por lo que es necesario dejarla en la ecuación.

2.4.10.4 Pruebas de hipótesis de la variable oeste

La variable oeste es la cuarta variable, sus hipótesis serían las siguientes:

$$H_0 : \beta_{x_4} = 0$$

$$H_1 : \beta_{x_4} \neq 0$$

Según la tabla que se muestra a continuación.

Tabla 2-50 Información para la prueba de hipótesis

Variables	Coeficientes	Error estándar	t-student	Intervalo de confianza	
				Límite inferior	Límite superior
Constante	8.197	0.100	81.695	7.986	8.408
Distancia	-0.027	0.020	-1.363	-0.069	0.015
Cuartos	0.310	0.025	12.371	0.257	0.363
Norte	0.184	0.077	2.402	0.023	0.345
Oeste	0.012	0.067	0.176	-0.128	0.152
Sur	0.162	0.074	2.201	0.007	0.317

Como se muestra en la siguiente figura, el intervalo de confianza incluye el cero.




Figura 2-16 Intervalo de confianza.

En este caso no se rechazó la hipótesis nula ($\beta_{x_4} \neq 0$); es decir, la variable oeste no explica a la variable renta, por lo que es necesario eliminarla de la ecuación.

2.4.10.5 Pruebas de hipótesis de la variable sur

La variable sur es la quinta y última variable, sus hipótesis serían las siguientes:

$$H_0 : \beta_{x_5} = 0$$

$$H_1 : \beta_{x_5} \neq 0$$

Según la tabla que se muestra a continuación.

Tabla 2-51 Información para la prueba de hipótesis

Variables	Coeficientes	Error estándar	t-student	Intervalo de confianza	
				Límite inferior	Límite superior
Constante	8.197	0.100	81.695	7.986	8.408
Distancia	-0.027	0.020	-1.363	-0.069	0.015
Cuartos	0.310	0.025	12.371	0.257	0.363
Norte	0.184	0.077	2.402	0.023	0.345
Oeste	0.012	0.067	0.176	-0.128	0.152
Sur	0.162	0.074	2.201	0.007	0.317

Para rechazar la H_0 es necesario que,

$$|t_C| > t_{t, \frac{\alpha}{2}, n-p}$$

Si el valor del estadístico calculado es de 2.201, al comparar los valores se tiene.

$$2.201 > 2.101 \text{ se rechaza } H_0$$

Como se rechazó la hipótesis nula ($\beta_{x_5} \neq 0$) se sabe que la variable sur sí explica a la variable renta, por lo que es necesario dejarla en la ecuación.

Toma de decisiones. Se concluye que las variables distancia y oeste no afectan de forma lineal a la variable renta, por lo que es necesario eliminarlas del modelo. La nueva ecuación sería:

Tabla 2-52 Nueva ecuación sin las variables distancia y oeste

Coeficientes ^a									
		Coeficientes no estandarizados		Coeficientes estandarizados		Intervalo de confianza para B 95%		Estadísticos de colinealidad	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia FIV
1	(Constante)	8.197	.066		122.609	.000	7.969	8.245	
	Cuartos	.323	.023	.940	14.171	.000	.276	.371	.929
	Norte	.183	.071	.172	2.589	.018	.036	.331	.926
	Sur	.177	.065	.181	2.702	.014	.040	.313	.915

^aVariable dependiente: Ln_renta.

Al revisar la tabla anterior se concluye que no existe multicolinealidad entre las tres variables del modelo; además los tres coeficientes son significativamente diferentes a cero. La nueva función sería:

$$\hat{Y} = 8.107 + 0.323X_1 + 0.183X_2 + 0.177X_3$$

Donde la primera variable sería cuartos, la segunda norte y la tercera sur. Los grados de libertad cambiaron ($p = 4$ ya que $K = 3$). Al continuar con el proceso y suponiendo que no se ha eliminado ninguna variable se tiene que:

Lo único que resta es probar que la:

$$\beta_0 \neq 0$$


2.4.10.6 Pruebas de hipótesis para la constante

Cabe aclarar que esta hipótesis se prueba bajo la consideración de que las estimaciones sobre el otro parámetro permanecen fijas; es decir, que no varían y que solamente se deben realizar cuando tenga sentido hacerlo. En este caso, supóngase que sí es necesario, por lo que se procede de la misma manera que las pruebas anteriores. Las hipótesis serían:

$$H_0 : \beta_0 = 0$$


$$H_1 : \beta_0 \neq 0$$

Si la hipótesis nula ($\beta_0 = 0$) es aceptada, la línea de regresión pasará por el origen, esto visualmente en tres dimensiones sería de la siguiente manera:



Gráfica 2-13 Modelo de regresión pasando por el origen.


La función de regresión pasaría por el origen. En dos dimensiones sería de la siguiente forma:




Gráfica 2-14 Modelo de regresión pasando por el origen.

Si $\beta_0 = 0$ es necesario volver a calcular la ecuación y quitar a β_0 , ya que la línea modificaría la inclinación.

Si la hipótesis nula es rechazada ($\beta_0 \neq 0$) entonces la línea de regresión no pasaría por el origen. En tres y dos dimensiones se vería de la siguiente manera:



Gráfica 2-15 La función de regresión no pasa por el origen.



Gráfica 2-16 La función de regresión no pasa por el origen.

El estadístico que utiliza es el mismo que con los otros parámetros.

$$t_{C\beta_0} = \frac{b_0 - \beta_0 \text{ Bajo } H_0}{C_{0,0}} =$$

Y el intervalo de confianza sería:

$$b_0 \pm t_{t, \frac{\alpha}{2}, n-p} C_{0,0}$$

De acuerdo con el ejemplo se tiene la siguiente información.

Tabla 2-53 Coeficientes finales

Coeficientes ^a							
	Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B 95%	
Modelo	B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1 (Constante)	8.107	.066		122.609	.000	7.969	8.245
Cuartos	.323	.023	.940	14.171	.000	.276	.371
Norte	.183	.071	.172	2.589	.018	.036	.331
Sur	.177	.065	.181	2.702	.014	.040	.313

^aVariable dependiente: Ln_renta,

Al sustituir los valores en la fórmula de la t , se tiene que:

$$t_{C_{\beta_0}} = \frac{b_0 - \beta_0 \text{ Bajo } H_0}{C_{0,0}} = \frac{8.107 - 0}{0.066} = 122.609$$

O bien, para construir el intervalo de confianza se tiene que:


$$8.107 \pm 2.086 * 0.066$$

El estadístico teórico es:


$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p = 24-4=20} = 2.086$$

Donde $p = k + 1 = 3 + 1 = 4$ ya que solamente se tienen tres variables independientes o regresoras, las cuales son: cuartos, norte y sur: el estadístico teórico sale de la siguiente manera:


Tabla 2-54 Parte de la tabla t-student



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965	4.286
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.861	1.066	1.328	1.728	2.093	2.539	2.861	3.174	3.579	3.883	4.187
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850	4.146
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
22	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792	4.077
23	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.768	4.047
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Se sabe que para rechazar la H_0 es necesario que el estadístico calculado esté en la zona de rechazo:



Como se rechazó la hipótesis nula entonces se concluye que:

$\beta_0 \neq 0$, así que dicha beta deberá quedarse en la ecuación.

Como $\beta_0 \neq 0$ indica que sí es correcta la función, la cual sería:

$$\hat{Y} = 8.107 + 0.323X_1 + 0.183X_2 + 0.177X_3$$

Una vez terminado el proceso y depurado el modelo, se procede a evaluarlo.

2.5 Evaluación del modelo

Existen varias formas de evaluar lo adecuado del modelo; es decir, qué tan bien se ajustaron los datos a través de la ecuación de regresión, todas se basan en los errores y en su suma de cuadrados; dichas medidas son:




Figura 2-17 Formas de evaluar el modelo.

Cada una de estas medidas indican de diferente manera lo bueno del ajuste, se empezará por explicar el primero.

2.5.1 Coeficiente de determinación

Este coeficiente indica en términos porcentuales la variabilidad⁶⁶ que tiene la variable dependiente y la cantidad que fue captada o explicada en forma lineal por las variables independientes;⁶⁷ sus fórmulas son:

Ecuación 2-24 Coeficiente de determinación

$$R^2 = 1 - \frac{SSE}{SST} = \frac{SSR}{SST}$$

⁶⁶ Variación total = SST .

⁶⁷ La variabilidad es explicada por la ecuación de regresión, es decir, la variación explicada SSR .

Donde:

SSR : es la variación explicada.

SST : es la variación total.






SSE : es la variación no explicada.

Al momento de estimarla sería $R^2 = \hat{\rho}^2$. Los valores de este coeficiente oscilan entre:

$$0 \leq R^2 \leq 1$$

Un valor cercano a cero indica que no se captó casi nada de la variación total o del comportamiento de Y ; por el contrario, un valor cercano a 1 indica que casi 100% de la variabilidad fue captada o es explicada por el modelo;⁶⁸ es decir, por las variables independientes. Esto en dos dimensiones se visualizaría de la siguiente manera:

Tabla 2-55 Variabilidades captadas

	Existe una relación lineal perfecta entre la X y la Y ; lo cual indica que 100% de la variación fue explicada por la X ; por lo que su $R^2 = 1$
	Existe una relación lineal perfecta entre la X y la Y ; lo cual indica que 100% de la variación fue explicada por la X ; por lo que su $R^2 = 1$
	Existe una relación lineal casi perfecta entre la X y la Y ; lo cual indica que menos de 100% de la variación fue explicada por la X ; por lo que su $0 < R^2 < 1$, pero es más cercano a 1 que a cero
	Existe una relación lineal casi perfecta entre la X y la Y ; lo cual indica que menos de 100% de la variación fue explicada por la X ; por lo que su $0 < R^2 < 1$, pero es más cercano a 1 que a cero
	No existe una relación lineal entre la X y la Y ; lo cual indica que fue captada casi nada de la variación, es decir que la X no explica casi nada a la Y ; por lo que su $R^2 \approx 0$

⁶⁸ Los términos *función* o *ecuación* son sinónimos de *modelo*.

Lo que se busca es que el modelo capte la mayor variación posible o el mayor comportamiento posible de Y , entonces es preferible que sea cercano a 1.

Para calcular el coeficiente de determinación en el ejemplo⁶⁹ es necesario encontrar las tres variaciones (identificadas con anterioridad) por lo que la tabla sería la siguiente:

Tabla 2-56 Variaciones

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y-\text{Prom})^2$	$(\hat{Y}-\text{Prom})^2$	$(Y-\hat{Y})^2$
9.048	2	0	1	8.930	0.004	0.003	0.014
9.094	2	1	0	8.937	0.012	0.002	0.025
9.547	4	1	0	9.584	0.318	0.361	0.001
8.517	1	0	0	8.430	0.217	0.305	0.008
9.306	4	0	0	9.400	0.104	0.174	0.009
8.987	2	0	0	8.754	0.000	0.052	0.055
9.048	2	0	1	8.930	0.004	0.003	0.014
9.393	4	0	0	9.400	0.168	0.174	0.000
8.269	1	0	0	8.430	0.510	0.305	0.026
9.393	4	0	0	9.400	0.168	0.174	0.000
8.923	3	0	0	9.077	0.004	0.009	0.024
9.071	3	0	0	9.077	0.008	0.009	0.000
8.987	3	0	0	9.077	0.000	0.009	0.008
8.243	1	0	0	8.430	0.547	0.305	0.035
8.854	2	1	0	8.937	0.017	0.002	0.007
9.105	3	0	1	9.254	0.015	0.073	0.022
8.412	1	0	0	8.430	0.326	0.305	0.000
8.476	1	0	1	8.607	0.256	0.141	0.017
8.975	2	0	1	8.930	0.000	0.003	0.002
8.517	1	0	0	8.430	0.217	0.305	0.008
9.510	4	0	0	9.400	0.279	0.174	0.012
9.510	4	0	0	9.400	0.279	0.174	0.012
8.854	2	0	0	8.754	0.017	0.052	0.010
9.547	4	1	0	9.584	0.318	0.361	0.001
Prom =	8.983			Suma =	3.787	3.478	0.310
					SST	SSR	SSE

Con dos de las tres variaciones se calcula el coeficiente de determinación, el cual sería:

$$R^2 = \frac{SSR}{SST} = \frac{3.478}{3.787} = 0.918$$

⁶⁹ Ya no están las variables *estudiante*, *distancia* y *oeste* pues se decidió eliminarlas por las siguientes razones: la primera tenía severos problemas de colinealidad con la variable “cuartos” y las dos restantes no eran significativas para explicar el comportamiento de la variable Y .

También se podría calcular de la siguiente manera:

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{0.310}{3.787} = 0.918$$

Como el valor es cercano a 1⁷⁰ (0.918) podría decirse que la mayoría de la variabilidad fue captada o explicada por la ecuación; también podría señalarse que la relación lineal que existe entre las X y la Y es bastante buena y que la variación no explicada es de 8.17%.

$$1 - 0.918 = 0.0817$$

2.5.2 Coeficiente de determinación corregido

El coeficiente de determinación corregido también denominado *coeficiente de determinación ajustado*; indica en términos porcentuales cuánta variabilidad de la variable dependiente fue captada por la ecuación, pero ajustada o corregida por los grados de libertad.⁷¹ Su fórmula es:

Ecuación 2-25 Coeficiente de determinación ajustado

$$R_{Adj}^2 = \bar{R}^2 = 1 - \left[\left(1 - R^2 \right) \frac{n-1}{n-p} \right] = 1 - \frac{\frac{SSE}{n-1}}{\frac{SST}{n-p}} = \left[R^2 - \frac{k}{n-1} \right] \left[\frac{n-1}{n-p} \right]$$

Donde:

R^2 : es el coeficiente de determinación;

n : es el número de datos;

p : es el número de parámetros en el análisis: $p = k + 1$, donde k es el número de variables independientes más 1 = p .⁷²

k : es el número de variables independientes.

Para calcular el coeficiente es necesario encontrar lo no explicado,⁷³ luego ajustarlo o corregirlo por los grados de libertad (cuando se multiplica) y posteriormente volverlo a su forma original.⁷⁴ La diferencia entre la R^2 y la R^2 corregida es que para calcular el primero no se usaron los grados de libertad y para el segundo sí; otra diferencia es cuándo se deberán utilizar; por ejemplo, si se comparan dos ecuaciones de regresión, la primera tiene 24 datos y 5 variables independientes y la segunda tiene 25 datos y 3 variables independientes, la pregunta obvia sería ¿con cuál modelo o ecuación nos quedaríamos o cuál de las dos sería la mejor? La respuesta sería con aquella que tenga el mayor coeficiente de determinación ajustado; esto debido a que al tener diferente número de datos y de variables independientes los grados de libertad cambian y no es posible utilizar la R^2 . Es decir, si los grados de libertad son diferentes es necesario utilizar el ajustado.

Cuando el coeficiente es estimado sería en la forma: $R_{Adj}^2 = \hat{\rho}_{Adj}^2$.

Los valores de este coeficiente también oscilan, al igual que el coeficiente de determinación; es decir, se encuentra entre:

$$0 \leq R_{Adj}^2 \leq 1$$

Y su significado sería el mismo; es decir, un valor cercano a cero indica que se captó casi nada de la variación total de Y , pero corregida por los grados de libertad. Por el contrario, un valor cercano a 1 señala

⁷⁰ Casi se captó 100%, es decir 91.8% del comportamiento de Y .

⁷¹ Es lo mismo que la R^2 , pero corregida o ajustada por los grados de libertad.




⁷² El más 1 se debe a B_0 , entonces p sería el número de parámetros estimados.

⁷³ En donde $1 - R^2$ sería la variación que no fue captada o explicada por regresión o bien no fue corregida.

⁷⁴ En donde $[1 - \text{el no corregido}]$ sería la variación que fue captada por regresión.

que casi 100% de la variabilidad fue captada, pero corregida por los grados de libertad. Como lo importante es que el modelo capte la mayor variación es preferible que sea cercano a 1:

Tabla 2-57 Variabilidades captadas

	Existe una relación lineal perfecta entre la X y la Y ; lo cual indica que 100% de la variación fue explicada por la X ; por lo que su $R^2_{Adj} = 1$
	Existe una relación lineal perfecta entre la X y la Y ; lo cual indica que 100% de la variación fue explicada por la X ; por lo que su $R^2_{Adj} = 1$
	Existe una relación lineal casi perfecta entre la X y la Y ; lo cual indica que menos de 100% de la variación fue explicada por la X ; por lo que su $0 < R^2_{Adj} < 1$, pero es más cercano a 1 que a cero
	Existe una relación lineal casi perfecta entre la X y la Y ; lo cual indica que menos de 100% de la variación fue explicada por la X ; por lo que su $0 < R^2_{Adj} < 1$, pero es más cercano a 1 que a cero
	No existe una relación lineal entre la X y la Y ; lo cual indica que fue captada casi nada de la variación, es decir, que la X no explicaba a la Y ; por lo que su $R^2_{Adj} \approx 0$

De acuerdo con el ejemplo se tiene la siguiente información:

Tabla 2-58 Variaciones

Y	X_1	X_2	X_3	$\hat{Y}$	$(Y - \text{Prom})^2$	$(\hat{Y} - \text{Prom})^2$	$(Y - \hat{Y})^2$
Ln_renta	Cuartos	Norte	Sur	Estimación			
9.048	2	0	1	8.930	0.004	0.003	0.014
9.094	2	1	0	8.937	0.012	0.002	0.025
9.547	4	1	0	9.584	0.318	0.361	0.001

(continúa)

Tabla 2-58 Variaciones (continuación)

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y-Prom)^2$	$(\hat{Y}-Prom)^2$	$(Y-\hat{Y})^2$
8.517	1	0	0	8.430	0.217	0.305	0.008
9.306	4	0	0	9.400	0.104	0.174	0.009
8.987	2	0	0	8.754	0.000	0.052	0.055
9.048	2	0	1	8.930	0.004	0.003	0.014
9.393	4	0	0	9.400	0.168	0.174	0.000
8.269	1	0	0	8.430	0.510	0.305	0.026
9.393	4	0	0	9.400	0.168	0.174	0.000
8.923	3	0	0	9.077	0.004	0.009	0.024
9.071	3	0	0	9.077	0.008	0.009	0.000
8.987	3	0	0	9.077	0.000	0.009	0.008
8.243	1	0	0	8.430	0.547	0.305	0.035
8.854	2	1	0	8.937	0.017	0.002	0.007
9.105	3	0	1	9.254	0.015	0.073	0.022
8.412	1	0	0	8.430	0.326	0.305	0.000
8.476	1	0	1	8.607	0.256	0.141	0.017
8.975	2	0	1	8.930	0.000	0.003	0.002
8.517	1	0	0	8.430	0.217	0.305	0.008
9.510	4	0	0	9.400	0.279	0.174	0.012
9.510	4	0	0	9.400	0.279	0.174	0.012
8.854	2	0	0	8.754	0.017	0.052	0.010
9.547	4	1	0	9.584	0.318	0.361	0.001
Prom =	8.983			Suma =	3.787	3.478	0.310
					SST	SSR	SSE

La información anterior es cuando aún no se ha calculado la R^2 , por lo que se tendrían que investigar primero las tres variaciones, las cuales se mostraron en la tabla anterior.

Cuando ya se tienen las tres variaciones se calcula la R^2 y luego la R^2_{Adj} .

También, si ya se conoce la R^2 :

$$R^2 = \frac{SSR}{SST} = \frac{3.478}{3.787} = 0.918$$

Entonces el coeficiente de determinación corregido se calcularía de la siguiente manera:

$$R^2_{Adj} = 1 - \left[(1 - 0.918) \frac{24 - 1}{24 - 4} \right] = 0.906$$

O bien:

$$R^2_{Adj} = 1 - \frac{\frac{0.310}{24 - 4}}{\frac{3.787}{24 - 1}} = 0.906$$

Y por último:

$$R_{Adj}^2 = \left[R^2 - \frac{k}{n-1} \right] \left[\frac{n-1}{n-p} \right] = \left[0.918 - \frac{3}{24-1} \right] \left[\frac{24-1}{24-4} \right] = 0.906$$

Esto significa que de 100% de la variación que tiene la variable dependiente (Y), 90.6% fue captada por la ecuación, pero ajustada por sus grados de libertad; la variación que no se explicó es de 9.4%.

$$1 - 0.906 = 0.094$$

2.5.3 Coeficiente de correlación de múltiple

A este coeficiente se le denomina *múltiple* porque es una correlación multivariante, es decir, entre muchas variables; en el análisis de correlación hay bivariadas, que es sólo entre dos variables, llamada de Pearson.⁷⁵ La correlación múltiple en términos porcentuales indica el poder de asociación o la relación que tienen las variables independientes (las X) con la dependiente (Y). La fórmula para calcularlo es:

Ecuación 2-26 Coeficiente de correlación múltiple

$$R_{Y|X_1, X_2, \dots, X_k} = \sqrt{R^2}$$

Donde:

$R_{Y|X_1, X_2, \dots, X_k}$: es la correlación o asociación de Y con las X .

R^2 : es el coeficiente de determinación.

Los valores del coeficiente de correlación múltiple oscilan entre:

$$0 \leq R_{Y|X_1, X_2, \dots, X_k} \leq 1$$

Un valor cercano a cero indica que las variables independientes X no están asociadas o no tienen una relación con la dependiente, un valor cercano a 1 señala que hay una fuerte asociación o relación entre las X y la Y , o que la relación es de casi 100%.

Volviendo al ejemplo se tiene la siguiente información:

Tabla 2-59 Variaciones

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y - \text{Prom})^2$	$(\hat{Y} - \text{Prom})^2$	$(Y - \hat{Y})^2$
9.048	2	0	1	8.930	0.004	0.003	0.014
9.094	2	1	0	8.937	0.012	0.002	0.025
9.547	4	1	0	9.584	0.318	0.361	0.001
8.517	1	0	0	8.430	0.217	0.305	0.008
9.306	4	0	0	9.400	0.104	0.174	0.009
8.987	2	0	0	8.754	0.000	0.052	0.055
9.048	2	0	1	8.930	0.004	0.003	0.014
9.393	4	0	0	9.400	0.168	0.174	0.000
8.269	1	0	0	8.430	0.510	0.305	0.026
9.393	4	0	0	9.400	0.168	0.174	0.000

(continúa)

⁷⁵ La correlación de Pearson se utilizó en este capítulo para encontrar multicolinealidad entre dos variables, por eso se le denomina *bivariada*.

Tabla 2-59 Variaciones (continuación)

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y-\text{Prom})^2$	$(\hat{Y}-\text{Prom})^2$	$(Y-\hat{Y})^2$
8.923	3	0	0	9.077	0.004	0.009	0.024
9.071	3	0	0	9.077	0.008	0.009	0.000
8.987	3	0	0	9.077	0.000	0.009	0.008
8.243	1	0	0	8.430	0.547	0.305	0.035
8.854	2	1	0	8.937	0.017	0.002	0.007
9.105	3	0	1	9.254	0.015	0.073	0.022
8.412	1	0	0	8.430	0.326	0.305	0.000
8.476	1	0	1	8.607	0.256	0.141	0.017
8.975	2	0	1	8.930	0.000	0.003	0.002
8.517	1	0	0	8.430	0.217	0.305	0.008
9.510	4	0	0	9.400	0.279	0.174	0.012
9.510	4	0	0	9.400	0.279	0.174	0.012
8.854	2	0	0	8.754	0.017	0.052	0.010
9.547	4	1	0	9.584	0.318	0.361	0.001
Prom =	8.983			Suma =	3.787	3.478	0.310
					SST	SSR	SSE

La información anterior es cuando aún no se ha calculado la R^2 ; por lo que primero es necesario conocer las tres variaciones, las cuales fueron mostradas en la tabla anterior.

Con dichas variaciones se calcula la R^2 y luego la R . Si ya se dispone de la información de la R^2 (cálculo anterior) y su valor fue de 0.918, el coeficiente de correlación múltiple se calcularía de la siguiente manera:

$$R_{Y|X_1, X_2, \dots, X_k} = \sqrt{R^2} = \sqrt{0.918} = 0.958$$

2.5.4 Error estándar del estimado

Este valor proporciona un indicio de qué tan bien se ajusta la línea a los datos; es decir, qué tanta dispersión tienen los valores observados alrededor del modelo de regresión en todos los datos.⁷⁶ Las fórmulas para calcularlo son:

Ecuación 2-27 Error estándar del estimado

$$S_e = \hat{\sigma} = \sqrt{\text{Var}(\hat{\epsilon})} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{SSE}{n-p}} = \sqrt{MSE}$$

Donde:

σ^2 : es la varianza de los errores.

SSE : es la variación no explicada.

n : es el número de datos.

p : es el número de parámetros en el análisis y que $p = k + 1$, donde k es el número de variables independientes más 1 = p .⁷⁷

MSE : es la suma de cuadrados promediada; es decir, dividida entre sus grados de libertad.

⁷⁶ En regresión simple sería las parejas (X, Y) .






⁷⁷ El más 1 se debe a B_0 . Entonces p sería el número de parámetros estimados.

Los valores del error estándar⁷⁸ del estimado deben ser:

$$S_e \geq 0$$

Un valor cercano a cero indica que existe casi nada de dispersión a través de la línea de regresión y que el ajuste es casi perfecto, lo que significa que la mayoría de los datos reales se encuentra sobre la línea de regresión;⁷⁹ si el dato fuera grande indicaría que los valores están muy dispersos o alejados de la línea de regresión; es decir, el ajuste es casi nulo; lo que significa que el modelo de regresión es malo (las variables elegidas no fueron las indicadas). Lo que interesa es que esta medida sea lo más pequeña posible o lo más cercana a cero. Gráficamente en dos dimensiones esto sería de la siguiente manera:

Tabla 2-60 Dispersiones

	Ajuste perfecto, casi no hay dispersión; por lo que su $S_e \approx 0$
	Ajuste perfecto, casi no hay dispersión; por lo que su $S_e \approx 0$
	Ajuste casi perfecto; es decir, hay dispersión pero muy poca; su $S_e > 0$, pero cercano a cero
	Ajuste casi perfecto; es decir, hay dispersión pero muy poca; su $S_e > 0$, pero cercano a cero
	Ajuste nulo; es decir, existe mucha dispersión; por lo que su $S_e \approx \infty$ es muy grande

⁷⁸ Es una medida que, al igual que el coeficiente de determinación corregido, se puede utilizar para comparar dos o más modelos de regresión ya que el error estándar tiene los grados de libertad.

⁷⁹ El valor del S_e de cero implica que todos los puntos o datos reales caen sobre la línea de regresión por lo que el ajuste sería excelente.

La información requerida ya fue calculada, la cual se muestra a continuación:

Tabla 2-61 Variaciones

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y-Prom)^2$	$(\hat{Y}-Prom)^2$	$(Y-\hat{Y})^2$
9.048	2	0	1	8.930	0.004	0.003	0.014
9.094	2	1	0	8.937	0.012	0.002	0.025
9.547	4	1	0	9.584	0.318	0.361	0.001
8.517	1	0	0	8.430	0.217	0.305	0.008
9.306	4	0	0	9.400	0.104	0.174	0.009
8.987	2	0	0	8.754	0.000	0.052	0.055
9.048	2	0	1	8.930	0.004	0.003	0.014
9.393	4	0	0	9.400	0.168	0.174	0.000
8.269	1	0	0	8.430	0.510	0.305	0.026
9.393	4	0	0	9.400	0.168	0.174	0.000
8.923	3	0	0	9.077	0.004	0.009	0.024
9.071	3	0	0	9.077	0.008	0.009	0.000
8.987	3	0	0	9.077	0.000	0.009	0.008
8.243	1	0	0	8.430	0.547	0.305	0.035
8.854	2	1	0	8.937	0.017	0.002	0.007
9.105	3	0	1	9.254	0.015	0.073	0.022
8.412	1	0	0	8.430	0.326	0.305	0.000
8.476	1	0	1	8.607	0.256	0.141	0.017
8.975	2	0	1	8.930	0.000	0.003	0.002
8.517	1	0	0	8.430	0.217	0.305	0.008
9.510	4	0	0	9.400	0.279	0.174	0.012
9.510	4	0	0	9.400	0.279	0.174	0.012
8.854	2	0	0	8.754	0.017	0.052	0.010
9.547	4	1	0	9.584	0.318	0.361	0.001
Prom =	8.983			Suma =	3.787	3.478	0.310
					SST	SSR	SSE

Después se procede a calcular el error estándar del estimado con la siguiente fórmula:

$$S_e = \sqrt{\frac{SSE}{n-p}} = \sqrt{\frac{0.310}{24-4}} = \sqrt{0.015} = 0.1244$$

Como la variable dependiente (Y) fue transformada,⁸⁰ el valor de S_e deberá ser destransformado, por lo que su valor deberá ser:

$$S_e = e^{0.1244} = 1.1325$$

⁸⁰ La variable dependiente se transformó en forma logarítmica (ln) por lo que la función inversa del Ln es el exponencial.

Este dato sigue siendo pequeño por lo que se espera que la mayoría de los errores sea pequeño; es decir, el ajuste o la dispersión de los datos alrededor del modelo de regresión es bastante bueno. Es importante señalar que se dice pequeño pero ¿comparado con qué? Para afirmar esto es necesario tener otro modelo y ahora sí concluir si es pequeño o grande. Por ejemplo, si se tuviera un nuevo modelo cuyo error estándar es 0.98, entonces este último modelo sería mejor.

Un valor grande en S_e significa que la mayoría de los errores será grande, por lo que el ajuste del modelo es pobre, lo cual significa que la ecuación captará o explicará muy poco de la variable dependiente. Un valor pequeño en S_e significa que los errores tienden a ser pequeños o cercanos a cero,⁸¹ por lo que el ajuste en el modelo es bueno.

2.5.5 Varianza de los errores

Para obtener la varianza de los errores es necesario que el estudio se haga con la población y como esto es imposible, pues se necesitaría más tiempo, dinero y esfuerzo, se calculará en la varianza de los residuales; es decir, de la muestra y se estimará la población. Este estadístico proporciona un indicio de la dispersión o variabilidad, qué tan bien el modelo se ajustó a los datos. Las fórmulas para calcularlo son:

Ecuación 2-28 Varianza de los errores

$$\hat{\sigma}_e^2 = \frac{SSE}{n - p} = MSE = (S_e)^2$$

Donde:

S_e : es el error estándar del estimado.

SSE : es la variación no explicada.

n : es el número de datos.

p : es el número de parámetros en el análisis y $p = k + 1$, donde k es el número de variables independientes más 1 = p .⁸²

MSE : es la suma de cuadrados promediada; es decir, dividida entre sus grados de libertad.

La raíz cuadrada de este estadístico daría el error estándar del estimado, obtenido en el inciso pasado, por lo que para encontrar la varianza de los residuales lo único que se debe hacer es elevar al cuadrado dicho número; o bien suponiendo que se tiene la variación no explicada, la cual está en la siguiente tabla:

Tabla 2-62 Variaciones

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y - \text{Prom})^2$	$(\hat{Y} - \text{Prom})^2$	$(Y - \hat{Y})^2$
9.048	2	0	1	8.930	0.004	0.003	0.014
9.094	2	1	0	8.937	0.012	0.002	0.025
9.547	4	1	0	9.584	0.318	0.361	0.001
8.517	1	0	0	8.430	0.217	0.305	0.008
9.306	4	0	0	9.400	0.104	0.174	0.009

(continúa)

⁸¹ Uno de los supuestos en los errores de la regresión es que la media de los errores es cero.

⁸² El más 1 se debe a B_0 . Entonces p sería el número de parámetros estimados. Donde p es el número de parámetros estimados, es decir $p = k + 1$, además el numerador (SSE) ya fue calculado en incisos pasados, ya que es la variación no explicada y se utilizó para conocer los coeficientes anteriores; las siglas MSE son los cuadrados medios del error o MSE y sale de dividir la variación no explicada entre sus grados de libertad.

Tabla 2-62 Variaciones (continuación)

Y	X_1	X_2	X_3	$\hat{Y}$			
Ln_renta	Cuartos	Norte	Sur	Estimación	$(Y-Prom)^2$	$(\hat{Y}-Prom)^2$	$(Y-\hat{Y})^2$
8.987	2	0	0	8.754	0.000	0.052	0.055
9.048	2	0	1	8.930	0.004	0.003	0.014
9.393	4	0	0	9.400	0.168	0.174	0.000
8.269	1	0	0	8.430	0.510	0.305	0.026
9.393	4	0	0	9.400	0.168	0.174	0.000
8.923	3	0	0	9.077	0.004	0.009	0.024
9.071	3	0	0	9.077	0.008	0.009	0.000
8.987	3	0	0	9.077	0.000	0.009	0.008
8.243	1	0	0	8.430	0.547	0.305	0.035
8.854	2	1	0	8.937	0.017	0.002	0.007
9.105	3	0	1	9.254	0.015	0.073	0.022
8.412	1	0	0	8.430	0.326	0.305	0.000
8.476	1	0	1	8.607	0.256	0.141	0.017
8.975	2	0	1	8.930	0.000	0.003	0.002
8.517	1	0	0	8.430	0.217	0.305	0.008
9.510	4	0	0	9.400	0.279	0.174	0.012
9.510	4	0	0	9.400	0.279	0.174	0.012
8.854	2	0	0	8.754	0.017	0.052	0.010
9.547	4	1	0	9.584	0.318	0.361	0.001
Prom =	8.983			Suma =	3.787	3.478	0.310
					SST	SSR	SSE

Con dichos valores se obtiene lo siguiente:

$$\hat{\sigma}_\varepsilon^2 = \frac{SSE}{n-p} = \frac{0.310}{24-4} = MSE = 0.015$$

O bien:

$$\hat{\sigma}_\varepsilon^2 = (S_\varepsilon)^2 = (0.1244)^2 = 0.015$$

Un valor de la varianza cercano a cero indica que existe casi nada de dispersión a través del modelo de regresión y que el ajuste es casi perfecto, por lo que la mayoría de los datos reales está sobre el plano que forma la ecuación de regresión,⁸³ si el valor fuera grande esto indicaría que los valores están muy dispersos o alejados del plano de la ecuación de regresión, es decir el ajuste es casi nulo; si el ajuste es nulo el modelo de regresión es malo, por lo que sería indicativo de que la regresión no debería haberse realizado con estas variables. Lo que interesa es que esta medida sea lo más pequeña posible o lo más cercana a cero. Recuerde que como la variable dependiente fue transformada, dicho valor se tiene que destransformar.

⁸³ Si el valor de la varianza es de cero implica que todos los puntos o datos reales caen sobre la línea o plano que forma la ecuación de regresión por lo que el ajuste es excelente.

2.6 Supuestos en los errores

Errores. Son la diferencia entre el dato real y el dato pronosticado.

Antes de hablar de los supuestos de los errores es necesario encontrarlos; como ya se había dicho, los **errores** son la diferencia entre el dato real y el dato pronosticado.

Ecuación 2-29 Error

$$\begin{aligned}\text{Error} &= \varepsilon_i = DR_i - DP_i = Y_i - \hat{Y}_i \\ \text{residual} &= r_i = DR_i - DP_i = y_i - \hat{y}_i\end{aligned}$$

Donde:

ε_i : Error de la observación i en la población.

r_i : Residual de la observación i en la muestra.

$DR_i = Y_i$: Dato real en la observación i en la población sería con mayúsculas y las minúsculas son en la muestra.

$DP_i = \hat{Y}_i$: Dato pronosticado en la observación i en la población sería con mayúsculas y las minúsculas son en la muestra.

Con los datos del ejemplo se encontrarán los errores; para la primera observación se tiene que:

Tabla 2-63 Datos de la primera observación

Y	X_1	X_2	X_3
Ln_renta	Cuartos	Norte	Sur
9.048	2	0	1

Ahora es necesario obtener el pronóstico por medio de la ecuación, la cual quedó de la siguiente manera:

$$\hat{Y} = 8.107 + 0.323X_1 + 0.183X_2 + 0.177X_3$$

Para la observación uno, sería:

$$\hat{Y}_1 = 8.107 + 0.323X_{1,1} + 0.183X_{2,1} + 0.177X_{3,1}$$

Al sustituir los datos de la observación uno en cada una de las variables de la ecuación, se tiene:

$$\hat{Y}_1 = 8.107 + 0.323(2) + 0.183(0) + 0.177(1) = 8.930$$

El error en la observación uno, sería:

$$r_1 = y_1 - \hat{y}_1 = 9.048 - 8.930 = 0.117$$

El error estimado para la observación uno es:

$$r_1 = 0.117 = \hat{\varepsilon}_1$$

Los errores para el resto de las observaciones se presentan en la siguiente tabla:

Tabla 2-64 Errores

Y	X_1	X_2	X_3	$\hat{Y}$	$(Y - \hat{Y})^2$
Ln_renta	Cuartos	Norte	Sur	Estimación	Error
9.048	2	0	1	8.930	0.117
9.094	2	1	0	8.937	0.157

(continúa)

Tabla 2-64 Errores (continuación)

Y	X_1	X_2	X_3	$\hat{Y}$	$(Y - \hat{Y})^2$
Ln_renta	Cuartos	Norte	Sur	Estimación	Error
9.547	4	1	0	9.584	-0.037
8.517	1	0	0	8.430	0.087
9.306	4	0	0	9.400	-0.095
8.987	2	0	0	8.754	0.234
9.048	2	0	1	8.930	0.117
9.393	4	0	0	9.400	-0.008
8.269	1	0	0	8.430	-0.162
9.393	4	0	0	9.400	-0.008
8.923	3	0	0	9.077	-0.154
9.071	3	0	0	9.077	-0.006
8.987	3	0	0	9.077	-0.090
8.243	1	0	0	8.430	-0.188
8.854	2	1	0	8.937	-0.083
9.105	3	0	1	9.254	-0.149
8.412	1	0	0	8.430	-0.019
8.476	1	0	1	8.607	-0.131
8.975	2	0	1	8.930	0.040
8.517	1	0	0	8.430	0.087
9.510	4	0	0	9.400	0.110
9.510	4	0	0	9.400	0.110
8.854	2	0	0	8.754	0.100
9.547	4	1	0	9.584	-0.037


Los supuestos de los errores son:

$$\varepsilon \sim N_{iid}[(\mu = 0), \hat{\sigma}_\varepsilon^2 \text{ constantes}]$$

Lo cual indica que los errores siguen una distribución normal (N), idénticamente distribuidos (id), independientes (id), con media o valor esperado igual a cero ($\mu = 0$) y varianzas constantes, pero desconocidas ($\hat{\sigma}_\varepsilon^2$); otra notación podría ser de la siguiente forma:

$$\varepsilon \sim N_{iid}[0, \hat{\sigma}_\varepsilon^2]$$

Estos supuestos se pueden ver en la siguiente gráfica:



Gráfica 2-17 Propiedades estadísticas de los errores o residuales.

En la gráfica anterior se muestra que los errores deben seguir una distribución normal, que su dispersión o variabilidad debe ser constante en cada una de las distribuciones, además como existen errores negativos y positivos su promedio debe ser cero y por último que no se puedan pronosticar, por lo que deben ser independientes. Si dichos supuestos no se cumplen implica que no se pueden llevar a cabo las pruebas que hasta este punto se han realizado, por eso es importante revisar si se cumplen.

2.7 Normalidad

El primer supuesto que se verificará será normalidad; hay diferentes maneras para probar que este supuesto se está cumpliendo, entre ellas están:




Figura 2-18 Diferentes pruebas para la normalidad.

En este capítulo se verán todas pero siempre recordando que con una sola es más que suficiente, sobre todo aquellas que tienen bastante soporte estadístico; también es importante remarcar que en todo análisis estadístico posterior a este tema (otros capítulos) deberán probarse los supuestos antes de poder analizar, concluir y tomar decisiones.

2.7.1 Histograma

Para un histograma es necesario formar una distribución de frecuencia con los errores y realizar la gráfica, como se muestra a continuación.

Como son 24 datos, el número de clases sería $C = \sqrt{24} = 4.90 \approx 5$.

La amplitud (a) de cada clase se calcula con el rango, el cual es el dato mayor (DM) menos el dato menor (dm), entre el número de clases de los 24 errores; el mayor de ellos es $DM = 0.234$ y el menor es $dm = -0.188$, redondeando esos valores a 0.3 y -0.2 , respectivamente, entonces la amplitud sería:


$$a = \frac{DM - dm}{C} = \frac{0.3 - (-0.2)}{5} = 0.1$$

Al empezar con el -0.2 la distribución de frecuencia, se suma la amplitud para formar cada límite inferior (LI) de las clases, luego se igualan los límites superiores (LS) y se contabiliza la cantidad de errores que entrarían en de cada clase; dicha distribución quedaría de la siguiente manera:

Tabla 2-65 Distribución de frecuencia de los errores


Clases			Frecuencia
LI		LS	
-0.20	--<	-0.10	6
-0.10	--<	0.00	3
0.00	--<	0.10	9
0.10	--<	0.20	5
0.20	--<	0.30	1

La tabla anterior se grafica en un histograma, el cual quedó de la siguiente manera:




Gráfica 2-18 Histograma de los errores.

En él se deberá buscar algo similar a una normal, al mismo histograma se le dibujó con línea punteada la curva normal, por lo que queda de la siguiente forma:



Gráfica 2-19 Histograma con curva normal.

El histograma que el SPSS™ da es el siguiente.



Gráfica 2-20 Histograma del SPSS™.

Como se ve los dos histogramas son muy diferentes y ninguno de ellos parece seguir una distribución normal.

2.7.2 Regla empírica

Es necesario calcular los porcentajes para saber si se cumple la normalidad, el problema con este procedimiento es que ningún paquete arroja los resultados, pero sí parte de dicho procedimiento.

La extensión del teorema de Chebyshev para una distribución que es simétrica y en forma de campana, indica lo siguiente:

68.27% de los valores caería dentro de 1 desviación estándar con respecto a la media, esto es:

$$\bar{e} \pm 1\sigma$$

95.45% de los valores caería dentro de 2 desviación estándar con respecto a la media, esto es:

$$\bar{e} \pm 2\sigma$$

99.73% de los valores caería dentro de 3 desviación estándar con respecto a la media, esto es:

$$\bar{e} \pm 3\sigma$$

Para lo anterior se requiere que los errores sean estandarizados, por lo que en la base del SPSS, al realizar la regresión, se pidió que arroje los errores y los mismos pero estandarizados; los resultados aparecen en la base de datos:

	PRE_1	RES_1	ZRE_1
1	8.94268	0.10514	0.84052
2	8.98942	0.10438	-0.19815
3	9.57142	-0.02461	0.43308
4	8.46341	0.05379	-1.13413
5	9.44650	-0.14085	1.38920
6	8.81467	0.17253	0.84661
7	8.94268	0.10514	0.32333
8	9.35251	0.04016	-1.61100
9	8.46880	-0.20007	0.11910
10	9.37787	0.01479	-0.84644
11	9.02778	-0.10512	0.35808
12	9.02661	0.04447	-1.23498
13	9.14057	-0.15337	-1.07274
14	8.37598	-0.13322	-0.79040
15	8.95183	-0.09816	-1.01459
16	9.23098	-0.12600	0.60084
17	8.33721	0.07462	-0.93579
18	8.59259	-0.11622	0.25716
19	8.94268	0.03194	0.42366
20	8.46458	0.05261	

Figura 2-19 Base con las nuevas variables.

La fórmula para llevar a cabo la estandarización de los residuales es:

Ecuación 2-30 Normal estándar

$$Z_{\varepsilon_i} = \frac{\varepsilon_i - \bar{\varepsilon}}{S_{\varepsilon}}$$

Donde:

Z_{ε_i} : es el puntaje estándar del error i .

ε_i : es el error i .

$\bar{\varepsilon}$: es el promedio de los errores.

S_{ε} : es el error estándar del estimado.

En puntos anteriores se ha calculado el error estándar del estimado, el cual tiene el siguiente valor:

$$S_{\varepsilon} = \sqrt{\frac{SSE}{n-p}} = \sqrt{\frac{0.310}{24-4}} = \sqrt{0.015} = 0.1244$$

Como siguiente paso se deberá encontrar la media de los errores, el SPSS™ pone ese valor en la tabla de estadísticos sobre los residuales.

Tabla 2-66 Descriptivos de los residuales

Estadísticos sobre los residuos ^a					
	Mínimo	Máximo	Media	Desviación típ.	N
Valor pronosticado	8.4304	9.5836	8.9827	.38886	24
Valor pronosticado típ.	-1.420	1.545	.000	1.000	24
Error típico del valor pronosticado	.034	.066	.050	.011	24
Valor pronosticado corregido	8.4155	9.5981	8.9836	.38993	24
Residuo bruto	-.18760	.23354	.00000	.11600	24
Residuo típ	-1.508	1.877	.000	.933	24

(continúa)

Tabla 2-66 Descriptivos de los residuales (continuación)

Estadísticos sobre los residuos ^a					
	Mínimo	Máximo	Media	Desviación típ.	N
Residuo estud.	-1.632	1.953	-.003	1.018	24
Residuo eliminado	-.21960	.25281	-.00096	.13872	24
Residuo eliminado estud.	-1.708	2.116	-.002	1.045	24
Dist. de Mahalanobis	.743	5.565	2.875	1.627	24
Distancia de Cook	.000	.220	.050	.054	24
Valor de influencia centrado	.032	.242	.125	.071	24

^a Variable dependiente: Ln_renta.

Como ejemplo se encontrará el puntaje estandarizado del primer error. La información del primer residual o error estimado se muestra a continuación.

$$\hat{\varepsilon}_1 = r_1 = y_1 - \hat{y}_1 = 9.048 - 8.930 = 0.117$$

Al sustituir el valor en la siguiente ecuación da el valor del error estandarizado o tipificado.

$$Z_{\varepsilon_1} = \frac{\hat{\varepsilon}_1 - \bar{\varepsilon}}{S_{\varepsilon}} = \frac{0.117 - 0}{0.1244} = 0.954$$

El procedimiento continúa para cada residual o error estimado, los resultados de todos los errores estandarizados o tipificados se presentan en la siguiente tabla.

Tabla 2-67 Errores estandarizados

Y	$\hat{Y}$	Error	Error
Ln_renta	Estimación	ε	Estandarizado
9.048	8.930	0.117	0.945
9.094	8.937	0.157	1.261
9.547	9.584	-0.037	-0.296
8.517	8.430	0.087	0.698
9.306	9.400	-0.095	-0.761
8.987	8.754	0.234	1.877
9.048	8.930	0.117	0.945
9.393	9.400	-0.008	-0.061
8.269	8.430	-0.162	-1.299
9.393	9.400	-0.008	-0.061
8.923	9.077	-0.154	-1.240
9.071	9.077	-0.006	-0.047
8.987	9.077	-0.090	-0.722
8.243	8.430	-0.188	-1.508
8.854	8.937	-0.083	-0.670
9.105	9.254	-0.149	-1.195
8.412	8.430	-0.019	-0.149
8.476	8.607	-0.131	-1.050

(continúa)

Tabla 2-67 Errores estandarizados (*continuación*)

γ	$\hat{\gamma}$	Error	Error
Ln_renta	Estimación	ϵ	Estandarizado
8.975	8.930	0.044	0.356
8.517	8.430	0.087	0.698
9.510	9.400	0.110	0.886
9.510	9.400	0.110	0.886
8.854	8.754	0.100	0.804
9.547	9.584	-0.037	-1.296

Como siguiente paso se ordenan de menor a mayor.

Tabla 2-68 Errores estandarizados ordenados

ϵ Error	ϵ Estandarizado
Ordenados	Ordenados
-0.188	-1.508
-0.162	-1.299
-0.154	-1.240
-0.149	-1.195
-0.131	-1.050
-0.095	-0.761
-0.090	-0.722
-0.083	-0.670
-0.037	-0.296
-0.037	-0.296
-0.019	-0.149
-0.008	-0.061
-0.008	-0.061
-0.006	-0.047
0.044	0.356
0.087	0.698
0.087	0.698
0.100	0.804
0.110	0.886
0.110	0.886
0.117	0.945
0.117	0.945
0.157	1.261
0.234	1.877

Ahora se procede a contabilizar los errores que caen dentro de ± 1 , los cuales fueron puestos en la siguiente tabla en la tercera columna; posteriormente los que se encuentran entre ± 2 , los cuales están en la cuarta columna y por último los de ± 3 se localizan en la última columna. A continuación dichos errores estandarizados se contabilizan, esto con el fin de saber si el porcentaje de la regla empírica se está cumpliendo.

Tabla 2-69 Contabilizar los errores estandarizados

ε Error	ε Estandarizado	ε Estandarizado	ε Estandarizado	ε Estandarizado
Ordenados	Ordenados	± 1	± 2	± 3
-0.188	-1.508	-1.508	-1.508	-1.508
-0.162	-1.299	-1.299	-1.299	-1.299
-0.154	-1.240	-1.240	-1.240	-1.240
-0.149	-1.195	-1.195	-1.195	-1.195
-0.131	-1.050	-1.050	-1.050	-1.050
-0.095	-0.761	-0.761	-0.761	-0.761
-0.090	-0.722	-0.722	-0.722	-0.722
-0.083	-0.670	-0.670	-0.670	-0.670
-0.037	-0.296	-0.296	-0.296	-0.296
-0.037	-0.296	-0.296	-0.296	-0.296
-0.019	-0.149	-0.149	-0.149	-0.149
-0.008	-0.061	-0.061	-0.061	-0.061
-0.008	-0.061	-0.061	-0.061	-0.061
-0.006	-0.047	-0.047	-0.047	-0.047
0.044	0.356	0.356	0.356	0.356
0.087	0.698	0.698	0.698	0.698
0.087	0.698	0.698	0.698	0.698
0.100	0.804	0.804	0.804	0.804
0.110	0.886	0.886	0.886	0.886
0.110	0.886	0.886	0.886	0.886
0.017	0.945	0.945	0.945	0.945
0.017	0.945	0.945	0.945	0.945
0.157	1.261	1.261	1.261	1.261
0.234	1.877	1.877	1.877	1.877

De 24 errores 17 se encuentran entre ± 1 , por lo que el porcentaje teóricamente sería 68.27%. Sigue encontrar con una regla de tres simple el porcentaje real:

$$\begin{array}{rcl} 24 & - & 100 \\ 17 & - & x \end{array} \quad \text{por lo que } x = 70.83\%$$

Se compara 68.27% con 70.83%, el cual es bastante cercano. Otra forma sería sacar cuántos errores estandarizados se deben tener en 68.27%, esto se obtiene de la siguiente manera:

$$\begin{array}{l} 24 - 100 \\ x - 68.27 \end{array} \quad \text{por lo que } x = 16.835 \approx 17$$

Ambos procedimientos son válidos. Lo siguiente sería encontrar cuántos errores hay en 95.45%, es decir a ± 2 , teóricamente el número de errores debería ser:

$$\begin{array}{l} 24 - 100 \\ x - 95.45 \end{array} \quad \text{por lo que } x = 22.908 \approx 23$$

Y se contabilizan los que realmente hay en la tabla anterior, los cuales son 24 errores; parece que los teóricos y los reales están cercanos. Por último se encuentran los del rango de ± 3 , con 99.73% se tendría:

$$\begin{array}{l} 24 - 100 \\ x - 99.73 \end{array} \quad \text{por lo que } x = 23.935 \approx 24$$

Se procede entonces a contabilizar a ± 3 , los cuales son.

Como los tres porcentajes reales y teóricos son parecidos se podría concluir que los errores siguen una distribución normal.

2.7.3 Prueba de bondad de ajuste por la ji cuadrada

La prueba de bondad de ajuste por la ji cuadrada es una prueba de hipótesis para corroborar que los errores siguen una distribución normal, los pasos a seguir son:

Establecer las hipótesis. Como se desea probar que los errores siguen una distribución normal, los enunciados serían:

$$\begin{array}{l} H_0 : \varepsilon \sim N, \text{ los errores siguen una distribución normal} \\ H_0 : \varepsilon \not\sim N, \text{ los errores no siguen una distribución normal} \end{array}$$

Se construye una distribución de frecuencia con los errores, el procedimiento para realizar esto ya se vio en el histograma, pero se repite aquí:

$$\text{Como son 24 datos, el número de clases sería } C = \sqrt{24} = 4.90 \approx 5$$

La amplitud (a) de cada clase se calcula con el rango, el cual es el dato mayor (DM) menos el dato menor (dm), entre el número de clases, de los 24 errores, el mayor de ellos es $DM = 0.234$ y el menor es $dm = 0.188$, al redondear esos valores quedan 0.3 y -0.2 , respectivamente, entonces la amplitud sería:

$$a = \frac{DM - dm}{C} = \frac{0.3 - (-0.2)}{5} = 0.1$$

Al empezar con el -0.2 la distribución de frecuencia se suma la amplitud para formar cada límite inferior (LI) de las clases, luego se igualan los límites superiores (LS); la distribución de frecuencia quedaría de la siguiente forma:

Tabla 2-70 Distribución de frecuencia al mostrar las clases

Clases		
<i>LI</i>		<i>LS</i>
-0.20	--<	-0.10
-0.10	--<	0.00
0.00	--<	0.10
0.10	--<	0.20
0.20	--<	0.30

Ahora, se contabiliza la cantidad de errores de cada clase; dicha distribución quedaría de la siguiente manera:

Tabla 2-71 Distribución de frecuencia de los errores

Clases			
<i>LI</i>		<i>LS</i>	Frecuencia = <i>fo</i>
-0.20	--<	-0.10	5
-0.10	--<	0.00	9
0.00	--<	0.10	3
0.10	--<	0.20	6
0.20	--<	0.30	1

Ahora es necesario obtener la media y desviación estándar de dicha distribución, para lo cual es necesario conocer la marca de clase (*MC*) o el punto medio (*PM*) de ellas, éste se obtiene de la siguiente manera:

$$MC_1 = PM_1 = \frac{LI_1 + LS_1}{2} = \frac{-0.2 + (-0.1)}{2} = -0.15$$

Donde:

LI_i : es el límite inferior de la clase *i*.

LS_i : es el límite superior de la clase *i*.

$MC_i = PM_i$: es la marca de clase o punto medio de la clase *i*.

El proceso es el mismo para cada una de las clases, posteriormente se multiplica el punto medio de cada clase por su frecuencia y se suma, la respuesta de lo obtenido se pone a continuación:

Tabla 2-72 Marca de clase por la frecuencia

Clases					
<i>LI</i>		<i>LS</i>	Frecuencia = <i>fo</i>	<i>MC = PM</i>	<i>PM * f</i>
-0.20	--<	-0.10	5	-0.15	-0.75
-0.10	--<	0.00	9	-0.05	-0.45
0.00	--<	0.10	3	0.05	0.15
0.10	--<	0.20	6	0.15	0.90
0.20	--<	0.30	1	0.25	0.25
Suma =			24		0.100

Para obtener la media de la distribución de frecuencia se divide la suma que se acaba de obtener entre el número de datos:

$$\bar{\varepsilon} = \bar{r} = \frac{\sum_{i=1}^C PM_i * f_i}{n} = \frac{0.1}{24} = 0.004$$

Donde:

$\bar{r}$: es el promedio de los residuales.

$\bar{\varepsilon}$: es el promedio de los errores estimados.

PM_i : es la marca de clase o punto medio de la clase *i*.

f_i : es la frecuencia de la clase i .

n : es el total de datos de la muestra.

Posterior a esto se obtiene la desviación estándar con los siguientes pasos: se busca el punto medio al cuadrado y se multiplica por la frecuencia; la información de esto se presenta en la siguiente tabla.

Tabla 2-73 Marca de clase al cuadrado por la frecuencia

Clases							
<i>LI</i>		<i>LS</i>	Frecuencia = <i>f_o</i>	<i>MC = PM</i>	<i>PM * f</i>	<i>PM²</i>	<i>PM² * f</i>
-0.20	--<	-0.10	5	-0.15	-0.75	0.023	0.113
-0.10	--<	0.00	9	-0.05	-0.45	0.003	0.023
0.00	--<	0.10	3	0.05	0.15	0.003	0.008
0.10	--<	0.20	6	0.15	0.90	0.023	0.135
0.20	--<	0.30	1	0.25	0.25	0.063	0.063
Suma =			24		0.100		0.340

La obtención de la desviación estándar de la distribución de frecuencia sería la raíz cuadrada de la suma que se acaba de obtener menos n veces el promedio al cuadrado, entre el número de datos:

$$\bar{\sigma} = S = \sqrt{\frac{\sum_{i=1}^C PM_i * f_i - n\bar{\epsilon}^2}{n-1}} = \sqrt{\frac{0.340 - 24 * (0.004)^2}{24-1}} = 0.122$$

Donde:

S : es la desviación estándar de los residuales.

$\hat{\sigma}$: es la desviación estándar estimada de los errores.

PM_i : es la marca de clase o punto medio de la clase i .

f_i : es la frecuencia de la clase i .

$\bar{\epsilon}$: es el promedio de los errores estimados.

n : es el total de datos de la muestra.

Ahora se obtiene la Z para cada valor del límite superior (LS), por ejemplo para el primer límite sería:

$$Z = \frac{LS - \bar{\epsilon}}{\sigma} = \frac{-0.10 - 0.004}{0.122} = -0.8573$$


Los demás valores se obtienen de la misma manera, los resultados se muestran en la siguiente tabla.

Tabla 2-74 Las Z de cada límite superior

Clases				
<i>LI</i>		<i>LS</i>	Frecuencia = <i>f_o</i>	<i>Z</i>
-0.20	--<	-0.10	5	-0.8573
-0.10	--<	0.00	9	-0.0343
0.00	--<	0.10	3	0.7887
0.10	--<	0.20	6	1.6117
0.20	--<	0.30	1	2.4347
Suma =			24	

La Z se tiene que convertir en probabilidad y ésta debe ser encontrada en la tabla de la normal estándar; la primera clase con una $Z = -0.8573$, la cual redondeada a dos decimales sería $Z = -0.86$, dicho valor se busca en la tabla de la siguiente manera:


Tabla 2-75 Normal estándar



z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611
-0.8	0.2119	0.2090	0.2061	0.2033	0.2005	0.1977	0.1949	0.1922	0.1894	0.1867
-0.7	0.2420	0.2389	0.2358	0.2327	0.2296	0.2266	0.2236	0.2206	0.2177	0.2148
-0.6	0.2743	0.2709	0.2676	0.2643	0.2611	0.2578	0.2546	0.2514	0.2483	0.2451
-0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
-0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3228	0.3192	0.3156	0.3121
-0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
-0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
-0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
0.0	0.5000	0.4960	0.4920	0.4880	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641

La probabilidad encontrada es de 0.1949, la segunda clase tiene una $Z = -0.0343$, la cual redondeada a dos decimales sería, $Z = -0.03$, el valor se busca en la tabla de la siguiente forma:

Tabla 2-76 Normal estándar




z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
-0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3228	0.3192	0.3156	0.3121
-0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
-0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
-0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
0.0	0.5000	0.4960	0.4920	0.4880	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641

El valor encontrado contiene la probabilidad acumulada de la clase anterior y de ésta, por lo que se tiene que restar al anterior valor de la primera clase y éste, es decir: $0.4880 - 0.1949$, lo que da 0.2931.

Ahora se continúa con la tercera clase, la cual tiene una $Z = 0.7887$, que al redondearla a dos decimales sería $Z = 0.79$, dicho valor, se busca en la tabla de la siguiente manera:

Tabla 2-77 Normal estándar




Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133

Como el valor contiene la probabilidad acumulada de las clases anteriores, se le restan; es decir, el valor de la primera clase y el de la segunda: $0.7852 - 0.2931 - 0.1949$ lo que da 0.2972.

Seguiría la cuarta clase, con una $Z = 1.6117$, la cual al redondearla a dos decimales sería $Z = 1.61$, el valor se busca en la tabla de la siguiente manera:

Tabla 2-78 Normal estándar



Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767

Otra vez se le resta lo acumulado en las clases anteriores:

$$0.9463 - 0.2972 - 0.2931 - 0.1949, \text{ lo que da } 0.1611.$$

Por último, la quinta clase se encuentra con las diferencias al saber que la suma de todas las probabilidades dan 1, entonces se tiene que:

$$1 - 0.1611 - 0.2972 - 0.2931 - 0.1949 = 0.0537$$

Las probabilidades de cada una de las clases están en la siguiente tabla:

Tabla 2-79 Probabilidades

Clases						
LI		LS	Frecuencia = f_o	Z	Probabilidad	Probabilidad
-0.20	--<	-0.10	5	-0.8573	0.1949	0.1956
-0.10	--<	0.00	9	-0.0343	0.2931	0.2907
0.00	--<	0.10	3	0.7887	0.2972	0.2985
0.10	--<	0.20	6	1.6117	0.1611	0.1616
0.20	--<	0.30	1	2.4347	0.0537	0.0535
Suma =			24		1.000	1.000

En la tabla anterior se muestran las probabilidades encontradas por medio de las tablas; en la última columna aparecen las encontradas por medio del Excel.⁸⁴ Ahora cada una de las probabilidades se multiplica por el total de la frecuencia observada.

$$0.1956 * 24 = 5$$

Los valores restantes se obtienen de la misma manera y están en la siguiente tabla:

Tabla 2-80 Frecuencia esperada

Clases					
LI		LS	Frecuencia = f_o	Probabilidad	f_e
-0.20	--<	-0.10	5	0.1956	5
-0.10	--<	0.00	9	0.2907	7
0.00	--<	0.10	3	0.2985	7.2
0.10	--<	0.20	6	0.1616	3.9
0.20	--<	0.30	1	0.0535	1.3
Suma =			24	1.000	24

Tras encontrar la frecuencia esperada se realiza la prueba de hipótesis, pero antes de eso se deberá comprobar si los supuestos se cumplen. Los supuestos para realizar la prueba de hipótesis son:

1. El método de muestreo debe haberse realizado por medio del muestreo aleatorio.
2. La población debe ser al menos 10 veces más grande que la muestra.
3. La variable en estudio debe corresponder con una variable categórica, es decir, no métrica.
4. El valor de las frecuencias esperadas de cada nivel de la variable debe ser al menos 5, es decir 5 o más.
5. Si existen frecuencias esperadas menores a 5, entonces menos de 20% de dichas frecuencias pueden ser menores a 5.

Los puntos 1 y 2 se cumplen, ya que se llevó a cabo un muestreo aleatorio y la población es de al menos 10 000 estudiantes foráneos. En el caso del punto 3, la variable de los residuales es métrica, pero

⁸⁴ De aquí en adelante sólo se usarán las encontradas por Excel, esto debido al redondeo que se realizó.

como se agrupó en clases se convirtió en no métrica. En el punto 4 se observan 2 frecuencias esperadas menores a 5 y en el punto 5 se procede a ver si el total de las frecuencias esperadas menores a 5 cumplen con 20%. Como dos clases de las 5 cuentan con frecuencias esperadas menores a 5, esto indica que 40% de las frecuencias esperadas son menores, por lo que 20% no se cumple; al no cumplirse dicho supuesto es necesario juntarlas con clases adyacentes, como la penúltima y última de las clases son menores a 5 se agrupan, esto se logra al sumar las frecuencias, lo cual se muestra en la siguiente tabla.

Tabla 2-81 Nuevas frecuencias

Clases					Clases				
LI		LS	Frecuencia = fo	fe	LI		LS	fo	fe
-0.20	--<	-0.10	5	5	-0.20	--<	-0.10	5	5
-0.10	--<	0.00	9	7	-0.10	--<	0.00	9	7
0.00	--<	0.10	3	7.2	0.00	--<	0.10	3	7.2
0.10	--<	0.20	6	3.9	0.10 o más			6	3.9
0.20	--<	0.30	1	1.3	Suma =			24	24
Suma =			24	24					

Ahora se obtendrá el estadístico calculado, el cual corresponde a una ji cuadrada de Pearson, que debe ser utilizada cuando las frecuencias esperadas sean mayores o iguales a 5.

Ecuación 2-31 Ji cuadrada de Pearson

$$\chi^2_C = \sum_{i=1}^K \frac{(fo_i - fe_i)^2}{fe_i}$$

Donde:

fo_i : es la frecuencia observada de la clase i .

fe_i : es la frecuencia esperada de la clase i .

K : es el número total de clases en la distribución de frecuencia.

Para obtener la frecuencia esperada de cada una de las categorías de la distribución de frecuencia se multiplica la probabilidad de cada categoría por el total de datos muestreados (recuerde que las frecuencias esperadas en cada categoría no deben ser menores a 5).

$$\chi^2_C = \frac{(5-5)^2}{5} + \frac{(9-7)^2}{7} + \frac{(3-7.2)^2}{7.2} + \frac{(7-5.2)^2}{5.2}$$

El resultado es:

$$\chi^2_C = 3.681$$

Dicho procedimiento se resume en la siguiente tabla.

Tabla 2-82 Valor de la ji cuadrada de Pearson

Clases							
LI		LS	fo	fe	fo-fe	(fo-fe) ²	(fo-fe) ² /fe
-0.20	--<	-0.10	5	5	0	0	0.0
-0.10	--<	0.00	9	7	2	4	0.587
0.00	--<	0.10	3	7.2	-4.2	17.35	2.421
0.10 o más			7	5.2	1.8	3.37	0.653
Suma =			24	24			3.681


El valor encontrado se compara con el estadístico teórico y como en el ejemplo se está utilizando 5% como nivel de significancia, entonces:

$$\chi^2_{t,\alpha=0.05,(\# \text{ de clases}-1)-1-1=(4-1)-1-1=1} = 3.841$$

Los valores de los grados de libertad son el número de clases finales,⁸⁵ que es 4 menos 1, el segundo -1 es debido a que no se conocía el promedio de la distribución de frecuencia y se tuvo que estimar al igual que la desviación estándar, que sería el tercer -1 . El problema con este tipo de prueba son los grados de libertad que se pierden al no disponer de la información necesaria y tenerla que estimar a partir de la muestra, cuando se tienen menos clases generalmente los grados de libertad den cero y es imposible encontrar el estadístico teórico o el p-valor.

El estadístico teórico fue encontrado de la siguiente manera:

Tabla 2-83 Estadístico teórico ji cuadrada⁸⁶



df	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	12.899	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264


Para rechazar la H_0 es necesario que:

$$\chi^2_c > \chi^2_t$$

Por lo que:

$$3.681 < 3.841 \text{ no se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



⁸⁵ Al principio se tenían cinco clases, posteriormente se agruparon las últimas dos con el fin de que las frecuencias fueran mayores o iguales que 5.

⁸⁶ Ver anexo 3.1 "Tabla ji cuadrada".

Como no se rechazó H_0 se puede concluir que los errores siguen una distribución normal, por lo que el supuesto de normalidad se cumple.

2.7.4 Prueba de Shapiro-Wilk

Esta prueba de hipótesis data de los años 60 y fue creada por Samuel Shapiro y por Martin Bradbury Wilk; es utilizada para muestras pequeñas, es decir, de entre 3 y 50 datos u observaciones.

El proceso para la obtención del estadístico de prueba requiere un coeficiente, el cual varía según el número de datos y son valores fijos.⁸⁷

El estadístico teórico, que se compara con el estadístico de prueba, se encuentra por medio de tablas,⁸⁸ requiere dos.

La fórmula para su obtención es:

$$SW_C = \frac{[\sum_{i=1}^S (a_i [X_{n-i+1} - X_i])]^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Donde:

SW_C : es el estadístico de prueba de Shapiro-Wilk.

a : es el coeficiente Shapiro-Wilk.

n : es el número de datos.

X_i : es la variable a probar en la observación i .

$\bar{X}$: es el promedio de la variable.

S : es el número de diferencias que deberán realizarse y sale de $S = \frac{j}{2}$.

j : es el lugar que ocupa la variable X_j , la cual previamente debe estar ordenada de menor a mayor.

Las hipótesis para saber si los datos siguen una distribución normal son:

$H_0 : \varepsilon \sim N$, los errores siguen una distribución normal

$H_0 : \varepsilon \not\sim N$, los errores no siguen una distribución normal

El proceso ordenado para obtener el estadístico es el siguiente:

1. Contabilizar los valores que se probarán, con el fin de saber si el número de datos es par o impar.
2. Ordenar los valores de menor a mayor.
3. Asignarles un lugar por medio de j .
4. Se encuentra $S = \frac{j}{2}$ que sería el número de comparaciones que se realizarán posteriormente.
5. Saber si el número de datos es:
 - Par: se continúa con el proceso.
 - Impar: se elimina el valor central, es decir la mediana o el dato X_{s+1} . Si éste es el caso, j y S cambian.
6. Se procede a calcular las sumas de cuadrados de las desviaciones, es decir, entre el dato y su promedio $(X_i - \bar{X})$.
7. Se cotejan los datos, las comparaciones son el último con el primero, el penúltimo con el segundo y así sucesivamente hasta tener S comparaciones, esto se resume como sigue $(X_{n-i+1} - X_i)$.
8. Se encuentra el coeficiente según n y j .
9. Se multiplica el coeficiente por las comparaciones y se suman.
10. Encontrar el estadístico de prueba SW_C .

⁸⁷ Los coeficientes para realizar la prueba de Shapiro-Wilk se muestran en el anexo 2.7 "Tabla Shapiro-Wilk".

⁸⁸ Los valores del estadístico teórico de Shapiro-Wilk están en el anexo 2.8 "Tabla Kolmogorov-Smirnov-Lilliefors".

11. Comparar con el teórico o de tablas SW_t .
12. Concluir si $SW_C < SW_t$ rechaza la hipótesis nula, es decir, la variable que se está probando no sigue una distribución normal.

Ahora bien, como en este caso se desea saber si los residuales siguen una distribución normal o no, se realizan los pasos para el ejemplo:

Lo primero es saber el número de datos, en este caso se tienen 24 residuales o errores, el número de datos es par.

El segundo paso es ordenar los valores de menor a mayor. En tercer lugar se asigna por medio de la j un lugar a cada dato de la variable. Estos pasos se siguen en la siguiente tabla, donde también se muestra el promedio de los errores:

Tabla 2-84 Errores ordenados

y	$\hat{y}$	Error	Error	
Ln_renta	Estimación	ϵ	Ordenados	j
9.048	8.930	0.117	-0.188	1
9.094	8.937	0.157	-0.162	2
9.547	9.584	-0.037	-0.154	3
8.517	8.430	0.087	-0.149	4
9.306	9.400	-0.095	-0.131	5
8.987	8.754	0.234	-0.095	6
9.048	8.930	0.117	-0.090	7
9.393	9.400	-0.008	-0.083	8
8.269	8.430	-0.162	-0.037	9
9.393	9.400	-0.008	-0.037	10
8.923	9.077	-0.154	-0.019	11
9.071	9.077	-0.006	-0.008	12
8.987	9.077	-0.090	-0.008	13
8.243	8.430	-0.188	-0.006	14
8.854	8.937	-0.083	0.044	15
9.105	9.254	-0.149	0.087	16
8.412	8.430	-0.019	0.087	17
8.476	8.607	-0.131	0.100	18
8.975	8.930	0.044	0.110	19
8.517	8.430	0.087	0.110	20
9.510	9.400	0.110	0.017	21
9.510	9.400	0.110	0.017	22
8.854	8.754	0.100	0.157	23
9.547	9.584	-0.037	0.234	24
Promedio =			8.882E - 16	

Como $j = 24$ ahora se procede a encontrar S :

$$S = \frac{j}{2} = \frac{24}{2} = 12$$

Como el número de datos es par no se elimina ninguna observación, cuando es impar se elimina el valor de en medio, al cual se le denomina mediana;⁸⁹ ahora se calcula la suma de cuadrados,

$$\sum_{i=1}^{24} (X_i - \bar{X})^2 = (-0.188 - 8.882 \times 10^{-16})^2 + \dots + (0.234 - 8.882 \times 10^{-16})^2$$

Resultado:

$$\sum_{i=1}^{24} (X_i - \bar{X})^2 = 0.310$$

Lo anterior se resume en la siguiente tabla:

Tabla 2-85 Suma de cuadrados

Error	Error		
ε	Ordenados	j	$(\varepsilon + \varepsilon)^2$
0.117	-0.188	1	0.03519
0.157	-0.162	2	0.02612
-0.037	-0.154	3	0.02381
0.087	-0.149	4	0.02210
-0.095	-0.131	5	0.01707
0.234	-0.095	6	0.00895
0.117	-0.090	7	0.00806
-0.008	-0.083	8	0.00694
-0.162	-0.037	9	0.00135
-0.008	-0.037	10	0.00135
-0.154	-0.019	11	0.00034
-0.006	-0.008	12	0.00006
-0.090	-0.008	13	0.00006
-0.188	-0.006	14	0.00003
-0.083	0.044	15	0.00196
-0.149	0.087	16	0.00754
-0.019	0.087	17	0.00754
-0.131	0.100	18	0.01000
0.044	0.110	19	0.01214
0.087	0.110	20	0.01214
0.110	0.017	21	0.01381
0.110	0.017	22	0.01381
0.100	0.157	23	0.02460
-0.037	0.234	24	0.05454
Promedio =	8.882E - 16	Suma =	0.310

El paso siguiente es encontrar las diferencias de las comparaciones, se empieza con la primera observación, es decir cuando $i = 1$:

⁸⁹ Un ejemplo de número de observaciones impares sería: 2, 4, 7, 9 y 10, los cuales se encuentran ordenados, como son 5 observaciones la mediana sería el 7, que es el valor central, este último se elimina del proceso.

$$(X_{n-i+1} - X_i) = (X_{24-1+1} - X_2) = (X_{24} - X_1) = [0.234 - (-0.188)]$$

Lo anterior da como resultado 0.421, note que en realidad se están comparando la primera observación con la última, ahora se sigue con $i = 2$:

$$(X_{n-i+1} - X_i) = (X_{24-2+1} - X_2) = (X_{23} - X_2) = [0.157 - (-0.162)]$$

El resultado es 0.318, se comparó la segunda observación con la penúltima, el proceso sigue hasta que $i = 12 = S$:

$$(X_{n-i+1} - X_i) = (X_{24-12+1} - X_2) = (X_{13} - X_{12}) = [0.008 - (-0.008)]$$

Lo anterior fue resumido en la siguiente tabla, donde se muestra también la columna de los residuales para que se siga el proceso, en las columnas de comparaciones se muestra la observación que se compara y con cuál se hace la equiparación, mientras que en la columna de las diferencias están los resultados.

Tabla 2-86 Diferencia de las comparaciones

Error	Error			Comparaciones				Diferencias
ϵ	Ordenados	j	$(\epsilon + \epsilon)^2$	$n - i + 1$		i		$(X_{n-i+1} - X_i)$
0.117	-0.188	1	0.03519	24	0.234	1	-0.188	0.421
0.157	-0.162	2	0.02612	23	0.157	2	-0.162	0.318
-0.037	-0.154	3	0.02381	22	0.117	3	-0.154	0.272
0.087	-0.149	4	0.02210	21	0.117	4	-0.149	0.266
-0.095	-0.131	5	0.01707	20	0.110	5	-0.131	0.241
0.234	-0.095	6	0.00895	19	0.110	6	-0.095	0.205
0.117	-0.090	7	0.00806	18	0.100	7	-0.090	0.190
-0.008	-0.083	8	0.00694	17	0.087	8	-0.083	0.170
-0.162	-0.037	9	0.00135	16	0.087	9	-0.037	0.124
-0.008	-0.037	10	0.00135	15	0.044	10	-0.037	0.081
-0.154	-0.019	11	0.00034	14	-0.006	11	-0.019	0.013
-0.006	-0.008	12	0.00006	13	-0.008	12	-0.008	0.000
-0.090	-0.008	13	0.00006					
-0.188	-0.006	14	0.00003					
-0.083	0.044	15	0.00196					
-0.149	0.087	16	0.00754					
-0.019	0.087	17	0.00754					
-0.131	0.100	18	0.01000					
0.044	0.110	19	0.01214					
0.087	0.110	20	0.01214					
0.110	0.017	21	0.01381					
0.110	0.017	22	0.01381					
0.100	0.157	23	0.02460					
-0.037	0.234	24	0.05454					
Promedio =	8.882E - 16	Suma =	0.310					

El paso siguiente de este procedimiento es encontrar los coeficientes Shapiro-Wilk, que están en el anexo 2.6, para esto se necesita conocer la $n = 24$, se empieza desde $i = 1$ hasta S , que en este caso es $S = 12$. La forma en que fueron encontrados los coeficientes se muestra a continuación:

Tabla 2-87 Coeficientes a de Shapiro-Wilk⁹⁰

Coeficiente a del estadístico de Shapiro-Wilk										
n										
1 a S	21	22	23	24	25	26	27	28	29	30
1	0.4643	0.4590	0.4542	0.4493	0.4450	0.4407	0.4366	0.4328	0.4291	0.4554
2	0.3185	0.3156	0.3126	0.3098	0.3069	0.3043	0.3018	0.2992	0.2968	0.2944
3	0.2578	0.2571	0.2563	0.2554	0.2543	0.2533	0.2522	0.2510	0.2499	0.2487
4	0.2119	0.2131	0.2139	0.2145	0.2148	0.2151	0.2152	0.2151	0.2150	0.2148
5	0.1736	0.1764	0.1787	0.1807	0.1822	0.1836	0.1848	0.1857	0.1864	0.1870
6	0.1399	0.1443	0.1480	0.1512	0.1539	0.1563	0.1584	0.1601	0.1616	0.1630
7	0.1092	0.1150	0.1201	0.1245	0.1283	0.1316	0.1346	0.1372	0.1395	0.1415
8	0.0804	0.0878	0.0941	0.0997	0.1046	0.1089	0.1128	0.1162	0.1192	0.1219
9	0.0530	0.0618	0.0696	0.0764	0.0823	0.0876	0.0923	0.0965	0.1002	0.1036
10	0.0263	0.0368	0.0459	0.0539	0.0610	0.0672	0.0728	0.0778	0.0822	0.0862
11	0.0000	0.0122	0.0228	0.0321	0.0403	0.0476	0.0540	0.598	0.0650	0.0697
12			0.0000	0.0107	0.0200	0.0284	0.0358	0.0424	0.0483	0.0537
13					0.0000	0.0094	0.0178	0.0253	0.0320	0.0381
14							0.0000	0.0084	0.0159	0.0227
15									0.0000	0.0076

$$i = 1:$$

$$a_i(X_{n-i+1} - X_i) = a_1(X_{24-1+1} - X_1) = 0.4493(0.421) = 0.1892$$

Eso indica que las diferencias deben ser multiplicadas de la siguiente manera, por ejemplo cuando $i = 2$:

$$a_i(X_{n-i+1} - X_i) = a_2(X_{24-2+1} - X_2) = 0.3098(0.318) = 0.0987$$

El proceso continúa hasta $i = 12$:

$$a_i(X_{n-i+1} - X_i) = a_{12}(X_{24-12+1} - X_{12}) = 0.0107(0.000) = 0.000$$

El resultado de lo anterior se muestra en la siguiente tabla:

Tabla 2-88 Operaciones con el coeficiente a

Comparaciones				Diferencias		coeficiente	S
$n - i + 1$		i		$(X_{n-i+1} - X_i)$	1 a S	a	$a * (X_{n-i+1} - X_i)$
24	0.234	1	-0.188	0.421	0.117	0.4493	0.1892
23	0.157	2	-0.162	0.318	0.157	0.3098	0.0987
22	0.117	3	-0.154	0.272	-0.037	0.2554	0.0694
21	0.117	4	-0.149	0.266	0.087	0.2145	0.0571
20	0.110	5	-0.131	0.241	-0.095	0.1807	0.0435

(continúa)

⁹⁰ Los coeficientes para realizar la prueba de Shapiro-Wilk se encuentran en el anexo 2.8.

Tabla 2-88 Operaciones con el coeficiente a (continuación)

Comparaciones				Diferencias		coeficiente	S
$n - i + 1$		i		$(X_{n-i+1} - X_i)$	1 a S	a	$a^*(X_{n-i+1} - X_i)$
19	0.110	6	-0.095	0.205	0.234	0.1512	0.0310
18	0.100	7	-0.090	0.190	0.117	0.1245	0.0236
17	0.087	8	-0.083	0.170	-0.008	0.0997	0.0170
16	0.087	9	-0.037	0.124	-0.162	0.0764	0.0094
15	0.044	10	-0.037	0.081	-0.008	0.0539	0.0044
14	-0.006	11	-0.019	0.013	-0.154	0.0321	0.0044
13	-0.008	12	-0.008	0.000	-0.006	0.0107	0.0000
Suma =							0.544

Con la información encontrada se sustituye en la fórmula del estadístico de prueba:

$$SW_C = \frac{[\sum_{i=1}^S (a_i [X_{n-i+1} - X_i])]^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{0.544^2}{0.310} = 0.955$$

Como el estudio se está realizando con 95% de confianza, el nivel de significancia sería 5%, entonces el estadístico teórico se busca de la siguiente manera:

$$SW_{t,\alpha=0.05,n=24}$$

En la tabla de Shapiro-Wilk se tiene que:

Tabla 2-89 Estadístico teórico Shapiro-Wilk⁹¹

Distribución del estadístico de Shapiro-Wilk para la prueba de normalidad									
α									
n	0.01	0.02	0.05	0.10	0.50	0.90	0.95	0.98	0.99
19	0.863	0.879	0.901	0.917	0.957	0.978	0.982	0.986	0.988
20	0.868	0.884	0.905	0.92	0.959	0.979	0.983	0.986	0.988
21	0.873	0.888	0.908	0.923	0.96	0.98	0.983	0.987	0.989
22	0.878	0.892	0.911	0.926	0.961	0.98	0.984	0.987	0.989
23	0.881	0.895	0.914	0.928	0.962	0.981	0.984	0.987	0.989
24	0.884	0.898	0.916	0.93	0.963	0.981	0.984	0.987	0.989
25	0.888	0.901	0.918	0.931	0.964	0.981	0.985	0.988	0.989
26	0.891	0.904	0.920	0.933	0.965	0.982	0.985	0.988	0.989
27	0.894	0.906	0.923	0.935	0.965	0.982	0.985	0.988	0.990
28	0.896	0.908	0.924	0.936	0.966	0.982	0.985	0.988	0.990
29	0.898	0.910	0.926	0.937	0.966	0.982	0.985	0.988	0.990
30	0.900	0.912	0.927	0.939	0.967	0.983	0.985	0.988	0.990

Por lo que el estadístico teórico sería:

$$SW_{t,\alpha=0.05,n=24} = 0.916$$

⁹¹ La tabla del estadístico teórico Shapiro-Wilk se encuentran en el anexo 2.14.

Ahora se compara el estadístico de prueba con el teórico; para rechazar la hipótesis nula:

$$SW_C < SW_t$$

Nótese que este estadístico calculado debe manejarse de diferente manera a la que usualmente se realiza, ya que siempre la regla de decisión dice que cuando el estadístico de prueba es mayor al de la tabla se rechaza la hipótesis nula. Entonces se tiene que:

$$0.955 > 0.916$$

La conclusión es que se tiene evidencia estadística para no rechazar la hipótesis nula, por lo que los errores siguen una distribución normal.

Los valores del estadístico Shapiro-Wilk que da el SPSS™ sobre esta prueba se encuentran en la siguiente tabla:⁹²

Tabla 2-90 Estadísticos para la prueba de normalidad

Pruebas de normalidad						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Residuo no estandarizado	.148	24	.188	.955	24	.351

^a Corrección de la significación de Lilliefors.

En la tabla anterior se puede observar que al estadístico de prueba se le ha asignado su respectivo *p*-valor (Sig.), el cual también se puede utilizar para realizar la prueba de hipótesis, recuerde que para rechazar la H_0 es necesario que:

$$p\text{-valor} < \alpha$$

Por lo que al comparar los valores se tiene que:

$$0.351 > 0.05$$

No se rechaza H_0 ; se concluye que hay evidencia estadística que indica que los errores siguen una distribución normal, por lo que se cumple dicho supuesto.

2.7.5 Prueba de Kolmogorov-Smirnov-Lilliefors

Ésta es una prueba de hipótesis que permite medir qué tanto se parecen o coinciden una distribución teórica específica y una variable. Dicha prueba fue realizada por Andrey Nikolaevich Kolmogorov y por Nikolay Vasilyevich Smirnov, finalmente Hubert Lilliefors realizó una adaptación al usar valores estandarizados para la prueba; esta variante fue dada porque la prueba de Kolmogorov-Smirnov requiere de la formación de clases a través de la probabilidad de la normal, luego (basándose en los límites de las clases) se encuentra la frecuencia observada y se compara con una frecuencia esperada.

El estadístico de Kolmogorov-Smirnov-Lilliefors generalmente se utiliza para muestras grandes, ya que con esto se vuelve más potente; es decir, para cuando el tamaño es mayor o igual a 50.

La fórmula para su obtención es:

$$KSL_C = |D_{\max}| = |F_{teo} - F_{obs}|$$

Donde:

KSL_C : es el estadístico de prueba de Kolmogorov-Smirnov-Lilliefors.

$|D_{\max}|$: es el valor absoluto de la diferencia entre la probabilidad acumulada teórica y la observada.

⁹² El procedimiento para el SPSS sería escoger del menú “analizar”, posteriormente seleccionar “estadísticos descriptivos” y por último se elige la opción “explorar”. La variable a analizar en la “lista de dependientes”, la cual muestra los errores no estandarizados; en la opción “gráficos” se deberá pedir la prueba de normalidad.

F_{teo} : es la probabilidad acumulada teórica.

F_{obs} : es la probabilidad acumulada real u observada.

Las hipótesis para saber si los datos siguen una distribución normal son:

$H_0 : \varepsilon \sim N$, los errores siguen una distribución normal

$H_0 : \varepsilon \not\sim N$, los errores no siguen una distribución normal

El proceso es muy simple, los pasos se muestran a continuación:

1. Ordenar los datos de la variable que se desea probar de menor a mayor.
2. Estandarizar la variable; es decir, obtener $Z = \frac{X - \mu}{\sigma}$. Donde X es la variable a ser estandarizada, μ es el promedio de la variable y σ es la desviación estándar de la misma.
3. Obtener la probabilidad acumulada basándose en la variable estandarizada; a dicha probabilidad se le denomina F_{obs} .
4. Buscar la probabilidad teórica, la cual es llamada F_{teo} y la probabilidad teórica acumulada rezagada o retrasada en un valor.
5. Encontrar todas las distancias entre las probabilidades acumuladas teóricas y observadas, que serían $D_{máx}$.
6. Conocer el estadístico de prueba KS_C , el cual es la diferencia más grande.
7. Encontrar el estadístico teórico KS_t .
8. Comparar si $KS_C > KS_t$, entonces se rechaza la hipótesis nula; es decir, la variable que se está probando no sigue una distribución normal.

De acuerdo con el ejemplo, en el primer paso se deben ordenar los residuales, lo cual aparece en la siguiente tabla; nótese que se agregó el promedio y la desviación estándar.

Tabla 2-91 Residuales ordenados

Y	$\hat{Y}$	Error	Error
Ln_renta	Estimación	ε	Ordenados
9.048	8.930	0.117	-0.188
9.094	8.937	0.157	-0.162
9.547	9.584	-0.037	-0.154
8.517	8.430	0.087	-0.149
9.306	9.400	-0.095	-0.131
8.987	8.754	0.234	-0.095
9.048	8.930	0.117	-0.090
9.393	9.400	-0.008	-0.083
8.269	8.430	-0.162	-0.037
9.393	9.400	-0.008	-0.037
8.923	9.077	-0.154	-0.019
9.071	9.077	-0.006	-0.008
8.987	9.077	-0.090	-0.008
8.243	8.430	-0.188	-0.006
8.854	8.937	-0.083	0.044
9.105	9.254	-0.149	0.087
8.412	8.430	-0.019	0.087

(continúa)

Tabla 2-91 Residuales ordenados (*continuación*)

γ	$\hat{\gamma}$	Error	Error
Ln_renta	Estimación	ε	Ordenados
8.476	8.607	-0.131	0.100
8.975	8.930	0.044	0.110
8.517	8.430	0.087	0.110
9.510	9.400	0.110	0.017
9.510	9.400	0.110	0.017
8.854	8.754	0.100	0.157
9.547	9.584	-0.037	0.234
		Promedio =	8.882E - 16
		Desviación estándar	0.116

El siguiente paso sería estandarizar la variable; para la primera observación se tiene que:

$$Z_1 = \frac{\varepsilon_1 - \bar{\varepsilon}}{S} = \frac{-0.188 - 8.88 \times 10^{-16}}{0.166} = 1.617$$

El proceso continúa hasta la última observación, que sería:

$$Z_{24} = \frac{\varepsilon_{24} - \bar{\varepsilon}}{S} = \frac{2.34 - 8.88 \times 10^{-16}}{0.166} = 2.013$$

La información completa se encuentra en la siguiente tabla:

Tabla 2-92 Residuales estandarizados

Error	Error	Error estandarizado
ε	Ordenados	
0.117	-0.188	-1.617
0.157	-0.162	-1.393
-0.037	-0.154	-1.330
0.087	-0.149	-1.281
-0.095	-0.131	-1.126
0.234	-0.095	-0.816
0.117	-0.090	-0.774
-0.008	-0.083	-0.718
-0.162	-0.037	-0.317
-0.008	-0.037	-0.317
-0.154	-0.019	-0.160
-0.006	-0.008	-0.066
-0.090	-0.008	-0.066
-0.188	-0.006	-0.051
-0.083	0.044	0.382
-0.149	0.087	0.749


(*continúa*)

Tabla 2-92 Residuales estandarizados (continuación)

Error	Error	Error estandarizado
ε	Ordenados	
-0.019	0.087	0.749
-0.131	0.100	0.862
0.044	0.110	0.950
0.087	0.110	0.950
0.110	0.017	1.013
0.110	0.017	1.013
0.100	0.157	1.352
-0.037	0.234	2.013

El siguiente paso es encontrar la probabilidad acumulada en la tabla de la normal, por ejemplo la primera $Z_1 = -1.617 \approx -1.62$ se buscaría de la siguiente manera:


Tabla 2-93 Normal estándar



z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0536	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
-1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1788	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611

Por lo que la probabilidad sería 0.0536, en la misma tabla se marcaron también los valores de $Z_2 = -1.393 \approx -1.39$ cuya probabilidad es 0.0823 y para $Z_3 = -1.33$ de 0.0934. Ahora bien si la Z es positiva la probabilidad se buscaría de la siguiente manera:

Tabla 2-94 Normal estándar



z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6299	0.6344	0.6388	0.6433	0.6477	0.6520	0.6562
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7604	0.7642	0.7678	0.7714	0.7749	0.7784	0.7819	0.7852	0.7885
0.8	0.7881	0.7910	0.7949	0.7987	0.8025	0.8062	0.8099	0.8136	0.8172	0.8208
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830

En la tabla anterior se muestran los valores para $Z_{15} = 0.382 \approx 0.38$ cuya probabilidad es 0.6480, para $Z_{16} = 0.749 \approx 0.75$ de 0.7734 y para $Z_{18} = 0.862 \approx 0.86$ de 0.8051. Los valores encontrados fueron puestos en la siguiente tabla, en la columna denominada probabilidad por medio de Z , o F_{obs} , la diferencia se debe al redondeo que la tabla de la normal tiene a sólo dos decimales:

Tabla 2-95 Probabilidad observada

Error	Error	Error	Probabilidad que se tiene en la
ϵ	Ordenados	estandarizado	distribución Z o F_{obs}
0.117	-0.188	-1.617	0.0529
0.157	-0.162	-1.393	0.0818
-0.037	-0.154	-1.330	0.0917
0.087	-0.149	-1.281	0.1000
-0.095	-0.131	-1.126	0.1300
0.234	-0.095	-0.816	0.2073
0.117	-0.090	-0.774	0.2195
-0.008	-0.083	-0.718	0.2363
-0.162	-0.037	-0.317	0.3756
-0.008	-0.037	-0.317	0.3756
-0.154	-0.019	-0.160	0.4366
-0.006	-0.008	-0.066	0.4738
-0.090	-0.008	-0.066	0.4738

(continúa)

Tabla 2-95 Probabilidad observada (continuación)

Error ϵ	Error Ordenados	Error estandarizado	Probabilidad que se tiene en la distribución Z o F_{obs}
-0.188	-0.006	-0.051	0.4798
-0.083	0.044	0.382	0.6487
-0.149	0.087	0.749	0.7729
-0.019	0.087	0.749	0.7729
-0.131	0.100	0.862	0.8057
0.044	0.110	0.950	0.8289
0.087	0.110	0.950	0.8289
0.110	0.017	1.013	0.8444
0.110	0.017	1.013	0.8444
0.100	0.157	1.352	0.9118
-0.037	0.234	2.013	0.9780

La probabilidad teórica se obtiene a partir del número de observaciones; para el primer valor sería:

$$F_{teo1} = \frac{1}{24} = 0.0417$$

Ahora bien para el segundo valor sería lo mismo, pero como es acumulada se le tiene que sumar la anterior, es decir:

$$F_{teo2} = 0.0417 + \frac{1}{24} = 0.0834$$

Y se continúa hasta obtener el total de todos los valores, lo cual se muestra en la siguiente tabla:

Tabla 2-96 Probabilidad teórica

Error ϵ	Error Ordenados	Error estandarizado	Probabilidad que se tiene en la distribución Z o F_{obs}	Probabilidad basada en el número de datos F_{teo}
0.117	-0.188	-1.617	0.0529	0.0417
0.157	-0.162	-1.393	0.0818	0.0833
-0.037	-0.154	-1.330	0.0917	0.1250
0.087	-0.149	-1.281	0.1000	0.1667
-0.095	-0.131	-1.126	0.1300	0.2083
0.234	-0.095	-0.816	0.2073	0.2500
0.117	-0.090	-0.774	0.2195	0.2917
-0.008	-0.083	-0.718	0.2363	0.3333
-0.162	-0.037	-0.317	0.3756	0.3750
-0.008	-0.037	-0.317	0.3756	0.4167
-0.154	-0.019	-0.160	0.4366	0.4583
-0.006	-0.008	-0.066	0.4738	0.5000

(continúa)

Tabla 2-96 Probabilidad teórica (continuación)

Error ε	Error Ordenados	Error estandarizado	Probabilidad que se tiene en la distribución Z o F_{obs}	Probabilidad basada en el número de datos F_{teo}
-0.090	-0.008	-0.066	0.4738	0.5417
-0.188	-0.006	-0.051	0.4798	0.5833
-0.083	0.044	0.382	0.6487	0.6250
-0.149	0.087	0.749	0.7729	0.6667
-0.019	0.087	0.749	0.7729	0.7083
-0.131	0.100	0.862	0.8057	0.7500
0.044	0.110	0.950	0.8289	0.7917
0.087	0.110	0.950	0.8289	0.8333
0.110	0.017	1.013	0.8444	0.8750
0.110	0.017	1.013	0.8444	0.9167
0.100	0.157	1.352	0.9118	0.9583
-0.037	0.234	2.013	0.9780	1.000

Posterior a esto, se obtiene la frecuencia retrasada en un valor. En el primer valor se tiene cero, en el segundo se tiene el primero, esto es:

$$F_{teo2} = \frac{1}{24} = 0.0417$$

Por lo que en el tercer valor sería el siguiente:

$$F_{teo3} = 0.0417 + \frac{1}{24} = 0.0834$$

Lo anterior se muestra en la columna denominada probabilidad teórica rezagada:

Tabla 2-97 Probabilidad teórica rezagada

Error Ordenados	Error estandarizado	Probabilidad real o Z o F_{obs}	Probabilidad teórica o F_{teo}	Probabilidad teórica rezagada o F_{teo}
-0.188	-1.617	0.0529	0.0417	0.0000
-0.162	-1.393	0.0818	0.0833	0.0417
-0.154	-1.330	0.0917	0.1250	0.0833
-0.149	-1.281	0.1000	0.1667	0.1250
-0.131	-1.126	0.1300	0.2083	0.1667
-0.095	-0.816	0.2073	0.2500	0.2083
-0.090	-0.774	0.2195	0.2917	0.2500
-0.083	-0.718	0.2363	0.3333	0.2917
-0.037	-0.317	0.3756	0.3750	0.3333
-0.037	-0.317	0.3756	0.4167	0.3750
-0.019	-0.160	0.4366	0.4583	0.4167
-0.008	-0.066	0.4738	0.5000	0.4583

(continúa)

Tabla 2-97 Probabilidad teórica rezagada (continuación)

Error Ordenados	Error estandarizado	Probabilidad real o Z o F_{obs}	Probabilidad teórica o F_{teo}	Probabilidad teórica rezagada o F_{teo}
-0.008	-0.066	0.4738	0.5417	0.5000
-0.006	-0.051	0.4798	0.5833	0.5417
0.044	0.382	0.6487	0.6250	0.5833
0.087	0.749	0.7729	0.6667	0.6250
0.087	0.749	0.7729	0.7083	0.6667
0.100	0.862	0.8057	0.7500	0.7083
0.110	0.950	0.8289	0.7917	0.7500
0.110	0.950	0.8289	0.8333	0.7917
0.017	1.013	0.8444	0.8750	0.8333
0.017	1.013	0.8444	0.9167	0.8750
0.157	1.352	0.9118	0.9583	0.9167
0.234	2.013	0.9780	1.000	0.9583

Ahora se diferencian las columnas observadas y teóricas, por ejemplo para el primer valor se tendría:

$$|D_1| = |F_{teo_1} - F_{obs_1}| = |0.0529 - 0.0417| = |-0.0113| = 0.0113$$

Para el segundo valor:

$$|D_2| = |F_{teo_2} - F_{obs_2}| = |0.0818 - 0.0833| = |-0.0016| = 0.0016$$

Cuando la probabilidad teórica esté en 0.50 o arriba de este valor se deberá utilizar el valor de la probabilidad teórica rezagada, como se presenta en el siguiente ejemplo de la observación 12:

$$|D_{12}| = |F_{teo_{12}} - F_{obs_{12}}| = |0.4583 - 0.4738| = |-0.0115| = 0.0115$$

Lo anterior se muestra en la siguiente tabla en la columna $|D|$, la cual ya tiene el valor absoluto de las diferencias:

Tabla 2-98 Diferencia absoluta entre lo teórico y lo observado

Error Ordenados	Error estandarizado	Probabilidad real o Z o F_{obs}	Probabilidad teórica o F_{teo}	Probabilidad teórica rezagada o F_{teo}	IDI
-0.188	-1.617	0.0529	0.0417	0.0000	0.011
-0.162	-1.393	0.0818	0.0833	0.0417	0.002
-0.154	-1.330	0.0917	0.1250	0.0833	0.033
-0.149	-1.281	0.1000	0.1667	0.1250	0.067
-0.131	-1.126	0.1300	0.2083	0.1667	0.078
-0.095	-0.816	0.2073	0.2500	0.2083	0.043
-0.090	-0.774	0.2195	0.2917	0.2500	0.072
-0.083	-0.718	0.2363	0.3333	0.2917	0.097
-0.037	-0.317	0.3756	0.3750	0.3333	0.001
-0.037	-0.317	0.3756	0.4167	0.3750	0.041
-0.019	-0.160	0.4366	0.4583	0.4167	0.022
-0.008	-0.066	0.4738	0.5000	0.4583	0.016
-0.008	-0.066	0.4738	0.5417	0.5000	0.026

(continúa)

Tabla 2-98 Diferencia absoluta entre lo teórico y lo observado (*continuación*)

Error Ordenados	Error estandarizado	Probabilidad real o Z o F_{obs}	Probabilidad teórica o F_{teo}	Probabilidad teórica rezagada o F_{teo}	$ DI $
-0.006	-0.051	0.4798	0.5833	0.5417	0.062
0.044	0.382	0.6487	0.6250	0.5833	0.065
0.087	0.749	0.7729	0.6667	0.6250	0.148
0.087	0.749	0.7729	0.7083	0.6667	0.106
0.100	0.862	0.8057	0.7500	0.7083	0.097
0.110	0.950	0.8289	0.7917	0.7500	0.079
0.110	0.950	0.8289	0.8333	0.7917	0.037
0.017	1.013	0.8444	0.8750	0.8333	0.011
0.017	1.013	0.8444	0.9167	0.8750	0.031
0.157	1.352	0.9118	0.9583	0.9167	0.005
0.234	2.013	0.9780	1.000	0.9583	0.020

De todos los valores se deberá escoger el mayor o más grande, entonces el estadístico de prueba quedaría de la siguiente manera:

$$KSL_C = |D_{\max}| = |0.625 - 0.7729| = |-0.1479| \approx 0.148$$

Como el estudio se está realizando con 95% de confianza, el nivel de significancia sería 5%, entonces el estadístico teórico se busca de la siguiente manera:

$$KSL_{t,\alpha=0.05,n=24}$$

Al buscar el valor en la tabla de Kolmogorov-Smirnov-Lilliefors se tiene que:

Tabla 2-99 Tabla Kolmogorov-Smirnov-Lilliefors⁹³

Distribución del estadístico Kolmogorov-Smirnov-Lilliefors para pruebas de normalidad						
α						
n	0.20	0.15	0.10	0.05	0.01	0.00
17	0.171	0.179	0.190	0.207	0.240	0.279
18	0.167	0.175	0.185	0.202	0.234	0.273
19	0.163	0.170	0.181	0.197	0.228	0.266
20	0.159	0.166	0.176	0.192	0.223	0.260
25	0.143	0.150	0.159	0.173	0.201	0.236
30	0.131	0.138	0.146	0.159	0.185	0.217
>30	$\frac{0.74}{\sqrt{n}}$	$\frac{0.77}{\sqrt{n}}$	$\frac{0.82}{\sqrt{n}}$	$\frac{0.89}{\sqrt{n}}$	$\frac{1.04}{\sqrt{n}}$	$\frac{1.22}{\sqrt{n}}$

El valor de 24 no viene en la tabla, entonces se escogerá el más cercano que sería 25. El estadístico teórico o de tablas sería:

$$KS_{t,\alpha=0.05,n=24} = 0.173$$

Si $KS_C > KS_t$ se rechaza la hipótesis nula, entonces:

$$0.148 < 0.173$$

Se concluye que hay evidencia estadística para no rechazar la hipótesis nula, por lo que los errores siguen una distribución normal.

⁹³ La tabla del estadístico teórico Kolmogorov-Smirnov-Lilliefors se encuentran en el anexo 2.

Los valores del estadístico Kolmogorov-Smirnov-Lilliefors que da el SPSS™ sobre esta prueba están en la siguiente tabla:⁹⁴

Tabla 2-100 Estadísticos para la prueba de normalidad

	Pruebas de normalidad					
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Residuo no estandarizado	.148	24	.188	.955	24	.351

^a Corrección de la significación de Lilliefors.

A la prueba se le asigna su respectivo p -valor (Sig.), que se utiliza para realizar la prueba de hipótesis; recuerde que para rechazar la H_0 es necesario que:

$$p\text{-valor} < \alpha$$

Aunque no se debería realizar la prueba, ya que es recomendable para mayor a 50, se decidió presentarla:




$$0.188 > 0.05$$

No se rechaza H_0 , por lo que se concluye que se tiene evidencia estadística que indica que los errores siguen una distribución normal, por lo que dicho supuesto se cumple.

2.7.6 Gráfica P-P y Q-Q

Denominadas P-P *plot* por los percentiles que se necesitan encontrar y Q-Q *plot* porque se necesitan los cuantiles; estas gráficas sirven para verificar que los errores siguen o no una distribución normal. Los tipos de gráfica que se pueden presentar son:


Tabla 2-101 Tipos de gráficas

	Estado ideal, en la que se puede concluir que los errores siguen una distribución normal.
	Por la bolsa que se forma hacia abajo se puede decir que existe un sesgo positivo; con este tipo de gráfica se puede concluir que los errores no siguen una distribución normal ya que está sesgada a la derecha.
	Por la bolsa que se forma hacia arriba se puede decir que existe un sesgo negativo; con este tipo de gráfica se puede concluir que los errores no siguen una distribución normal ya que está sesgada a la izquierda.

⁹⁴ El procedimiento para el SPSS sería escoger del menú “analizar”, posteriormente elegir la opción “estadísticos descriptivos” y por último seleccionar “explorar”. La variable a analizar en “lista de dependientes” debe ser errores no estandarizados, en “gráficos” se deberá pedir la prueba de normalidad.

Pasos a seguir para encontrar la P-P o Q-Q *plot*:


1. Encontrar los errores.
2. Ordenar los errores de menor a mayor.
3. Poner en la columna j el lugar que ocupa el error, esto equivale a una numeración.
4. Encontrar la probabilidad de la normal con $\frac{j - 0.5}{n}$, el 0.5 equivale a la mitad de la normal y la n es el número de errores que se tienen en el análisis.
5. Multiplicar la probabilidad por 100 para convertirla a percentil. En esta parte se puede encontrar la P-P *plot*, graficando en el eje X los percentiles o las probabilidades y en el eje Y los errores ordenados,⁹⁵ agregándole una línea recta ajustada.⁹⁶ La gráfica obtenida se muestra a continuación:



Gráfica 2-21 P-P *plot* o gráfica P-P.

Encontrar los valores de Z en la tabla de la normal basándose en la probabilidad del inciso c.

Graficar en el eje X los cuantiles (quantiles en inglés) y en el eje Y los errores ordenados; dicha gráfica se presenta a continuación:



Gráfica 2-22 Q-Q *plot* o gráfica Q-Q.

⁹⁵ Los datos para realizar esta gráfica se presentan en la siguiente página.

⁹⁶ Es decir, que trate de pasar lo más cerca posible de todos los puntos.


Los datos para realizar lo anterior se presentan a continuación:

Tabla 2-102 Residuales ordenados

y	$\hat{y}$	Error	Error					
Ln_renta	Estimación	ε	Ordenados	j	$(j - 0.5)/n$	Percentil	Z	Cuantil o Z
9.048	8.930	0.117	-0.188	1	0.0208	2.08	-2.035	-2.037
9.094	8.937	0.157	-0.162	2	0.0625	6.25	-1.535	-1.534
9.547	9.584	-0.037	-0.154	3	0.1042	10.42	-1.255	-1.258
8.517	8.430	0.087	-0.149	4	0.1458	14.58	-1.055	-1.054
9.306	9.400	-0.095	-0.131	5	0.1875	18.75	-0.885	-0.887
8.987	8.754	0.234	-0.095	6	0.2292	22.92	-0.745	-0.742
9.048	8.930	0.117	-0.090	7	0.2708	27.08	-0.615	-0.610
9.393	9.400	-0.008	-0.083	8	0.3125	31.25	-0.485	-0.489
8.269	8.430	-0.162	-0.037	9	0.3542	35.42	-0.375	-0.374
9.393	9.400	-0.008	-0.037	10	0.3958	39.58	-0.265	-0.264
8.923	9.077	-0.154	-0.019	11	0.4375	43.75	-0.155	-0.157
9.071	9.077	-0.006	-0.008	12	0.4792	47.92	-0.055	-0.052
8.987	9.077	-0.090	-0.008	13	0.5208	52.08	0.055	0.052
8.243	8.430	-0.188	-0.006	14	0.5625	56.25	0.155	0.157
8.854	8.937	-0.083	0.044	15	0.6042	60.42	0.265	0.264
9.105	9.254	-0.149	0.087	16	0.6458	64.58	0.375	0.374
8.412	8.430	-0.019	0.087	17	0.6875	68.75	0.485	0.489
8.476	8.607	-0.131	0.100	18	0.7292	72.92	0.615	0.610
8.975	8.930	0.044	0.110	19	0.7708	77.08	0.745	0.742
8.517	8.430	0.087	0.110	20	0.8125	81.25	0.885	0.887
9.510	9.400	0.110	0.017	21	0.8542	85.42	1.055	1.054
9.510	9.400	0.110	0.017	22	0.8958	89.58	1.255	1.258
8.854	8.754	0.100	0.157	23	0.9375	93.75	1.535	1.534
9.547	9.584	-0.037	0.234	24	0.9792	97.92	2.035	2.037

En las dos últimas columnas se muestra el valor del cuantil o Z , los cuales fueron encontrados con la probabilidad y en la tabla de la normal estándar; en la última columna se utilizaron los valores que Excel arroja al respecto; el primero se muestra a continuación:

Tabla 2-103 Normal estándar




z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823

Por lo que el valor de la Z corresponde a:

$$Z = \frac{(-2.03) + (-2.04)}{2} = -2.035$$

El segundo de los valores fue encontrado de la siguiente manera:

Tabla 2-104 Normal estándar



z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823

Por lo que el valor de la Z corresponde a:


$$Z = \frac{(-1.53) + (-1.54)}{2} = -1.535$$

Los demás valores serían encontrados de la misma manera.

Si se grafican los percentiles *versus* los errores, a la gráfica se le denomina P-P *plot* y si se grafican los cuantiles *versus* los errores se le llamaría Q-Q *plot*. Es importante recordar que los errores siempre van en el eje Y.

Las gráficas con los valores encontrados se mostraron con anterioridad y se debe ver si siguen una línea recta o qué tan cerca de esa línea están.


En el listado del SPSS™, los resultados anteriores aparecen en la gráfica de normalidad:



Gráfica 2-23 P-P plot del SPSS™.

Como se ve casi todos los valores se encuentran fuera de la línea, por lo que se recomienda encontrar los intervalos para cada valor, éstos marcarían el límite que se tendría en la muestra.

La gráfica con los intervalos se muestra a continuación:



Gráfica 2-24 P-P plot con los intervalos de confianza.

Por ejemplo el SPSS™ utiliza la probabilidad observada en el eje X y la esperada en el eje Y. Como se ve las gráficas son diferentes por lo que se usa para graficar, pero al final se concluye en todas ellas que los errores siguen una distribución normal.

2.7.7 Prueba de Bowman-Shelton

En 1975 K. Bowman y L. Shelton propusieron esta prueba de hipótesis que se utiliza para corroborar si los datos siguen una distribución normal. Dicha prueba involucra los momentos,⁹⁷ parte de éstos forman el sesgo y la curtosis, la fórmula del estadístico cuando el número de datos es grande se aproxima a una ji cuadrada, la cual sería de la siguiente manera:

⁹⁷ Los momentos son medidas que resumen la información: el primero es el promedio o la media, el cual indica dónde se encuentra la mayoría de la información; el segundo forma parte de la varianza, con esta medida se indica la dispersión o variabilidad que los datos tienen alrededor del promedio; el tercero es parte del sesgo, que indica el grado de simetría; y parte del cuarto momento es la curtosis que muestra qué tan rápido o lento caen los extremos de la distribución.

Ecuación 2-32 Estadístico Bowman-Shelton

$$BS = n \left[\frac{(\text{Sesgo})^2}{6} + \frac{(\text{Curtosis} - 3)^2}{24} \right] \approx \chi^2_C$$

Donde:

BS : es el estadístico Bowman-Shelton que se aproxima a una ji cuadrada con dos grados de libertad.

n : es el número de datos.

Sesgo : es el sesgo o parte del tercer momento e indica el grado de simetría en los datos con respecto al valor central o promedio.

Curtosis : Es curtosis o parte del cuarto momento e indica el peso de los extremos o colas de la distribución, es decir que tan rápido o lento bajan.

El sesgo es el grado de simetría; si es negativo, la distribución será sesgada a la izquierda, esto se muestra a continuación:




Figura 2-20 Asimetría a la izquierda o sesgo negativo.

Si el sesgo es positivo, la distribución será sesgada a la derecha, lo cual se muestra en la siguiente figura:




Figura 2-21 Asimetría a la derecha o sesgo positivo.

Si el sesgo es cero, entonces la distribución sería simétrica, como a continuación se ve:




Figura 2-22 Insesgada o simétrica.

Lo que se desea es que el sesgo sea cero. La fórmula para encontrar el sesgo involucra al tercero y al segundo momentos y se muestra en seguida, se involucran a los errores:

Ecuación 2-33 Sesgo

$$\text{Sesgo} = \frac{m_3}{(m_2)^{\frac{3}{2}}} = \frac{\sum_{i=1}^n (X - \bar{X})^3}{n(S^2)^{\frac{3}{2}}} = \frac{\sum_{i=1}^n (\varepsilon - \bar{\varepsilon})^3}{n(S^2)^{\frac{3}{2}}}$$

Donde:

n : es el número de datos, en este caso sería el número de errores.

m_i : es el momento i .

S^2 : es la varianza, en este caso sería la varianza de los errores, la cual se encuentra en la tabla ANOVA y anteriormente se calculó.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	3.478	3	1.159	74.912	.000 ^a
	Residual	.310	20	.015		
	Total	.3787	23			

^a Variables predictoras: (Constante) sur, cuartos, norte.

^b Variable dependiente: Ln_renta.

A continuación se muestran los resultados que se obtendrían de los errores, para calcular el segundo y tercer momentos:

Tabla 2-105 Datos

Ln (renta)		Error		
Y	$\hat{Y}$	ε_t	$(\varepsilon_t - \text{Prom})^2$	$(\varepsilon_t - \text{Prom})^3$
9.048	8.930	0.117	0.01381	0.001622
9.094	8.937	0.157	0.02460	0.003858
9.547	9.584	-0.037	0.00135	-0.000050
8.517	8.430	0.087	0.00754	0.000655
9.306	9.400	-0.095	0.00895	-0.000847
8.987	8.754	0.234	0.05454	0.012737
9.048	8.930	0.117	0.01381	0.001622
9.393	9.400	-0.008	0.00006	0.000000
8.269	8.430	-0.162	0.02612	-0.004222
9.393	.400	-0.008	0.00006	0.000000
8.923	9.077	-0.154	0.02381	-0.003674
9.071	9.077	-0.006	0.00003	0.000000
8.987	9.077	-0.090	0.00806	-0.000723
8.243	8.430	-0.188	0.03519	-0.006602
8.854	8.937	-0.083	0.00694	-0.000578
9.105	9.254	-0.149	0.02210	-0.003285
8.412	8.430	-0.019	0.00034	-0.000006
8.476	8.607	-0.131	0.01707	-0.002230

(continúa)

Tabla 2-105 Datos (continuación)


Ln (renta)		Error		
Y	$\hat{Y}$	ε_t	$(\varepsilon_t - \text{Prom})^2$	$(\varepsilon_t - \text{Prom})^3$
8.975	8.930	0.044	0.00196	0.000087
8.517	8.430	0.087	0.00754	0.000655
9.510	9.400	0.110	0.01214	0.001337
9.510	9.400	0.110	0.01214	0.001337
8.854	8.754	0.100	0.01000	0.001000
9.547	9.584	-0.037	0.00135	-0.000050
Suma =		2.132E - 14	0.3095	0.00264

Lo que se desea es que el sesgo sea cero. La fórmula para encontrar el sesgo involucra al tercero y al segundo momentos y se muestra en seguida, pero involucrando a los errores:

$$\text{Sesgo} = \frac{\sum_{i=1}^n (\varepsilon - \bar{\varepsilon})^3}{n(S^2)^{\frac{3}{2}}} = \frac{0.00264}{24 \left(\frac{0.3095}{24-4} \right)^{\frac{3}{2}}} = \frac{0.00264}{24(0.015)^{\frac{3}{2}}} = 0.057$$

El valor anterior muestra que como es cercano a cero tiende a ser simétrica con un ligero sesgo a la derecha.

La curtosis es el peso de los extremos o colas de la distribución; es decir, qué tan rápido o lento bajan. Si los extremos caen muy rápidamente, la curtosis sería mayor a 3; por el contrario si las colas caen muy lentamente, entonces la curtosis sería menor a 3 y si la curtosis es de 3 la distribución sería de una normal; esto se muestra a continuación:



Una curtosis mayor a 3 significa que la curva es más esbelta o aguda que la normal y sus extremos caen muy rápidamente, mientras que una curtosis menor a 3 indica que la curva es más aplanada de la normal, lo que implicaría que los extremos tardan más en caer. Se desea que la curtosis sea 3. La fórmula para encontrar curtosis involucra al cuarto y al segundo momentos como se muestra en seguida:

Ecuación 2-34 Curtosis.

$$\text{Curtosis} = \frac{m_4}{n(m_2)^2} = \frac{\sum_{i=1}^n (X - \bar{X})^{-4}}{n(S^2)^2} = \frac{\sum_{i=1}^n (\varepsilon - \bar{\varepsilon})^{-4}}{n(S^2)^2}$$

Donde:

n : es el número de datos, en este caso sería el número de errores.

m_i : es el momento i .

S^2 : es la varianza, en este caso sería la varianza de los errores, la cual se encuentra en la tabla ANOVA y anteriormente se calculó.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	3.478	3	1.159	74.912	.000 ^a
	Residual	.310	20	.015		
	Total	.3787	23			

^a Variables predictoras: (constante) sur, cuartos, norte.

^b Variable dependiente: Ln_renta.

A continuación se muestran los resultados que se obtendrían de los errores para calcular el segundo y cuarto momentos:

Tabla 2-106 Datos

Ln : (renta)		Error		
Y	$\hat{Y}$	ε_t	$(\varepsilon_t - \text{Prom})^2$	$(\varepsilon_t - \text{Prom})^4$
9.048	8.930	0.117	0.01381	0.0001906064
9.094	8.937	0.157	0.02460	0.0006050850
9.547	9.584	-0.037	0.00135	0.0000018277
8.517	8.430	0.087	0.00754	0.000056867
9.306	9.400	-0.095	0.00895	0.0000801682
8.987	8.754	0.234	0.05454	0.0029745064
9.048	8.930	0.117	0.01381	0.0001906064
9.393	9.400	-0.008	0.00006	0.0000000034
8.269	8.430	-0.162	0.02612	0.0006823466
9.393	.400	-0.008	0.00006	0.0000000034
8.923	9.077	-0.154	0.02381	0.0005669814
9.071	9.077	-0.006	0.00003	0.0000000012
8.987	9.077	-0.090	0.00806	0.0000649442
8.243	8.430	-0.188	0.03519	0.0012385421
8.854	8.937	-0.083	0.00694	0.0000481531
9.105	9.254	-0.149	0.02210	0.0004882603
8.412	8.430	-0.019	0.00034	0.0000001177
8.476	8.607	-0.131	0.01707	0.0002913156
8.975	8.930	0.044	0.00196	0.0000038499
8.517	8.430	0.087	0.00754	0.0000568670
9.510	9.400	0.110	0.01214	0.0001473202
9.510	9.400	0.110	0.01214	0.0001473202
8.854	8.754	0.100	0.01000	0.0001000182
9.547	9.584	-0.037	0.00135	0.0000018277
Suma =		2.132E - 14	0.3095	0.00794

Lo que se desea es que el sesgo sea cero. La fórmula para encontrar el sesgo involucra al tercero y al segundo momentos y se muestra en seguida, pero involucrando a los errores:

$$Curtosis = \frac{\sum_{i=1}^n (\varepsilon - \bar{\varepsilon})^4}{n(S^2)^2} = \frac{0.00794}{24 \left(\frac{0.3095}{24-4} \right)^2} = \frac{0.00264}{24(0.015)^2} = 1.381$$

El valor anterior muestra que como es menor a tres tiende a ser aplanada.

Ahora bien, después de haber calculado el sesgo y la curtosis se procede a encontrar el estadístico de Bowman-Shelton, pero primero se deben establecer las hipótesis:

$H_0 : \varepsilon \sim N$, los errores siguen una distribución normal

$H_a : \varepsilon \not\sim N$, los errores no siguen una distribución normal

El estadístico sería:

$$BS = n \left[\frac{(\text{Sesgo})^2}{6} + \frac{(\text{Curtosis} - 3)^2}{24} \right] = 24 \left[\frac{(0.057)^2}{6} + \frac{(1.381 - 3)^2}{24} \right]$$

Entonces el resultado sería:


$$BS = 2.623 \approx \chi^2_c$$

Lo anterior significa que el estadístico de prueba se aproxima a una ji cuadrada y que el valor se compara con el de una ji cuadrada teórica o de tablas con dos grados de libertad, lo cual se debe a las dos estimaciones realizadas.

$$\chi^2_{t,\alpha=0.05,2}$$

El valor se busca de la siguiente manera:

Tabla 2-107 Tabla ji cuadrada⁹⁸



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322

Entonces, el estadístico teórico sería:

$$\chi^2_{t,\alpha=0.05,2} = 5.991$$

Para rechazar la H_0 es necesario que:


$$\chi^2_C > \chi^2_{t,\alpha,2}$$

⁹⁸ Ver anexo 3.1 "Tabla ji cuadrada".

Por lo que:

$$2.623 < 5.991 \text{ no se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Como no se rechazó H_0 se puede concluir que los errores siguen una distribución normal, por lo que el supuesto de normalidad se cumple.

Teóricamente el estadístico de Bowman-Shelton es muy bueno cuando la muestra es lo suficientemente grande.

2.8 Detección de valores atípicos

Valores atípicos. Son valores o muy grandes o muy chicos con respecto a los demás o a la mayoría de los residuales o errores; son valores muy alejados de todas las observaciones.

Los **valores atípicos** también conocidos como *outliers*, por su nombre en inglés, son valores o muy grandes o muy chicos con respecto a los demás o a la mayoría de los residuales o errores, es decir son valores muy alejados de todas las observaciones. Un valor atípico trae como consecuencia que la normalidad no se cumpla, así como que tampoco se cumpla la homoscedasticidad.⁹⁹

Entre las posibles formas de detectar un valor atípico se encuentran:





Figura 2-22 Posibles formas de detectar un valor atípico.

2.8.1 Histograma

El histograma,¹⁰⁰ además de servir para ver la forma o el tipo de distribución, ayuda a detectar los valores atípicos (*outliers*); al observar el histograma que el SPSS™ da como resultado se observa lo siguiente:

⁹⁹ Los términos *varianzas homogéneas*, *homoscedasticidad* o bien *homogeneidad de varianzas* son sinónimos; este tema se verá posteriormente en este capítulo.

¹⁰⁰ La construcción del histograma se vio en puntos anteriores.



Gráfica 2-25 Histograma del SPSS™

Se puede notar que el histograma utiliza los errores estandarizados,¹⁰¹ ningún valor se encuentra alejado del ± 2 , por lo que podría concluirse que no existe ningún valor atípico. La siguiente regla también puede aplicarse a los *outlier*.

2.8.2 Regla empírica

En puntos anteriores se habían estandarizado los valores de los residuales, la información al respecto se muestra en la siguiente tabla:

Tabla 2-108 Contabilizar los errores estandarizados

ε Error	ε Estandarizado	ε Estandarizado	ε Estandarizado	ε Estandarizado
Ordenados	Ordenados	± 1	± 2	± 3
-0.188	-1.508	-1.508	-1.508	-1.508
-0.162	-1.299	-1.299	-1.299	-1.299
-0.154	-1.240	-1.240	-1.240	-1.240
-0.149	-1.195	-1.195	-1.195	-1.195
-0.131	-1.050	-1.050	-1.050	-1.050
-0.095	-0.761	-0.761	-0.761	-0.761
-0.090	-0.722	-0.722	-0.722	-0.722
-0.083	-0.670	-0.670	-0.670	-0.670
-0.037	-0.296	-0.296	-0.296	-0.296
-0.037	-0.296	-0.296	-0.296	-0.296
-0.019	-0.149	-0.149	-0.149	-0.149
-0.008	-0.061	-0.061	-0.061	-0.061
-0.008	-0.061	-0.061	-0.061	-0.061
-0.006	-0.047	-0.047	-0.047	-0.047

(continúa)

¹⁰¹ La estandarización de una variable se cubrió en el tema que trata de la normalidad.

Tabla 2-108 Contabilizar los errores estandarizados (*continuación*)

ε Error	ε Estandarizado	ε Estandarizado	ε Estandarizado	ε Estandarizado
Ordenados	Ordenados	± 1	± 2	± 3
0.044	0.356	0.356	0.356	0.356
0.087	0.698	0.698	0.698	0.698
0.087	0.698	0.698	0.698	0.698
0.100	0.804	0.804	0.804	0.804
0.110	0.886	0.886	0.886	0.886
0.110	0.886	0.886	0.886	0.886
0.117	0.945	0.945	0.945	0.945
0.117	0.945	0.945	0.945	0.945
0.157	1.261	1.261	1.261	1.261
0.234	1.877	1.877	1.877	1.877

De 24 errores 17 están entre ± 1 , entonces el porcentaje que se encuentra dentro de ± 1 , teóricamente sería 68.27%.

Dentro de 95.45%, es decir a ± 2 , teóricamente el número de errores debería ser 23, pero en realidad hay 24, en el ejemplo.

Por último se encuentran los del rango de ± 3 , esto es 99.73%, se tendrían también los 24 errores. Ahora bien comparando los porcentajes encontrados de la regla empírica, se tiene:

Tabla 2-109 Porcentajes


Número de desviaciones	Número de residuales	Porcentaje teórico	Porcentaje real
± 1	17	68.27%	70.83%
± 2	24	95.45%	100.00%
± 3	24	99.73%	100.00%

En la tabla anterior se muestra el número de desviaciones según la regla empírica, en la segunda columna aparece el número de residuales que se encuentran entre esas desviaciones, la tercera columna es el porcentaje teórico según la regla empírica y en la última columna se muestran los porcentajes reales; como las 2 columnas de los porcentajes son muy parecidas se puede concluir que los valores tienden a una distribución normal y además no se tiene ningún valor muy alejado ni fuera de ± 2 y ± 3 ; por lo que esto podría indicar que no existe ningún valor atípico.

2.8.3 Gráfica de los residuales


En puntos anteriores se habían estandarizado los valores de los residuales, al graficarlos dan una idea de qué valores se encuentran muy alejados de la mayoría. A continuación se presentan las posibles formas en que se pueden detectar los valores atípicos.

Tabla 2-110 Tipos de gráficas

	Uno de los valores es muy grande con respecto a los demás.
---	--

(*continúa*)

Tabla 2-110 Tipos de gráficas (continuación)


	Uno de los valores es muy pequeño con respecto a los demás.
	Estado ideal; se puede concluir que no existe un valor atípico.

De acuerdo con el ejemplo, los valores a graficar serían los errores estandarizados y los pronósticos, dicha información se presenta a continuación:

Tabla 2-111 Pronósticos y residuales estandarizados

$\hat{y}$	
Estimación	Error estandarizado
8.930	−1.617
8.937	−1.393
9.584	−1.330
8.430	−1.281
9.400	−1.126
8.754	−.0816
8.930	−0.774
9.400	−0.718
8.430	−0.317
9.400	−0.317
9.077	−0.160
9.077	−0.066
9.077	−0.066
8.430	−0.051
8.937	−.382
9.254	0.749
8.430	0.749
8.607	0.862
8.930	0.950
8.430	0.950
9.400	1.013
9.400	1.013
8.754	1.352
9.584	2.013

Ahora la gráfica quedaría de la siguiente manera:




Gráfica 2-26 Residuales estandarizados.

Como ningún valor se encuentra fuera de ± 2 y ± 3 se puede concluir que no existe ningún valor atípico, pues ninguno se ve muy alejado de la mayoría de la información.

2.9 Independencia de los errores


El siguiente supuesto a probar es la independencia de los errores. Para corroborar que los errores no están correlacionados es necesario saber si los datos originales están o no acomodados cronológicamente; cuando sí lo están se les denominan *datos de corte longitudinal*, cuando esto no ocurre se les llaman *datos de corte transversal*, ya que fueron medidos en sólo una fracción del tiempo; gráficamente los datos de corte longitudinal y transversal se verían de la siguiente manera:



Gráfica 2-27 Datos longitudinales y transversales.


La gráfica anterior muestra que con relación al tiempo los datos longitudinales (línea de color gris claro) fueron medidos en 12 periodos, los cuales pueden ser en meses, en años o en días, sin embargo los datos de corte transversal (línea de color negro) fueron medidos todos en el tiempo seis.

Si los datos fueron longitudinales se tienen las siguientes formas para medir la independencia de los residuales o errores:



Dibujo 2-2 Datos de corte longitudinal.

Si los datos fueron transversales se tienen las siguientes formas para medir la independencia de los residuales o errores:



Dibujo 2-3 Datos de corte transversal.

En el ejemplo, los datos son de corte transversal, ya que la información fue recabada de varios estudiantes al mismo tiempo. Esto indica que no se puede realizar la prueba con el estadístico Durbin-Watson. Se empezará con la gráfica de los residuales, que debe tener un comportamiento aleatorio, de no ser así hay algún problema.

2.9.1 Gráfica para probar independencia


Si se decidió utilizar la gráfica, en el eje de las abscisas va el pronóstico y en el eje de las ordenadas van los residuales; si al observar dicha gráfica se ve que los errores se comportan de forma aleatoria, se concluiría que hay independencia, por el contrario, si no existe aleatoriedad, entonces es necesario analizar los problema que se podrían tener. A continuación se presentan los posibles tipos de gráficas:

Tabla 2-112 Gráficas de dependencia o independencia

	Esta gráfica indica que existe una dependencia lineal, lo cual significa que se debe agregar un término lineal con respecto a Y misma, pero arreglados cronológicamente. En este caso la Y depende de sí misma.
	Esta gráfica indica que existe una dependencia no lineal (cuadrática); en este caso se deberá volver al principio ya que se debió utilizar un término polinomial, pues existe no linealidad con alguna variable independiente. Es necesario saber cuál de las variables independencia (o ellas) sería el término no lineal al graficar la Y con cada una de las X.
	Otra vez, en este tipo como en la anterior, existe una dependencia no lineal (cúbica), se deberá utilizar el término polinomial (al igual que con la gráfica anterior), pero en este caso cúbica, ya que existe no linealidad. Otra vez, es necesario saber cuál de las variables independencia sería el término no lineal al graficar la Y con cada una de las X.
	Condición normal o ideal; los errores son independientes, por lo que el supuesto de independencia se cumple.


Si la gráfica de los residuales con respecto al pronóstico muestra abanicos es necesario quitar este tipo de problema antes de poder analizar la independencia.

La gráfica que da como resultado el SPSS™ se muestra a continuación:




Gráfica 2-28 Dispersión de los errores.

Se interpreta al buscar un patrón lineal o no lineal, parece ser de la existencia del último tipo; para mostrar lo anterior se le ajustará una línea, la cual en las repeticiones deberá pasar por en medio de ellas, esto quedaría de la siguiente manera:



Gráfica 2-29 Interpretación no lineal.

Como se ve en la gráfica anterior, se tiene un comportamiento polinomial (no lineal), por lo que se debe corregir la no linealidad. Es necesario saber qué variable o variables independientes tienen una relación no lineal con Y; en este caso es muy sencillo ya que las variables incluidas en el modelo son: cuartos, norte y sur; en las dos últimas sólo se marca la presencia y la ausencia, por lo que ninguna de ellas puede tener una relación no lineal, finalmente por eliminación la única es la variable cuartos, a continuación se muestra el ajuste que deberá realizarse a dicha variable:



Gráfica 2-30 Ajuste no lineal.

Toma de decisiones. La variable cuartos tiene una relación no lineal con Y; es decir, tiene una relación polinomial de grado 3, por lo que es necesario agregar el cuadrado y el cubo¹⁰² de la variable cuartos, esto da como resultado que, de sólo 3 variables,¹⁰³ ahora sólo se cuenta con cinco.


La nueva ecuación sería la siguiente:

Tabla 2-113 Nueva ecuación

Modelo		Coefficientes no
		B
1	(Constante)	6.654
	Cuartos	2.602
	Norte	.091
	Sur	.110
	Cuartos 2	-.999
	Cuartos 3	.130

^a Variable dependiente: Ln_renta.

Una vez corregido el problema,¹⁰⁴ después de volver a realizar todas las pruebas correspondientes, medir si el supuesto de normalidad se cumple y de ver si el modelo final es mejor que el anterior, se procede de nuevo a revisar la gráfica de los residuales con respecto al pronóstico, la cual se muestra a continuación:




Gráfica 2-31 Dispersión de los errores.

¹⁰² El cuadrado y el cubo de la variable “cuartos”, se refiere a que dicha variable se elevó al cuadrado y al cubo respectivamente, las cuales fueron llamadas *CuartosDOS* y *CuartosTRES* respectivamente.

¹⁰³ Las variables con las cuales se contaban son “cuartos”, “zona norte” y “sur”; ahora serán las mismas tres más las dos agregadas.


¹⁰⁴ Al corregir cada uno de los problemas, es necesario revisar cada una de las pruebas realizadas hasta el momento, pero es importante comentar que no puede medirse la multicolinealidad entre las variables lineales y sus polinomios, por ejemplo en este caso no debe de ver si existe multicolinealidad entre cuartos, cuartos al cuadrado y cuartos al cubo.

Parece que ahora sí se obtiene un comportamiento aleatorio, esto se muestra en la siguiente gráfica, a la cual se le agregó una línea de interpretación:



Gráfica 2-32 Comportamiento aleatorio.

Se ve que existen repeticiones de los datos, entonces la línea debe trazarse en medio de las repeticiones y donde existe sólo una observación (no hay repeticiones) entonces la línea deberá pasar por ese punto o dato. Esa línea trazada por medio del SPSS™ se vería en la gráfica de la siguiente manera:



Gráfica 2-33 Comportamiento aleatorio.

Con esto se corrobora que el comportamiento es aleatorio, por lo que el supuesto de independencia se cumple.

2.9.2 Prueba de Durbin-Watson

El estadístico Durbin-Watson sirve para medir la autocorrelación,¹⁰⁵ recuerde que es necesario que los datos deben acomodarse cronológicamente,¹⁰⁶ en el ejemplo no es el caso, ya que los datos son de corte transversal, por lo que no debe hacerse la prueba de hipótesis; sólo a modo de ejemplo se realizará. Las hipótesis¹⁰⁷ correspondientes a esta prueba son:

¹⁰⁵ La independencia indica que los errores son estadísticamente independientes; en la autocorrelación, los errores que están en un periodo específico se encuentran relacionados con los errores que se encuentran en otro periodo, es decir, es la correlación de los errores en el tiempo. Tanto la dependencia como la autocorrelación violan uno de los supuestos de la regresión (aleatorios e independientes). El estadístico Durbin-Watson se utiliza para probar la autocorrelación del primer rezago, es decir un periodo atrás (con el pasado o ayer), por lo cual se dice que es de primer orden.

¹⁰⁶ Los datos que se arreglan cronológicamente son de corte longitudinal y los datos que no se pueden arreglar de esa forma son de corte transversal.

¹⁰⁷ En esta prueba existen tres zonas: H_0 , Zona de indecisión y H_1 .

H_0 : los errores de primer orden son independientes, aleatorios, o no correlacionados; es decir, la correlación entre el error en el tiempo t es independiente del error en el tiempo $t - 1$, lo cual se representa de la siguiente manera $\text{Corr}(\varepsilon_t - \varepsilon_{t-1}) = 0$.

H_1 : los errores de primer orden no son independientes, no aleatorios, o correlacionados; es decir, la correlación entre el error en el tiempo t es independiente del error en el tiempo $t - 1$, lo cual se representa de la siguiente manera $\text{Corr}(\varepsilon_t - \varepsilon_{t-1}) \neq 0$.

La fórmula del estadístico de prueba o estadístico Durbin-Watson es la siguiente:

Ecuación 2-35 Estadístico Durbin-Watson.

$$DW_c = \frac{\sum_{t=2}^n (\varepsilon_t - \varepsilon_{t-1})^2}{\sum_{t=1}^n (\varepsilon_t)^2}$$

Donde:

ε_t : es el error organizado cronológicamente en el tiempo t .

ε_{t-1} : es el error ordenado cronológicamente en el tiempo $t - 1$.

Por ejemplo, si hoy es el tiempo t y la información está arreglada por día, entonces $t - 1$ es ayer o bien si el tiempo está en años, entonces el ayer es el año pasado. Es importante añadir que se le llama *variable rezagada* en el primer tiempo o bien *lag* (1) en inglés.

El valor del estadístico oscila entre cero y 4, en donde un valor cercano a 0 indica que existe una autocorrelación positiva ($p > 0$), mientras que un valor cercano a 4 significa que la autocorrelación negativa ($p < 0$) está presente y un valor cercano a 2 implica que la hipótesis nula no fue rechazada por lo que no existe autocorrelación ($p = 0$). El acomodo de los valores de Durbin-Watson de tablas da como resultado una zona entre la hipótesis nula y las regiones de rechazo, a ésta se le denomina zona de indecisión, todo lo anterior se muestra en la siguiente figura:




Figura 2-23 Zonas del estadístico Durbin-Watson.

De acuerdo con el ejemplo al agregar la columna de los nuevos errores se tienen cinco variables, las cuales son:

Cuartos, norte, sur, cuartos al cuadrado y cuartos al cubo.

Los errores deben estar acomodados cronológicamente, es importante recalcar que en este ejemplo no se cumple esta condición, por lo que la prueba de Durbin y Watson no debería realizarse, sólo se hace para ejemplificar el uso de dicha prueba. Si se desea ver un ejemplo al cual sí se le puede aplicar hay uno en el anexo 2.1 “Regresión lineal simple” de este capítulo.

Con los errores arreglados cronológicamente y al seguir la fórmula se tiene que:

Tabla 2-114 Datos

Ln_renta		Error			
Y	Y	ε_t	ε_{t-1}	$(\varepsilon_t - \varepsilon_{t-1})^2$	ε_t^2
9.048	9.017	0.031	—	—	0.001
9.094	8.998	0.096	0.031	0.004	0.009
9.547	9.523	0.024	0.096	0.005	0.001

(continúa)

Tabla 2-114 Datos (continuación)

Ln_renta		Error			
Y	Y	ε_t	ε_{t-1}	$(\varepsilon_t - \varepsilon_{t-1})^2$	ε_t^2
8.517	8.387	0.130	0.024	0.011	0.017
9.306	9.432	-0.126	0.130	0.066	0.016
8.987	8.907	0.081	-0.126	0.043	0.006
9.048	9.017	0.031	0.081	0.002	0.001
9.393	9.432	-0.039	0.031	0.005	0.002
8.269	8.387	-0.119	-0.039	0.006	0.014
9.393	9.432	-0.039	-0.119	0.006	0.002
8.923	8.994	-0.071	-0.039	0.001	0.005
9.071	8.994	0.077	-0.071	0.022	0.006
8.987	8.994	-0.007	0.077	0.007	0.000
8.243	8.387	-0.145	-0.007	0.019	0.021
8.854	8.998	-0.144	-0.145	0.000	0.021
9.105	9.104	0.001	-0.144	0.021	0.000
8.412	8.387	0.025	0.001	0.001	0.001
8.476	8.497	-0.021	0.025	0.002	0.000
8.975	9.017	-0.042	-0.021	0.000	0.002
8.517	8.387	0.130	-0.042	0.030	0.017
9.510	9.432	0.079	0.130	0.003	0.006
9.510	9.432	0.079	0.079	0.000	0.006
8.854	8.907	-0.053	0.079	0.017	0.003
9.547	9.523	0.024	-0.053	0.006	0.001
Suma =				0.278	0.156

Al sustituir los valores en la fórmula:

$$DW_C = \frac{\sum_{t=2}^n (\varepsilon_t - \varepsilon_{t-1})^2}{\sum_{t=1}^n (\varepsilon_t)^2} = \frac{0.278}{0.156} = 1.776$$

Un valor cercano a 2 indicaría que no existe autocorrelación y es lo deseable. Los resultados que el SPSS™ reporta para este estadístico se muestran a continuación:

Tabla 2-115 Estadístico Durbin-Watson

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.979 ^a	.959	.947	.09318	1.776

^a Variables predictoras: (constante), cuartos3, norte, sur, cuartos, cuartos2.


^b Variable dependiente: Ln_renta.

Ahora sigue encontrar el estadístico teórico, es necesario recordar que los análisis de este ejemplo se están realizando con 95% de confianza; el estadístico teórico sería:

$$DW_{t,\alpha=0.05,n=24,K=5}$$

Donde n es el número de errores (24) y K el número de variables independientes (5). Se busca el valor en la tabla de Durbin-Watson, la cual se encuentra en el anexo 2.5 “Tabla Durbin-Watson”:

Tabla 2-116 Tabla Durbin-Watson



<i>n</i>	α	<i>K</i> =1		<i>K</i> =2		<i>K</i> =3		<i>K</i> =4		<i>K</i> =5		<i>K</i> =6		<i>K</i> =7		<i>K</i> =8		<i>K</i> =9	
		<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U	<i>d</i> _L	<i>d</i> _U
22	0.05	1.239	1.429	1.147	1.541	1.053	1.664	0.958	1.797	0.863	1.940	0.769	2.090	0.677	2.246	0.588	2.407	0.504	2.571
	0.01	0.997	1.174	0.914	1.284	0.831	1.407	0.748	1.543	0.667	1.691	0.587	1.849	0.510	2.015	0.437	2.188	0.368	2.367
23	0.05	1.257	1.437	1.168	1.543	1.078	1.660	0.986	1.785	0.895	1.920	0.804	2.061	0.715	2.208	0.628	2.360	0.545	2.514
	0.01	1.018	1.187	0.938	1.291	0.858	1.407	0.777	1.534	0.698	1.673	0.620	1.821	0.545	1.977	0.473	2.140	0.404	2.308
24	0.05	1.273	1.446	1.188	1.546	1.101	1.656	1.013	1.775	0.925	1.902	0.837	2.035	0.751	2.174	0.666	2.318	0.584	2.464
	0.01	1.037	1.199	0.960	1.298	0.882	1.407	0.805	1.528	0.728	1.658	0.652	1.797	0.578	1.944	0.507	2.097	0.439	2.255
25	0.05	1.288	1.454	1.206	1.550	1.123	1.654	1.038	1.767	0.953	1.886	0.868	2.012	0.784	2.144	0.702	2.280	0.621	2.419
	0.01	1.055	1.211	0.981	1.305	0.906	1.409	0.831	1.523	0.756	1.645	0.682	1.766	0.610	1.915	0.540	2.059	0.473	2.209
26	0.05	1.302	1.461	1.224	1.553	1.143	1.652	1.062	1.759	0.979	1.873	0.897	1.992	0.816	2.117	0.735	2.246	0.657	2.379
	0.01	1.072	1.222	1.001	1.312	0.928	1.411	0.855	1.518	0.783	1.635	0.711	1.759	0.640	1.889	0.575	2.026	0.505	2.168
27	0.05	1.316	1.469	1.240	1.556	1.162	1.651	1.084	1.753	1.004	1.861	0.925	1.974	0.845	2.093	0.767	2.216	0.691	2.342
	0.01	1.089	1.233	1.019	1.319	0.949	1.413	0.878	1.515	0.808	1.626	0.738	1.743	0.669	1.867	0.602	1.997	0.536	2.131

El valor más pequeño encontrado sería:

$$DW_{Lower, t, a=0.05, n=24, K=5} = 0.925$$

El valor más grande encontrado es:

$$DW_{Upper, t, a=0.05, n=24, K=5} = 1.902$$

Como los valores del estadístico sólo pueden encontrarse en el rango de 0 a 4, dichos valores se le restan a 4 que es el valor máximo que la distribución podría tener, lo que da como resultado para el primer valor $4 - 0.925 = 3.075$ y para el segundo $4 - 1.902 = 2.098$.

Los valores encontrados se acomodan en la distribución y se comparan con el valor del estadístico de prueba con las fronteras, esto se vería de la siguiente manera:




Figura 2-24 Zonas del estadístico Durbin-Watson.

Las hipótesis fueron las siguientes:

H_0 , los errores de primer orden son independientes, aleatorios, o no correlacionados; es decir, la correlación entre el error en el tiempo t es independiente del error en el tiempo $t - 1$, lo cual se representa de la siguiente manera $\text{Corr}(\varepsilon_t - \varepsilon_{t-1}) = 0$.

H_1 , los errores de primer orden no son independientes, no aleatorios, o correlacionados; es decir la correlación entre el error en el tiempo t es dependiente del error en el tiempo $t - 1$, lo cual se representa de la siguiente manera $\text{Corr}(\varepsilon_t - \varepsilon_{t-1}) \neq 0$.

Como el estadístico calculado cae en la zona de indecisión se concluye¹⁰⁸ que no se tiene evidencia estadística para aceptar o rechazar la hipótesis nula; hay indecisión en cuanto a la autocorrelación de primer orden en los errores, esto es, no se sabe si están o no autocorrelacionados en el primer rezago del tiempo.

Si los datos estuvieran acomodados cronológicamente o fueran de corte longitudinal y si se hubiera encontrado autocorrelación de primer orden, se recomendaría buscar un modelo autorregresivo de primer tiempo.

Un modelo autorregresivo sería construido con la variable dependiente rezagada en un periodo como una variable independiente; es decir, la misma variable dependiente estaría impactando el pasado sobre el presente, esto sería de la siguiente manera:

$$Y_t = f(C_t, N_t, S_t, C_t^2, C_t^3, Y_{t-1})$$

Pero éste no es el caso, como ya se indicó, la prueba Durbin-Watson no se debió realizar.

2.9.3 Prueba de Bartlett

Esta prueba se realiza para saber si algunas variables se encuentran correlacionadas o no, para localizar el estadístico es necesario calcular correlaciones bivariadas entre cada par de variables y formar una matriz con todas las correlaciones; el estadístico de prueba sería:

¹⁰⁸ Es importante recordar que este procedimiento no se debió realizar ya que los datos originales no pueden arreglarse cronológicamente.

Ecuación 2-36 Estadístico de la prueba de Bartlett

$$X_c^2 = - \left[n - 1 - \frac{1}{6}(2K + 5) \right] \text{Ln}|R| \approx$$

Donde:

U : es el estadístico de prueba, el cual se puede aproximar a una χ^2 (ji cuadrada) con $\frac{1}{2}K(K-1)$ grados de libertad.

n : es el número de datos u observaciones en las variables.

K : es el número de variables.

$\text{Ln}|R|$: es el logaritmo natural del determinante de la matriz de correlación.

Las hipótesis para esta prueba serían:

$H_0 : R = I$, los diferentes subvectores de los errores no están correlacionados, ya que las correlaciones entre los subvectores son cero (lo que implica que la matriz de correlación sea una matriz identidad; al no estar correlacionados son independientes y se cumple este supuesto).

$H_a : R \neq I$, los diferentes subvectores de los errores están correlacionados, ya que las correlaciones entre los subvectores no son cero (lo que implica que la matriz de correlación no es una matriz identidad; al estar correlacionados son dependientes, por lo que no se cumple el supuesto de independencia).

Si se pueden subdividir los residuales en dos o más subvectores (o submuestras), entonces es posible realizar esta prueba. En el ejemplo hay 24 datos y este valor es divisible entre 3 o 4, se decidió dividir en 3 subvectores, los cuales se muestran a continuación:

Tabla 2-117 Tres subvectores de los residuales

ϵ_1	ϵ_2	ϵ_3
0.130	-0.071	0.001
-0.119	0.077	-0.126
-0.145	-0.007	-0.039
0.025	0.096	-0.039
0.130	-0.144	0.079
-0.021	0.031	0.079
0.081	0.031	0.024
-0.053	-0.042	0.024

Ahora se deben encontrar las correlaciones entre los 3 subvectores, para esto es necesario calcular las varianzas y covarianzas y para hacerlo se necesita encontrar el cuadrado de cada uno de los subvectores, esto se muestra a continuación:

Tabla 2-118 Sumas de cuadrados

i	ϵ_1	ϵ_1^2	ϵ_2	ϵ_2^2	ϵ_3	ϵ_3^2
1	0.130	0.0169	-0.071	0.00508	0.001	0.000001
2	-0.119	0.0141	0.077	0.00595	-0.126	0.015945
3	-0.145	0.0209	-0.007	0.00005	-0.039	0.001542

(continúa)

Tabla 2-118 Sumas de cuadrados (continuación)

i	ε_1	ε_1^2	ε_2	ε_2^2	ε_3	ε_3^2
4	0.025	0.0006	0.096	0.00925	-0.039	0.001542
5	0.130	0.0169	-0.144	0.02072	0.079	0.006165
6	-0.021	0.0004	0.031	0.00097	0.079	0.006165
7	0.081	0.0065	0.031	0.00097	0.024	0.000570
8	-0.053	0.0028	-0.042	0.00177	0.024	0.000570
	0.0276	0.0790	-0.0286	0.0448	0.0009	0.0325
	$\Sigma \varepsilon_1$	$\Sigma \varepsilon_1^2$	$\Sigma \varepsilon_2$	$\Sigma \varepsilon_2^2$	$\Sigma \varepsilon_3$	$\Sigma \varepsilon_3^2$
	0.0035		-0.0036		0.0001	
	ε_1		ε_2		ε_3	

Ahora se deberán calcular los productos cruzados entre los subvectores, lo cual se muestra en la siguiente tabla:

Tabla 2-119 Productos cruzados

ε_1	ε_2	ε_3	$\varepsilon_1 * \varepsilon_2$	$\varepsilon_1 * \varepsilon_3$	$\varepsilon_2 * \varepsilon_3$
0.130	-0.071	0.001	-0.0093	0.0001	-0.0001
-0.119	0.077	-0.126	-0.0091	0.0150	-0.0097
-0.145	-0.007	-0.039	0.0010	0.0057	0.0003
0.025	0.096	-0.039	0.0024	-0.0010	-0.0038
0.130	-0.144	0.079	-0.0187	0.0102	-0.0113
-0.021	0.031	0.079	-0.0007	-0.0017	0.0024
0.081	0.031	0.024	0.0025	0.0019	0.0007
-0.053	-0.042	0.024	0.0022	-0.0013	-0.0010
			-0.0297	0.0290	-0.0224
			$\Sigma \varepsilon_1 * \varepsilon_2$	$\Sigma \varepsilon_1 * \varepsilon_3$	$\Sigma \varepsilon_2 * \varepsilon_3$

Ahora es necesario encontrar las correlaciones entre cada par de subvectores; la fórmula de las correlaciones se muestra a continuación:

$$R_{\varepsilon_i, \varepsilon_j} = \frac{\sum_{i=1}^n \varepsilon_i \varepsilon_j - n \bar{\varepsilon}_i \bar{\varepsilon}_j}{\sqrt{\sum_{i=1}^n \varepsilon_i^2 - n \bar{\varepsilon}_i^2} \sqrt{\sum_{i=1}^n \varepsilon_j^2 - n \bar{\varepsilon}_j^2}}$$

Por ejemplo si se desea calcular la correlación entre ε_1 y ε_2 se tendría lo siguiente:

$$R_{\varepsilon_1, \varepsilon_2} = \frac{\sum_{i=1}^n \varepsilon_{1i} \varepsilon_{2i} - n \bar{\varepsilon}_1 \bar{\varepsilon}_2}{\sqrt{\sum_{i=1}^n \varepsilon_{1i}^2 - n \bar{\varepsilon}_1^2} \sqrt{\sum_{i=1}^n \varepsilon_{2i}^2 - n \bar{\varepsilon}_2^2}}$$

Al sustituir los valores encontrados se tiene que:

$$R_{\varepsilon_1, \varepsilon_2} = \frac{-0.0297 - 8(0.0035)(-0.0036)}{\sqrt{0.079 - 8(0.0035)^2} \sqrt{0.0448 - 8(-0.0036)^2}} = -0.498$$

De forma similar se encuentran las correlaciones entre todas las parejas que se puedan formar; la información de las correlaciones y la matriz de correlación se muestra en la siguiente tabla:

Tabla 2-120 Matriz de correlación entre los subvectores

	ε_1	ε_2	ε_3
ε_1	1	-0.498	0.573
ε_2	-0.498	1	-0.589
ε_3	0.572	-0.589	1

Es necesario encontrar el determinante en la matriz anterior, lo cual se muestra a continuación:

$$|R| = \begin{vmatrix} 1 & -0.498 & 0.573 \\ -0.498 & 1 & -0.589 \\ 0.573 & -0.589 & 1 \end{vmatrix}$$

Se agregan las dos primeras columnas:

$$|R| = \left(\begin{array}{ccc|cc} 1 & -0.498 & 0.573 & 1 & -0.498 \\ -0.498 & 1 & -0.589 & -0.498 & 1 \\ 0.572 & -0.589 & 1 & 0.573 & -0.589 \end{array} \right)$$

Para encontrar el determinante, primero se suman los productos de las diagonales de arriba por la izquierda y hacia la derecha, esto se muestra a continuación:

$$(1)(1)(1) + (-0.498)(-0.589)(0.573) + (0.573)(-0.498)(-0.589) = 1.336$$

Después se obtiene la suma del producto de las diagonales de derecha a izquierda, esto se muestra a continuación:

$$(-0.498)(-0.498)(1) + (1)(-0.589)(-0.589) + (0.573)(1)(0.573) = 0.923$$

El determinante sería el primer resultado menos el segundo:

$$|R| = 1.336 - 0.923 = 0.413$$

El valor se sustituye en el estadístico de prueba:

$$X_C^2 = - \left[n - 1 - \frac{1}{6}(2K + 5) \right] \ln |R| = - \left[8 - 1 - \frac{1}{6}(2 * 3 + 5) \right] \ln |0.413|$$


El resultado es:

$$X_C^2 = - \left[8 - 1 - \frac{1}{6}(2 * 3 + 5) \right] \ln |0.413| = 4.569$$

Posterior a esto se obtiene el estadístico teórico o de tablas; como el ejemplo se está realizando con 95% de confianza, el estadístico teórico debe ser el siguiente:

$$X_{t, \alpha, \frac{1}{2}K(K-1)}^2 = X_{t, \alpha = 0.05, \frac{1}{2}3(3-1)=3}^2$$

Dicho valor se encuentra en tablas, la forma de buscarlo se muestra a continuación:

Tabla 2-121 Ji cuadrada¹⁰⁹

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322

Entonces el estadístico teórico sería:

$$X^2_{t, \alpha=0.05, 3} = 7.815$$


Para rechazar la H_0 es necesario que:

$$X^2_C > X^2_t$$

Por lo que:

$$4.569 < 7.815 \text{ no se rechaza la } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en zona de rechazo:



No se rechaza H_0 . Se concluye que los diferentes subvectores de los residuales o errores no están correlacionados, así que el supuesto de independencia se cumple.

Esta prueba también podría realizarse para ver si las variables independientes se encuentran correlacionadas o no; es decir, para ver si existe multicolinealidad en el modelo.

2.10 Media cero

El supuesto de media cero se debe cumplir con el método de mínimos cuadrados ordinarios, si no es así es recomendable que se cambie de software o bien cuando no se cumple deberá realizarse una prueba de hipótesis de una media con la t-student.

¹⁰⁹ Para la tabla de la ji cuadrada ver anexo 3.1 "Tabla ji cuadrada".

El problema con este procedimiento es que ningún paquete lo arroja como resultado, ya que este supuesto, como se comentó con anterioridad, debe cumplirse. Supóngase que en este caso no se cumple y desea probarse; el procedimiento se muestra a continuación:

Establecer las hipótesis. En este caso se desea probar que el promedio de los errores (en la muestra son los residuales) es cero, por lo que las hipótesis quedarían de la siguiente manera:

$H_0 : \varepsilon = 0$, el promedio de los errores es cero.

$H_a : \varepsilon \neq 0$, la media de los errores no es cero.

El siguiente paso es obtener el estadístico de prueba o el estadístico calculado, el cual deberá ser:

$$t_c = \frac{\bar{r} - \bar{\varepsilon}}{\sqrt{\sigma^2}} = \frac{\bar{r} - 0}{\sqrt{MSE}} = \frac{\bar{r}}{S_E}$$

A continuación se obtiene el estadístico teórico o de tablas, el cual debe ser el siguiente:

$$t_{t, \left(\frac{\alpha}{2}\right), (n-p)}$$

Se compara el estadístico de prueba con el teórico; la regla de decisión para rechazar la hipótesis nula sería:

$$|t_c| > t_t$$

En este caso se desea no rechazar la hipótesis nula.

Lo primero que se debe hacer es encontrar el promedio de los residuales del ejemplo, lo que se muestra a continuación:

Tabla 2-122 Datos

ln (renta)		Error	
ln (Y)	ln ($\hat{Y}$)	ε_t	ε_t^2
9.048	9.017	0.031	0.001
9.094	8.998	0.096	0.009
9.547	9.523	0.024	0.001
8.517	8.387	0.130	0.017
9.306	9.432	-0.126	0.016
8.987	8.907	0.081	0.006
9.048	9.017	0.031	0.001
9.393	9.432	-0.039	0.002
8.269	8.387	-0.119	0.014
9.393	9.432	-0.039	0.002
8.923	8.994	-0.071	0.005
9.071	8.994	0.077	0.006
8.987	8.994	-0.007	0.000
8.243	8.387	-0.145	0.021
8.854	8.998	-0.144	0.021
9.105	9.104	0.001	0.000

(continúa)

Tabla 2-122 Datos (continuación)

ln (renta)		Error	
ln (Y)	ln ($\hat{Y}$)	ε_t	ε_t^2
8.412	8.387	0.025	0.001
8.476	8.497	-0.021	0.000
8.975	9.017	-0.042	0.002
8.517	8.387	0.130	0.017
9.510	9.432	0.079	0.006
9.510	9.432	0.079	0.006
8.854	8.907	-0.053	0.003
9.547	9.523	0.024	0.001
Suma =		8.882E - 14	0.156
Promedio =		3.701E - 5	

En el listado del SPSS™ los estadísticos de los residuales aparecen en la siguiente tabla:

Estadístico sobre los residuos ^a					
	Mínimo	Máximo	Media	Desviación típ.	N
Valor pronosticado	8.3873	9.5229	8.9827	.39734	24
Residuo bruto	-.14457	.12986	.00000	.08243	24
Valor pronosticado tip.	-1.498	1.360	.000	1.000	24
Residuo típ.	-1.551	1.394	.000	.885	24

^a Variable dependiente: ln_renta.

Las hipótesis de esta prueba o contraste son:

$H_0 : \varepsilon = 0$, el promedio de los errores es cero.

$H_a : \varepsilon \neq 0$, la media de los errores no es cero.

Debe obtenerse el estadístico de prueba o *estadístico calculado*, el cual deberá ser:

$$t_c = \frac{\bar{r}}{S_e} = \frac{3.701 \times 10^{-15}}{\sqrt{\frac{0.156}{24-6}}} = \frac{3.701 \times 10^{-15}}{0.093} = 3.971 \times 10^{-14}$$


Posterior a esto se debe buscar el estadístico teórico o de tablas; como el ejemplo se está haciendo con 95% de confianza, el estadístico teórico debe ser el siguiente:

$$t_{t, \left(\frac{\alpha}{2}\right)} = \left(\frac{0.05}{2}\right) = 0.025, (n-p) = (24-6) = 18$$


O bien:

$$t_{t, \alpha=0.05, (n-p)=(24-6)=18}$$

La forma de encontrar el estadístico teórico sería en la tabla respectiva; es decir, en la t-student; si se usa 0.05, entonces se busca por arriba, pero si se usa 0.025, sería por abajo; esto se muestra a continuación:

Tabla 2-123 Tabla t^{110} 

gl	0.0	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015	4.346
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965	4.286
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.174	3.579	3.883	4.187
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850	4.146
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Entonces el estadístico teórico sería:

$$t_{t,0.025,18} = 2.101$$


Ahora se deberá comparar el estadístico de prueba con el teórico; la regla de decisión para rechazar la hipótesis nula sería:

$$|t_C| > t_t$$

Por lo que al sustituir los valores se tiene que:

$$3.971 \times 10^{-14} < 2.101$$

O bien para rechazar la hipótesis nula, el estadístico de prueba debe caer en la zona de rechazo,



Como no se rechazó la H_0 , se concluye que el supuesto de que el promedio de los errores es cero es cierto.

2.11 Homoscedasticidad

El término **homoscedasticidad** se usa para indicar homogeneidad de varianzas o que las varianzas son constantes. El no cumplimiento de este supuesto puede ocasionar que los pronósticos puntuales y por intervalo sean menos precisos.

Homoscedasticidad. Indica homogeneidad de varianzas o que las varianzas son constantes.

¹¹⁰ Ver anexo 2.2 "Tabla t-student".

Existen varias formas de ver si la homoscedasticidad o *varianzas constantes* se cumple, en este caso se escogieron las siguientes:




Figura 2-25 Posibles formas de detectar la homoscedasticidad.

Heteroscedasticidad.
Es cuando las varianzas no son constantes.

El procedimiento más común es ver la gráfica de los residuales, cuando las varianzas no son constantes se dice que existe **heteroscedasticidad** y se pueden observar abanicos o rombos; por el contrario, si el supuesto de homoscedasticidad se cumple no se pueden ver dichos comportamientos, lo que se distinguiría en la gráfica es una forma aleatoria. La gráfica se obtiene al poner los datos pronosticados o los datos reales en el eje X y los errores en el eje Y.




En esta gráfica los errores pueden revelar qué problemas se tienen en el modelo, los comportamientos más comunes son: aleatorios, abanico o rombo, pero también podrían detectarse otros, por ejemplo la dependencia lineal o no lineal. Los problemas más comunes se visualizan en la siguiente tabla de gráficas:

Tabla 2-124 Posibles gráficas o patrones a presentar

	Varianzas no constantes se forma un abanico; en valores grandes para ambas variables existe mucha variabilidad
	Varianzas no constantes ya que se forma un abanico; en valores grandes los residuales presentan mucha variabilidad
	Varianzas no constantes ya que existe mucha variabilidad o dispersión en los valores centrales
	Dependencia lineal, es necesario agregar un término lineal con respecto a la renta misma, pero deberán estar arreglados cronológicamente

(continúa)

Tabla 2-124 Posibles gráficas o patrones a presentar (continuación)

	Dependencia no Lineal, es necesario agregar un término polinomial de segundo grado, ya que existe no linealidad
	Dependencia no lineal, es necesario agregar un término polinomial de grado más avanzado, ya que existe no linealidad
	Condición normal o ideal de los residuales aleatorios, ya que con esto el supuesto de homoscedasticidad u homogeneidad de varianzas se cumpliría

Para la gráfica de los residuales es necesario tener estos valores y los pronósticos, los cuales se muestran en la siguiente tabla:

Tabla 2-125 Residuales y pronósticos


Pronósticos	Error
$\ln (\hat{Y})$	ε_t
9.017	0.031
8.998	0.096
9.523	0.024
8.387	0.130
9.432	-0.126
8.907	0.081
9.017	0.031
9.432	-0.039
8.387	-0.119
9.432	-0.039
8.994	-0.071
8.994	0.077
8.994	-0.007
8.387	-0.145
8.998	-0.144
9.104	0.001

(continúa)

Tabla 2-125 Residuales y pronósticos (*continuación*)


Pronósticos	Error
$\ln(\hat{Y})$	ε_t
8.387	0.025
8.497	-0.021
9.017	-0.042
8.387	0.130
9.432	0.079
9.432	0.079
8.907	-0.053
9.523	0.024

La gráfica de esta información se muestra a continuación; recuerde siempre que los residuales van en el eje de las ordenadas y los pronósticos en el eje de las abscisas:




Gráfica 2-34 Residuales y pronósticos.

En el SPSS™ los resultados aparecen en el gráfico de dispersión, pero los errores o residuales y los pronósticos se encuentran estandarizados o tipificados, dicha gráfica se muestra a continuación:



Gráfica 2-35 Dispersión de los errores.

¿Qué se debe hacer para localizar algún rombo o abanico? Es recomendable trazar líneas que unan los puntos que se encuentran fuera o extremos para encontrar alguna figura, por ejemplo:



Gráfica 2-36 Dispersión de los errores.

Es necesario comentar que cuando son muy pocos datos; es decir, para n pequeña, el gráfico de los residuales suele ser confuso para determinar si hay o no homoscedasticidad. Hay pruebas más potentes, por ejemplo la de Levene o la de M de Box transformada a la F.

Como se puede observar en el ejemplo no existen abanicos o rombos.

2.11.1 Prueba de Levene

En el año de 1960 Howard Levene realizó la contribución a la estadística con esta prueba, en honor a Harold Hotelling; ésta no es sensible al cumplimiento de la normalidad como muchos de los contrastes que existen, por eso es una de las más utilizadas. Para poder usar la prueba es necesario tener dos o más grupos en la variable a probar. Existen variantes de la prueba de Levene y su diferencia se debe a en qué se basan para obtener el estadístico de prueba. Se pueden utilizar:

1. El promedio o la media es muy sensible a los valores atípicos.
2. La mediana es la más recomendada, si existen valores atípicos.
3. La mediana con los grados de libertad corregidos.
4. La media recortada se utiliza cuando existen valores atípicos recortando un porcentaje de los datos más chicos y más grandes.

La fórmula para la primera variante sería:

Ecuación 2-37 Estadístico de prueba de Levene

$$F_C = \frac{\frac{SS_{\text{Inter}}}{(g-1)}}{\frac{SS_{\text{Intra}}}{\sum_{j=1}^g (n_j - 1)}} = \frac{\frac{\sum_{i=1}^n \sum_{j=1}^g (D_{i,j} - \bar{D}_j)^2}{(g-1)}}{\frac{\sum_{j=1}^g n_j (\bar{D}_j - \bar{D}_T)^2}{\sum_{j=1}^g (n_j - 1)}}$$

Donde:

SS_{Inter} : es la suma de cuadrados intergrupos o bien entre los grupos.

SS_{Intra} : es la suma de cuadrados intragrupos; es decir, dentro de los grupos.

g : es el número de grupos.

n_j : es el tamaño o los datos que tiene cada uno de los grupos.

D_{ij} : es la diferencia de la observación i en el grupo j .

$\bar{D}_j$: es el promedio del grupo j .

$\bar{D}_T$: es el promedio de todos los datos o la media total.

Si se desea encontrar el estadístico Levene para la mediana en lugar del promedio se utiliza la mediana. Ahora bien la diferencia D_{ij} se calcula de la siguiente manera:

Ecuación 2-38 Diferencia de cada uno de los grupos

$$D_{i,j} = |\varepsilon_{i,j} - \bar{\varepsilon}_j|$$

Donde:

D_{ij} : es la diferencia de la observación i en el grupo j .

$\varepsilon_{i,j}$: es la observación i del grupo j .

$\bar{\varepsilon}_j$: es el promedio del grupo j .

El promedio de los grupos sería:

Ecuación 2-39 Promedio de los grupos

$$\bar{D}_j = \sum_{i=1}^{n_j} \frac{D_{i,j}}{n_j}$$

La media total se calcularía de la siguiente manera:

Ecuación 2-40 Promedio total

$$\bar{D}_T = \frac{\sum_{i=1}^n \sum_{j=1}^g D_{i,j}}{n}$$

Donde n es el número total de datos al cual se le está aplicando la prueba.

Las hipótesis de esta prueba serían:

$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_g^2$, las varianzas son iguales o constantes, por lo que el supuesto de homoscedasticidad se cumple.

$H_a: \sigma_1^2 \neq \sigma_2^2 \neq \dots \neq \sigma_g^2$, las varianzas no son iguales o constantes, por lo que el supuesto de homoscedasticidad no se cumple, lo que implica que existe heteroscedasticidad.

El procedimiento sería el siguiente:

1. Acomodar los residuales en grupos de igual o diferente tamaño, a los que se les denomina g .
2. Separar los datos por grupos.
3. Encontrar las diferencias de cada uno de los grupos con respecto al promedio de cada grupo, es decir

$$D_{i,j} = |\varepsilon_{i,j} - \bar{\varepsilon}_j|$$

4. Calcular el promedio de las diferencias de cada grupo, lo cual sería

$$\bar{D}_j = \sum_{i=1}^{n_j} \frac{D_{i,j}}{n_j}$$

5. Hallar el promedio de los promedios o bien el promedio de todas las diferencias, esto sería por medio de

$$\bar{D}_T = \frac{\sum_{i=1}^n \sum_{j=1}^g D_{i,j}}{n}$$

6. Evaluar la suma de cuadrados intragrupos o dentro de los grupos

$$(SS_{\text{Intra}}).$$

7. Calcular la suma de cuadrados intergrupos o entre los grupos

$$(SS_{\text{Inter}}).$$

8. Encontrar los grados de libertad, los cuales son dos, el del numerador sería $(g - 1)$ y el del denominador es

$$\sum_{j=1}^g (n_j - 1):$$


9. Hallar los cuadrados medios, que se obtienen al dividir las sumas de los cuadrados entre los grados de libertad.

10. Calcular el estadístico de prueba F_C .

11. Encontrar el estadístico teórico F_t .


12. Comparar: si $F_C > F_t$ se rechaza la hipótesis nula, por lo que el supuesto de homoscedasticidad no se cumple.

Para mostrar el procedimiento de la prueba de Leven se volverá al ejemplo. Lo primero que se recomienda es que se grafiquen los residuales,¹¹¹ dicha gráfica se muestra a continuación:



Gráfica 2-37 Dispersión de los errores.

Podría dividirse en 3 regiones o grupos, los cuales se muestran a continuación:



Gráfica 2-38 Grupos de los errores.

¹¹¹ Es importante recordar que la gráfica que se recomienda es errores *versus* los pronósticos y que los errores siempre se deben poner en el eje de las ordenadas.

Eso significa que se tienen 3 grupos, lo cual sería $g = 3$. Por lo que las hipótesis de esta prueba quedarían de la siguiente manera:

$H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2$, las varianzas son iguales o constantes, así que el supuesto de homoscedasticidad se cumple.

$H_a: \sigma_1^2 \neq \sigma_2^2 \neq \sigma_3^2$, las varianzas no son iguales o constantes, por lo que el supuesto de homoscedasticidad no se cumple, lo que implica que existe heteroscedasticidad.

Los 3 subvectores o grupos, junto con sus promedios, se muestran a continuación:

Tabla 2-126 Tabla de los subvectores

ε_1	ε_2	ε_3
0.130	0.081	-0.126
-0.119	-0.053	-0.039
-0.145	-0.071	-0.039
0.025	0.077	0.079
0.130	-0.007	0.079
-0.021	0.096	0.024
	-0.144	0.024
	0.031	
	0.031	
	-0.042	
	0.001	
-1.770E - 136	3.682E - 14	1.066E - 13
$\bar{\varepsilon}_1$	$\bar{\varepsilon}_2$	$\bar{\varepsilon}_3$

Ahora se encuentra la diferencia del primer grupo; al usar la primera observación se tendría lo siguiente:

$$D_{1,1} = |\varepsilon_{1,1} - \bar{\varepsilon}_1| = |0.130 - (-1.77 \times 10^{-13})| = 0.1299$$

El proceso continúa para cada observación del primer grupo, los resultados de lo anterior y de las demás observaciones del grupo 1 se muestran en la siguiente tabla a la cual se le agregó el promedio y la suma de las diferencias:

Tabla 2-127 Diferencias del grupo 1

i	ε_1	$\varepsilon_{i,1} - \bar{\varepsilon}_1$	$ \varepsilon_{i,1} - \bar{\varepsilon}_1 = D_{i,1}$
1	0.130	0.1299	0.1299
2	-0.119	-0.1186	0.1186
3	-0.145	-0.1446	0.1446
4	0.025	0.0245	0.0245
5	0.130	0.1299	0.1299
6	-0.021	-0.0211	0.0211
	-1.062E - 12		0.568
	$\Sigma \varepsilon_1$		$\Sigma \varepsilon_{i,1} - \bar{\varepsilon}_1 $
	-1.770E - 13		0.0947
	$\bar{\varepsilon}_1$		$\bar{D}_1$

Se realiza lo mismo con el segundo vector y se encuentran las diferencias del segundo grupo; al usar la primera observación se tendría lo siguiente:

$$D_{1,2} = |\varepsilon_{1,2} - \bar{\varepsilon}_2| = |0.081 - 3.682 \times 10^{-14}| = 0.0806$$

Los resultados de todas las operaciones del grupo 2 se muestran en la siguiente tabla a la cual se le agregó el promedio y la suma de las diferencias:

Tabla 2-128 Diferencias del grupo 2

i	ε_2	$\varepsilon_{i,2} - \bar{\varepsilon}_2$	$ \varepsilon_{i,2} - \bar{\varepsilon}_2 = D_{i,2}$
1	0.081	0.0806	0.0806
2	-0.053	-0.0529	0.0529
3	-0.071	-0.0713	0.0713
4	0.077	0.0771	0.0771
5	-0.007	-0.0068	0.0068
6	0.096	0.0962	0.0962
7	-0.144	-0.1440	0.1440
8	0.031	0.0311	0.0311
9	0.031	0.0311	0.0311
10	-0.042	-0.0421	0.0421
11	0.001	0.0009	0.0009
4.050E - 13 $\Sigma \varepsilon_2$			0.634 $\Sigma \varepsilon_{i,2} - \bar{\varepsilon}_2 $
3.682E - 14 $\bar{\varepsilon}_2$			0.0576 $\bar{D}_2$

Por último se realiza lo mismo con el tercer vector para encontrar las diferencias del tercer grupo; al usar la primera observación se tendría lo siguiente:

$$D_{1,3} = |\varepsilon_{1,3} - \bar{\varepsilon}_3| = |-0.126 - 1.066 \times 10^{-13}| = 0.1263$$

Los resultados de todas las operaciones del grupo 3 se muestran en la siguiente tabla a la cual se le agregó el promedio y la suma de las diferencias:

Tabla 2-129 Diferencias del grupo 3

i	ε_3	$\varepsilon_{i,3} - \bar{\varepsilon}_3$	$ \varepsilon_{i,3} - \bar{\varepsilon}_3 = D_{i,3}$
1	-0.126	-0.1263	0.1263
2	-0.039	-0.0393	0.0393
3	-0.039	-0.0393	0.0393
4	0.079	0.0785	0.0785
5	0.079	0.0785	0.0785
6	0.024	0.0239	0.0239
7	0.024	0.0239	0.0239
7.461E - 13 $\Sigma \varepsilon_3$			0.410 $\Sigma \varepsilon_{i,3} - \bar{\varepsilon}_3 $
1.066E - 13 $\bar{\varepsilon}_3$			0.0585 $\bar{D}_3$

El paso 4 indica que se debe obtener el promedio de las diferencias de los grupos, el cual fue previamente definido por:

$$\bar{D}_j = \sum_{i=1}^g \frac{\sum_{j=1}^{n_j} D_{i,j}}{n_j}$$

Esto indica que sería un promedio ponderado, ya que se tienen diferentes números de datos en cada uno de los grupos (también se puede buscar el promedio de cada uno de los grupos y sumarlos). Los datos encontrados arrojaron que: el primer grupo tiene 6 observaciones y la suma de sus diferencias es 0.568, el segundo grupo suma 11 datos y la suma de las diferencias es 0.634, el tercer grupo presenta 7 datos y la suma de las diferencias es 0.410, por lo que el promedio se calcularía de la siguiente manera:

$$\bar{D}_j = \sum_{j=1}^g \frac{\sum_{i=1}^{n_j} D_{i,j}}{n_j} = \frac{0.568}{6} + \frac{0.634}{11} + \frac{0.410}{7} = 0.211$$

O bien el promedio del primer grupo es 0.0947, la media del segundo es 0.0576 y el promedio del tercer grupo es 0.0585, por lo que el promedio sería:

$$\bar{D}_j = \sum_{j=1}^g \frac{\sum_{i=1}^{n_j} D_{i,j}}{n_j} = 0.0947 + 0.0576 + 0.0585 = 0.211$$

En el paso 5 se tiene que calcular el promedio de todas las diferencias, dicho promedio fue definido de la siguiente manera:

$$\bar{D}_j = \frac{\sum_{i=1}^n \sum_{j=1}^g D_{i,j}}{n}$$

Ya que en el primer grupo se tienen 6 observaciones y la suma de las diferencias es 0.568; el segundo grupo suma 11 datos y la suma de las diferencias es 0.634 y el tercer grupo cuenta con 7 datos y la suma de las diferencias es 0.410, el promedio se calcularía de la siguiente manera:

$$\bar{D}_T = \frac{\sum_{i=1}^n \sum_{j=1}^g D_{i,j}}{n} = \frac{0.568 + 0.634 + 0.410}{6 + 11 + 7} = 0.067$$

En los pasos 6 y 7 se buscan las sumas de los cuadrados; el proceso sería el siguiente para la diferencia dentro de los grupos; es decir, la SS_{Intra} , la cual fue definida por medio de:

$$SS_{\text{Intra}} = \sum_{i=1}^n \sum_{j=1}^g (D_{i,j} - \bar{D}_j)^2$$

Se tiene para el grupo 1, que la primera diferencia fue de 0.1299 y el promedio de las diferencias de este grupo fue de 0.0947, la siguiente diferencia sería... hasta la última, la cual fue de 0.0211, entonces la suma de cuadrados para el primer grupo sería:

$$(0.1299 - 0.0947)^2 + \dots + (0.0211 - 0.0947)^2 = 0.0159$$

El resumen de la suma de cuadrados del grupo 1 se muestra en la siguiente tabla:

Tabla 2-130 Suma de cuadrados del grupo 1

i	ε_1	$\varepsilon_{i,1} - \bar{\varepsilon}_1$	$ \varepsilon_{i,1} - \bar{\varepsilon}_1 = D_{i,1}$	$(D_{i,1} - \bar{D}_1)^2$
1	0.130	0.1299	0.1299	0.0012
2	-0.119	-0.1186	0.1186	0.0006
3	-0.145	-0.1446	0.1446	0.0025

(continúa)

Tabla 2-130 Suma de cuadrados del grupo 1 (*continuación*)

i	ε_1	$\varepsilon_{i1} - \bar{\varepsilon}_1$	$ \varepsilon_{i1} - \bar{\varepsilon}_1 = D_{i1}$	$(D_{i1} - \bar{D}_1)^2$
4	0.025	0.0245	0.0245	0.0049
5	0.130	0.1299	0.1299	0.0012
6	-0.021	-0.0211	0.0211	0.0054
	-1.062E - 12 $\Sigma \varepsilon_1$		0.568 $\Sigma \varepsilon_{i1} - \bar{\varepsilon}_1 $	0.0159 $\Sigma (D_{i1} - \bar{D}_1)^2$
	-1.770E - 13 $\bar{\varepsilon}_1$		0.0947 $\bar{D}_1$	

Ahora sería para el grupo 2, ya que la primera diferencia fue de 0.0806 y el promedio de las diferencias fue de 0.0576, la siguiente diferencia sería... hasta la última, la cual fue de 0.0009, entonces la suma de cuadrados sería:

$$(0.0806 - 0.0576)^2 + \dots + (0.0009 - 0.0576)^2 = 0.0175$$

El resumen de la suma de cuadrados del grupo 2 se muestra en la siguiente tabla:

Tabla 2-131 Suma de cuadrados del grupo 2

i	ε_2	$\varepsilon_{i2} - \bar{\varepsilon}_2$	$ \varepsilon_{i2} - \bar{\varepsilon}_2 = D_{i2}$	$(D_{i2} - \bar{D}_2)^2$
1	0.081	0.0806	0.0806	0.0005
2	-0.053	-0.0529	0.0529	0.0000
3	-0.071	-0.0713	0.0713	0.0002
4	0.077	0.0771	0.0771	0.0004
5	-0.007	-0.0068	0.0068	0.0026
6	0.096	0.0962	0.0962	0.0015
7	-0.144	-0.1440	0.1440	0.0074
8	0.031	0.0311	0.0311	0.0007
9	0.031	0.0311	0.0311	0.0007
10	-0.042	-0.0421	0.0421	0.0002
11	0.001	0.0009	0.0009	0.0032
	4.050E - 13 $\Sigma \varepsilon_2$		0.634 $\Sigma \varepsilon_{i2} - \bar{\varepsilon}_2 $	0.0175 $\Sigma (D_{i2} - \bar{D}_2)^2$
	3.682E - 14 $\bar{\varepsilon}_2$		0.0576 $\bar{D}_2$	

Por último le corresponde al grupo 3, como la primera diferencia fue de 0.1263 y el promedio de las diferencias fue de 0.0585, la siguiente diferencia sería 0.0393 y así sucesivamente hasta la última, la cual fue de 0.0239, entonces la suma de cuadrados sería:

$$(0.1263 - 0.0585)^2 + \dots + (0.0239 - 0.0585)^2 = 0.0085$$

El resumen de la suma de cuadrados del grupo 3 se muestra en la siguiente tabla:

Tabla 2-132 Suma de cuadrados del grupo 3

i	ε_3	$\varepsilon_{i,3} - \bar{\varepsilon}_3$	$ \varepsilon_{i,3} - \bar{\varepsilon}_3 = D_{i,3}$	$(D_{i,1} - \bar{D}_3)^2$
1	-0.126	-0.1263	0.1263	0.0046
2	-0.039	-0.0393	0.0393	0.0004
3	-0.039	-0.0393	0.0393	0.0004
4	0.079	0.0785	0.0785	0.0004
5	0.079	0.0785	0.0785	0.0004
6	0.024	0.0239	0.0239	0.0012
7	0.024	0.0239	0.0239	0.0012
	7.461E - 13 $\Sigma \varepsilon_3$		0.410 $\Sigma \varepsilon_{i,3} - \bar{\varepsilon}_3 $	0.0085 $\Sigma (D_{i,1} - \bar{D}_3)^2$
	1.066E - 13 $\bar{\varepsilon}_3$		0.0585 $\bar{D}_3$	

Entonces finalmente se tiene que la suma de cuadrados intragrupos da como resultado:

$$SS_{Intra} = \sum_{i=1}^n \sum_{j=1}^g (D_{i,j} - \bar{D}_j)^2 = 0.0159 + 0.0175 + 0.0085 = 0.042$$

La suma de cuadrados entre los grupos o bien la SS_{Inter} se realiza de la siguiente manera:

$$SS_{Inter} = \sum_{j=1}^g n_j (\bar{D}_j - \bar{D}_T)^2 =$$

Recuerde que el promedio del primer grupo fue de 0.0947 con 6 observaciones, la media del segundo de 0.0576 con 11 datos y el promedio del tercero fue de 0.0585 con 7 observaciones; también se encontró que el promedio de las diferencias de todas las observaciones fue de 0.067; por lo que la suma de cuadrados sería

$$SS_{Inter} = \sum_{j=1}^g n_j (\bar{D}_j - \bar{D}_T)^2 =$$

Al sustituir la información en la fórmula se tiene que:

$$SS_{Inter} = 6 + (0.0947 + 0.067)^2 - 11 + (0.0576 - 0.067)^2 - 7 + (0.0585 - 0.067)^2 = 0.0061$$

El siguiente paso serían los grados de libertad. Se sabe que hay 3 grupos, entonces para el numerador sería:

$$(g - 1) = (3 - 1) = 2$$

Para el denominador se sabe que en el grupo 1 se tienen 6 datos, en el 2 hay 11 y en el 3 suman 7, entonces los grados de libertad quedarían de la siguiente manera:


$$\sum_{j=1}^g (n_j - 1) = (6 - 1) + (11 - 1) + (7 - 1) = 21$$

Al sustituir la información encontrada se tiene que:

$$F_C = \frac{\frac{\sum_{i=1}^n \sum_{j=1}^g (D_{i,j} - \bar{D}_j)^2}{(g - 1)}}{\frac{\sum_{j=1}^g n_j (\bar{D}_j - \bar{D}_T)^2}{\sum_{j=1}^g (n_j - 1)}} = \frac{\frac{0.0061}{2}}{\frac{0.042}{21}} = 1.524$$

El paso siguiente sería buscar el estadístico teórico o de tablas, como el estudio se está realizando con 95% de confianza y con los grados de libertad del numerador y del denominador, se tiene que:

Tabla 2-133 Tabla F¹¹²



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
20	0.100	2.975	2.589	2.380	2.249	2.158	2.091	2.040	1.999	1.965	1.937	1.892	1.845	1.794	1.767	1.738
	0.050	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447	2.393	2.348	2.278	2.203	2.124	2.082	2.039
	0.025	5.871	4.461	3.859	3.515	3.289	3.128	3.007	2.913	2.837	2.774	2.676	2.573	2.464	2.408	2.349
	0.010	8.096	5.849	4.938	4.431	4.103	3.871	3.699	3.564	3.457	3.368	3.231	3.088	2.938	2.859	2.778
	0.005	9.944	6.986	5.818	5.174	4.762	4.472	4.257	4.090	3.956	3.847	3.678	3.502	3.318	3.222	3.123
21	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	26.37	2.534	2.425	2.368	2.308
	0.010	8.017	5.780	4.874	4.369	4.042	3.812	3.640	3.506	3.398	3.310	3.173	3.030	2.880	2.801	2.720
	0.005	9.830	6.891	5.730	5.091	4.681	4.393	4.179	4.013	3.880	3.771	3.602	3.427	3.243	3.147	3.049
22	0.100	2.949	2.561	2.351	2.219	2.128	2.060	2.008	1.967	1.933	1.904	1.859	1.811	1.759	1.731	1.702
	0.050	4.301	3.443	3.049	2.817	2.661	2.549	2.464	2.397	2.342	2.297	2.226	2.151	2.071	2.028	1.984
	0.025	5.786	4.383	3.783	3.440	3.215	3.055	2.934	2.839	2.763	2.700	2.602	2.498	2.389	2.331	2.272
	0.010	7.945	5.719	4.817	4.313	3.988	3.758	3.587	3.453	3.346	3.258	3.121	2.978	2.827	2.749	2.667
	0.005	9.727	6.806	5.652	5.017	4.609	4.322	4.109	3.944	3.812	3.703	3.535	3.360	3.176	3.081	2.982

¹¹² Para la tabla F, ver anexo 2.3.

$$F_{t, \alpha=0.05, (g-1)=2, \sum_{j=1}^g (n_j-1)=21} = F_{t, \alpha=0.05221}$$

El valor se buscaría en la tabla F, como se muestra en la tabla 2-133 de la página anterior.

Lo anterior indica que:

$$F_{t, \alpha=0.05, 2, 21} = 3.467$$


Recuerde que para rechazar la hipótesis nula se sabe que:

$$F_C > F_t$$

Al comparar los valores se tiene que:

$$1.524 < 3.467$$

Por lo que no se rechaza la hipótesis nula. Para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Se concluye que hay evidencia estadística para no rechazar la H_0 con esto se puede indicar que los errores o residuales tienen varianzas homogéneas o el supuesto de homoscedasticidad se cumple.

Los resultados que el SPSS™ da sobre dicha prueba se muestran a continuación:¹¹³

Tabla 2-134 Prueba de homogeneidad de varianzas¹¹⁴

Prueba de homogeneidad de la varianza					
		Estadístico de Levene	gl1	gl2	Sig.
Error	Basándose en la media	1.524	2	21	.241
	Basándose en la mediana.	1.415	2	21	.265
	Basándose en la mediana y con gl corregido	1.415	2	19.761	.266
	Basándose en la media recortada	1.519	2	21	.242

Para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.241 > 0.05 \text{ no se rechaza } H_0$$

Se concluye entonces que hay evidencia estadística para no rechazar la H_0 por lo que se puede indicar que los errores o residuales tienen varianzas homogéneas o el supuesto de homoscedasticidad se cumple.

¹¹³ El procedimiento para el SPSS sería escoger el menú “analizar”, posteriormente seleccionar la opción “estadísticos descriptivos” y por último elegir la opción “explorar”. La variable a analizar en “lista de dependientes” debe ser los errores no estandarizados y en “lista de factores” se debe poner la nueva variable de grupos, mientras que en “gráficos” se deberá pedir “dispersión por niveles con prueba de Levene” y posterior a esto, escoger “estimación de potencia”.

¹¹⁴ La fórmula a utilizar, sería el estadístico “basando en la media”, el estadístico de “la mediana” se usaría si en lugar de calcular el promedio se calculó la mediana, al igual que el “corregido” el cual tiene de diferencia con la mediana que los grados de libertad son ajustados y el estadístico en la media recortada quita un porcentaje de datos de cada uno de los extremos, es decir quita los valores más pequeños y los más grandes; esto sería bueno si se cuenta con datos atípicos en las muestras.

2.11.2 Prueba M de Box transformada a una F

En 1949 G. E. P. Box propuso un estadístico denominado M de Box, el cual puede transformarse en una ji cuadrada o en una F; para realizar esta prueba es necesario tener al menos 2 grupos en la variable que se probará el supuesto de homoscedasticidad.

Si es posible subdividir los residuales en 2 o más subvectores o grupos, es posible realizar esta prueba; el estadístico de prueba se muestra a continuación:

Ecuación 2-41 Estadístico de prueba M de Box transformado a F

$$F_c = \frac{\frac{M \text{ de Box}}{f_1}}{\frac{(B - M \text{ de Box})}{f_2}}$$

Donde:

M de Box : es el estadístico M de Box, que se definirá más adelante.

f_1 : son los grados de libertad del numerador.

B : es la expresión matemática en la que se involucran los grados de libertad.

f_2 : son los grados de libertad del denominador.

Las hipótesis de esta prueba serían:

$H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2$, las varianzas son iguales o constantes, por lo que el supuesto de homoscedasticidad se cumple.


$H_a: \sigma_1^2 \neq \sigma_2^2 \neq \sigma_3^2$, las varianzas no son iguales o constantes, por lo que el supuesto de homoscedasticidad no se cumple, lo que implica que existe heteroscedasticidad.

El procedimiento sería el siguiente:

1. Acomodar los residuales en grupos ya sean de igual o diferente tamaño. A los grupos se les denomina g .
2. Separar los datos por grupos.
3. Encontrar la suma de cuadrados de cada uno de los grupos, esto es por medio de $W|_j = \sum_{i=1}^{n|j} \epsilon_{i,j}^2$; a dichos valores se les conoce como suma de cuadrados intergrupos o entre los grupos.
4. Calcular la varianza de cada uno de los grupos; es decir, para cada grupo encontrar $\bar{W}|_j = \frac{\sum_{i=1}^{n|j} \epsilon_{i,j}^2}{n_j - 1}$; al dividirlo entre los grados de libertad se obtiene la suma de cuadrados promediada o bien la varianza.
5. Hallar la suma de cuadrados sin la diferenciación de los grupos, lo cual sería $W_T = \sum_{j=1}^g W|_j$, también conocido como la suma de cuadrados intragrupos o dentro de los grupos.
6. Calcular la varianza de los datos sin diferenciarlos por grupo, lo cual se logra por medio de $\bar{W}_T = \frac{\sum_{j=1}^g W|_j}{n - g}$; al dividirlo entre los grados de libertad se obtiene la suma de cuadrados promediada o bien la varianza.
7. Encontrar el estadístico de prueba M de Box, para esto es necesario que a cada una de las varianzas se les calcule el determinante y a éste el logaritmo natural, luego encontrar el estadístico de prueba que se conoce como la *M de Box* $(n - g) \ln |W_T| - \sum_{j=1}^g (n|_j - 1) \ln |\bar{W}|_j$.
8. Obtener las expresiones matemáticas en las que se involucran los grados de libertad para convertirla a F. Dichas expresiones son: A_1, A_2, f_1, f_2 y B. La forma de buscarlas se verá más adelante.
9. Calcular el estadístico de prueba F_c .


10. Encontrar el estadístico teórico o de tablas F_t .
11. Comparar valores sabiendo que cuando $F_C > F_t$ se rechaza la hipótesis nula, por lo que el supuesto de homoscedasticidad no se cumple.

El primer paso es obtener los subvectores, los cuales se muestran en la gráfica de los residuales:



Gráfica 2-39 Dispersión de los errores.

Es posible dividir en 3 regiones, las cuales se muestran a continuación:



Gráfica 2-40 Dispersión de los errores.

Los 3 subvectores serían los siguientes:

Tabla 2-135 Tabla de los subvectores

ε_1	ε_2	ε_3
0.130	0.081	-0.126
-0.119	-0.053	-0.039
-0.145	-0.071	-0.039
0.025	0.077	0.079
0.130	-0.007	0.079
-0.021	0.096	0.024

(continúa)

Tabla 2-135 Tabla de los subvectores (*continuación*)

ε_1	ε_2	ε_3
	-0.144	0.024
	0.031	
	0.031	
	-0.042	
	0.001	
-1.770E - 13	3.682E - 14	1.066E - 13
$\bar{\varepsilon}_1$	$\bar{\varepsilon}_2$	$\bar{\varepsilon}_3$

Ahora se obtienen las varianzas de cada grupo, para esto es necesario conocer la suma de cuadrados de los residuales para cada uno de los grupos. El proceso para el grupo 1 se muestra a continuación:

$$W|_1 = \sum_{i=1}^{n|_1} \varepsilon_{i,1}^2 = (0.130)^2 + (-0.119)^2 + \dots + (-0.021)^2 = 0.070$$

Entonces la varianza sería:

$$\overline{W}|_1 = \frac{\sum_{i=1}^{n|_1} \varepsilon_{i,1}^2}{n|_1 - 1} = \frac{0.070}{6 - 1} = 0.014$$

Los resultados de esto se muestran en la siguiente tabla:

Tabla 2-136 Suma de cuadrados del grupo 1

i	ε_1	ε_1^2
1	0.130	0.0169
2	-0.119	0.0141
3	-0.145	0.0209
4	0.025	0.0006
5	0.130	0.0169
6	-0.021	0.0004
	-1.062E - 12	0.070
	$\Sigma \varepsilon_1$	$\Sigma \varepsilon_1^2$
	-1.770E - 13	
	$\bar{\varepsilon}_1$	

Para el grupo 2, la suma de cuadrados de los residuales se muestra a continuación:

$$W|_2 = \sum_{i=1}^{n|_2} \varepsilon_{i,2}^2 = (0.081)^2 + (-0.053)^2 + \dots + (0.001)^2 = 0.054$$

Y la varianza para el grupo 2 es:

$$\overline{W}|_2 = \frac{\sum_{i=1}^{n|_2} \varepsilon_{i,2}^2}{n|_2 - 1} = \frac{0.054}{11 - 1} = 0.005$$

Los resultados de esto se muestran en la siguiente tabla:

Tabla 2-137 Suma de cuadrados del grupo 2

i	ε_2	ε_2^2
1	0.081	0.00649
2	-0.053	0.00280
3	-0.071	0.00508
4	-0.077	0.00595
5	-0.007	0.00005
6	0.096	0.00925
7	-0.144	0.02072
8	0.031	0.00097
9	0.031	0.00097
10	-0.042	0.00177
11	0.001	0.000001
	4.050E - 13	0.054
	$\Sigma \varepsilon_2$	$\Sigma \varepsilon_2^2$
	3.682E - 14	
	$\bar{\varepsilon}_2$	

Por último para el grupo 3, la suma de cuadrados de los residuales se muestra a continuación:

$$W|_3 = \sum_{i=1}^{n|_3} \varepsilon_{i,3}^2 = (-0.126)^2 + (-0.039)^2 + \cdots + (0.024)^2 = 0.032$$

Y la varianza para el grupo 3 es:

$$\overline{W}|_3 = \frac{\sum_{i=1}^{n|_3} \varepsilon_{i,3}^2}{n|_3 - 1} = \frac{0.032}{7 - 1} = 0.005$$

Los resultados de esto se muestran en la siguiente tabla:

Tabla 2-138 Suma de cuadrados del grupo 3

i	ε_3	ε_3^2
1	-0.126	0.0159
2	-0.039	0.0015
3	-0.039	0.0015
4	0.079	0.0062
5	0.079	0.0062
6	0.024	0.0006
7	0.024	0.0006
	7.461E - 13	0.032
	$\Sigma \varepsilon_3$	$\Sigma \varepsilon_3^2$
	1.066E - 13	
	$\bar{\varepsilon}_3$	

Ahora se buscará la varianza dentro de los grupos de la siguiente forma:

$$W_T = W|_1 + W|_2 + W|_3 = 0.070 + 0.054 + 0.032 = 0.156$$

Y la varianza W_T es:

$$\overline{W}_T = \frac{\sum_{j=1}^g W|_j}{n - g} = \frac{0.156}{24 - 3} = 0.007$$

Sigue encontrar el estadístico de prueba M de Box, su fórmula es:

Ecuación 2-42 Estadístico de prueba M de Box.

$$M \text{ de Box} = (n - g) \ln |\overline{W}_T| - \sum_{j=1}^g (n|_j - 1) \ln |W|_j|$$

Donde:

M de Box : es el estadístico de prueba M de Box.

n : es el número de datos u observaciones de la variable que se está probando.

g : es el número de grupos que se tiene en la variable.

$\ln |\overline{W}_T|$: es el logaritmo natural del determinante de la varianza intragrupos o dentro de los grupos.

$n|_j$: es el número de observaciones en el grupo j .

$\ln |W|_j|$: es el logaritmo natural del determinante de la varianza intergrupos o dentro de los grupos.

Entonces a cada varianza se le encuentra el determinante y posteriormente el logaritmo natural del valor para cada uno de los determinantes, las operaciones fueron resumidas en la siguiente tabla:

Tabla 2-139 Determinante y logaritmo de las varianzas

	Grupo	Varianza	Determinante	Logaritmo natural
Intergrupos = W_i =	1	0.014	0.01395	-4.272
	2	0.005	0.00541	-5.220
	3	0.005	0.00542	-5.218
	Intragrupos = W_T =	0.007	0.00744	-4.901

Los resultados que el SPSS™ pone al respecto se muestran en la siguiente tabla:¹¹⁵

Tabla 2-140 Resultados de los logaritmos

Logaritmo de los determinantes		
Grupos	Rango	Logaritmo del determinante
Grupo 1	1	-4.272
Grupo 2	1	-5.220
Grupo 3	1	-5.218
Intragrupos combinada	1	-4.901
Los rangos y logaritmos naturales de los determinantes impresos son los de las matrices de covarianzas de los grupos.		

Ahora se buscará el estadístico de prueba M de Box, que sería el siguiente:

$$M \text{ de Box} = (24 - 3)(-4.901) - [(6 - 1)(-4.272) + (11 - 1)(-5.22) + (7 - 1)(-5.210)]$$

¹¹⁵ Para encontrar los valores se realizó un análisis discriminante usando a los errores como variable independiente y a los grupos como variable dependiente.

El resultado sería:

$$M \text{ de Box} = -102.911 - [-104.875] = 1.964$$

Los resultados que el SPSS™ pone al respecto se muestran en la siguiente tabla:¹¹⁶

Tabla 2-141 Estadístico de prueba M de Box

Resultados de la prueba		
M de Box		1.964
F	Aprox.	.918
	gl1	2
	gl2	820.041
	Sig.	.400
Contrasta la hipótesis nula de que las matrices de covarianzas poblacionales son iguales.		

Por carecer de distribución el estadístico M de Box debe transformarse en una ji cuadrada o en una F; el segundo caso requiere que se calculen varias expresiones matemáticas en las que se involucran los grados de libertad, las cuales son: A_1 , A_2 , f_1 , f_2 y B ; dichas expresiones dependen del número de variables y del número de grupos que se tienen.

En este caso se tienen 3 grupos y una sola variable, los residuales o errores;¹¹⁷ entonces:

El número de grupos es $g = 3$, los cuales fueron encontrados previamente.

El número de variables es $K = 1$, en este caso serían los residuales o errores.

Ahora si $K = 1$ entonces A_1 sería encontrada de la siguiente manera:

Ecuación 2-43 Expresión matemática en la que se involucran grados de libertad

$$A_1 = \left(\frac{1}{3(g-1)} \right) \left(\sum_{j=1}^g \frac{1}{n|_j - 1} - \frac{1}{n-g} \right)$$

Donde:

g : es el número de grupos que se tienen en la variable.

$n|_j$: es el número de datos que se tienen en el grupo j .

n : es el número de datos u observaciones de la variable que se está probando.

Recuerde que en el grupo 1 se tienen 6 datos, en el 2 hay 11 observaciones y el 3 cuenta con 7; además la variable cuenta con 24 datos y 3 grupos; entonces la forma de encontrar la expresión sería la siguiente:

$$A_1 = \left(\frac{1}{3(3-1)} \right) \left[\left(\frac{1}{6-1} + \frac{1}{11-1} + \frac{1}{7-1} \right) - \frac{1}{24-3} \right] = 0.0698$$

Ahora cuando $K = 1$ entonces $A_2 = 0$ por lo que no es necesario encontrar el valor.

Se sabe que si $K = 1$ entonces f_1 , que son los grados de libertad del numerador, sale del número de grupos menos 1, esto es:

Ecuación 2-44 Grados de libertad del numerador

$$f_1 = g - 1$$

¹¹⁶ Para encontrar los valores se realizó un análisis discriminante usando a los errores como variable independiente y a los grupos como variable dependiente.

¹¹⁷ Si se desea mayores informes para pruebas con mayor número de variables, esta prueba se muestra también en el capítulo de análisis discriminante.

Donde:

g : es el número de grupos que se tienen en la variable.

Entonces el valor sería el siguiente:

$$f_1 = g - 1 = 3 - 1 = 2$$

Como $K = 1$ entonces f_2 , que son los grados de libertad del denominador, lo cual se calcula de la siguiente manera:

Ecuación 2-45 Grados de libertad del denominador

$$f_2 = \frac{g + 1}{A_1^2}$$

Donde:

g : es el número de grupos que se tienen en la variable.

A_1 : es la expresión matemática en la que se involucran grados de libertad.

Por lo que:

$$f_2 = \frac{g + 1}{A_1^2} = \frac{3 + 1}{(0.0698)^2} = 820.04132$$

Por último cuando $K = 1$ entonces B se calcula de la siguiente manera:

Ecuación 2-46 Expresión matemática que involucra los grados de libertad y forma parte de la F

$$B = \frac{\frac{f_2}{1 - A_1 + 2}}{f_2}$$

Donde:

f_2 : son los grados de libertad del denominador.

A_1 : es la expresión matemática en la que se involucran los grados de libertad.

Entonces el valor sería el siguiente:

$$B = \frac{\frac{f_2}{1 - A_1 + 2}}{f_2} = \frac{\frac{820.04132}{1 - 0.0698 + 2}}{820.04132} = 879.30882$$

Viene ahora encontrar el valor del estadístico de prueba, el cual fue definido previamente y al sustituir los valores se tiene:


$$F_c = \frac{\frac{\overbrace{M de Box}^{f_1}}{(B - \overbrace{M de Box}^{f_2})}}{\frac{1.964}{820.04132}} = \frac{\frac{2}{(879.30882 - 1.964)}}{820.04132} = 0.918$$

El paso siguiente sería encontrar el estadístico teórico o de tablas, como el estudio se está realizando con 95% de confianza y con los grados de libertad del numerador y denominador, se tiene que:

$$F_{t,\alpha=0.05,2,820}$$

El valor se buscaría en la tabla F de la siguiente manera:

Tabla 2-142 Tabla F¹¹⁸



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
200	0.100	2.748	2.347	2.130	1.992	1.896	1.824	1.767	1.722	1.684	1.652	1.601	1.545	1.447	1.447	1.409
	0.050	3.920	3.072	2.680	2.447	2.290	2.175	2.087	2.016	1.959	1.910	1.834	1.750	1.659	1.608	1.554
	0.025	5.152	3.805	3.227	2.894	2.674	2.515	2.395	2.299	2.222	2.157	2.055	1.945	1.825	1.760	1.690
	0.010	6.851	4.787	3.949	3.480	3.174	2.956	2.792	2.663	2.559	2.472	2.336	2.192	2.035	1.950	1.860
	0.005	8.179	5.539	4.497	3.921	3.548	3.285	3.087	2.933	2.808	2.705	2.544	2.373	2.188	2.089	1.984
∞	0.100	2.705	2.303	2.084	1.945	1.847	1.774	1.717	1.670	1.632	1.599	1.546	1.487	1.421	1.383	1.342
	0.050	3.841	2.996	2.605	2.372	2.214	2.099	2.010	1.938	1.880	1.831	1.752	1.666	1.571	1.517	1.459
	0.025	5.024	3.689	3.116	2.786	2.566	2.408	2.288	2.192	2.114	2.048	1.945	1.833	1.708	1.640	1.566
	0.010	6.635	4.605	3.782	3.319	3.017	2.802	2.639	2.511	2.407	2.321	2.185	2.039	1.878	1.791	1.696
	0.005	7.879	5.298	4.279	3.715	3.350	3.091	2.897	2.744	2.621	2.519	2.358	2.187	2.000	1.898	1.789

¹¹⁸ Para la tabla F, ver anexo 2.3.

Los grados de libertad se encuentran muy alejados de 200, lo cual indica que:

$$F_{t,\alpha=0.05,2,1157} = 2.996$$


Recuerde que para rechazar la hipótesis nula se sabe que:

$$F_c > F_t$$

Al comparar los valores se tiene que:

$$0.927 < 2.996$$

Por lo que no se rechaza la hipótesis nula. Para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Se concluye entonces que hay evidencia estadística para no rechazar la H_0 con esto se puede indicar que los errores o residuales tienen varianzas y covarianzas homogéneas, por lo que el supuesto de homoscedasticidad se cumple.

Los resultados que el SPSS[™] pone al respecto se muestran en la siguiente tabla:¹¹⁹

Tabla 2-143 Estadístico de prueba M de Box

Resultados de la prueba		
M de Box		1.964
F	Aprox.	.918
	gl1	2
	gl2	820.041
	Sig.	.400
Contrasta la hipótesis nula sobre que las matrices de covarianzas poblacionales son iguales.		

Para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.400 > 0.05 \text{ no se rechaza } H_0$$

Se concluye entonces que hay evidencia estadística para no rechazar la H_0 por lo que se puede indicar que los errores o residuales tienen varianzas y covarianzas homogéneas, por lo que el supuesto de homoscedasticidad se cumple.

¹¹⁹ Para encontrar los valores se realizó un análisis discriminante usando a los errores como variable independiente y a los grupos como variable dependiente.

Como todos los supuestos se cumplen, ahora es posible encontrar los valores esperados o bien realizar los pronósticos,¹²⁰ éstos pueden ser puntuales o por intervalos, los cuales se verán a continuación.

2.12 Pronósticos o estimaciones puntuales

Existen 2 tipos de estimación:

1. Puntuales, que son un valor específico
2. Intervalos, sirven para indicar entre qué valores se encuentra el verdadero valor.

Se calculará un pronóstico puntual, el cual se encuentra sustituyendo los datos de cada una de las variables en la ecuación de regresión; como ya se ha visto dicha ecuación se muestra en la siguiente tabla:

Tabla 2-144 Nueva ecuación

		Coefficientes no
Modelo		B
1	(Constante)	6.654
	Cuartos	2.602
	Norte	.091
	Sur	.110
	Cuartos2	-.999
	Cuartos3	.130

^a Variable dependiente: Ln_renta.

Como se tienen 5 variables independientes, la ecuación sería de la siguiente forma:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 * X_1 + \hat{\beta}_2 * X_2 + \hat{\beta}_3 * X_3 + \hat{\beta}_4 * X_4 + \hat{\beta}_5 * X_5$$

Como las variables 4 y 5 provienen de la misma variable 1, generalmente se les representa de la siguiente manera:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 * X_1 + \hat{\beta}_2 * X_2 + \hat{\beta}_3 * X_3 + \hat{\beta}_{1,2} * X_{1,2} + \hat{\beta}_{1,3} * X_{1,3}$$

El subíndice 1,2 significa que la variable $X_{1,2}$ procede de X_1 y que está elevada al cuadrado, por lo que el subíndice 1,3 indicaría que la variable $X_{1,3}$ proviene de X_1 y que está elevada al cubo.

Entonces la ecuación final quedaría de la siguiente manera:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602C + 0.091N + 0.110S - 0.999C^2 + 0.130C^3$$

En este caso R es la renta, pero con la transformación logarítmica sería $\text{Ln}(R)$, además $\hat{R}$ es la renta estimada. Las variables independientes serían: C es el numero de cuartos, N es la zona norte, S es la zona sur y además C^2 y C^3 es el número de cuartos elevados al cuadrado y al cubo, respectivamente.

Sustituir los valores que se desean en lugar de las variables independientes en la ecuación daría un pronóstico puntual; por ejemplo, si se deseara conocer la renta que se puede pagar en una casa que tenga 2 cuartos y se encuentre en la zona sur, dichos valores se sustituyen en la ecuación de regresión, la cual se muestra a continuación:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602 * 2 + 0.091 * 0 + 0.110 * 1 - 0.999 * 2^2 + 0.130 * 2^3$$

Por lo que el estimado sería:

$$\text{Ln}(\hat{R}) = 9.017$$

¹²⁰ Si algún supuesto no se cumple, no es posible continuar, es necesario realizar las correcciones necesarias (transformaciones, mínimos cuadrados ponderados, etc.) hasta que todos y cada uno de los supuestos se cumplan.

Pero como el resultado obtenido está en logaritmo natural, para encontrar el valor de la renta estimada es necesario:

$$\hat{R} = e^{9.017} = 8\,239.631$$

Donde e es la base del sistema logarítmico neperiano (natural) y es una constante con un valor aproximado de 2.71828...

Los demás valores de los pronósticos puntuales se muestran en la siguiente tabla:

Tabla 2-145 Pronósticos puntuales de las observaciones

Renta	Cuartos	Norte	Sur	Cuartos 2	Cuartos 3	ln (renta)		Renta
Renta	X_1	X_2	X_3	X_4	X_5	ln (Y)	ln($\hat{Y}$)	$\hat{Y}$
8 500	2	0	1	4	8	9.048	9.017	8 239.631
8 900	2	1	0	4	8	9.094	8.998	8 083.806
14 000	4	1	0	16	64	9.547	9.523	13 669.612
5 000	1	0	0	1	1	8.517	8.387	4 391.078
11 000	4	0	0	16	64	9.306	9.432	12 480.537
8 000	2	0	0	4	8	8.987	8.907	7 380.622
8 500	2	0	1	4	8	9.048	9.017	8 239.631
12 000	4	0	0	16	64	9.393	9.432	12 480.537
3 900	1	0	0	1	1	8.269	8.387	4 391.078
12 000	4	0	0	16	64	9.393	9.432	12 480.537
7 500	3	0	0	9	27	8.923	8.994	8 054.240
8 700	3	0	0	9	27	9.071	8.994	8 054.240
8 000	3	0	0	9	27	8.987	8.994	8 054.240
3 800	1	0	0	1	1	8.243	8.387	4 391.078
7 000	2	1	0	4	8	8.854	8.998	8 083.806
9 000	3	0	1	9	27	9.105	9.104	8 991.649
4 500	1	0	0	1	1	8.412	8.387	4 391.078
4 800	1	0	1	1	1	8.476	8.497	4 902.143
7 900	2	0	1	4	8	8.975	9.017	8 239.631
5 000	1	0	0	1	1	8.517	8.387	4 391.078
13 500	4	0	0	16	64	9.510	9.432	12 480.537
13 500	4	0	0	16	64	9.510	9.432	12 480.537
7 000	2	0	0	4	8	8.854	8.907	7 380.622
14 000	4	1	0	16	64	9.547	9.523	13 669.612

En el SPSS™ los resultados anteriores aparecen en la base de datos:

	PRE_1	RES_1	ZRE_1
1	9.01671	0.03111	0.33386
2	8.99762	0.09619	1.03225
3	9.52293	0.02388	0.25629
4	8.36733	0.12986	1.39363
5	9.43193	-0.12626	-1.35512
6	8.90661	0.09059	0.86476
7	9.01671	0.03111	0.33386
8	9.43193	-0.03926	-0.42136
9	8.36733	-0.11860	-1.27274
10	9.43193	-0.03926	-0.42136
11	8.99395	-0.07130	-0.76511
12	8.99395	0.07712	0.82766
13	8.99395	-0.00676	-0.07251
14	8.36733	-0.14457	-1.55150
15	8.99762	-0.14395	-1.54483
16	9.10405	0.00093	0.00996
17	8.36733	0.02450	0.36295
18	8.49743	-0.02106	-0.22697
19	9.01671	-0.04209	-0.45172
20	8.36733	0.12986	1.39363
21	9.43193	0.07852	0.84263
22	9.43193	0.07852	0.84263
23	8.90661	-0.05295	-0.56821
24	9.52293	0.02388	0.25629

Figura 2-26 Pronósticos puntuales de las observaciones.

En la primera columna se muestran los pronósticos puntuales, en la segunda los residuales o errores y en la tercera los residuales estandarizados.

2.13 Pronósticos puntuales del modelo exponencial

Como la variable dependiente desde un principio se transformó a logaritmo natural se puede manejar el pronóstico sin el logaritmo, esto se logra volviendo el modelo a forma multiplicativa, para hacerlo es necesario encontrar para cada coeficiente el inverso de la función logarítmica, el cual es el exponencial de los coeficientes. Por ejemplo si se desea encontrarlo para la variable cuartos, se tiene que:

$$e^{\hat{\beta}_{x_i}} = e^{2.602} = 13.490$$

La información de las demás variables y de la constante se encuentra en la siguiente tabla:

Tabla 2-146 Exponencial de los coeficientes

	Coefficientes no estandarizados	Inversa del logaritmo natural
Constante	6.654	775.518
Cuartos	2.602	13.490
Norte	0.091	1.095
Sur	0.110	1.116
Cuartos dos	-0.999	0.368
Cuartos tres	0.130	1.139

Ahora el modelo multiplicativo sería el siguiente:

$$\hat{R} = 775.518 * 13.49^C * 1.095^N * 1.116^S * 0.368^{C^2} * 1.139^{C^3}$$

En este caso R es la renta, pero sin la transformación logarítmica, además R es la renta estimada. Las variables independientes serían: C es el numero de cuartos, N es la zona norte, S es la zona sur y además C^2 y C^3 es el número de cuartos elevados al cuadrado y al cubo, respectivamente.

Al momento de sustituir los valores que se desean en las variables independientes en la ecuación daría un pronóstico puntual. Por ejemplo si se deseara conocer la renta que se puede pagar en una casa que tenga 2 cuartos y se encuentre en la zona sur, dichos valores se sustituyen en el modelo multiplicativo, lo cual se muestra a continuación:

$$\hat{R} = 775.518 * 13.49^2 * 1.095^0 * 1.116^1 * 0.368^{2^2} * 1.139^{2^3} = 8\,239.631$$

Al comparar los resultados de lo anterior y recordar que el pronóstico del modelo de regresión lineal fue:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602 * 2 + 0.091 * 0 + 0.110 * 1 - 0.999 * 2^2 + 0.130 * 2^3$$

El estimado sería:

$$\text{Ln}(\hat{R}) = 9.017$$

Pero como el resultado obtenido está en logaritmo natural, para encontrar el valor de la renta estimada sería:

$$\hat{R} = e^{9.017} = 8\,239.631$$

Los resultados son los mismos.

2.14 Pronósticos del intervalo

Como ya se dijo con anterioridad, los pronósticos pueden ser puntuales y por intervalo, a continuación se mostrará cómo encontrar los últimos. Los intervalos deben calcularse, ya que indican entre qué valores podrían oscilar los verdaderos precios de la renta. Existen 2 tipos de intervalos de confianza: para la media y para la predicción individual.

2.14.1 Intervalo de confianza para la media

Dichos intervalos se calculan con el valor esperado medio, es decir al valor puntual se le agrega una distancia. El intervalo de confianza para la media se puede realizar con la siguiente fórmula:

Ecuación 2-47 Intervalo de confianza para la media


$$\hat{Y}_0 \pm t_{t, \frac{\alpha}{2}, (n-p)} S_{\varepsilon} \sqrt{X_0^T (X^T X)^{-1} X_0}$$

Si se desea incluir la varianza estimada de los errores, nombrada con anterioridad como *MSE*, también se podría calcular de la siguiente manera:

Ecuación 2-48 Intervalo de confianza para la media

$$\hat{Y} \pm t_{t, \frac{\alpha}{2}, (n-p)} \sqrt{MSE [X_0^T (X^T X)^{-1} X_0]}$$

Gráficamente en 2 dimensiones, los valores que arrojaría el intervalo serían:



Gráfica 2-41 Intervalos de confianza para la predicción media en 2 dimensiones.

Si se desea construir el intervalo de confianza para la predicción media, una vez que se realizó la estimación puntual del ejemplo o si se desea conocer la renta que se puede pagar en una casa que tenga 2 cuartos y se encuentre en la zona sur, recuerde que la estimación puntual de estos valores se realizó en el punto pasado; los valores dados, se sustituyen en la ecuación de regresión, lo cual se muestra a continuación:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602 * 2 + 0.091 * 0 + 0.110 * 1 - 0.999 * 2^2 + 0.130 * 2^3$$

Entonces el estimado es:

$$\text{Ln}(\hat{R}) = 9.017$$

El cual sería:

$$\text{Ln}(\hat{R}) = 9.017 = \hat{Y}_0$$

Entonces, el vector X_0^T sería el siguiente:

$$X_0^T = [1 \quad 2 \quad 0 \quad 1 \quad 4 \quad 8]$$

Donde el primer 1 es para $\hat{\beta}_0$, el 2 es para la variable cuartos, el 0 es para la variable norte, el 1 es para la variable sur, el 4 corresponde a cuartos elevado al cuadrado y el 8 a cuartos al cubo. Entonces X_0 es:

$$X_0 = \begin{bmatrix} 1 \\ 2 \\ 0 \\ 1 \\ 4 \\ 8 \end{bmatrix}$$

La matriz $(X^T X)^{-1}$ se muestra a continuación:

	14.097	-21.833	0.848	0.495	9.575	-1.256
	-21.833	34.596	-1.387	-0.845	-15.378	2.034
$(X^T * X)^{-1} =$	0.848	-1.387	0.380	0.099	0.600	-0.078
	0.495	-0.845	0.099	0.329	0.335	-0.039
	9.575	-15.378	0.600	0.335	6.921	-0.924
	-1.256	2.034	-0.078	-0.039	-0.924	0.124

Lo cual para cada una de las variables sería de la siguiente manera:

		Cuartos	Norte	Sur	Cuartos 2	Cuartos 3
	14.097	-21.833	0.848	0.495	9.575	-1.256
	-21.833	34.596	-1.387	-0.845	-15.378	2.034
$(X^T * X)^{-1} =$	0.848	-1.387	0.380	0.099	0.600	-0.078
	0.495	-0.845	0.099	0.329	0.335	-0.039
	9.575	-15.378	0.600	0.335	6.921	-0.924
	-1.256	2.034	-0.078	-0.039	-0.924	0.124

La columna que no tiene nombre de variable corresponde a $\hat{\beta}_0$. Entonces el producto de $X_0^T (X^T X)^{-1}$ sería:

$$X_0^T (X^T X)^{-1} = [-0.817 \quad 1.270 \quad -0.052 \quad 0.160 \quad -0.052 \quad 0.072]$$

Y el producto de $X_0^T (X^T X)^{-1} X_0$ sería:

$$X_0^T (X^T X)^{-1} X_0 = 0.249$$

Ahora el error estándar se encuentra en la tabla de resumen del modelo:

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.979 ^a	.959	.947	.09318	1.776

^a Variables predictoras: (constante), cuartos3, norte, sur, cuartos, Cuartos2.

^b Variable dependiente: Ln_renta.

Como el estudio se está realizando con 95%, el estadístico teórico es:


$$t_{t, \frac{\alpha}{2}} = \frac{0.05}{2} = 0.025, (n-p) = (24-6) = 18$$

O bien:


$$t_{t, \alpha=0.05, (n-p)=(24-6)=18}$$

La forma de encontrar el estadístico teórico sería en la tabla respectiva, es decir en la t-student; si se usa el 0.05 se busca por arriba, pero si se utiliza el 0.025 sería por abajo, esto se muestra a continuación:

Tabla 2-147 Tabla t^{121}



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015	4.346
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965	4.286
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.174	3.579	3.883	4.187
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850	4.146
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Entonces el estadístico teórico sería:

$$t_{t, 0.025} = 2.101$$

Por último sustituya todo lo anteriormente encontrado en la ecuación:

$$\hat{Y}_0 \pm t_{t, \frac{\alpha}{2}, (n-p)} S_e \sqrt{X_0^T (X^T X)^{-1} X_0}$$

¹²¹ Ver anexo 2.2 “Tabla t-student”.

Entonces:

$$9.017 \pm 2.101 * 0.09318 \sqrt{0.249}$$

Se obtiene que:

$$9.017 \pm 0.98$$

Por lo que el valor real oscilaría entre:

$$8.919 \leq Ln(R) \leq 9.114$$

Pero como el valor está en logaritmo, se le encuentra el inverso del logaritmo natural, lo que da como resultado:

$$e^{8.919} \text{ y además } e^{9.114}$$


Entonces, los valores serían:

$$7\,472.741 \leq R \leq 9\,085.224$$

Es decir con 95% de confianza la Y media real puede oscilar entre 7 472.741 y 9 085.224.

Los demás intervalos pueden ser encontrados de la misma manera, por lo que los valores en el SPSS™ los pone en la base de datos:

Tabla 2-148 Base con los intervalos para la proyección media



	LMCI_1	UMCI_1
1	8.91902	9.11440
2	8.88405	9.11119
3	9.40936	9.63650
4	8.30525	8.46941
5	9.35030	9.51355
6	8.80709	9.00613
7	8.91902	9.11440
8	9.35030	9.51355
9	8.30525	8.46941
10	9.35030	9.51355
11	8.89212	9.09578
12	8.89212	9.09578
13	8.89212	9.09578
14	8.30525	8.46941
15	8.88405	9.11119
16	8.97493	9.23317
17	8.30525	8.46941
18	8.37438	8.62048
19	8.91902	9.11440
20	8.30525	8.46941
21	9.35030	9.51355
22	9.35030	9.51355
23	8.80709	9.00613
24	9.40936	9.63650
25		

En la primera columna se muestra el límite inferior del intervalo de confianza para la media y en la segunda se encuentra el límite superior.

2.14.2 Intervalo de confianza para la predicción individual

Dichos intervalos se calculan con el valor esperado individual, es decir, al valor puntual se le agrega una distancia extra. El intervalo de confianza para la predicción individual sirve para aquellos valores muy alejados de la línea de regresión y se puede realizar con la siguiente fórmula:

Ecuación 2-48 Intervalo de confianza para la media

$$\hat{Y}_0 \pm t_{t, \frac{\alpha}{2}, (n-p)} S_{\varepsilon} \sqrt{1 + X_0^T (X^T X)^{-1} X_0}$$


Si se desea incluir la varianza estimada de los errores, la cual fue nombrada con anterioridad como MSE , también se podría calcular de la siguiente manera:

Ecuación 2-49 Intervalo de confianza para la media

$$\hat{Y} \pm t_{t, \frac{\alpha}{2}, (n-p)} \sqrt{MSE \left[1 + X_0^T (X^T X)^{-1} X_0 \right]}$$

Note que la fórmula es la misma pero con $1 +$ adentro de la raíz,¹²² lo que hace que el intervalo se abra un poco más y con 95% de confianza pueda abarcar más valores.


Gráficamente en 2 dimensiones, los valores que arrojaría el intervalo son un poco más abiertos que los intervalos de confianza para el promedio, entonces ambos se verían de la siguiente manera:



Gráfica 2-42 Intervalos de confianza para la predicción media y para la predicción individual en 2 dimensiones.

Nótese que el primer intervalo (interno) abarca casi la mayoría de las observaciones, éste sería para la predicción media y que el segundo intervalo (externo) abarca todos los valores, éste es para la predicción individual, por lo que si se piensa que alguna observación está muy alejada de las observaciones este intervalo sería el correcto a construir o calcular.

Entonces los intervalos para la predicción individual se verían de la siguiente manera:



Gráfica 2-43 Intervalos de confianza para la predicción media en 2 dimensiones.

Los intervalos que se encuentran en los extremos serían los de la predicción individual y los que están más cerca de la línea de regresión serían para la media. Nótese que existen 3 valores que los in-

¹²² Por lo que el procedimiento sería el mismo que el intervalo de confianza para el valor esperado medio.

tervalos para la media no comprenden, por lo que los de la predicción individual sí lo hace. De acuerdo con el ejemplo, si se desea construir el intervalo de confianza para la predicción individual que se realizó en la estimación puntual (conocer la renta que se pagaría en una casa que tenga 2 cuartos y se encuentre en la zona sur) dichos valores se sustituyen en la ecuación de regresión, lo cual se muestra a continuación:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602 * 2 + 0.091 * 0 + .0110 * 1 - 0.999 * 2^2 + 0.130 * 2^3$$

Entonces el estimado es:

$$\text{Ln}(\hat{R}) = 9.017$$

El cual sería:

$$\text{Ln}(\hat{R}) = 9.017 = \hat{Y}_0$$

Entonces, el vector X_0^Y sería el siguiente:

$$X_0^Y = [1 \quad 2 \quad 0 \quad 1 \quad 4 \quad 8]$$

Donde el primer 1 es para $\hat{\beta}_0$ el 2 es para la variable cuartos, el 0 es para la variable norte, el 1 es para la variable sur, el 4 corresponde a cuartos elevado al cuadrado y el 8 a cuartos al cubo. Entonces X_0 es:

$$X_0 = \begin{bmatrix} 1 \\ 2 \\ 0 \\ 1 \\ 4 \\ 8 \end{bmatrix}$$

La matriz $(X^T X)^{-1}$ se muestra a continuación:

$(X^T * X)^{-1} =$	14.097	-21.833	0.848	0.495	9.575	-1.256
	-21.833	34.596	-1.387	-0.845	-15.378	2.034
	0.848	-1.387	0.380	0.099	0.600	-0.078
	0.495	-0.845	0.099	0.329	0.335	-0.039
	9.575	-15.378	0.600	0.335	6.921	-0.924
	-1.256	2.034	-0.078	-0.039	-0.924	0.124

La cual sería para cada una de las variables de la siguiente manera:

$(X^T * X)^{-1} =$		Cuartos	Norte	Sur	Cuartos 2	Cuartos 3
	14.097	-21.833	0.848	0.495	9.575	-1.256
	-21.833	34.596	-1.387	-0.845	-15.378	2.034
	0.848	-1.387	0.380	0.099	0.600	-0.078
	0.495	-0.845	0.099	0.329	0.335	-0.039
	9.575	-15.378	0.600	0.335	6.921	-0.924
	-1.256	2.034	-0.078	-0.039	-0.924	0.124

La columna que no tiene nombre de variable corresponde a $\hat{\beta}_0$. Entonces el producto de $X_0^T (X^T X)^{-1}$ sería:

$$X_0^T (X^T X)^{-1} = [-0.817 \quad 1.270 \quad -0.052 \quad 0.160 \quad -0.052 \quad 0.072]$$

Y el producto de $X_0^T (X^T X)^{-1} X_0$ sería:

$$X_0^T (X^T X)^{-1} X_0 = 0.249$$

El error estándar se encuentra en la tabla de resumen del modelo:

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.979 ^a	.959	.947	.09318	1.776

^a Variables predictoras: (constante), cuartos3, norte, sur, cuartos, Cuartos2.

^b Variable.

Como el estudio se realiza con 95% de confianza, el estadístico teórico es:


$$t_{t, \left(\frac{\alpha}{2}\right)} = \left(\frac{0.05}{2}\right) = 0.025, (n-p) = (24-6) = 18$$

O bien:


$$t_{t, \alpha=0.05, (n-p)=(24-6)=18}$$

La forma de encontrar el estadístico teórico sería en la tabla respectiva; es decir, en la t-student; si se usa el 0.05 se busca por arriba, pero si se usa el 0.025 sería por abajo, esto se muestra a continuación:

Tabla 2-148 Tabla t^{123}



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015	4.346
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965	4.286
18	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.174	3.579	3.883	4.187
20	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850	4.146
21	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Entonces el estadístico teórico sería:

$$t_{t, \alpha=0.025, 18} = 2.101$$

¹²³ Ver anexo 2.2 “Tabla t-student”.

Por último sustituye todo lo anteriormente encontrado en la ecuación:

$$\hat{Y}_0 \pm t_{t, \frac{\alpha}{2}, (n-p)} S_\varepsilon \sqrt{1 + X_0^T (X^T X)^{-1} X_0}$$

Entonces:

$$9.017 \pm 2.101 * 0.09318 \sqrt{1 + 0.249}$$

Se obtiene que:

$$9.017 \pm 0.219$$

Por lo que el valor real oscilaría entre:

$$8.797 \leq \ln(R) \leq 9.236$$

Pero como el valor está en logaritmo, se le encuentra el inverso del logaritmo natural, lo que da como resultado:

$$e^{8.798} \text{ y además } e^{9.236}$$


Entonces, los valores serían:

$$6\,620.445 \leq R \leq 10\,254.828$$

Es decir con 95% de confianza la Y media real oscilaría entre 6 620.445 y 10 254.828.

El SPSS™ los resultados los pone en la base de datos:

Tabla 2-149 Base con los intervalos para la proyección media



	LICI_1	UICI_1
1	8.79792	9.23560
2	8.77129	9.22395
3	9.29660	9.74926
4	8.17505	8.59961
5	9.21982	9.64403
6	8.68700	9.12623
7	8.79792	9.23560
8	9.21982	9.64403
9	8.17505	8.59961
10	9.21982	9.64403
11	8.77328	9.21463
12	8.77328	9.21463
13	8.77328	9.21463
14	8.17505	8.59961
15	8.77129	9.22395
16	8.86953	9.33857
17	8.17505	8.59961
18	8.26620	8.72866
19	8.79792	9.23560
20	8.17505	8.59961
21	9.21982	9.64403
22	9.21982	9.64403
23	8.68700	9.12623
24	9.29660	9.74926

Es importante comentar que también es posible obtener valores que no están comprendidos en los datos recabados, pero que se deben usar valores dentro de los rangos de las variables; por ejemplo, si el número de cuartos oscila entre 1 y 4 es preferible que no se pronostique más allá de esos valores.

2.15 Estrategias

Para crear estrategias basta con analizar la tabla donde se encuentran los coeficientes de la ecuación de regresión:

Tabla 2.150 Ecuación final

		Coeficientes no estandarizados		Coeficientes estandarizados
Modelo		B	Error típ.	Beta
1	(Constante)	6.654	.350	
	Cuartos	2.602	.548	7.563
	Norte	.091	.057	.085
	Sur	.110	.053	.113
	Cuartos2	-.999	.245	-14.993
	Cuartos3	.130	.033	8.511

^a Variable dependiente: Ln_renta.

Con la tabla anterior se puede encontrar la ecuación siguiente:

$$\text{Ln}(\hat{R}) = 6.654 + 2.602 * C + 0.091 * N + 0.110 * S - 0.999 * C^2 + 0.130 * C^3$$

Lo anterior indica que el mayor peso se tiene en la variable cuartos y que afecta en forma directa, es decir entre más cuartos más renta se pagaría. Pero lo que más ayuda a las estrategias es la columna de los coeficientes estandarizados, los cuales indican qué tan fuerte impactan o de qué forma afectan a la variable dependiente, que en este caso sería la variable renta. La fórmula para encontrar dichos coeficientes estandarizados es:

Ecuación 2.50 Coeficientes estandarizados de la ecuación de regresión

$$\beta_{X_i}^{std} = \hat{\beta}_{X_i} \sqrt{\frac{SS_{X_i}}{gl_{X_i}}} = \hat{\beta}_{X_i} \sqrt{\frac{SS_{X_i}}{SS_Y}} = \hat{\beta}_{X_i} \sqrt{\frac{S_{X_i}^2}{S_Y^2}} = \hat{\beta}_{X_i} \left(\frac{S_{X_i}}{S_Y} \right)$$

Donde:

- $\beta_{X_i}^{std}$: es el coeficiente estandarizado de la variable independiente i .
- $\hat{\beta}_{X_i}$: es la estimación puntual del coeficiente no estandarizado (son los que se encuentran en la ecuación) de la variable independiente i .
- SS_{X_i} : es la suma de cuadrados de la variable independiente i .
- $gl_{X_i=n-q}$: son los grados de libertad de la variable independiente i .
- SS_Y : es la suma de cuadrados de la variable dependiente.
- $gl_Y = n - 1$: son los grados de libertad de la variable dependiente.
- $S_{X_i}^2$: es la suma de cuadrados promediados; es decir, la varianza de la variable independiente i .
- S_Y^2 : es la suma de cuadrados promediados; es decir, la varianza de la variable dependiente.
- S_{X_i} : es la raíz cuadrada de la varianza de la variable independiente i , dicho valor corresponde a la desviación estándar de la X_i .
- S_Y : es la raíz cuadrada de la varianza de la variable dependiente, dicho valor corresponde a la desviación estándar de la Y .

El proceso para encontrar las desviaciones estándar de la variable cuartos y de la variable dependiente se muestra en la siguiente tabla:

Tabla 2-151 Variables cuartos y Ln renta

Cuartos		Ln (Renta)	
X_1	$(X_{i1} - X_1)^2$	Ln (Y)	$(Y_i - Y)^2$
2	0.250	9.048	0.0042
2	0.250	9.094	0.0124
4	2.250	9.547	0.3183
1	2.250	8.517	0.2167
4	2.250	9.306	0.1043
2	0.250	8.987	0.0000
2	0.250	9.048	0.0042
4	2.250	9.393	0.1681
1	2.250	8.269	0.5097
4	2.250	9.393	0.1681
3	0.250	8.923	0.0036
3	0.250	9.071	0.0078
3	0.250	8.987	0.0000
1	2.250	8.243	0.5475
2	0.250	8.854	0.0166
3	0.250	9.105	0.0150
1	2.250	8.412	0.3259
1	2.250	8.476	0.2563
2	0.250	8.975	0.0001
1	2.250	8.517	0.2167
4	2.250	9.510	0.2785
4	2.250	9.510	0.2785
2	0.250	8.854	0.0166
4	2.250	9.547	0.3183
Suma =	60	32.000	3.787
Promedio =	2.5	8.983	
Varianza =	1.391	0.165	
Desviación estándar =	1.180	0.406	

Entonces, si se desea encontrar la beta estandarizada de la variable cuartos sería de la siguiente forma:

$$\beta_{Cuartos}^{std} = 2.602 \sqrt{\frac{32}{24-1}} \frac{24-1}{3.787} = 2.602 \sqrt{\frac{1.391}{0.165}} = 2.602 \left(\frac{1.180}{0.406} \right) = 7.563$$

El procedimiento para las demás variables es el mismo, los resultados de los coeficientes que da el SPSS™ se muestran en la siguiente tabla:

Tabla 2-152 Coeficientes estandarizados

		Coeficientes no estandarizados		Coeficientes estandarizados
Modelo		B	Error típ.	Beta
1	(Constante)	6.654	.350	
	Cuartos	2.602	.548	7.563
	Norte	.091	.057	.085
	Sur	.110	.053	.113
	Cuartos2	-.999	.245	-14.993
	Cuartos3	.130	.033	8.511

^a Variable dependiente: Ln_renta.

Estos coeficientes estandarizados se convierten a porcentaje al sumarlos, la operación sería la siguiente:

$$\sum_{i=1}^K |\beta_{x_i}^{std}| = |7.563| + |0.085| + |0.113| + |-14.993| + |8.511| = 31.265$$

Ahora cada uno de los coeficientes estandarizados se convierte en porcentaje de la siguiente manera:

$$\% \beta_{Cuartos}^{std} = \frac{7.563}{31.265} \times 100 = 0.242 \times 100 = 24.19\%$$

El resto de los porcentajes se calcula de la misma manera; la información de cada uno de los coeficientes estandarizados se resume en la tabla siguiente:

Tabla 2-153 Porcentaje de contribución

	Coeficientes no estandarizados	Coeficientes estandarizados	Valor absoluto	Conversión a proporciones	Conversión a porcentaje
Cuartos	2.602	7.563	7.563	0.242	24.19%
Norte	0.091	0.085	0.085	0.003	0.27%
Sur	0.110	0.113	0.113	0.004	0.36%
Cuartos2	-0.999	-14.993	14.993	0.480	47.95%
Cuartos3	0.130	8.511	8.511	0.272	27.22%
		Suma =	31.265	1.000	100%

Esto se debe interpretar de la siguiente manera: la variable cuartos es la que más afecta al logaritmo natural de la variable renta y que impacta en 99.37%, en comparación con las restantes 2 zonas que aportan sólo un poco (0.27% y 0.36%); por lo que se debe considerar más el número de cuartos de cualquier casa que se desee rentar en las cercanías de la zona analizada.

2.16 Ejercicios de análisis de regresión

Problema 1:

Un economista desea poner un despacho, por lo cual quiere investigar las rentas de oficinas. Tomó una muestra aleatoria de las rentas mensuales en pesos por metro cuadrado y el porcentaje de oficinas vacantes en 30 lugares diferentes de la ciudad. Con la información disponible se corrió un modelo de regresión lineal y algunos resultados se muestran a continuación:

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.998 ^a	¿?	¿?	2.09538	2.022

^a Variables predictoras: (constante), vacantes.

^b Variable dependiente: renta.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	¿?	¿?	¿?	¿?	a
	Residual	¿?	¿?	¿?		
	Total	27 921.039	¿?			

^a Variables predictoras: (constante), vacantes.

^b Variable dependiente: renta.

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	-2.775	¿?		-3.488	.002	-4.405	-1.145
	Vacantes	9.049	¿?	.998	¿?	¿?	¿?	9.282

^a Variable dependiente: Renta.

- ¿Cuál es la relación entre la renta y el número de vacantes?
- ¿Cuánto fue lo que se logró captar por medio del modelo de regresión?
- Efectúe una prueba de hipótesis para ver si el valor esperado de las rentas está siendo afectado por el número de vacantes. Use un nivel de significancia de 5%.
- ¿Cuál es la dispersión a través de la línea de regresión?
- Encuentre la estimación puntual y por intervalo para cada uno de los parámetros. Utilice una confianza de 95%.

Problema 2:

El gobernador ha dicho que si pone más policías, el número de robos disminuirá en la ciudad. Un despacho de abogados decidió probar lo anterior para lo cual tomará una muestra aleatoria de 22 datos. Con la información disponible se corrió un modelo de regresión lineal y algunos resultados se muestran a continuación:

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.998 ^a	¿?	¿?	.253	3.001

^a Variables predictoras: (constante), policías.

^b Variable dependiente: robos.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	¿?	¿?	¿?	¿?	a
	Residual	¿?	¿?	¿?		
	Total	281.091	¿?			

^a Variables predictoras: (constante), policías.

^b Variable dependiente: robos.

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	.304	¿?		2.863	.010	.083	.526
	Vacantes	.110	¿?	.998	¿?	¿?	.107	¿?

^a Variable dependiente: robos.

- ¿Cuánta relación existe entre el número de policías y el número de robos?
- ¿Cuánto fue lo que no se logró explicar por medio de la función?
- ¿Es significativa la relación entre el número de robos y el número de policías? Use un nivel de confianza de 95%.
- Realice una estimación por intervalo para cada uno de los coeficientes de regresión. Utilice una significancia de 5%.
- ¿Cuál sería el valor de la varianza de los errores?

Problema 3:

Si el estadístico de prueba de una regresión simple dio como resultados $t_c = 3.500$ y se tienen 37 datos u observaciones.

- ¿Cuál sería el estadístico de prueba F?
- ¿Cuál sería el valor-p que haría que se rechace la hipótesis nula por medio de la t, si se realiza una prueba de hipótesis de dos extremos, es decir si la hipótesis alterna dijera $H_1: \beta_1 \neq 0$?
- ¿Cuál sería su respuesta si se decidiera realizar la prueba de hipótesis de un extremo por medio de la t, es decir si la hipótesis alterna fuera $H_1: \beta_1 > 0$?

Problema 4:

El dueño de una tienda de venta de ropa desea desarrollar un modelo para predecir la cantidad de ropa que necesita tener en dicho negocio, se realizó una regresión con las variables de temporada y el ingreso que las personas de su barrio perciben; la regresión con 12 datos y con todas las variables dio los siguientes resultados.

Nota: La variable temporada como es categórica se recodificó poniendo las 4 temporadas con 1 y 0, pero sólo se introdujeron 3 de ellas en el modelo.

Resumen del modelo ^b				
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación
1	.981 ^a	.962	.948	37.039

^a Variables predictoras: (constante), vacantes.

^b Variable dependiente: renta.

Ahora se decidió realizar una regresión simple, pero sólo con la variable ingreso y las ventas, los resultados de dicha regresión fueron los siguientes: la variación total fue de 281.091 y la no explicada fue de 79.812.

- ¿Cuál sería la R^2 de la regresión simple?
- ¿Cuál sería la R^2_{adj} de la regresión simple?
- Compare las R^2_{adj} de ambos modelos. ¿A qué conclusión llegó?
- ¿Por qué se compararían las R^2_{adj} y por qué no usar las R^2 ? ¿Qué medidas de las que sirven para evaluar el modelo recomendaría en este caso; es decir, R , R^2 , R^2_{adj} o S_e (el error estándar del estimado)? ¿Por qué?
- ¿Cuál modelo fue el mejor? Realice esto a 99% de confianza y analice la respuesta, dé conclusiones basadas en lo encontrado.

Problema 5:

El dueño de una empresa desea desarrollar un modelo para predecir el consumo de energía eléctrica en su empresa (en cientos de Kw consumidos por luz, aire acondicionado, calefacción, aparatos eléctricos y electrónicos, etc.) según la temperatura exterior (promedio de la temporada en grados centígrados) y la estación del año. Dispone de datos de los recibos mensuales y la información de temperatura promedio mensual para un periodo de 12 meses; con la información disponible corrió un modelo de regresión lineal y algunos resultados se muestran a continuación.

Nota: La variable estación como es categórica se recodificó poniendo las 4 estaciones con 1 y 0.

Correlaciones de los coeficientes ^a						
Modelo			Otoño	Temperatura	Primavera	Invierno
1	Correlaciones	Otoño	1.000	.742	.814	.793
		Temperatura	.742	1.000	.899	.981
		Primavera	.814	.899	1.000	.925
		Invierno	.793	.981	.925	1.000
	Covarianzas	Otoño	1 526.263	120.043	1 903.541	4 184.361
		Temperatura	120.043	17.149	222.937	548.769
		Primavera	1 903.541	222.937	3 584.145	7 476.973
		Invierno	4 184.361	548.769	7 476.973	18 246.557

^a Variable dependiente: energía.

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	¿? ^a	¿?	¿?	¿?	1.759

^a Variables predictoras: (constante), otoño, temperatura, primavera, invierno.

^b Variable dependiente: energía.

Coeficientes ^a									
		Coeficientes no estandarizados		Coeficientes estandarizados		Intervalo de confianza para B a 95%		Estadísticos de colinealidad	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia FIV
1	(Constante)	355.500	¿?		2.139	.056	-10.355	723.355	
	Temperatura	4.413	¿?	.339	¿?	¿?	¿?	13.527	.034 29.300
	Invierno	-78.300	¿?	-.215	¿?	¿?	-375.609	¿?	.025 39.900
	Primavera	-340.138	¿?	-.934	¿?	¿?	¿?	-208.370	.128 7.838
	Otoño	-320.863	¿?	-.881	¿?	¿?	-406.849	¿?	.300 3.338

^a Variable dependiente: energía.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	¿?	¿?	95 684.85	¿?	^a
	Residual	¿?	¿?	¿?		
	Total	397 830.438	15			

^a Variables predictoras: (constante), otoño, temperatura, primavera, invierno.

^b Variable dependiente: energía.

- ¿Por qué la variable verano no fue incluida en el modelo?
- ¿Existe multicolinealidad en este modelo? Utilice 99% de confianza. Si existe multicolinealidad, ¿qué recomendaciones se harían?
- Realice la prueba de hipótesis del modelo. Use un nivel de significancia de 1%.
- ¿Cuáles serían los estadísticos de prueba para cada uno de los parámetros?
- Realice la prueba de hipótesis para cada uno de los parámetros, lleve a cabo esto a 99% de confianza.
- Ahora realice las mismas pruebas del inciso anterior, pero hágalo a 5% de significancia. ¿La respuesta del inciso pasado y la de éste son diferentes?
- ¿A qué se debe esto?

Problema 6:

En el problema pasado, el dueño de la empresa desea desarrollar un modelo para predecir el consumo de energía eléctrica en su empresa (en cientos de Kw consumidos por luz, aire acondicionado, calefacción, aparatos eléctricos y electrónicos, etc.), según la temperatura exterior (promedio de la temporada en grados centígrados) y la estación del año. Dispone de datos de los recibos mensuales y la información de temperatura promedio mensual para un periodo de 12 meses, con la información disponible corrió un modelo de regresión lineal y algunos resultados se muestran a continuación.

Nota: La variable estación como es categórica se recodificó poniendo las 4 estaciones con 1 y 0.

Prueba de homogeneidad de la varianza					
		Estadístico de Levene	gl1	gl2	Sig.
Residuales	Basándose en la media	4.731	2	13	.029
	Basándose en la mediana	4.716	2	13	.029
	Basándose en la mediana y con gl corregido	4.716	2	8.087	.044
	Basándose en la media recortada	4.730	2	13	.029

Pruebas de normalidad						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Residuales	.129	16	.200 ^b	.978	16	.949

^a Corrección de la significación de Lilliefors.

^b Éste es un límite inferior de la significación verdadera.

Resultados de la prueba		
M de Box		7.706
F	Aprox.	3.500
	gl1	2
	gl2	268.304
	Sig.	.032
Contrasta la hipótesis nula de que las matrices de covarianzas poblacionales son iguales		

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.706 ^a	.499	.497	1.759	

^a Variables predictoras: (constante), otoño, primavera, invierno.



^b Variable dependiente: energía.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	.499	3	.166	10.885	.000 ^a
	Residual	.499	264	.002		
	Total	.998	267			

^a Variables predictoras: (constante), otoño, temperatura, primavera, invierno.

^b Variable dependiente: energía.

Variable dependiente: energía



- ¿El supuesto de normalidad se cumple?
- ¿El supuesto de independencia se cumple?
- ¿Existe heteroscedasticidad en este modelo?

Si necesita un nivel de confianza utilice 95%.

Problema 7:

Cierta constructora desea saber si las ventas de sus viviendas están siendo afectadas por el ingreso que los habitantes de la ciudad reciben y la temporada del año, por lo que contrató a un analista para que evaluara dicha relación. El analista tomó una muestra aleatoria de las ventas y con la información disponible corrió un modelo de regresión, algunos de los resultados se muestran a continuación.

Nota: La variable temporada como es categórica se recodificó poniendo las 4 estaciones con 1 y 0.

Como se sospecha que existe multicolinealidad en el modelo se realizaron las siguientes regresiones:

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.983 ^a	.966	.957	2.582	.150

^a Variables predictoras: (constante), otoño, verano, primavera.

^b Variable dependiente: ingreso.

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.837 ^a	.700	.625	.274	1.139

^a Variables predictoras: (constante), ingreso, otoño, verano.

^b Variable dependiente: primavera.

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.987 ^a	.975	.969	.079	.305

^a Variables predictoras: (constante), primavera, ingreso, otoño.

^b Variable dependiente: verano.

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.934 ^a	.872	.841	.179	.695

^a Variables predictoras: (constante), verano, primavera, ingreso.

^b Variable dependiente: otoño.

Diagnósticos de colinealidad ^a								
Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de la varianza				
				(Constante)	Ingreso	Primavera	Verano	Otoño
1	1	2.652	1.000	.00	.00	.01	.00	.00
	2	1.062	1.580	.00	.00	.04	.01	.00
	3	1.000	1.628	.00	.00	.08	.00	.06
	4	.285	3.052	.00	.01	.26	.00	.08
	5	.002	38.582	1.00	.99	.61	.98	.85

^a Variable dependiente: ventas.

- ¿Existe multicolinealidad en este modelo? Realice los cálculos necesarios para decidir esto. Además justifique su respuesta.
- Utilice el VIF.
- Empleando la tolerancia.
- Con el índice de condición.
- Realice esto con los eigenvalores y eigenvectores.

Problema 8:

En el problema pasado, cierta constructora desea saber si las ventas de sus viviendas están siendo afectadas por el ingreso que los habitantes de la ciudad reciben y la temporada del año, por lo que contrató a un analista para que evaluara dicha relación. El analista tomó una muestra aleatoria y utilizando la información disponible corrió un modelo de regresión, algunos resultados se muestran a continuación: (Nota: la variable temporada como es categórica se recodificó poniendo las 4 estaciones con 1 y 0).

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	¿? ^a	¿?	¿?	¿?	2.657

^a Variables predictoras: (constante), otoño, ingreso, primavera, verano.

^b Variable dependiente: ventas.

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	¿?	¿?	17 438.750	¿?	¿? ^a
	Residual	¿?	¿?	¿?		
	Total	583 600.000	15			

^a Variables predictoras: (constante), otoño, ingreso, primavera, verano.

^b Variable dependiente: ventas.

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	−502.500	972.595		−.517	.616	−2 643.168	1 638.168
	Ingreso	22.250	¿?	1.410	¿?	¿?	¿?	75.435
	Primavera	153.250	¿?	.347	¿?	¿?	−348.499	¿?
	Verano	604.500	¿?	1.371	¿?	¿?	¿?	2 339.353
	Otoño	249.250	¿?	.565	¿?	¿?	−519.641	¿?

^a Variable dependiente: ventas.

Con 95% de confianza, se le pide lo siguiente:

- Realice la prueba de hipótesis del modelo.
- Realice la prueba de hipótesis para cada una de los coeficientes de las variables.
- ¿A qué conclusión puede llegar?

Problema 9:

Cierto consultorio cree que el estado de un paciente (esquizofrénico, paranoico y maniaco-depresivo) afecta la calificación que tienen en educación especial, aunque también se cree que la edad influye en dicha calificación, la información disponible es la siguiente.

Nota: La variable estado como es categórica se recodificó poniendo los 3 estados con 1 y 0.

Si se cuenta con 14 observaciones, la variación más alta es 37.214 y el error estándar del estimado es 1.28686.

Además se sabe que:

Coeficientes ^a									
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%		Estadísticos de colinealidad
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia FIV
1	(Constante)	18.400	3.742		4.917	.001	10.063	26.737	
	Esquizofrénico	1.040	.871	.306	1.194	.260	-.901	2.981	.679 1.473
	Paranoico	-.120	.879	-.035	-.136	.894	-2.080	1.840	.666 1.501
	Edad	-.800	.259	-.665	-3.093	.011	-1.376	-.224	.963 1.039

^a Variable dependiente: calificación.

Pruebas de normalidad						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Residuales no estandarizados	.125	14	.200*	.953	14	.601

^a Corrección de la significación de Lilliefors.

* Éste es un límite inferior de la significación verdadera.

Prueba de homogeneidad de la varianza					
		Estadístico de Levene	gl1	gl2	Sig.
Residuales no estandarizados	Basándose en la media	2.608	1	12	.132
	Basándose en la mediana	.964	1	12	.345
	Basándose en la mediana y con gl corregido	.964	1	7.597	.356
	Basándose en la media recortada	2.626	1	12	.131

- ¿Cuál sería el estadístico de prueba si se desea realizar una prueba de hipótesis global? ¿A qué conclusión llegaría al realizar la prueba?
- ¿Existe multicolinealidad en el modelo?
- Realice la prueba de hipótesis para cada una de las variables.
- ¿El supuesto de normalidad se cumple?
- ¿El supuesto de homoscedasticidad se cumple?

Si necesita un nivel de confianza utilice 95%.

Problema 10:

Cierta compañía desea saber si sus ganancias están siendo afectadas por la renta de departamentos (por semana), tiene vacantes (renta por día) o vende (precio) los departamentos en una playa del país.

Si se cuenta con 30 observaciones, la variación más alta es 509.367 y la correlación múltiple es 0.956, además se sabe que:

Diagnósticos de colinealidad ^a							
				Proporciones de la varianza			
Modelo	Dimensión	Autovalor	Índice de condición	(Constante)	Vacantes	Renta	Precio
1	1	3.672	1.000	.00	.00	.00	.00
	2	.299	3.502	.02	.00	.00	.08
	3	.028	11.380	.88	.00	.00	.92
	4	.001	83.255	.09	1.00	1.00	.00

^a Variable dependiente: ganancia.

Coeficientes ^a									
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%		Estadísticos de colinealidad
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior	Tolerancia FIV
1	(Constante)	6.572	1.141		5.759	.000	4.226	8.917	
	Vacantes	-.288	¿?	-.235	¿?	¿?	¿?	¿?	.004 227.132
	Renta	.026	¿?	.195	¿?	¿?	¿?	¿?	.004 227.119
	Precio	.756	¿?	.948	¿?	¿?	¿?	¿?	.965 1.0337

^a Variable dependiente: ganancia.

Correlaciones de los coeficientes ^a					
Modelo			Precio	Renta	Vacantes
1	Correlaciones	Precio	1.000	.004	.009
		Renta	.004	1.000	-.998
		Vacantes	.009	-.998	1.000
	Covarianzas	Precio	.002	2.276E - 5	.000
		Renta	2.276E - 5	-.014	-.123
		Vacantes	.000	-.123	1.119

^a Variable dependiente: ganancia.

- ¿Existe multicolinealidad en el modelo?
- ¿Cuál sería el estadístico de prueba si se desea realizar una prueba de hipótesis del modelo? ¿A qué conclusión llegaría al realizar la prueba?
- Realice la prueba de hipótesis para cada una de las variables por medio de los intervalos de confianza. ¿A qué conclusión llegó?
- Según las betas estandarizadas, ¿qué podría recomendarle a la compañía?

Si necesita un nivel de confianza utilice 95%.

Anexo 2.1 Regresión lineal simple

A2.1.1 Detectar el problema o área de oportunidad

Se desea desarrollar un modelo¹²⁴ para predecir las ganancias de cierta empresa. Se tiene una variable: la publicidad, manejada en pesos.

Es importante recordar que la regresión se utilizará para fines predictivos, por lo que para inferir causalidad se tiene que intuir que: entre más publicidad le ponga la empresa a un producto, más ganancias obtendrán porque lo conocerán más personas y cada vez lo comprarán más; sin embargo entre menos publicidad tenga la empresa de su producto menos ganancias obtendrá pues menos personas lo conocerán, entonces habrá menos ventas por lo que las ganancias bajarían; es decir existe una relación directa. Esto indica que podría tratarse de una relación causa-efecto de la siguiente manera:




Figura 2.1.1 Relación causa-efecto.

A2.1.2 Graficar la variable dependiente contra la variable independiente

La regresión exige que la relación entre la variable independiente (X) y la dependiente (Y) sea lineal, ya que la ecuación que se propone es del tipo aditiva en sus parámetros $Y = \beta_0 + \beta_1 X + \varepsilon$ que equivale a un ajuste lineal con los parámetros β_0 y β_1 .

En la gráfica se podrá ver si se cumple la relación lineal, si no es así, es necesario realizar transformaciones, las cuales se indican en cada gráfica; es decir, se trataría de una regresión no lineal (la herramienta para corregir esto es realizar transformaciones matemáticas en las variables para volver la relación no lineal a una relación lineal entre la variable dependiente y la independiente). Entonces las relaciones más comunes que existen son:







Cuadro de gráficas 2.1.1 Mostrando todas las más frecuentes relaciones

	Relación lineal positiva perfecta o directa
	Relación lineal negativa, indirecta o inversa perfecta

(continúa)





¹²⁴ Los términos *función* y *ecuación* son sinónimos.

Cuadro de gráficas 2.1.1 Mostrando todas las más frecuentes relaciones (*continuación*)

	Relación lineal positiva imperfecta
	Relación lineal negativa, indirecta o inversa imperfecta
	Relación curvilínea positiva. Requiere la transformación logarítmica, por ejemplo podría ser que $Y = f(\ln X)$, o del modo $\ln(Y) = f(X)$ o bien podría ser $\ln(Y) = f(\ln X)$
	Relación curvilínea negativa. Nota: requiere transformación logarítmica, por ejemplo podría ser que $Y = f(\ln X)$, o quizá $\ln(Y) = f(X)$ o bien podría ser $\ln(Y) = f(\ln X)$
	Relación cuadrática (parábola o polinomio de grado 2). Requiere la transformación de una parábola: $\hat{Y} = b_0 + b_1X + b_2X^2$ (polinomio de grado 2)
	Relación polinomial de grado mayor a 2. Nota: requiere una transformación de un polinomio de grado avanzado (3, es decir una cúbica) $\hat{Y} = b_0 + b_1X + b_2X^2 + b_3X^3$

(continúa)

Cuadro de gráficas 2.1.1 Mostrando todas las más frecuentes relaciones (*continuación*)

	Aunque existe una relación lineal (en forma de abanico), este modelo requiere transformación (ln, inversa, raíz)
	Aunque existe una relación lineal (en forma de abanico), este modelo requiere transformación (ln, inversa, raíz)
	Aunque existe una relación lineal (en forma de rombo), este modelo requiere transformación (ln, inversa, raíz)
	Aunque existe una relación lineal (en forma de rombo), este modelo requiere transformación (ln, inversa, raíz)
	No existe relación ya que las variables son independientes. En este caso no se deberá realizar regresión.

A continuación se dan los datos¹²⁵ del ejemplo para realizar la gráfica:

Tabla 2.1.1 Datos

X Publicidad	Y Ganancia
5	15
10	24
7	18


(*continúa*)

¹²⁵ Los datos están arreglados cronológicamente, ya que son las ganancias y los gastos de publicidad a través del tiempo de cierta empresa. Los datos fueron recabados en abril de 2010 en Monterrey, Nuevo León, México.

Tabla 2.1.1 Datos (continuación)


4	13
2	9
3	11
6	16
8	21
9	22
4	12

La gráfica que arroja el SPSS™ de la variable dependiente con respecto a la variable independiente se muestra a continuación:




Gráfica 2.1.1 Datos.

Para saber qué tipo de relación se presenta entre las 2 variables se traza una línea que esté lo más cerca posible de todos los puntos, por ejemplo podría ser de la siguiente forma:



Gráfica 2.1.2 Ajuste lineal.

Parece que el ajuste a una relación lineal imperfecta es el correcto, aunque se podría pensar o ajustar quizás un modelo polinomial de grado más avanzado, por ejemplo:



Gráfica 2.1.3 Ajuste de un polinomio.

Esto significa que se tendría que utilizar alguna transformación matemática,¹²⁶ pero para la regresión simple sólo se puede utilizar una variable independiente por lo que se supondrá que la relación es lineal e imperfecta.

A2.1.3 Estimar los coeficientes del modelo

Para encontrar los estimadores puntuales de los betas en regresión simple¹²⁷ se minimizan los errores mediante las propiedades del valor esperado, dado que el error se definió como:

Dato real u observado menos dato pronosticado o esperado, en la población se tendría:

$$Y_i - \hat{Y}_i = \varepsilon_i$$

En la población es error y en la muestra se definirá como residual:

$$Y_i - \hat{Y}_i = e_i = r_i$$

Se sabe que una de las propiedades del valor esperado es:

$$\sum_{i=1}^n (Y_i - \hat{Y}_i) = \sum_{i=1}^n (\varepsilon_i) = 0$$

Entonces lo que se desea es que la suma de los errores sea igual a cero, eso se logrará siempre y cuando obtengamos un valor mínimo y eso se obtendrá por medio de:

$$\min \sum_{i=1}^n (\varepsilon_i) = \min \sum_{i=1}^n (Y_i - \hat{Y}_i)$$

Al usar esa propiedad tenemos entonces que:

$$\sum_{i=1}^n (\varepsilon_i)^2 = \min \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


¹²⁶ Sería un polinomio de grado 6.

¹²⁷ Al igual que en la regresión múltiple.

Donde por definición el dato real y el pronóstico se obtienen de la siguiente manera:

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad \hat{Y} = \beta_0 + \beta_1 X$$

La diferencia entre el dato real Y , los errores ε y el pronóstico $\hat{Y}$ se vería gráficamente de la siguiente manera:



Gráfica 2-1-4 El error.

Al sustituir la variable pronosticada en la ecuación se tiene que:

$$\sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2 = \sum_{i=1}^n [Y_i - \beta_0 - \beta_1 X_i]^2$$

Ahora se deberán escoger los parámetros que minimicen¹²⁸ esa suma, por lo tanto se usarán las derivadas, en este caso son parciales de:

$$L(\beta_0, \beta_1) = \sum_{i=1}^n [Y_i - \beta_0 - \beta_1 X_i]^2$$

Al derivar con respecto a β_0 se tiene:

$$\frac{\partial L(\beta_0, \beta_1)}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \left[\sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2 \right] = \left[\sum_{i=1}^n \frac{\partial}{\partial \beta_0} (Y_i - \beta_0 - \beta_1 X_i)^2 \right]$$

Al derivar parcialmente la expresión que se encuentra en el paréntesis quedaría:

$$\frac{\partial L(\beta_0, \beta_1)}{\partial \beta_0} = \left[\sum_{i=1}^n \frac{\partial}{\partial \beta_0} (Y_i - \beta_0 - \beta_1 X_i)^2 \right] = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 X_i)^{2-1} (0 - 1 - 0)$$

Para obtener el mínimo se deberá igualar a cero y al simplificar se tiene:

$$\sum_{i=1}^n -2(Y_i - \beta_0 - \beta_1 X_i) = 2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0$$

Al pasar el -2 dividiendo, ya que está multiplicando, e introducir la sumatoria¹²⁹ se obtendrá lo siguiente:

¹²⁸ Cuando se quiere minimizar, el mínimo se obtiene por derivadas; como en este caso se desean obtener los valores para los dos betas eso significa que se deberá derivar primero con respecto a β_0 y luego con respecto a β_1 o viceversa.

¹²⁹ Esto ocurre por las propiedades de las sumatorias.

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 X_i) = \sum_{i=1}^n Y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 X_i = 0$$

$$\sum_{i=1}^n Y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 X_i = \sum_{i=1}^n Y_i - n\beta_0 - \beta_1 \sum_{i=1}^n X_i = 0$$

Dicha igualdad se conoce como ecuación normal y se le denominará 1.

$$\sum_{i=1}^n Y_i - n\beta_0 - \beta_1 \sum_{i=1}^n X_i = 0 \quad \text{Ecuación 1}$$

Si de la ecuación 1 se despeja β_0 y se deja en términos de β_1 , se tiene que:

$$-n\beta_0 - \beta_1 \sum_{i=1}^n X_i = -\sum_{i=1}^n Y_i$$

Al cambiar los negativos:

$$n\beta_0 + \beta_1 \sum_{i=1}^n X_i = \sum_{i=1}^n Y_i$$

Al despejar β_0 :

$$n\beta_0 = \sum_{i=1}^n Y_i - \beta_1 \sum_{i=1}^n X_i$$

$$\beta_0 = \frac{\sum_{i=1}^n Y_i}{n} - \frac{\beta_1 \sum_{i=1}^n X_i}{n}$$

Al simplificar la fórmula:

$$\beta_0 = \bar{Y} - \beta_1 \frac{\sum_{i=1}^n X_i}{n}$$

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}$$

Por lo tanto el mejor estimador para β_0 en términos de $b_1 = \beta_1$ sería por medio de:

$$b_0 = \hat{\beta}_0 = \bar{y} - b_1 \bar{x}$$

Al volver a las derivadas, primero se derivará con respecto a β_0 y posteriormente con respecto a β_1 :

$$\frac{\partial L(\beta_0, \beta_1)}{\partial \beta_1} = \left[\sum_{i=1}^n \frac{\partial}{\partial \beta_1} (Y_i - \beta_0 - \beta_1 X_i)^2 \right] = \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 X_i)^{2-1} (0 - 0 - X_i)$$

Para obtener el mínimo se deberá igualar a cero y al simplificar se tiene:

$$\sum_{i=1}^n -2(Y_i - \beta_0 - \beta_1 X_i)(X_i) = 2 \sum_{i=1}^n (X_i Y_i - \beta_0 X_i - \beta_1 X_i^2) = 0$$

Al pasar el -2 dividiendo, ya que está multiplicando, e introducir la sumatoria¹³⁰ se obtendrá lo siguiente:

$$\sum_{i=1}^n (X_i Y_i - \beta_0 X_i - \beta_1 X_i^2) = \sum_{i=1}^n (X_i Y_i) - \sum_{i=1}^n (\beta_0 X_i) - \sum_{i=1}^n (\beta_1 X_i^2) = 0$$

$$\sum_{i=1}^n X_i Y_i - \beta_0 \sum_{i=1}^n X_i - \beta_1 \sum_{i=1}^n X_i^2 = 0$$

¹³⁰ Esto ocurre por las propiedades de las sumatorias.

A dicha igualdad se le conoce como ecuación normal y se le denominará 2.

$$\sum_{i=1}^n X_i Y_i - \beta_0 \sum_{i=1}^n X_i - \beta_1 \sum_{i=1}^n X_i^2 = 0 \quad \text{Ecuación 2}$$

Al resolver β_0 así como β_1 de las ecuaciones 1 y 2¹³¹ se tiene que los mejores estimadores para ambos valores serían los siguientes:

Para β_0 :

$$\hat{\beta}_0 = b_0 = \frac{\sum_{i=1}^n Y_i \sum_{i=1}^n X_i^2 - \sum_{i=1}^n X_i \sum_{i=1}^n X_i Y_i}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2}$$

O bien:

$$\hat{\beta}_0 = b_0 = \bar{Y} - b_1 \bar{X} = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Ahora para β_1 :

$$\hat{\beta}_1 = b_1 = \frac{\sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2} = \frac{SS_{XY}}{SS_{XX}}$$

Son los estimadores puntuales para β_0 y para β_1 . Dichos estimadores fueron encontrados con el método de mínimos cuadrados ordinarios (MCO). Existen muchas maneras de representar las fórmulas anteriores, por ejemplo:

La estimación de punto para la pendiente β_1 por mínimos cuadrados es $b_1 = \frac{SS_{XY}}{SS_{XX}}$ en donde la varianza y la covarianza son:

$$SS_{XY} = \sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}$$

$$SS_{XX} = \sum (x_i - \bar{x})^2 = \sum x_i^2 - \frac{(\sum x_i)^2}{n}$$

Y la estimación de punto para el intercepto (en y), es decir para β_0 mediante mínimos cuadrados, es $b_0 = \bar{Y} - b_1 \bar{X}$ donde:

$$\bar{y} = \frac{\sum y_i}{n} \text{ y que } \bar{x} = \frac{\sum x_i}{n}$$

Entonces con las ecuaciones anteriores podremos estimar la de regresión:

$$\hat{y}_1 = b_0 + b_1 x_i = \hat{\beta}_0 + \hat{\beta}_1 x$$

De acuerdo con el ejemplo los valores de las variables son:

Tabla 2-1-2 Datos

X Publicidad	Y Ganancia	X * Y	X ²
5	15	75	25
10	24	240	100
7	18	126	49
4	13	52	16
2	9	18	4

(continúa)

¹³¹ Esto se puede realizar de muchas maneras, por ejemplo ya se tenía despejada la β_0 por lo que se puede sustituir en la ecuación dos y resolver para β_1 , por suma y resta; también se podría utilizar la regla de Cramer; pero siempre recordando que se deben despejar las betas, se quiere encontrar los mejores estimadores de β_0 y β_1 .

Tabla 2-1-2 Datos (continuación)

	X Publicidad	Y Ganancia	X * Y	X ²
	3	11	33	9
	6	16	96	36
	8	21	168	64
	9	22	198	81
	4	12	48	16
Suma =	58	161	1 054	400
Promedio =	5.80	16.10		

Al sustituir los valores en las fórmulas se tiene lo siguiente:

$$b_1 = \frac{SS_{xy}}{SS_{xx}} = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} = \frac{1054 - \frac{(58)(161)}{10}}{400 - \frac{(58)^2}{10}}$$

Por lo que

$$b_1 = \frac{120.2}{63.6} = 1.89$$

Al calcular el valor de la pendiente se tendrá que estimar el valor hacia la población:

$$b_1 = 1.89 = \hat{\beta}_1$$

El otro estadístico sería:

$$b_0 = \bar{y} - b_1 \bar{x} = \frac{161}{10} - 1.89 * \frac{58}{10}$$


Por lo que

$$b_0 = 5.138$$

Al calcular el valor de la intersección¹³² con el eje Y se tiene que estimar el valor hacia la población:


$$b_0 = 5.138 = \hat{\beta}_0$$

Ahora la pregunta sería ¿qué es b_1 ?, ésta representa el cambio en la respuesta media de Y cuando X incrementa o disminuye una unidad (en este caso incrementa ya que b_1 es positivo).

Gráfica 2-1-5 Mostrar b_1 .

¹³² También denominados *intercept* o *constante*.

Y, ¿qué es b_0 ? Es el valor con el cual la línea de regresión corta el eje de la Y.



Gráfica 2-1-6 Mostrar b_0 .

En el listado del SPSS™ las betas aparecen en la tabla de coeficientes y son los no estandarizados:

Dibujo 2-1-2 Coeficientes

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable dependiente: ganancia.

Por lo que la ecuación para estimar la renta quedaría:


$$\hat{Y} = b_0 + b_1X = \hat{\beta}_0 + \hat{\beta}_1X = 5.138 + 1.89 * X$$

$$\hat{G} = 5.138 + 1.89 * P$$

Donde $\hat{G}$ es la ganancia estimada y P es la publicidad que cierta empresa contrata.


A2.1.4 Prueba global del modelo de regresión

En realidad, al tratar de pronosticar la variable dependiente se intenta captar el comportamiento de dicha variable por medio de una ecuación, éste debe ser normal; es decir, la muestra proviene de una variable poblacional que tiene un comportamiento o sigue una distribución normal que tiene variabilidad y ésta (variación total o SST) se puede descomponer en dos variaciones: la variación explicada consecuencia de la regresión y la variación no explicada, aquella que no se logró captar por medio de la ecuación. Gráficamente en dos dimensiones los datos observados (Y) y los pronosticados ($\hat{Y}$) se verían de la siguiente manera (los datos observados aparecen con puntos y los pronosticados con línea de regresión):




Gráfica 2-1-7 Diferencia entre observado y real.

Suponga que se le agrega una línea indicadora del promedio ($\bar{Y}$) de la variable dependiente:




Gráfica 2-1-8 Diferencia entre observado, real y promedio.

Ahora se borrarán todos los puntos excepto uno, se escoge el más lejano, por lo que sólo se diferenciará un dato observado (Y), las líneas del promedio y de regresión se dejarán; al escoger un valor para X , por ejemplo $X = 6$ se tienen tres posibles puntos para ese valor en Y , el primero es el dato real representado por Y , el segundo es el pronóstico $\hat{Y}$ cuando $X = 6$ y el tercero es el promedio $\bar{Y}$ también cuando $X = 6$. La gráfica quedaría de la siguiente manera:



Gráfica 2-1-9 Una sola observación.

Como se observa hay tres desviaciones:



Gráfica 2-1-10 Desviaciones.

Dichas desviaciones elevadas al cuadrado y obtenidas en suma para todas las observaciones se convertirían en variaciones, lo cual indica la variación total,¹³³ la cual es $\sum_{i=1}^n (y_i - \bar{y})^2$; ésta se puede descomponer en dos partes: la variación explicada¹³⁴ por la regresión $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ y la variación no explicada¹³⁵ por la regresión $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ ya que no se logró explicar o captar por la regresión y se forma a partir del término del error $\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (\varepsilon_i)^2$ en la población; en la muestra sería el residual $\sum_{i=1}^n (r_i)^2$. Las tres variaciones serían:

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Generalmente estas variaciones son denominadas *SS (Sum of square)*:¹³⁶

$$SSTotal = SSR_{regresión} + SSE_{error}$$

$$SST = SSR - SSE$$

La forma en que se calcula cada una de ellas se presenta a continuación:

La variación total:

$$SST = \sum (y_i - \bar{y})^2 = \sum y_i^2 - \frac{(\sum y_i)^2}{n}$$

La variación explicada:

$$SSR = b_0 \sum y_i + b_1 \sum x_i y_i - \frac{(\sum y_i)^2}{n}$$

La variación no explicada:

$$SSE = \sum y_i^2 - b_0 \sum y_i - b_1 \sum x_i y_i$$

¹³³ La cual da una medida de lo diferente que son los valores de y_i alrededor de su promedio, $\bar{y}$.

¹³⁴ Es la variación que se le atribuye a la relación lineal que existe entre la variable X y la variable Y; dicha relación se trata de explicar por medio de la ecuación que se calculó por la regresión.

¹³⁵ Es la variación que no se le atribuye a la relación lineal que existe entre las variables X y la variable Y; es decir se puede atribuir a otros factores (variables independientes) diferentes a la utilizada en la regresión.

¹³⁶ Es la suma de cuadrados ya que se eleva al cuadrado y al final se suma.

o también mediante las siguientes ecuaciones,

$$SSE = SS_{yy} - \frac{SS_{xy}^2}{SS_{xx}}$$

$$\text{siendo } SS_{yy} = \sum (y_i - \bar{y})^2 = \sum y_i^2 - \frac{(\sum y_i)^2}{n}$$

Por lo tanto la variación explicada (SSR) es aquella variabilidad que se capta por medio de la ecuación de regresión. MSR sería la variación media que fue captada por medio de la regresión.

La variación no explicada (SSE) es aquella variabilidad que no fue captada por medio de la regresión. MSE es la variabilidad media que no fue captada por medio de la regresión.

$$\sum_{i=1}^n (Y - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y} - \bar{Y})^2 + \sum_{i=1}^n (Y - \hat{Y})^2$$


Por lo que:

$$SST = SSR + SSE$$

Entonces es necesario probar si la variabilidad que se captó por medio de la regresión es lo suficientemente grande para ser significativa (se debe realizar una prueba de hipótesis); es decir, la SST tiene un valor, el cual se descompone en SSR y en SSE ; si la SSR , al tomar en cuenta los grados de libertad ($df_{\text{Regresión}}$), es significativamente más grande que la SSE (también con sus grados de libertad df_{Error}), entonces la variabilidad captada por la regresión se considera significativa, ya que el MSR es más grande que el MSE . Para saber si es o no más grande se tienen que comparar al encontrar el siguiente cociente:

$$\frac{\frac{SSR}{df_{\text{Regresión}}}}{\frac{SSE}{df_{\text{Error}}}}$$

Ahora la pregunta sería: ¿qué tipo de distribución sigue ese cociente?, saber esto sirve para determinar qué tipo de estadístico utilizar en la prueba de hipótesis que se intenta realizar. Las propiedades estadísticas de la Y por herencia de los errores se pueden representar en una gráfica:



Gráfica 2-1-11 Propiedades estadísticas de Y .

Por lo que las consideraciones para la variable dependiente son:

$$E(Y | X) = E(\beta_0 + \beta_1 X + \varepsilon) = \beta_0 + \beta_1 X$$

$$Var(Y | X) = Var(\beta_0 + \beta_1 X + \varepsilon) = Var(\varepsilon) = \sigma^2$$

El comportamiento probabilístico de Y se puede resumir de la siguiente manera:

$$Y|X \sim \text{Niid}(\beta_0 + \beta_1 X, \sigma^2)$$

Entonces como sabemos que:

$$Y \sim N$$

Por lo que:

$$(Y - \bar{Y}) \sim N$$

Una distribución normal elevada al cuadrado nos da una ji cuadrada, para el caso de la variación explicada media (MSR) se tiene que:

$$\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p-1} \sim \chi^2$$

Donde p es el número de parámetros que se está estimando o con $K+1-1$ grados de libertad, donde K es el número de variables independientes, en el caso de regresión simple siempre $K=1$.

En el caso de la variación no explicada media (MSE) se tiene que:

$$\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-p} \sim \chi^2$$

con $n-p$ grados de libertad.

Una ji cuadrada con $p-1$ grados de libertad, dividida entre otra ji cuadrada con $n-p$ grados de libertad da una distribución $F_{p-1, n-p}$:

$$\frac{\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p-1}}{\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-p}} = \frac{\frac{SSR}{df_{Regresión}}}{\frac{SSE}{df_{Error}}} \sim F_{p-1, n-p}$$

Si la F tiene en el numerador un grado de libertad y en el denominador cualquier número, esto podría manejarse también con una t -student, ya que:

$$\sqrt{F_{1, (n-p)}} = t_{(n-p)}$$

Todo lo anterior está indicando que es necesario utilizar el estadístico F de Fisher, con lo cual se estaría probando si el modelo es estadísticamente significativo. Esto equivale a corroborar las siguientes hipótesis:

$$\begin{aligned} H_0: \beta_1 &= 0 \text{ es decir que } \hat{Y} = \bar{Y} \\ H_1: \beta_1 &\neq 0 \text{ indicando que } \hat{Y} \neq \bar{Y} \end{aligned}$$

En la hipótesis nula (H_0) se prueba que la $\beta_1 = 0$, si se acepta entonces cualquier valor que se le asigne a la variable independiente se nulificará. La ecuación de regresión es:

$$\hat{Y} = \beta_0 + \beta_1 X$$

y como se acepta que $\beta_1 = 0$ entonces:

$$\hat{Y} = \beta_0 + (0)X$$

Es decir, no importa qué valor se le asigne a la X , el término se volverá cero, eso quiere decir que dicha variable no causa efecto en Y , por lo que X deberá eliminarse de la ecuación, y por lo tanto el análisis se termina, esto indica que el mejor pronóstico de la variable dependiente es su promedio, es decir:

$$\hat{Y} = \beta_0 = \bar{Y}$$

Recuerde que:

$$\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{X} = \bar{Y} - (0) \bar{X} = \bar{Y}$$

Si la hipótesis nula (H_0) es rechazada, se prueba que $\beta_1 \neq 0$, si esto sucede entonces cualquier valor que se le asigne a la variable independiente no se nulificará, sino que el pronóstico de la variable dependiente se incrementará o disminuirá según el valor de β_1 y de X , por lo que X deberá quedarse en la ecuación. Pero posteriormente es necesario saber o probar si la beta cero es diferente de cero, es decir:

$$\beta_0 \neq 0$$

Esto se realiza en el siguiente paso (5).

Todo lo anterior es verificable bajo el cumplimiento de H_0 por medio del estadístico F, el cual ya fue especificado como:

$$\frac{\frac{\sum_{i=1}^n (\hat{Y} - \bar{Y})^2}{p-1}}{\frac{\sum_{i=1}^n (Y - \hat{Y})^2}{n-p}} = \frac{\frac{SSR}{df_{Regresión}}}{\frac{SSE}{df_{Error}}} = \frac{MSR}{MSE}$$

El SPSS™ construye el estadístico F de la siguiente forma:

Cuadro de fórmulas 2-1-1 ANOVA

Fuente	Suma de cuadrados (SS)	Grados de libertad	Cuadrados medios (MS)	Valor F
Regresión	$\sum_{i=1}^n (\hat{Y} - \bar{Y})^2$	$p - 1$	$\frac{\sum_{i=1}^n (\hat{Y} - \bar{Y})^2}{p - 1}$	$\frac{\frac{\sum_{i=1}^n (\hat{Y} - \bar{Y})^2}{p - 1}}{\frac{\sum_{i=1}^n (Y - \hat{Y})^2}{n - p}}$
Residual o error	$\sum_{i=1}^n (Y - \hat{Y})^2$	$n - p$	$\frac{\sum_{i=1}^n (Y - \hat{Y})^2}{n - p}$	
Total	$\sum_{i=1}^n (Y - \bar{Y})^2$	$n - 1$		

Con siglas la tabla podría ser resumida de la siguiente manera:

Cuadro de fórmulas 2-1-2 Siglas en ANOVA

Fuente	Suma de cuadrados (SS)	Grados de libertad	Cuadrados medios (MS)	Valor F
Regresión	SSR	$p - 1$	$\frac{SSR}{p - 1} = MSR$	$\frac{MSR}{MSE}$
Residual o error	SSE	$n - p$	$\frac{SSE}{n - p} = MSE$	
Total	SST	$n - 1$		

La variación explicada (*SSR*) es aquella variabilidad que se capta por medio de la ecuación de regresión. *MR* sería la variación media que fue captada por medio de la regresión. Variación no explicada (*SSE*) es aquella variabilidad que no se capta por medio de la regresión. El *MSE* es la variabilidad media que no se capta por medio de la regresión.

Lo que se desea es que el modelo capte la mayor variación posible o el mayor comportamiento posible de *Y*.

De acuerdo con el ejemplo, para realizar la prueba es necesario encontrar las tres variaciones. Para el presente estudio $K = 1$, K es el número de variables independientes y $p = 2$ es el número de parámetros que fueron estimados en la ecuación; además se sabe que $n = 10$, ya que se tienen 10 datos en las variables.

Al realizar los cálculos se tiene:

Tabla 2-1-3 Datos y variaciones

<i>X</i>	<i>Y</i>	$(Y - \text{Prom})^2$		$(Y - \hat{Y})^2$	$(\hat{Y} - \text{Prom})^2$
Publicidad	Ganancia	<i>SST</i>	$\hat{Y}$	<i>SSE</i>	<i>SSR</i>
5	15	1.21	14.59	0.17	2.29
10	24	62.41	24.04	0.00	63.01
7	18	3.61	18.37	0.14	5.14
4	13	9.61	12.70	0.09	11.57
2	9	50.41	8.92	0.01	51.58
3	11	26.01	10.81	0.04	28.00
6	16	0.01	16.48	0.23	0.14
8	21	24.01	20.26	0.55	17.29
9	22	34.81	22.15	0.02	36.58
4	12	16.81	12.70	0.49	11.57
Suma =	58	161		1.730	227.170
Promedio =	5.80	16.10			
<i>n</i> =	10				

A continuación, los resultados se sustituyen en la fórmula:

$$F_c = \frac{\frac{SSR}{df_{\text{Regresión}}}}{\frac{SSE}{df_{\text{Error}}}} = \frac{MSR}{MSE} = \frac{\frac{227.17}{2-1}}{\frac{1.73}{10-2}} = \frac{227.17}{0.216}$$

Por lo que:

$$F_c = 1\,050.767$$

Los resultados del SPSS™ aparecen en la tabla ANOVA:

Dibujo 2-1-3 Tabla ANOVA^b

Modelo	Suma de cuadrados	gl	Media cuadrática	F	Sig.
1 Regresión	227.170	1	227.170	1 050.767	.000 ^a
Residual	1.730	8	.216		
Total	228.900	9			

^a Variables predictorias: (constante), publicidad.

^b Variable dependiente: ganancia.

Así que sólo resta probar si se acepta o rechaza la hipótesis nula. Para realizar una prueba de hipótesis se requieren 5 pasos:

1. Formular las hipótesis:

$$H_0 : \beta_1 = 0 \text{ es decir que } \hat{Y} = \bar{Y}$$

$$H_1 : \beta_1 \neq 0 \text{ indicando que } \hat{Y} \neq \bar{Y}$$

2. Encontrar el valor estadístico de prueba o el calculado:

$$F_c = 1050.767$$

3. Encontrar el valor del estadístico teórico en la tabla correspondiente,¹³⁷ al suponer que esta prueba se realizará con un nivel de significancia de 5%, es decir el nivel de confianza es de 95%:

$$F_{t, \alpha=0.05, p-1=2-1=1, n-p=10-2=8} = 5.318$$

El cual fue encontrado de la siguiente manera:

Tabla 2-1-4 Parte de la tabla F

gl	α	1	2
7	0.100	3.589	3.257
	0.050	5.591	4.737
	0.025	8.073	6.542
	0.010	12.246	9.547
	0.005	16.235	12.404
8	0.100	3.458	3.113
	0.050	5.318	4.459
	0.025	7.571	6.059
	0.010	11.259	8.649
	0.005	14.688	11.043


4. Decisión: para rechazar la H_0 es necesario que:

$$F_c > F_{t, \alpha, p-1, n-p}$$

Por lo que:

$$1\ 050.767 > 5.138 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



¹³⁷ La tabla F se encuentra en el anexo 2.8 "Tabla Kolmogorov-Smirnov-Lilliefors".

De igual manera para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig}) < \alpha$$

Por lo que:

$$0.000 < 0.05 \text{ se rechaza } H_0$$

5. Toma de decisiones: como se rechazó la hipótesis nula entonces se concluye que:

$\beta_1 \neq 0$, entonces cualquier valor que se le asigne a la variable independiente no nulificará el segundo término, sino que el pronóstico de la variable dependiente se incrementará porque β_1 es positiva (se disminuirá cuando β_1 sea negativo) y eso también significa que X (o sea la variable publicidad) deberá quedarse en la ecuación. Por lo que es necesario ahora saber si

$$\beta_0 \neq 0$$

Esto se realiza en la siguiente prueba.

A2.1.5 Prueba individual para cada coeficiente

Con los resultados del paso anterior se tienen los elementos necesarios para probar estadísticamente cada uno de los parámetros de la regresión. La prueba de hipótesis sirve para corroborar si cada beta es o no estadística o significativamente diferente a cero. Esto equivale a probar las siguientes hipótesis:

$$H_0 : \beta_i = 0 \text{ donde } i = 0, 1$$

$$H_1 : \beta_i \neq 0 \text{ donde } i \neq 0, 1$$

O bien:

$$H_0 : \beta_i = 0 \text{ donde } i = 0, 1$$

$$H_a : \beta_i \neq 0 \text{ donde } i \neq 0, 1$$

Estas pruebas de hipótesis se deberán realizar para cada β que existe en la ecuación (tanto para β_1 como para β_0).

Pero antes es necesario estimar la varianza de los errores para calcular cualquier varianza se tiene:

$$Var(\varepsilon) = \sigma^2 = \frac{\sum_{i=1}^n (\varepsilon_i - \bar{\varepsilon})^2}{gl(\varepsilon)}$$

Y se conoce que el promedio de los errores es cero (por los supuestos de los errores):

$$Var(\varepsilon) = \sigma^2 = \frac{\sum_{i=1}^n (\varepsilon_i - 0)^2}{gl(\varepsilon)}$$

También se sabe que los errores o residuales:

$$e = Y - \bar{Y}$$

Al sustituir eso en la ecuación anterior se tiene:

$$Var(\varepsilon) = \sigma^2 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - p} = MSE$$

En regresión simple siempre $p = 2$. Entonces el mejor estimador de la varianza de los errores es el que se encuentra en la tabla del ANOVA:

Dibujo 2-1-4 Tabla ANOVA^b

Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	227.170	1	227.170	1 050.767	.000 ^a
	Residual	1.730	8	.216		
	Total	228.900	9			

^a Variables predictoras: (constante), publicidad.^b Variable dependiente: ganancia.

Y su valor es

$$MSE = 0.216$$

Ahora bien, si a la varianza se le saca raíz cuadrada, esto da como resultado la desviación estándar o el error estándar del estimado, el cual sería:

$$S_e = \sqrt{\frac{\sum_{i=1}^n (Y - \hat{Y})^2}{n - p}} = \sqrt{MSE} = \hat{\sigma}$$

$$S_e = \sqrt{\frac{1.73}{10 - 2}} = \sqrt{0.216} = 0.465$$

El SPSS[™] lo pone en la siguiente figura:

Dibujo 2-1-5 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.^b Variable dependiente: ganancia.

Lo que primero se debe realizar es la prueba de hipótesis para β_1 y luego probar β_0 . Dichos procedimientos se explican a continuación.

A2.1.6 Prueba individual para la pendiente

Esta prueba es redundante ya que esto se realizó en el inciso anterior, debido a que

$$\sqrt{F_{1,(n-p)}} = t_{(n-p)}$$

1. Hipótesis:

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

Como ya se dijo en el apartado anterior es igual llevar a cabo esta prueba con la F que con la t-student, siempre y cuando sea regresión simple; es decir en la hipótesis nula (H_0) se prueba que $\beta_1 = 0$, si dicha hipótesis es aceptada entonces la variable que acompaña a β_1 deberá salir de la ecuación porque, como ya se explicó, cualquier valor que se le asigne a la variable independiente se nulificará. Como la ecuación de regresión es:

$$\hat{Y} = \beta_0 + \beta_1 X$$

y como aceptamos que $\beta_1 = 0$ entonces:

$$\hat{Y} = \beta_0 + (0)X$$

Cualquier valor que se le asigne a la X , el término lineal, se volverá cero, eso quiere decir que la variable no causa efecto en Y por lo que X deberá salir de la ecuación; el análisis termina y el mejor pronóstico de la variable dependiente es su promedio:

$$\hat{Y} = \beta_0 = \bar{Y}$$

Recuerda que:

$$\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{X} = \bar{Y} - (0)\bar{X} = \bar{Y}$$

Si la hipótesis nula (H_0) es rechazada se prueba que $\beta_1 \neq 0$, entonces cualquier valor que se le asigne a la variable independiente no se nulificará, sino que el pronóstico de la variable dependiente se incrementará o disminuirá según el valor de β_1 y de X , por lo que X deberá quedarse en la ecuación.

2. Encontrar el valor del estadístico calculado: para realizar esto es necesario saber las consideraciones que se hacen para el parámetro, las cuales son:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{XX}}\right)$$

Eso quiere decir que el estadístico que se deberá utilizar es una Z o una t -student, en este caso se estima la varianza de los errores por lo que el estadístico correcto es la t , el cual se muestra a continuación:

$$t_c: \frac{b_1}{S_{b_1}}$$

En donde S_{b_1} es el error estándar de b_1 , el cual se calcula como sigue:

$$S_{b_1} = \sqrt{\frac{MSE}{SS_{XX}}} = \frac{S_e}{\sqrt{SS_{XX}}}$$

Por lo que la fórmula final sería la siguiente:

$$t_c = \frac{b_1 - \beta_{1BajoH_0}}{\frac{S_e}{\sqrt{SS_{XX}}}} = \frac{\hat{\beta}_1 - 0}{\frac{S_e}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2}}}$$

De acuerdo con el ejemplo se tienen los siguientes datos:

Tabla 2-1-5 Datos

X Publicidad	Y Ganancia	X^2	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
5	15	25	14.59	0.17
10	24	100	24.04	0.00
7	18	49	18.37	0.14
4	13	16	12.70	0.09
2	9	4	8.92	0.01
3	11	9	10.81	0.04
6	16	36	16.48	0.23

(continúa)

Tabla 2-1-5 Datos (continuación)

	X Publicidad	Y Ganancia	X ²	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
	8	21	64	20.26	0.55
	9	22	81	22.15	0.02
	4	12	16	12.70	0.49
Suma =	58	161	400		0.730
Promedio =	5.80	16.10			

Al sustituir en la fórmula anterior tenemos que:

$$t_c = \frac{b_1}{\frac{S_e}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2}}} = \frac{1.89}{\frac{\sqrt{1.73}}{\sqrt{10-2}}} = \frac{1.89}{\frac{0.216}{\sqrt{63.6}}} =$$

Lo que da como resultado:

$$t_c = \frac{1.89}{0.058} = 32.416$$

En el listado del SPSS™ los resultados anteriores aparecen en la tabla de los coeficientes:

Dibujo 2-1-6 Tabla de los coeficientes


Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable de pendiente: ganancia.

Como se ve los resultados son los mismos. Así que sólo resta probar si se acepta o rechaza la hipótesis nula.

3. Encontrar el valor del estadístico teórico a 95% de confianza, se busca en la tabla t-student:

Tabla 2-1-6 Parte de la tabla t-student




gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041

(continúa)

Tabla 2-1-6 Parte de la tabla t-student (continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



Por lo que el estadístico teórico sería:

$$t_{t, \frac{\alpha}{2}} = \frac{0.05}{2} = 0.025, n-p = 10-2 = 8 = 2.306$$


4. Decisión: para rechazar la H_0 es necesario que,

$$|t_c| > t_{t, \frac{\alpha}{2}, n-p}$$

Por lo que:

$$32.416 > 2.306 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico calculado caiga en la zona de rechazo:



De igual forma se tendría que para rechazar la H_0 es necesario que:

$$P\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.000 < 0.05 \text{ se rechaza } H_0$$

Como otra alternativa se podría llevar a cabo esta prueba por medio del intervalo de confianza que se puede calcular para β_1 , el cual se encuentra con la fórmula:

$$b_1 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) (S_{b_1})$$

O bien:

$$b_1 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \frac{S_\varepsilon}{\sqrt{SS_{XX}}}$$

Por lo que:

$$b_1 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \frac{S_\varepsilon}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2}}$$


Volviendo al ejemplo:

Tabla 2-1-7 Datos


	X Publicidad	Y Ganancia	X^2	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
	5	15	25	14.59	0.17
	10	24	100	24.04	0.00
	7	18	49	18.37	0.14
	4	13	16	12.70	0.09
	2	9	4	8.92	0.01
	3	11	9	10.81	0.04
	6	16	36	16.48	0.23
	8	21	64	20.26	0.55
	9	22	81	22.15	0.02
	4	12	16	12.70	0.49
Suma =	58	161	400		1.730
Promedio =	5.80	16.10			

El valor fue encontrado con anterioridad en la t-student.

Tabla 2-1-8 Parte de la tabla t-student



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



$$t_{t, \frac{\alpha}{2}} = \frac{0.05}{2=0.25, n-p=10-2=8} = 2.306$$

Al sustituir en la fórmula los valores se tiene que:

$$b_1 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \frac{S_e}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2}} = 1.89 \pm 2.306 \frac{\sqrt{\frac{1.73}{10-2}}}{\sqrt{400 - 10 * (5.8)^2}}$$

Lo que da como resultado

$$1.89 \pm 2.306 * 0.058$$

Entonces β_1 oscila entre:

$$1.755 \leq \beta_1 \leq 2.024$$

En el listado del SPSSTM los resultados anteriores aparecen en la tabla coeficientes:

Dibujo 2-1-7 Tabla de los coeficientes

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable dependencia: ganancia.

Además se puede afirmar que como en el intervalo:

$$1.755 \leq \beta_1 \leq 2.024$$

No se incluye el cero, por lo que se rechaza la hipótesis nula.

5. Toma de decisiones: como se rechazó la hipótesis nula entonces se concluye que:

$$\beta_1 \neq 0$$

La variable que acompaña a β_1 deberá quedarse en la ecuación; en este caso publicidad se queda porque sí existe una relación causa-efecto entre publicidad y ganancia.

Eso significa que $\beta_1 \neq 0$ por lo que cualquier valor que se le asigne a la variable independiente no se nulificará, sino que el pronóstico de la variable dependiente se incrementará por que β_1 es positiva (o disminuirá cuando β_1 sea negativa); eso también significa que X (o sea la variable publicidad) deberá quedarse en la ecuación. Por lo que es necesario ahora saber si la $\beta_1 \neq 0$.

A2.1.7 Prueba individual para la constante

Cabe aclarar que esta hipótesis se prueba bajo la consideración de que las estimaciones sobre el otro parámetro permanecen fijas. Es decir que no varían y que en realidad tiene un significado que sea cero,¹³⁸ suponga que en este caso sí tiene un significado específico, por lo que se procederá a realizar la prueba de hipótesis:

1. Hipótesis:

$$H_0: \beta_0 = 0$$

$$H_1: \beta_0 \neq 0$$


En la hipótesis nula (H_0) se prueba que la $\beta_1 = 0$, si dicha hipótesis es aceptada entonces la línea de regresión pasará por el origen:



¹³⁸ En este caso el significado de cero indica que, si la compañía no invierte en publicidad, no se tendrán ganancias, lo cual no sucede con regularidad.

Si esto sucede, es decir que se acepte la hipótesis nula (H_0), que $\beta_0 = 0$, hay que volver a calcular β_1 ya que la línea adquiere mayor pendiente al quitar a β_0 .

Si la hipótesis nula (H_0) es rechazada y se prueba que $\beta_0 \neq 0$ entonces el valor que tiene es verdadero β_0 :



Si se rechaza la hipótesis nula se acepta que $\beta_0 \neq 0$ eso significa que se usarán los valores β_0 y β_1 para calcular las betas.

2. Encontrar el valor del estadístico calculado: las consideraciones que se hacen para el parámetro son:

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}}\right)\right)$$

Eso quiere decir que el estadístico que se debe utilizar es una Z o una t-student, en este caso se está estimando la varianza de los errores por lo que el estadístico correcto es la t, el cual se muestra a continuación:

$$t_c: \frac{b_1}{S_{b_1}}$$

En donde S_{b_0} es el error estándar de b_0 , que se calcula como sigue:

$$S_{b_0} = \sqrt{MSE \left[\frac{1}{n} + \frac{\bar{X}^2}{SS_{XX}} \right]} = S_e \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

Por lo que la fórmula final sería la siguiente:

$$t_c = \frac{b_0 - \beta_{0BajoH_0}}{S_e \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{SS_{XX}} \right]}} = \frac{b_0 - 0}{S_e \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}}$$

De acuerdo con el ejemplo se tienen los datos:

Tabla 2-1-9 Datos

X Publicidad	Y Ganancia	X ²	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
5	15	25	14.59	0.17
10	24	100	24.04	0.00
7	18	49	18.37	0.14
4	13	16	12.70	0.09
2	9	4	8.92	0.01
3	11	9	10.81	0.04
6	16	36	16.48	0.23
8	21	64	20.26	0.55

(continúa)

Tabla 2-1-9 Datos (continuación)

	X Publicidad	Y Ganancia	X ²	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
	9	22	81	22.15	0.02
	4	12	16	12.70	0.49
Suma =	58	161	400		0.730
Promedio =	5.80	16.10			

Al sustituir en la fórmula anterior se tiene que:

$$t_c = \frac{b_0}{S_e \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}} = \frac{5.138}{\sqrt{\frac{1.73}{10-2} \left[\frac{1}{10} + \frac{5.80^2}{400 - 10 * (5.8)^2} \right]}}$$

Lo que da como resultado:

$$t_c = \frac{5.138}{0.216 \sqrt{\left[0.1 + \frac{33.64}{63.6} \right]}} = \frac{5.138}{0.369} = 13.935$$

En el listado del SPSS™ los resultados anteriores aparecen en la tabla de los coeficientes:

Dibujo 2-1-8 Tabla de los coeficientes


Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable dependiente: ganancia.

Como se ve los resultados son los mismos. Así que sólo resta probar si se acepta o rechaza la hipótesis nula.

3. Encontrar el valor del estadístico teórico a 95% de confianza, se busca en la tabla t-student:

Tabla 2-1-10 Parte de la tabla t-student.




gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781

(continúa)

Tabla 2-1-10 Parte de la tabla t-student (continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



Por lo que el estadístico teórico sería:

$$t_{t, \frac{\alpha}{2} = 0.025, n-p = 10-2 = 8} = 2.306$$


4. Decisión: para rechazar la H_0 es necesario que,

$$|t_c| > t_{t, \frac{\alpha}{2}, n-p}$$

Por lo que:

$$13.935 > 2.306 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico calculado caiga en la zona de rechazo:



También para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Por lo que:

$$0.000 < 0.05 \text{ se rechaza } H_0$$

Como otra alternativa se podría llevar a cabo esta prueba por medio del intervalo de confianza que se puede calcular para β_0 , el cual se encuentra con la fórmula:

$$b_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) (S_{b_0})$$

O bien:

$$b_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \sqrt{MSE \left[\frac{1}{n} + \frac{\bar{X}^2}{SS_{XX}} \right]}$$

Por lo que:

$$b_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_\varepsilon \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$


De acuerdo con el ejemplo:

Tabla 2-1-11 Datos


	X Publicidad	Y Ganancia	X^2	$\hat{Y}$	$(Y - \hat{Y})^2$ SSE
	5	15	25	14.59	0.17
	10	24	100	24.04	0.00
	7	18	49	18.37	0.14
	4	13	16	12.70	0.09
	2	9	4	8.92	0.01
	3	11	9	10.81	0.04
	6	16	36	16.48	0.23
	8	21	64	20.26	0.55
	9	22	81	22.15	0.02
	4	12	16	12.70	0.49
Suma =	58	161	400		1.730
Promedio =	5.80	16.10			

El valor de la tabla t-student se encontró con anterioridad:

Tabla 2-1-10 Parte de la tabla t-student



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



$$t_{t, \frac{\alpha}{2} = 0.05, n-p=10-2=8} = 2.306$$

Al sustituir en la fórmula los valores se tiene que:

$$b_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_e \sqrt{\left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]} = 5.138 \pm 2.306 * \sqrt{\frac{1.73}{10-2}} \sqrt{\left[\frac{1}{10} + \frac{5.8^2}{400 - 10 * (5.8)^2} \right]}$$

Lo que da como resultado

$$5.138 \pm 2.306 * 0.369$$

Entonces β_1 oscila entre:

$$4.288 \leq \beta_0 \leq 5.989$$

En el listado del SPSSTM los resultados anteriores aparecen en la tabla coeficientes:

Dibujo 2-1-9 Tabla de los coeficientes

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable dependiente: ganancia.

Además se puede afirmar que como en el intervalo:

$$4.288 \leq \beta_0 \leq 5.989$$

no se incluye el cero se rechaza la hipótesis nula.

5. Toma de decisiones: como se rechazó la hipótesis nula entonces se concluye que:

$$\beta_0 \neq 0$$

La intersección en el eje de la variable dependiente no es en el origen, por lo que toma el valor que tiene β_0 . Como se rechazó la hipótesis nula se probó que $\beta_0 \neq 0$ entonces el valor que se tiene para β_0 es correcto.

A2.1.7.1 Evaluación del modelo

Una vez que ya se probó la ecuación en forma global y posteriormente de modo individual, se procede a evaluar lo adecuado del modelo, esto se realiza al calcular:

- Coeficiente de correlación.
- Coeficiente de determinación.
- Coeficiente de determinación ajustado o corregido.
- Error estándar del estimado.

Los cuales se explican a detalle a continuación.

A2.1.7.2 Coeficiente de correlación múltiple

Este coeficiente es múltiple¹³⁹ y en términos porcentuales indica qué tanto la variable independiente (X) afecta a la dependiente (Y); la fórmula para calcularlo es:

$$r_{(Y|X)} = R_{(Y|X)} = \frac{Cov(X, Y)}{\sqrt{Var(X)}\sqrt{Var(Y)}}$$

¹³⁹ Se le denomina *múltiple* porque con él se encuentra un valor global, aunque en este caso es bivariado ya que sólo se encuentra para la variable X y para Y; no tiene signo por lo que su valor oscila entre cero y 1; para saber qué signo debería tener es necesario ver qué signo tiene b_1 , si éste es negativo indica que la relación entre X y Y es inversa, por el contrario si el signo de b_1 es positivo indica una relación directa. Sin embargo, cuando se tienen dos o más variables independientes, dicho coeficiente no tiene algún significado.

Al sustituir las fórmulas en las covarianzas (Cov) y en las varianzas (Var), se tiene:

$$R_{(Y|X)} = \frac{\sum_{i=1}^n (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum_{i=1}^n (X - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y - \bar{Y})^2}}$$

Ahora con las fórmulas reducidas:

$$R_{(Y|X)} = \frac{\sum_{i=1}^n XY - n\bar{X}\bar{Y}}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2} \sqrt{\sum_{i=1}^n Y^2 - n\bar{Y}^2}}$$




Otra forma de encontrar dicho coeficiente sería por medio del coeficiente de determinación,¹⁴⁰ para obtenerlo se haría lo siguiente:

$$r_{(Y|X)} = R_{(Y|X)} = \sqrt{R^2}$$

Si se encuentra de la forma pasada, el coeficiente de correlación múltiple no tiene signo, por lo que, el valor que salga de la fórmula anterior deberá ser positivo; así los valores de este coeficiente múltiple oscilan en el rango de:

$$0 \leq r_{Y|X} \leq 1$$

Un valor cercano a cero indica que la variable X (independiente) no explica casi nada por lo que no está asociada o no tiene una relación lineal¹⁴¹ con la variable dependiente (Y), un valor cercano a 1 indica que hay una fuerte asociación o relación lineal entre la X y la Y , o que la relación lineal es de casi 100%. Gráficamente en dos dimensiones sería de la siguiente manera:


	Existe una relación lineal perfecta entre la X y la Y; lo cual indica que ésta es de 100%; por lo que su $R = 1$
	Existe una relación lineal perfecta entre la X y la Y; lo cual indica que ésta es de 100%; por lo que su $R = -1$
	Existe una relación lineal casi perfecta entre la X y la Y; lo cual indica que las variables están relacionadas en menos de 100%; por lo que su $0 < R < 1$

(continúa)

¹⁴⁰ Dicho coeficiente se mencionará más adelante.

¹⁴¹ El que no se tenga una asociación lineal no implica que no sea no lineal, ya que al no tener asociación lineal puede tener otro tipo de relación (cuadrática, cúbica, etc.); esto es un punto importante.

(continuación)

	Existe una relación lineal casi perfecta entre la X y la Y; lo cual indica que las variables están relacionadas en menos de 100%; por lo que su $-1 < R < 0$
	No existe una relación lineal entre la X y la Y; lo cual indica que no hay relación; por lo que su $R \approx 0$

Dicho coeficiente puede ser estimado como $R = \beta$.

Se tiene la siguiente información del ejemplo:

Tabla 2-1-13 Valores

	X Publicidad	Y Ganancia	$X * Y$	X^2	Y^2
	5	15	75	25	225
	10	24	240	100	576
	7	18	126	49	324
	4	13	52	16	169
	2	9	18	4	81
	3	11	33	9	121
	6	16	96	36	256
	8	21	168	64	441
	9	22	198	81	484
	4	12	48	16	144
Suma =	58	161	1 054	400	2 821
Promedio =	5.80	16.10			

Al sustituir los valores en la fórmula se tiene que:

$$R_{(Y|X)} = \frac{\sum_{i=1}^n XY - n\bar{X}\bar{Y}}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2} \sqrt{\sum_{i=1}^n Y^2 - n\bar{Y}^2}} = \frac{1054 - 20 * 30 - 16.1}{\sqrt{400 - 10 * 5.8^2} \sqrt{2.025 - 10 * 16.1^2}}$$

El resultado es:

$$R_{(Y|X)} = \frac{120.2}{\sqrt{63.6} \sqrt{220.9}} = 0.990$$

Por lo que se puede decir que X tiene una alta asociación lineal con Y , ya que el valor es cercano a 1 y esa relación¹⁴² es bastante buena o bien la X está asociada con la variable dependiente Y en un 99.60%.

¹⁴² Es importante recalcar que solamente cuando este coeficiente se calcula para dos variables, es decir cuando es bivariado, tiene esta interpretación; cuando las variables son más no tiene ningún significado.

En el listado del SPSS™ el resultado anterior aparece en la tabla de resumen del modelo:

Dibujo 2-1-10 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

A2.1.8 Coeficiente de determinación

Este coeficiente, en términos porcentuales, indica cuánta de toda la variabilidad o el comportamiento que tiene la variable dependiente se capta o explica por la ecuación de regresión; el modo de obtener dicho coeficiente sería:

$$R^2 = \frac{\text{Variación Explicada}}{\text{Variación Total}} = \frac{SSR}{SST}$$

O bien por medio del coeficiente de correlación múltiple:

$$R^2 = (R_{(Y|X)})^2 = \left[\frac{\sum_{i=1}^n XY - n\bar{X}\bar{Y}}{\sqrt{\sum_{i=1}^n X^2 - n\bar{X}^2} \sqrt{\sum_{i=1}^n Y^2 - n\bar{Y}^2}} \right]^2$$

Dicho coeficiente puede ser estimado como

$$R^2 = \hat{\rho}^2.$$

Los valores de este coeficiente oscilan entre:

$$0 \leq R^2 \leq 1$$

Un valor cercano a cero indica que no se captó casi nada de la variación total de Y, un valor cercano a 1 señala que casi 100% de la variabilidad fue captada. Lo que interesa de un modelo es que capte la mayor variación, entonces es preferible que sea cercano a 1.

De acuerdo con el ejemplo se tiene la siguiente información:

Tabla 2-1-14 Valores

	X Publicidad	Y Ganancia	X * Y	X ²	Y ²	(Y – Prom) ²		(Y – Ŷ) ²	(Ŷ – Prom) ²
						SST	Ŷ	SSE	SSR
	5	15	75	25	225	1.21	14.59	0.17	2.29
	10	24	240	100	576	62.41	24.04	0.00	63.01
	7	18	126	49	324	3.61	18.37	0.14	5.14
	4	13	52	16	169	9.61	12.70	0.09	11.57
	2	9	18	4	81	50.41	8.92	0.01	51.58
	3	11	33	9	121	26.01	10.81	0.04	28.00
	6	16	96	36	256	0.01	16.48	0.23	0.14
	8	21	168	64	441	24.01	20.26	0.55	17.29
	9	22	198	81	484	34.81	22.15	0.02	36.58
	4	12	48	16	144	16.81	12.70	0.49	11.57
Suma =	58	161	1 054	400	2 821	228.900		1.730	227.170
Promedio =	5.80	16.10							

Por lo que el cálculo del coeficiente de determinación sería:

$$R^2 = \frac{SSR}{SST} = \frac{227.17}{228.9} = 0.992$$

La información¹⁴³ anterior se puede obtener de la tabla ANOVA que arroja el SPSS™, la cual se muestra a continuación:

Dibujo 2-1-11 Tabla ANOVA^b

Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	227.170	1	227.170	1 050.767	.000 ^a
	Residual	1.730	8	.216		
	Total	228.900	9			

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

O bien se puede obtener por medio del coeficiente de correlación múltiple:

$$R^2 = (R_{(Y|X)})^2 = \left[\frac{1\,054 - 10 * 5.8 * 16.1}{\sqrt{400 - 10 * 5.8^2} \sqrt{2\,821 - 10 * 16.1^2}} \right]^2 = (0.996)^2 = 0.992$$

Esto significa que de 100% de la variación o del comportamiento que tiene la variable dependiente (99.2%) fue captada por la ecuación, y queda sin explicar 0.08%, este último porcentaje se obtuvo de la siguiente manera:

$$1 - 0.992 = 0.008$$

Esto significa que el ajuste fue casi perfecto.

En el listado del SPSS™ los resultados anteriores aparecen en la tabla de resumen del modelo:

Dibujo 2-1-12 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

A2.1.9 Error estándar del estimado

Este valor indica qué tanta dispersión se tiene alrededor de la línea de regresión en todas las parejas de los datos de (X, Y).

$$S_e \sqrt{\frac{\sum_{i=1}^n (Y - \hat{Y})^2}{n - p}} = \sqrt{MSE} = \hat{\sigma}$$

Los valores de esta medida oscilan entre:

$$0 \leq \hat{\sigma} \leq \infty$$

¹⁴³ Dichos valores tienen una mejor comprensión en el tema de prueba de hipótesis del modelo o global, que fue explicado con anterioridad.

Un valor cercano a cero indica que no existe casi nada de dispersión a través de la línea de regresión; es decir, casi todos los valores (o las parejas de X y de Y) están sobre la línea de regresión, un valor grande indica que los valores están muy dispersos o alejados de la línea de regresión. Entonces lo que interesa es que esta medida sea lo más pequeña posible o lo más cercana a cero.

De acuerdo con el ejemplo se tiene la siguiente información:

Tabla 2-1-15 Valores

X Publicidad	Y Ganancia	$(Y - \text{Prom})^2$		$(Y - \hat{Y})^2$	$(\hat{Y} - \text{Prom})^2$
		SST	$\hat{Y}$	SSE	SSR
5	15	1.21	14.59	0.17	2.29
10	24	62.41	24.04	0.00	63.01
7	18	3.61	18.37	0.14	5.14
4	13	9.61	12.70	0.09	11.57
2	9	50.41	8.92	0.01	51.58
3	11	26.01	10.81	0.04	28.00
6	16	0.01	16.48	0.23	0.14
8	21	24.01	20.26	0.55	17.29
9	22	34.81	22.15	0.02	36.58
4	12	16.81	12.70	0.49	11.57
Suma =	58	161	228.900	1.730	227.170

Los resultados se muestran en la tabla del ANOVA; el SPSS™ arroja esta tabla con la siguiente información:

Dibujo 2-1-13 Tabla ANOVA

ANOVA ^b						
Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	227.170	1	227.170	1 050.767	.000 ^a
	Residual	1.730	8	.216		
	Total	228.900	9			

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Al sustituir los valores en la fórmula se tiene que:

$$S_e \sqrt{\frac{1.73}{10 - 2}} = \sqrt{0.216} = 0.465$$

Por lo que el resultado de la estimación puntual sería el siguiente:

$$\hat{\sigma} = 0.465$$

Ahora, la pregunta es ¿la dispersión es pequeña? La respuesta es ¿comparado con qué?, es necesario tener otra dispersión.

En el listado del SPSS™ los resultados anteriores aparecen en la tabla de resumen:

Dibujo 2-1-14 Tabla de resumen.

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Al finalizar este punto ya es posible realizar los pronósticos, es decir, las estimaciones tanto puntuales como por intervalo. Hasta este punto se han hecho muchas consideraciones estadísticas sobre las distribuciones que sigue la variable dependiente y los parámetros, por lo que es de vital importancia saber si esas consideraciones fueron hechas en forma correcta. Éstas provienen de los supuestos de los errores, los cuales se verán a continuación.

A2.1.10 Supuestos de los errores

Los supuestos de los errores se pueden representar de la siguiente forma:

$$\varepsilon \sim Niid(\mu = 0, \sigma^2 \text{ constantes})$$

Lo anterior indica que los errores siguen una distribución normal (N), idénticamente distribuidos (id), independientes (id), con media o valor esperado igual a cero ($\mu = 0$) y varianzas constantes, pero desconocidas (σ^2), otra notación más resumida está dada por la siguiente expresión:

$$\varepsilon \sim Nid(0, \hat{\sigma}^2)$$

Otra explicación sería que la distribución probabilística de los errores (población) es una normal, idénticamente distribuidos; cada uno de los errores asociados con cada valor correspondiente de Y son independientes, el valor esperado (la media) de los errores es cero y la varianza (dispersión o variabilidad) de los errores es desconocida, pero cada valor de X y de Y son constantes. Basta decir que si alguno de ellos no se cumple no se debería haber realizado alguna de las pruebas (es importante recalcar que el uso de la F y de la t -student es debido a que la Y debe provenir de la población normal).


Ahora se probarán los supuestos en las residuales del ejemplo que se está utilizando.

A2.1.10.1 Distribución normal o normalidad

Cuando la normalidad no se cumple se dice que este supuesto es violado; si esto ocurre entonces no pueden usarse la prueba global (por medio de la F) y las pruebas individuales (por medio de la t -student). Este supuesto se puede verificar de muchas maneras, aquí sólo se verán algunas.

A2.1.10.2 Histograma

Para esto es necesario formar una distribución de frecuencia con los errores y realizar un histograma. En el listado del SPSS™ los resultados anteriores aparecen en la gráfica de histograma:



Gráfica 2-1-12 Histograma.

Nótese la línea delgada y en forma de campana, está para que el investigador vea si en realidad tiene un comportamiento normal o en forma de campana. Podría decirse que en ciertas partes da un comportamiento normal y en otras no.

A2.1.10.3 Tendencia a la simetría

Para averiguar si se cumple es necesario saber que para una distribución simétrica y en forma de campana:

- 68.27% de los valores caería dentro de 1 desviación estándar con respecto a la media, esto es: $\varepsilon \pm 1\sigma$.
- 95.45% de los valores caería dentro de 2 desviación estándar con respecto a la media, esto es: $\varepsilon \pm 2\sigma$.
- 99.73% de los valores caería dentro de 3 desviación estándar con respecto a la media, esto es: $\varepsilon \pm 3\sigma$.

Esto indica que en la muestra se encontrarían residuales (errores en la población) fuera del rango de ± 3 ; para poder realizarlo es necesario estandarizar los residuales, la fórmula sería:

$$Z_{\text{Residual}_i} = \frac{\text{Residual}_i - \bar{\varepsilon}}{S_{\varepsilon}}$$

Como el promedio de los residuales es cero se tiene lo siguiente:

$$Z_{\text{Residual}_i} = \frac{\text{Residual}_i}{S_{\varepsilon}}$$

Es necesario tener los residuales y la desviación estándar¹⁴⁴ de los errores del ejemplo; la información necesaria se presenta a continuación.

Dibujo 2-1-15 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregido	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Tabla 2-1-16 Valores

X Publicidad	Y Ganancia	$\hat{Y}$	Residual ($Y - \hat{Y}$) ²
5	15	14.59	0.41
10	24	24.04	-0.04
7	18	18.37	-0.37
4	13	12.70	0.30
2	9	8.92	0.08
3	11	10.81	0.19
6	16	16.48	-0.48
8	21	20.26	0.74
9	22	22.15	-0.15
4	12	12.70	-0.70
Suma =	58	161	0.000
Promedio =	5.80	16.10	0.000

¹⁴⁴ El error estándar del estimado es sinónimo de la desviación estándar de los residuales.

Por lo que para estandarizar el primer residual se tiene que:

$$Z_{Residual_1} = \frac{0.41}{0.465} = 1.9055$$

Al estandarizar el segundo error se tiene que:

$$Z_{Residual_1} = \frac{-0.04}{0.465} = -0.1745$$

El procedimiento continúa para cada residual. Los resultados se presentan en la siguiente tabla:

Tabla 2-1-17 Valores

<i>X</i> Publicidad	<i>Y</i> Ganancia		Residual	Residual
		$\hat{Y}$	$(Y - \hat{Y})^2$	Estandarizado
5	15	14.59	0.41	0.8860
10	24	24.04	-0.04	-0.0812
7	18	18.37	-0.37	-0.7913
4	13	12.70	0.30	0.6493
2	9	8.92	0.08	0.1758
3	11	10.81	0.19	0.4126
6	16	16.48	-0.48	-1.0280
8	21	20.26	0.74	1.5961
9	22	22.15	-0.15	-0.3179
4	12	12.70	-0.70	-1.5014
Suma =	58	161	0.000	0.000
Promedio =	5.80	16.10	0.000	0.000

Los resultados ordenados se presentan en la siguiente tabla:

Tabla 2-1-18 Valores

Residual
Estandarizado
Ordenados
-1.5014
-1.0280
-0.7913
-0.3179
-0.0812
0.1758
0.4126
0.6493
0.8860
1.5961

Ahora se contabilizarán los errores que caen en ± 1 , los cuales fueron puestos y sombreados en la segunda columna de la siguiente tabla; en la tercera columna se realizó lo mismo pero con ± 2 y en la cuarta columna con ± 3 :

Tabla 2-1-19 Valores

Residual	Residual	Residual	Residual
Estandarizado	Estandarizado	Estandarizado	Estandarizado
Ordenados	± 1	± 2	± 3
-1.5014	-1.5014	-1.5014	-1.5014
-1.0280	-1.0280	-1.0280	-1.0280
-0.7913	-0.7913	-0.7913	-0.7913
-0.3179	-0.3179	-0.3179	-0.3179
-0.0812	-0.0812	-0.0812	-0.0812
0.1758	0.1758	0.1758	0.1758
0.4126	0.4126	0.4126	0.4126
0.6493	0.6493	0.6493	0.6493
0.8860	0.8860	0.8860	0.8860
1.5961	1.5961	1.5961	1.5961

De 10 residuales los que se encuentran entre ± 1 son 8 (80%).

Según la extensión del teorema dice que a ± 1 se debe tener 68.27%, por lo que 80% es bastante cercano. Ahora se contabiliza a ± 2 , este conteo se encuentra en la tercera columna de la tabla anterior; son 10 los que caen en ± 2 , es decir, 100% cae realmente y teóricamente sería 95.45%; por último ningún error estandarizado excede del límite de ± 3 , por lo que 100% entraría en ese rango, observe que se debería cumplir 99.73%. Con lo anterior se podría concluir que los errores sí siguen una distribución normal porque los porcentajes reales y teóricos son muy parecidos.




En el listado del SPSS™ los resultados anteriores aparecen en la base de datos, en la columna llamada ZRe_1, esto se muestra a continuación.

	ZPR_1	ZRE_1	var	
1	-.30094	.88597		
2	1.57995	-.08116		
3	.45141	-.79129		
4	-.67712	.64926		
5	-1.42947	.17584		
6	-1.05330	.41255		
7	.07524	-1.02800		
8	.82759	1.59611		
9	1.20377	-.31787		
10	-.67712	-1.50142		
11				
12				

Figura 2-1-5 Resultados que arroja el SPSS™.

A2.1.10.4 Gráfica P-P y Q-Q plot

Estas gráficas se utilizan para probar que los errores siguen una distribución normal. Los tipos de gráfica que se pueden presentar son:

	Estado ideal; los errores siguen una distribución normal
	Por la bolsa que se forma hacia abajo se puede concluir que existe un sesgo positivo, por lo que se concluye que no sigue una distribución normal
	Por la bolsa que se forma hacia arriba se puede concluir que existe un sesgo negativo, por lo que se concluye que no sigue una distribución normal

Pasos a seguir para graficar la P-P y la Q-Q:

1. Los errores se ordenan de menor a mayor.
2. Poner j , que es una numeración o lugar que ocupa el error.
3. Encontrar la probabilidad de la normal a través de $\frac{(j - 0.5)}{n}$
4. Multiplicar la probabilidad por 100 para convertirla a percentil.
5. Encontrar los valores de Z en la tabla de la normal.
6. Graficar los errores en el eje Y , los percentiles (*P-P Plot*) o los cuantiles (*Q-Q Plot*) en el eje X .

El procedimiento realizado se encuentra en la siguiente tabla, la cual tiene las columnas numeradas, esto indica qué paso se está realizando en la columna:

Tabla 2-1-20 Valores

Error	1	2	3	4	5
Residual	Residual	Lugar	Probabilidad normal	Probabilidad convertida en	Cuantil de la normal
$(Y - \hat{Y})^2$	Ordenados	j	$(j - 0.5)/n$	Percentil	Estándar
0.41	-0.70	1	0.05	5	-1.645
-0.04	-0.48	2	0.15	15	-1.036
-0.37	-0.37	3	0.25	25	-0.674


(continúa)

Tabla 2-1-20 Valores (continuación)

Error	1	2	3	4	5
Residual	Residual	Lugar	Probabilidad normal	Probabilidad convertida en	Cuantil de la normal
$(Y - \hat{Y})^2$	Ordenados	j	$(j - 0.5)/n$	Percentil	Estándar
0.30	-0.15	4	0.35	35	-0.385
0.08	-0.04	5	0.45	45	-0.126
0.19	0.08	6	0.55	55	0.126
-0.48	0.19	7	0.65	65	0.385
0.74	0.30	8	0.75	75	0.674
-0.15	0.41	9	0.85	85	1.036
-0.70	0.74	10	0.95	95	1.645

Si se grafican los percentiles la gráfica se denomina *P-P plot* y si se grafican los cuantiles se denomina *Q-Q plot*. Lo que se hace es ver si se sigue una línea recta o qué tan cerca de esa línea se encuentran los datos.

En el listado del SPSS™ los resultados anteriores aparecen en la gráfica de normalidad:



Gráfica 2-1-13 P-P plot.

Puede notarse que casi todos los puntos caen sobre la línea, por lo que se concluye que los errores siguen una distribución normal.

A2.1.10.5 Prueba de Kolmogorov-Smirnov y de Shapiro-Wilk

Estas pruebas se utilizan para corroborar que los errores siguen una distribución normal. Es una de las más potentes y utilizadas. La prueba de Kolmogorov-Smirnov se puede utilizar para muestras grandes, pero cuando son pequeñas es preferible usar Shapiro-Wilk. Con ambas pruebas no es necesario realizar una gráfica o un histograma.

Las hipótesis serían:

$$H_0: \varepsilon \sim N$$

$$H_1: \varepsilon \not\sim N$$

El valor del estadístico se encuentra en la siguiente tabla, la cual presenta los resultados arrojados por el SPSS™:

Dibujo 2-1-16 Prueba de normalidad

	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Residual estandarizado	.099	10	.200*	.991	10	.998

^a Éste es un límite inferior de la significación verdadera.

* Corrección de la significación de Lilliefors.

Al realizar la prueba, se tendría que para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Como en el ejemplo el tamaño de la muestra es $n = 10$ se deberá utilizar Shapiro-Wilk, por lo que:

$$0.998 > 0.05 \text{ no se rechaza } H_0$$


Se concluye que los errores siguen una distribución normal, si la muestra fuera más grande se utilizaría Kolmogorov-Smirnov:

$$0.200 > 0.05 \text{ no se rechaza } H_0$$

Por lo tanto no se rechaza la hipótesis nula y se concluye que los errores siguen una distribución normal, una vez probado el primer supuesto se procede con los demás.




A2.1.11 Independencia en los errores

Para probar la correlación, relación o dependencia entre los errores o residuales es necesario saber si los datos están o no arreglados cronológicamente; si dicha condición se da se podría probar este supuesto con una gráfica o utilizar la prueba de hipótesis Durbin-Watson, pero si no están acomodados en orden cronológico se podría usar la gráfica; lo anterior se resume en el siguiente diagrama:




Dibujo 2-1-17 Diagrama.

Si se eligió la gráfica y no están en forma aleatoria, se podría presentar alguna de las siguientes situaciones:

	Esta gráfica indica que existe una dependencia lineal ya que hay que agregar un término lineal con respecto a Y misma; la Y se está autoafectando. Es necesario que los datos se encuentren arreglados cronológicamente
	Esta gráfica indica que existe una dependencia no lineal (cuadrática), por lo que desde un principio se debió utilizar un modelo polinomial¹⁴⁵ ya que existe no linealidad con alguna variable independiente
	Dependencia no lineal (cúbica), se deberá utilizar un modelo polinomial (al igual que la gráfica anterior) ya que hay problemas de no linealidad

Si la gráfica de los residuales con respecto al pronóstico muestra abanicos, es necesario quitar este tipo de problema antes de analizar la independencia. La gráfica que da como resultado el SPSS[™] se muestra a continuación:



Gráfica 2-1-14 Gráfica de los residuales.

Parece ser que no existe ningún patrón lineal o no lineal, por lo que se concluye que sí hay independencia.

Si se utilizó el estadístico Durbin-Watson se medirá la autocorrelación,¹⁴⁶ es necesario recordar que los errores deberán estar acomodados cronológicamente¹⁴⁷ y realizar la prueba de hipótesis:

¹⁴⁵ Indica que la variable independiente tiene una relación polinomial con la variable dependiente (4).

¹⁴⁶ La independencia implica que los errores deberán estar estadísticamente independientes; en la autocorrelación; los errores que están en un periodo específico se encuentran relacionados con los errores que están en otro; es decir, es la correlación de los errores en el tiempo. Ambos, la dependencia y la autocorrelación, violan uno de los supuestos de la regresión (de que los errores deben comportarse en forma aleatoria e independiente). El estadístico Durbin-Watson es utilizado para probar la autocorrelación del primer rezago, es decir un periodo atrás en el tiempo (con el pasado o ayer), por lo cual se dice que mide la autocorrelación de primer orden.

¹⁴⁷ En el ejemplo que se tiene no pueden estar acomodados cronológicamente, por lo que el procedimiento que se va a realizar no debería hacerse.

1. Hipótesis¹⁴⁸ l:

H_0 : Los errores de primer orden son independientes no correlacionados, aleatorios,

$$\text{Cor}(\varepsilon_i - \varepsilon_{i-1}) = 0$$

H_1 : Los errores de primer orden son dependientes correlacionados, no aleatorios,

$$\text{Cor}(\varepsilon_i - \varepsilon_{i-1}) \neq 0$$

En esta prueba de hipótesis, a diferencia de las demás, hay 3 zonas, las cuales se encuentran delimitadas por estadísticos teóricos, los que se obtienen en las tablas de Durbin-Watson.


2. Se calcula el estadístico de prueba, el cual es denominado Durbin-Watson con la siguiente fórmula:

$$DW_c = \frac{\sum_{i=2}^n (\varepsilon_i - \varepsilon_{i-1})^2}{\sum_{i=2}^n (\varepsilon_i)^2}$$

El valor del estadístico oscila entre:

$$0 \leq DW \leq 4$$

Un valor cercano a 0 indica que existe una autocorrelación positiva, mientras que un valor cercano a 4 indica una autocorrelación negativa y un valor cercano a 2 muestra que no existe autocorrelación por lo que la hipótesis nula es aceptada; entre los valores teóricos existe una zona que se denomina *zona de indecisión*, la cual al momento de concluir se indica que no se tiene evidencia estadística para tomar una decisión. El acomodo de los valores de Durbin-Watson de tablas y lo anteriormente explicado se muestra a continuación:



Dibujo 2-1-18 Zonas del estadístico.

De acuerdo con el ejemplo, en la siguiente tabla se tiene el tiempo y la columna de los residuales arreglados cronológicamente, en la columna con el número 2 están los residuales al cuadrado, en la 3 se encuentra el residual rezagado en un periodo (lag 1) y en las columnas 4 y 5 se calcularon las diferencias y las diferencias al cuadrado, respectivamente; esto se muestra en la siguiente tabla:

Tabla 2-1-21 Valores

Tiempo	Error	1	2	3	4	5
↑	Residual	Residual	Residual al cuadrado	(Lag 1)	Diferencia	Diferencia al cuadrado
	$(Y - \hat{Y})^2$	α_i	$(\alpha_i)^2$	α_{i-1}	$(\alpha_i - \alpha_{i-1})$	$(\alpha_i - \alpha_{i-1})^2$
1	0.41	0.41	0.170	---	---	---
2	-0.04	-0.04	0.001	0.41	-0.45	0.20
3	-0.37	-0.37	0.135	-0.04	-0.33	0.11
4	0.30	0.30	0.091	-0.37	0.67	0.45
5	0.08	0.08	0.007	0.30	-0.22	0.05

(continúa)

¹⁴⁸ En esta prueba existen tres zonas: H_0 , zona de indecisión y H_1 .

Tabla 2-1-21 Valores (continuación)

Tiempo	Error	1	2	3	4	5
↑	Residual $(Y - \hat{Y})^2$	Residual α_i	Residual al cuadrado $(\alpha_i)^2$	(Lag 1) α_{i-1}	Diferencia $(\alpha_i - \alpha_{i-1})$	Diferencia al cuadrado $(\alpha_i - \alpha_{i-1})^2$
6	0.19	0.19	0.037	0.08	0.11	0.01
7	-0.48	-0.48	0.228	0.19	-0.67	0.45
8	0.74	0.74	0.551	-0.48	1.22	1.49
9	-0.15	-0.15	0.022	0.74	-0.59	0.79
10	-0.70	-0.70	0.487	-0.15	-0.55	0.30
Suma =			1.730			3.853

Al sustituir los valores en la fórmula:

$$DW_c = \frac{\sum_{i=2}^n (\varepsilon_i - \varepsilon_{i-1})^2}{\sum_{i=1}^n (\varepsilon_i)^2} = \frac{3.853}{1.73} = 2.228$$

Los resultados que el SPSS™ presenta de este estadístico se muestran a continuación:

Dibujo 2-1-19 Tabla de resumen.

Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Como se ve el resultado es el mismo.

El estadístico teórico, con 95% de confianza y 5% de significancia y con los grados de libertad, los cuales son $K = 1$, que es el número de variables independientes y $n = 10$, que indica el número de datos en el problema. En la siguiente tabla se muestra cómo buscar el valor:

Tabla 2-1-22 Parte de la tabla de Durbin-Watson


		$K = 1$	
N	α	d_L	d_U
6	0.05	0.610	1.400
	0.01	0.390	1.142
7	0.05	0.700	1.356
	0.01	0.435	1.086
8	0.05	0.763	1.332
	0.01	0.497	1.003
9	0.05	0.824	1.320
	0.01	0.554	0.998
10	0.05	0.879	1.320
	0.01	0.604	1.001

n = número de errores

K = número de variables independientes

$$DW_{t, K=1, n=10} = (d_L, d_U) = (0.879, 1.320)$$

3. Decisión: el valor calculado de Durbin-Watson se tiene que comparar con los valores de tablas



Dibujo 2-1-20 Zonas del estadístico.

4. Conclusión: el estadístico de prueba cae en la zona de indecisión, por lo que se concluye que no se tiene evidencia estadística para indicar si los errores de primer orden son independientes entre sí.

A2.1.12 Media cero

El supuesto de media cero se cumple con el método de mínimos cuadrados ordinarios. Si no es así es recomendable que se cambie de software; cuando no se cumple deberá realizarse una prueba de hipótesis de una media con la t-student.

El problema con este procedimiento es que ningún paquete lo arroja como resultado:

1. Establecer las hipótesis:

$$H_0: \bar{\varepsilon} = 0$$

$$H_1: \bar{\varepsilon} \neq 0$$

2. Obtener el estadístico calculado:

$$t_c = \frac{\bar{e} - \bar{\varepsilon}_{\text{Bajo } H_0}}{\sqrt{\hat{\sigma}^2}} = \frac{\bar{e} - \bar{\varepsilon}_{\text{Bajo } H_0}}{S_e}$$

Donde:

$\bar{e}$ = es el promedio de los residuales.

$\bar{\varepsilon}$ = es el promedio de los errores.

S_e = es la desviación estándar (error estándar del estimado) de los errores.

3. Obtener el estadístico teórico o de tablas:

$$t_{t, \frac{\alpha}{2}, n-p}$$

4. Comparar:

$$|t_c| > t_{t, \frac{\alpha}{2}, n-p}$$

5. Concluir:

En el listado del SPSS™ el resultado de la media de los errores aparece en la tabla de los errores o residuales.

Dibujo 2-1-21 Descriptivos de los residuales.

Estadísticos sobre los residuos ^a					
	Mínimo	Máximo	Media	Desviación típ.	N
Valor pronosticado	8.92	24.04	16.10	5.024	10
Residuo bruto	-.698	.742	.000	.438	10
Valor pronosticado típ.	-1.429	1.580	.000	1.000	10
Residuo típ.	-1.501	1.596	.000	.943	10




^a Variable dependiente: ganancia.

Como muestra la tabla anterior, el promedio de los residuales es cero (residuo bruto), se da por cumplido dicho supuesto.

A2.1.13 Homoscedasticidad

Como ya se vio, el término *homoscedasticidad* indica que existe homogeneidad en las varianzas, es decir que las varianzas son constantes, cuando no lo son se dice que existe *heteroscedasticidad*. Este supuesto se revisa en la gráfica de los residuales, que se obtiene cuando se trazan los errores en el eje de la Y y los datos reales (o los valores de la X o los valores de los datos pronosticados) en el eje de la X.




En esta gráfica los errores pueden revelar qué problemas¹⁴⁹ tiene el modelo, para la homoscedasticidad se deberá visualizar que los errores sean aleatorios y no se abran en abanico o en rombo:

	Condición normal o ideal
	Varianzas no constantes ya que existe mucha variabilidad o dispersión en los valores grandes de los errores
	Varianzas no constantes ya que existe mucha variabilidad o dispersión en los valores grandes de los errores


(continúa)

¹⁴⁹ Los problemas que se pueden presentar son: no linealidad, dependencia y homoscedasticidad.

(continuación)


	Varianzas no constantes ya que existe mucha variabilidad o dispersión en los valores centrales
	Dependencia lineal, hay que agregar un término lineal con respecto a Y misma, los datos deberán estar arreglados cronológicamente
	Dependencia no lineal, hay que agregar un término polinomial ya que existe no linealidad
	Dependencia no lineal hay que agregar términos polinomiales (ya que existe no linealidad)

En el listado del SPSS™ los resultados anteriores aparecen en la gráfica de los errores o residuales:




Gráfica 2-1-15 Gráfica de los residuales.

La conclusión de la gráfica pasada es que posiblemente exista dependencia. Para interpretar este supuesto es necesario tratar de encontrar un abanico o rombo, por ejemplo si se tuviera la siguiente gráfica:



Gráfica 2-1-16 Ejemplo de otros datos.

O bien se podría pensar en lo siguiente:



Gráfica 2-1-17 Ejemplo de otros datos.

Es importante recalcar que cuando son muy pocos datos (es decir para n pequeña), el gráfico de los errores contra X o el pronóstico suele ser confuso para determinar si existe o no homoscedasticidad.

Existe una prueba, la cual se considera potente y es llamada prueba de Levene:

Las hipótesis serían:

$$H_0 : \sigma^2 \text{ constantes}$$

$$H_1 : \sigma^2 \text{ no constantes}$$

El estadístico de prueba sería una F y la información que el SPSS™ da al respecto es la siguiente:

Dibujo 2-1-22 Prueba de Levene.

Prueba de homogeneidad de la varianza					
		Estadístico de Levene	gl1	gl2	Sig.
Residuales estandarizados	Basándose en la media	0.40	1	8	.847
	Basándose en la mediana	0.50	1	8	.829
	Basándose en la mediana y con gl corregido	0.50	1	7.824	.829
	Basándose en la media recortada	0.48	1	8	.832

Al realizar la prueba se tendría que para rechazar la H_0 es necesario que:

$$p\text{-valor}(\text{Sig.}) < \alpha$$

Al utilizar la información del estadístico de la media recortada se tiene que:

$$0.832 > 0.05 \text{ no se rechaza } H_0$$

Se concluye que los errores tienen homoscedasticidad, por lo que este supuesto se cumple.

Por lo tanto se acepta H_0 y se concluye que los errores tienen varianzas constantes o iguales, por lo que este supuesto también se cumplió.

Como todos los supuestos se cumplen podemos continuar con el análisis; si algún supuesto no se cumpliera no se podría continuar.

A2.1.14 Pronósticos puntuales

Los pronósticos puntuales o de punto se encuentran con la fórmula de regresión:

$$\hat{Y} = b_0 + b_1X = \hat{\beta}_0 + \hat{\beta}_1X = 5.138 + 1.89 * X$$

$$\hat{G} = 5.138 + 1.89 * P$$

Donde $\hat{G}$ es la ganancia estimada y P es la publicidad que cierta empresa gasta en su producto.

De acuerdo con el ejemplo, al sustituir la información en la ecuación de regresión, la cual se calculó con anterioridad, se podría encontrar dicha información en la siguiente tabla.

Dibujo 2-1-23 Tabla de los coeficientes

Coeficientes ^a								
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%	
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior	Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288	5.989
	Publicidad	1.890	.058		32.416	.000	1.755	2.024

^a Variable dependiente: ganancia.

Al sustituir la variable independiente en la ecuación, se tienen los siguientes resultados:

Tabla 2-1-23 Valores

X Publicidad	Y Ganancia	$\hat{Y}$
5	15	14.59
10	24	24.04
7	18	18.37
4	13	12.70
2	9	8.92
3	11	10.81
6	16	16.48
8	21	20.26
9	22	22.15
4	12	12.70

Por ejemplo para el primer pronóstico se tiene que la publicidad tiene un valor de:

$$X = P = 5$$

Al sustituir ese valor en la ecuación se obtiene el valor de la ganancia estimada, que sería el pronóstico puntual:

$$\hat{G} = 5.138 + 1.89 \cdot 5 = 14.59$$

Los demás valores fueron encontrados de igual manera, se le recomienda al lector que realice al menos un valor. Si se desean obtener valores distintos a los dados, se enlistan algunos ejemplos a continuación:

Tabla 2-1-24 Valores

X Publicidad	Y Ganancia	$\hat{Y}$
2.8		10.43
3.3		11.38
6.7		17.80
7.9		20.07


Por ejemplo para el primer pronóstico, en el cual se le dio a la publicidad el valor de 2.8, se tiene que:

$$X = P = 2.8$$

Al sustituir ese valor en la ecuación se obtiene el de la ganancia estimada; esta estimación sería el pronóstico puntual:

$$\hat{G} = 5.138 + 1.89 \cdot 2.8 = 10.43$$

En el listado del SPSS™ los resultados anteriores aparecen en la base de datos, los cuales se muestran a continuación.



The screenshot shows the 'Regresión Simple.sav [Conjunto_de_datos1] - Editor de datos' window. The table below represents the data shown in the window, with columns for case number, predicted value (PRE_1), residual (RES_1), and standardized residual (ZPR_1).

	PRE_1	RES_1	ZPR_1
1	14.58805	.41195	-.300
2	24.03774	-.03774	1.579
3	18.36792	-.36792	.451
4	12.69811	.30189	-.677
5	8.91824	.08176	-1.429
6	10.80818	.19182	-1.053
7	16.47799	-.47799	.075
8	20.25786	.74214	.827
9	22.14780	-.14780	1.203
10	12.69811	-.69811	-.677
11			
12			

Figura 2-1-6 Resultados que arroja el SPSS™

Una vez encontrados todos los pronósticos puntuales, es necesario aclarar que los pronósticos que se pueden obtener deben estar contenidos en el rango de la variable independiente con los cuales se trabajó el problema, tratar de pronosticar más allá de esos valores sería bastante arriesgado porque la pendiente podría tener algún cambio, recuerde que este método (el de análisis de regresión) no predice los puntos de cambio; también es necesario aclarar que con los pronósticos puntuales no se

obtiene un valor verdadero del comportamiento original de los datos, por lo que es conveniente crear para cada valor del pronóstico un intervalo de confianza dentro del cual caerá el verdadero valor; el siguiente punto cubre este tema.

A2.1.14.1 Pronósticos por intervalo

Dentro de los pronósticos por intervalo se tienen 2 tipos, el intervalo de confianza para la media y el intervalo de confianza para la predicción individual, a continuación se explicará cómo obtenerlos.

A2.1.14.2 Para la media

El intervalo de confianza al $100(1 - \alpha)^{\times}$ para la media de Y cuando el valor de la variable independiente es x_0 podría también llamarse *intervalo de confianza para y_0* ; cuando se construye un intervalo de confianza es necesario encontrar el error estándar, el cual es el valor de la distancia para un valor particular x_0 de X :

$$\left[\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{SS_{XX}} \right] = \left[\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]$$

Por lo que el intervalo de confianza al $100(1 - \alpha)^{\times}$ para la media es:

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_{\epsilon} \sqrt{\left[\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

Los cálculos se pueden hacer con las siguientes fórmulas:

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \sqrt{MSE \left[\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

Existen muchos datos que ya fueron encontrados con anterioridad, pero se pondrá la información de dónde se recabarán para completar el intervalo. El error estándar del estimado está en la siguiente tabla.

Dibujo 2-1-24 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Además se necesita la siguiente información.

Dibujo 2-1-25 Tabla de los coeficientes

Coeficientes ^a							
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288 5.989
	Publicidad	1.890	.058		32.416	.000	1.755 2.024

^a Variable dependiente: ganancia.


Y los datos de la siguiente tabla.

Tabla 2-1-25 Datos


	X Publicidad	Y Ganancia	$\hat{Y}$	X^2
	5	15	14.59	25
	10	24	24.04	100
	7	18	18.37	49
	4	13	12.70	16
	2	9	8.92	4
	3	11	10.81	9
	6	16	16.48	36
	8	21	20.26	64
	9	22	22.15	81
	4	12	12.70	16
Suma =	58	161		400
Promedio =	5.80	16.10		

El valor de las tablas se encontró de la siguiente manera.

Tabla 2-1-26 Parte de la tabla t-student



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



Por lo que el estadístico teórico sería:

$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p=10-2=8} = 2.306$$

Por ejemplo si se desea encontrar el intervalo para la media cuando $x = p = 5$, al sustituir la información del ejemplo en la fórmula se tiene que

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_\varepsilon \sqrt{\left[\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

Con los valores.

$$(5.138 + 1.89 * 5) \pm 2.306 * 0.456 \sqrt{\left[\frac{1}{10} + \frac{(5 - 5.8)^2}{400 - 10 * 5.8^2} \right]}$$

Los resultados son:


$$14.232 \leq Y \leq 14.944$$

Es decir con 95% de confianza la Y media real puede oscilar entre 14.232 y 14.944, la siguiente tabla contiene los demás valores, los cuales fueron encontrados de igual manera.

Tabla 2-1-27 Intervalos de confianza para la media

Intervalo de confianza para la media límite inferior	Intervalo de confianza para la media límite superior
14.232	14.944
23.379	24.696
17.992	18.743
12.282	13.115
8.305	9.531
10.302	11.315
16.138	16.818
19.808	20.708
21.600	22.696
12.282	13.115

En el listado del SPSS™ los resultados anteriores aparecen en la base de datos, lo cual se muestra a continuación.



1: PRE_1	LMCI 1	UMCI 1
1	14.23233	14.94377
2	23.37908	24.69639
3	17.99243	18.74342
4	12.28154	13.11469
5	8.30506	9.53142
6	10.30154	11.31481
7	16.13786	16.81812
8	19.80791	20.70781
9	21.60002	22.69558
10	12.28154	13.11469
11		

Figura 2-1-7 Resultados que arroja el SPSS™

LMCI_1, por sus siglas en inglés, indica el límite inferior del intervalo de confianza medio y UMCI_1, por sus siglas en inglés, indica el límite superior del intervalo de confianza medio.

A2.1.14.3 Para la predicción individual

El intervalo de confianza al $100(1 - \alpha)^x$ para la predicción individual de Y cuando el valor de la variable independiente es x_0 , por lo que podría también llamarse *intervalo de confianza para y_0* ; cuando se construye un intervalo de confianza es necesario encontrar el **error estándar**, el cual es el valor de la distancia para un valor particular x_0 de X :

Error estándar. Valor de la distancia para un valor particular.

$$\left[1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{SS_{XX}} \right] = \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]$$

Por lo que el intervalo de confianza al $100(1 - \alpha)^x$ para la predicción individual es:

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_e \sqrt{\left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

O bien los cálculos se pueden hacer con las siguientes fórmulas:

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) \sqrt{MSE \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2} \right]}$$

Existen muchos datos que fueron encontrados con anterioridad, pero se pondrá la información de dónde se recabará para completar el intervalo. El error estándar del estimado está en la siguiente tabla.

Dibujo 2-1-26 Tabla de resumen

Resumen del modelo ^b					
Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación	Durbin-Watson
1	.996 ^a	.992	.991	.465	2.228

^a Variables predictoras: (constante), publicidad.

^b Variable dependiente: ganancia.

Además se necesita la siguiente información.

Dibujo 2-1-27 Tabla de los coeficientes

Coeficientes ^a							
		Coeficientes no estandarizados		Coeficientes estandarizados			Intervalo de confianza para B a 95%
Modelo		B	Error típ.	Beta	t	Sig.	Límite inferior Límite superior
1	(Constante)	5.138	.369	.996	13.935	.000	4.288 5.989
	Publicidad	1.890	.058		32.416	.000	1.755 2.024

^a Variable dependiente: ganancia.


Y los datos de la siguiente tabla.

Tabla 2-1-28 Valores


	X Publicidad	Y Ganancia	$\hat{Y}$	X^2
	5	15	14.59	25
	10	24	24.04	100
	7	18	18.37	49
	4	13	12.70	16
	2	9	8.92	4
	3	11	10.81	9
	6	16	16.48	36
	8	21	20.26	64
	9	22	22.15	81
	4	12	12.70	16
Suma =	58	161		400
Promedio =	5.80	16.10		

El valor de tablas se encontró de la siguiente manera.

Tabla 2-1-29 Parte de la tabla t-student



df	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001
1	1.0000	1.3764	1.9626	3.0777	6.3138	12.7062	31.8205	63.6567	127.321	318.309	636.619
6	0.7176	0.9057	1.1342	1.4398	1.9432	2.4469	3.1427	3.7074	4.317	5.208	5.959
7	0.7111	0.8960	1.1192	1.4149	1.8946	2.3646	2.9980	3.4995	4.029	4.785	5.408
8	0.7064	0.8889	1.1081	1.3968	1.8595	2.3066	2.8965	3.3554	3.833	4.501	5.041
9	0.7027	0.8834	1.0997	1.3830	1.8331	2.2622	2.8214	3.2498	3.690	4.297	4.781
43	0.6802	0.8501	1.0491	1.3016	1.6811	2.0167	2.4163	2.6951	2.959	3.291	3.532
44	0.6801	0.8499	1.0488	1.3011	1.6802	2.0154	2.4141	2.6923	2.956	3.286	3.526
45	0.6800	0.8497	1.0485	1.3006	1.6794	2.0141	2.4141	2.6896	2.952	3.281	3.520
df	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005



Por lo que el estadístico teórico sería:

$$t_{t, \frac{\alpha}{2} = \frac{0.05}{2} = 0.025, n-p=10-2=8} = 2.306$$

Por ejemplo si se desea encontrar el intervalo para la predicción individual cuando $x = p = 5$, al sustituir la información del ejemplo en la fórmula se tiene que:

$$\hat{y}_0 \pm \left(t_{t, \frac{\alpha}{2}, n-p} \right) S_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n X^2 - n\bar{X}^2}}$$

Con los valores:

$$(5.129 + 1.95 * 5) \pm 2.306 * 0.456 \sqrt{1 + \frac{1}{10} + \frac{(5 - 5.8)^2}{400 - 10 * 5.8}}$$

Los resultados son:


$$13.459 \leq Y \leq 15.719$$

Es decir con 95% de confianza la Y real puede oscilar entre 13.458 y 15.718, por lo que estos intervalos son más amplios;¹⁵⁰ la siguiente tabla contiene los demás valores, los cuales fueron encontrados de igual manera.

Tabla 2-1-30 Intervalos de confianza para la media

Intervalo de confianza para la media límite inferior	Intervalo de confianza para la media límite superior
13.458	15.718
22.779	25.296
17.232	19.504
11.548	13.848
7.683	10.153
9.622	11.994
15.353	17.603
19.095	21.421
20.944	23.352
11.548	13.848

En el listado del SPSS[™] los resultados anteriores aparecen en la base de datos, lo cual se muestra a continuación.




PRE_1	LIC1_1	UIC1_1	val
1	13.45837	15.71773	
2	22.77937	25.29610	
3	17.23186	19.50399	
4	11.54782	13.84841	
5	7.68307	10.15341	
6	9.62229	11.99407	
7	15.35311	17.60286	
8	19.09506	21.42066	
9	20.94376	23.35184	
10	11.54782	13.84841	
11			
12			
13			

Figura 2-1-8 Resultados que arroja el SPSS[™].

¹⁵⁰ Note la diferencia entre este intervalo de predicción individual y el intervalo para la media, que es más cerrado y más pequeño, mientras que el intervalo para la predicción es más abierto, más ancho por lo que abarca más valores.

LICI_1, por sus siglas en inglés, indica el límite inferior del intervalo de confianza individual y UICI_1, por sus siglas en inglés, señala el límite superior del intervalo de confianza individual.

Anexo 2.2 Tabla t





gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
1	1.000	1.378	1.963	3.078	6.814	12.708	31.821	63.657	127.321	219.909	836.619	1273.299
2	0.818	1.081	1.86	1.888	2.920	4.303	6.985	9.925	14.089	22.327	31.599	44.705
3	0.766	0.978	1.250	1.638	2.353	3.182	4.541	5.481	7.453	10.215	12.924	18.326
4	0.741	0.941	1.190	1.533	2.132	2.778	3.747	4.604	5.598	7.173	8.610	10.306
5	0.727	0.920	1.158	1.476	2.015	2.571	3.365	4.032	4.773	5.893	6.860	7.978
6	0.718	0.908	1.134	1.440	1.943	2.447	3.143	3.707	4.317	5.208	5.950	6.788
7	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.029	4.785	5.408	6.082
8	0.706	0.850	1.108	1.397	1.890	2.308	2.898	3.365	3.833	4.501	5.041	5.617
9	0.708	0.853	1.100	1.383	1.833	2.262	2.821	3.250	3.690	4.297	4.781	5.291
10	0.700	0.879	1.098	1.372	1.812	2.228	2.784	3.169	3.581	4.144	4.587	5.049
11	0.697	0.876	1.088	1.368	1.798	2.201	2.718	3.106	3.497	4.025	4.437	4.883
12	0.896	0.873	1.083	1.358	1.782	2.179	2.881	3.065	3.428	3.930	4.318	4.716
13	0.894	0.870	1.079	1.350	1.771	2.160	2.650	3.012	3.372	3.852	4.221	4.697
14	0.892	0.858	1.078	1.345	1.761	2.145	2.824	2.977	3.326	3.787	4.140	4.499
15	0.891	0.856	1.074	1.341	1.753	2.131	2.602	2.947	3.286	3.733	4.073	4.417
16	0.890	0.855	1.071	1.337	1.748	2.120	2.583	2.921	3.252	3.789	4.015	4.348
17	0.680	0.853	1.069	1.333	1.740	2.110	2.587	2.898	3.222	3.649	3.955	4.288
18	0.688	0.852	1.067	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922	4.233
19	0.688	0.851	1.068	1.328	1.729	2.088	2.530	2.861	3.174	3.579	3.853	4.187
20	0.887	0.850	1.064	1.325	1.725	2.086	2.5228	2.845	3.153	3.552	3.850	4.148
21	0.888	0.850	1.063	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819	4.110
22	0.888	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792	4.077
23	0.885	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.768	4.047
24	0.686	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.091	3.487	3.745	4.021
25	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.078	3.450	3.725	3.698
26	0.684	0.856	1.058	1.315	1.706	2.058	2.479	2.779	3.067	3.435	3.707	3.974
27	0.684	0.856	1.057	1.314	1.703	2.052	2.473	2.771	3.057	3.421	3.690	3.954
28	0.683	0.856	1.056	1.313	1.701	2.048	2.467	2.763	3.047	3.408	3.674	3.935
29	0.683	0.854	1.055	1.311	1.699	2.045	2.462	2.768	3.038	3.398	3.650	3.918

(continúa)

(continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
30	0.683	0.854	1.055	1.310	1.697	2.042	2.457	2.750	3.030	3.385	3.646	3.902
31	0.682	0.853	1.054	1.309	1.696	2.040	2.453	2.744	3.022	3.375	3.633	3.887
32	0.682	0.853	1.054	1.309	1.694	2.037	2.449	2.738	3.015	3.365	3.622	3.873
33	0.682	0.853	1.053	1.308	1.692	2.035	2.445	2.733	3.008	3.358	3.611	3.860
34	0.682	0.852	1.052	1.307	1.691	2.032	2.441	2.728	3.002	3.348	3.601	3.848
35	0.682	0.852	1.052	1.306	1.690	2.030	2.438	2.724	2.996	3.340	3.591	3.838
36	0.681	0.852	1.052	1.306	1.688	2.028	2.434	2.719	2.990	3.333	3.582	3.828
37	0.681	0.851	1.051	1.305	1.687	2.028	2.431	2.715	2.985	3.329	3.574	3.815
38	0.681	0.851	1.051	1.304	1.686	2.024	2.429	2.712	2.980	3.319	3.566	3.808
39	0.681	0.851	1.050	1.304	1.685	2.023	2.426	2.708	2.976	3.313	3.558	3.797
40	0.681	0.851	1.050	1.303	1.684	2.021	2.423	2.704	2.971	3.307	3.551	3.788
41	0.681	0.850	1.050	1.303	1.683	2.020	2.421	2.701	2.963	3.301	3.544	3.780
42	0.680	0.850	1.049	1.302	1.682	2.018	2.418	2.698	2.963	3.298	3.538	3.773
43	0.680	0.850	1.049	1.302	1.681	2.017	2.416	2.695	2.959	3.291	3.532	3.765
44	0.680	0.850	1.049	1.301	1.680	2.015	2.414	2.692	2.956	3.289	3.526	3.758
45	0.680	0.850	1.049	1.301	1.679	2.014	2.412	2.690	2.952	3.281	3.520	3.752
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025





gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
46	0.680	0.850	1.048	1.300	1.679	2.013	2.410	2.687	2.949	3.277	3.515	3.748
47	0.680	0.849	1.048	1.300	1.678	2.012	2.408	2.685	2.948	3.273	3.510	3.740
48	0.680	0.849	1.048	1.299	1.677	2.011	2.407	2.682	2.943	3.289	3.505	3.734
49	0.680	0.849	1.048	1.299	1.677	2.10	2.405	2.680	2.940	3.285	3.500	3.728
50	0.679	0.849	1.047	1.299	1.676	2.009	2.403	2.678	2.937	3.281	3.496	3.723
51	0.679	0.849	1.047	1.298	1.675	2.008	2.402	2.678	2.934	3.258	3.492	3.718
52	0.679	0.849	1.047	1.298	1.675	2.007	2.400	2.674	2.932	3.255	3.488	3.718
53	0.679	0.848	1.047	1.298	1.674	2.006	2.399	2.672	2.929	3.251	3.484	3.709
54	0.679	0.848	1.046	1.297	1.674	2.005	2.397	2.670	2.927	3.248	3.480	3.704
55	0.679	0.848	1.046	1.297	1.673	2.004	2.396	2.668	2.925	3.245	3.476	3.700
56	0.679	0.848	1.046	1.297	1.673	2.003	2.395	2.667	2.923	3.242	3.473	3.698

(continúa)


(continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.005	0.002	0.001	0.0005
57	0.679	0.848	1.046	1.297	1.672	2.002	2.394	2.665	2.920	3.239	3.470	3.692
58	0.679	0.848	1.046	1.296	1.673	2.002	2.392	2.663	2.918	3.237	3.466	3.688
59	0.679	0.848	1.046	1.296	1.671	2.001	2.391	2.662	2.916	3.234	3.463	3.684
60	0.679	0.848	1.045	1.296	1.671	2.000	2.390	2.660	2.915	3.232	3.460	3.681
61	0.679	0.848	1.045	1.296	1.670	2.000	2.389	2.659	2.913	3.229	3.457	3.677
62	0.678	0.847	1.045	1.295	1.670	1.999	2.388	2.657	2.911	3.227	3.454	3.674
63	0.678	0.847	1.045	1.295	1.669	1.998	2.387	2.656	2.090	3.225	3.452	3.671
64	0.678	0.847	1.045	1.295	1.669	1.998	2.386	2.655	2.908	3.223	3.449	3.668
65	0.678	0.847	1.045	1.295	1.669	1.997	2.385	2.654	2.906	3.220	3.447	3.665
66	0.678	0.847	1.045	1.295	1.668	1.997	2.384	2.652	2.904	3.218	3.444	3.662
67	0.678	0.847	1.045	1.294	1.668	1.996	2.383	2.651	2.903	3.218	3.442	3.659
68	0.678	0.847	1.044	1.294	1.668	1.995	2.382	2.650	2.902	3.214	3.439	3.658
69	0.678	0.847	1.044	1.294	1.667	1.995	2.382	2.649	2.900	3.213	3.437	3.653
70	0.678	0.847	1.044	1.294	1.667	1.994	2.381	2.648	2.899	3.211	3.435	3.651
71	0.678	0.847	1.044	1.294	1.667	1.994	2.380	2.647	2.897	3.209	3.433	3.648
72	0.678	0.847	1.044	1.293	1.666	1.993	2.379	2.646	2.896	3.207	3.431	3.648
73	0.678	0.847	1.044	1.293	1.666	1.993	2.379	2.645	2.895	3.205	3.429	3.644
74	0.678	0.847	1.044	1.293	1.666	1.993	2.378	2.644	2.894	3.204	3.427	3.641
75	0.678	0.846	1.044	1.293	1.665	1.992	2.377	2.643	2.892	3.204	3.425	3.639
76	0.678	0.846	1.044	1.293	1.665	1.992	2.376	2.642	2.891	3.201	3.423	3.637
77	0.678	0.846	1.043	1.293	1.665	1.991	2.376	2.641	2.890	3.199	3.421	3.635
78	0.678	0.846	1.043	1.292	1.665	1.991	2.375	2.640	2.889	3.198	3.420	3.633
79	0.678	0.846	1.043	1.292	1.664	1.990	2.374	2.640	2.888	3.197	3.418	3.631
80	0.678	0.846	1.043	1.292	1.664	1.990	2.374	2.639	2.887	3.195	3.416	3.629
81	0.678	0.846	1.043	1.292	1.664	1.990	2.373	2.638	2.886	3.194	3.415	3.627
82	0.677	0.846	1.043	1.292	1.664	1.989	2.373	2.637	2.885	3.193	3.413	3.625
83	0.677	0.846	1.043	1.292	1.663	1.989	2.372	2.636	2.884	3.191	3.412	3.623
84	0.677	0.846	1.043	1.292	1.663	1.989	2.372	2.635	2.883	3.190	3.410	3.622
85	0.677	0.846	1.043	1.292	1.663	1.988	2.371	2.634	2.882	3.189	3.409	3.620
86	0.677	0.846	1.043	1.291	1.663	1.988	2.370	2.634	2.881	3.188	3.407	3.618
87	0.677	0.846	1.043	1.291	1.663	1.988	2.370	2.633	2.880	3.187	3.406	3.617
88	0.677	0.846	1.043	1.291	1.662	1.987	2.360	2.632	2.880	3.185	3.405	3.615
89	0.677	0.846	1.043	1.291	1.662	1.987	2.360	2.632	2.879	3.184	3.403	3.613
90	0.677	0.846	1.042	1.291	1.662	1.987	2.358	2.632	2.878	3.183	3.402	3.612
gl	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005	0.00025






gl	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.006	0.002	0.001	0.0006
91	0.677	0.846	1.042	1.291	1.662	1.986	2.358	2.631	2.877	3.182	3.401	3.610
92	0.677	0.846	1.042	1.291	1.662	1.986	2.358	2.630	2.876	2.181	3.399	3.609
93	0.677	0.846	1.042	1.291	1.661	1.986	2.367	2.630	2.876	3.180	3.398	3.607
94	0.677	0.845	1.042	1.291	1.661	1.986	2.387	2.629	2.875	3.179	3.397	3.606
95	0.677	0.845	1.042	1.291	1.661	1.985	2.386	2.629	2.874	3.178	3.396	3.605
96	0.677	0.845	1.042	1.290	1.661	1.985	2.386	2.628	2.873	3.177	3.396	3.603
97	0.677	0.845	1.042	1.290	1.661	1.985	2.385	2.627	2.873	3.176	3.394	3.602
98	0.677	0.845	1.042	1.290	1.861	1.984	2.385	2.627	2.872	3.175	3.393	3.601
99	0.677	0.845	1.042	1.290	1.860	1.984	2.385	3.628	2.871	3.175	3.392	3.600
100	0.677	0.845	1.042	1.290	1.660	1.984	2.384	2.628	2.871	3.174	3.390	3.598
105	0.677	0.845	1.042	1.290	1.659	1.983	2.382	2.623	2.858	3.170	3.386	3.593
110	0.677	0.845	1.041	1.289	1.659	1.982	2.351	2.621	2.855	3.165	3.381	3.587
115	0.677	0.845	1.041	1.286	1.658	1.981	2.359	2.619	2.852	3.163	3.377	3.583
120	0.677	0.845	1.041	1.288	1.657	1.979	2.357	2.616	2.858	3.157	3.370	3.574
130	0.676	0.844	1.041	1.288	1.657	1.978	2.354	2.613	2.854	3.152	3.364	3.567
135	0.676	0.844	1.040	1.288	1.658	1.978	2.354	2.613	2.854	3.152	3.384	2.567
140	0.676	0.844	1.040	1.288	1.656	1.977	2.353	2.611	2.852	3.149	3.367	3.584
145	0.676	0.844	1.040	1.287	1.655	1.976	2.352	2.610	2.851	3.147	3.359	3.581
150	0.676	0.844	1.040	1.287	1.655	1.976	2.351	2.609	2.849	3.145	3.357	3.558
155	0.676	0.844	1.040	1.287	1.655	1.975	2.351	2.608	2.848	3.144	3.354	3.556
160	0.676	0.844	1.040	1.287	1.654	1.975	2.350	2.607	2.846	3.142	3.352	3.553
165	0.676	0.844	1.040	1.287	1.654	1.974	2.349	2.606	2.845	3.140	3.350	3.551
170	0.676	0.844	1.040	1.287	1.654	1.974	2.348	2.605	2.844	3.139	3.349	3.549
175	0.676	0.844	1.040	1.266	1.654	1.974	2.348	2.604	2.843	3.137	3.347	3.547
180	0.676	0.844	1.039	1.286	1.653	1.973	2.347	2.603	2.842	3.136	3.345	3.545
185	0.676	0.844	1.039	1.286	1.653	1.973	2.347	2.603	2.841	3.135	3.344	3.543
190	0.676	0.844	1.039	1.286	1.653	1.973	2.346	2.602	2.840	3.134	3.342	3.542
195	0.676	0.843	1.039	1.286	1.653	1.972	2.346	2.601	2.839	3.133	3.341	3.540
200	0.676	0.843	1.039	1.286	1.653	1.972	2.345	2.601	2.839	3.131	3.340	3.539
∞	0.674	0.842	1.038	1.282	1.645	1.960	2.326	2.579	2.807	3.090	3.291	3.431
gl	0.25	0.20	0.15	0.10	0.05	0.0025	0.01	0.005	0.0025	0.001	0.0005	0.00025



Anexo 2.3 Tabla F



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	0.100	39.863	49.500	53.593	55.833	57.240	58.204	58.906	59.439	59.858	60.195	60.705	61.220	61.740	62.002	62.265	62.529	62.794	63.061	63.328
	0.050	161.45	199.50	215.71	224.58	230.16	233.99	236.77	238.88	240.54	241.88	243.91	245.95	248.01	249.05	250.10	251.14	252.20	253.25	254.31
	0.025	647.79	799.50	864.16	899.58	921.85	937.11	948.22	956.66	963.28	968.63	976.71	984.87	993.10	997.25	1 001.4	1 005.6	1 009.8	1 014.0	1 018.3
	0.010	4 052.2	4 999.5	5 403.4	5 624.6	5 763.6	5 859.0	5 928.4	5 981.1	6 022.5	6 055.8	6 106.3	6 157.3	6 208.7	6 234.6	6 260.6	6 286.8	6 313.0	6 339.4	6 365.9
	0.005	16 211	20 000	21 615	22 500	23 056	23 437	23 715	23 925	24 091	24 224	24 426	24 630	24 836	24 940	25 044	25 148	25 253	25 359	25 464
2	0.100	8.526	9.000	9.162	9.243	9.293	9.326	9.349	9.367	9.381	9.392	9.408	9.425	9.441	9.450	9.458	9.466	9.475	9.483	9.491
	0.050	18.513	19.000	19.164	19.247	19.296	19.330	19.353	19.371	19.385	19.396	19.413	19.429	19.446	19.454	19.462	19.471	19.479	19.487	19.496
	0.025	38.506	39.000	39.165	39.248	39.298	39.331	39.355	39.373	39.387	39.398	39.415	39.431	39.448	39.456	39.465	39.473	39.481	39.490	39.498
	0.010	98.503	99.000	99.166	99.249	99.299	99.333	99.356	99.374	99.388	99.399	99.416	99.433	99.449	99.458	99.466	99.474	99.482	99.491	99.499
	0.005	198.50	199.00	199.17	199.25	199.30	199.33	199.36	199.37	199.39	199.40	199.42	199.43	199.45	199.46	199.47	199.47	199.48	199.49	199.50
3	0.100	5.538	5.462	5.391	5.343	5.309	5.285	5.266	5.252	5.240	5.230	5.216	5.200	5.184	5.176	5.168	5.160	5.151	5.143	5.134
	0.050	10.128	9.552	9.277	9.117	9.013	8.941	8.887	8.845	8.812	8.786	8.745	8.703	8.660	8.639	8.617	8.594	8.572	8.549	8.526
	0.025	17.443	16.044	15.439	15.101	14.885	14.735	14.624	14.540	14.473	14.419	14.337	14.253	14.167	14.124	14.081	14.037	13.992	13.947	13.902
	0.010	34.116	30.817	29.457	28.710	28.237	27.911	27.672	27.489	27.345	27.229	27.052	26.872	26.690	26.598	26.505	26.411	26.316	26.221	26.125
	0.005	55.552	49.799	47.467	46.195	45.392	44.838	44.434	44.126	43.882	43.686	43.387	43.085	42.778	42.622	42.466	42.308	42.149	41.989	41.828
4	0.100	4.545	4.325	4.191	4.107	4.051	4.010	3.979	3.955	3.936	3.920	3.896	3.870	3.844	3.831	3.817	3.804	3.790	3.775	3.761
	0.050	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041	5.999	5.964	5.912	5.858	5.803	5.774	5.746	5.717	5.688	5.658	5.628
	0.025	12.218	10.649	9.979	9.605	9.364	9.197	9.074	8.980	8.905	8.844	8.751	8.657	8.560	8.511	8.461	8.411	8.360	8.309	8.257
	0.010	21.198	18.000	16.694	15.977	15.522	15.207	14.976	14.799	14.659	14.546	14.374	14.198	14.020	13.929	13.838	13.745	13.652	13.558	13.463
	0.005	31.333	26.284	24.259	23.155	22.456	21.975	21.622	21.352	21.139	20.967	20.705	20.438	20.167	20.030	19.892	19.752	19.611	19.468	19.325
5	0.100	4.060	3.780	3.619	3.520	3.453	3.405	3.368	3.339	3.316	3.297	3.268	3.238	3.207	3.191	3.174	3.157	3.140	3.123	3.105

(continúa)

(continuación)

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
	0.050	6.608	5.786	5.409	5.192	5.050	4.950	4.876	4.818	4.772	4.735	4.678	4.619	4.558	4.527	4.496	4.464	4.431	4.398	4.365
	0.025	10.007	8.434	7.764	7.388	7.146	6.978	6.853	6.757	6.681	6.619	6.525	6.428	6.329	6.278	6.227	6.175	6.123	6.069	6.015
	0.010	16.258	13.274	12.060	11.392	10.967	10.672	10.456	10.289	10.158	10.051	9.888	9.722	9.553	9.466	9.379	9.291	9.202	9.112	9.020
	0.005	22.785	18.314	16.530	15.556	14.940	14.513	14.200	13.961	13.772	13.618	13.384	13.146	12.903	12.780	12.656	12.530	12.402	12.274	12.144
	6	0.100	3.776	3.463	3.289	3.181	3.055	3.014	2.983	2.958	2.937	2.905	2.871	2.836	2.818	2.800	2.781	2.762	2.742	2.722
	0.050	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147	4.099	4.060	4.000	3.938	3.874	3.841	3.808	3.774	3.740	3.705	3.669
	0.025	8.813	7.260	6.599	6.227	5.988	5.820	5.695	5.600	5.523	5.461	5.366	5.269	5.168	5.117	5.065	5.012	4.959	4.904	4.849
	0.010	13.745	10.925	9.780	9.148	8.746	8.466	8.260	8.102	7.976	7.874	7.718	7.559	7.396	7.313	7.229	7.143	7.057	6.969	6.880
	0.005	18.635	14.544	12.917	12.028	11.464	11.073	10.786	10.566	10.391	10.250	10.034	9.814	9.589	9.474	9.358	9.241	9.122	9.001	8.879
	7	0.100	3.589	3.257	3.074	2.961	2.827	2.785	2.752	2.725	2.703	2.668	2.632	2.595	2.575	2.555	2.535	2.514	2.493	2.471
	0.050	5.591	4.737	4.347	4.120	3.972	3.866	3.787	3.726	3.677	3.637	3.575	3.511	3.445	3.410	3.376	3.340	3.304	3.267	3.230
	0.025	8.073	6.542	5.890	5.523	5.285	5.119	4.995	4.899	4.823	4.761	4.666	4.568	4.467	4.415	4.362	4.309	4.254	4.199	4.142
	0.010	12.246	9.547	8.451	7.847	7.460	7.191	6.993	6.840	6.719	6.620	6.469	6.314	6.155	6.074	5.992	5.908	5.824	5.737	5.650
	0.005	16.236	12.404	10.882	10.050	9.522	9.155	8.885	8.678	8.514	8.380	8.176	7.968	7.754	7.645	7.534	7.422	7.309	7.193	7.076
	8	0.100	3.458	3.113	2.924	2.806	2.668	2.624	2.589	2.561	2.538	2.502	2.464	2.425	2.404	2.383	2.361	2.339	2.316	2.293
	0.050	5.318	4.459	4.066	3.838	3.687	3.581	3.500	3.438	3.388	3.347	3.284	3.218	3.150	3.115	3.079	3.043	3.005	2.967	2.928
	0.025	7.571	6.059	5.416	5.053	4.817	4.652	4.529	4.433	4.357	4.295	4.200	4.101	3.999	3.947	3.894	3.840	3.784	3.728	3.670
	0.010	11.259	8.649	7.591	7.006	6.632	6.371	6.178	6.029	5.911	5.814	5.667	5.515	5.359	5.279	5.198	5.116	5.032	4.946	4.859
	0.005	14.688	11.042	9.596	8.805	8.302	7.952	7.694	7.496	7.339	7.211	7.015	6.814	6.608	6.503	6.396	6.288	6.177	6.065	5.951
	9	0.100	3.360	3.006	2.813	2.693	2.611	2.551	2.469	2.440	2.416	2.379	2.340	2.298	2.277	2.255	2.232	2.208	2.184	2.159
	0.050	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.073	3.006	2.936	2.900	2.864	2.826	2.787	2.748	2.707
	0.025	7.209	5.715	5.078	4.718	4.484	4.320	4.197	4.102	4.026	3.964	3.868	3.769	3.667	3.614	3.560	3.505	3.449	3.392	3.333
	0.010	10.561	8.022	6.992	6.422	6.057	5.802	5.613	5.467	5.351	5.257	5.111	4.962	4.808	4.729	4.649	4.567	4.483	4.398	4.311
	0.005	13.614	10.107	8.717	7.956	7.471	7.134	6.885	6.693	6.541	6.417	6.227	6.032	5.832	5.729	5.625	5.519	5.410	5.300	5.188
	10	0.100	3.285	2.924	2.728	2.605	2.461	2.414	2.377	2.347	2.323	2.284	2.244	2.201	2.178	2.155	2.132	2.107	2.082	2.055
	0.050	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.913	2.845	2.774	2.737	2.700	2.661	2.621	2.580	2.538
	0.025	6.937	5.456	4.826	4.468	4.236	4.072	3.950	3.855	3.779	3.717	3.621	3.522	3.419	3.365	3.311	3.255	3.198	3.140	3.080
	0.010	10.044	7.559	6.552	5.994	5.636	5.386	5.200	5.057	4.942	4.849	4.706	4.558	4.405	4.327	4.247	4.165	4.082	3.996	3.909
	0.005	12.826	9.427	8.081	7.343	6.872	6.545	6.302	6.116	5.968	5.847	5.661	5.471	5.274	5.173	5.071	4.966	4.859	4.750	4.639

11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076	2.052	2.026	2.000	1.972
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570	2.531	2.490	2.448	2.404
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118	3.061	3.004	2.944	2.883
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941	3.860	3.776	3.690	3.602
	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654	4.551	4.445	4.337	4.226
12	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011	1.986	1.960	1.932	1.904
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466	2.426	2.384	2.341	2.296
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963	2.906	2.848	2.787	2.725
	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701	3.619	3.535	3.449	3.361
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331	4.228	4.123	4.015	3.904
13	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958	1.931	1.904	1.876	1.846
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380	2.339	2.297	2.252	2.206
	0.025	6.414	4.965	4.347	3.996	3.767	3.604	3.483	3.388	3.312	3.250	3.153	3.053	2.948	2.893	2.837	2.780	2.720	2.659	2.595
	0.010	9.074	6.701	5.739	5.205	4.862	4.620	4.441	4.302	4.191	4.100	3.960	3.815	3.665	3.587	3.507	3.425	3.341	3.255	3.165
	0.005	11.374	8.186	6.926	6.233	5.791	5.482	5.253	5.076	4.935	4.820	4.643	4.460	4.270	4.173	4.073	3.970	3.866	3.758	3.647
14	0.100	3.102	2.726	2.522	2.395	2.307	2.243	2.193	2.154	2.122	2.095	2.054	2.010	1.962	1.938	1.912	1.885	1.857	1.828	1.797
	0.050	4.600	3.739	3.344	3.112	2.958	2.848	2.764	2.699	2.646	2.602	2.534	2.463	2.388	2.349	2.308	2.266	2.223	2.178	2.131
	0.025	6.298	4.857	4.242	3.892	3.663	3.501	3.380	3.285	3.209	3.147	3.050	2.949	2.844	2.789	2.732	2.674	2.614	2.552	2.487
	0.010	8.862	6.515	5.564	5.035	4.695	4.456	4.278	4.140	4.030	3.939	3.800	3.656	3.505	3.427	3.348	3.266	3.181	3.094	3.004
	0.005	11.060	7.922	6.680	5.998	5.562	5.257	5.031	4.857	4.717	4.603	4.428	4.247	4.059	3.961	3.862	3.760	3.655	3.547	3.436
15	0.100	3.073	2.695	2.490	2.361	2.273	2.208	2.158	2.119	2.086	2.059	2.017	1.972	1.924	1.899	1.873	1.845	1.817	1.787	1.755
	0.050	4.543	3.682	3.287	3.056	2.901	2.790	2.707	2.641	2.588	2.544	2.475	2.403	2.328	2.288	2.247	2.204	2.160	2.114	2.066
	0.025	6.200	4.765	4.153	3.804	3.576	3.415	3.293	3.199	3.123	3.060	2.963	2.862	2.756	2.701	2.644	2.585	2.524	2.461	2.395
	0.010	8.683	6.359	5.417	4.893	4.556	4.318	4.142	4.004	3.895	3.805	3.666	3.522	3.372	3.294	3.214	3.132	3.047	2.959	2.868
	0.005	10.798	7.701	6.476	5.803	5.372	5.071	4.847	4.674	4.536	4.424	4.250	4.070	3.883	3.786	3.687	3.585	3.480	3.372	3.260
16	0.100	3.048	2.668	2.462	2.333	2.244	2.178	2.128	2.088	2.055	2.028	1.985	1.940	1.891	1.866	1.839	1.811	1.782	1.751	1.718
	0.050	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591	2.538	2.494	2.425	2.352	2.276	2.235	2.194	2.151	2.106	2.059	2.010
	0.025	6.115	4.687	4.077	3.729	3.502	3.341	3.219	3.125	3.049	2.986	2.889	2.788	2.681	2.625	2.568	2.509	2.447	2.383	2.316
	0.010	8.531	6.226	5.292	4.773	4.437	4.202	4.026	3.890	3.780	3.691	3.553	3.409	3.259	3.181	3.101	3.018	2.933	2.845	2.753

(continúa)

(continuación)

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
17	0.005	10.575	7.514	6.303	5.638	5.212	4.913	4.692	4.521	4.384	4.272	4.099	3.920	3.734	3.638	3.539	3.437	3.332	3.224	3.112
	0.100	3.026	2.645	2.437	2.308	2.218	2.152	2.102	2.061	2.028	2.001	1.958	1.912	1.862	1.836	1.809	1.781	1.751	1.719	1.686
	0.050	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.381	2.308	2.230	2.190	2.148	2.104	2.058	2.011	1.960
	0.025	6.042	4.619	4.011	3.665	3.438	3.277	3.156	3.061	2.985	2.922	2.825	2.723	2.616	2.560	2.502	2.442	2.380	2.315	2.247
	0.010	8.400	6.112	5.185	4.669	4.336	4.102	3.927	3.791	3.682	3.593	3.455	3.312	3.162	3.084	3.003	2.920	2.835	2.746	2.653
18	0.005	10.384	7.354	6.156	5.497	5.075	4.779	4.559	4.389	4.254	4.142	3.971	3.793	3.607	3.511	3.412	3.311	3.206	3.097	2.984
	0.100	3.007	2.624	2.416	2.286	2.196	2.130	2.079	2.038	2.005	1.977	1.933	1.887	1.837	1.810	1.783	1.754	1.723	1.691	1.657
	0.050	4.414	3.555	3.160	2.928	2.773	2.661	2.577	2.510	2.456	2.412	2.342	2.269	2.191	2.150	2.107	2.063	2.017	1.968	1.917
	0.025	5.978	4.560	3.954	3.608	3.382	3.221	3.100	3.005	2.929	2.866	2.769	2.667	2.559	2.503	2.445	2.384	2.321	2.256	2.187
	0.010	8.285	6.013	5.092	4.579	4.248	4.015	3.841	3.705	3.597	3.508	3.371	3.227	3.077	2.999	2.919	2.835	2.749	2.660	2.566
19	0.005	10.218	7.215	6.028	5.375	4.956	4.663	4.445	4.276	4.141	4.030	3.860	3.683	3.498	3.402	3.303	3.201	3.096	2.987	2.873
	0.100	2.990	2.606	2.397	2.266	2.176	2.109	2.058	2.017	1.984	1.956	1.912	1.865	1.814	1.787	1.759	1.730	1.699	1.666	1.631
	0.050	4.381	3.522	3.127	2.895	2.740	2.628	2.544	2.477	2.423	2.378	2.308	2.234	2.155	2.114	2.071	2.026	1.980	1.930	1.878
	0.025	5.922	4.508	3.903	3.559	3.333	3.172	3.051	2.956	2.880	2.817	2.720	2.617	2.509	2.452	2.394	2.333	2.270	2.203	2.133
	0.010	8.185	5.926	5.010	4.500	4.171	3.939	3.765	3.631	3.523	3.434	3.297	3.153	3.003	2.925	2.844	2.761	2.674	2.584	2.489
20	0.005	10.073	7.093	5.916	5.268	4.853	4.561	4.345	4.177	4.043	3.933	3.763	3.587	3.402	3.306	3.208	3.106	3.000	2.891	2.776
	0.100	2.975	2.589	2.380	2.249	2.158	2.091	2.040	1.999	1.965	1.937	1.892	1.845	1.794	1.767	1.738	1.708	1.677	1.643	1.607
	0.050	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447	2.393	2.348	2.278	2.203	2.124	2.082	2.039	1.994	1.946	1.896	1.843
	0.025	5.871	4.461	3.859	3.515	3.289	3.128	3.007	2.913	2.837	2.774	2.676	2.573	2.464	2.408	2.349	2.287	2.223	2.156	2.085
	0.010	8.096	5.849	4.938	4.431	4.103	3.871	3.699	3.564	3.457	3.368	3.231	3.088	2.938	2.859	2.778	2.695	2.608	2.517	2.421
21	0.005	9.944	6.986	5.818	5.174	4.762	4.472	4.257	4.090	3.956	3.847	3.678	3.502	3.318	3.222	3.123	3.022	2.916	2.806	2.690
	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719	1.689	1.657	1.623	1.586
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010	1.965	1.916	1.866	1.812
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	2.637	2.534	2.425	2.368	2.308	2.246	2.182	2.114	2.042
	0.010	8.017	5.780	4.874	4.369	4.042	3.812	3.640	3.506	3.398	3.310	3.173	3.030	2.880	2.801	2.720	2.636	2.548	2.457	2.360
22	0.005	9.830	6.891	5.730	5.091	4.681	4.393	4.179	4.013	3.880	3.771	3.602	3.427	3.243	3.147	3.049	2.947	2.841	2.730	2.614
	0.100	2.949	2.561	2.351	2.219	2.128	2.060	2.008	1.967	1.933	1.904	1.859	1.811	1.759	1.731	1.702	1.671	1.639	1.604	1.567
	0.050	4.301	3.443	3.049	2.817	2.661	2.549	2.464	2.397	2.342	2.297	2.226	2.151	2.071	2.028	1.984	1.938	1.889	1.838	1.783
	0.025	5.786	4.383	3.783	3.440	3.215	3.055	2.934	2.839	2.763	2.700	2.602	2.498	2.389	2.331	2.272	2.210	2.145	2.076	2.003

23	0.010	7.945	5.719	4.817	4.313	3.988	3.758	3.587	3.453	3.346	3.258	3.121	2.978	2.827	2.749	2.667	2.583	2.495	2.403	2.305
	0.005	9.727	6.806	5.652	5.017	4.609	4.322	4.109	3.944	3.812	3.703	3.535	3.360	3.176	3.081	2.982	2.880	2.774	2.663	2.546
	0.100	2.937	2.549	2.339	2.207	2.115	2.047	1.995	1.953	1.919	1.890	1.845	1.796	1.744	1.716	1.686	1.655	1.622	1.587	1.549
	0.050	4.279	3.422	3.028	2.796	2.640	2.528	2.442	2.375	2.320	2.275	2.204	2.128	2.048	2.005	1.961	1.914	1.865	1.813	1.757
	0.025	5.750	4.349	3.750	3.408	3.183	3.023	2.902	2.808	2.731	2.668	2.570	2.466	2.357	2.299	2.239	2.176	2.111	2.041	1.968
24	0.010	7.881	5.664	4.765	4.264	3.939	3.710	3.539	3.406	3.299	3.211	3.074	2.931	2.781	2.702	2.620	2.535	2.447	2.354	2.256
	0.005	9.635	6.730	5.582	4.950	4.544	4.259	4.047	3.882	3.750	3.642	3.475	3.300	3.116	3.021	2.922	2.820	2.713	2.602	2.484
	0.100	2.927	2.538	2.327	2.195	2.103	2.035	1.983	1.941	1.906	1.877	1.832	1.783	1.730	1.702	1.672	1.641	1.607	1.571	1.533
	0.050	4.260	3.403	3.009	2.776	2.621	2.508	2.423	2.355	2.300	2.255	2.183	2.108	2.027	1.984	1.939	1.892	1.842	1.790	1.733
	0.025	5.717	4.319	3.721	3.379	3.155	2.995	2.874	2.779	2.703	2.640	2.541	2.437	2.327	2.269	2.209	2.146	2.080	2.010	1.935
25	0.010	7.823	5.614	4.718	4.218	3.895	3.667	3.496	3.363	3.256	3.168	3.032	2.889	2.738	2.659	2.577	2.492	2.403	2.310	2.211
	0.005	9.551	6.661	5.519	4.890	4.486	4.202	3.991	3.826	3.695	3.587	3.420	3.246	3.062	2.967	2.868	2.765	2.658	2.546	2.428
	0.100	2.918	2.528	2.317	2.184	2.092	2.024	1.971	1.929	1.895	1.866	1.820	1.771	1.718	1.689	1.659	1.627	1.593	1.557	1.518
	0.050	4.242	3.385	2.991	2.759	2.603	2.490	2.405	2.337	2.282	2.236	2.165	2.089	2.007	1.964	1.919	1.872	1.822	1.768	1.711
	0.025	5.686	4.291	3.694	3.353	3.129	2.969	2.848	2.753	2.677	2.613	2.515	2.411	2.300	2.242	2.182	2.118	2.052	1.981	1.906
26	0.010	7.770	5.568	4.675	4.177	3.855	3.627	3.457	3.324	3.217	3.129	2.993	2.850	2.699	2.620	2.538	2.453	2.364	2.270	2.169
	0.005	9.475	6.598	5.462	4.835	4.433	4.150	3.939	3.776	3.645	3.537	3.370	3.196	3.013	2.918	2.819	2.716	2.609	2.496	2.377
	0.100	2.909	2.519	2.307	2.174	2.082	2.014	1.961	1.919	1.884	1.855	1.809	1.760	1.706	1.677	1.647	1.615	1.581	1.544	1.504
	0.050	4.225	3.369	2.975	2.743	2.587	2.474	2.388	2.321	2.265	2.220	2.148	2.072	1.990	1.946	1.901	1.853	1.803	1.749	1.691
	0.025	5.659	4.265	3.670	3.329	3.105	2.945	2.824	2.729	2.653	2.590	2.491	2.387	2.276	2.217	2.157	2.093	2.026	1.954	1.878
27	0.010	7.721	5.526	4.637	4.140	3.818	3.591	3.421	3.288	3.182	3.094	2.958	2.815	2.664	2.585	2.503	2.417	2.327	2.233	2.131
	0.005	9.406	6.541	5.409	4.785	4.384	4.103	3.893	3.730	3.599	3.492	3.325	3.151	2.968	2.873	2.774	2.671	2.563	2.450	2.330
	0.100	2.901	2.511	2.299	2.165	2.073	2.005	1.952	1.909	1.874	1.845	1.799	1.749	1.695	1.666	1.636	1.603	1.569	1.531	1.491
	0.050	4.210	3.354	2.960	2.728	2.572	2.459	2.373	2.305	2.250	2.204	2.132	2.056	1.974	1.930	1.884	1.836	1.785	1.731	1.672
	0.025	5.633	4.242	3.647	3.307	3.083	2.923	2.802	2.707	2.631	2.568	2.469	2.364	2.253	2.195	2.133	2.069	2.002	1.930	1.853
28	0.010	7.677	5.488	4.601	4.106	3.785	3.558	3.388	3.256	3.149	3.062	2.926	2.783	2.632	2.552	2.470	2.384	2.294	2.198	2.097
	0.005	9.342	6.489	5.361	4.740	4.340	4.059	3.850	3.687	3.557	3.450	3.284	3.110	2.928	2.832	2.733	2.630	2.522	2.408	2.287
	0.100	2.894	2.503	2.291	2.157	2.064	1.996	1.943	1.900	1.865	1.836	1.790	1.740	1.685	1.656	1.625	1.592	1.558	1.520	1.478
	0.050	4.196	3.340	2.947	2.714	2.558	2.445	2.359	2.291	2.236	2.190	2.118	2.041	1.959	1.915	1.869	1.820	1.769	1.714	1.654


(continúa)

(continuación)

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
	0.025	5.610	4.221	3.626	3.286	3.063	2.903	2.782	2.687	2.611	2.547	2.448	2.344	2.232	2.174	2.112	2.048	1.980	1.907	1.829
	0.010	7.636	5.453	4.568	4.074	3.754	3.528	3.358	3.226	3.120	3.032	2.896	2.753	2.602	2.522	2.440	2.354	2.263	2.167	2.064
	0.005	9.284	6.440	5.317	4.698	4.300	4.020	3.811	3.649	3.519	3.412	3.246	3.073	2.890	2.794	2.695	2.592	2.483	2.369	2.247
29	0.100	2.887	2.495	2.283	2.149	2.057	1.988	1.935	1.892	1.857	1.827	1.781	1.731	1.676	1.647	1.616	1.583	1.547	1.509	1.467
	0.050	4.183	3.328	2.934	2.701	2.545	2.432	2.346	2.278	2.223	2.177	2.104	2.027	1.945	1.901	1.854	1.806	1.754	1.698	1.638
	0.025	5.588	4.201	3.607	3.267	3.044	2.884	2.763	2.669	2.592	2.529	2.430	2.325	2.213	2.154	2.092	2.028	1.959	1.886	1.807
	0.010	7.598	5.420	4.538	4.045	3.725	3.499	3.330	3.198	3.092	3.005	2.868	2.726	2.574	2.495	2.412	2.325	2.234	2.138	2.034
	0.005	9.230	6.396	5.276	4.659	4.262	3.983	3.775	3.613	3.483	3.377	3.211	3.038	2.855	2.759	2.660	2.557	2.448	2.333	2.210
	0.100	2.881	2.489	2.276	2.142	2.049	1.980	1.927	1.884	1.849	1.819	1.773	1.722	1.667	1.638	1.606	1.573	1.538	1.499	1.456
30	0.050	4.171	3.316	2.922	2.690	2.534	2.421	2.334	2.266	2.211	2.165	2.092	2.015	1.932	1.887	1.841	1.792	1.740	1.683	1.622
	0.025	5.568	4.182	3.589	3.250	3.026	2.867	2.746	2.651	2.575	2.511	2.412	2.307	2.195	2.136	2.074	2.009	1.940	1.866	1.787
	0.010	7.562	5.390	4.510	4.018	3.699	3.473	3.304	3.173	3.067	2.979	2.843	2.700	2.549	2.469	2.386	2.299	2.208	2.111	2.006
	0.005	9.180	6.355	5.239	4.623	4.228	3.949	3.742	3.580	3.450	3.344	3.179	3.006	2.823	2.727	2.628	2.524	2.415	2.300	2.176
	0.100	2.835	2.440	2.226	2.091	1.997	1.927	1.873	1.829	1.793	1.763	1.715	1.662	1.605	1.574	1.541	1.506	1.467	1.425	1.377
	0.050	4.085	3.232	2.839	2.606	2.449	2.336	2.249	2.180	2.124	2.077	2.003	1.924	1.839	1.793	1.744	1.693	1.637	1.577	1.509
40	0.025	5.424	4.051	3.463	3.126	2.904	2.744	2.624	2.529	2.452	2.388	2.288	2.182	2.068	2.007	1.943	1.875	1.803	1.724	1.637
	0.010	7.314	5.179	4.313	3.828	3.514	3.291	3.124	2.993	2.888	2.801	2.665	2.522	2.369	2.288	2.203	2.114	2.019	1.917	1.805
	0.005	8.828	6.066	4.976	4.374	3.986	3.713	3.509	3.350	3.222	3.117	2.953	2.781	2.598	2.502	2.401	2.296	2.184	2.064	1.932
60	0.100	2.791	2.393	2.177	2.041	1.946	1.875	1.819	1.775	1.738	1.707	1.657	1.603	1.543	1.511	1.476	1.437	1.395	1.348	1.291
	0.050	4.001	3.150	2.758	2.525	2.368	2.254	2.167	2.097	2.040	1.993	1.917	1.836	1.748	1.700	1.649	1.594	1.534	1.467	1.389
	0.025	5.286	3.925	3.343	3.008	2.786	2.627	2.507	2.412	2.334	2.270	2.169	2.061	1.944	1.882	1.815	1.744	1.667	1.581	1.482
	0.010	7.077	4.977	4.126	3.649	3.339	3.119	2.953	2.823	2.718	2.632	2.496	2.352	2.198	2.115	2.028	1.936	1.836	1.726	1.601
	0.005	8.495	5.795	4.729	4.140	3.760	3.492	3.291	3.134	3.008	2.904	2.742	2.570	2.387	2.290	2.187	2.079	1.962	1.834	1.689
	0.100	2.835	2.440	2.226	2.091	1.997	1.927	1.873	1.829	1.793	1.763	1.715	1.662	1.605	1.574	1.541	1.506	1.467	1.425	1.377
80	0.050	4.085	3.232	2.839	2.606	2.449	2.336	2.249	2.180	2.124	2.077	2.003	1.924	1.839	1.793	1.744	1.693	1.637	1.577	1.509
	0.025	5.424	4.051	3.463	3.126	2.904	2.744	2.624	2.529	2.452	2.388	2.288	2.182	2.068	2.007	1.943	1.875	1.803	1.724	1.637
	0.010	7.314	5.179	4.313	3.828	3.514	3.291	3.124	2.993	2.888	2.801	2.665	2.522	2.369	2.288	2.203	2.114	2.019	1.917	1.805
	0.005	8.828	6.066	4.976	4.374	3.986	3.713	3.509	3.350	3.222	3.117	2.953	2.781	2.598	2.502	2.401	2.296	2.184	2.064	1.932

100	0.100	2.791	2.393	2.177	2.041	1.946	1.875	1.819	1.775	1.738	1.707	1.657	1.603	1.543	1.511	1.476	1.437	1.395	1.348	1.291
	0.050	4.001	3.150	2.758	2.525	2.368	2.254	2.167	2.097	2.040	1.993	1.917	1.836	1.748	1.700	1.649	1.594	1.534	1.467	1.389
	0.025	5.286	3.925	3.343	3.008	2.786	2.627	2.507	2.412	2.334	2.270	2.169	2.061	1.944	1.882	1.815	1.744	1.667	1.581	1.482
	0.010	7.077	4.977	4.126	3.649	3.339	3.119	2.953	2.823	2.718	2.632	2.496	2.352	2.198	2.115	2.028	1.936	1.836	1.726	1.601
	0.005	8.495	5.795	4.729	4.140	3.760	3.492	3.291	3.134	3.008	2.904	2.742	2.570	2.387	2.290	2.187	2.079	1.962	1.834	1.689
120	0.100	2.748	2.347	2.130	1.992	1.896	1.824	1.767	1.722	1.684	1.652	1.601	1.545	1.482	1.447	1.409	1.368	1.320	1.265	1.193
	0.050	3.920	3.072	2.680	2.447	2.290	2.175	2.087	2.016	1.959	1.910	1.834	1.750	1.659	1.608	1.554	1.495	1.429	1.352	1.254
	0.025	5.152	3.805	3.227	2.894	2.674	2.515	2.395	2.299	2.222	2.157	2.055	1.945	1.825	1.760	1.690	1.614	1.530	1.433	1.310
	0.010	6.851	4.787	3.949	3.480	3.174	2.956	2.792	2.663	2.559	2.472	2.336	2.192	2.035	1.950	1.860	1.763	1.656	1.533	1.381
	0.005	8.179	5.539	4.497	3.921	3.548	3.285	3.087	2.933	2.808	2.705	2.544	2.373	2.188	2.089	1.984	1.871	1.747	1.606	1.431
150	0.100	2.791	2.393	2.177	2.041	1.946	1.875	1.819	1.775	1.738	1.707	1.657	1.603	1.543	1.511	1.476	1.437	1.395	1.348	1.291
	0.050	4.001	3.150	2.758	2.525	2.368	2.254	2.167	2.097	2.040	1.993	1.917	1.836	1.748	1.700	1.649	1.594	1.534	1.467	1.389
	0.025	5.286	3.925	3.343	3.008	2.786	2.627	2.507	2.412	2.334	2.270	2.169	2.061	1.944	1.882	1.815	1.744	1.667	1.581	1.482
	0.010	7.077	4.977	4.126	3.649	3.339	3.119	2.953	2.823	2.718	2.632	2.496	2.352	2.198	2.115	2.028	1.936	1.836	1.726	1.601
	0.005	8.495	5.795	4.729	4.140	3.760	3.492	3.291	3.134	3.008	2.904	2.742	2.570	2.387	2.290	2.187	2.079	1.962	1.834	1.689
200	0.100	2.748	2.347	2.130	1.992	1.896	1.824	1.767	1.722	1.684	1.652	1.601	1.545	1.482	1.447	1.409	1.368	1.320	1.265	1.193
	0.050	3.920	3.072	2.680	2.447	2.290	2.175	2.087	2.016	1.959	1.910	1.834	1.750	1.659	1.608	1.554	1.495	1.429	1.352	1.254
	0.025	5.152	3.805	3.227	2.894	2.674	2.515	2.395	2.299	2.222	2.157	2.055	1.945	1.825	1.760	1.690	1.614	1.530	1.433	1.310
	0.010	6.851	4.787	3.949	3.480	3.174	2.956	2.792	2.663	2.559	2.472	2.336	2.192	2.035	1.950	1.860	1.763	1.656	1.533	1.381
	0.005	8.179	5.539	4.497	3.921	3.548	3.285	3.087	2.933	2.808	2.705	2.544	2.373	2.188	2.089	1.984	1.871	1.747	1.606	1.431
∞	0.100	2.706	2.303	2.084	1.945	1.847	1.774	1.717	1.670	1.632	1.599	1.546	1.487	1.421	1.383	1.342	1.295	1.240	1.169	1.000
	0.050	3.841	2.996	2.605	2.372	2.214	2.099	2.010	1.938	1.880	1.831	1.752	1.666	1.571	1.517	1.459	1.394	1.318	1.221	1.000
	0.025	5.024	3.689	3.116	2.786	2.567	2.408	2.288	2.192	2.114	2.048	1.945	1.833	1.708	1.640	1.566	1.484	1.388	1.268	1.000
	0.010	6.635	4.605	3.782	3.319	3.017	2.802	2.639	2.511	2.407	2.321	2.185	2.039	1.878	1.791	1.696	1.592	1.473	1.325	1.000
	0.005	7.879	5.298	4.279	3.715	3.350	3.091	2.897	2.744	2.621	2.519	2.358	2.187	2.000	1.898	1.789	1.669	1.533	1.364	1.000

Anexo 2.4 Tabla normal estándar




z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0396	0.0438	0.0476	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.4	0.1554	0.1591	0.1626	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.0	0.3413	0.3438	0.3461	0.3485	0.3506	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3543	0.3665	0.3586	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.2	0.3849	0.3859	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.3	0.4032	0.4049	0.4066	0.4062	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.4	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.5	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.7	0.4554	0.4554	0.4573	0.4582	0.4591	0.4599	0.4606	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4736	0.4744	0.4750	0.4756	0.4761	0.4767
2.0	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.1	0.4821	0.4826	0.4830	0.4834	0.4836	0.4842	0.4846	0.4850	0.4854	0.4857
2.2	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.3	0.4893	0.4896	0.4896	0.4907	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.4	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.5	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4946	0.4949	0.4951	0.4952
2.6	0.4953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.8	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.9	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986

(continúa)

(continuación)

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
3.0	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990
3.1	0.4990	0.4991	0.4991	0.4991	0.4992	0.4992	0.4992	0.4992	0.4993	0.4993
3.2	0.4993	0.4993	0.4994	0.4994	0.4994	0.4994	0.4994	0.4995	0.4995	0.4995
3.3	0.4995	0.4995	0.4995	0.4996	0.4996	0.4996	0.4996	0.4996	0.4996	0.4997
3.4	0.4997	0.4997	0.4997	0.4997	0.4997	0.4997	0.4997	0.4997	0.4997	0.4998
3.5	0.4998	0.4998	0.4998	0.4998	0.4998	0.4998	0.4998	0.4998	0.4998	0.4998
3.6	0.4998	0.4998	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999
3.7	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999
3.8	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999	0.4999
3.9	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000
4.0	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000




z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-4.0	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-3.9	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
-3.8	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001
-3.7	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001	0.0001
-3.6	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002
-3.5	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002	0.0002
-3.4	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0003	0.0002
-3.3	0.0005	0.0005	0.0005	0.0004	0.0004	0.0004	0.0004	0.0004	0.0004	0.0003
-3.2	0.0007	0.0007	0.0006	0.0006	0.0006	0.0006	0.0006	0.0005	0.0005	0.0005
-3.1	0.0010	0.0009	0.0009	0.0009	0.0008	0.0008	0.0008	0.0008	0.0007	0.0007
-3.0	0.0013	0.0013	0.0013	0.0012	0.0012	0.0011	0.0011	0.0011	0.0010	0.0010
-2.9	0.0019	0.0018	0.0018	0.0017	0.0016	0.0016	0.0015	0.0015	0.0014	0.0014
-2.8	0.0026	0.0025	0.0024	0.0023	0.0023	0.0022	0.0021	0.0021	0.0020	0.0019
-2.7	0.0035	0.0034	0.0033	0.0032	0.0031	0.0030	0.0029	0.0028	0.0027	0.0026
-2.6	0.0047	0.0045	0.0044	0.0043	0.0041	0.0040	0.0039	0.0038	0.0037	0.0036
-2.5	0.0062	0.0060	0.0059	0.0057	0.0055	0.0054	0.0052	0.0051	0.0049	0.0048

(continúa)

(continuación)

z	0.00	-0.01	-0.02	-0.03	-0.04	-0.05	-0.06	-0.07	-0.08	-0.09
-2.4	0.0082	0.0080	0.0076	0.0075	0.0073	0.0071	0.0069	0.0068	0.0066	0.0064
-2.3	0.0107	0.0104	0.0102	0.0099	0.0096	0.0094	0.0091	0.0089	0.0087	0.0084
-2.2	0.0139	0.0136	0.0132	0.0129	0.0125	0.0122	0.0119	0.0116	0.0113	0.0110
-2.1	0.0179	0.0174	0.0170	0.0166	0.0162	0.0158	0.0154	0.0150	0.0146	0.0143
-2.0	0.0228	0.0222	0.0217	0.0212	0.0207	0.0202	0.0197	0.0192	0.0188	0.0183
-1.9	0.0287	0.0281	0.0274	0.0268	0.0262	0.0256	0.0250	0.0244	0.0239	0.0233
-1.8	0.0359	0.0351	0.0344	0.0336	0.0329	0.0322	0.0314	0.0307	0.0301	0.0294
-1.7	0.0446	0.0436	0.0427	0.0418	0.0409	0.0401	0.0392	0.0384	0.0375	0.0367
-1.6	0.0548	0.0537	0.0526	0.0516	0.0505	0.0495	0.0485	0.0475	0.0465	0.0455
-1.5	0.0668	0.0655	0.0643	0.0630	0.0618	0.0606	0.0594	0.0582	0.0571	0.0559
-1.4	0.0808	0.0793	0.0778	0.0764	0.0749	0.0735	0.0721	0.0708	0.0694	0.0681
-1.3	0.0968	0.0951	0.0934	0.0918	0.0901	0.0885	0.0869	0.0853	0.0838	0.0823
-1.2	0.1151	0.1131	0.1112	0.1093	0.1075	0.1056	0.1038	0.1020	0.1003	0.0985
-1.1	0.1357	0.1335	0.1314	0.1292	0.1271	0.1251	0.1230	0.1210	0.1190	0.1170
-1.0	0.1587	0.1562	0.1539	0.1515	0.1492	0.1469	0.1446	0.1423	0.1401	0.1379
-0.9	0.1841	0.1814	0.1786	0.1762	0.1736	0.1711	0.1685	0.1660	0.1635	0.1611
-0.8	0.2119	0.2090	0.2061	0.2033	0.2005	0.1977	0.1949	0.1922	0.1894	0.1867
-0.7	0.2420	0.2389	0.2358	0.2327	0.2296	0.2266	0.2236	0.2206	0.2177	0.2148
-0.6	0.2743	0.2709	0.2676	0.2643	0.2611	0.2578	0.2546	0.2514	0.2483	0.2451
-0.5	0.3085	0.3050	0.3015	0.2981	0.2946	0.2912	0.2877	0.2843	0.2810	0.2776
-0.4	0.3446	0.3409	0.3372	0.3336	0.3300	0.3264	0.3226	0.3192	0.3156	0.3121
-0.3	0.3821	0.3783	0.3745	0.3707	0.3669	0.3632	0.3594	0.3557	0.3520	0.3483
-0.2	0.4207	0.4168	0.4129	0.4090	0.4052	0.4013	0.3974	0.3936	0.3897	0.3859
-0.1	0.4602	0.4562	0.4522	0.4483	0.4443	0.4404	0.4364	0.4325	0.4286	0.4247
0.0	0.5000	0.4960	0.4920	0.4882	0.4840	0.4801	0.4761	0.4721	0.4681	0.4641




z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5396	0.5438	0.5476	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517

(continúa)

(continuación)

[illegible]

Anexo 2.5 Tabla Durbin-Watson



K = 1		K = 2		K = 3		K = 4		K = 5		K = 6		K = 7		K = 8		K = 9		K = 10	
n	α	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
6	0.05	0.610	1.400	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
	0.01	0.390	1.142	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7	0.05	0.700	1.356	0.467	1.896	...	...	...	...	...	...	...	...	...	...	...	...	...	...
	0.01	0.435	1.036	0.294	1.676	...	...	...	...	...	...	...	...	...	...	...	...	...	...
8	0.05	0.763	1.332	0.559	1.777	0.368	2.287	...	...	...	...	...	...	...	...	...	...	...	...
	0.01	0.497	1.003	0.345	1.489	0.229	2.102	...	...	...	...	...	...	...	...	...	...	...	...
9	0.05	0.824	1.320	0.629	1.699	0.455	2.128	0.296	2.588	...	...	...	...	...	...	...	...	...	...
	0.01	0.554	0.998	0.408	1.389	0.279	1.875	0.183	2.443	...	...	...	...	...	...	...	...	...	...
10	0.05	0.879	1.320	0.697	1.641	0.525	2.016	0.376	2.414	0.243	2.822	...	...	...	...	...	...	...	...
	0.01	0.604	1.001	0.466	1.333	0.340	1.733	0.230	2.193	0.150	2.690	...	...	...	...	...	...	...	...
11	0.05	0.927	1.324	0.758	1.604	0.595	1.928	0.444	2.283	0.316	2.645	0.203	3.005	...	...	...	...	...	...
	0.01	0.653	1.010	0.519	1.297	0.396	1.640	0.286	2.030	0.193	2.453	0.124	2.892	...	...	...	...	...	...
12	0.05	0.971	1.331	0.812	1.579	0.658	1.864	0.512	2.177	0.379	2.506	0.268	2.832	0.171	3.149	...	...	...	...
	0.01	0.697	1.023	0.569	1.274	0.449	1.575	0.339	1.913	0.244	2.280	0.164	2.665	0.105	3.053	...	...	...	...
13	0.05	1.010	1.340	0.861	1.562	0.715	1.816	0.574	2.094	0.445	2.390	0.328	2.692	0.230	2.985	0.147	3.266	...	...
	0.01	0.738	1.038	0.616	1.261	0.449	1.526	0.391	1.826	0.294	2.150	0.211	2.490	0.140	2.838	0.090	3.182	...	...

14	0.05	1.045	1.350	0.905	1.551	0.767	1.779	0.632	2.030	0.505	2.296	0.389	2.572	0.286	2.848	0.200	3.111	0.127	3.360	...	...
	0.01	0.776	1.054	0.66	1.254	0.547	1.490	0.441	1.757	0.343	2.049	0.257	2.354	0.183	2.667	0.122	2.981	0.078	3.287	...	...
15	0.05	1.077	1.361	0.946	1.543	0.814	1.750	0.685	1.977	0.562	2.220	0.447	2.472	0.343	2.727	0.251	2.979	0.175	3.216	0.111	3.438
	0.01	0.811	1.070	0.700	1.252	0.591	1.464	0.488	1.704	0.391	1.967	0.303	2.244	0.226	2.530	0.161	2.817	0.107	3.101	0.068	3.374
16	0.05	1.106	1.371	0.982	1.539	0.857	1.728	0.734	1.935	0.615	2.157	0.502	2.388	0.398	2.624	0.304	2.860	0.222	3.090	0.155	3.304
	0.01	0.844	1.086	0.737	1.252	0.633	1.446	0.532	1.663	0.437	1.900	0.349	2.153	0.269	2.416	0.200	2.681	0.142	2.944	0.094	3.201
17	0.05	1.133	1.381	1.015	1.536	0.897	1.710	0.779	1.900	0.664	2.104	0.554	2.318	0.451	2.537	0.356	2.757	0.272	2.975	0.198	3.184
	0.01	0.874	1.102	0.772	1.256	0.672	1.432	0.574	1.630	0.480	1.847	0.393	2.078	0.313	2.319	0.241	2.566	0.179	2.811	0.127	3.053
18	0.05	1.158	1.391	1.046	1.535	0.933	1.696	0.820	1.872	0.710	2.060	0.603	2.257	0.502	2.461	0.407	2.667	0.321	2.873	0.244	3.073
	0.01	0.902	1.118	0.805	1.259	0.708	1.422	0.613	1.604	0.522	1.803	0.435	2.015	0.355	2.238	0.282	2.467	0.216	2.691	0.160	2.925
19	0.05	1.180	1.401	1.074	1.536	0.967	1.685	0.859	1.848	0.752	2.023	0.649	2.206	0.459	2.396	0.456	2.589	0.369	2.783	0.290	2.974
	0.01	0.928	1.132	0.835	1.265	0.742	1.415	0.650	1.584	0.561	1.767	0.476	1.963	0.396	2.169	0.322	2.381	0.255	2.597	0.196	2.813
20	0.05	1.201	1.411	1.100	1.537	0.998	1.676	0.894	1.828	0.792	1.991	0.692	2.162	0.595	2.339	0.502	2.521	0.416	2.704	0.336	2.885
	0.01	0.952	1.147	0.863	1.271	0.773	1.411	0.685	1.567	0.598	1.737	0.515	1.918	0.436	2.110	0.362	2.308	0.294	2.510	0.232	2.714
21	0.05	1.221	1.420	1.125	1.538	1.026	1.669	0.927	1.812	0.829	1.964	0.732	2.124	0.637	2.290	0.547	2.460	0.461	2.633	0.380	2.806
	0.01	0.975	1.161	0.890	1.277	0.803	1.408	0.718	1.554	0.633	1.712	0.552	1.881	0.474	2.059	0.400	2.244	0.331	2.434	0.268	2.625

(continuación)

$K = 1$		$K = 2$		$K = 3$		$K = 4$		$K = 5$		$K = 6$		$K = 7$		$K = 8$		$K = 9$		$K = 10$	
n	α	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
30	0.01	1.119	1.254	1.054	1.332	0.988	1.418	0.921	1.512	0.855	1.611	0.788	1.718	0.723	1.830	0.658	1.947	0.595	2.068
	0.05	1.352	1.489	1.284	1.567	1.214	1.650	1.143	1.739	1.071	1.833	0.998	1.931	0.926	2.034	0.854	2.141	0.782	2.251
31	0.01	1.133	1.263	1.070	1.339	1.006	1.421	0.941	1.511	0.877	1.606	0.812	1.707	0.748	1.814	0.684	1.925	0.622	2.041
	0.05	1.363	1.496	1.297	1.570	1.229	1.650	1.160	1.735	1.090	1.825	1.020	1.920	0.950	2.018	0.879	2.120	0.810	2.226
32	0.01	1.147	1.273	1.085	1.345	1.023	1.425	0.960	1.510	0.897	1.601	0.834	1.698	0.772	1.800	0.710	1.906	0.649	2.017
	0.05	1.373	1.502	1.309	1.574	1.244	1.650	1.177	1.732	1.109	1.819	1.041	1.909	0.972	2.004	0.904	2.102	0.836	2.203
33	0.01	1.160	1.282	1.100	1.352	1.040	1.428	0.979	1.510	0.917	1.597	0.856	1.690	0.794	1.788	0.734	1.889	0.674	1.995
	0.05	1.383	1.508	1.321	1.577	1.258	1.651	1.193	1.730	1.127	1.813	1.061	1.900	0.994	1.991	0.927	2.085	0.861	2.181
34	0.01	1.172	1.291	1.114	1.358	1.055	1.432	0.996	1.510	0.936	1.594	0.876	1.683	0.816	1.776	0.757	1.874	0.698	1.975
	0.05	1.393	1.514	1.333	1.580	1.271	1.652	1.208	1.728	1.144	1.808	1.080	1.891	1.015	1.979	0.950	2.069	0.885	2.162
35	0.01	1.184	1.299	1.128	1.364	1.070	1.435	1.012	1.511	0.954	1.591	0.896	1.677	0.837	1.766	0.779	1.860	0.722	1.957
	0.05	1.402	1.519	1.343	1.584	1.283	1.653	1.222	1.726	1.160	1.803	1.097	1.884	1.034	1.967	0.971	2.054	0.908	2.144
36	0.01	1.195	1.307	1.140	1.370	1.085	1.439	1.028	1.512	0.971	1.589	0.914	1.671	0.857	1.757	0.800	1.847	0.744	1.940
	0.05	1.411	1.525	1.354	1.587	1.295	1.654	1.236	1.724	1.175	1.799	1.114	1.877	1.053	1.957	0.991	2.041	0.930	2.127
37	0.01	1.206	1.315	1.153	1.376	1.098	1.442	1.043	1.513	0.988	1.588	0.932	1.666	0.877	1.749	0.821	1.836	0.766	1.825
	0.05	1.419	1.530	1.364	1.590	1.307	1.655	1.249	1.723	1.190	1.795	1.131	1.870	1.071	1.948	1.011	2.029	0.951	2.112
38	0.01	1.217	1.323	1.165	1.382	1.112	1.446	1.058	1.514	1.004	1.586	0.950	1.662	0.895	1.742	0.841	1.825	0.787	1.911
	0.05	1.427	1.535	1.373	1.594	1.318	1.656	1.261	1.722	1.204	1.792	1.146	1.864	1.088	1.939	1.029	2.017	0.970	2.098
39	0.01	1.227	1.330	1.176	1.388	1.124	1.449	1.072	1.515	1.019	1.585	0.966	1.658	0.913	1.735	0.860	1.816	0.807	1.899
	0.05	1.237	1.337	1.187	1.393	1.137	1.453	1.085	1.517	1.034	1.584	0.982	1.655	0.930	1.729	0.878	1.807	0.826	1.887

n	α	$K = 11$		$K = 12$		$K = 13$		$K = 14$		$K = 15$		$K = 16$		$K = 17$		$K = 18$		$K = 19$		$K = 20$	
		d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
22	0.05	0.349	2.897	0.281	3.057	0.220	3.211	0.166	3.358	0.120	3.495	0.083	3.619	0.052	3.731						
	0.01	0.246	2.729	0.194	2.909	0.148	3.084	0.109	3.252	0.077	3.412	0.050	3.562	0.032	3.700						
23	0.05	0.391	2.826	0.322	2.979	0.259	3.128	0.202	3.272	0.153	3.409	0.110	3.535	0.076	3.650	0.048	3.753				
	0.01	0.281	2.651	0.227	2.822	0.178	2.991	0.136	3.155	0.100	3.311	0.070	3.459	0.046	3.597	0.029	3.725				
24	0.05	0.431	2.761	0.362	2.908	0.297	3.053	0.239	3.193	0.186	3.327	0.141	3.454	0.101	3.572	0.070	3.678	0.044	3.773		
	0.01	0.315	2.580	0.260	2.744	0.209	2.906	0.165	3.085	0.125	3.218	0.092	3.363	0.065	3.501	0.043	3.629	0.027	3.747		
25	0.05	0.470	2.702	0.400	2.844	0.335	2.983	0.275	3.119	0.221	3.251	0.172	3.376	0.130	3.494	0.094	3.604	0.065	3.702	0.041	3.790
	0.01	0.348	2.517	0.292	2.674	0.240	2.829	0.194	2.982	0.152	3.131	0.116	3.274	0.085	3.410	0.060	3.538	0.039	3.657	0.025	3.766
26	0.05	0.508	2.649	0.438	2.784	0.373	2.919	0.312	3.051	0.256	2.179	0.205	3.303	0.160	3.420	0.120	3.531	0.087	3.632	0.060	3.724
	0.01	0.381	2.460	0.324	2.610	0.272	2.758	0.224	2.906	0.180	3.050	0.141	3.191	0.107	3.325	0.079	3.452	0.055	3.572	0.038	3.682
27	0.05	0.544	2.600	0.475	2.730	0.409	2.859	0.348	2.987	0.291	3.112	0.238	3.233	0.191	3.349	0.149	3.460	0.112	3.583	0.081	3.658
	0.01	0.413	2.409	0.356	2.552	0.303	2.694	0.253	2.836	0.208	2.976	0.167	3.113	0.131	3.245	0.100	3.371	0.073	3.490	0.051	3.602
28	0.05	0.578	2.555	0.510	2.680	0.445	2.805	0.383	2.928	0.325	3.050	0.271	3.169	0.222	3.283	0.178	3.392	0.138	3.494	0.104	3.592
	0.01	0.444	2.363	0.387	2.499	0.333	2.635	0.283	2.772	0.237	2.907	0.194	3.040	0.156	3.169	0.122	3.294	0.093	3.412	0.068	3.524
29	0.05	0.612	2.515	0.544	2.634	0.479	2.755	0.418	2.874	0.359	2.991	0.305	3.107	0.254	3.219	0.208	3.327	0.166	3.431	0.129	3.528
	0.01	0.474	2.321	0.417	2.451	0.363	2.582	0.313	2.713	0.266	2.843	0.222	2.972	0.182	3.098	0.146	3.220	0.114	3.338	0.087	3.450
30	0.05	0.643	2.477	0.577	2.592	0.512	2.708	0.451	2.823	0.392	2.937	0.337	3.050	0.286	3.160	0.238	3.266	0.195	3.368	.0156	3.465
	0.01	0.503	2.283	0.447	2.407	0.393	2.533	0.342	2.659	0.294	2.785	0.249	2.909	0.208	3.032	0.171	3.152	0.137	3.267	0.107	3.379
31	0.05	0.674	2.443	0.608	2.553	0.545	2.665	0.484	2.776	0.425	2.987	0.370	2.996	0.317	3.103	0.269	3.208	0.224	3.309	0.183	3.406
	0.01	0.531	2.248	0.475	2.367	0.422	2.487	0.371	2.609	0.322	2.730	0.277	2.851	0.234	2.970	0.196	3.087	0.160	3.201	0.128	3.311
32	0.05	0.703	2.411	0.638	2.517	0.576	2.625	0.515	2.733	0.457	2.840	0.401	2.946	0.349	3.050	0.299	3.153	0.253	3.252	0.211	3.348
	0.01	0.558	2.216	0.503	2.330	0.450	2.446	0.399	2.583	0.350	2.680	0.304	2.797	0.261	2.912	0.221	3.026	0.184	3.137	0.151	3.246
33	0.05	0.731	2.382	0.668	2.484	0.606	2.588	0.546	2.692	0.488	2.796	0.432	2.899	0.379	3.000	0.329	3.100	0.283	3.198	0.239	3.293
	0.01	0.585	2.187	0.530	2.296	0.477	2.408	0.426	2.520	0.377	2.633	0.331	2.746	0.287	2.858	0.246	2.989	0.209	3.078	0.174	3.184

(continúa)

(continuación)

		$K = 1$		$K = 2$		$K = 3$		$K = 4$		$K = 5$		$K = 6$		$K = 7$		$K = 8$		$K = 9$		$K = 10$	
		d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
n	α																				
34	0.05	0.758	2.355	0.695	2.454	0.634	2.554	0.575	2.654	0.518	2.754	0.462	2.854	0.409	2.954	0.359	3.051	0.312	3.147	0.267	3.240
	0.01	0.610	2.160	0.556	2.266	0.503	2.373	0.452	2.481	0.404	2.590	0.357	2.699	0.313	2.808	0.272	2.915	0.233	3.022	0.197	3.126
35	0.05	0.783	2.330	0.722	2.425	0.682	2.521	0.604	2.619	0.547	2.716	0.492	2.813	0.439	2.910	0.388	3.005	0.340	3.099	0.295	3.190
	0.01	0.634	2.136	0.581	2.237	0.529	2.340	0.478	2.444	0.430	2.550	0.383	2.655	0.339	2.761	0.297	2.885	0.257	2.969	0.221	3.071
36	0.05	0.808	2.306	0.748	2.398	0.689	2.492	0.631	2.586	0.575	2.680	0.520	2.774	0.467	2.868	0.417	2.961	0.389	3.053	0.323	3.142
	0.01	0.658	2.113	0.605	2.210	0.554	2.310	0.504	2.410	0.455	2.512	0.409	2.614	0.384	2.717	0.322	2.818	0.282	2.919	0.244	3.019
37	0.05	0.831	2.285	0.772	2.374	0.714	2.464	0.657	2.555	0.602	2.646	0.548	2.738	0.495	2.829	0.445	2.920	0.397	3.009	0.351	3.097
	0.01	0.680	2.092	0.628	2.196	0.578	2.282	0.528	2.379	0.480	2.477	0.434	2.576	0.389	2.675	0.347	2.774	0.306	2.872	0.268	2.989
38	0.05	0.854	2.265	0.796	2.351	0.739	2.438	0.683	2.526	0.628	2.614	0.575	2.703	0.522	2.792	0.472	2.880	0.424	2.968	0.378	3.054
	0.01	0.702	2.073	0.651	2.164	0.601	2.256	0.552	2.350	0.504	2.445	0.458	2.540	0.414	2.637	0.371	2.733	0.330	2.828	0.291	2.923
39	0.05	0.875	2.246	0.819	2.329	0.763	2.413	0.707	2.499	0.653	2.585	0.600	2.671	0.549	2.757	0.499	2.843	0.451	2.909	0.404	3.013
	0.01	0.723	2.055	0.673	22.143	0.623	2.232	0.575	2.323	0.528	2.414	0.482	2.507	0.438	2.600	0.395	2.694	0.354	2.787	0.315	2.879

		$K = 1$		$K = 2$		$K = 3$		$K = 4$		$K = 5$		$K = 6$		$K = 7$		$K = 8$		$K = 9$		$K = 10$	
		d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
n	α																				
40	0.05	1.442	1.544	1.391	2.309	1.600	1.338	1.659	1.285	1.721	1.230	1.786	1.175	1.854	1.120	1.924	1.064	1.997	1.008	2.072	2.149
	0.01	1.2446	1.344	1.198	1.398	1.148	1.457	1.098	1.518	1.048	1.584	0.997	1.652	0.946	1.724	0.895	1.799	0.844	1.876	0.789	1.956
45	0.05	1.475	1.566	1.430	1.615	1.383	1.666	1.336	1.720	1.287	1.776	1.238	1.835	1.189	1.895	1.139	1.958	1.089	2.002	1.038	2.088
	0.01	1.288	1.376	1.245	1.423	1.201	1.474	1.156	1.528	1.111	1.584	1.065	1.643	1.019	1.704	0.974	1.768	0.927	1.834	0.881	1.902
50	0.05	1.503	1.585	1.462	1.628	1.421	1.674	1.378	1.721	1.335	1.771	1.291	1.822	1.246	1.875	1.201	1.930	1.156	1.986	1.110	2.044
	0.01	1.324	1.403	1.2885	1.446	1.245	1.491	1.205	1.538	1.164	1.587	1.123	1.639	1.081	1.692	1.039	1.748	0.997	1.805	0.955	1.884
55	0.05	1.528	1.601	1.490	1.641	1.452	1.681	1.414	1.724	1.374	1.768	1.334	1.814	1.294	1.861	1.253	1.909	1.212	1.959	1.170	2.010

	0.01	1.356	1.427	1.320	1.466	1.284	1.506	1.247	1.548	1.209	1.592	1.172	1.638	1.134	1.685	1.095	1.734	1.057	1.785	1.0118	1.837
60	0.05	1.549	1.616	1.514	1.652	1.480	1.689	1.444	1.727	1.408	1.767	1.372	1.808	1.335	1.850	1.298	1.894	1.260	1.939	1.222	1.984
	0.01	1.383	1.449	1.35	1.484	1.317	1.520	1.283	1.558	1.249	1.598	1.214	1.639	1.179	1.682	1.144	1.726	1.108	1.771	1.072	1.817
65	0.05	1.587	1.629	1.536	1.662	1.503	1.696	1.471	1.731	1.438	1.767	1.404	1.805	1.370	1.843	1.336	1.882	1.301	1.923	1.266	1.964
	0.01	1.407	1.468	1.377	1.500	1.346	1.534	1.315	1.568	1.283	1.604	1.251	1.642	1.218	1.680	1.186	1.720	1.153	1.761	1.120	1.802
70	0.05	1.583	1.641	1.554	1.672	1.525	1.703	1.494	1.735	1.464	1.768	1.433	1.802	1.401	1.837	1.369	1.873	1.337	1.910	1.305	1.948
	0.01	1.429	1.485	1.400	1.515	1.372	1.546	1.343	1.578	1.313	1.611	1.283	1.645	1.253	1.680	1.223	1.716	1.192	1.754	1.162	1.792
75	0.05	1.598	1.652	1.571	1.680	1.543	1.709	1.515	1.739	1.487	1.770	1.458	1.801	1.428	1.834	1.399	1.867	1.369	1.901	1.339	1.935
	0.01	1.429	1.485	1.400	1.515	1.372	1.546	1.343	1.578	1.313	1.611	1.283	1.645	1.253	1.680	1.223	1.716	1.192	1.754	1.162	1.792
80	0.05	1.611	1.662	1.586	1.688	1.560	1.715	1.534	1.743	1.507	1.772	1.480	1.801	1.453	1.831	1.425	1.861	1.397	1.893	1.369	1.925
	0.01	1.466	1.515	1.441	1.541	1.416	1.568	1.390	1.595	1.364	1.624	1.338	1.653	1.312	1.683	1.285	1.714	1.259	1.745	1.232	1.777
85	0.05	1.624	1.671	1.600	1.696	1.575	1.721	1.550	1.747	1.525	1.774	1.500	1.801	1.474	1.829	1.448	1.857	1.422	1.896	1.396	1.916
	0.01	1.482	1.528	1.458	1.553	1.435	1.578	1.411	1.603	1.386	1.630	1.362	1.657	1.337	1.695	1.312	1.714	1.287	1.743	1.262	1.773
90	0.05	1.635	1.679	1.612	1.703	1.589	1.726	1.566	1.751	1.542	1.776	1.518	1.801	1.494	1.827	1.469	1.854	1.445	1.881	1.420	1.909
	0.01	1.496	1.540	1.474	1.563	1.452	1.587	1.429	1.611	1.406	1.636	1.383	1.661	1.360	1.687	1.336	1.714	1.312	1.741	1.288	1.769
95	0.05	1.645	1.687	1.623	1.709	1.602	1.732	1.579	1.755	1.557	1.778	1.535	1.802	1.512	1.827	1.489	1.852	1.465	1.877	1.442	1.903
	0.01	1.510	1.552	1.489	1.573	1.468	1.596	1.446	1.618	1.425	1.642	1.403	1.666	1.381	1.690	1.358	1.715	1.336	1.741	1.313	1.767
100	0.05	1.654	1.694	1.634	1.715	1.613	1.736	1.592	1.758	1.571	1.780	1.550	1.803	1.528	1.826	1.506	1.850	1.484	1.874	1.462	1.898
	0.01	1.522	1.562	1.503	1.583	1.482	1.604	1.462	1.625	1.441	1.647	1.421	1.670	1.400	1.693	1.378	1.717	1.357	1.741	1.335	1.765
150	0.05	1.720	1.746	1.706	1.760	1.693	1.774	1.679	1.788	1.685	1.802	1.651	1.817	1.637	1.832	1.622	1.847	1.608	1.862	1.594	1.877
	0.01	1.611	1.637	1.598	1.651	1.584	1.665	1.571	1.679	1.557	1.693	1.543	1.708	1.530	1.722	1.515	1.737	1.501	1.752	1.486	1.767
200	0.05	1.758	1.778	1.748	1.789	1.738	1.799	1.728	1.810	1.718	1.820	1.707	1.831	1.697	1.841	1.666	1.852	1.875	1.683	1.665	1.874
	0.01	1.664	1.684	1.653	1.693	1.643	1.704	1.633	1.715	1.623	1.725	1.613	1.735	1.603	1.746	1.592	1.757	1.582	1.768	1.571	1.779

K = 11			K = 12			K = 13			K = 14			K = 15			K = 16			K = 17			K = 18			K = 19			K = 20		
n	α	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
40	0.05	0.896	2.228	0.840	2.309	0.785	2.391	0.731	2.473	0.678	2.557	0.626	2.641	0.575	2.724	0.525	2.808	0.477	2.892	0.430	2.974								
	0.01	0.744	2.039	0.694	2.123	0.645	2.210	0.597	2.297	0.551	2.386	0.505	2.476	0.461	2.566	0.418	2.657	0.377	2.748	0.338	2.838								
45	0.05	0.988	2.156	0.938	2.225	0.887	2.296	0.838	2.387	0.788	2.439	0.740	2.512	0.692	2.596	0.644	2.659	0.598	2.733	0.553	2.807								
	0.01	0.913	1.925	0.871	1.987	0.829	2.051	0.787	2.116	0.746	2.182	0.705	2.250	0.665	2.318	0.625	2.387	0.596	2.456	0.548	2.526								
50	0.05	1.064	2.103	1.019	2.163	0.973	2.225	0.927	2.287	0.882	2.350	0.836	2.414	0.792	2.479	0.747	2.544	0.703	2.610	0.660	2.675								
	0.01	0.913	1.925	0.871	1.987	0.829	2.051	0.787	2.116	0.746	2.182	0.705	2.250	0.665	2.318	0.625	2.387	0.586	2.456	0.548	2.526								
55	0.05	1.129	2.062	1.087	2.116	1.045	2.170	1.003	2.225	0.961	2.281	0.919	2.338	0.877	2.396	0.836	2.454	0.795	2.512	0.754	2.571								
	0.01	0.979	1.891	0.940	1.945	0.902	2.002	0.863	2.059	0.825	2.117	0.786	2.176	0.748	2.237	0.711	2.298	0.674	2.359	0.637	0.421								
60	0.05	1.184	2.031	1.145	2.079	1.106	2.127	1.068	2.177	1.029	2.227	0.990	2.278	0.951	2.330	0.913	2.382	0.874	2.434	0.836	2.487								
	0.01	1.037	1.865	1.001	1.914	0.965	1.984	0.929	2.015	0.893	2.067	0.857	2.120	0.822	2.173	0.786	2.227	0.751	2.283	0.716	2.338								
65	0.05	1.231	2.006	1.195	2.049	1.160	2.093	1.124	2.138	1.088	2.183	1.052	2.229	1.016	2.278	0.980	2.323	0.944	2.371	0.908	2.419								
	0.01	1.087	1.845	1.053	1.889	1.020	1.934	0.986	1.980	0.953	2.027	0.919	2.075	0.886	2.123	0.852	2.172	0.819	2.221	0.786	2.272								
70	0.05	1.272	1.986	1.239	2.026	1.206	2.066	1.172	2.106	1.139	2.148	1.105	2.189	1.072	2.232	1.038	2.275	1.005	2.318	0.971	2.362								
	0.01	1.131	1.831	1.099	1.870	1.068	1.911	1.037	1.953	1.005	1.995	0.974	2.038	0.943	2.082	0.911	2.127	0.880	2.172	0.849	2.217								
75	0.05	1.308	1.970	1.277	2.006	1.247	2.043	1.215	2.080	1.184	2.118	1.153	2.156	1.121	2.195	1.090	2.235	1.058	2.275	1.027	2.315								
	0.01	1.170	1.819	1.141	1.856	1.111	1.893	1.082	1.931	1.052	1.970	1.023	2.009	0.993	2.049	0.964	2.090	0.934	2.131	0.905	2.172								
80	0.05	0.140	1.957	1.311	1.991	1.283	2.024	1.253	2.059	1.224	2.093	1.195	2.129	1.165	2.165	1.138	2.201	1.106	2.238	1.076	2.275								
	0.01	1.205	1.810	1.777	1.844	1.150	1.878	1.122	1.913	1.094	1.949	1.066	1.984	1.039	2.022	1.011	2.057	0.983	2.097	0.955	2.135								
85	0.05	1.369	1.946	1.342	1.977	1.315	2.009	1.287	2.040	1.260	2.073	1.232	2.105	1.205	2.139	1.177	2.172	1.149	2.206	1.121	2.241								
	0.01	1.236	1.803	1.210	1.834	1.184	1.866	1.158	1.898	1.132	1.931	1.106	1.985	1.080	1.999	1.053	2.033	1.027	2.068	1.000	2.104								
90	0.05	1.395	1.937	1.369	1.966	1.344	1.995	1.318	2.025	1.292	2.055	1.266	2.085	1.240	2.116	1.213	2.148	1.187	2.179	1.160	2.211								

	0.01	1.264	1.798	1.240	1.827	1.215	1.856	1.191	1.886	1.166	1.917	1.141	1.948	1.116	1.979	1.091	2.012	1.066	2.044	1.041	2.077
95	0.05	1.418	1.929	1.394	1.956	1.370	1.984	1.345	2.012	1.321	2.040	1.296	2.068	1.271	2.097	1.247	2.126	1.222	2.156	1.197	2.186
	0.01	1.290	1.793	1.267	1.821	1.244	1.848	1.221	1.876	1.197	1.905	1.174	1.934	1.150	1.963	1.126	1.993	1.102	2.023	1.079	2.054
100	0.05	1.434	1.923	1.416	1.948	1.393	1.974	1.371	2.000	1.347	2.026	1.324	2.053	1.301	2.080	1.277	2.108	1.253	2.135	1.229	2.164
	0.01	1.314	1.790	1.292	1.816	1.270	1.841	1.248	1.868	1.225	1.895	1.203	1.922	1.181	1.949	1.158	1.977	1.136	2.006	1.113	2.034
150	0.05	1.579	1.892	1.564	1.908	1.550	1.924	1.535	1.940	1.519	1.956	1.504	1.972	1.489	1.989	1.474	2.006	1.458	2.023	1.443	2.040
	0.01	1.473	1.783	1.458	1.799	1.444	1.814	1.429	1.830	1.414	1.847	1.400	1.863	1.385	1.880	1.370	1.897	1.355	1.913	1.340	1.931
200	0.05	1.654	1.885	1.643	1.896	1.632	1.908	1.621	1.919	1.610	1.931	1.599	1.943	1.588	1.955	1.576	1.967	1.565	1.979	1.554	1.991
	0.01	1.561	1.791	1.550	1.807	1.539	1.813	1.528	1.824	1.518	1.836	1.507	1.847	1.495	1.860	1.484	1.871	1.474	1.883	1.462	1.896

N										
1 a S	31	32	33	34	35	36	37	38	39	40
1	0.4220	0.4188	0.4156	0.4127	0.4096	0.4068	0.4040	0.4015	0.3989	0.3964
2	0.2921	0.2898	0.2876	0.2854	0.2834	0.2813	0.2794	0.2774	0.2755	0.2737
3	0.2475	0.2463	0.2451	0.2439	0.2427	0.2415	0.2403	0.2391	0.2380	0.2368
4	0.2145	0.2141	0.2137	0.2132	0.2127	0.2121	0.2116	0.2110	0.2104	0.2098
5	0.1874	0.1878	0.1880	0.1882	0.1883	0.1883	0.1883	0.1881	0.1880	0.1878
6	0.1641	0.1651	0.1660	0.1667	0.1673	0.1678	0.1683	0.1686	0.1689	0.1691
7	0.1433	0.1449	0.1463	0.1475	0.1487	0.1496	0.1505	0.1513	0.1520	0.1526
8	0.1243	0.1265	0.1284	0.1301	0.1317	0.1331	0.1344	0.1356	0.1366	0.1376
9	0.1066	0.1093	0.1118	0.1140	0.1160	0.1179	0.1196	0.1211	0.1225	0.1237
10	0.0899	0.0931	0.0961	0.0988	0.1013	0.1036	0.1056	0.1075	0.1092	0.1108
11	0.0739	0.0777	0.0812	0.0844	0.0873	0.0900	0.0924	0.0947	0.0967	0.0986
12	0.0585	0.0629	0.0669	0.0706	0.0739	0.0770	0.0796	0.0824	0.0848	0.0870
13	0.0435	0.0485	0.0530	0.0572	0.0610	0.0645	0.0677	0.0706	0.0733	0.0759
14	0.0289	0.0344	0.0395	0.0441	0.0484	0.0523	0.0559	0.0592	0.0622	0.0651
15	0.0144	0.0206	0.0262	0.0314	0.0361	0.0404	0.0444	0.0481	0.0515	0.0546
16	0.0000	0.0068	0.0187	0.0187	0.0239	0.0287	0.0331	0.0372	0.0409	0.0444
17			0.0000	0.0062	0.0119	0.0172	0.0220	0.0264	0.0305	0.0343
18					0.0000	0.0057	0.0110	0.0158	0.0203	0.0244
19							0.0000	0.0053	0.0101	0.0146
20									0.0000	0.0049

N										
1 a S	41	42	43	44	45	46	47	48	49	50
1	0.3940	0.3917	0.3894	0.3872	0.3850	0.3830	0.3808	0.3789	0.3770	0.3751
2	0.2719	0.2701	0.2684	0.2667	0.2651	0.2635	0.2620	0.2604	0.2589	0.2574
3	0.2357	0.2345	0.2334	0.2323	0.2313	0.2302	0.2291	0.2281	0.2271	0.2260
4	0.2091	0.2085	0.2078	0.2072	0.2065	0.2058	0.2052	0.2045	0.2038	0.2032
5	0.1876	0.1874	0.1871	0.1868	0.1865	0.1862	0.1859	0.1855	0.1851	0.1847
6	0.1693	0.1694	0.1695	0.1695	0.1695	0.1695	0.1695	0.1693	0.1692	0.1691
7	0.1531	0.1535	0.1539	0.1542	0.1545	0.1548	0.1550	0.1551	0.1553	0.1554
8	0.1384	0.1392	0.1398	0.1405	0.1410	0.1415	0.1420	0.1423	0.1427	0.1430
9	0.1249	0.1259	0.1269	0.1278	0.1286	0.1293	0.1300	0.1306	0.1312	0.1317

(continúa)

(continuación)

N										
1 a S	41	42	43	44	45	46	47	48	49	50
10	0.1123	0.1136	0.1149	0.1160	0.1170	0.1180	0.1189	0.1197	0.1205	0.1212
11	0.1004	0.1020	0.1035	0.1049	0.1062	0.1073	0.1085	0.1095	0.1105	0.1113
12	0.0891	0.0909	0.0927	0.0943	0.0959	0.0972	0.0986	0.0998	0.1010	0.1020
13	0.0782	0.0804	0.0824	0.0842	0.0860	0.0876	0.0892	0.0906	0.0919	0.0932
14	0.0677	0.0701	0.0724	0.0745	0.0765	0.0783	0.0801	0.0817	0.0832	0.0846
15	0.0575	0.0602	0.0628	0.0651	0.0673	0.0694	0.0713	0.0731	0.0748	0.0764
16	0.0476	0.0506	0.0534	0.0560	0.0584	0.0607	0.0628	0.0648	0.0667	0.0685
17	0.0379	0.0411	0.0442	0.0471	0.0497	0.0522	0.0546	0.0568	0.0588	0.0608
18	0.0283	0.0318	0.0352	0.0383	0.0412	0.0439	0.0465	0.0489	0.0511	0.0532
19	0.0188	0.0227	0.0263	0.0296	0.0328	0.0357	0.0385	0.0411	0.0436	0.0459
20	0.0094	0.0136	0.0175	0.0211	0.0245	0.0277	0.0307	0.0335	0.0361	0.0386
21	0.0000	0.0045	0.0087	0.0126	0.0163	0.0197	0.0229	0.0259	0.0288	0.0314
22			0.0000	0.0042	0.0081	0.0118	0.0153	0.0185	0.0215	0.0244
23					0.0000	0.0039	0.0076	0.0111	0.0143	0.0174
24							0.0000	0.0037	0.0071	0.0104
25									0.0000	0.00335

Anexo 2.7 Tabla Shapiro-Wilk

Distribución del estadístico de Shapiro-Wilk para la prueba de normalidad									
α									
n	0.01	0.02	0.05	0.10	0.50	0.90	0.95	0.98	0.99
3	0.753	0.756	0.767	0.789	0.959	0.998	0.999	1.000	1.000
4	0.687	0.707	0.748	0.792	0.935	0.987	0.992	0.996	0.997
5	0.686	0.715	0.762	0.806	0.927	0.979	0.986	0.991	0.993
6	0.713	0.743	0.788	0.826	0.927	0.974	0.981	0.986	0.989
7	0.73	0.76	0.803	0.838	0.928	0.972	0.979	0.985	0.988
8	0.749	0.778	0.818	0.851	0.932	0.972	0.978	0.984	0.987
9	0.764	0.791	0.829	0.859	0.935	0.972	0.978	0.984	0.986

(continúa)

(continuación)

Distribución del estadístico de Shapiro-Wilk para la prueba de normalidad									
α									
n	0.01	0.02	0.05	0.10	0.50	0.90	0.95	0.98	0.99
10	0.781	0.806	0.842	0.869	0.938	0.972	0.978	0.983	0.986
11	0.792	0.817	0.85	0.876	0.94	0.973	0.979	0.984	0.986
12	0.805	0.828	0.859	0.883	0.943	0.973	0.979	0.984	0.986
13	0.814	0.837	0.866	0.889	0.945	0.974	0.979	0.984	0.986
14	0.825	0.846	0.874	0.895	0.947	0.975	0.98	0.984	0.986
15	0.835	0.855	0.881	0.901	0.95	0.975	0.98	0.984	0.987
16	0.844	0.863	0.887	0.906	0.952	0.976	0.981	0.985	0.987
17	0.851	0.869	0.892	0.91	0.954	0.977	0.981	0.985	0.987
18	0.858	0.874	0.897	0.914	0.956	0.978	0.982	0.986	0.988
19	0.863	0.879	0.901	0.917	0.957	0.978	0.982	0.986	0.988
20	0.868	0.884	0.905	0.92	0.959	0.979	0.983	0.986	0.988
21	0.873	0.888	0.908	0.923	0.96	0.98	0.983	0.987	0.989
22	0.878	0.892	0.911	0.926	0.961	0.98	0.984	0.987	0.989
23	0.881	0.895	0.914	0.928	0.962	0.981	0.984	0.987	0.989
24	0.884	0.898	0.916	0.93	0.963	0.981	0.984	0.987	0.989
25	0.888	0.901	0.918	0.931	0.964	0.981	0.985	0.988	0.989
26	0.891	0.904	0.920	0.933	0.965	0.982	0.985	0.988	0.989
27	0.894	0.906	0.923	0.935	0.965	0.982	0.985	0.988	0.990
28	0.896	0.908	0.924	0.936	0.966	0.982	0.985	0.988	0.990
29	0.898	0.910	0.926	0.937	0.966	0.982	0.985	0.988	0.990
30	0.900	0.912	0.927	0.939	0.967	0.983	0.985	0.988	0.990
31	0.902	0.914	0.929	0.940	0.967	0.983	0.986	0.988	0.990
32	0.904	0.915	0.930	0.941	0.968	0.983	0.986	0.988	0.990
33	0.906	0.917	0.931	0.942	0.968	0.983	0.986	0.989	0.990
34	0.908	0.919	0.933	0.943	0.969	0.983	0.986	0.989	0.990
35	0.910	0.920	0.934	0.944	0.969	0.984	0.986	0.989	0.990
36	0.912	0.922	0.935	0.945	0.970	0.984	0.986	0.989	0.990
37	0.914	0.924	0.936	0.946	0.970	0.984	0.987	0.989	0.990

(continúa)

(continuación)

Distribución del estadístico de Shapiro-Wilk para la prueba de normalidad									
α									
n	0.01	0.02	0.05	0.10	0.50	0.90	0.95	0.98	0.99
38	0.916	0.925	0.938	0.947	0.971	0.984	0.987	0.989	0.990
39	0.917	0.927	0.939	0.948	0.971	0.984	0.987	0.989	0.991
40	0.919	0.928	0.940	0.949	0.972	0.985	0.987	0.989	0.991
41	0.920	0.929	0.941	0.950	0.972	0.985	0.987	0.989	0.991
42	0.922	0.930	0.942	0.951	0.972	0.985	0.987	0.989	0.991
43	0.923	0.932	0.943	0.951	0.973	0.985	0.987	0.990	0.991
44	0.924	0.933	0.944	0.952	0.973	0.985	0.987	0.990	0.991
45	0.926	0.934	0.945	0.953	0.973	0.985	0.988	0.990	0.991
46	0.927	0.935	0.945	0.953	0.974	0.985	0.988	0.990	0.991
47	0.928	0.936	0.946	0.954	0.974	0.985	0.988	0.990	0.991
48	0.929	0.937	0.941	0.954	0.974	0.985	0.988	0.990	0.991
49	0.929	0.937	0.947	0.955	0.974	0.985	0.988	0.990	0.991
50	0.930	0.938	0.947	0.955	0.974	0.985	0.988	0.990	0.991

Anexo 2.8 Tabla Kolmogorov-Smirnov-Lilliefors

Distribución del estadístico						
Kolmogorov-Smirnov-Lilliefors para pruebas de normalidad						
α						
n	0.20	0.15	.010	0.05	0.01	0.00
4	0.303	0.321	0.346	0.376	0.413	0.433
5	0.289	0.303	0.319	0.343	0.397	0.439
6	0.269	0.281	0.297	0.323	0.371	0.424
7	0.252	0.264	0.280	0.304	0.351	0.402
8	0.239	0.250	0.265	0.288	0.333	0.384
9	0.227	0.238	0.252	0.274	0.317	0.365
10	0.217	0.228	0.241	0.262	0.304	0.352
11	0.208	0.218	0.231	0.251	0.291	0.338

(continúa)

(continuación)

Distribución del estadístico						
Kolmogorov-Smirnov-Lilliefors para pruebas de normalidad						
α						
12	0.200	0.210	0.222	0.242	0.281	0.325
13	0.193	0.202	0.215	0.234	0.271	0.314
14	0.187	0.196	0.208	0.226	0.262	0.305
15	0.181	0.190	0.201	0.219	0.254	0.296
16	0.176	0.184	0.195	0.213	0.247	0.287
17	0.171	0.179	0.190	0.207	0.240	0.279
18	0.167	0.175	0.185	0.202	0.234	0.273
19	0.163	0.170	0.181	0.197	0.228	0.266
20	0.159	0.166	0.176	0.192	0.223	0.260
25	0.143	0.150	0.159	0.173	0.201	0.236
30	0.131	0.138	0.146	0.159	0.185	0.217
>30	$\frac{0.74}{\sqrt{n}}$	$\frac{0.77}{\sqrt{n}}$	$\frac{0.82}{\sqrt{n}}$	$\frac{0.89}{\sqrt{n}}$	$\frac{1.04}{\sqrt{n}}$	$\frac{1.22}{\sqrt{n}}$

Distribución del estadístico Kolmogorov-Smirnov					
α					
n	0.20	0.10	0.05	0.02	0.01
1	0.900	0.950	0.975	0.990	0.995
2	0.684	0.776	0.842	0.900	0.929
3	0.565	0.636	0.780	0.785	0.829
4	0.493	0.595	0.624	0.689	0.734
5	0.447	0.509	0.563	0.627	0.669
6	0.410	0.468	0.519	0.577	0.617
7	0.381	0.436	0.483	0.538	0.576
8	0.358	0.410	0.454	0.507	0.542
9	0.339	0.387	0.430	0.480	0.513
10	0.323	0.369	0.409	0.457	0.489
11	0.308	0.352	0.391	0.437	0.468
12	0.296	0.338	0.375	0.419	0.449

(continúa)

(continuación)

Distribución del estadístico Kolmogorov-Smirnov					
α					
n	0.20	0.10	0.05	0.02	0.01
13	0.285	0.325	0.361	0.404	0.432
14	0.275	0.314	0.349	0.390	0.418
15	0.266	0.304	0.338	0.377	0.404
16	0.258	0.295	0.327	0.366	0.392
17	0.250	0.286	0.318	0.355	0.381
18	0.244	0.279	0.309	0.346	0.371
19	0.237	0.271	0.301	0.337	0.361
20	0.232	0.265	0.294	0.329	0.352
21	0.226	0.259	0.287	0.321	0.344
22	0.221	0.253	0.281	0.314	0.337
23	0.216	0.247	0.275	0.307	0.330
24	0.212	0.242	0.269	0.301	0.323
25	0.206	0.238	0.264	0.295	0.317
26	0.204	0.233	0.259	0.290	0.311
27	0.200	0.229	0.254	0.284	0.305
28	0.197	0.225	0.250	0.279	0.300
29	0.193	0.221	0.246	0.275	0.295
30	0.190	0.216	0.242	0.270	0.290
31	0.187	0.214	0.238	0.266	0.285
32	0.184	0.211	0.234	0.262	0.281
33	0.182	0.208	0.231	0.258	0.277
34	0.179	0.205	0.227	0.254	0.273
35	0.177	0.202	0.224	0.251	0.269
36	0.174	0.199	0.221	0.247	0.265
37	0.172	0.196	0.218	0.244	0.262
38	0.170	0.194	0.215	0.241	0.258
39	0.168	0.191	0.213	0.238	0.255
40	0.165	0.189	0.210	0.235	0.252
≥ 40	$\frac{1.07}{\sqrt{n}}$	$\frac{1.22}{\sqrt{n}}$	$\frac{1.35}{\sqrt{n}}$	$\frac{1.52}{\sqrt{n}}$	$\frac{1.63}{\sqrt{n}}$

Anexo 2.9 Manejo de matrices

Usualmente la mayoría de la información de las técnicas multivariadas requieren de operaciones matriciales, es por ello que este anexo incluye definiciones y la mayor parte de la información necesaria en la realización de operaciones.

A2.9.1 Matrices

Una **matriz** es un arreglo rectangular de números, como en una tabla con números ordenados y se puede representar de la siguiente manera:

Matriz. Arreglo rectangular de números en una tabla ordenada.

$$\begin{bmatrix} X_{1_1} & X_{1_2} & \cdots & X_{1_K} \\ X_{2_1} & X_{2_2} & \cdots & X_{2_K} \\ \vdots & \vdots & \vdots & \vdots \\ X_{N_1} & X_{N_2} & \cdots & X_{N_K} \end{bmatrix}$$

En donde a cada X_{ij} se le denomina escalar y los términos que se encuentran en forma horizontal se conocen como *renglones* o *filas* y se representan por el subíndice i. Los valores verticales se llaman *columnas de la matriz* y se representan por el subíndice j. Como la matriz anterior tiene N renglones y K columnas, los cuales son sus dimensiones y se le denomina matriz N por K o bien $(N \times K)$, lo cual generalmente se indica en la parte inferior de la matriz, esto se muestra a continuación:

$$\begin{bmatrix} X_{1_1} & X_{1_2} & \cdots & X_{1_K} \\ X_{2_1} & X_{2_2} & \cdots & X_{2_K} \\ \vdots & \vdots & \vdots & \vdots \\ X_{N_1} & X_{N_2} & \cdots & X_{N_K} \end{bmatrix}$$

$(N * K)$

Las matrices generalmente se representan con letras mayúsculas, por ejemplo:

$$A = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix}$$

El elemento X_{13} se encuentra en el renglón uno y la columna 3, por lo que dicho elemento sería $X_{13} = 14$.

De la matriz A sus renglones serían los siguientes:

$$(2, -4, 6); (8, 10, 12) \text{ y } (14, 16, -18_6)$$

Y sus columnas serían:

$$\begin{pmatrix} 2 \\ 8 \\ 14 \end{pmatrix}, \begin{pmatrix} -4 \\ 10 \\ 16 \end{pmatrix} \text{ y } \begin{pmatrix} 6 \\ 12 \\ 18 \end{pmatrix}$$

La diagonal principal de la matriz A sería la siguiente:

$$A = \begin{bmatrix} 2 & \cdot & \cdot \\ \cdot & 10 & \cdot \\ \cdot & \cdot & -18 \end{bmatrix}$$

La diagonal secundaria de la matriz A sería la siguiente:

$$A = \begin{bmatrix} \cdot & \cdot & 6 \\ \cdot & 10 & \cdot \\ 14 & \cdot & \cdot \end{bmatrix}$$

A2.9.2 Escalar

Si las dimensiones son 1×1 , se trata de un escalar, es decir, es un número; un ejemplo de esto puede ser:

$$B = [4]$$

A2.9.3 Vector

Si una de las dos dimensiones es 1, se trata de un vector; los tipos de vectores pueden ser:

- De dimensiones $(N \times 1)$. Se le denomina *vector columna de orden N* ; por ejemplo un vector columna de orden 3, podría ser:

$$C = \begin{bmatrix} 4 \\ -5 \\ 6 \end{bmatrix}$$

- De dimensiones $(1 \times N)$. Llamado *vector renglón de orden N* ; por ejemplo un vector renglón de orden 3, podría ser:

$$D = [-1 \quad 3 \quad 5]$$

En seguida se verán los tipos más comunes de matrices.

A2.9.4 Tipos

A continuación se mencionan los tipos más comunes de matrices o su clasificación:

A2.9.4.1 Matriz identidad

Cuando una matriz es cuadrada y de orden N que, además, tiene números uno en su diagonal principal y ceros en cualquier otra parte, se le conoce como **matriz identidad** y se le denota por una I ; supóngase que se tiene una matriz de orden 3 y además es una matriz identidad, ésta sería de la siguiente forma:

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Cuando dicha matriz premultiplica ($I * A$) a cualquier otra matriz o posmultiplica ($A * I$), siempre dará como resultado la matriz original, es decir, supóngase que se tiene la matriz B , posmultiplicada por la matriz identidad, entonces se tendría el siguiente resultado:

$$B * I = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix} * \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix}$$

Es decir, $B * I = I * B = B$.

Matriz identidad. Matriz cuadrada y de orden N que, además, tiene números uno en su diagonal principal y ceros en cualquier otra parte.

A2.9.4.2 Matriz o vector cero

A una matriz de orden N o un vector de orden N que contiene ceros en sus elementos se les denomina *matriz cero* o *vector cero* respectivamente y se le representa o denota por $\tilde{0}$; supóngase que se tiene una matriz de orden 3 que además es una matriz cero, ésta sería de la siguiente forma:

$$\tilde{0} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Cuando dicha matriz se le suma ($\tilde{0} + A$) a cualquier otra matriz, siempre dará como resultado la matriz original, es decir, supóngase que se tiene la matriz B , a la cual se le sumó la matriz cero, lo que daría el siguiente resultado:

$$B + \tilde{0} = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix}$$

Es decir, $B + 0 = \tilde{0} + B = B$

A2.9.4.3 Matrices cuadradas

Las **matrices cuadradas** tienen el mismo número de renglones y columnas; por ejemplo, si el número de filas es 2, entonces el número de columnas también debe ser 2, por lo que esta matriz se llamaría *matriz 2-cuadrada* o *matriz cuadrada de orden 2*, este tipo podría ser:

$$A = \begin{bmatrix} -1 & 2 \\ 4 & 5 \end{bmatrix}$$

Si B es una matriz 3-cuadrada o una matriz cuadrada de orden 3, ésta podría ser:

$$B = \begin{bmatrix} 2 & -4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & -18 \end{bmatrix}$$

Matrices cuadradas.

Tienen el mismo número de renglones y columnas.

A2.9.4.4 Matriz diagonal

Si una matriz cuadrada tiene ceros arriba y debajo de la diagonal principal, se le denomina **matriz diagonal** y generalmente se le denota por una D ; por ejemplo:

Matriz diagonal de orden 2:

$$D = \begin{bmatrix} -1 & 0 \\ 0 & 5 \end{bmatrix}$$

La cual también puede representarse de la siguiente manera:

$$D = \text{diag}(-1, 5)$$

Una matriz diagonal de orden 3 puede ser:

$$B = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 10 & 0 \\ 0 & 0 & -18 \end{bmatrix}$$

La cual puede representarse de la siguiente manera:

$$D = \text{diag}(2, 10, -18)$$

Matriz diagonal. Matriz cuadrada que tiene ceros arriba y debajo de la diagonal principal.

A2.9.4.5 Matriz triangular

Matriz triangular superior. Matriz cuadrada que tiene ceros en la parte inferior de la diagonal principal.

Matriz triangular inferior. Matriz cuadrada que tiene ceros en la parte superior de la diagonal principal.

Cuando una matriz cuadrada tiene ceros en la parte inferior de la diagonal principal, se la llama **matriz triangular superior**, pero si la matriz tiene cero arriba de la diagonal principal se le denomina **matriz triangular inferior**.

Una matriz triangular superior de orden 2 puede ser:

$$A = \begin{bmatrix} -1 & 2 \\ 0 & 5 \end{bmatrix}$$

Una matriz triangular inferior de orden 3 puede ser:

$$B = \begin{bmatrix} 2 & 0 & 0 \\ 8 & 10 & 0 \\ 14 & 16 & -18 \end{bmatrix}$$

A2.9.4.6 Matriz simétrica

Matriz simétrica. Es una matriz que es igual a su transpuesta.

Una **matriz** es **simétrica** si la matriz es igual a su transpuesta, es decir supóngase que se tiene la siguiente matriz:

$$B = \begin{bmatrix} 2 & 3 & -4 \\ 3 & 10 & 0 \\ -4 & 0 & -18 \end{bmatrix}$$

Por lo que su transpuesta,¹⁵⁰ que se representa por B^T , sería:

$$B^T = \begin{bmatrix} 0 & 3 & -4 \\ 3 & 10 & 0 \\ -4 & 0 & -18 \end{bmatrix}$$

Entonces B es simétrica ya que $B = B^T$.

A2.9.4.7 Matriz antisimétrica

Matriz antisimétrica. Matriz que es igual al negativo de su transpuesta.

Una **matriz** es **antisimétrica** si la matriz es igual al negativo de su transpuesta, es decir supóngase que se tiene la siguiente matriz:

$$C = \begin{bmatrix} 0 & 2 & 3 \\ -2 & 0 & -8 \\ -3 & 8 & 0 \end{bmatrix}$$

Por lo que su transpuesta sería:

$$C^T = \begin{bmatrix} 0 & -2 & -3 \\ 2 & 0 & 8 \\ 3 & -8 & 0 \end{bmatrix}$$

Además de que:

$$-C^T = -\begin{bmatrix} 0 & -2 & -3 \\ 2 & 0 & 8 \\ 3 & -8 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 2 & 3 \\ -2 & 0 & -8 \\ -3 & 8 & 0 \end{bmatrix} = C$$

Por lo que C es antisimétrica ya que $C = -C^T$.

¹⁵⁰ Una transpuesta es cuando los renglones se convierten en columna o las columnas en renglones; esto se verá más adelante en "Operaciones con matrices".

A2.9.4.8 Matrices ortogonales

Si la matriz A es ortogonal, entonces debe cumplirse que si A se pre o posmultiplica por su transpuesta da como resultado la matriz identidad, es decir que:

$$A * A^T = A^T * A = I$$

Además A debe ser cuadrada e invertible, es decir debe tener inversa la cual se representa por A^{-1} ; cumpliéndose que $A^{-1} = A^T$; lo que implica que:

$$A * A^{-1} = A^{-1} * A = I$$

Por lo que si A se pre o posmultiplica por su inversa da la matriz identidad. Supóngase que se tiene la siguiente matriz de orden 2, la cual sería:

$$A = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

Su transpuesta sería:

$$A^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

Entonces, si $A * A^T$ la respuesta sería la matriz identidad lo cual se muestra a continuación:

$$A * A^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} * \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Además,

$$A^{-1} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

Por lo que $A^{-1} = A^T$, lo cual sería:

$$A^{-1} = A^T = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

Entonces, si $A * A^{-1}$ la respuesta sería la matriz identidad lo cual se muestra a continuación:

$$A * A^{-1} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} * \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

A2.9.4.9 Matriz normal

Matriz normal. Cumple con la propiedad conmutativa con la transpuesta misma.

Se dice que una **matriz** es **normal** si cumple con la propiedad conmutativa con la transpuesta misma, esto es si se pre o posmultiplica por la transpuesta dará el mismo resultado, es decir $A * A^T = A^T * A$, por ejemplo:

$$A = \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix}$$

Por lo que su transpuesta sería:

$$A^T = \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix}$$

Entonces si se multiplica:

$$A * A^T = \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix} \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix} = \begin{bmatrix} 29 & -26 & -38 \\ -26 & 29 & 32 \\ -38 & 32 & 56 \end{bmatrix}$$

Y además:

$$A^T * A = \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix} \begin{bmatrix} 2 & -3 & -4 \\ -3 & 4 & 2 \\ -4 & 2 & 6 \end{bmatrix} = \begin{bmatrix} 29 & -26 & -38 \\ -26 & 29 & 32 \\ -38 & 32 & 56 \end{bmatrix}$$

Por lo que se cumple que $A * A^T = A^T * A$, entonces A es una matriz normal.

A2.9.5 Operaciones con matrices

En seguida se estudiarán las diferentes operaciones que se pueden aplicar a las matrices.

A2.9.5.1 Traza de una matriz

Para encontrar la traza de una matriz, basta con sumar los elementos que se encuentran en la diagonal principal; por ejemplo, supóngase que se desea encontrar la traza de B , dicha matriz se presenta a continuación:

$$B = \begin{bmatrix} 2 & 4 & 6 \\ 8 & 10 & 12 \\ 14 & 16 & 18 \end{bmatrix}$$

Dicha traza se representa por $tr\ B$, por lo que la traza sería:

$$tr(B) = 2 + 10 + 18 = 30$$

A2.9.5.2 Transpuesta de un vector y de una matriz

Transpuesta. Cambiar las columnas por renglones o bien los renglones por columnas de los vectores o matrices.

Ya sea vector o matriz, para encontrar su **transpuesta** se deben cambiar las columnas por renglones o bien los renglones por columnas; la transpuesta se denota por, A^T ; ahora supóngase que se tiene el siguiente vector:

$$C = \begin{bmatrix} 4 \\ -5 \\ 6 \end{bmatrix} \text{ por lo que la transpuesta sería } C^T = [4 \quad -5 \quad 6]$$

Las dimensiones de C son (3×1) y las de C^T serían (1×3) . O bien si se desea obtener la transpuesta de la matriz B , la cual se presenta a continuación:

$$B = \begin{bmatrix} 2 & 3 \\ 5 & 7 \\ 6 & 8 \end{bmatrix}$$

Por lo que la transpuesta de B sería:

$$B^T = \begin{bmatrix} 2 & 5 & 6 \\ 3 & 7 & 8 \end{bmatrix}$$

Nótese que la matriz B es de dimensiones (3×2) por lo que su transpuesta es ahora de dimensiones (2×3) . Las propiedades de la transpuesta son:

- Si X es un escalar y A una matriz, entonces $(XA)^T = A^T$
- Si A es una matriz, entonces $(A^T)^T = A$
- Si A y B son matrices, entonces $(A + B)^T = A^T + B^T$
- Si A y B son matrices, entonces $(AB)^T = B^T A^T$
- Si A , B y C son matrices, entonces $(ABC)^T = C^T B^T A^T$

A2.9.5.3 Determinante de una matriz

El determinante de una matriz se representa por:

$$\det(A) = |A|$$

Ahora bien, si la matriz tiene dimensiones de (2×2) , encontrar el determinante es muy sencillo ya que es el producto de la diagonal principal menos el producto de la diagonal secundaria, por ejemplo:

$$|A| = \begin{vmatrix} 2 & 3 \\ 4 & 5 \end{vmatrix} = (2)(5) - (3)(4) = -2$$

Pero si la matriz es de dimensiones mayores de 2×2 el procedimiento es diferente, para ilustrar esto supóngase que se tiene la siguiente matriz:

$$|B| = \begin{vmatrix} 2 & 3 & 1 \\ 6 & 4 & 5 \\ 1 & 7 & 8 \end{vmatrix}$$

Por lo que su determinante se calcularía agregando¹⁵¹ las primeras dos columnas al final de la matriz, de la siguiente manera:

$$|B| = \begin{vmatrix} 2 & 3 & 1 \\ 6 & 4 & 5 \\ 1 & 7 & 8 \end{vmatrix} = \left\langle \begin{vmatrix} 2 & 3 & 1 & 2 & 3 \\ 6 & 4 & 5 & 6 & 4 \\ 1 & 7 & 8 & 1 & 7 \end{vmatrix} \right\rangle$$

Ahora el determinante sería la suma del producto de las diagonales de arriba por la izquierda y hacia la derecha menos, la suma del producto de las diagonales de derecha a izquierda, esto se muestra a continuación:

$$|B| = (2)(4)(8) + (3)(5)(1) + (1)(6)(7) - (3)(6)(8) - (2)(5)(7) - (1)(4)(1)$$

Entonces, el determinante sería:

$$|B| = 64 + 15 + 42 - 144 - 70 - 4 = -97$$

¹⁵¹ Cuando a una matriz se le aumentan columnas se le denomina *matriz aumentada*.

Para matrices de dimensiones superiores se escoge particiona la matriz escogiendo alguna o algunas de dimensiones de 3×3 .

A2.9.5.4 Suma y resta de matrices

Para obtener la suma de dos matrices, se suman o se restan los términos que ocupan el mismo lugar en ambas matrices; por lo que para que dos matrices se puedan sumar o restar, ambas deben tener forzosamente las mismas dimensiones, es decir si A es (3×2) entonces para que se pueda sumar a la matriz B ésta debe tener dimensiones (3×2) ; es decir:

Suponga que A es:

$$A = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix}$$

Ahora, si B es:

$$B = \begin{bmatrix} 2 & 3 \\ 5 & 7 \\ 6 & 8 \end{bmatrix}$$

Por lo que su suma sería de la siguiente manera:

$$A + B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} + \begin{bmatrix} 2 & 3 \\ 5 & 7 \\ 6 & 8 \end{bmatrix} = \begin{bmatrix} -1+2 & 4+3 \\ 2+5 & 1+7 \\ 8+6 & 9+8 \end{bmatrix} = \begin{bmatrix} 1 & 7 \\ 7 & 8 \\ 14 & 17 \end{bmatrix}$$

Propiedades:

- Propiedad asociativa: $A + (B + C) = (A + B) + C$
- Propiedad conmutativa: $A + B = B + A$
- Propiedad del elemento nulo: $A + \tilde{0} = A$ en donde $\tilde{0}$ es una matriz de ceros
- Propiedad del inverso aditivo: $A + (-A) = \tilde{0}$
- Diferencia entre matrices: $A + (-B) = A - B$

Por lo que su diferencia sería:

$$A - B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} - \begin{bmatrix} 2 & 3 \\ 5 & 7 \\ 6 & 8 \end{bmatrix} = \begin{bmatrix} -1-2 & 4-3 \\ 2-5 & 1-7 \\ 8-6 & 9-8 \end{bmatrix} = \begin{bmatrix} -3 & 1 \\ -3 & -6 \\ 12 & 1 \end{bmatrix}$$

A2.9.5.5 Producto de matrices

En la multiplicación de matrices es necesario que la primera tenga el mismo número de columnas que la segunda, más aún el resultado será una matriz con dimensiones equivalentes al número de renglones de la primera por el número de columnas de la segunda; es decir, si la matriz A es de dimensiones $(N \times M)$ para poder multiplicarse con B , es necesario que B sea de dimensiones $(M \times \text{cualquier otro número})$. Por ejemplo si A es de dimensiones (4×5) y B es de dimensiones (5×2) , entonces A y B se pueden multiplicar y el resultado de esa multiplicación será una matriz de (4×2) . Esto se puede representar de la siguiente manera:

$$\begin{matrix} A & * & B & = & C \\ (4 \times 5) & (5 \times 2) & (4 \times 2) \end{matrix}$$

O bien si se tienen las siguiente matrices:

$$\begin{matrix} A & * & B & = & C \\ (2 \times 3) & (3 \times 4) & (2 \times 4) \end{matrix}$$

Cuando ambas matrices tienen las mismas dimensiones, el resultado será una matriz igual, es decir:

$$\begin{matrix} A & * & B & = & C \\ (3 \times 3) & (3 \times 3) & (3 \times 3) \end{matrix}$$

Por lo que:

$$A * B = C$$

Entonces también se puede:

$$A * B = D$$

Pero es importante comentar que al conmutar las matrices para realizar la multiplicación, ambos productos no dan el mismo resultado.

Si no se tienen las mismas dimensiones:

$$\begin{matrix} A & * & B & = & C \\ (4 \times 5) & (5 \times 2) & (4 \times 2) \end{matrix}$$

Pero el producto siguiente no se puede realizar:

$$\begin{matrix} B & * & A & = & \text{No se puede llevar a cabo} \\ (5 \times 2) & (4 \times 5) \end{matrix}$$

A2.9.5.5.1 Producto de un escalar por una matriz

Si la multiplicación es por un escalar, es de elemento a elemento, esto se presenta a continuación:

$$A * 3 = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * 3 = \begin{bmatrix} -1*3 & 4*3 \\ 2*3 & 1*3 \\ 8*3 & 9*3 \end{bmatrix} = \begin{bmatrix} -3 & 12 \\ 6 & 3 \\ 24 & 27 \end{bmatrix}$$

A2.9.5.5.2 Producto de un vector por otro

Si la multiplicación es de un vector por otro, puede dar como resultado un escalar o una matriz, es decir, si los vectores que se multiplican están de la siguiente forma:

$$\begin{matrix} A & * & B & = & C \\ (1 \times 5) & (5 \times 1) & (1 \times 1) \end{matrix}$$

Da como resultado un escalar; siempre la multiplicación es el renglón de primer vector por la columna de segundo vector; un ejemplo del caso anterior es el siguiente:

$$A * B = [1 \quad 3 \quad 5] * \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} = [1*2 + 3*4 + 5*6] = 44$$

Si los vectores se encuentran de la forma:

$$\begin{matrix} A & * & B & = & C \\ (5 \times 1) & (1 \times 5) & (5 \times 5) \end{matrix}$$

La solución es una matriz, la multiplicación es el renglón de primer vector por la columna de segundo vector; un ejemplo de este caso podría ser el siguiente:

$$A * B = \begin{bmatrix} 4 \\ 8 \end{bmatrix} * \begin{bmatrix} 1 & 5 \end{bmatrix} = \begin{bmatrix} 4*1 & 4*5 \\ 8*1 & 8*5 \end{bmatrix} = \begin{bmatrix} 4 & 20 \\ 8 & 40 \end{bmatrix}$$

A2.9.5.5.3 Producto de un vector por una matriz

El resultado de la multiplicación de un vector por una matriz, depende de las dimensiones de los dos, por ejemplo, si los dos se encuentran de la siguiente forma:

$$\begin{matrix} A & * & B & = & C \\ (3 \times 5) & (5 \times 1) & (3 \times 1) \end{matrix}$$

La solución sería un vector, un ejemplo de lo anterior sería:

$$A * B = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix} * \begin{bmatrix} 4 \\ 8 \end{bmatrix} = \begin{bmatrix} 1*4 + 2*8 \\ 3*4 + 6*8 \end{bmatrix} = \begin{bmatrix} 20 \\ 60 \end{bmatrix}$$

Si se encuentran como se indica:

$$\begin{matrix} A & * & B & = & C \\ (1 \times 5) & (5 \times 2) & (1 \times 2) \end{matrix}$$

El resultado sería también un vector, esto se puede ejemplificar de la siguiente manera:

$$B^T * A = \begin{bmatrix} 4 & 8 \end{bmatrix} * \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} 4*1 + 8*3 & 4*2 + 8*6 \end{bmatrix} = \begin{bmatrix} 28 & 56 \end{bmatrix}$$

A2.9.5.5.4 Producto de matrices

La multiplicación de dos matrices siempre debe ser de los renglones de la primera matriz por las columnas de la segunda. Por ejemplo, suponga que se tienen la matriz A y la matriz B , por lo que el producto sería:

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix}$$

Como la matriz A es de dimensiones (3×2) y la matriz B es de dimensiones (2×3) , el resultado sería una matriz de (3×3) , el proceso de multiplicar el primer renglón de la matriz A por la primera columna de la matriz B se muestra a continuación:

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} -1*6 + 4*7 & \dots & \dots \\ \dots & \dots & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

El resultado es de 22; como siguiente paso, se multiplicará el segundo renglón de la matriz A por la primera columna de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & \dots & \dots \\ 2*6 + 1*7 & \dots & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

Lo cual da como respuesta 19; ahora se multiplicará el renglón tres de la matriz A por la columna uno de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & \cdots & \cdots \\ 19 & \cdots & \cdots \\ 8*6+9*7 & \cdots & \cdots \end{bmatrix}$$

Lo cual da como resultado 111; como siguiente paso, se multiplicará el renglón uno de la matriz A por la columna dos de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -1*5+4*(-2) & \cdots \\ 19 & \cdots & \cdots \\ 111 & \cdots & \cdots \end{bmatrix}$$

El resultado es -13 ; ahora sigue el renglón dos de la matriz A por la columna dos de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & \cdots \\ 19 & 2*5+1*(-2) & \cdots \\ 111 & \cdots & \cdots \end{bmatrix}$$

Que da como respuesta 8; ahora se procederá a multiplicar el renglón tres de la matriz A por la columna dos de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & \cdots \\ 19 & 8 & \cdots \\ 111 & 8*5+9*(-2) & \cdots \end{bmatrix}$$

Lo cual da como resultado 22; como siguiente paso se multiplicará el renglón uno de la matriz A por la columna tres de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & -1*3+4*(-3) \\ 19 & 8 & \cdots \\ 111 & 22 & \cdots \end{bmatrix}$$

Dando como respuesta -15 ; ahora se multiplicará el renglón dos de la matriz A por la columna tres de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & -15 \\ 19 & 8 & 2*3+1*(-3) \\ 111 & 22 & \cdots \end{bmatrix}$$

Lo cual da como resultado 3; por último se multiplica el renglón tres de la matriz A por la columna tres de la matriz B :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & -15 \\ 19 & 8 & 3 \\ 111 & 22 & 8*3+9*(-3) \end{bmatrix}$$

La respuesta a lo anterior es -3 :

$$A * B = \begin{bmatrix} -1 & 4 \\ 2 & 1 \\ 8 & 9 \end{bmatrix} * \begin{bmatrix} 6 & 5 & 3 \\ 7 & -2 & -3 \end{bmatrix} = \begin{bmatrix} 22 & -13 & -15 \\ 19 & 8 & 3 \\ 111 & 22 & -3 \end{bmatrix}$$

Lo anterior se puede tomar como regla para matrices de orden superior.

División de matrices.
Producto del numerador multiplicado por la matriz inversa del denominador.

A2.9.5.6 División de matrices

La **división de matrices** se define como el producto del numerador multiplicado por la matriz inversa del denominador. Es decir, sean las matrices A y B tal que $A/B = AB^{-1}$; en seguida se verán algunos ejemplos:

A2.9.5.6.1 Dividido entre un escalar

Si una matriz está dividida entre un escalar, todos los términos de la matriz quedarán divididos por ese escalar. Ejemplo:

Sean la matriz $A = \begin{pmatrix} 8 & 16 \\ 3 & -6 \end{pmatrix}$, y $k = 2$ un escalar. En este caso:

$$\frac{A}{k} = \frac{\begin{pmatrix} 8 & 16 \\ 3 & -6 \end{pmatrix}}{2} = \begin{pmatrix} \frac{8}{2} & \frac{16}{2} \\ \frac{3}{2} & \frac{-6}{2} \end{pmatrix} = \begin{pmatrix} 4 & 8 \\ \frac{3}{2} & -3 \end{pmatrix}$$

A2.9.5.6.2 Inversa en matrices

La inversa de una matriz cuadrada está dada de tal manera que si se tiene la matriz A , la inversa de A es B si:

$$A * B = B * A = I$$

Entonces a B , que es la inversa de A , se representa por A^{-1} por lo que:

$$A * A^{-1} = A^{-1} * A = I$$

Se dice que una matriz cuadrada A es invertible, cuando A tiene inversa y además se le llama matriz no singular.¹⁵² De ahí que:

- Si A es invertible, entonces su inversa es única y a A se le denomina *no singular*.
- No todas las matrices cuadradas tienen inversa, a éstas se les denominan *matrices singulares*.
- La inversa de la inversa da la matriz original: $(A^{-1})^{-1} = A$
- Si A y B son invertibles y tienen las mismas dimensiones ($N \times N$), entonces $(A * B) = B^{-1} * A^{-1}$.

Ejemplo:

Supongamos $A = \begin{pmatrix} 2 & 5 \\ 1 & 3 \end{pmatrix}$ y $B = \begin{pmatrix} 3 & -5 \\ -1 & 2 \end{pmatrix}$. Entonces:

$$AB = \begin{pmatrix} 2 & 5 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 3 & -5 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 6-5 & -10+10 \\ 3-3 & -5+6 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I$$

$$BA = \begin{pmatrix} 3 & -5 \\ -1 & 3 \end{pmatrix} \begin{pmatrix} 2 & 5 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 6-5 & 15-15 \\ -2+2 & -5+6 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I$$

Puesto que $AB = BA = I$, A y B son invertibles, siendo cada una la inversa de la otra.

A2.9.5.7 Método de Gauss

Sea $A = (a_{ij})$ una matriz cuadrada de orden n . Para calcular la matriz inversa de A , que denotaremos como A^{-1} , seguiremos los siguientes pasos:

- **Paso 1.** Construir la matriz $n - 2n$ $M = (A^{-1}I)$ esto es, A está en la mitad izquierda de M y la matriz identidad I en la derecha.

¹⁵² Una matriz no singular siempre tiene inversa; a las matrices que no la tienen se les denomina *singulares*.

- **Paso 2.** Se deja tal y como está la primera fila de M , y debajo del primer término de la diagonal principal, a_{11} , que llamaremos *pivote*, colocaremos ceros. Luego se opera como se indica en el siguiente ejemplo:

Consideremos una matriz 3×3 arbitraria

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}$$

Paso 1:

$$M = (A : I) = \begin{pmatrix} a_{11} & a_{12} & a_{13} & : & 1 & 0 & 0 \\ a_{21} & a_{22} & a_{23} & : & 0 & 1 & 0 \\ a_{31} & a_{32} & a_{33} & : & 0 & 0 & 1 \end{pmatrix} \sim$$

Paso 2:

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & : & 1 & 0 & 0 \\ 0 & a_{11}a_{22} - a_{21}a_{12} & a_{11}a_{23} - a_{21}a_{13} & : & a_{11}0 - a_{21}1 & a_{11}1 - a_{21}0 & a_{11}0 - a_{21}0 \\ 0 & a_{11}a_{32} - a_{31}a_{12} & a_{11}a_{33} - a_{31}a_{13} & : & a_{11}1 - a_{31}1 & a_{31}0 - a_{31}0 & a_{11}1 - a_{31}0 \end{pmatrix}$$

El siguiente paso es igual que el anterior, pero esta vez el pivote es el segundo término de la diagonal principal.

Al llegar al último término de la diagonal, se procede igual que antes, pero poniendo los ceros encima del nuevo pivote. Se observa que al escoger como pivote el último término de la diagonal, la matriz A se transforma en una matriz triangular.

Una vez realizados todos los pasos, la mitad izquierda de la matriz M se convierte en una matriz diagonal. En este momento hay que proceder a transformar, si es que no lo está, la mitad izquierda en la matriz identidad, dividiendo si fuera necesario las filas de M por un escalar.

Ejemplo:

Supongamos que queremos encontrar la inversa de

$$A = \begin{pmatrix} 1 & 0 & 2 \\ 2 & -1 & 3 \\ 4 & 1 & 8 \end{pmatrix}.$$

Primero construimos la matriz $M = (A : I)$,

$$\begin{aligned} M &= \begin{pmatrix} 1 & 0 & 2 & : & 1 & 0 & 0 \\ 2 & -1 & 3 & : & 0 & 1 & 0 \\ 4 & 1 & 8 & : & 0 & 0 & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & 2 & : & 1 & 0 & 0 \\ 0 & -1-2 \cdot 0 & 3-2 \cdot 2 & : & 0-2 & 1-2 \cdot 0 & 0 \\ 0 & 1-4 \cdot 0 & 8-4 \cdot 2 & : & 0-4 & 0 & 1-0 \end{pmatrix} \\ &\sim \begin{pmatrix} 1 & 0 & 2 & : & 1 & 0 & 0 \\ 0 & -1 & -1 & : & -2 & 1 & 0 \\ 0 & 1 & 0 & : & -4 & 0 & 1 \end{pmatrix}, \text{ luego se coge como pivote } a_{22} = -1 \\ &\sim \begin{pmatrix} 1 & 0 & 2 & : & 1 & 0 & 0 \\ 0 & -1 & -1 & : & -2 & 1 & 0 \\ 0 & 0 & 0-(-1) & : & 4-(-2) & 0-1 & -1-0 \end{pmatrix} \\ &\sim \begin{pmatrix} 1 & 0 & 2 & : & 1 & 0 & 0 \\ 0 & -1 & -1 & : & -2 & 1 & 0 \\ 0 & 0 & 1 & : & 6 & -1 & -1 \end{pmatrix} \sim \end{aligned}$$

La mitad izquierda de M está en forma triangular, por consiguiente, A es invertible. Si hubiera quedado toda una fila con ceros en la mitad A de M , la operación habría terminado (A no es invertible).

A continuación, escogemos como pivote a_{33} , colocamos ceros encima de éste y seguimos operando hasta que nos quede una matriz diagonal.

$$\sim \begin{pmatrix} 1 & 0 & 0 & \vdots & -11 & 2 & 2 \\ 0 & -1 & 0 & \vdots & 4 & 0 & -1 \\ 0 & 0 & 1 & \vdots & 6 & -1 & -1 \end{pmatrix}.$$

Ya que la matriz colocada en la mitad izquierda es diagonal, no hay que operar más. Transformamos la matriz diagonal en una matriz identidad; para ello hay que dividir la segunda fila entre -1 :

$$\sim \begin{pmatrix} 1 & 0 & 0 & \vdots & -11 & 2 & 2 \\ 0 & 1 & 0 & \vdots & -4 & 0 & 1 \\ 0 & 0 & 1 & \vdots & 6 & -1 & -1 \end{pmatrix}.$$

La matriz que ha quedado en la mitad derecha de M es precisamente la matriz inversa de A :

$$A^{-1} = \begin{pmatrix} -11 & 2 & 2 \\ -4 & 0 & 1 \\ 6 & -1 & -1 \end{pmatrix}$$

Para comprobar si el resultado es correcto, se multiplica AA^{-1} , lo cual da como resultado la matriz identidad I .

Comprobación:

$$AA^{-1} = I$$

$$\begin{pmatrix} 1 & 0 & 2 \\ 2 & -1 & 3 \\ 4 & 1 & 8 \end{pmatrix} \begin{pmatrix} -11 & 2 & 2 \\ -4 & 0 & 1 \\ 6 & -1 & -1 \end{pmatrix} = \begin{pmatrix} -11+0+12 & 2+0-2 & 2+0-2 \\ -22+4+18 & 4+0-3 & 4-1-3 \\ -44-4+48 & 8+0-8 & 8+1-8 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = I.$$

A2.9.6 Operaciones con matrices en Excel

Matriz. Arreglo de dos dimensiones en el cual se puede guardar información y está formado por renglones y columnas que se relacionan entre sí.

Una **matriz** es un arreglo de dos dimensiones en el cual se puede guardar información y está formada por renglones y columnas que se relacionan entre sí. Su orden se representa de la manera $A \times B$, en dónde A es el número de renglones y B es el número de columnas. Por ejemplo:

	A10		=	
	A	B	C	D
1				
2				
3	MATRIZ 1			
4				
5	12	90	13	
6	45	76	45	
7	67	89	7	
8	85	56	65	
9	34	31	43	
10				
11				

El número de renglones es 5 y el número de columnas es 3, por lo que la matriz 1 es de orden 5×3 .

Nota: Para multiplicar dos matrices, el número de columnas de la primera debe ser igual al número de renglones de la segunda; el orden de la matriz resultante será el número de renglones de la primer matriz por el número de columnas de la segunda.

A2.9.6.1 Multiplicación de matrices

Para multiplicar matrices se deben seguir los pasos que se enlistan a continuación:

1. Se escriben las dos matrices a multiplicar.


	A	B	C	D	E	F	G	H
1								
2								
3	MATRIZ 1				MATRIZ 2			
4								
5		12	90	13		34	27	
6		45	76	45		67	98	
7		67	89	7		54	78	
8		85	56	65				
9		34	31	43				
10								

La matriz 1 es de orden 5×3 y la matriz 2 es de orden 3×2 , por lo que la matriz resultante será de orden 5×2 .


2. Seleccione el espacio necesario donde irá la matriz resultante.

	A	B	C	D	E	F	G
1							
2							
3	MATRIZ 1				MATRIZ 2		
4							
5		12	90	13		34	27
6		45	76	45		67	98
7		67	89	7		54	78
8		85	56	65			
9		34	31	43			
10							
11							
12							
13							
14							
15							
16							
17							


3. Del menú "Insert" seleccione la opción "Function", le aparecerá una pantalla, en "Function Category" seleccione "All", y en "Function Name" seleccione "MMULT". Oprima "OK".




- Aparecerá una pantalla con dos renglones. Se debe posicionar en “Array 1” y seleccionar el rango en que se encuentra la matriz 1 para posteriormente posicionarse en “Array 2” y seleccionar el rango de la matriz 2. Por último se da clic en “OK”.



- La matriz resultante no aparecerá completa por lo que se tendrá que posicionar en la barra de fórmulas y presionar las teclas Shift, Control y Enter al mismo tiempo.



- Le aparecerá la matriz resultante siguiente.




A2.9.6.2 Matriz inversa

Prácticamente se siguen los primeros pasos de la multiplicación de matrices:


- Se escribe la matriz a invertir, y se selecciona el espacio de la matriz resultante, que en este caso es del mismo orden que el de la matriz a transponer.
- Del menú “Insert”; seleccione “Function”. En “Function Category” seleccione “All”; y de “Function Name” seleccione “Minverse”. Dé OK.
- En la pantalla que aparecerá en seguida, se debe posicionar en “Array” y seleccionar el espacio de su matriz a invertir.

4. En la barra de fórmulas, presione Shift, Control y Enter al mismo tiempo para obtener el resultado.



A2.9.6.3 Matriz transpuesta

El proceso para obtener la matriz transpuesta es el mismo que se sigue en la búsqueda de la matriz inversa, sólo que el orden de la matriz resultante se transpone al de la matriz a transponer, por ejemplo, si la matriz a transponer es de orden 2×3 , la matriz resultante será de orden 3×2 , entonces se tienen que seleccionar tres renglones por cuatro columnas.



Por último se posiciona en la barra de fórmulas, y oprime Shift, Control y Enter al mismo tiempo para obtener la matriz transpuesta.

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 3

Análisis de factores

Objetivo general:

Dar a conocer la técnica de análisis de factores y su aplicación en la solución de problemas de las diferentes áreas administrativas.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Explicar con sus propias palabras en qué consiste la técnica de análisis de factores.
- Diferenciar la técnica de análisis de factores de otras técnicas multivariantes.
- Aplicar la técnica de análisis de factores a un problema específico del área administrativa.
- Reconocer cuándo debe usarse el análisis de factores y en qué situaciones no.
- Identificar qué variables son adecuadas para este tipo de análisis y cuáles no.
- Explicar los términos *factor*, *puntaje de factor* y *cargas de factor*.
- Describir en qué consiste el análisis de componentes principales.
- Comprender el modelo de factor común.
- Interpretar la información de la matriz de factores no rotada.
- Conocer las distintas técnicas usadas para determinar el número de factores a extraer.
- Comprender los conceptos de *eigenvalor* y *comunalidad*.
- Explicar el concepto de *rotación de factores*.
- Comprender las distintas técnicas de rotación de factores.
- Utilizar la matriz de factores rotada para agrupar las variables.
- Establecer los diferentes criterios para identificar cargas de factores significativas.
- Describir en qué forma se pueden extraer nuevas variables o puntajes de esta técnica.
- Mencionar el uso de los puntajes de factores para manejar la información de éstos en análisis posteriores.

3.1 Antecedentes

El **análisis de factores** también es conocido como *análisis factorial*; es una técnica estructural o de interdependencia, eso significa que todas las variables tienen la misma importancia y son indepen-

Análisis de factores o análisis factorial. Técnica estructural o de interdependencia en la que todas las variables tienen la misma importancia.

dientes puesto que no hay variables que fueron dadas antes (*a priori*) y otras después; no existe un concepto que las vuelva dependientes entre ellas o que coloque unas sobre otras.

El objetivo principal de esta técnica es resumir la información para describirla más fácilmente; en este proceso se reducen las dimensiones o variables. Esta técnica exige que la mayoría de las variables sea independiente en cierto grado y métricas o medidas en escala de intervalo o razón.

El análisis de factores surge de una necesidad en psicología y matemáticas. Zaltman y Burger (1980) señalan que esta técnica se originó con los psicólogos de inicio del siglo pasado, quienes suponían que existían muchos aspectos desconocidos vinculados con la personalidad y la inteligencia, cuyo análisis profundo detectaría la presencia de ciertos esquemas básicos responsables del comportamiento. Fue el psicólogo Charles Spearman quien aplicó inicialmente el análisis de factores al intentar resolver el dilema acerca de si la inteligencia respondía a un solo factor general o estaba conformada por un conjunto de habilidades específicas.

Posteriormente el análisis de factores se aplicó a la investigación de mercados. La difusión de esta técnica fue impulsada a partir de la década de 1960 por la aparición de potentes equipos de cómputo capaces de procesar grandes cantidades de datos y programas informáticos cada vez más accesibles.

3.2 Áreas de aplicación

Esta técnica se puede aplicar a cualquier área, como medicina para agrupar las variables que puedan diferenciar síntomas o tratamientos, el posicionamiento de enfermedades basándose en la sintomatología para estudiar cuáles de ellas provocarían padecimientos más o menos graves, o bien para ver cuáles enfermedades son similares; en psicología se puede utilizar para agrupar variables y conocer patologías afines o posicionar sintomatologías para decidir los tratamientos a aplicar o saber en qué se pueden diferenciar; en educación para agrupar variables que indiquen las competencias que los estudiantes requieren para lograr un desempeño eficiente en las empresas; en ética podrían agruparse valores para diferenciarlos o ver cuáles atributos hacen que dichos valores se logren discriminar; en economía se podrían agrupar recursos económicos o naturales para diferenciarlos, aunque también es posible conocer la clasificación de países para decidir los posibles caminos a seguir basándose en dichos recursos.

Definitivamente existe mucho campo de acción para esta técnica, pues formar grupos de variables facilita el análisis de éstas.

3.3 Definición

El análisis de factores ayuda a reducir información o datos, es decir, encuentra homogeneidad al interior de un conjunto de muchas variables para así formar grupos. La técnica parte de la idea de que existe un gran número de variables simultáneas a las que se les denomina **dimensión**, entonces de un gran conjunto de variables busca aquellas que estén muy relacionadas (o correlacionadas) y las une para formar una nueva dimensión o una nueva variable que, a su vez, tiene nuevos valores llamados **puntajes o puntuaciones**.

Existen varios sinónimos para denominar a los factores nuevos como: *dimensiones, componentes, características, atributos* y, por supuesto, *factores*.

La técnica de factores analiza las relaciones existentes entre un gran número de variables con el fin de identificar grupos afines o similares ya que toma las similitudes que hay en la estructura interna de las variables para tratar de explicarlas por medio de esas nuevas dimensiones o factores. Esto es, resume la información de las variables originales a través de características comunes y forma otras nuevas llamadas *factores* o *componentes*; estos últimos deben representar lógicamente a las variables originales. Los factores finales pueden utilizarse como variables en análisis posteriores, lo que facilita el manejo de la información ya resumida.

Existen muchas formas de resumir, esto quiere decir que podremos tener múltiples resultados, pero sólo uno de ellos es el mejor.

La pregunta es ¿cómo se reducirá o resumirá la información o el número de variables? La respuesta, de la forma en que represente la información lo más fielmente posible.

Dimensión. Variables simultáneas que hay en un conjunto.

Puntajes o puntuaciones. Nueva dimensión o variable que surge a partir del análisis de factores.

Suponga por ejemplo que se tiene la siguiente información ya graficada en tres dimensiones, imagínese que las barras o tubos del dibujo son las respuestas de las variables y con ellas se construyó la siguiente figura:




Figura 3.1

Si se rota todo el dibujo de manera que quede adelante el eje y del eje x , es decir, si se rota de abajo hacia arriba como lo muestran las flechas curvas, surgiría la figura 3.2.




Figura 3.2

El objetivo de la técnica de análisis de factores es reducir o resumir variables, supongamos que quitamos el eje z , el dibujo quedaría de la siguiente forma:




Figura 3.3

Al comparar este dibujo con el original se puede ver que faltan los tres cilindros grises y una barra gris, por lo que se pierde exactitud.




Figura 3.4

Como se pierde información entonces esta solución no sería la adecuada. Al regresar al dibujo original encontramos:




Figura 3.5

Si se rota todo el dibujo de otra manera, ahora se muestra el eje z adelante del eje y , es decir, si se rota de izquierda a derecha como lo muestran las flechas grises resultaría la figura 3.6.




Figura 3.6

Recordemos que el objetivo es reducir o resumir variables; si se quita el eje x , el dibujo quedaría como se indica a continuación:




Figura 3.7

Si se compara este dibujo con el original, podemos observar que faltan dos cilindros grises y las dos barras grises, por lo que otra vez no es una solución adecuada.




Figura 3.8

Al tener una solución incorrecta deberemos regresar al dibujo original:




Figura 3.9

Otra posibilidad que existe es rotar el dibujo de derecha a izquierda como lo muestran las líneas grises de la figura 3.10 de manera que el eje z quede adelante del eje x.




Figura 3.10

Al eliminar el eje y el dibujo quedaría de la siguiente forma:




Figura 3.11

Si se compara este dibujo con el original podemos observar que no falta nada, incluso se pueden ver los diferentes tamaños de los cilindros y las barras.




Figura 3.12

De lo anterior podemos concluir que la mejor forma de resumir es quitar el eje y, pues la información se observa de la misma forma que en un inicio, pero sin una dimensión (la y), y éste es precisamente el objetivo de la técnica.

3.4 Objetivos específicos del análisis de factores

En seguida enlistamos los objetivos específicos del análisis de factores:

- Identificar un conjunto de dimensiones o características que se encuentran latentes (es decir, que no se detectan fácilmente) dentro de un gran conjunto de variables.
- Encontrar características que describan a núcleos poblacionales (personas u objetos).
- Identificar nuevas variables, las cuales podrán utilizarse en análisis posteriores, como el de regresión, el discriminante, etcétera.
- Crear datos para las nuevas variables encontradas, a partir de la información original.
- Obtener los mapas de posicionamiento semántico.

Factor. Desde el punto de vista matemático, es una combinación lineal de las variables originales de la investigación.

Antes de pasar a otro punto, es importante definir qué significa **factor**. Desde el punto de vista matemático, es una combinación lineal de las variables originales de la investigación, representado por la siguiente ecuación:

Fórmula 3-1 Ecuación para encontrar los puntajes de los factores

$$Fi = A_1X_1 + A_2X_2 + A_3X_3 + \cdots + A_kX_k$$

donde:

F = es el factor o componente i de la observación k .

A = representa la importancia o peso que cada variable tiene con respecto al factor encontrado, dicha importancia es relativa, es decir, es la importancia ponderada que tiene cada variable original con respecto a la característica obtenida, pero se debe recordar que las variables originales fueron estandarizadas o tipificadas.

X = es la(s) variable(s) original(es)

i = es el número del factor.

k = es el número de variable.

Los supuestos¹ que el análisis de factores requiere son:

1. Las variables involucradas en el análisis deben provenir de poblaciones con distribuciones normales.
2. Las variables deben tener varianzas constantes, es decir, homogeneidad de varianzas u homoscedasticidad.
3. Las variables incluidas en el análisis deben ser lineales.
4. Las variables, a pesar de ser independientes, deben presentar cierta relación entre ellas para que el análisis de factores se pueda llevar a cabo y tenga sentido realizarlo.

También es importante aclarar que las variables deben estandarizarse antes de iniciar el análisis, es decir, que en términos de unidades puedan ser comparables, ya que la estandarización quita efectos de unidades y vuelve comparables a las variables; cuando esto sucede, su media es cero y su varianza es igual a 1. Muchos de los paquetes estadísticos que realizan el método de análisis de factores estandarizan las variables en el procedimiento.

3.5 Pasos generales para llevar a cabo un análisis de factores

Antes de mencionar los pasos generales para el análisis de factores cabe aclarar lo siguiente:

- Se mencionarán de forma general los pasos de la técnica y lo que el investigador debe tomar en cuenta para su análisis, pero el lector deberá recordar que cada paso contiene subpasos y que éstos se describirán conforme se vean los pasos generales.
- Cuando se explique cada paso se manejará un ejemplo detallado relacionado con el área de política para que el lector comprenda mejor la técnica, pero deberá recordar siempre que este método es útil en cualquier área.
- Cuando cualquier paso requiera más explicación se detallará el ejemplo, con el fin de que el lector comprenda cualquier posible solución.

Los pasos generales para el análisis de factores se muestran en la figura 3-13.

En el ejemplo de la página 337 se tiene un área de oportunidad, al ver todas las variables juntas no se sabe en realidad qué se está midiendo por lo que es necesario resumir la información para ver cómo se puede describir el o los conjuntos de variables.

Se debe establecer cuál es o son los objetivos, como en todo análisis. El objetivo principal o general es único y va de acuerdo con el problema o área de oportunidad; cuando se tiene un gran número de variables en el cuestionario y se miden en forma simultánea, lo que puede interesar es encontrar si dichas preguntas se pueden agrupar de alguna forma mínima pero capaz de explicar lo máximo de la información o de los datos y además da como resultado varios grupos de variables que representen algo en común; de esta manera se reducirá el número de variables o dimensiones para poder explicar de una forma lógica las respuestas que las personas han contestado.

El objetivo general en el ejemplo sería: sintetizar conceptos globales a partir de temas o aspectos económicos.

Los objetivos específicos deberán ser por lo menos dos y cada uno englobará al menos dos preguntas, es importante recordar esto al medir la información. Para el ejemplo se tienen los siguientes objetivos específicos:

Objetivo específico 1: Medir las condiciones de seguridad que prevalecen en el país.

Objetivo específico 2: Medir las condiciones económicas que prevalecen en el país.

¹ Normalidad, homoscedasticidad y linealidad, además es deseable que exista cierto grado de multicolinealidad (dado que el objetivo de este análisis es identificar series de variables interrelacionadas). Para probar dichos supuestos se recomienda leer el capítulo 2 "Análisis de regresión múltiple", en donde el tema es tratado con profundidad.




Figura 3-13 Pasos generales del análisis de factores.



Ejemplo

Ejemplo² de análisis de factores:

Se parte de una encuesta con la cual se pretendió conocer las opiniones de las personas sobre ciertos aspectos de relevancia actual y el cuestionario es el siguiente:

Para cada uno de los siguientes cuestionamientos dé su opinión:

¿Sobre delincuencia, asaltos y robos?

Excelente esfuerzo

Pésimo esfuerzo

—	—	—	—	—	—	—	—	—
1	2	3	4	5	6	7	8	9

¿Sobre sueldos?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre derechos humanos?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre empleo?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre terrorismo?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre vivienda?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre medidas para combatir las protestas?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre pobreza?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre educación?

Excelente esfuerzo _____ Pésimo esfuerzo

¿Sobre alzas de precios, inflación?

Excelente esfuerzo _____ Pésimo esfuerzo

Como en todo análisis, se debe establecer cuál es el problema que se tratará en la investigación o cuál es el área de oportunidad, en ambos casos, si se pretende resumir la información para poder describirla, lo mejor es utilizar el análisis de factores. Como ya se dijo antes, este método es aplicable a cualquier área.

3.5.1 Diseño del análisis de factores

En este punto se deberá pensar qué se desea resumir: el mercado a través de información referente a resumir personas, objetos, el seguimiento de la información a través del tiempo o variables (figura 3-14).

Análisis de factores tipo-R: si se desea identificar un conjunto de dimensiones que están latentes dentro de un gran conjunto de variables, con el fin de agruparlas para describirlas en un menor número de dimensiones. Para entender esto, podríamos hablar de que las variables fueron almacenadas en alguna base de datos en columnas (tabla 3-1).

² La base de datos se obtuvo de un estudio, del cual se prefiere conservar el anonimato.




Figura 3-14 Tipo de análisis de factores.

Tabla 3-1 Muestra cómo ordenar la información para el análisis de factores tipo-R

	Variable 1	Variable 2	Variable 3		Variable K
Persona u objeto 1	5	3	4		6
Persona u objeto 2	5	3	4		6
Persona u objeto 3	2	4	1		6
.	4	1	5		6
.					
Persona u objeto N	4	5	2		6

Se podría decir que la técnica busca disminuir el número de columnas con base en sus semejanzas. Análisis de factores tipo-Q: se utiliza cuando se desea encontrar características que describan a núcleos poblacionales. En este caso se puede hablar de que las respuestas de las personas fueron necesariamente almacenadas en alguna base de datos en las columnas, es decir:

Tabla 3-2 Muestra cómo ordenar la información para el análisis de factores tipo-Q

	Variable 1	Variable 2	Variable 3		Variable K
Persona u objeto 1	5	5	2		4
Persona u objeto 2	3	3	4		5
Persona u objeto 3	4	4	1		2
· · ·	2	2	5		3
Persona u objeto N	6	6	6		6

Otro tipo de análisis es el P, éste agrupa variables, pero a diferencia del R, las mediciones están identificadas a través de regiones o del tiempo.

Se desea examinar un siglo de economía en Estados Unidos, los años comprendidos pueden ser entre 1850 y 1950; se recolecta información del número de habitantes, inmigrantes e índice de muertes por cáncer, entre otras variables, dichos datos corresponden a cada año. Por lo que los renglones son la información de los 100 años y las columnas son las variables; este análisis se puede comparar con otro realizado en un país distinto, por ejemplo Inglaterra.

Tabla 3-3 Muestra cómo ordenar la información para el análisis de factores tipo-P

	Habitantes	Inmigrantes	Muertes		Nacimientos
1850	5	3	4		6
1851	5	3	4		6
1852	2	4	1		6
· · ·	4	1	5		6
1950	4	5	2		6

El análisis de factores tipo-O es muy parecido al tipo P, pero con la diferencia de que no agrupa a las variables, sino a las regiones o épocas por lo que en los renglones no se pone la información de los n años de una región que se pretende analizar, sino la información de cada país.

Tabla 3-4 Muestra cómo ordenar la información para el análisis de factores tipo-O

	Habitantes	Inmigrantes	Muertes		Nacimientos
País 1	5	3	4		6
País 2	5	3	4		6
País 3	2	4	1		6
· · ·	4	1	5		6
País K	4	5	2		6

El análisis de factores tipo-S agrupa a personas a las cuales se les realiza una medición y se le da seguimiento a lo largo de cierto tiempo, por lo que los renglones son las épocas o fechas y las columnas corresponden a las personas.

Tabla 3-5 Muestra cómo ordenar la información para el análisis de factores tipo-S

	Persona 1	Persona 2	Persona 3		Persona N
1950	5	3	4		6
1951	5	3	4		6
1952	2	4	1		6
.	4	1	5		6
.					
1980	4	5	2		6

El análisis de factores tipo-T agrupa regiones o épocas que identifican a grupos de personas por haber analizado sus características a lo largo de cierto tiempo, en este análisis los renglones corresponden a las regiones o las diferentes épocas y las columnas a las personas.

Tabla 3-6 Muestra cómo ordenar la información para el análisis de factores tipo-T

Década	Persona 1	Persona 2	Persona 3		Persona N
1950	5	3	4		6
1960	5	3	4		6
1970	2	4	1		6
.	4	1	5		6
.					
2020	4	5	2		6

De acuerdo con el ejemplo lo que se desea reducir es el número de variables, pues hay 10; lo que se debe realizar es un análisis de factores R.

Aquí se deberá obtener la información por medio de un cuestionario o también es posible que se haya conseguido de algún otro modo, por ejemplo, de medios secundarios, ésta deberá capturarse en algún software estadístico.³ En este paso es importante tener en cuenta las siguientes consideraciones:

- Las variables deben ser métricas; la mayoría medida en escala de intervalo o de razón ya que la técnica no acepta variables no métricas.
- Esta técnica permite el uso de variables *dummys* o dicotómicas, en menor número que las de intervalo o razón.
- Se requiere normalidad entre los datos.
- La técnica de factores no debe usarse para los casos en los que el número de entrevistas sea menor a 50, preferentemente debe aplicarse en investigaciones que comprendan 100 o más entrevistas o encuestas. Como regla se considera que el tamaño de la muestra debe ser 4 o 5 veces el número de variables que se pretenda agrupar con la técnica.

³ Para conocer la forma de captura de la información en el SPSS™ revise el anexo 2-2 “Tabla t”, del capítulo 2 “Análisis de regresión múltiple”.

3.5.2 Estandarización o tipificación de las variables

Una vez almacenada la información es recomendable estandarizar las variables⁴ (pero no es necesario, porque se puede trabajar con la matriz de varianzas y covarianzas); si se desea estandarizar el SPSS™ lo puede realizar.

3.5.3 Generar la matriz de correlación

Para calcular las correlaciones es necesario obtener las varianzas y covarianzas⁵ de las variables y después encontrar las correlaciones,⁶ pero si las variables se encuentran estandarizadas no es necesario este paso, ya que las varianzas y covarianzas de variables estandarizadas son las correlaciones; ésta es una de las ventajas que se tiene cuando se estandarizan las variables.

3.5.3.1 Matriz de correlación

Esta matriz se genera por computadora y proporciona una medida de relación entre las variables de interés, comparándolas por parejas; en el análisis de factores debe existir cierto grado de relación entre los grupos de variables, es decir, las correlaciones deben ser mayores que cierto valor (si se desea saber cuáles correlaciones son significativas pueden utilizarse los p-valores que arrojan los programas), de no ser así no es necesario usar la técnica.

La tabla 3-7 muestra la matriz de correlación que arroja el SPSS™ del ejemplo sobre la labor o esfuerzo que el gobierno dedica para solucionar problemas sociales.

En la matriz de correlación ciertas correlaciones son muy bajas (cercanas a cero) y otras son altas (cercanas⁷ a 1 o a -1); se marcaron con un círculo gris las que son significativas con 95% de confianza y las mismas pero en negro para señalar el valor-p.⁸

La matriz de correlación indica cuáles variables posiblemente quedarán agrupadas en el mismo factor y cuáles posiblemente no lo hagan. Por ejemplo, si se ven los círculos que se agregaron a la tabla de la matriz de correlación se aprecia que hay una relación alta entre *delincuencia* y *derechos humanos* por lo que posiblemente las dos variables queden juntas en algún factor o componente, pero si se observa *delincuencia* y *empleo* hay una correlación bastante baja y cercana a cero por lo que posiblemente no queden en el mismo factor, en pocas palabras, nos podemos dar cuenta de la posible solución.

La matriz de correlación sirve para cuando las variables se identifican con más de un factor o característica y se tiene que deslindar para que cada variable se relacione con un solo factor; este punto se cubrirá posteriormente.

3.5.3.2 Determinante de la matriz de correlación

El determinante de la matriz de correlación oscila entre: 0 y 1.

$$0 \leq |R| \leq 1$$

donde

R = es la matriz de correlación

$|R|$ = es el determinante de la matriz de correlación

Si el valor del determinante es cercano a cero indica la conveniencia de analizar el problema mediante el análisis de factores; si, por el contrario, el valor se aproxima a 1 muestra que el análisis no se

⁴ Si las variables se encuentran estandarizadas se puede trabajar con la matriz de correlación o con la matriz de varianzas y covarianzas; si no están estandarizadas forzosamente se deberá trabajar con la matriz de correlación.

⁵ El anexo 2-5 "Tabla Durbin-Watson" muestra el procedimiento para calcular las covarianzas de las variables.

⁶ En el anexo 2-6 "Coeficientes Shapiro-Wilk" se puede ver el procedimiento para calcular las correlaciones de dichas variables.

⁷ Una correlación positiva y cercana a 1 es una relación directa entre las dos variables, por el contrario una correlación negativa y cercana a -1 es una relación indirecta entre ambas variables pero una correlación cercana a cero indica que las dos variables no tienen relación.

⁸ Si se usa 95% de confianza, para que el p-valor sea significativo deberá ser menor a 0.05.

Tabla 3-7 Matriz de correlación

Matriz de correlaciones ^a										
	¿Sobre delincuencia, asaltos y robos?	¿Sobre sueldos?	¿Sobre derechos humanos?	¿Sobre empleo?	¿Sobre terrorismo?	¿Sobre vivienda?	¿Sobre medidas para combatir las protestas?	¿Sobre pobreza?	¿Sobre educación?	¿Sobre precios?
Correlación										
	¿Sobre delincuencia, asaltos y robos?	.1.000	.022	.601	.005	.414	.500	-.022	-.206	-.036
	¿Sobre sueldos?	.022	1.000	.108	.523	-.014	.107	.533	-.061	-.051
	¿Sobre derechos humanos?	.601	.108	1.000	-.111	.295	.422	.060	-.145	.078
	¿Sobre empleo?	.005	.523	-.111	1.000	-.001	-.005	.507	.124	.133
	¿Sobre terrorismo?	.414	-.014	.595	-.001	1.000	.595	.052	-.043	.076
	¿Sobre vivienda?	-.070	.551	-.016	.529	1.000	.028	.634	-.006	.055
	¿Sobre medidas para combatir las protestas?	.500	.107	.422	-.005	.595	1.000	.141	-.063	.037
	¿Sobre pobreza?	-.022	.533	.060	.507	.052	.141	1.000	.132	.113
	¿Sobre educación?	-.206	-.061	-.145	.124	-.043	-.063	.132	1.000	.323
	¿Sobre precios?	-.036	-.051	.078	.133	.076	.037	.113	.323	1.000
Sig. (Unilateral)										
	¿Sobre delincuencia, asaltos y robos?	.394	.394	.000	.475	.000	.000	.395	.006	.332
	¿Sobre sueldos?	.394		.095	.000	.000	.097	.000	.228	.267
	¿Sobre derechos humanos?	.000	.095		.087	.000	.000	.235	.038	.170
	¿Sobre empleo?	.475	.000	.087		.494	.474	.000	.066	.052
	¿Sobre terrorismo?	.000	.434	.000	.494		.000	.263	.300	.178
	¿Sobre vivienda?	.198	.000	.425	.000	.210	.367	.000	.473	.250
	¿Sobre medidas para combatir las protestas?	.000	.097	.000	.474	.000		.042	.223	.325
	¿Sobre pobreza?	.395	.000	.235	.000	.263	.042		.054	.085
	¿Sobre educación?	.006	.228	.038	.066	.300	.223	.054		.000
	¿Sobre precios?	.332	.267	.170	.052	.178	.325	.085	.000	

^a Determinante = .044.

debe llevar a cabo. Para el ejemplo, en la tabla 3-3, el círculo oscuro indica el valor de $4.411 \times 10^{-2} = 0.04411$, el problema con este criterio es que no existe un límite para decir si es cercano a cero o no, por lo que se recomienda mejor utilizar las correlaciones bivariadas.

3.5.3.3 Prueba de contraste de esfericidad de Bartlett

Como ya se dijo en la matriz de correlación se puede ver la relación entre las variables; de hecho es necesario que exista correlación entre ellas, es decir que haya cierto grado de multicolinealidad ya que la técnica de análisis de factores identifica las variables que están interrelacionadas, en caso contrario la matriz de correlación sería una *matriz identidad*⁹ y no tendría sentido llevar a cabo el análisis de factores. Esto se puede verificar por medio de la prueba de contraste de esfericidad de Bartlett, sus hipótesis serían:

$H_0: |R| = I$; no se debe utilizar la técnica de análisis de factores para resumir la información de la base de datos.

$H_a: |R| \neq I$; sí se puede emplear la técnica de análisis de factores.

Donde:

R = es la matriz de correlación

$|R|$ = es el determinante de la matriz de correlación

I = es la matriz identidad

Volviendo al ejemplo sobre la labor o esfuerzo que el gobierno dedica para solucionar problemas, los resultados del SPSS[™] se presentan a continuación:

Tabla 3-8 Muestra la prueba de esfericidad de Bartlett

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.694
Prueba de esfericidad de Bartlett	Ji cuadrada	452.048
	df	45
	Sig.	.000

Entonces se realiza la prueba de hipótesis de la esfericidad de Bartlett; la fórmula para obtener el valor de ji cuadrada calculada es la siguiente:

Fórmula 3-2 Ecuación para obtener el valor de ji cuadrada

$$X_C^2 = - \left[n - 1 - \frac{1}{6}(2m + 5) \right] \ln|R|$$

Con los grados de libertad $= 0.5 (n^2 - n)$.

Donde:

m = es el número de variables

n = es el número de datos

$|R|$ = es la determinante de la matriz de correlación.

De acuerdo con el ejemplo se tiene: $m = 10$, $n = 15_0$ y el $|R| = 0.0441_1$

$$X_C^2 = - \left[150 - 1 - \frac{1}{6}(2(10) + 5) \right] \ln|.0441_1|$$

⁹ Una *matriz identidad* es aquella que en su diagonal principal tiene 1 y fuera de ella, ceros; esto indicaría que no existen correlaciones entre las variables.

por lo que el valor de la ji cuadrada calculada es el siguiente:

$$X_C^2 = 452.048$$

y para los grados de libertad $= 0.5(1_0^2 - 1_0) = 4_5$.

Éste se deberá comparar con una ji cuadrada de tablas, si se desea un nivel de confianza en el estudio de 95%; al buscar en la tabla de la ji cuadrada, que se encuentra en el anexo 3-1 “Tabla ji cuadrada” se tiene:

$$X_{t,a=0.05,4_5}^2$$

df	0.10	0.05	0.025
44	56.369	60.481	64.201
45	57.505	61.656	65.410
46	58.641	62.830	66.617

$$X_{t,a=0.05,4_5}^2 = 61.65_6$$

Si: $X_C^2 > X_t^2$ se rechaza H_0 .

Al comparar el calculado contra el teórico se tiene que:

$$452.048 > 61.656 \text{ y por lo tanto se rechaza } H_0$$

Si se hiciera de otra forma, por ejemplo, con el p-valor = sig. = 0.000:

$$\text{Si } p - \text{valor} < 0.0_5 \text{ se rechaza } H_0$$

Al comparar el calculado contra el teórico se tiene que:

$$0.000 < 0.0_5 \text{ y por lo tanto se rechaza } H_0.$$

Como se rechazó H_0 entonces se concluye que la matriz de $|R| \neq I$, por lo que llevar a cabo el análisis de factores sí tiene sentido.

3.5.3.4 Análisis de suficiencia general o Kaiser-Meyer-Olkin

Una vez que se rechazó la hipótesis nula se realiza el análisis de suficiencia de la técnica de análisis de factores, que se hace tanto global como para cada variable. La medida de suficiencia o adecuación del muestreo general (por sus siglas en inglés *MASg*) o *KMO* (Kaiser-Meyer-Olkin) es una medida global que indica si se llevará a cabo el análisis de factores, qué tan fuerte y adecuada sería la posible solución a encontrar; mientras más grande es este valor la solución es más fuerte, lo óptimo es que sea: *MASg* ≥ 0.5 . Como referencia se puede considerar lo siguiente:

Tabla 3-9 Evaluación para la medida de adecuación

MASg	Evaluación
De .90 en adelante	Excelente
De .80 a .90	Bueno
De .70 a .80	Aceptable
De .60 a .70	Regular
De .50 a .60	Bajo
Menor a .50	Inaceptable

Volviendo al ejemplo sobre la labor o esfuerzo que el gobierno dedica para solucionar problemas, se tienen los cálculos que realiza el SPSS™:

Tabla 3-10 KMO o MASg

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.694
Prueba de esfericidad de Bartlett	Ji cuadrada aprox.	452.048
	df	45
	Sig.	.000

El KMO o MASg se obtiene bajo la siguiente expresión:

Ecuación 3-3 Ecuación para obtener el KMO.

$$KMO = \frac{\sum \sum_{h \neq j} r^2 j^h}{\sum \sum_{h \neq j} r^2 j^h + \sum \sum_{h \neq j} a^2 j^h}$$

Se ve que el valor del MASg = 0.694 por lo que $0.694 \geq 0.5$, esto muestra que la solución a encontrar es algo fuerte, aunque sólo lo supera por 0.194 (el cual sale de $0.694 - 0.5$), esto podría ser indicativo de que alguna variable no debería estar en el análisis; esto se verá en el siguiente punto.

3.5.3.5 Análisis de adecuación individual

Después del análisis global se tiene que analizar cada variable y esto se lleva a cabo en la antiimagen de la matriz de correlación, que es una matriz formada por el valor negativo de la correlación parcial y la diagonal de dicha matriz. El resultado es una medida que se le conoce como MASi (por sus siglas en inglés y es la medida de adecuación muestral individual de cada variable), el resto son las correlaciones parciales.

Las correlaciones parciales con valores muy grandes indican que los datos de la variable no son adecuados y que ésta no debería estar en el análisis, es decir, fuera de la diagonal de la matriz antiimagen no deberán colocarse valores grandes (valores absolutos), pero los valores del MASi, los de la diagonal principal, deberán ser valores grandes. Si $MASg \geq 0.5$ se ve la matriz antiimagen, pero sin olvidar que si el MASi de las variables es menor a 0.5 la variable deberá ser eliminada del estudio (tabla 3-12).

Como se puede observar la variable *alza de precios* tiene valor menor a 0.5, por lo que es necesario eliminarla del análisis, si existieran más valores se procedería por partes, primero se saca del análisis a la variable que tenga el menor MASi, luego se vuelve a realizar el análisis del MASi para ver si alguna otra tiene un valor menor a 0.5, se quita aquella variable con el menor MASi y así sucesivamente hasta que todas queden con valores mayores a 0.5. De acuerdo con el ejemplo, al quitar la variable alza de precios se tiene lo siguiente:

Tabla 3-11 Muestra el KMO sin la variable *alza de precios*

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.709
Prueba de esfericidad de Bartlett	Ji cuadrada	427.472
	df	36
	Sig.	.000

Como se puede observar el MASg aumentó de 0.694 a 0.709, la sig. = 0.000 todavía sigue siendo menor a 0.05, por lo que llevar a cabo la técnica de factores tiene sentido; a continuación se presenta nuevamente la matriz antiimagen para revisar los valores del MASi (tabla 3-13).

Tabla 3-12 Matriz antiimagen

	¿Sobre delincuencia, asaltos y robos?	¿Sobre sueldos?	¿Sobre derechos humanos?	¿Sobre empleo?	¿Sobre terrorismo?	¿Sobre vivienda?	¿Sobre medidas para combatir las protestas?	¿Sobre pobreza?	¿Sobre educación?	¿Sobre precios?
Covarianza antiimagen	¿Sobre delincuencia, asaltos y robos?	.503	-.273	-.115	-.078	.030	-.126	.042	.090	.065
	¿Sobre sueldos?	.052	-.100	-.185	.039	-.112	-.045	-.109	.069	.103
	¿Sobre derechos humanos?	-.273	.557	.144	.010	.002	-.064	-.041	.032	-.120
	¿Sobre empleo?	-.115	.144	.546	-.031	-.117	.058	-.090	-.073	-.098
	¿Sobre terrorismo?	-.078	.010	-.031	.613	.046	-.279	-.024	.014	-.048
	¿Sobre vivienda?	.030	.002	-.117	.046	.491	-.009	-.211	.080	-.021
	¿Sobre medidas para combatir las protestas?	-.126	-.064	.058	-.279	-.009	.532	-.055	-.024	.001
	¿Sobre pobreza?	.042	-.041	-.090	-.024	-.211	-.055	.495	-.098	-.019
	¿Sobre educación?	.090	.032	-.073	.014	.080	-.024	-.098	.814	-.237
	¿Sobre precios?	.065	-.120	-.098	-.048	-.021	.001	-.019	-.237	.838
Correlación antiimagen	¿Sobre delincuencia, asaltos y robos?	.651 ^a	-.156	-.220	-.141	.061	-.244	.084	.141	.100
	¿Sobre sueldos?	.100	-.181	-.341	.069	-.217	-.084	-.210	.104	.153
	¿Sobre derechos humanos?	-.516	.618 ^a	.261	.017	.005	-.117	-.078	.048	-.175
	¿Sobre empleo?	-.220	.261	.703 ^a	-.054	-.225	.107	-.173	-.109	-.145
	¿Sobre terrorismo?	-.141	.017	-.054	.691 ^a	.084	-.489	-.043	.020	-.067
	¿Sobre vivienda?	.061	.005	-.225	.084	.763 ^a	-.017	-.428	.127	-.032
	¿Sobre medidas para combatir las protestas?	-.244	-.117	.107	-.489	-.017	.704 ^a	-.106	-.037	.002
	¿Sobre pobreza?	.084	-.078	-.173	-.043	-.428	-.106	.754 ^a	-.154	-.029
	¿Sobre educación?	.141	.048	-.109	.020	.127	-.037	-.154	.554 ^a	-.288
	¿Sobre precios?	.100	-.175	-.145	-.067	-.032	.002	-.029	-.288	.471 ^a

^a Medida de adecuación muestral.

Tabla 3-13 Matriz antiimagen sin la variable *alza de precios*

Matrices antiimagen										
	¿Sobre delincuencia, asaltos y robos?	¿Sobre sueldos?	¿Sobre derechos humanos?	¿Sobre empleo?	¿Sobre terrorismo?	¿Sobre vivienda?	¿Sobre medidas para combatir las protestas?	¿Sobre pobreza?	¿Sobre educación?	
Antiimagen de la covarianza	¿Sobre delincuencia, asaltos y robos?	.508	4.598E-02	-.275	-.111	-.076	3.226E-02	-.128	4.374E-02	.120
	¿Sobre sueldos?	4.598E-02	.554	-8.973E-02	-.181	4.664E-02	-.112	-4.656E-02	-.109	.109
	¿Sobre derechos humanos?	-.275	-8.973E-02	.574	.137	2.897E-03	-5.917E-04	-6.534E-02	-4.531E-02	-.1992E-03
	¿Sobre empleo?	-.111	-.181	.137	.558	-.038	-.122	5.926E-02	-9.444E-02	-.112
	¿Sobre terrorismo?	-7.582E-02	4.664E-02	2.897E-03	-3.769E-02	.616	4.522E-02	-.281	-2.488E-02	7.711E-04
	¿Sobre vivienda?	3.226E-02	-.112	-5.917E-04	-.122	4.522E-02	.491	-8.791E-03	-.212	8.136E-02
	¿Sobre medidas para combatir las protestas?	-.128	-4.656E-02	-6.534E-02	5.926E-02	-.281	-8.791E-03	.532	-5.458E-02	-2.596E-02
	¿Sobre pobreza?	4.374E-02	-.109	-4.531E-02	-9.444E-02	-.025	-.212	-5.458E-02	.496	-.113
	¿Sobre educación?	.120	.109	-1.992E-03	-.112	7.711E-04	8.136E-02	-2.596E-02	-.113	.887
Antiimagen de la correlación	¿Sobre delincuencia, asaltos y robos?	.657 ^a	8.665E-02	-.509	-.209	-.136	6.457E-02	-.245	8.717E-02	.178
	¿Sobre sueldos?	8.665E-02	.770 ^a	-.159	-.326	7.983E-02	-.215	-8.577E-02	-.208	.156
	¿Sobre derechos humanos?	-.509	-.159	.649 ^a	.242	4.871E-03	-1.114E-03	-.118	-8.491E-02	-2.790E-03
	¿Sobre empleo?	-.209	-.326	.242	.714 ^a	-.064	-.232	.109	-.180	-.159
	¿Sobre terrorismo?	-.136	7.983E-02	4.871E-03	-6.433E-02	.691 ^a	8.219E-02	-.490	-4.504E-02	1.043E-03
	¿Sobre vivienda?	6.457E-02	-.215	-1.114E-03	-.232	8.219E-02	.762 ^a	-1.720E-02	-.430	.123
	¿Sobre medidas para combatir las protestas?	-.245	-8.577E-02	-.118	109	-.490	-1.720E-02	.702 ^a	-.106	-3.780E-02
	¿Sobre pobreza?	8.717E-02	-.208	-8.491E-02	-.180	-.045	-.430	-.106	.757 ^a	-.170
	¿Sobre educación?	.178	.156	-2.790E-03	-.159	1.043E-03	.123	-3.780E-02	-.170	.455 ^a

^a Medidas de la adecuación de la muestra (MSA, por sus siglas en inglés).

Todavía existe la variable *educación* con un valor de *MASi* menor a 0.5 por lo que se quitará del análisis, este proceso sigue hasta que todas las variables tengan un *MASi* superior a 0.5, el resultado de eliminar la variable *educación* se muestra la tabla 3-13 de la página anterior.

Como se observa el *KMO* aumentó de 0.709 a 0.723, la *sig.* = 0.000 todavía es menor a 0.05, por lo que llevar a cabo la técnica de factores tiene sentido; nuevamente se revisa la matriz antiimagen para analizar los valores del *MASi* (tablas 3-14 y 3-15).

Tabla 3-14 Muestra el *KMO* sin la variable *educación*

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.723
Prueba de esfericidad de Bartlett	Ji cuadrada	411.029
	df	28
	Sig.	.000

Como ninguna variable tiene un *MASi* menor a 0.5, se procede con el análisis.

La fórmula para obtener la adecuación individual es:

Fórmula 3-4 Ecuación para obtener la adecuación individual

$$MSA_j = \frac{\sum_{h \neq j} r^2 j_h}{\sum_{h \neq j} r^2 j_h + \sum_{h \neq j} a^2 j_h}$$

3.5.4 Seleccionar el modelo de factores

La técnica de factores puede utilizarse en un análisis confirmatorio o exploratorio. El modelo de componentes principales¹⁰ es útil si el objetivo es confirmar una teoría o hipótesis previamente establecida, lo que se llamará *confirmatorio* y el modelo de factor común se enfoca a un análisis de tipo exploratorio, pues se desea estudiar dentro del conjunto de datos esa estructura latente que hace que las variables muestren interrelación. Hay otros modelos como:

- **Centroide.** Fue desarrollado por Thurstone, quien realizó una estimación matemática más sencilla del modelo de componentes principales, este método era más utilizado cuando no se tenía un software estadístico.
- **Máxima verosimilitud.** Obtiene factores que explican tanta varianza como sea posible en la matriz de correlaciones de la población, como estimaciones de la matriz de correlación de la muestra.
- **Ejes principales.** Es parecido al método de componentes principales que se explicará más adelante, sólo que este método no tiene unos en la diagonal de la matriz de correlación, pues las communalidades son estimadas.

Existen más modelos diferentes a los aquí presentados, pero éstos son los más comunes.

Para explicar estos modelos se debe recordar que al estandarizar las variables, la varianza de cada una de ellas es 1. Como ya se mencionó, el análisis de factores busca aspectos comunes entre variables para agruparlas y la dispersión o variación de los datos indica posibles similitudes entre las variables; el análisis de factores conceptualiza la variación de cada variable como se indica a continuación:

Ecuación 3-5 Ecuación que muestra los tipos de variación en los que se descompone la variación total de las variables

$$Var\ Total = Var\ Común + Var\ Específica + Var\ Aleatoria$$

¹⁰ El modelo de componentes principales requiere muchos cálculos matemáticos, lo que consume mucho tiempo, pero en la actualidad es el más utilizado.

Tabla 3-15 Matriz antiimagen sin la variable *educación*

Antiimagen de la covarianza	¿Sobre delincuencia, asaltos y robos?	¿Sobre sueldos?	¿Sobre derechos humanos?	¿Sobre empleo?	¿Sobre terrorismo?	¿Sobre vivienda?	¿Sobre medidas para combatir las protestas?	¿Sobre pobreza?
	¿Sobre delincuencia, asaltos y robos?	.525	-.284	-.102	-.078	2.234E-02	-.128	6.268E-02
	¿Sobre sueldos?	.568	-9.170E-02	-.176	4.770E-02	-.127	-4.451E-02	-.100
	¿Sobre derechos humanos?	-9.170E-02	.574	.140	2.898E-03	-4.154E-04	-6.549E-02	-4.692E-02
	¿Sobre empleo?	-.176	.140	.572	-.039	-.116	5.752E-02	-.115
	¿Sobre terrorismo?	4.770E-0	2.898E-03	-3.858E-02	.616	4.584E-02	-.281	-2.552E-02
	¿Sobre vivienda?	-.127	-4.154E-04	-.116	4.584E-02	.499	-6.518E-03	-.211
	¿Sobre medidas para combatir las protestas?	-4.451E-02	-6.549E-02	5.752E-02	-.281	-6.518E-03	.532	-5.970E-02
	¿Sobre pobreza?	-.100	-4.692E-02	-.115	-.026	-.211	-5.970E-02	.510
Antiimagen de la correlación	¿Sobre delincuencia, asaltos y robos?	6.063E-02	-.517	-.186	-.138	4.366E-02	-.243	.121
	¿Sobre sueldos?	.794 ^a	-.161	-.309	6.066E-02	-.238	-8.093E-02	-.187
	¿Sobre derechos humanos?	-.161	.636 ^a	.245	4.874E-03	-7.758E-04	-.118	-8.665E-02
	¿Sobre empleo?	-.309	.245	.735 ^a	-.065	-.217	.104	-.213
	¿Sobre terrorismo?	8.066E-02	4.874E-03	-6.500E-02	.689 ^a	8.270E-02	-.491	-4.553E-02
	¿Sobre vivienda?	-.238	-7.758E-04	-.217	8.270E-02	.776 ^a	-1.265E-02	-.418
	¿Sobre medidas para combatir las protestas?	-8.093E-02	-.118	.104	-.491	-1.265E-02	.703 ^a	-.115
	¿Sobre pobreza?	-.187	-8.665E-02	-.213	-.046	-.418	-.115	.768 ^a

^a Medidas de la adecuación de la muestra (MSA).

Donde:

Var Total = es la variación total e indica la variación o dispersión de la variable. Cuando las variables están estandarizadas, el valor de esta variación es de 1.

Var Común = es la variación común y representa la variación que hace parecidas a las variables y es lo que las une.

Var Específica = es la variación específica, es la que hace diferentes y únicas a las variables, por lo que dicha variación separa a las variables.

Var Aleatorias = es la variación aleatoria y representa el error o el azar; se asume su presencia, pero en virtud de que no se puede cuantificar o calcular se le considera como mínimo su efecto.

3.5.4.1 Componentes principales

Este modelo asume que la variación específica es tan pequeña que la considera como cero y desprecia la variación aleatoria. Por tanto, la variación total se considera igual a la variación común.

$$Var Total = Var Común + \underbrace{Var Específica + Var Aleatoria}_{\text{Es cero}}$$

$$Var Total = Var Común$$

Esto significa que el máximo valor que puede tener la variación común es 1.¹¹ En un análisis de tipo confirmatorio se supone que el factor está formado de una combinación lineal de las variables originales.

Ecuación 3-6 Ecuación de componentes principales

$$F_{1j} = U_1X_{1j} + U_2X_{2j} + U_3X_{3j} + \dots + A_kX_{kj}$$

Donde:

F = es el factor 1 de la observación j .

U = representa la importancia o peso relativo que cada variable estandarizada tiene con respecto al factor encontrado.

X = es la variable.

j = es el número de la observación.

k = es el número de variable.

Así toda la información contenida en las variables que se analizan, nada es específico, todo es variación común.

3.5.4.2 Factor común

En este modelo se asume que la variación específica es importante y que por lo tanto se deberá calcular y eliminar del modelo de variación para que con el resto se intente agrupar a las variables.

$$Var Total - Var Específica = Var Común + \underbrace{Var Específica - Var Específica}_{\text{Se elimina}} + \underbrace{Var Aleatoria}_{\text{Es cero}}$$

$$Var Total - Var Específica = Var Común$$

Esto significa que el máximo valor que puede tener la variación común es menor a 1,¹² pero si la variación específica es cero entonces puede llegar a valer 1.

¹¹ Las variables fueron estandarizadas.

¹² Las variables fueron estandarizadas.

En un análisis de tipo exploratorio se supone que las variables comparten algo que es común del grupo y una parte de ellas es específico o propio, esta última se elimina y sólo se trabaja con la parte común.

Ecuación 3-7 Forma conceptual en la que se asume que están formados los datos de cualquiera de las variables

$$X_{ij} = U_{1ij}F_1 + U_{2ij}F_2 + U_{3ij}F_3 + \cdots + U_{mij}F_m + e_{ij}$$

Ecuación 3-8 Forma conceptual en la que se asume están formados los datos de las variables independientes

$$\begin{aligned} X_{1j} &= U_{11j}F_1 + U_{21j}F_2 + U_{31j}F_3 + \cdots + U_{m1j}F_m + e_{1j} \\ X_{2j} &= U_{12j}F_1 + U_{22j}F_2 + U_{32j}F_3 + \cdots + U_{m2j}F_m + e_{2j} \\ X_{pj} &= U_{1pj}F_1 + U_{2pj}F_2 + U_{3pj}F_3 + \cdots + U_{mpj}F_m + e_{pj} \end{aligned}$$

Donde:

F = son los factores comunes.

U = representa la importancia o peso relativo que cada variable estandarizada tiene con respecto al factor encontrado.

X = es la variable i de la observación j .

i = es el número de variables.

j = es el número de observación.

m = es el número máximo de factores.

p = es el número máximo de variables.

e = son los factores únicos o específicos.

Para seguir con la técnica de análisis de factores se deberá seleccionar alguno de estos dos modelos, la mayoría de los paquetes estadísticos contienen, de forma preestablecida, el de componente (incluyendo el SPSS™).

3.5.5 Descomposición espectral, singular o única

Una vez que se ha escogido el modelo, a la matriz de correlación, que es la entrada de esta técnica, se le aplica un procedimiento matemático llamado *descomposición espectral* o *singular*; se recomienda ver el anexo 3-2 “Descomposición espectral”, ya que aquí sólo se proporcionará la definición y los pasos de dicho procedimiento.

Definición:

Sea A una matriz cuadrada, entonces la expresión:

$$A - \lambda I$$

Donde:

A = es la matriz característica.

λ = son los valores propios (*eigenvalues* o *eigenvalores*) de la matriz A .

I = es la matriz identidad.

3.5.5.1 Pasos

Los pasos que deben seguirse en la descomposición espectral son los siguientes:

1. Se calculan los valores propios para cualquier matriz cuadrada A , ésta tendrá un valor de λ que satisface la siguiente expresión:

$$|A - \lambda I| = 0$$

es decir el determinante de la matriz característica de A es igual a cero. Y existirá más de un eigen-vector dependiendo del rango de la matriz A . Si se hace $A = R$, donde R es la matriz de correlación:

$$|R - \lambda I| = 0$$

entonces a la matriz de correlación se le extraerán los eigenvalores y el número de éstos depende de las dimensiones de la matriz y de cuántas variables¹³ se tienen en el análisis.

- Se calcula para cada valor propio su vector propio (eigenvector): si ν representa los vectores propios (eigenvectores) de A y además son aquellos que satisfacen la siguiente ecuación:

$$(A - \lambda I)\nu = 0$$

Para este caso $A = R$, entonces los eigenvectores a extraer serán los que satisfacen la ecuación siguiente:

$$(R - \lambda I)\nu = 0$$

Volviendo al ejemplo, en el análisis se tenían 10 variables, pero dos fueron eliminadas por el criterio del *MASi*, por lo que la matriz de correlación sería de 8×8 , así se extraerían 8 eigenvalores, los cuales se presentan en la siguiente tabla que resulta de procesar mediante el paquete estadístico SPSS™:

Tabla 3-16 Variación total explicada que muestra los eigenvalores

Variación total explicada						
Componentes	Eigenvalores iniciales			Sumas de extracción de las cargas al cuadrado		
	Total	% de variación	% de acumulación	Total	% de variación	% de acumulación
1	2.662	33.276	33.276	2.662	33.276	33.276
2	2.419	30.239	63.515	2.419	30.239	63.515
3	.829	10.367	73.882	.829	10.367	73.882
4	.584	7.302	81.184	.584	7.302	81.184
5	.472	5.894	87.078	.472	5.894	87.078
6	.380	4.747	91.826	.380	4.747	91.826
7	.355	4.432	96.257	.355	4.432	96.257
8	.299	3.743	100.000	.299	3.743	100.000

Los 8 eigenvalores

Método de extracción: análisis de componentes principales.

Y como a cada eigenvalor le corresponde un eigenvector se tendrían 8 eigenvectores, los cuales se presentan en la siguiente tabla generada por el SPSS™:

Tabla 3-17 Matriz no rotada con 8 dimensiones

Matriz de componentes ^a								
	Componente							
	1	2	3	4	5	6	7	8
¿Sobre delincuencia, asaltos y robos?	.158	.798	.284	.329	.184	-.143	.032	-.308
¿Sobre sueldos?	.794	-.119	.164	.015	-.552	.030	.043	-.147
¿Sobre derechos humanos?	.180	.723	.549	-.143	.009	.228	-.004	.266
¿Sobre empleo?	.743	-.243	-.114	.547	.083	.033	-.115	.236
¿Sobre terrorismo?	.159	.715	-.551	.027	-.023	.330	.192	-.047
¿Sobre vivienda?	.803	-.259	.039	-.192	.228	-.161	.411	.053
¿Sobre medidas para combatir las protestas?	.282	.770	-.296	-.170	-.121	-.387	-.153	.155
¿Sobre pobreza?	.821	-.126	-.059	-.300	.243	-.146	-.330	-.167

El eigenvector que le corresponde al primer eigenvalor de 2.662

El eigenvector que le corresponde al último eigenvalor de 0.299

Análisis del método de extracción del componente principal.

^a 8 componentes extraídos.

¹³ Es decir, si se tienen 20 variables, la matriz de correlación será de dimensiones de 20×20 por lo que se extraerán 20 eigenvalores o valores propios.

Como el objetivo de la técnica es resumir o reducir variables o dimensiones, esto no sería lo deseable para una solución con la técnica, resumir o reducir indica que entraron 8 variables y deben salir menos de 8 factores o componentes.

3.5.6 Seleccionar un criterio para determinar qué características deberán estar presentes en los factores

Los factores a obtener mediante la aplicación de la técnica podrían presentar relación o no entre sí. La decisión de obtener factores independientes (no tienen relación) o dependientes (sí se relacionan) se hará seleccionando alguno de los siguientes criterios:

- A. **Ortogonal.** Con este criterio los factores se extraen de tal manera que los ángulos entre ellos serán de 90° y con ello las características que se encuentran son independientes, esto es, los factores tienen una relación igual a cero.
- B. **Oblicuo.** Los ejes de los factores pueden tomar cualquier posición y se obtienen características con cierto grado de relación entre sí.

Si se representan gráficamente los factores de estos dos criterios se tiene lo siguiente:

Cuando la relación entre los factores es de cero (son independientes), el ángulo entre ellos es de 90° ; entonces, los factores que se obtengan a través del criterio ortogonal se representan así:




Figura 3-15 Factores o componentes ortogonales.

Cuando la relación entre los factores es diferente a cero (sí hay relación) y los ejes (factores) están acercándose para apuntar en dirección opuesta se dice que tienen una *relación positiva*. Mientras que, si se están alejando los ejes (factores) para apuntar a diferente dirección se dice que tienen una *relación negativa*. Ambas relaciones indican dependencia entre factores y sería el resultado de aplicar el criterio oblicuo, lo cual se representa gráficamente en las figuras 3-16 y 3-17.




Figura 3-16 Factores oblicuos.




Figura 3-17 Factores oblicuos.

3.5.7 Obtener una matriz de factores no rotada

Matriz no rotada.
Resultado de la descomposición espectral que muestra los eigenvectores correspondientes.

La **matriz no rotada** es el resultado de la descomposición espectral y muestra los eigenvectores correspondientes. Cada elemento en lo individual es llamado *carga de factor* y es interpretado como el grado de relación entre cada variable y el factor correspondiente. En esta matriz casi todas las cargas resultan altas y por ello no es posible agrupar a las variables, solamente es utilizada para determinar el número de factores en los que quedarán agrupadas las variables de manera tentativa.

Es importante mencionar que el primer factor es el que alcanza a tener la mayor cantidad de información captada de las variables y que cada factor que se agrega a la solución en la matriz no rotada recaba una cantidad menor de información del conjunto de variables.

En este paso sólo se establece de manera inicial o tentativa en cuántos factores quedarán agrupadas las variables, pero no es una solución final en la que se decide qué factor agrupa a qué variable.

3.5.7.1 Conceptos

Para un mejor entendimiento de lo que se tratará es conveniente dejar claros algunos conceptos:

Carga del factor.
Término que indica el grado de relación que llegan a tener cada una de las variables con cada uno de los factores.

La **carga del factor** es el término que indica el grado de relación que llegan a tener cada una de las variables con cada uno de los factores; es una medida de correlación entre la variable y el factor. Por otra parte, a todo el conjunto de cargas de un solo factor se le llama *eigenvector*.

A continuación se presenta la matriz no rotada para ubicar la carga de factor.

Tabla 3-18 Matriz no rotada

	Matriz de componentes ^a							
	Componente							
	1	2	3	4	5	6	7	8
¿Sobre delincuencia, asaltos y robos?	.158	.798	.284	.329	.184	-.143	.032	-.308
¿Sobre sueldos?	.794	-.119	.164	.015	-.552	.030	.043	-.147
¿Sobre derechos humanos?	.180	.723	.549	-.143	.009	.228	-.004	.266
¿Sobre empleo?	.743	-.243	-.114	.547	.083	.033	-.115	.236
¿Sobre terrorismo?	.159	.715	-.551	.027	-.023	.330	.192	-.047
¿Sobre vivienda?	.803	-.259	.039	-.192	.228	-.161	.411	.053
¿Sobre medidas para combatir las protestas?	.282	.770	-.296	-.170	-.121	-.387	-.153	.155
¿Sobre pobreza?	.821	-.126	-.059	-.300	.243	-.146	-.330	-.167

Método de extracción: análisis de componentes principales.

^a 8 componentes extraídos.

Por lo que todos los números que aparecen en la tabla son cargas de factor; por ejemplo, la variable *sobre sueldos* tiene una relación de 0.794 con el factor (o componente) 1.

Con el término **eigenvalor** se denomina a la variación o cantidad de información que cada uno de los factores logra captar del conjunto de variables.

Para calcular el eigenvalor de cada factor, cada carga en la matriz no rotada se eleva al cuadrado y se suma para cada factor. Los eigenvalores de cada factor aparecen en la tabla de la variación total, la cual se muestra a continuación:

Eigenvalor. Variación o cantidad de información que cada uno de los factores logra captar del conjunto de variables.

Tabla 3-19 Variación total explicada

Variación total explicada						
Componente	Eigenvalores iniciales			Sumas de extracción de las cargas al cuadrado		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	2.662	33.276	33.276	2.662	33.276	33.276
2	2.419	30.239	63.515	2.419	30.239	63.515
3	.829	10.367	73.882	.829	10.367	73.882
4	.584	7.302	81.184	.584	7.302	81.184
5	.472	5.894	87.078	.472	5.894	87.078
6	.380	4.747	91.826	.380	4.747	91.826
7	.355	4.432	96.257	.355	4.432	96.257
8	.299	3.743	100.000	.299	3.743	100.000

Los 8 eigenvalores

Método de extracción: análisis de componentes principales.

- **Porcentaje de variación explicada (PVE):** es la relación entre la variación explicada por el factor con respecto a la variación total (VT) manejada por el conjunto de variables. Como en el análisis todas las variables fueron estandarizadas, cada una tiene una variación de 1, la suma de esas variaciones da el número de variables en el estudio, por lo que la variación total es igual a dicha suma; entonces, la mayor variación que se puede llegar a explicar es igual al número de variables, por lo que la fórmula para calcular ésta sería la siguiente:

Porcentaje de variación explicada. Relación entre la variación explicada por el factor con respecto a la variación total manejada por el conjunto de variables.

Ecuación 3-9 Porcentaje de variación explicada por factor

$$PVE_i = \frac{\lambda_i}{VT} * 100$$

Donde:

PVE_i = es el porcentaje de variación explicada del componente o factor i .

λ_i = es el eigenvalor de la observación i .

VT = es la variación total o el número de variables en el análisis.¹⁴

A mayor porcentaje de varianza el factor logró captar una mayor cantidad de información de las variables. Los porcentajes de varianza se muestran a continuación:

Tabla 3-20 Se muestra el porcentaje de variación que cada componente o factor logró captar de todas las variables

Variación total explicada						
Componente	Eigenvalores iniciales			Sumas de extracción de las cargas al cuadrado		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	2.662	33.276	33.276	2.662	33.276	33.276
2	2.419	30.239	63.515	2.419	30.239	63.515
3	.829	10.367	73.882	.829	10.367	73.882
4	.584	7.302	81.184	.584	7.302	81.184
5	.472	5.894	87.078	.472	5.894	87.078
6	.380	4.747	91.826	.380	4.747	91.826
7	.355	4.432	96.257	.355	4.432	96.257
8	.299	3.743	100.000	.299	3.743	100.000

Porcentaje de variación explicada

Método de extracción: análisis de componentes principales.

¹⁴ Siempre y cuando las variables originales del análisis hayan sido estandarizadas.

Comunalidad. Variación explicada por el conjunto de factores para cada variable.

- **Comunalidad.** Este término es la variación explicada por el conjunto de factores para cada variable.

Como ya se dijo, la variación de cada variable estandarizada es de 1, por lo tanto el valor máximo de información que se puede manejar por cada variable, o sea el valor máximo posible de la comunalidad, es de 1. Mientras más se aproxime el valor de la comunalidad a 1, más información se tiene en los factores de la variable.

El valor de la comunalidad se obtiene al elevar al cuadrado cada carga en la matriz no rotada y se le suma cada variable. A continuación se muestra la tabla de comunalidades:

Tabla 3-21 Comunalidades

Comunalidades		
	Inicial	Extracción
¿Sobre delincuencia, asaltos y robos?	1.000	.672
¿Sobre sueldos?	1.000	.620
¿Sobre derechos humanos?	1.000	.560
¿Sobre empleo?	1.000	.621
¿Sobre terrorismo?	1.000	.515
¿Sobre vivienda?	1.000	.697
¿Sobre medidas para combatir las protestas?	1.000	.655
¿Sobre pobreza?	1.000	.698
¿Sobre educación?	1.000	.078
¿Sobre alza de precios?	1.000	.023

Método de extracción: análisis de componentes principales.

La tabla anterior indica que la variación inicial que tiene cada variable es de 1 y la columna de extracción indica la variación que se logró captar por los factores que se tienen en la matriz no rotada.

Una vez aclarados estos términos se debe recordar que el análisis de factores genera una respuesta que hasta cierto punto puede considerarse subjetiva. Se iniciará ahora el estudio de los primeros criterios, los cuales ayudarán a determinar el número de factores como posible solución inicial.

3.5.7.2 Criterios para la determinación del número de factores a ser extraídos como solución inicial

La aplicación de alguno de los siguientes criterios deberá hacerse en la información reportada por la matriz no rotada y como guía para determinar una primera solución al problema. La solución definitiva no necesariamente será la obtenida por el grado de los criterios a mencionar; ésta se conocerá al analizar soluciones con uno o dos factores más o menos al número de factores obtenidos en la solución inicial. Aquella solución que agrupe lógicamente a las variables será la definitiva.

Los criterios para determinar el número de factores como solución inicial son los siguientes:

- **Criterio a priori.** Se utiliza en aquellos casos donde el investigador desea probar alguna teoría o hipótesis y de antemano conoce cuántos factores se deben tener en la solución; el investigador decide el número de factores a pedir con base en su hipótesis. Se recomienda si se usa la técnica de análisis de factores para un análisis confirmatorio.

De acuerdo con el ejemplo, en el punto 3.5 de este capítulo se dijo que se proponían 2 objetivos,¹⁵ por lo que la posible solución es de sólo 2 factores, según este criterio.

- **Criterio de raíz latente.** En éste se pueden tomar en cuenta 2 consideraciones: en caso de que los datos no estén estandarizados, la idea es retener a los factores cuya raíz característica exceda la

¹⁵ Objetivo 1: medir las condiciones de seguridad que prevalecen en el país y objetivo 2: medir las condiciones económicas que prevalecen en el país.

media de las raíces características. La **raíz característica** es la variación explicada por cada factor. Cuando los datos están estandarizados se considera que un factor debe ser retenido en la solución si su raíz característica es mayor a 1. Debido a que los eigenvalores o *raíces características* representan las varianzas y las varianzas de las variables estandarizadas son igual a 1, un factor con un eigenvalor menor a 1 no es importante o se considera que no tiene la cantidad de información significativa captada; lo lógico es mantener a los factores que tengan mayor información (varianza) que cualquiera de las originales. Se recomienda este criterio si el objetivo del análisis de factores es para un análisis exploratorio. Este criterio es usado por la mayoría de los paquetes computacionales cuando no se les especifica un cierto número de factores en la solución.

Raíz característica.
Variación explicada por cada factor.

Con la tabla generada por el SPSS™ se puede observar que bajo el criterio de raíz latente el número tentativo de factores a retener en la solución es de 2, pues son sólo las 2 primeras componentes las que alcanzan un eigenvalor mayor a 1.

Tabla 3-22 Tabla eigenvalores

Variación total analizada						
Componente	Eigenvalores iniciales			Sumas de extracción de las cargas al cuadrado		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	2.662	33.276	33.276	2.662	33.276	33.276
2	2.419	30.239	63.515	2.419	30.239	63.515
3	.829	10.367	73.882	.829	10.367	73.882
4	.584	7.302	81.184	.584	7.302	81.184
5	.472	5.894	87.078	.472	5.894	87.078
6	.380	4.747	91.826	.380	4.747	91.826
7	.355	4.432	96.257	.355	4.432	96.257
8	.299	3.743	100.000	.299	3.743	100.000

2 factores

Método de extracción: análisis de componentes principales.

- *Criterio del porcentaje de variación explicada acumulada.* Mediante este criterio se considera que “n” factores deben manejarse como solución inicial, si el porcentaje de variación explicada acumulada se encuentra en un rango de entre 60 y 95%. Es decir, a través de este criterio se está dispuesto a perder cuando mucho 40% y cuando menos 5% de información.

En la tabla del SPSS™ se puede observar que el número inicial de factores está en un rango de 2 a 6 factores, pues son los que se encuentran dentro de 60 y 95% del porcentaje de variación explicada acumulada.

Tabla 3-23 Tabla eigenvalores

Variación total analizada						
Componente	Eigenvalores iniciales			Sumas de extracción de las cargas al cuadrado		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	2.662	33.276	33.276	2.662	33.276	33.276
2	2.419	30.239	63.515	2.419	30.239	63.515
3	.829	10.367	73.882	.829	10.367	73.882
4	.584	7.302	81.184	.584	7.302	81.184
5	.472	5.894	87.078	.472	5.894	87.078
6	.380	4.747	91.826	.380	4.747	91.826
7	.355	4.432	96.257	.355	4.432	96.257
8	.299	3.743	100.000	.299	3.743	100.000

De 2 a 6 factores

Método de extracción: análisis de componentes principales.

- *Criterio scree test.* Fue desarrollado por el psicólogo británico Raymond Bernard Cattell; *scree* es un término utilizado en geología, es el escombros al final de un precipicio. La idea en el *scree test* es que si los factores son importantes tendrán una varianza grande. Al extraer los factores, el prime-

ro contabiliza la mayor variación, el segundo que se extrae tiene menor variación que el primero y así sucesivamente. En virtud de esta manera natural en que se extraen, para la aplicación de este criterio se realiza una gráfica en la que se ubica el número del factor en el eje de las x y los valores de las varianzas o los eigenvalores en el eje de las y . Al unir estos puntos se obtiene una figura que es similar al perfil de una montaña con una pendiente fuerte hasta llegar a la base, formada por una meseta con una ligera inclinación. En esta meseta es donde se acumula el escombros tirado desde la cumbre, es decir, donde se sedimenta. La idea es quedarse con los factores previos a la zona de sedimentación.

A diferencia del criterio de raíz latente en el que se pedía que la variación explicada fuera mayor a 1 (eigenvalor mayor a 1) para aceptar a un nuevo factor en la solución; este criterio podría dar como resultado soluciones con 1 o 2 factores más que la raíz latente.

La gráfica de sedimentación o *scree plot*, como se conoce en inglés, es la siguiente:




Figura 3-18 Gráfica de sedimentación o *scree plot*.

Si se sigue con el criterio antes explicado en este estudio quedarían 3 factores, pues es el punto en donde las variaciones (eigenvalores) se empiezan a sedimentar; también se puede trazar una línea recta, donde ésta se despega de la original allí termina el sedimento, lo cual se muestra en la siguiente figura con la línea discontinua, la flecha en gris indica el número de factores a retener como posible solución:




Figura 3-19 Señala el criterio de sedimentación o *scree test*.

Éstos son los cuatro criterios que ayudan a determinar el número de factores a manejar en una solución inicial del análisis de factores. Después del análisis de la matriz no rotada se tendrá que hacer el análisis de la matriz rotada, el cual se explica a continuación.

3.5.8 Obtención de la matriz de factores rotada

La matriz de factores rotada, al igual que la no rotada, se genera por computadora y contiene información referente al grado de explicación de las variables por los factores, es decir, las cargas de factores, pero ahora serán las definitivas las que permitirán determinar la agrupación de las variables en dichos factores, se busca obtener así una solución final lógica.

Mediante este proceso se ajustan los ejes coordenados o *ejes factores* con el fin de obtener una solución más sencilla y con mayor significado teórico; esto es, hacer que una de las cargas de la variable sea lo más alta posible para que se identifique con un solo factor, mientras que sus demás cargas sean bajas, de manera que pierda su relación con otros factores.

Al rotar los factores las cargas cambian en virtud de la nueva posición de los ejes, es decir, cambia el valor de los eigenvalores para cada factor, pero la variación explicada total y las communalidades no cambian, a menos que se eliminen o agreguen factores. Entonces, al rotar, no se explica mayor o menor información; la variación total se mantiene, así como las communalidades.

Gráficamente, lo que se trata de hacer al rotar los factores es que los ejes se acerquen a las variables y queden lo más cerca posible a éstos y que las variables se agrupen bajo una sola característica, lo cual sería la mejor solución.

Un ejemplo de la rotación¹⁶ sería que se tienen 5 variables, las cuales se han agrupado como solución inicial en 2 factores; a continuación se presentan la matriz no rotada y la rotada para estas variables:

Tabla 3-24 Matriz no rotada y rotada

Matriz no rotada			Matriz rotada		
	F1	F2		F1	F2
V1	0.01	0.95	V1	-0.02	0.95
V2	0.2	0.9	V2	-0.151	0.91
V3	0.95	-0.3	V3	0.98	0.18
V4	0.8	-0.2	V4	0.82	0.1
V5	0.72	-0.15	V5	0.73	0.1

Para graficar, generalmente se usa el eje X para el factor 1 y el eje Y para el factor 2, aunque puede ser al revés; esto se muestra a continuación:




Figura 3-20 Gráfica de los factores o componentes.

¹⁶ Se usará un ejemplo con menos variables y con sólo 2 dimensiones o factores, debido a la complejidad del tema.

Posteriormente se obtiene la gráfica de la matriz no rotada; para poder ver en qué coordenada se encuentra cada variable se toman las cargas de dicha matriz y se localizan en la gráfica, la cual quedaría de la siguiente manera:




Figura 3-21 Gráfica de la matriz no rotada.

A continuación se dejan fijas las variables, es decir, los puntos y se rotan los ejes para cualquier lado, como se muestra a continuación:




Figura 3-22 Modos en que se puede rotar.

Posteriormente al rotar los ejes se obtiene la matriz rotada, ésta se muestra en la siguiente figura:




Figura 3-23 Gráfica de la matriz rotada.

Ahora se buscan las nuevas coordenadas en las cuales quedaron las variables, éstas serían las cargas de la matriz rotada; el procedimiento se muestra a continuación:




Figura 3-24 En busca de las coordenadas o cargas de las variables.

Al graficar en conjunto las 2 se obtiene la siguiente figura, en la cual se puede observar el cambio que se da al realizar la rotación de factores o de ejes:




Figura 3-25 Rotación de factores.

Como se puede observar los factores (F_1 y F_2) giran de manera que la variable 1 y la variable 2 estén lo más cerca posible del eje del factor 2, mientras que las variables 3, 4 y 5 se encuentran más cerca del eje del factor 1. Esto es, las variables han quedado mejor identificadas con el factor 1 y con el factor 2.

Cabe señalar que la gráfica del factor 1 y la del factor 2 guardan entre sí un ángulo de 90 grados, lo cual significa que son independientes; es decir, se obtuvieron a través de la rotación ortogonal.

Si el proceso de la rotación de factores se lleva a cabo de manera manual es de muy alta complejidad, por lo tanto se han creado paquetes computacionales que realizan la rotación de factores, pero para ello es necesario especificar a la computadora el criterio que deberá usar para realizar la rotación de factores.¹⁷ En la siguiente sección se explican estos criterios.

¹⁷ El SPSS™ da una matriz que denomina *matriz de transformaciones de las componentes*, multiplicando la matriz no rotada por ésta da como resultado la matriz de factores rotada.

3.5.8.1 Criterio para la rotación de factores

Entre los métodos de rotación ortogonal están los siguientes:

- *Método varimax*. El término *varimax* proviene de que la *varianza* se *maximiza*. Mediante este criterio se trata de identificar a un grupo de variables con un solo factor, es decir, simplifica por componente o columna; busca la máxima simplificación al generar tantos unos y ceros como le es posible en la matriz. El eigenvalor que es la variación explicada de esta manera se maximiza. Este método de rotación es el más utilizado.
- *Método quartimax*. La rotación de factores tendrá por objetivo identificar a cada variable con al menos uno de los factores, esto es, simplifica por variable o renglón, tratando de que las cargas de la mayoría de los factores sean tan bajas como se pueda y al menos una lo suficientemente alta para considerarse como significativa.
- *Método equamax*. Es una solución intermedia entre las anteriores, la simplificación se hace en forma alternativa, esto es, se simplifica por renglón o por columna indistintamente en la matriz de factores.

Los métodos de rotación oblicua se desglosan a continuación:

- *Método oblimin directo*. Se apoya en la simplificación de los pesos factoriales sobre los factores primarios y no sobre los ejes de referencia.
- *Método promax*. Es un criterio del método varimax en el cual se le permite a los factores relacionarse. Este método es considerado muy eficiente y genera soluciones muy buenas.
- *Método quartimin*. Parte de una hipótesis donde cierto grupo de variables van a identificarse con un factor. Cada grupo de variables tendría una carga cercana a cero en todos los ejes de referencia menos en 1. Los factores extraídos por este método están altamente correlacionados.

Existen otros métodos oblicuos, los cuales sólo se mencionarán y son: binormamin, biquarimin, covarimin, indirect oblimin, maxplane, oblinorm, oblimax, obliquimax, optres, orthoblique, orthotran y tandem.

Las rotaciones oblicuas pueden tener los siguientes problemas:

1. La suma de los cuadrados de las cargas factoriales en cualquiera de los renglones no suele ser igual a la communalidad. En consecuencia las cargas oblicuas no indican claramente la proporción de la varianza para cada variable explicada por los factores.
2. Las correlaciones originales entre variables no pueden ser reproducidas a partir de los productos de las cargas factoriales.
3. Se debe tener mucho cuidado en la explicación de los factores, ya que 2 factores pueden estar superpuestos, lo que traería confusión al tratar de distinguirlos o interpretarlos.

No existe una guía que señale el criterio a emplear;¹⁸ es indistinto, pero es indispensable indicar bajo qué criterio se realizará la rotación de factores.

Una vez generada la matriz rotada es necesario identificar en ella las cargas significativas y con ello con qué factor se ha identificado cada una de las variables. Para esto existen diversos criterios que a continuación se explican.

3.5.8.2 Criterio para la identificación de cargas significativas

Una carga es significativa en función del tamaño de la muestra y el nivel de significancia manejado en la investigación. Se requiere conocer el tamaño de la muestra, ya que conforme va aumentando se tiene una mayor credibilidad o confianza en la información y por lo tanto se puede manejar un límite cada vez menor en la carga de factor, para considerarla significativa. Por el contrario, al manejar un nivel de significancia menor se es más estricto con la confiabilidad del factor, y por lo tanto, se manejará un límite cada vez mayor en la carga del factor para considerarla significativa.

¹⁸ Como ya se señaló, el criterio más utilizado es el varimax.

A continuación se mencionan los criterios para identificar cargas significativas:

1. Cuando el tamaño de la muestra se encuentra entre 50 y 100:
 - Carga altamente significativa es la de ± 0.5 en adelante, lo que quiere decir que valores entre -0.5 y 0.5 no son significativos (prioridad 1).
 - Carga significativa, entre ± 0.4 a ± 0.5 (prioridad 2).
 - Carga significativa, entre ± 0.3 a ± 0.4 (prioridad 3).
 - Si la carga se encuentra entre -0.3 y 0.3 , esto es si la carga es menor a ± 0.3 , se considera que no es carga significativa (prioridad 4).
2. Cuando el tamaño de la muestra se encuentra entre 100 y 200:
 - Para un alfa igual a 5%, la carga significativa es de ± 0.19 en adelante, siempre que se hayan aplicado primero las prioridades 1, 2 y 3 del apartado anterior. Una carga menor a ± 0.19 ya no se considera significativa.
3. Para un alfa igual a 1%, la carga significativa es ± 0.26 en adelante, siempre que se hayan aplicado primero las prioridades del inciso 1.
4. Cuando el tamaño de la muestra se encuentra entre 200 y 300:
 - Para un alfa igual a 5%, la carga significativa es ± 0.14 en adelante, siempre que se hayan aplicado primero las prioridades a, b, c y d del punto 1.
 - Para un alfa igual a 1%, la carga significativa es ± 0.18 en adelante, siempre que se hayan aplicado primero las prioridades a, b, c y d del punto 1.
5. Cuando el tamaño de muestra es mayor o igual a 300:
 - Para un alfa igual a 5%, la carga significativa es ± 0.11 en adelante, siempre que se hayan aplicado primero las prioridades a, b, c y d del punto 1.
 - Para un alfa de 1%, la carga significativa es ± 0.15 en adelante, siempre que se hayan aplicado primero las prioridades a, b, c y d del punto 1.

Éstos son los criterios para las cargas significativas, cuyo objetivo es identificar la variable con el factor. Se tiene la necesidad de identificar la variable con sólo un factor y por eso se establecen las prioridades para que la variable haga uso de la prioridad 1 para colocarse con algún factor, si esto no se logra, se le da oportunidad con la alternativa 2; si aún no lo consigue existe una prioridad 3, hasta llegar al mínimo aceptable para cada caso.

Si existe alguna variable que no tenga carga significativa, es decir, que no se haya identificado con ningún factor, puede deberse a que ésta tiene una variación específica muy alta y es muy particular. Cuando esto sucede se tienen dos alternativas de acción:

1. Se deja la solución tal cual, sin agrupar a esa variable y así se realiza el análisis.
2. Se elimina del banco de datos y se vuelve a correr de nuevo la solución.

Como se mencionó anteriormente, estos criterios de cargas significativas se aplican en la matriz rotada para identificar qué variables van a quedar agrupadas en cada factor. En el siguiente ejemplo se puede observar la aplicación de los criterios.

Supóngase que se tienen 80 encuestas y la siguiente matriz rotada:

Tabla 3-25 Matriz rotada

Matriz de componentes rotados ^a		
	Componente	
	1	2
Ingreso	.810	-.119
Tarjetas	.475	-.024
Edad	.306	.043
Hijos	-.040	.297

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación convergida en 3 iteraciones.

La variable *ingreso* queda en el factor 1, pues al revisar las cargas de factor, la carga que es mayor a ± 0.5 es la de 0.810.

La variable *tarjetas* no tiene cargas mayores a ± 0.5 con la prioridad 2, que es la que menciona como carga significativa aquella entre ± 0.4 y ± 0.5 , por lo que también esta variable queda en el factor 1, pues su carga es 0.475.

La variable *edad* no tiene cargas mayores a ± 0.5 , ni cargas entre ± 0.4 y ± 0.5 , por lo que al seguir con la prioridad 3 (± 0.3 a ± 0.4) la variable queda en el factor 1, pues tiene una carga de 0.306.

Finalmente la variable *hijos* no tiene cargas mayores a ± 0.5 , ni cargas entre ± 0.4 y ± 0.5 , ni cargas mayores a ± 0.3 y ± 0.4 , por lo que esa variable se elimina del estudio, al no tener cargas significativas.

Es importante aclarar que la variable *hijos* se elimina, pues el número de encuestas es de 80, si esta misma matriz se hubiera obtenido de un estudio con más de 100 encuestas y un alfa de 5%, entonces las prioridades se hubieran tomado igual, es decir las tres primeras variables quedarían con el factor 1, en este caso la variable *hijos* sí se hubiera relacionado con un factor, pues una carga ± 0.19 es aceptable, como indica la teoría antes vista y en este caso 0.297 sí cumple con este requisito y se agruparía en el factor 2.

La solución mencionada sería la inicial, pero no necesariamente es la mejor. Hay que analizar si en este caso las variables que quedan bajo cada factor se refieren a un concepto común, si no se puede identificar tal cosa, no sería la mejor solución y se tendrían que probar otras soluciones con más o menos factores, hasta que las variables queden agrupadas de manera lógica, bajo conceptos comunes o afines a cada grupo de variables.

Siguiendo con el ejemplo,¹⁹ la matriz rotada de este estudio es la siguiente, la matriz se corrió con el criterio inicial de raíz latente, donde tentativamente se le pidió agrupar a las variables en 2 factores lo que generó la siguiente información:

Tabla 3-26 Matriz rotada

Matriz de componentes rotados ^a		
	Componente	
	1	2
¿Sobre delincuencia, asaltos y robos?	-.038	.812
¿Sobre sueldos?	.799	.075
¿Sobre derechos humanos?	.002	.745
¿Sobre empleo?	.780	-.058
¿Sobre terrorismo?	-.017	.732
¿Sobre vivienda?	.842	-.059
¿Sobre medidas para combatir las protestas?	.089	.815
¿Sobre pobreza?	.827	.074

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación convergida en 3 iteraciones.

El factor 1 agrupó a las variables *sueldos*, *empleo*, *vivienda* y *pobreza*, por lo que se puede nombrar *factor económico*.

Y el factor 2 agrupó a las variables *delincuencia*, *derechos humanos*, *terrorismo* y *combatir las protestas*, por lo que se pudiera llamar *factor social*.

¹⁹ El objetivo general es sintetizar conceptos globales a partir de temas o aspectos económicos.

En el caso de que una variable se agrupe al mismo tiempo en dos factores, como es el caso de la variable X2, que tiene carga significativa tanto con el factor 1 como con el factor 2, como se puede observar en la tabla siguiente:

Tabla 3-27 Matriz rotada

Matriz de componentes rotados ^a		
	Componente	
	1	2
x1	.849	.138
x2	.591	.695
x3	.819	.075
x4	.114	.907
x5	.634	-.640

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación convergida en 3 iteraciones.

Lo que se tiene que hacer es decidir con cuál de los dos factores dejarla y esto se hace basado en la lógica. Es decir, se observa qué variables se agruparon en un factor y cuáles en el otro y al grupo de variables que más se asemeje la variable que tiene el problema, con ese grupo de variables y en ese factor se queda.

3.5.9 Obtención de puntajes de factores

Esta etapa del análisis de factores sólo es necesaria si los factores encontrados se utilizarán como variables en otros análisis estadísticos.

Se llama **puntajes** a los datos con los que se manejaría cada factor como variable. Los puntajes se pueden obtener a través de tres enfoques:

- preciso,
- aproximado y
- promedio.

Preciso

En el enfoque preciso existen tres criterios para obtener los coeficientes estandarizados que forman ecuaciones lineales para la extracción de los puntajes, dichos criterios son:

- regresión,
- anderson-Rubin y
- Bartlett.

En cualquiera de ellos todas las variables se involucran y consisten en obtener los respectivos puntajes al sustituir los datos estandarizados en la ecuación que define al factor. Dicha ecuación está formada por una combinación lineal de las variables que se manejan en la investigación; entonces, las respuestas de una entrevista se sustituyen en la ecuación y resulta un puntaje del factor. Es decir, habrá tantos puntajes como entrevistas se hayan realizado.

No explicaremos el proceso de obtención de los puntajes de los tres criterios, pero podemos mencionar que el más utilizado es el de Anderson-Rubin debido a que los puntajes que se alcanzan son de variables sin relación (ortogonales) y estandarizados. En el de regresión los puntajes de factores pueden estar correlacionados y en el de Bartlett se aplica el método de máxima verosimilitud, bajo el supuesto de que los factores deben presentar normalidad.

Se presenta un ejemplo de cómo obtener los puntajes de factores al utilizar el enfoque largo o preciso. Para este método se necesita la matriz de coeficientes estandarizados (calculados por el SPSSTM por medio del criterio de regresión), los cuales se presentan a continuación:

Puntajes. Datos con los que se manejaría cada factor como variable.

Tabla 3-28 Matriz de coeficientes estandarizados

Matriz de coeficientes estandarizados		
	Componente	
	1	2
¿Sobre delincuencia, asaltos y robos?	-.022	.334
¿Sobre sueldos?	.301	.024
¿Sobre derechos humanos?	-.006	.306
¿Sobre empleo?	.295	-.031
¿Sobre terrorismo?	-.013	.301
¿Sobre vivienda?	.318	-.032
¿Sobre medidas para combatir las protestas?	.026	.334
¿Sobre pobreza?	.312	.023

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

Puntuaciones de los componentes.

Los datos estandarizados de 5 personas son los siguientes, se omite el nombre de cada variable, se utilizan las letras V.

Tabla 3-29 Datos estandarizados de las primeras 5 personas

V ₁	V ₂	V ₃	V ₄	V ₅	V ₆	V ₇	V ₈
-1.181	-1.354	-1.177	-1.165	0.482	-1.868	-1.179	-0.509
-0.434	0.297	-0.465	1.144	-0.330	0.846	0.563	0.892
-0.434	0.297	-0.465	-0.395	0.482	0.167	0.563	-1.209
-0.434	1.949	-0.465	1.914	-0.330	1.524	-0.308	1.592
1.062	-0.528	1.671	1.914	-0.330	-0.511	0.563	0.191

El *método largo o preciso* consiste en sustituir en una ecuación obtenida a partir de la matriz de coeficientes estandarizados, los datos estandarizados de cada persona; se debe recordar que la ecuación de componentes principales es:

$$F_{ij} = U_1X_{1j} + U_2X_{2j} + U_3X_{3j} + \cdots + U_kX_{kj}$$

Ecuación para el factor 1:²⁰

$$F_{1j} = -0.022V_{1j} + 0.30_1V_{2j} - 0.006V_{3j} + 0.295V_{4j} - 0.013V_{5j} \\ + 0.318V_{6j} + 0.026V_{7j} + 0.312V_{8j}$$

En esta ecuación se sustituyen los datos estandarizados, por ejemplo de la persona 1:

$$F_{1j} = -0.022(-1.18) + 0.30_1(-1.35) - 0.00_6(-1.17) + 0.295(-1.16) - 0.01_3(0.481) \\ + 0.31_8(-1.86) + 0.026(-1.17) + 0.31_2(-.508) = -1.508$$

²⁰ Para obtener la ecuación se utilizó la fórmula 3-6 de componentes principales y en las U se sustituyeron los coeficientes estandarizados de la componente 1.

El puntaje de la persona 1 en el concepto llamado *F1* es -1.508 y de esta misma forma se obtienen los puntajes de todos los datos del estudio. A continuación se dan los cinco²¹ puntajes que se calcularon para el factor 1 y los otros cinco para el factor 2:

Tabla 3-30 Los primeros 5 puntajes de los 2 factores

Factor 1	Factor 2
-1.508	-0.952
1.005	-0.233
-0.330	0.032
2.141	-0.514
0.288	0.903

Aproximado

Al enfoque aproximado también se le denomina *corto*; consiste en utilizar como puntajes los datos originales de la variable que se haya identificado más con el factor, para esto es necesario volver a la matriz rotada y encontrar la variable que tenga la mayor carga²² pero por factor. El procedimiento para el factor 1 es el siguiente:

Tabla 3-31 Matriz rotada

Matriz de componentes rotados ^a		
	Componente	
	1	2
¿Sobre delincuencia, asaltos y robos?	$-.038$	$.812$
¿Sobre sueldos?	$.799$	$.075$
¿Sobre derechos humanos?	$.002$	$.745$
¿Sobre empleo?	$.780$	$-.058$
¿Sobre terrorismo?	$-.017$	$.732$
¿Sobre vivienda?	$.842$	$-.059$
¿Sobre medidas para combatir las protestas?	$.089$	$.815$
¿Sobre pobreza?	$.827$	$.074$

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación convergida en 3 iteraciones.

Para el factor 1, los puntajes que se obtendrán serán los datos originales de la variable *sobre vivienda*, es decir, la variable 6, ya que es la que tiene la carga más alta para este factor.

Los datos originales de las variables para las 5 personas son:

Tabla 3-32 Datos originales de las primeras 5 personas, en donde se muestran los puntajes del factor 1 en negro y del factor 2 en gris

V ₁	V ₂	V ₃	V ₄	V ₅	V ₆	V ₇	V ₈
1	2	1	2	3	1	1	3
2	4	2	5	2	5	3	5
2	4	2	3	3	4	3	2
2	6	2	6	2	6	2	6
4	3	5	6	2	3	3	4

²¹ Es necesario recordar que se tienen 150 observaciones, por lo que se tendrían que calcular el resto de ellas.

²² Se deberá escoger la mayor carga en valor absoluto.

Los puntajes del resto de los elementos se obtienen al copiar los datos originales de la mencionada variable. Pero si no se tienen las variables originales o si éstas no tienen las mismas unidades se deberán utilizar las estandarizadas.

Tabla 3-33 Datos estandarizados de las primeras 5 personas, en donde se muestran los puntajes del factor 1 en negro y del factor 2 en gris

V ₁	V ₂	V ₃	V ₄	V ₅	V ₆	V ₇	V ₈
-1.181	-1.354	-1.177	-1.165	0.482	-1.868	-1.179	-0.509
-0.434	0.297	-0.465	1.144	-0.330	0.846	0.563	0.892
-0.434	0.297	-0.465	-0.395	0.482	0.167	0.563	-1.209
-0.434	1.949	-0.465	1.914	-0.330	1.524	-0.308	1.592
1.062	-0.528	1.671	1.914	-0.330	-0.511	0.563	0.191

Promedio

Enfoque promedio.

Consiste en utilizar como puntajes los promedios de las variables que se agruparon con cada factor.

El **enfoque promedio** consiste en utilizar como puntajes los promedios de las variables que se agruparon con cada factor. Por ejemplo, para calcular los puntajes del factor 1 es necesario volver a la matriz rotada y saber cuáles son las variables que se agruparon con dicho factor,²³ a continuación se muestra la matriz rotada:

Tabla 3-34 Matriz rotada

Matriz de componentes rotados ^a		
	Componente	
	1	2
¿Sobre delincuencia, asaltos y robos?	-.038	.812
¿Sobre sueldos?	.799	.075
¿Sobre derechos humanos?	.002	.745
¿Sobre empleo?	.780	-.058
¿Sobre terrorismo?	-.017	.732
¿Sobre vivienda?	.842	-.059
¿Sobre medidas para combatir las protestas?	.089	.815
¿Sobre pobreza?	.827	.074

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación convergida en 3 iteraciones.

Con esta información se vuelve a los datos originales (si no están disponibles o si no se tienen las mismas unidades, se pueden utilizar los valores de las variables estandarizados) y se encuentra el promedio de dichas variables, por lo que los puntajes para el factor 1 serían los siguientes:

²³ Se debe recordar que en el factor 1 se agruparon las variables *sueldos*, *empleo*, *vivienda* y *pobreza*.

Tabla 3-35 Datos estandarizados de las primeras 5 personas, en donde se muestran los puntajes del factor 1

V_2	V_4	V_6	V_8	Promedio o factor 1
-1.354	-1.165	-1.868	-0.509	-1.224
0.297	1.144	0.846	0.892	0.795
0.297	-0.395	0.167	-1.209	-0.285
1.949	1.914	1.524	1.592	1.745
-0.528	1.914	-0.511	0.191	0.267

En la tabla anterior se encontró el promedio de las cuatro variables estandarizadas, si por el contrario se dispone de los datos originales y las variables tienen las mismas unidades, los puntajes serían los siguientes:

Tabla 3-36 Datos originales de las primeras 5 personas, en donde se muestran los puntajes del factor 1

V_2	V_4	V_6	V_8	Promedio o factor 1
2	2	1	3	2.00
4	5	5	5	4.75
4	3	4	2	3.25
6	6	6	6	6.00
3	6	3	4	4.00

De la misma manera se calculan los puntajes del factor 2, los cuales serían los siguientes:

Tabla 3-37 Datos estandarizados de las primeras 5 personas, en donde se muestran los puntajes del factor 2

V_1	V_3	V_5	V_7	Promedio o factor 2
-1.181	-1.177	0.482	-1.179	-0.764
-0.434	-0.465	-0.330	0.563	-0.166
-0.434	-0.465	0.482	0.563	0.037
-0.434	-0.465	-0.330	-0.308	-0.384
1.062	1.671	-0.330	0.563	0.741

Tabla 3-38 Datos originales de las primeras 5 personas, en donde se muestran los puntajes del factor 2

V_1	V_3	V_5	V_7	Promedio o factor 2
1	1	3	1	1.50
2	2	2	3	2.25
2	2	3	3	2.50
2	2	2	2	2.00
4	5	2	3	3.50

3.6 Análisis posteriores

El análisis de factores es una técnica muy útil si se tiene un gran número de variables, las cuales se pueden resumir en pocos factores o componentes.

En factores se obtienen nuevas variables que pueden explicar con más éxito alguna estructura (al resumir las variables y obtener los puntajes de los factores, esos puntajes forman las nuevas variables), ahora la pregunta sería ¿qué se puede hacer con las nuevas variables que se encontraron?

La respuesta es: utilizarlas en el análisis de regresión múltiple, en el análisis discriminante, etc., las cuales son técnicas dependientes y que requieren de 2 o más variables independientes métricas, que no estén correlacionadas²⁴ y que afecten la variable que se desea pronosticar, por lo que si las variables independientes tienen problemas de multicolinealidad se recomienda que se ortogonalicen por medio del análisis de factores y puedan utilizarse en cualquiera de los análisis antes mencionados.

3.7 Ejercicios de análisis de factores

Problema 1

Se tiene la siguiente matriz de factores no rotada.

- Se pide obtenga las comunalidades, el eigenvalor y el porcentaje de variación explicada.

Matriz no rotada ^a				
	Componente			
	1	2	3	4
VAR00001	.881	-.347	-.165	.268
VAR00002	.828	.508	-.070	-.200
VAR00003	.664	-.711	.154	-.031
VAR00004	.792	.564	-.179	-.029
VAR00005	.731	-.647	.117	-.125
VAR00006	.476	.804	.329	.135

Método de extracción: análisis de componentes principales.

^a 4 componentes extraídos.

- A partir de estos resultados, ¿se puede saber cómo agrupar a las variables? Explique.
- ¿Cuál es la variable que más se identifica con las características? Explique su respuesta.

Problema 2

Se tiene la siguiente matriz de factores no rotada.

Matriz no rotada ^a		
	Componente	
	1	2
VAR00001	.839	-.220
VAR00002	-.739	.520
VAR00003	.524	.675
VAR00004	.585	.367

Método de extracción: análisis de componentes principales.

^a 2 componentes extraídos.

- Obtenga la variación explicada de cada factor y las comunalidades.

²⁴ Es decir, que no tengan multicolinealidad.

Se rotó la matriz y generó la siguiente información:

Matriz rotada ^a		
	Componente	
	1	2
VAR00001	.805	.322
VAR00002	.903	-.020
VAR00003	-.021	.854
VAR00004	-.252	.643

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación converge en 3 iteraciones.

- Obtenga eigenvalor y comunalidades.
- ¿Se ganó o se perdió información con respecto a la matriz no rotada?
- Agrupe o identifique cada variable con el factor que le corresponda y concluya cómo se quedaron agrupadas las variables.
- ¿Por qué no se alteraron las comunalidades?

Problema 3

Se capturó en la computadora una serie de datos y con el programa SPSS™ se obtuvo la siguiente información:

Matriz de transferencia ortogonal			
Componente	1	2	3
1	.637	.628	.448
2	-.767	.455	.453
3	.081	-.632	.771

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

Matriz rotada ^a			
	Componente		
	1	2	3
VAR00001	.714	.648	-.064
VAR00002	-.001	.926	.308
VAR00003	.952	-.034	.216
VAR00004	.152	.215	.955

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación converge en 6 iteraciones.

Variación explicada por cada factor		
Factor 1	Factor 2	Factor 3
1.519638	1.025627	1.023216

Comunalidades		
	Inicial	Extracción
VAR00001	1.000	.935
VAR00002	1.000	.952
VAR00003	1.000	.955
VAR00004	1.000	.982

Método de extracción: análisis de componentes principales.

- Con base en esta información obtenga los puntajes para cada uno de los factores por el método corto.

Problema 4

Debido a los cambios que se han ido dando en el rol que desempeña la mujer actualmente, se realizó una investigación para medir el grado de oportunidad que tiene la mujer emprendedora en México para comprobar que en este país la mujer tiene iguales o más oportunidades que el hombre para ser emprendedora. Algunos de sus objetivos generales eran:

- Determinar la relación que existe entre mujeres y hombres que trabajen en altos puestos directivos.
- Investigar el machismo como obstáculo para la mujer.
- Determinar si el estado civil de la mujer es considerado como una oportunidad para su realización.
- Analizar si el factor económico influye de la misma manera en hombres como en mujeres.

El cuestionario estaba conformado por preguntas como las siguientes:

Marque su grado de aceptación a las siguientes afirmaciones siendo:

CA = Completamente de acuerdo

A = Acuerdo

I = Indiferente

D = Desacuerdo

CD = Completamente en desacuerdo

	CA	A	I	D	CD
1. Actualmente 90% de los puestos directivos son ocupados por hombres:					
2. El hombre tiene más probabilidad de ocupar altos puestos directivos:					
3. El hombre, en comparación con la mujer, resuelve más rápido cualquier problema:					
4. Un obstáculo para ser emprendedor es determinado por el sexo de la persona:					
5. El machismo es un obstáculo para la mujer al querer emprender un negocio:					
6. El ser mujer casada es un obstáculo para iniciar un negocio:					
7. El estado civil de soltera es considerado como oportunidad para abrir un negocio:					
8. Un obstáculo para ser emprendedor es el estado civil:					
9. Una persona decide ser emprendedor por ganar dinero:					

Con el fin de verificar el planteamiento de los objetivos anteriores y su evaluación a través del cuestionario que se mostró, la información de 150 entrevistas fueron procesadas, se decidió aplicar la técnica de análisis de factores y se obtuvo lo siguiente:

Comunalidades		
	Inicial	Extracción
VAR00001	1.000	.970
VAR00002	1.000	.870
VAR00003	1.000	.890
VAR00004	1.000	.877
VAR00005	1.000	.914
VAR00006	1.000	.961
VAR00007	1.000	.907
VAR00008	1.000	.889
VAR00009	1.000	.953

Método de extracción: análisis de componentes principales.

Varianza total explicada									
Componente	Eigenvalores iniciales			Extracción de cargas de suma de cuadrados			Rotación de cargas de suma de cuadrados		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	3.938	43.757	43.757	3.938	43.757	43.757	3.231	35.902	35.902
2	2.826	31.399	75.155	2.826	31.399	75.155	2.420	26.894	62.797
3	.802	8.915	84.071	.802	8.915	84.071	1.425	15.834	78.630
4	.664	7.376	91.447	.664	7.376	91.447	1.153	12.817	91.447
5	.397	4.413	95.660						
6	.187	2.078	97.938						
7	.112	1.249	99.187						
8	.065	.719	99.907						
9	.008	.093	100.000						

Método de extracción: análisis de componentes principales.

Matriz no rotada ^a				
	Componente			
	1	2	3	4
VAR00001	.571	.630	-.345	.359
VAR00002	.891	-.266	.026	.070
VAR00003	.320	.875	-.042	.142
VAR00004	.760	-.407	-.197	.307
VAR00005	.540	.659	.350	-.256
VAR00006	.730	-.522	-.112	-.378
VAR00007	.660	.625	.194	-.205
VAR00008	.835	-.339	-.210	-.180
VAR00009	.426	-.462	.652	.364

Método de extracción: análisis de componentes principales.

^a 4 componentes extraídos.

- De acuerdo con el criterio *a priori*, ¿cuántas y cuáles dimensiones se esperarían tener como solución óptima a este problema?
- De acuerdo con el criterio de la raíz latente y hablando cuantitativamente, ¿son suficientes 4 características como solución adecuada?
- Por el criterio de variación acumulada, ¿cuántos conceptos necesitamos?

- Si los investigadores deciden fijar una variación explicada significativa para cada factor de más de 0.7, ¿cuántos conceptos serán necesarios como solución inicial?
- ¿Qué cantidad explica el concepto 2 a la V8 y qué relación?
- ¿Qué variable es la que mejor se explica en esta investigación con la solución presente, y por qué?

Problema 5

El Movimiento Familiar Cristiano de Monterrey realizó una investigación para conocer los sentimientos de las parejas de matrimonios regiomontanos con respecto al estado de su relación conyugal. El cuestionario aplicado contenía preguntas como las siguientes:

Con respecto a las siguientes afirmaciones, indique su grado de acuerdo marcando con una X.

	CA	A	I	D	CD
1. Si durante mi matrimonio existieran problemas graves me divorciaría:					
2. Dios existe:					
3. No confío en mi pareja, oculto algunas cosas para evitar que se moleste:					
4. Es necesario tener una religión:					
5. Es necesario que la mamá trabaje para no perder poder económico en la familia:					
6. Los celos son una señal de desconfianza en la pareja:					
7. Al trabajar la mujer, el hombre pierde poder de autoridad en la familia:					
8. Acudo siempre a misa los domingos y días de guardar:					
9. El hombre no debe comunicarle a su esposa su salario, sólo debe proporcionar lo que necesite:					
10. Las decisiones de compra importantes las hacemos por común acuerdo:					

Fueron entrevistadas 100 personas para este estudio, la información fue procesada en un programa de análisis de factores y se obtuvieron los siguientes resultados:

Comunalidades		
	Inicial	Extracción
x1	1.000	.771
x2	1.000	.638
x3	1.000	.936
x4	1.000	.894
x5	1.000	.822
x6	1.000	.853
x7	1.000	.564
x8	1.000	.867
x9	1.000	.653
x10	1.000	.277

Método de extracción: análisis de componentes principales.

Matriz no rotada ^a			
	Componente		
	1	2	3
x1	-.405	-.387	.676
x2	.798	-.036	.013
x3	.462	.845	.089
x4	.041	.844	.424
x5	-.772	.392	.269
x6	.818	.222	.366
x7	-.213	-.370	.618
x8	.877	.164	.268
x9	.727	.353	-.017
x10	.425	-.306	.054

Método de extracción: análisis de componentes principales.

^a 3 componentes extraídos.

Matriz rotada ^a			
	Componente		
	1	2	3
x1	-.194	-.006	.856
x2	.691	.351	-.192
x3	.200	.902	.285
x4	.843	-.435	.028
x5	-.456	-.227	.792
x6	.123	.039	.911
x7	-.045	.073	.746
x8	.918	.140	-.069
x9	.127	-.170	-.352
x10	.306	.425	.052

Método de extracción: análisis de componentes principales.

^a Rotación converge en 5 iteraciones.

- El responsable de este estudio se pregunta si 3 dimensiones son el número adecuado para representar a las variables medidas en esta parte del cuestionario, le pide a usted que le ayude a resolver esta duda.
- ¿Cuál es la relación entre la variable V_c y la tercera dimensión?
- ¿Qué cantidad explica la tercera dimensión a la variable V_c ?
- Se ha reportado que las dimensiones obtenidas se refieren a aspectos de religión, actitud de la pareja y comunicación entre la pareja. ¿Podría usted afirmar que esto es cierto?
- ¿Cuál es la variable que ha logrado identificarse mejor con esta solución de factores?
- ¿Qué información utilizaría como puntajes de las 3 dimensiones extraídas según el método corto?

Problema 6

La Secretaría de Comercio y Fomento Industrial llevó a cabo una investigación entre comerciantes de diferentes giros (zapaterías, ropa, farmacias, abarrotes), con el objetivo de conocer las características del comercio en la ciudad, así como la forma en que las personas administran sus negocios.

Algunas de las preguntas realizadas en el cuestionario son las siguientes:

1. De acuerdo con su estilo de administrar, ¿cómo se considera usted al tomar decisiones que dan rumbo a su negocio?

Arriesgado						Cauteloso
------------	--	--	--	--	--	-----------

2. ¿Qué tipo de relación guarda usted con sus empleados?

Amistosa						Fría
----------	--	--	--	--	--	------

3. ¿En qué grado podría clasificar la comunicación entre usted y sus empleados?

Abierta						Limitada
---------	--	--	--	--	--	----------

4. ¿Acepta reclamaciones de sus clientes?

Siempre						Nunca
---------	--	--	--	--	--	-------

5. ¿Busca siempre satisfacer las necesidades de sus clientes?

Definitivamente sí						Definitivamente no
--------------------	--	--	--	--	--	--------------------

6. Usted tiene con su negocio _____ años.

7. El número de empleados en su negocio es _____.

8. ¿Tiene planes de expansión de su negocio?

Definitivamente sí						Definitivamente no
--------------------	--	--	--	--	--	--------------------

9. El monto aproximado del capital invertido en su negocio es de _____ millones de pesos.

10. Edad _____ (del dueño o de la persona encargada de tomar decisiones en el negocio).

Los datos recopilados a través de la aplicación de las encuestas fueron procesados mediante la técnica de análisis de factores y se generaron los resultados que aparecen en seguida y en la página siguiente.

Matriz no rotada ^a				
	Componente			
	1	2	3	4
x1	.912	-.259	.036	-.143
x2	.832	.351	-.165	-.161
x3	.678	-.576	.307	.196
x4	.598	.036	-.475	-.607
x5	.451	-.738	-.404	.210
x6	.474	.702	-.411	.253
x7	.826	-.282	.326	.267
x8	.645	.630	-.250	.337
x9	.120	.713	.606	.033
x10	.547	.100	.689	-.296

Método de extracción: análisis de componentes principales.

^a 4 componentes extraídos.

- De acuerdo con los criterios para el número de factores en la solución inicial, aprendidos en este capítulo, analice si 4 factores son suficientes para agrupar a las variables.
- De acuerdo con la información de la matriz no rotada, ¿con cuál de los factores se identificó mejor el conjunto de las 10 variables?

Matriz rotada ^a				
	Componente			
	1	2	3	4
x1	.780	.187	-.025	.526
x2	.341	.615	.175	.587
x3	.952	-.082	-.103	.040
x4	.089	.217	-.149	.936
x5	.591	-.015	-.764	.154
x6	-.086	.954	.061	.171
x7	.943	.204	.076	.053
x8	.159	.964	.134	.127
x9	-.016	.301	.881	-.153
x10	.548	-.074	.701	.273

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación converge en 5 iteraciones.

- ¿Cuál de las variables ha sido mejor explicada por la solución de factores?
- Teniendo como supuesto que las características obtenidas no tienen nada que ver entre sí, ¿cuál criterio de obtención de factores se utilizó?

Problema 7

Para los hospitales siempre ha sido un problema identificar al cliente, ya que la selección del mismo se puede deber a instancia del doctor o del paciente, por lo anterior se llevó a cabo un estudio de mercado para un hospital de la localidad en el que se intenta evaluar algunos factores.

Los objetivos generales son:

1. Determinar la importancia de los alimentos.
2. Determinar la importancia de la atención médica.
3. Determinar la importancia de los costos.

Estos objetivos fueron evaluados en un cuestionario con las siguientes preguntas:

1. ¿Ha ocupado atención médica en los últimos 6 meses? Sí _____ No _____

De acuerdo con la atención recibida conteste lo siguiente:

	CA	A	I	D	CD
2. El grado de preparación de los médicos fue el adecuado (x1):					
3. El personal fue amable (x2):					
4. Buena accesibilidad de pago (x3):					
5. Buena calidad de la comida en general (x4):					
6. Los médicos estaban actualizados (x5):					
7. Pago justo (x6):					
8. Buen trato de la aseguradora (x7):					
9. Las enfermeras estaban bien preparadas (x8):					
10. Buena temperatura de los alimentos (x9):					
11. Buena atención personalizada de los responsables de servir los alimentos (x10):					

Se realizaron 170 entrevistas, con los siguientes resultados:

Matriz de correlación ^a											
		x1	x2	x3	x4	x5	x6	x7	x8	x9	x10
Correlación	x1	1.000	.434	.506	.256	.193	.025	.391	-.253	-.314	.095
	x2	.434	1.000	.221	.458	.041	.465	.254	.171	-.336	-.180
	x3	.506	.221	1.000	-.260	.662	.183	.737	.000	-.372	.356
	x4	.256	.458	-.260	1.000	-.084	.024	-.215	.231	.287	.091
	x5	.193	.041	.662	-.084	1.000	.254	.823	.541	.184	.431
	x6	.025	.465	.183	.024	.254	1.000	.379	.542	-.374	-.237
	x7	.391	.254	.737	-.215	.823	.379	1.000	.361	-.158	.132
	x8	-.253	.171	.000	.231	.541	.452	.361	1.000	.526	.310
	x9	-.314	-.336	-.372	.287	.184	-.374	-.158	.526	1.000	.540
	x10	.095	-.180	.356	.091	.431	-.237	.132	.310	.540	1.000

^a Determinante = .000.

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.523
Prueba de esfericidad de Bartlett	Ji cuadrada aprox.	104.102
	gl	45
	Sig.	.000

Matriz antiimagen											
		x1	x2	x3	x4	x5	x6	x7	x8	x9	x10
Covarianzas antiimagen	x1	.327	-.044	-.019	-.161	.036	-.025	-.091	.092	-.013	-.043
	x2	-.044	.327	-.041	-.175	.076	-.019	-.036	-.063	.025	.032
	x3	-.019	-.041	.097	.033	-.050	.044	-.028	.003	.061	-.106
	x4	-.161	-.175	.033	.334	-.065	.012	.089	-.024	-.018	.008
	x5	.036	.076	-.050	-.065	.121	-.023	-.066	-.017	-.028	.011
	x6	-.025	-.019	.044	.012	-.023	.243	.001	-.120	.104	-.035
	x7	-.091	-.036	-.028	.089	-.066	.001	.120	-.030	-.010	.069
	x8	.092	-.063	.003	-.024	-.017	-.120	-.030	.136	-.061	-.012
	x9	-.013	.025	.061	-.018	-.028	.104	-.010	-.061	.096	-.086
	x10	-.043	.032	-.106	.008	.011	-.035	.069	-.012	-.086	.221
Correlación antiimagen	x1	-.541 ^a	-.135	-.109	-.488	.180	-.089	-.458	.436	-.071	-.161
	x2	-.135	.578 ^a	-.232	-.530	.384	-.068	-.183	-.297	.138	.121
	x3	-.109	-.232	.541 ^a	.185	-.465	.289	-.257	.028	.636	-.726
	x4	-.488	-.530	.185	.579 ^a	-.325	.043	.447	-.115	-.098	.030
	x5	.180	.384	-.465	-.325	.655 ^a	-.136	-.553	-.134	-.262	.069
	x6	-.089	-.068	.289	.043	-.136	.454 ^a	.003	-.661	.678	-.149
	x7	-.458	-.183	-.257	.447	-.553	.003	.630 ^a	-.237	-.089	.424
	x8	.436	-.297	.028	-.115	-.134	-.661	-.237	.511 ^a	-.537	-.070
	x9	-.071	.138	.636	-.098	-.262	.678	-.089	-.537	.626 ^a	-.592
	x10	-.161	.121	-.726	.030	.069	-.149	.424	-.070	-.592	.622 ^a

^a Medida de adecuación muestral (MSA).

Comunalidades		
	Inicial	Extracción
x1	1.000	.411
x2	1.000	.806
x3	1.000	.882
x4	1.000	.628
x5	1.000	.894
x6	1.000	.535
x7	1.000	.858
x8	1.000	.822
x9	1.000	.907
x10	1.000	.604

Método de extracción: análisis de componentes principales.

Varianza total explicada									
	Eigenvalores iniciales			Extracción de cargas de suma de cuadrados			Rotación de cargas de suma de cuadrados		
Componente	Total	% de variación	% acumulado	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	3.225	32.246	32.246	3.225	32.246	32.246	2.999	29.987	29.987
2	2.347	23.474	55.720	2.347	23.474	55.720	2.348	23.482	53.469
3	1.776	17.756	73.477	1.776	17.756	73.477	2.001	20.007	73.477
4	1.444	14.438	87.915						
5	.481	4.810	92.725						
6	.302	3.017	95.725						
7	.237	2.373	98.115						
8	.079	.787	98.903						
9	.067	.666	99.569						
10	.043	.431	100.000						

Método de extracción: análisis de componentes principales.

Matriz no rotada ^a			
	Componente		
	1	2	3
x1	.499	-.402	.012
x2	.435	-.428	.659
x3	.832	-.152	-.408
x4	-.033	.129	.781
x5	.840	.405	-.154
x6	.502	-.258	.465
x7	.912	.005	-.161
x8	.425	.639	.483
x9	-.188	.922	.151
x10	.295	.689	-.205

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a 3 componentes extraídos.

Matriz rotada ^a			
	Componente		
	1	2	3
x1	.484	-.301	.292
x2	.875	-.204	.157
x3	.035	-.090	-.928
x4	-.345	.679	.257
x5	.800	.500	.062
x6	.299	-.069	.664
x7	.199	.125	.883
x8	.752	.187	.424
x9	-.302	.888	-.166
x10	.297	.672	-.252

Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación converge en 6 iteraciones.

Matriz de coeficientes estandarizados			
	Componente		
	1	2	3
x1	.153	-.138	.105
x2	-.007	-.077	.428
x3	.332	-.066	-.097
x4	-.185	.142	.377
x5	.260	.192	-.028
x6	.049	-.026	.319
x7	.295	.031	.020
x8	-.006	.340	.223
x9	-.117	.386	-.044
x10	.106	.275	-.145

Método de rotación: varimax con normalización kaiser.

- ¿Se puede realizar un análisis de factores?
- De acuerdo con la matriz antiimagen, ¿eliminaría alguna variable?, ¿por qué?
- De acuerdo con los criterios para la determinación del número de factores como solución inicial estudiados en este capítulo, ¿son suficientes 4 factores en la solución?
- Realice un análisis en el que evalúe, de acuerdo con los criterios de la pregunta anterior, si valdría la pena agregar o eliminar factores a esta solución.
- ¿Cuál de las variables logró identificarse mejor con esta solución de factores?
- Explique por qué ocurre la tendencia descendente en el valor de los eigenvalores de cada factor que se agrega en la matriz no rotada.
- Determine si el cuestionario aplicado ha logrado medir los objetivos planteados en la investigación. Explique ampliamente su respuesta.
- Determine los 2 primeros puntajes por el método largo para el factor 2; tome en cuenta los datos estandarizados de las siguientes 4 entrevistas:

	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10
1	.99	.54	.67	.65	.78	.34	.32	.54	.76	.87
2	.23	4.5	.67	.50	.37	.85	.24	.98	.46	.25
3	.78	.65	.45	.37	.24	.31	.65	.34	.56	.43
4	.13	.64	.27	.89	.64	.78	.43	.90	.43	.14

- Por el método corto determine qué puntajes se utilizarían para los 4 factores.

Problema 8

Se realizó un estudio sobre un establecimiento de comida rápida, se le preguntó a 100 personas sobre el sabor de la comida, el precio, el estacionamiento y el servicio de los empleados, se corrió un análisis de factores en el SPSS™ y los resultados son los siguientes:

Matriz de correlación ^a					
		x1	x2	x3	x4
Correlación	x1	1.000	.197	.548	.058
	x2	.197	1.000	.578	.726
	x3	.548	.578	1.000	.406
	x4	.058	.726	.406	1.000

^a Determinante = .209.

KMO y prueba de Bartlett		
Kaiser-Meyer-Olkin medida de la adecuación muestral		.604
Prueba de esfericidad de Bartlett	Ji cuadrada aprox.	21.629
	gl	6
	Sig.	.001

Comunalidades		
	Inicial	Extracción
x1	1.000	.997
x2	1.000	.865
x3	1.000	.968
x4	1.000	.934

Método de extracción: análisis de componentes principales.

Varianza total explicada									
Componente	Eigenvalores iniciales			Extracción de cuadrados de cargas			Rotación de suma de cuadrados de cargas		
	Total	% de variación	% acumulado	Total	% de variación	% acumulado	Total	% de variación	% acumulado
1	2.310	57.745	57.745	2.310	57.745	57.745	1.913	47.828	47.828
2	1.108	27.692	85.437	1.108	27.692	85.437	1.504	37.609	85.437
3	.346	8.648	94.085						
4	.237	5.915	100.000						

Método de extracción: análisis de componentes principales.

Matriz no rotada ^a		
	Componente	
	1	2
x1	.515	.790
x2	.871	-.323
x3	.837	.326
x4	.765	-.522

Método de extracción: análisis de componentes principales.

^a 2 componentes extraídos.

Matriz rotada ^a		
	Componente	
	1	2
x1	-.032	.943
x2	.898	.236
x3	.498	.748
x4	.926	.012


Método de extracción: análisis de componentes principales.

Método de rotación: varimax con normalización kaiser.

^a Rotación converge en 3 iteraciones.

- ¿Qué indica el KMO y la prueba de Bartlett?
- ¿Cuánta información se logró explicar con este estudio?
- ¿Cuál es la variable que mejor se explicó?
- ¿Cómo quedaron agrupadas las variables? ¿Se le puede poner un nombre lógico a cada factor?
- ¿Qué problema hay en la variable 1?

Anexo 3.1 Tabla ji cuadrada




gl	0.50	0.60	0.70	0.80	0.90	0.95	0.975	0.980	0.985	0.990	0.995	0.999
1	0.455	0.275	0.148	0.054	0.015	0.004	0.001	0.001	0.000	0.000	0.000	0.000
2	1.385	1.022	0.713	0.446	0.211	0.103	0.051	0.040	0.030	0.020	0.010	0.002
3	2.366	1.869	1.424	1.005	0.584	0.352	0.216	0.185	0.152	0.115	0.072	0.024
4	3.357	2.753	2.195	1.649	1.064	0.711	0.484	0.429	0.368	0.297	0.207	0.091
5	4.351	3.655	3.000	2.343	1.610	1.145	0.831	0.752	0.662	0.554	0.412	0.210
6	5.348	4.570	3.828	3.070	2.204	1.635	1.237	1.134	1.016	0.872	0.676	0.381
7	6.346	5.493	4.671	3.822	2.833	2.167	1.690	1.564	1.418	1.239	0.989	0.596
8	7.344	6.423	5.527	4.594	3.490	2.733	2.180	2.032	1.860	1.646	1.344	0.857
9	8.343	7.357	6.393	5.380	4.168	3.325	2.700	2.532	2.335	2.088	1.735	1.152
10	9.342	8.295	7.267	6.179	4.865	3.940	3.247	3.059	2.837	2.558	2.156	1.479
11	10.341	9.237	8.148	6.989	5.578	4.575	3.816	3.609	3.363	3.053	2.603	1.834
12	11.340	10.162	9.034	7.607	6.304	5.226	4.404	4.176	3.910	3.571	3.074	2.214
13	12.340	11.129	9.926	8.634	7.042	5.892	5.009	4.765	4.476	4.107	3.565	2.617
14	13.339	12.078	10.821	9.467	7.790	6.571	5.629	5.368	5.057	4.660	4.075	3.041
15	14.339	13.030	11.721	10.307	8.547	7.261	6.262	5.985	5.653	5.229	4.601	3.483
16	15.338	13.963	12.624	11.152	9.312	7.962	6.908	6.614	6.263	5.812	5.142	3.942
17	16.338	14.937	13.531	12.002	10.085	8.672	7.564	7.255	6.884	6.406	5.697	4.416
18	17.338	15.893	14.440	12.857	10.865	9.390	8.231	7.906	7.516	7.015	6.265	4.905
19	18.338	16.850	15.352	13.716	11.651	10.117	8.907	8.567	8.159	7.633	6.844	5.407
20	19.337	17.809	16.266	14.578	12.443	10.651	9.597	9.237	8.810	8.260	7.434	5.921
21	20.337	18.768	17.182	15.445	13.240	11.591	10.283	9.915	9.471	8.897	8.034	6.447
22	21.337	19.729	18.101	16.314	14.041	12.336	10.962	10.600	10.139	9.542	8.643	6.983
23	22.337	20.690	19.021	17.167	14.846	13.091	11.689	11.293	10.815	10.196	9.260	7.529
24	23.337	21.652	19.943	18.062	15.659	13.848	12.401	11.992	11.497	10.856	9.886	8.085
25	24.337	22.616	20.867	18.940	16.473	14.611	13.120	12.697	12.187	11.524	10.520	8.649
26	25.336	23.579	21.792	19.820	17.292	15.379	13.844	13.409	12.862	12.198	11.160	9.222
27	26.336	24.544	22.719	20.703	18.114	16.151	14.573	14.125	13.583	12.879	11.808	9.803
28	27.336	25.509	23.647	21.588	18.939	16.926	15.308	14.847	14.290	13.565	12.461	10.391
29	28.336	26.475	24.577	22.475	19.768	17.706	16.047	15.574	15.002	14.256	13.121	10.986
30	29.336	27.442	25.508	23.364	20.599	18.493	16.791	16.306	15.719	14.953	13.787	11.588

(continúa)

(continuación)

gl	0.50	0.60	0.70	0.80	0.90	0.95	0.975	0.980	0.985	0.990	0.995	0.999
40	39.335	37.134	34.872	32.345	29.051	26.509	24.433	23.838	23.113	22.164	20.707	17.916
50	49.335	46.864	44.313	41.449	37.689	34.764	32.357	31.664	30.818	29.707	27.991	24.674
60	59.335	56.620	53.809	50.641	46.459	43.186	40.482	39.699	38.744	37.485	35.534	31.736
70	69.334	66.396	63.346	59.898	55.329	51.739	46.758	47.393	46.836	45.442	43.275	39.036
80	79.334	76.188	72.915	69.207	64.276	60.391	57.153	56.213	55.061	53.540	51.172	46.520
90	89.334	85.993	82.511	78.558	73.291	69.126	65.647	64.635	63.394	61.754	59.196	54.155
100	99.334	95.808	92.129	87.945	82.358	77.929	74.222	73.142	71.818	70.065	67.328	61.918
110	109.33	105.632	101.766	97.362	91.471	86.792	82.867	81.723	80.318	78.458	75.550	69.789
120	119.33	115.455	111.419	106.806	100.624	95.706	91.573	90.367	88.856	86.923	83.852	77.755
140	139.33	135.149	130.766	125.758	119.029	113.659	109.137	107.815	106.190	104.034	100.655	93.926
150	149.33	145.000	140.457	135.263	128.275	122.692	117.985	116.608	114.915	112.668	109.142	102.113
160	159.33	154.856	150.158	144.783	137.546	131.756	126.870	125.440	123.681	121.346	117.679	110.360
170	169.33	164.716	159.859	154.319	146.839	140.849	135.790	134.308	132.486	130.064	126.261	118.661
180	179.33	174.580	169.588	163.868	156.153	149.969	144.741	143.210	141.325	138.820	134.884	127.011
190	189.33	184.448	179.315	173.430	165.485	159.113	153.721	152.141	150.196	147.610	143.545	135.405
200	199.33	194.319	189.049	183.003	174.835	168.279	162.728	161.100	159.096	156.432	152.241	143.843



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.624	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.615	9.348	9.837	10.465	11.345	12.836	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.096	15.086	16.750	20.515
6	5.348	6.211	7.231	8.556	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.363	9.803	12.017	14.067	16.013	16.622	17.396	18.475	20.276	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.463	21.161	22.021	23.209	25.168	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264
12	11.340	12.584	14.011	15.812	18.549	21.026	23.337	24.054	24.963	26.217	28.300	32.909
13	12.340	13.636	15.119	16.985	19.812	22.362	24.736	25.472	26.403	27.688	29.819	34.526
14	13.339	14.685	16.222	18.151	21.064	23.685	26.119	26.873	27.827	29.141	31.319	36.123
15	14.339	15.733	17.322	19.311	22.307	24.996	27.468	28.259	29.235	30.578	32.801	37.697
16	15.338	16.780	18.416	20.465	23.542	26.296	28.845	29.633	30.629	32.000	34.267	39.252
17	16.338	17.824	19.511	21.615	24.769	27.587	30.191	30.995	32.011	33.409	35.716	40.790
18	17.338	18.868	20.601	22.760	25.989	28.869	31.526	32.346	33.382	34.805	37.156	42.312
19	18.338	19.910	21.689	23.900	27.204	30.144	32.852	33.687	34.742	36.191	38.582	43.820

(continúa)

(continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
20	19.337	20.951	22.775	25.036	26.412	31.410	34.170	35.020	36.093	37.566	39.997	45.315
21	20.337	21.991	23.856	26.171	29.615	32.671	35.479	36.343	37.434	38.932	41.401	46.797
22	21.337	23.031	24.939	27.301	30.813	33.924	36.781	37.659	38.768	40.289	42.796	48.268
23	22.337	24.069	26.018	28.429	32.007	35.172	38.076	38.968	40.094	41.638	44.181	49.728
24	23.337	25.106	27.096	29.553	33.196	36.415	39.364	40.270	41.413	42.980	45.559	51.179
25	24.337	26.143	28.172	30.675	34.382	37.652	40.646	41.556	42.725	44.314	46.928	52.620
26	25.336	27.179	29.246	31.795	35.563	38.885	41.923	42.856	44.031	45.642	48.290	54.052
27	26.336	28.214	30.319	32.912	36.741	40.113	43.195	44.140	45.331	46.963	49.645	55.476
28	27.336	29.249	31.391	34.027	37.916	41.337	44.461	45.419	46.626	48.276	50.993	56.892
29	28.336	30.283	32.461	35.139	39.087	42.557	45.722	46.693	47.915	49.588	52.336	58.301
30	29.336	31.316	33.530	36.250	40.256	43.773	46.979	47.962	49.199	50.892	53.672	59.703
40	39.335	41.622	44.165	47.269	51.805	55.756	59.342	60.436	61.812	63.691	66.766	73.402
50	49.335	51.892	54.723	58.164	63.167	67.505	71.420	72.613	74.111	76.154	79.490	86.661
60	59.335	62.135	65.227	68.972	74.397	79.082	83.298	84.580	86.168	88.379	91.952	99.607
70	69.334	72.358	75.689	79.715	85.527	90.531	95.023	96.386	96.098	100.425	104.215	112.317
80	79.334	82.566	86.120	90.405	96.576	101.679	106.629	108.069	109.874	112.329	116.321	124.839
90	89.334	92.761	96.524	101.054	107.565	113.145	118.136	119.648	121.542	124.116	128.299	137.208
100	99.334	102.946	106.906	111.667	118.496	124.342	129.561	131.142	133.120	135.807	140.69	148.449
110	109.33	113.121	117.269	122.250	129.385	135.480	140.917	142.562	144.620	147.414	151.948	161.581
120	119.33	123.289	127.616	132.250	140.233	146.567	152.211	153.918	156.053	158.950	163.648	173.617
140	139.33	143.604	148.269	153.854	161.627	168.613	174.648	176.471	178.750	181.840	186.847	197.451
150	149.33	153.753	158.577	164.349	172.581	179.581	185.800	187.678	190.025	193.208	198.360	209.265
160	159.33	163.898	168.876	174.828	183.311	190.516	195.915	198.846	201.259	204.530	209.824	221.019
170	169.33	174.037	179.165	185.293	194.017	201.423	207.995	209.978	212.455	215.812	221.242	232.719
180	179.33	184.173	189.446	195.743	204.704	212.304	219.044	221.077	223.616	227.056	232.620	244.370
190	189.33	194.305	199.719	206.182	215.371	223.160	230.044	232.146	234.745	238.265	243.959	255.976
200	199.33	204.434	209.985	216.609	226.021	233.994	241.058	243.167	245.845	249.445	255.264	267.541

Anexo 3.2 Descomposición espectral

Pasos a seguir para la descomposición espectral:

1. Estandarice las variables (opcional si se parte de la matriz de correlación. ¿Por qué?).
2. Calcule la varianza y covarianza de las variables.
3. Calcule las correlaciones entre las variables.
4. Realice una descomposición espectral a la matriz de correlación.
 - Calcule los valores propios (eigenvalor).
 - Calcule para cada valor propio su vector propio (eigenvector).
5. Con los eigenvalores y los eigenvectores construya la matriz de factores no rotada.
6. Rotar los factores y encontrar los valores en los ejes para las variables, con esto queda construida la matriz de factores rotada.

Descomposición espectral, única o singular

Primero se explicará teóricamente y después se dará un ejemplo numérico, pero siempre siguiendo los pasos anteriores:

Definición

Sea A una matriz cuadrada, entonces la expresión:

$$A - \lambda I$$

es la matriz característica de A y λ son los valores propios (eigenvalores) de la matriz A .

Pasos

- A. Se calculan los valores propios (eigenvalor): donde cualquier matriz cuadrada A tiene un valor de λ que satisfaga la siguiente expresión:

$$|A - \lambda I| = 0$$

es decir el determinante de la matriz característica de A es igual a cero. Y existirá más de un eigenvector dependiendo del rango de la matriz A .

- B. Se calcula para cada valor propio su vector propio (eigenvector): además se sabe que ν representa los vectores propios (eigenvectores) de A y satisfacen la siguiente ecuación:

$$(A - \lambda I) \nu = 0$$

Pasos a seguir con un ejemplo:

Estandarizar las variables (opcional si se parte de la matriz de correlación. ¿Por qué?).

Se realizará con sólo 2 variables y luego se inferirá para otras.

Se tienen 2 variables X_1 y X_2 , cuyos valores fueron medidos en la misma escala, a continuación se dan los datos:

	X_1	X_2
	21	26
	22	16
	16	28
	17	30
	12	26
	25	10
	18	21
	15	17
	14	23
	18	20
	14	29
	15	23
	25	21
	15	20
Prom.	17.64	22.14
Desv. Std.	4.13	5.53

La estandarización de las 2 variables se realiza con la siguiente fórmula.

$$Z_{ij} = \frac{X_{ij} - \bar{X}_i}{S_i}$$

Donde i es la variable y j es la observación, entonces para la observación 2 de la variable 1 se tiene que:

$$Z_{12} = \frac{X_{12} - \bar{X}_1}{S_1}$$

Al redondear valores se tiene que:

$$Z_{12} = \frac{22 - 17.64}{4.13} = 1.0563$$

Al realizar el mismo procedimiento para cada observación de cada variable se tiene la siguiente tabla para cada variable:

	Z_1	Z_2
Z_{11} →	0.8138	0.6974
Z_{12} →	1.0563	-1.111
	-0.398	1.0589
Z_{24} →	0.156 →	1.4205
	-1.368	0.6974
	1.7835	-2.195
	0.0866	-0.207
	-0.641	-0.93
	-0.883	0.155
	0.0866	-0.387
	-0.883	1.2397
	-0.641	0.155
	1.7835	-0.207
	-0.641	-0.387
Prom.	0.00	0.00
Desv. Std.	1.00	1.00

Se calculan la varianza y covarianza con las siguientes fórmulas.

Las fórmulas de la varianza y covarianza de las dos variables serían:

$$Var(Z_1) = \frac{\sum_{j=1}^n Z_j^2 - n\bar{Z}_1^2}{n-1}$$

$$Var(Z_2) = \frac{\sum_{j=1}^n Z_j^2 - n\bar{Z}_2^2}{n-1}$$

$$Cov(Z_1 Z_2) = \frac{\sum_{j=1}^n \sum_{i=1}^2 Z_{1j} Z_{2j} - n\bar{Z}_1 \bar{Z}_2}{n-1}$$

Esto significa que se necesitan obtener productos y promedios:

Dato	Z_1^2	Z_2^2	$Z_1 * Z_2$
1	0.6623	0.4863	0.5675
2	1.1157	1.2334	-1.1731
3	0.1586	1.1214	-0.4217
4	0.0243	2.0179	-0.2214
5	1.8712	0.4863	-0.9539
6	3.1809	4.8196	-3.9154
7	0.0075	0.0427	-0.0179
8	0.4105	0.8645	0.5957
9	0.7799	0.0240	-0.1369
10	0.0075	0.1501	-0.0335
11	0.7799	1.5369	-1.0948
12	0.4105	0.0240	-0.0993
13	3.1809	0.0427	-0.3685
14	0.4105	0.1501	0.2482
Suma	13	13	-7.0250
	1	1	-0.5404
	Varianza	Varianza	Covarianza

Al sustituir en las fórmulas los valores encontrados en la tabla anterior se calcula la varianza de la primera variable:

$$Var(Z_1) = \frac{\sum_{j=1}^n Z_j^2 - n\bar{Z}_1^2}{n-1} = \frac{13 - 14 * 0}{14 - 1} = 1$$

Para calcular la varianza de la segunda variable se tiene que:

$$Var(Z_2) = \frac{\sum_{j=1}^n Z_j^2 - n\bar{Z}_2^2}{n-1} = \frac{13 - 14 * 0}{14 - 1} = 1$$

Para calcular la covarianza de las dos variables:

$$Cov(Z_1 Z_2) = \frac{\sum_{j=1}^n \sum_{i=1}^n Z_{1j} Z_{2j} - n\bar{Z}_1 \bar{Z}_2}{n-1} = \frac{-7.025 - 14 * 0}{14 - 1} = -0.5404$$

Para calcular las correlaciones y construir la matriz de correlación se usan las siguientes fórmulas:

$$R_{Z_1, Z_2} = \frac{Cov(Z_1, Z_2)}{\sqrt{Var(Z_1)}\sqrt{Var(Z_2)}}$$

$$R_{Z_1, Z_2} = \frac{\sum_{j=1}^n (Z_{1j} - \bar{Z}_1)(Z_{2j} - \bar{Z}_2)}{\sqrt{\sum_{j=1}^n (Z_{1j} - \bar{Z}_1)^2} \sqrt{\sum_{j=1}^n (Z_{2j} - \bar{Z}_2)^2}}$$

$$R_{Z_1, Z_2} = \frac{\sum_{i=1}^n Z_{1j} Z_{2j} - n\bar{Z}_1 \bar{Z}_2}{\sqrt{\sum_{j=1}^n Z_{1j}^2 - n\bar{Z}_1^2} \sqrt{\sum_{j=1}^n Z_{2j}^2 - n\bar{Z}_2^2}} = \frac{Cov(Z_1 Z_2)}{\sqrt{Var(Z_1)}\sqrt{Var(Z_2)}}$$

La correlación de la primera variable, que está estandarizada, es 1, como se muestra a continuación:

$$R_{Z_1, Z_1} = \frac{\sum_{i=1}^n Z_{1j}^2 - n\bar{Z}_1^2}{\sqrt{\sum_{j=1}^n Z_{1j}^2 - n\bar{Z}_1^2} \sqrt{\sum_{j=1}^n Z_{2j}^2 - n\bar{Z}_2^2}} = \frac{Cov(Z_1 Z_2)}{\sqrt{Var(Z_1)}\sqrt{Var(Z_2)}}$$

$$R_{Z_1, Z_1} = \frac{Var(Z_1)}{Var(Z_1)} = \frac{1}{1} = 1$$

Para la variable 2 es lo mismo:

$$R_{Z_2, Z_2} = \frac{\sum_{i=1}^n Z_{2j}^2 - n\bar{Z}_2^2}{\sqrt{\sum_{j=1}^n Z_{2j}^2 - n\bar{Z}_2^2} \sqrt{\sum_{j=1}^n Z_{2j}^2 - n\bar{Z}_2^2}} = \frac{Cov(Z_2 Z_2)}{\sqrt{Var(Z_2)}\sqrt{Var(Z_2)}}$$

$$R_{Z_2, Z_2} = \frac{Var(Z_2)}{Var(Z_2)} = \frac{1}{1} = 1$$

Ahora se calcula la correlación entre las 2 variables:

$$R_{Z_1, Z_2} = \frac{\sum_{i=1}^n Z_{1j} Z_{2j} - n\bar{Z}_1 \bar{Z}_2}{\sqrt{\sum_{j=1}^n Z_{1j}^2 - n\bar{Z}_1^2} \sqrt{\sum_{j=1}^n Z_{2j}^2 - n\bar{Z}_2^2}} = \frac{Cov(Z_1 Z_2)}{\sqrt{Var(Z_1)}\sqrt{Var(Z_2)}}$$

$$R_{Z_1, Z_1} = \frac{Cov(Z_1 Z_2)}{\sqrt{Var(Z_1)}\sqrt{Var(Z_2)}} = \frac{-0.5404}{\sqrt{1}\sqrt{1}} = -0.5404$$

Con los 3 valores anteriores se construye la matriz de correlación, la cual quedaría de la siguiente forma:

$$R = \begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix}$$

Ahora se realiza la descomposición espectral, con la cual se hará que $R = A$, esto es la matriz de correlación es igual a la matriz que se expuso en la definición de la descomposición singular; se tiene lo siguiente:

A. Se calculan los valores propios (eigenvalor).

$$|A - \lambda I| = |R - \lambda I| = 0$$

Al sustituir los valores de $R = A$:

$$|R - \lambda I| = \left| \begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right| = 0$$

Se multiplica el eigenvalor por la matriz identidad:

$$\left| \begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right| = 0$$

se resta, recuerde que en sumas o restas la diferencia o la suma es término a término:

$$\left| \begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right| = \left| \begin{bmatrix} 1 - \lambda & -0.5404 \\ -0.5404 & 1 - \lambda \end{bmatrix} \right|$$

El siguiente paso es encontrar el determinante de la matriz obtenida e igualar a cero; como ya se mencionó, el determinante de una matriz de 2 por 2 es el producto de la diagonal principal menos el producto de la diagonal secundaria:

$$\left| \begin{bmatrix} 1 - \lambda & -0.5404 \\ -0.5404 & 1 - \lambda \end{bmatrix} \right| = (1 - \lambda)(1 - \lambda) - (-0.5404)(-0.5404) = 0$$

Al simplificar la expresión anterior se convirtió en una ecuación cuadrática, en la que se tienen que encontrar los valores de λ que satisfagan esa ecuación (o sea los valores que hagan que esa fórmula sea igual a cero):

$$1 - \lambda - \lambda + \lambda^2 - 0.292015 = \lambda^2 - 2\lambda + 0.707985 = 0$$

Ahora se resuelve la ecuación cuadrática para los eigenvalores:

Se sabe que si:

$$aX^2 + bX + c = 0$$

La siguiente fórmula se resuelve para X :

$$X = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

Al comparar las ecuaciones se encuentra que: $a = 1$, $b = -2$ y $c = 0.707985$, al sustituir esto en la expresión anterior se tiene:

$$\lambda = \frac{-(-2) \pm \sqrt{(-2)^2 - 4(1)(0.707985)}}{2(1)}$$

Al despejar se obtienen 2 valores:

$$\lambda_1 = 1.5404 \text{ y } \lambda_2 = 0.4596$$

Se tienen 2 variables, se construyó una matriz de correlación de dimensión 2×2 , se obtienen 2 eigenvalores; eso significa que si se tienen 3 variables la matriz de correlación será de 3×3 y que se obtendrán 3 eigenvalores, etcétera.

- B. Para encontrar los vectores propios (eigenvectores) se sustituyen los eigenvalores en la siguiente ecuación:

$$(R - \lambda I)\nu = (A - \lambda I)\nu = 0$$

$$(R - \lambda I)\nu = \left(\begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right) \begin{bmatrix} \nu_1 \\ \nu_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Esto se deberá realizar por cada eigenvalor y así se obtiene un eigenvector para cada valor propio; ahora hagamos la operación para λ_1 .

$$\begin{bmatrix} 1 - \lambda_1 & -0.5404 \\ -0.5404 & 1 - \lambda_1 \end{bmatrix} \begin{bmatrix} \nu_1 \\ \nu_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Se sabe que: $\lambda_1 = 1.5404$, al sustituir ese valor en la ecuación pasada:

$$\begin{bmatrix} 1 - 1.5404 & -0.5404 \\ -0.5404 & 1 - 1.5404 \end{bmatrix} \begin{bmatrix} \nu_1 \\ \nu_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Al resolver para el vector quedan las siguientes 2 ecuaciones; la primera es:

$$\begin{aligned} (1 - 1.5404)\nu_1 + (-0.5404)\nu_2 &= 0 \\ -0.5404\nu_1 - 0.5404\nu_2 &= 0 \\ -0.5404\nu_1 - 0.5404\nu_2 & \\ -\nu_1 &= \nu_2 \end{aligned}$$

y la segunda es:

$$\begin{aligned} (-0.5404)\nu_1 + (1 - 1.5404)\nu_2 &= 0 \\ -0.5404\nu_1 - 0.5404\nu_2 &= 0 \\ -0.5404\nu_1 - 0.5404\nu_2 & \\ -\nu_1 &= \nu_2 \end{aligned}$$

Las 2 ecuaciones anteriores son iguales, ahora hay que simplificar ya que resultarán iguales. Si se trata de resolver para ν_1 y ν_2 se le tiene que dar un valor a ν_1 para poder obtener el valor de ν_2 o viceversa; por ejemplo, si:

$$\nu_1 = 1 \Rightarrow \nu_2 = -1 \quad \therefore \text{ para } \lambda_1 = 1.5404 \text{ el } \nu_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Cualquier valor que se le dé a ν_1 será el mismo valor, pero en negativo para ν_2 , entonces dejémoslo de ese modo:

$$-\nu_1 = \nu_2$$

o lo que es lo mismo:

$$\lambda_1 = 1.5404 \text{ el } \nu_1 = \begin{bmatrix} \nu_1 \\ \nu_2 = -\nu_1 \end{bmatrix}$$

Del mismo modo se obtiene el eigenvector para el otro eigenvalor, ahora se sustituye el valor de λ_2 en la misma ecuación:

$$(R - \lambda I)\nu = (A - \lambda I)\nu = 0$$

$$(R - \lambda I)\nu = \left(\begin{bmatrix} 1 & -0.5404 \\ -0.5404 & 1 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right) \begin{bmatrix} \nu_3 \\ \nu_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Al simplificar queda:

$$\begin{bmatrix} 1 - \lambda_2 & -0.5404 \\ -0.5404 & 1 - \lambda_2 \end{bmatrix} \begin{bmatrix} v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Se sabe que $\lambda_2 = 0.4596$, al sustituir se tiene que:

$$\begin{bmatrix} 1 - 0.4596 & -0.5404 \\ -0.5404 & 1 - 0.4596 \end{bmatrix} \begin{bmatrix} v_3 \\ v_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Al despejar y resolver se tiene que:

$$\begin{aligned} (1 - 0.4596)v_3 + (-0.5404)v_4 &= 0 \\ 0.5404v_3 - 0.5404v_4 &= 0 \\ 0.5404v_3 - 0.5404v_4 &= 0 \\ v_3 &= v_4 \end{aligned}$$

Y lo mismo sucede para la segunda ecuación:

$$\begin{aligned} (-0.5404)v_3 + (1 - 0.4596)v_4 &= 0 \\ -0.5404v_3 + 0.5404v_4 &= 0 \\ -0.5404v_3 &= -0.5404v_4 \\ v_3 &= v_4 \end{aligned}$$

Si:

$$v_3 = 1 \Rightarrow v_4 = 1 \quad \therefore \text{ para } \lambda_2 = 0.4596 \text{ el } v_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Cualquier valor que se le dé a v_3 será el mismo valor y con el mismo signo para v_4 , entonces se deja de ese modo:

$$v_3 = v_4$$

o lo que es lo mismo:

$$\lambda_2 = 0.4596 \text{ el } v_2 = \begin{bmatrix} v_3 \\ v_4 = v_3 \end{bmatrix}$$

Ahora bien si se quiere que los eigenvectores sean ortogonales y además normalizados (es decir ortonormales) se tienen que dividir entre la norma del vector y si el vector tiene valores los valores anteriores de:

$$v_1 = 1 \Rightarrow v_2 = -1 \quad \therefore \text{ para } \lambda_1 = 1.5404 \text{ el } v_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$v_3 = 1 \Rightarrow v_4 = 1 \quad \therefore \text{ para } \lambda_2 = 0.4596 \text{ el } v_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Entonces se tiene que los vectores son:

$$v_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \text{ y } v_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Su norma es la raíz del vector transpuesto por el mismo vector:

$$||\nu_1|| = \sqrt{[1 \ -1] \begin{bmatrix} 1 \\ 1 \end{bmatrix}} = \sqrt{2} \text{ y para } ||\nu_2|| = \sqrt{[1 \ 1] \begin{bmatrix} 1 \\ 1 \end{bmatrix}} = \sqrt{2}$$

entonces los eigenvectores ortonormales quedarían de la siguiente manera:

$$\nu_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \text{ y } \nu_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

Con las eigenvalores y los eigenvectores se construye la matriz de factores no rotada. Para construirla deberá acomodar los eigenvalores y eigenvectores de la siguiente forma:

Matriz no rotada			
	F_1	F_2	Comunalidad
X_1	$\frac{1}{\sqrt{2}}$	$\frac{1}{\sqrt{2}}$	1
X_2	$-\frac{1}{\sqrt{2}}$	$\frac{1}{\sqrt{2}}$	1
Eigenvalor	$\lambda_1 = 1.5404$	$\lambda_2 = 0.4596$	2

Este sería el primer vector para un valor propio de 1.5404
 Este sería el segundo vector para un valor propio de 0.4596

Ahora bien la comunalidad y los eigenvalores se obtienen con la suma de cuadrados de los renglones y de las columnas, respectivamente, esto es:

$$\text{Comunalidad}(X_1) = \left(\frac{1}{\sqrt{2}}\right)^2 + \left(\frac{1}{\sqrt{2}}\right)^2 = 1$$

$$\text{Comunalidad}(X_2) = \left(-\frac{1}{\sqrt{2}}\right)^2 + \left(\frac{1}{\sqrt{2}}\right)^2 = 1$$

El valor que se ha encontrado sí coincide con el que se tiene en la columna, pero el eigenvalor tendría el valor de 1:

$$\text{Eigenvalor}(F_1) = \left(\frac{1}{\sqrt{2}}\right)^2 + \left(-\frac{1}{\sqrt{2}}\right)^2 = 1 \neq 1.5404$$

$$\text{Eigenvalor}(F_2) = \left(\frac{1}{\sqrt{2}}\right)^2 + \left(\frac{1}{\sqrt{2}}\right)^2 = 1 \neq 0.4596$$


Entonces se deberá darles valores diferentes a: ν_1 , ν_2 , ν_3 y ν_4 , hasta que coincidan los valores de la comunalidad y los eigenvalores, por razones obvias se pondrán sólo los correctos:

Matriz no rotada			
	F_1	F_2	Comunalidad
X_1	-0.878	0.497	1
X_2	0.878	0.497	1
Eigenvalor	1.5404	0.4596	2

Generalmente el eje de las abscisas corresponde a F_1 y el eje de las ordenadas es para F_2 , pero podría ser al revés.


Al graficar la tabla anterior, los ejes son los factores y se grafican X_1 y X_2 , según las coordenadas que tengan en F_1 y F_2 :

Las coordenadas de X_1 son $(-0.878, 0.497)$ y las coordenadas de X_2 son $(0.878, 0.497)$




Rotación de factores


Al rotar los factores (sólo los ejes se rotan, ya que las variables quedan exactamente en el lugar donde se graficaron) se encontrarán los valores en los ejes para las variables, con esto queda construida la matriz de factores rotada. Una vez graficada la no rotada, se rotan los ejes, los ejes no deberán despegarse del origen; los ejes pueden rotar a la izquierda, a la derecha, hacia arriba o hacia abajo (la rotación depende del software que se utilice), al rotar dichos ejes tendrán que estar lo más cerca de todos los puntos, o sea cerca de X_1 y X_2 para obtener la matriz de factores rotada.



Supóngase que se rota hacia la izquierda, es decir, al contrario de las manecillas del reloj:




Es bien importante recordar que se mueven los ejes de la gráfica no las variables; al rotar los factores o ejes se obtiene la matriz de factores rotada:



Gráfica de la rotación de ejes o gráfica de la rotada

Para construir la matriz rotada se deberá ver qué coordenadas corresponden a cada variable en cada factor, esto gráficamente es bastante difícil, como se puede observar:



Gráfica de la rotación de ejes

Con esto se buscan los valores para construir la matriz rotada. Los valores que se obtienen de la gráfica se colocan en la matriz rotada y vuelven a calcularse los eigenvalores y el porcentaje de variación explicada; lo que sí es cierto es que el total de la comunalidad y la comunalidad de cada variable deberán coincidir, es decir deberán ser iguales a los valores calculados en la no rotada.

Matriz rotada			
	F_1	F_2	Comunalidad
X_1	-0.31	0.95	1
X_2	0.95	-0.31	1
Eigenvalores	1.00	1.00	2

Obviamente esto se vuelve más complicado cuando se aumenta el número de variables, ya que si son 3 variables se necesitan encontrar 3 eigenvalores y 3 eigenvectores, si se tienen 4 se buscarán 4 de todo y así sucesivamente.

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 4

Análisis de conglomerados

Objetivo general:

Entender y aplicar los conceptos del análisis de conglomerados en situaciones del área administrativa.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Explicar el análisis de conglomerados.
- Especificar los problemas básicos del análisis de conglomerados.
- Conocer el concepto de *similitud*.
- Definir matemáticamente las medidas de distancia y explicar su significado.
- Describir matemáticamente las medidas de similitud y explicar su significado.
- A partir de una matriz de distancia (o similitud), determinar qué objetos o variables son más parecidos o menos parecidos, en un ejemplo administrativo.
- Explicar en qué consisten las técnicas de agrupamiento jerárquico, aglomerativo y divisional.
- Conocer y diferenciar las técnicas de eslabonamiento simple, completo y promedio.
- Definir el término *dendograma*.
- Aplicar el método jerárquico aglomerativo y cada una de las técnicas de eslabonamiento a un problema del área, representando la agrupación realizada en el dendograma.
- Explicar en qué consiste la técnica de agrupamiento no jerárquico y diferenciarlo del jerárquico.
- Describir las aplicaciones del análisis de agrupamiento.

4.1 Antecedentes

En los últimos años, la importancia del análisis multivariante se ha acrecentado en gran medida debido a que se utiliza comúnmente en diversos campos como: la industria, el gobierno, centros universitarios y de investigación. El análisis multivariante permite resolver problemas y ayuda en la toma de decisiones con un enfoque analítico sobre todas las variables que llegan a influir en el o los problemas en cuestión.

Análisis de conglomerados. Técnica del grupo estructural que tiene por objeto resumir información.

Análisis de conglomerados. Técnica que sirve para clasificar en grupos o categorías.

Clasificación. Es uno de los procesos fundamentales de la ciencia que ordena los fenómenos para poderlos entender.

El **análisis de conglomerados** es una técnica del grupo estructural,¹ el cual tiene por objeto resumir información; en este análisis todas las variables son consideradas independientes, trabaja con variables medidas en escala de intervalo, de razón y nominales convertidas a *dummy*;² para realizar este análisis las variables deberán ser o todas en escala de intervalo y de razón o todas *dummy*, esto es, no se pueden manejar en un mismo análisis diferentes tipos de escalas.

El análisis de conglomerados se aplica básicamente para la segmentación de mercados y su propósito es la formación de grupos o conglomerados de individuos o de objetos similares, ya que busca formar grupos lo más homogéneos posible entre sí; es decir, al comparar los elementos que conforman un grupo deberán ser tan parecidos como sea posible, y lo más heterogéneos al compararse un grupo con otro.

El término **análisis de conglomerados** fue utilizado por primera vez por Tryon en 1939; a esta técnica también se le conoce como *análisis de agrupamiento*, *análisis de segmentación de datos* o *cluster analysis*, por su nombre en inglés, y tiene sus inicios en la biología al clasificar diferentes especies en grupos homogéneos. Para Sokal y Sneath (1963), dos autores que han sobresalido en el estudio de esta técnica, la **clasificación** es uno de los procesos fundamentales de la ciencia, ya que los fenómenos deben ser ordenados para que se puedan entender.

Tanto el análisis de conglomerados como el análisis discriminante sirven para clasificar a individuos u objetos en grupos o categorías, la diferencia principal entre ellos es que en el análisis discriminante se conoce *a priori* el grupo de pertenencia y en el análisis de agrupamiento se forman dichos grupos.

4.2 Áreas de aplicación

El análisis de conglomerados se puede utilizar en muchas áreas, por ejemplo, en la medicina se pueden agrupar padecimientos o síntomas y encontrar un remedio para un grupo de pacientes. En psiquiatría el diagnóstico correcto de enfermedades como paranoia o esquizofrenia. Esto es esencial para definir la terapia a aplicar.

El análisis de conglomerados también es ampliamente utilizado en mercadotecnia para encontrar segmentos de mercado y dirigir una publicidad acertada a dicho segmento o encontrar nichos para la venta de un producto. En economía se podría utilizar para agrupar países dependiendo de sus recursos económicos o naturales, etcétera.

Definitivamente existe mucho campo de acción para esta técnica, pues la formación de grupos en una población facilita el análisis.

4.3 Decisiones a tomar

En el análisis de conglomerados se deben tomar varias decisiones, las cuales enlistamos a continuación:

1. Observar lo que rodea a los posibles grupos.
2. Seleccionar las variables para identificar a los grupos.
3. Definir la medida de proximidad.
4. Elegir el método a aplicar.
5. Determinar la técnica o criterio para agrupar individuos en conglomerados.

4.4 Pasos a seguir en un análisis de conglomerados

Para llevar a cabo el análisis de conglomerados es necesario seguir ciertos pasos, los cuales se muestran en la figura 4-1.

¹ También llamadas *independientes*.

² En una variable *dummy* se registra la ausencia y la presencia de lo que se desea evaluar.




Figura 4-1 Pasos del análisis de conglomerados.

4.4.1 Observación de lo que rodea a los posibles grupos

Antes de iniciar un análisis de conglomerados se debe observar si los objetos o las personas que se agruparán lo pueden hacer en forma natural, si no, sería inútil tratar de agruparlos.

4.4.2 Selección de las variables

La selección de las variables es muy importante, pues son decisivas para un óptimo agrupamiento de los individuos, de acuerdo con el objetivo que se pretende alcanzar; si éstas no se seleccionan con cuidado, la investigación corre el riesgo de no tener sentido. Los datos pueden medirse en escala de intervalo, en escala de razón, datos de frecuencia o utilizar datos dicotómicos para las características.



Figura 4-2 Tipos de datos para la entrada del análisis de conglomerados.

4.4.3 Definir la medida de proximidad

Proximidad. Grado de similitud o diferencia que existe entre parejas de individuos, objetos y variables.

La **proximidad** expresa el grado de similitud o diferencia que existe entre parejas de individuos, objetos y variables; como se muestra en la figura 4-3, dichas proximidades son de dos tipos: disimilares y similares.




Figura 4-3 Tipos de proximidades.

Disimilaridad. Las proximidades se interpretan en términos de lo diferente.

Cuando las proximidades se interpretan en términos de lo diferente se habla de **disimilaridad**; cuando se expresan por lo parecido se refieren a **similitud**.

El análisis de conglomerados utiliza medidas de similitud o disimilaridad entre los objetos o individuos que se agruparán; la diferencia está en su interpretación, ya que:

- Cuanto más pequeño es el valor de una medida de disimilaridad, más parecidos son dos objetos.
- Cuanto más grande es el valor de una medida de similitud, más parecidos son.

Para seleccionar la medida de proximidad se debe tomar en cuenta:

1. el tipo de datos con que se cuenta,
2. posteriormente el tipo de proximidad que se desea manejar, es decir, disimilaridad o similitud;
3. por último se escoge la medida que se desea utilizar.

Estos pasos que se acaban de enumerar se muestran en la siguiente figura:




Figura 4-4 Tipos de datos y posibles proximidades a encontrar.

Por ejemplo, si se agrupa por medio de frecuencias, lo único que se puede encontrar son disimilitudes ya sea por ji cuadrada o por la medida de phi cuadrado; otro ejemplo sería si se tiene información métrica y se desean encontrar similitudes lo adecuado sería utilizar el coeficiente de Pearson o la medida de cosenos.

Una vez que ya se decidió qué medida utilizar lo que procede es usar la fórmula adecuada, según sea el caso, y encontrar las proximidades.

4.4.4 Medidas de distancia, disimilaridad o desemejanza

Para comprender por qué la medida de distancia puede representar lo parecido, se usará el siguiente ejemplo: supóngase que se tiene el ingreso y la edad de 15 individuos y se desea evaluar su parecido. La información se presenta en la siguiente gráfica:




Figura 4-5 Gráfica del ingreso y la edad que tienen 15 individuos.

En forma *a priori* note que en la figura 4-6 existen 3 grupos de personas debido a los diferentes ingresos y edades; si se tratara de ver el perfil de cada conglomerado (grupo o *cluster*), en la figura 4-6 se ve que el grupo con 4 elementos está formado por personas que tienen poco ingreso y baja edad, mientras que el grupo con 6 unidades tiene mucha edad y un ingreso medio; por el contrario, el grupo que cuenta con 5 elementos tiene mucho ingreso y una edad promedio.




Figura 4-6 Gráfica de los 3 segmentos a encontrar.

Hasta aquí esto parece muy sencillo, pero qué pasaría si uno de los individuos estuviera algo alejado de todos los grupos, la pregunta sería ¿con quién se agruparía?, esto se muestra en la figura 4-7.




Figura 4-7 Gráfica del ingreso y la edad de otros 15 individuos.

Se tendría que evaluar la distancia que existe entre cada individuo de los 3 grupos con el elemento aislado y así escoger la distancia más pequeña; en la figura 4-8 se muestran sólo algunas de las distancias que son necesarias encontrar para saber en qué grupo deberá quedar.




Figura 4-8 Muestra de sólo algunas distancias que deberán encontrarse.

A continuación se explicará una de las medidas de distancia. Supóngase que se tiene la información de la edad a la cual se dio inicio un cierto tratamiento y la edad al finalizar éste, la información se presenta a continuación en la figura 4-9.




Figura 4-9 La edad de 15 individuos al inicio y al finalizar un tratamiento

En la figura 4-9 se muestran 15 individuos, pero solamente se analizarán 2 de ellos como se puede observar en la figura 4-10.




Figura 4-10 Sólo 2 observaciones.

Para encontrar la distancia que existe entre las 2 personas considere la siguiente figura en la que se eliminaron las etiquetas y se coloca la información de esas personas; la evaluación de esa distancia es sencilla, si se ve la siguiente figura, en la que se eliminaron las etiquetas y se pone la información que se tiene de esas 2 personas:




Figura 4-11 Información disponible de las 2 personas.

Al observar la figura anterior se sabe que la persona 1 tenía 20 años al empezar el estudio y la persona 2 tenía 50 años, y al terminar el estudio tenían 40 y 60 años, respectivamente; si todas las flechas se eliminan y sólo se dejan los corchetes y se reemplazan por medio de líneas se tiene la siguiente figura.




Figura 4-12 La figura que se forma es de un triángulo.

La figura 4-12 muestra un triángulo; al aplicarle el teorema de Pitágoras se encuentra la distancia correspondiente entre las 2 personas:

Ecuación 4-1 Teorema de Pitágoras

$$(CO)^2 + (CA)^2 = H^2$$

donde:

H es la hipotenusa y en este caso es la distancia que se desea encontrar.

CO es el cateto opuesto y en este caso es la distancia que se tiene de la variable edad al finalizar el estudio.

CA es el cateto adyacente y en este problema es la distancia que se tiene de la variable edad al iniciar el estudio.

Al despejar la hipotenusa se tiene que:

Ecuación 4-2 Teorema de Pitágoras donde se despejó la hipotenusa

$$H = \sqrt{(CO)^2 + (CA)^2}$$

Al sustituir los valores se tiene que:

Ecuación 4-3 Al sustituir las coordenadas de las 2 personas en el teorema de Pitágoras

$$D_{1,2} = \sqrt{(60 - 40)^2 + (50 - 20)^2} = 36.06$$

Se puede concluir que la distancia que existe entre los 2 sujetos es de 36.06 años. Cuando sólo se tienen 2 dimensiones con las mismas unidades se puede utilizar el teorema de Pitágoras; cuando existen 2 o más variables con o sin las mismas unidades se utiliza la fórmula de la distancia euclidiana, siempre y cuando las variables se hayan medido en escalas de intervalo o razón.

Cuando las variables se miden en escalas de intervalo o de razón se utilizan medidas de distancia o de disimilitud para evaluar lo parecido que son las personas u objetos y así agruparlos.

Las medidas de disimilitudes métricas más comunes se presentan a continuación:

Nombre	Medida de disimilitud métrica
Ecuación 4-4 Distancia euclidiana	$d_{ij} = \left[\sum_{k=1}^r (X_{ik} - X_{jk})^2 \right]^{\frac{1}{2}}$
Ecuación 4-5 Distancia euclidiana al cuadrado	$d_{ij}^2 = \sum_{k=1}^r (X_{ik} - X_{jk})^2$
Ecuación 4-6 Distancia de Chebychev	$C_{ij} = \text{Máx} X_{ik} - X_{jk} $
Ecuación 4-7 Distancia de Mahalanobis (sólo matricialmente)	$d_{ij} = [(X_i - X_j)^T \sum^{-1} (X_i - X_j)]^{\frac{1}{2}}$ y cuando se compara con el centroide sería: $d_{ij} = [(X_i - X_k)^T \sum^{-1} (X_i - X_k)]^{\frac{1}{2}}$
Ecuación 4-8 Distancia de Manhattan o <i>city block</i> métrica	$d_{ij} = \sum_{k=1}^r X_{ik} - X_{jk} $
Ecuación 4-9 Distancia de Minkowski métrica	$d_{ij} = \left[\sum_{k=1}^r X_{ik} - X_{jk} ^\lambda \right]^{\frac{1}{\lambda}} \lambda \geq 1$
Ecuación 4-10 Distancia en un poder métrico absoluto	$d_{ij} = \left[\sum_{k=1}^r X_{ik} - X_{jk} ^\rho \right]^{\frac{1}{\rho}}$

La d_{ij} es la distancia que se encuentra entre el objeto i y el objeto j , por ejemplo, se tiene $d_{4,5}$ es la distancia entre el objeto 4 y el objeto 5; cuando dicha distancia es cero quiere decir que no hay diferencia entre esos objetos; una distancia muy pequeña significa que los objetos o las personas que se comparan son parecidos y una distancia grande significa que son muy diferentes. El X_{ik} es el valor que tiene el objeto i en la variable k y el X_{jk} es el valor que tiene el objeto j en la variable k ; por ejemplo si se tiene $X_{ik} - X_{jk} = X_{4,8} - X_{5,8}$ es la evaluación que posee en la variable 8 los objetos o personas 4 y 5, mientras que r , que se utiliza en la fórmula de la distancia euclidiana, representa el número de variables. Al utilizar estas medidas, se obtendrán distancias o disimilaridades.

Ahora se verán las medidas de similaridad métricas:

Nombre	Medida de similaridad métrica
Ecuación 4-11 Coseno	$\text{Cos}_{ij} = \frac{\sum_{k=1}^r X_{ik} X_{jk}}{\left[\sum_{k=1}^r X_{ik}^2 \sum_{k=1}^r X_{jk}^2 \right]^{\frac{1}{2}}}$
Ecuación 4-12 Correlación de Pearson	$R_{ij} = \frac{\sum_{k=1}^r (X_{ik} - \bar{X}_k)(X_{jk} - \bar{X}_k)}{\left[\sum_{k=1}^r (X_{ik} - \bar{X}_k)^2 \sum_{k=1}^r (X_{jk} - \bar{X}_k)^2 \right]^{\frac{1}{2}}}$

La R_{ij} es la correlación y el Cos_{ij} es el coseno encontrado entre el objeto i y el objeto j ; es decir, si por ejemplo se tiene $R_{3,5}$ es la correlación entre el objeto 3 y el objeto 5; cuando esa correlación es cero quiere decir que no existe relación o parecido entre dichos objetos, por lo que siempre que el objeto i sea igual al objeto j la correlación y el coseno será de 1; una correlación y un coseno muy pequeño significa que los objetos que se comparan son poco parecidos, mientras que una correlación y coseno grande significa que son muy similares. El X_{ik} es la evaluación que posee el objeto i en la variable k y el X_{jk} es la evaluación que tiene el objeto j en la variable k ; por ejemplo, si se tiene $X_{ik} - \bar{X}_k = X_{3,6} - \bar{X}_6$ es la evaluación que posee en la variable 6 la persona 3 y r , que se utiliza en la fórmula del coseno, es el número de variables. Al utilizar estas medidas, se forman similaridades o semejanzas.

En la siguiente tabla se verán las medidas de frecuencia:

Nombre	Medidas de frecuencia
Ecuación 4-13 Ji cuadrada	$\chi_{ij}^2 = \sqrt{\sum_{k=1}^r \frac{[X_{ik} - E(X_k)]^2}{E(X_k)} + \sum_{k=1}^r \frac{[X_{jk} - E(X_k)]^2}{E(X_k)}}$
Ecuación 4-14 Phi cuadrado	$\Phi_{ij}^2 = \sqrt{\frac{\sum_{k=1}^r \frac{[X_{ik} - E(X_k)]^2}{E(X_k)} + \sum_{k=1}^r \frac{[X_{jk} - E(X_k)]^2}{E(X_k)}}{N}}$

La χ_{ij}^2 es la ji cuadrada y Φ_{ij}^2 es el coeficiente phi cuadrado encontrado entre el objeto i y el objeto j , es decir, si por ejemplo, se tiene χ_{23}^2 es la correlación entre el objeto 2 y el objeto 3; cuando dicho valor es cero quiere decir que los objetos se parecen, ya que la frecuencia observada $[X_{ik}]$ y la frecuencia esperada $[E(X_k)]$ son iguales; por lo tanto, esto debe interpretarse en forma similar a una medida de desemejanza; un coeficiente muy pequeño significa que los objetos que se comparan son muy parecidos, mientras que un coeficiente grande significa que los objetos son muy diferentes. El X_{ik} es la evaluación que tiene el objeto i en la variable k y el $E(X_k)$ es el valor esperado o valor promedio de la variable k ; por ejemplo, si se tiene $X_{ik} - E(X_k) = X_{3,6} - E(X_6)$ es la evaluación que tiene el objeto 3 en la variable 6 y su promedio en dicha variable, mientras que r , que se utiliza en las fórmulas de ji y phi cuadrados, representa el número de variables.

Cuando se realiza un análisis de conglomerados por distancia se debe tener en cuenta que las variables utilizadas en la técnica son por lo general actitudes, opiniones, características demográficas

o correlaciones entre objetos o personas, por lo que todas estas variables deben estandarizarse previamente.

Por ejemplo, supongamos que se analizan 3 marcas en el mercado cuyos perfiles se determinan a través de 6 características, los cuales se representan en la siguiente gráfica:




Figura 4-13 Gráfica de 3 marcas con 6 características.

La proximidad entre las marcas 2 y 3 llevan a la conclusión de que dichos objetos son muy parecidos, a diferencia del objeto 1 que por su separación o distancia hace que la marca 1 sea la menos similar. La conclusión de esta gráfica se realiza casi visualmente, aunque para cuantificar la distancia entre las personas u objetos existen las opciones mencionadas anteriormente.

4.4.5 Medidas de similitud, similaridad o semejanza

Otra medida con la que se puede evaluar lo parecido que son las personas u objetos para así agruparlos es la similitud. Ésta se utiliza principalmente cuando se manejan variables binarias que se caracterizan por tener sólo 2 posibles estados o categorías, por ejemplo:

- Hombre-mujer.
- Sí compra-no compra.
- Sí ve televisión-no ve televisión.

En la matriz de datos las 2 primeras variables se codifican a menudo con 1 y 2; para convertirlas a variables *dummy* en este análisis se deberán codificar como:

- 1: se usa para marcar la presencia del atributo a medir, por ejemplo si en esta parte se quiere codificar a los “hombres” con 1, entonces a esta categoría se le asigna la presencia; en el caso de los compradores se podría codificar a “sí compra” con 1.
- 0: se utiliza para medir la ausencia del atributo; si la codificación del 1 fue para “hombres” el 0 corresponde a las “mujeres” y a “no compra”.

A este tipo de variables se les llamaría *dummy* y con base en la presencia o ausencia de atributos en los objetos puede establecerse la similitud existente.

Al contabilizar las semejanzas entre 2 objetos y al considerar p características binarias se forma una tabla de contingencia de tamaño 2×2 que se presenta de la siguiente forma:

Tabla 4-1 Nomenclatura a utilizar en los coeficientes de similitud

Respuesta de los objetos		Objeto <i>i</i>		Total
		1	0	
Objeto <i>j</i>	1	<i>a</i>	<i>b</i>	<i>a + b</i>
	0	<i>c</i>	<i>d</i>	<i>c + d</i>
Total		<i>a + c</i>	<i>b + d</i>	<i>p = a + b + c + d</i>

En ella cada letra representa lo siguiente:

- a*: son las características presentes al comparar el objeto *i* con el objeto *j*, comúnmente denominadas *la presencia*.
- b*: son las características ausentes en el objeto *i* y presentes en el objeto *j*; en este caso no se parecen los objetos ya que en uno está ausente y en el otro está presente y forma parte de las diferencias.
- c*: son las características ausentes en el objeto *j* y presentes en el objeto *i*; también en este caso no se parecen los objetos ya que en uno está ausente y en el otro está presente y forma parte de las diferencias.
- d*: son las características ausentes en ambos objetos, tanto en el *i* como en el *j*, comúnmente denominadas *ausencias* y forman parte de las semejanzas, ya que se parecen porque en ambos objetos se encuentran ausentes los atributos.
- p*: es el total de las características que serán evaluadas (*a + b + c + d*).
- a + d*: juntos representan lo parecido, ya que en ambos están tanto las características presentes como las ausentes de ambos objetos.
- b + c*: juntos se les denomina *lo diferente* o *las diferencias*, ya que ambos objetos no se parecen porque en uno las características están presentes y en el otro están ausentes.

Ahora bien, se tienen las siguientes figuras:




Figura 4-14 Objetos a comparar.

En los objetos anteriormente mostrados se evaluarán los siguientes atributos:

- ¿Es de color verde? Sí ____ No ____
- ¿Tiene cuadrados? Sí ____ No ____
- ¿Tiene triángulos? Sí ____ No ____
- ¿Tiene círculos? Sí ____ No ____
- ¿Tiene corazones? Sí ____ No ____

La codificación de las preguntas sería 1 cuando esté presente el atributo, es decir, si se contestó “Sí” y 0 cuando esté ausente el atributo, si se respondió “No”.

La comparación tiene que hacerse por parejas, es decir, suponga que se están comparando el objeto 3 y el 5, imagine que el objeto 3 sea la *i* y el 5 sea el objeto *j*; la respuesta a cada pregunta se presenta a continuación:

Tabla 4-2 Comparación entre el objeto 3 y el objeto 5

Pregunta a ser evaluada	Objeto 3		Objeto 5		Letra
	Respuesta	Codificación	Respuesta	Codificación	
1. ¿Es de color verde?	No	0	No	0	<i>d</i>
2. ¿Tiene cuadrados?	Sí	1	No	0	<i>b</i>
3. ¿Tiene triángulos?	Sí	1	Sí	1	<i>a</i>
4. ¿Tiene círculos?	Sí	1	Sí	1	<i>a</i>
5. ¿Tiene corazones?	No	0	Sí	1	<i>c</i>

Inicialmente se sabe que $p = 5$ ya que es el número de variables (que equivale al número de preguntas). En la tabla anterior el “color verde” no lo tiene el objeto 3 ni el 5, por lo tanto la respuesta en ambos es “No”; codificando esto se tienen 0 para el objeto 3 y 0 para el 5, por lo tanto al volver a la nomenclatura de las similitudes que se encuentran en la tabla 4-1, significa 0 y 0 está representado en la columna “Letra” por una “d”, y el procedimiento sigue hasta completar todas y cada una de las comparaciones.

Posteriormente se contabilizan las letras para saber la frecuencia que se observó en cada una de ellas:

$$a = 2, b = 1, c = 1 \text{ y } d = 1$$

Los valores que se acaban de encontrar son utilizados para sustituirlos en alguno de los coeficientes de similitud que a continuación se describen:

Nombre	Medida de similaridad binaria
Ecuación 4-15 Russell y Rao	$RR_{ij} = \frac{a}{p} = \frac{a}{a + (b + c) + d}$
Ecuación 4-16 Parejas Simples	$PS_{ij} = \frac{a + d}{p} = \frac{a + d}{a + (b + c) + d}$
Ecuación 4-17 Jacard	$J_{ij} = \frac{a}{a + (b + c)}$
Ecuación 4-18 Czekanowski-Sorensen-Dice	$D_{ij} = \frac{2a}{2a + (b + c)}$
Ecuación 4-19 Sokal y Sneath 1	$SS_{1ij} = \frac{2(a + d)}{2(a + d) + (b + c)}$
Ecuación 4-20 Rogers y Tanimoto	$RT_{ij} = \frac{a + d}{(a + d) + 2(b + c)}$
Ecuación 4-21 Sokal y Sneath 2	$SS_{2ij} = \frac{a}{a + 2(b + c)}$
Ecuación 4-22 Kulezynski 1	$K_{1ij} = \frac{a}{b + c}$
Ecuación 4-23 Sokal y Sneath 3	$SS_{3ij} = \frac{a + d}{b + c}$
Ecuación 4-24 Hamman	$H_{ij} = \frac{a - (b + c) + d}{(a + d) + (b + c)}$
Ecuación 4-25 Kulezynski 2	$K_{2ij} = \frac{a / (a + b) + a / (a + c)}{2}$

(continúa)

(continuación)

Nombre	Medida de similitud binaria
Ecuación 4-26 Sokal y Sneath 4	$SS_{Aij} = \frac{a / (a + b) + a / (a + c) + d / (b + d) + d / (c + d)}{4}$
Ecuación 4-27 D de Anderbeg	$D_{ij} = \frac{\max(a, b) + \max(c, d) + \max(a, c) + \max(b, d) - \max(a + c, b + d) - \max(a + b, c + d)}{2(a + b + c + d)}$
Ecuación 4-28 Y de Yule	$Y_{ij} = \frac{\sqrt{ad} - \sqrt{bc}}{\sqrt{ad} + \sqrt{bc}}$
Ecuación 4-29 Q de Yule	$Y_{ij} = \frac{ad - bc}{ad + bc}$
Ecuación 4-30 Ochiai	$O_{ij} = \frac{a}{\sqrt{(a + b)(a + c)}}$
Ecuación 4-31 Sokal y Sneath (medida 5)	$SSS_{ij} = \frac{ad}{\sqrt{(a + b)(a + c)(b + d)(c + d)}}$
Ecuación 4-32 Coeficiente de correlación phi	$\Phi_{ij} = \frac{ad - bc}{(a + b)(a + c)(b + d)(c + d)}$
Ecuación 4-33 Dispersión	$D_{ij} = \frac{ad - bc}{(a + b + c + d)^2}$
Ecuación 4-34 Varianza disimilar	$V_{ij} = \frac{b + c}{4(a + b + c + d)}$
Ecuación 4-35 Distancia euclidiana binaria	$EB_{ij} = \sqrt{b + c}$
Ecuación 4-36 Distancia euclidiana binaria al cuadrado	$EB_{ij}^2 = b + c$
Ecuación 4-37 Diferencia de tamaño	$T_{ij} = \frac{(b - c)^2}{(a + b + c + d)^2}$
Ecuación 4-38 Diferencia de patrón	$P_{ij} = \frac{bc}{(a + b + c + d)^2}$
Ecuación 4-39 Diferencia no métrica binaria de Lance y Williams	$LW_{ij} = \frac{b + c}{2a + b + c}$
Ecuación 4-40 Diferencia binaria de forma	$DBF_{ij} = \frac{(a + b + c + d)(b + c) - (b - c)^2}{(a + b + c + d)^2}$

4.4.6 Selección del criterio para reunir a individuos en grupos

El análisis de conglomerados tiene por objetivo formar grupos o segmentos de personas, objetos (como marcas, productos, servicios etc.) o variables (aunque no es común) lo más parecidos posibles dentro de cada grupo y lo más diferentes al compararse entre grupos. El análisis de conglomerados se divide como indica la figura 4-15:




Figura 4-15 Tipos de métodos del análisis de conglomerados.

La diferencia entre ellos estriba en que, basándose en las proximidades, el jerárquico se realiza en forma ordenada al agrupar de lo más parecido a lo menos parecido y en el no jerárquico el agrupamiento se realiza en forma arbitraria. A continuación se verá cada uno por separado.

4.5 Métodos jerárquicos

Hasta el momento se ha hablado solamente de lo parecido que son los objetos o personas con base en medidas de similitud o distancia; sin embargo, no se ha tratado el procedimiento mediante el cual puedan agruparse basándose en su semejanza; en este apartado se tratará precisamente el algoritmo a seguir para formar grupos de personas u objetos similares entre sí, el cual es conocido como **método jerárquico**. Como muestra la figura 4-16, el método jerárquico se subdivide en:

Método jerárquico.
Algoritmo que se sigue para formar grupos de personas u objetos similares entre sí.




Figura 4-16 Tipos de agrupamiento jerárquico.

La subdivisión del jerárquico aglomerativo y del jerárquico divisional se basa en las semejanzas que hay entre los objetos, dependiendo del criterio que se use para agruparlos o unirlos. Como es lógico, lo esperado es tener como solución mínima a todos los objetos o personas en un grupo y como solución máxima un grupo para cada entidad o elemento. A continuación se detallan las 2 formas de agrupamiento.

4.5.1 Método jerárquico aglomerativo

El método jerárquico aglomerativo inicia suponiendo que cada uno de los elementos que se pretende agrupar constituye un grupo, es decir, se tienen tantos grupos como objetos o personas a agrupar. Basándose en lo parecido que son los objetos se fusionan hasta unir todos los elementos en un solo grupo. De ahí el nombre de este método;³ lo anterior se muestra en la siguiente figura:




Figura 4-17 Técnica aglomerativa.

³ El término *aglomerativo* significa que tiene muchos grupos, éstos se unen hasta formar un todo.

4.5.2 Método jerárquico divisional

El **método jerárquico divisional** trabaja a la inversa, supone que existe en un principio un solo grupo que contiene a todos los objetos y basándose en las diferencias los separa hasta terminar con tantos grupos como objetos se tienen. De ahí su nombre de divisional.⁴

Método jerárquico divisional. Supone que existe un solo grupo que contiene a todos los objetos y basándose en las diferencias los separa hasta terminar con tantos grupos como objetos se tienen.




Figura 4-18 Técnica divisional.

En este apartado es donde la quinta decisión de la que se habló al inicio del capítulo debe ponerse en práctica, la cual consiste en elegir el método de eslabonamiento o vinculación. Al agrupar los elementos parecidos por parejas quedan otros que no se han agrupado; por ejemplo, supongamos que se tienen 3 elementos a agrupar, los cuales son:

U, V y W.

Si U y V son los más parecidos, entonces éstos se deberán agrupar y formar un nuevo grupo al cual se le denominará “U, V”. El siguiente paso es evaluar qué tan parecidos son estos grupos (U, V) con W, al comparar y decidir con base en el criterio de eslabonamiento o vinculación. Lo anterior se muestra en la siguiente figura:




Figura 4-19 Proceso de agrupar y eslabonar o vincular.

En la figura anterior las flechas en ambos sentidos indican que se están comparando entre todos para escoger el próximo segmento a formar, los paréntesis significan que esos elementos se unieron para formar un nuevo grupo.

Para evaluar todo lo anterior, es decir, lo parecido que llega a ser una pareja de objetos o un grupo con los restantes elementos que no se han fusionado se utilizan los llamados *criterios de eslabonamiento*.

La figura 4-20 da una visión más clara sobre los métodos de agrupamiento jerárquico que existen y los criterios de eslabonamiento que se pueden aplicar:

⁴ De un todo se fraccionan las partes.




Figura 4-20 Tipos de técnicas y eslabonamientos en los métodos jerárquicos.

4.6 Criterios de eslabonamiento

Eslabonamiento.

Consiste en volver a establecer el grado de parecido de un nuevo grupo con el resto de los elementos.

El **eslabonamiento** consiste en volver a establecer el grado de parecido de un nuevo grupo con el resto de los elementos. Existen varias formas o criterios para volver a establecer ese grado de parecido. A continuación se describen cada uno de estos criterios y se comentan sus ventajas y desventajas como apoyo en la decisión del método apropiado.

Nota: Para la terminología que se utilizará a continuación se sigue el ejemplo de los elementos U, V y W, que fueron explicados en la figura 4-18, de los cuales ya se unieron (U, V), y se pretende evaluar el parecido con W.

4.6.1 Promedio entre grupos (*between-groups linkage*)

Promedio entre grupos. Define la distancia entre 2 grupos como el promedio de las distancias entre todas las combinaciones posibles por parejas, al combinar todos los grupos, en los cuales un miembro del par pertenece a cada uno de los grupos formados anteriormente.

El **promedio entre grupos** (*between-groups linkage*) define la distancia entre 2 grupos como el promedio de las distancias entre todas las combinaciones posibles por parejas, al combinar todos los grupos, en los cuales un miembro del par pertenece a cada uno de los grupos formados anteriormente. Por ejemplo, si en el grupo 1 están las personas A, B y C; en el grupo 2 están las personas D, E y F, la distancia del grupo 1 y 2 será la media de las distancias AD, AE, AF, BD, BE, BF, CD, CE, CF. Este método utiliza por tanto todas las distancias entre los pares de datos. Lo interesante de este método es que tanto en disimilaridad como en similaridad se utiliza el mismo criterio, cuya ecuación es:

Ecuación 4-41 Eslabonamiento promedio

$$D_{[(U,V),W]} = \frac{\sum_{i,k} d_{i,k}}{N_{(U,V)} N_{(W)}} \quad \text{y} \quad S_{[(U,V),W]} = \frac{\sum_{i,k} S_{i,k}}{N_{(U,V)} N_{(W)}}$$

donde:

$d_{i,k}$ es la distancia entre el elemento i en el grupo (U, V) y el objeto k en el grupo (W).

$N_{(U,V)}$ es el número de elementos en el segmento (U, V).

$N_{(W)}$ es el número de objetos en el segmento (W).

En el ejemplo, $N_{(A,B,C)} = 3$ porque son 3 elementos los que integran ese grupo y lo mismo para el grupo $N_{(D,E,F)} = 3$.

La siguiente figura muestra un grupo formado por 3 elementos y un segundo grupo formado por 2 y todas las combinaciones de las distancias que se tomarán para promediarlas:




Figura 4-21 Criterio del eslabonamiento promedio entre grupos.

Este criterio tiende a producir segmentos compactos dentro del grupo con menores diferencias, por lo cual es uno de los más utilizados.

4.6.2 Promedios intragrupos (*withing-groups linkage*)

Los **promedios intragrupos** (*withing-groups linkage*) combinan los grupos de manera que la media de las distancias entre todos los casos en el grupo resultante sea lo más pequeña posible.




Figura 4-22 Criterio de eslabonamiento promedio dentro de grupos.

Promedios intragrupos. Combinan grupos de manera que la media de las distancias entre todos los casos en el grupo resultante sea lo más pequeña posible.

4.6.3 Simple o distancias mínimas (*single linkage*)

El **criterio simple** o **distancias mínimas** (*single linkage*), conocido como el *vecino más próximo* o *más cercano* asume que al fusionarse 2 objetos se tomarán como características las de aquel elemento que sea más parecido a aquel con el que se compara, o lo que es lo mismo cuya distancia sea la mínima o bien cuya similitud sea la máxima:

Ecuación 4-42 Eslabonamiento simple

$$D_{[(U,V),W]} = \text{Mín} \{d_{U,W}, d_{V,W}\} \text{ en distancia}$$

$$S_{[(U,V),W]} = \text{Máx} \{S_{U,W}, S_{V,W}\} \text{ en similitudes}$$

Criterio simple o distancias mínimas. Asume que al fusionarse dos objetos se tomarán como características las de aquel elemento que sea más parecido a aquel con el que se compara.

El diagrama siguiente ejemplifica el criterio del vecino más cercano, al unir los 2 elementos más próximos:




Figura 4-23 Criterio de eslabonamiento simple o el vecino más cercano.

4.6.4 Completo o distancias máximas (*complete linkage*)

Criterio completo o distancias máximas. Supone que cuando dos elementos se unen, el parecido de ese grupo a un tercer elemento estará dado por las características del elemento con el cual tenga más diferencias, es decir, se eslabona con la máxima de las distancias o la mínima de las similitudes.

El **criterio completo** o **distancias máximas** (*complete linkage*) también conocido como el *vecino más lejano* supone que cuando dos elementos se unen, el grado de parecido de ese grupo a un tercer elemento estará dado por las características de aquel elemento que tenga más diferencias con el elemento con el cual se le compara, es decir, se eslabona con la máxima de las distancias o la mínima de las similitudes:

Ecuación 4-43 Eslabonamiento completo

$$D_{[(U,V),W]} = \text{Máx} \{d_{U,W}, d_{V,W}\}$$

$$S_{[(U,V),W]} = \text{Mín} \{S_{U,W}, S_{V,W}\}$$

El diagrama siguiente ejemplifica el concepto del vecino más lejano.




Figura 4-24 Criterio del eslabonamiento completo o el vecino más lejano.

4.6.5 Método de Ward

Método de Ward. Busca a los dos grupos o conglomerados cuya unión conlleve el menor incremento de la varianza.

El **método de Ward**, también llamado *método de la varianza mínima*, busca a los dos grupos o conglomerados cuya unión conlleve el menor incremento de la varianza. Esto significa que en cada paso se debe probar con todas las combinaciones posibles de dos grupos, calcular el valor del índice de la suma de cuadrados y seleccionar aquel con el menor valor. La desventaja es que tiende a formar grupos compactos y del mismo tamaño, utiliza más información sobre el contenido de los grupos que otros métodos, pero es el que ha demostrado mayor eficacia en estudios de simulación.

Ecuación 4-44 Eslabonamiento del método de Ward

$$SCE = \sum_{j=1}^k \left(\sum_{i=1}^{n_j} X_{ij}^2 - \frac{1}{n_j} \left(\sum_{i=1}^{n_j} X_{ij} \right)^2 \right)$$

El diagrama de la figura 4-25 ejemplifica lo que se menciona antes.




Figura 4-25 Criterio de eslabonamiento del método de Ward.

Método del centroide. Criterio que considera que, cuando dos elementos se unen y forman un grupo, las características que prevalecen respecto a un tercer elemento están dadas por el promedio de las características originales.

4.6.6 Método del centroide (*centroid method*)

El **método del centroide** (*centroid method*) es un criterio que considera que, al unirse dos elementos y formar un grupo, las características que prevalecerán con respecto a un tercer elemento

estarán dadas por el promedio de las que originalmente poseían, lo cual se representa de la siguiente manera:

Ecuación 4-45 Eslabonamiento del centroide

$$d_{(UV)W} = \frac{n_U}{n_U + n_V} d_{UW} + \frac{n_V}{n_U + n_V} d_{VW} - \frac{n_U n_V}{(n_U + n_V)^2} d_{UV}$$

$$S_{(UV)W} = \frac{n_U}{n_U + n_V} S_{UW} + \frac{n_V}{n_U + n_V} S_{VW} - \frac{n_U n_V}{(n_U + n_V)^2} S_{UV}$$

Es decir, este criterio supone que no le interesa lo más o lo menos parecido, sino en realidad el promedio. El diagrama siguiente ejemplifica lo anterior con los promedios:




Figura 4-26 Criterio del eslabonamiento por el método del centroide.

4.6.7 Método de la mediana (*median method*)

La **distancia entre dos grupos** es la existente entre las medianas de las características de los individuos que componen los grupos, de este modo los dos grupos que se combinan se ponderan de forma equivalente al método centroide, pero independientemente del número de individuos que haya en cada grupo. Con lo anterior, la desventaja que se presenta en el método del centroide es que al fusionar dos grupos de diferente tamaño, el centroide del nuevo grupo queda más cerca del grupo de mayor tamaño y más lejos de aquel de menor dimensión en proporción a sus diferencias de tamaño. Esto ocasionaría que durante el proceso aglomerativo de fusión se perdieran las propiedades de los grupos pequeños paulatinamente.

Distancia entre dos grupos. Distancia que existe entre las medianas de las características de los individuos que componen los grupos.

Ecuación 4-46 Eslabonamiento de la mediana

$$d_{(UV)W} = \frac{d_{UW} + d_{VW}}{2} - \frac{d_{UV}}{4}$$

$$S_{(UV)W} = \frac{S_{UW} + S_{VW}}{2} - \frac{S_{UV}}{4}$$

Los 7 criterios que se acaban de exponer pueden utilizarse tanto para el método aglomerativo como para el divisional. En este libro se ejemplificarán los criterios simple, completo y promedio.

Los resultados del agrupamiento se representarán en 2 tipos de diagramas que se denominan:

- Dendogramas
- Diagramas de carámbanos o témpanos

Los cuales serán explicados y analizados más adelante.

Una vez establecidos los criterios para agrupar los elementos, analizaremos el procedimiento para llevar a cabo el agrupamiento aglomerativo.

4.7 Pasos del agrupamiento jerárquico aglomerativo

Para llevar a cabo el agrupamiento jerárquico aglomerativo es necesario seguir varios pasos; éstos se analizan a continuación:

1. Detectar el tipo de variables que se tiene en el análisis:
 - Si las variables son métricas se deberán estandarizar, esto con el fin de quitar los efectos de las unidades y hacer que las variables sean comparables.
 - Si las variables son no métricas, éstas deberán ser del tipo dicotómico⁵ o convertirlas a *dummy* ya que cualquier variable se puede cambiar a este tipo de escala.
2. Para evaluar lo parecido que son los objetos se requiere tener como información una matriz:
 - De distancia, si se escogieron disimilaridades.
 - De similitud, si se escogieron similitudes.
3. De acuerdo con el método aglomerativo se comienza con “n” grupos, cada uno de ellos está formado por un elemento. Posteriormente, con base en la información manejada en la matriz de distancia o similitud se empieza a agrupar, para lo cual se selecciona la pareja de elementos más parecidos para formar un grupo; si se manejan distancias se escogerá la menor, si son similitudes se selecciona la mayor:

$AGRUPAR \Rightarrow \min \{d_{ij}\}$ en distancias, o

$AGRUPAR \Rightarrow \max \{S_{ij}\}$ en similitudes

4. Una vez fusionados los elementos y formado el grupo se debe aplicar alguno de los criterios de eslabonamiento antes vistos, con el fin de evaluar lo parecido que es este grupo respecto al resto de los elementos.
5. Se repiten los pasos 3 y 4 un total de “n – 1” veces hasta fusionar todos los elementos en un solo grupo.

Para que este procedimiento quede claro se pondrá en práctica a continuación.

Primero se analizará el agrupamiento a través de una medida de distancia. Bajo este criterio se tendría como enfoque central agrupar a aquellas personas u objetos con menores distancias entre sí, es decir, los más parecidos.

4.8 Problemas de distancia

Como ya se dijo la medida más utilizada en distancias es la euclidiana que se muestra en seguida:

Ecuación 4-47 Distancia euclidiana

$$d_{ij} = \left[\sum_{k=1}^r (X_{ik} - X_{jk})^2 \right]^{\frac{1}{2}}$$

donde:

d_{ij} es la distancia de los perfiles de los objetos i y j .

X_{ik} representa la característica k medida en el objeto i .

X_{jk} representa la característica k medida en el objeto j .

r es el número de características utilizadas para evaluar lo parecido.



Ejemplo

Se tiene como información la altura y el peso de 5 personas, se desea reducir el número de personas para describirlas de una manera más general (es decir, formar segmentos o grupos de personas). Los datos son los siguientes:⁶

⁵ Ausencia y presencia.

⁶ Datos generados para este texto.

Tabla 4-3 Información sobre la altura (en centímetros) y el peso (en kilogramos) de 5 personas

Personas	Altura (cm)	Peso (kg)
1	173	64
2	185	84
3	170	75
4	164	54
5	193	95
Promedio =	177.00	74.40
Desviación estándar =	11.77	16.13

4.8.1 Estandarización de las variables

Antes que nada se debe recordar que uno de los requisitos para realizar el análisis de agrupamiento métrico es que los datos de las variables estén estandarizados, es decir, se debe eliminar el efecto de las unidades y hacerlas comparables, de manera que todas se encuentren en términos de “Z”.

Los datos estandarizados de las 5 personas, al considerar las 2 variables, se presentan a continuación:

Tabla 4-4 Información estandarizada de la altura y el peso de 5 personas

Personas	Altura estandarizada	Peso estandarizado
1	-0.34	-0.64
2	0.68	0.60
3	-0.59	0.04
4	-1.10	-1.26
5	1.36	1.28
Promedio =	0.00	0.00
Desviación estándar =	1.00	1.00

4.8.2 Número de distancias a encontrar

Para empezar a evaluar el parecido de las personas en cuanto a su peso y altura es necesario compararlas por parejas y determinar la distancia entre ellas; para ello se usa alguna de las fórmulas de distancia mencionadas.

Para saber cuántas distancias por parejas se van a calcular se podría aplicar la siguiente fórmula, la cual indica el número de distancias a encontrar:

Ecuación 4-48 Número de distancias a encontrar

$$\text{Número}(d_{ij}) = \frac{n * (n - 1)}{2}$$

donde:

$\text{Número}(d_{ij})$ es el número de distancias por parejas que se tienen que calcular.

n es el número de observaciones (personas u objetos).

En el ejemplo $n = 5$ por lo que se tiene el siguiente resultado:

$$\text{Número}(d_{ij}) = \frac{5 * (5 - 1)}{2} = 10$$

4.8.3 Cálculo de las distancias a encontrar

Se inicia con la distancia de la persona 1 con la 2, la 1 con la 3 y así sucesivamente hasta establecer cada una de las distancias para todas las parejas posibles; la nomenclatura $d_{i,j} = d_{1,2}$, significa que se encontró la distancia existente entre los elementos 1 y 2; el procedimiento de cada una de las distancias se presenta a continuación.

$$d_{1,2} = [(-0.34 - 0.68)^2 + (-0.64 - 0.60)^2]^{\frac{1}{2}} = 1.61$$

$$d_{1,3} = [(-0.34 + 0.59)^2 + (-0.64 - 0.04)^2]^{\frac{1}{2}} = 0.73$$

$$d_{1,4} = [(-0.34 + 1.10)^2 + (-0.64 + 1.26)^2]^{\frac{1}{2}} = 0.98$$

$$d_{1,5} = [(-0.34 - 1.36)^2 + (-0.64 - 1.28)^2]^{\frac{1}{2}} = 2.57$$

$$d_{2,3} = [(0.68 + 0.59)^2 + (0.60 - 0.04)^2]^{\frac{1}{2}} = 1.39$$

$$d_{2,4} = [(0.68 + 1.10)^2 + (0.60 + 1.26)^2]^{\frac{1}{2}} = 2.58$$

$$d_{2,5} = [(0.68 - 1.36)^2 + (0.60 - 1.28)^2]^{\frac{1}{2}} = 0.96$$

$$d_{3,4} = [(-0.59 + 1.10)^2 + (0.04 + 1.26)^2]^{\frac{1}{2}} = 1.40$$

$$d_{3,5} = [(-0.59 - 1.36)^2 + (0.04 - 1.28)^2]^{\frac{1}{2}} = 2.31$$

$$d_{4,5} = [(-1.10 - 1.36)^2 + (-1.26 - 1.28)^2]^{\frac{1}{2}} = 3.54$$

Posteriormente esta información se vacía en una matriz cuadrada (de 5×5 , debido a que son 5 personas) a la que se le denomina *matriz de distancia*, la cual resume lo parecido que son las personas con base en la distancia entre ellas. En virtud de la característica de esta matriz sólo es necesario utilizar la información del triángulo inferior o superior de ella, basándonos en los cálculos anteriores. La información se muestra a continuación.

Tabla 4-5 Matriz de distancia

	1	2	3	4	5
1	0				
2	1.61	0			
3	0.73	1.39	0		
4	0.98	2.58	1.40	0	
5	2.57	0.96	2.31	3.54	0

A esta matriz se le llama *matriz de disimilaridad* o *matriz de proximidad*. Como se puede observar, la diagonal de la matriz está representada por ceros, ya que la distancia que hay al comparar una persona consigo misma es nula.

Al observar la matriz se puede responder lo planteado en el problema, es decir, cuáles son las personas más y menos parecidas. Las parejas más parecidas son aquellas cuya distancia entre sí es

menor, mientras que las menos parecidas tienen una distancia mayor entre ellas. Así se puede concluir que la pareja más parecida es la 3 y 1 con una medida de distancia de 0.73, que es la menor de todas, y la pareja menos parecida es la 4 y 5 con una medida de distancia de 3.54, que es la mayor de todas. La información que el SPSSTM presenta de esa matriz es la siguiente:

Tabla 4-6 Matriz de distancia arrojada por el SPSSTM

Caso	Distancia euclidiana				
	1	2	3	4	5
1	.000	1.605	.728	.984	2.565
2	1.605	.000	1.391	2.577	.963
3	.728	1.391	.000	1.398	2.314
4	.984	2.577	1.398	.000	3.540
5	2.565	.963	2.314	3.540	.000

Ésta es una matriz de similitudes.

Como se ve es la misma matriz pero completa, es decir, sin quitar los valores de la diagonal para arriba, además note que en la parte superior dice que es una matriz de distancia y que el coeficiente utilizado fue el de la distancia euclidiana.

4.9 Vinculación o eslabonamiento

En este apartado es necesario escoger el tipo de eslabonamiento o vinculación que se utilizará; suponga que se decidió por el criterio del vecino más cercano, también denominado *simple*.

4.9.1 Vinculación o eslabonamiento simple

Una vez escogido el tipo de eslabonamiento que se aplicará, se realizan los siguientes pasos:

1. Agrupar. Consiste en escoger los elementos más parecidos para formar un segmento o grupo, el cual sería la próxima pareja a formar.
2. Eslabonar. Se refiere a confrontar las distancias o similitudes de los elementos agrupados con el resto de los elementos.

Ahora realizarán los pasos anteriores.

4.9.1.1 Agrupar

Como en el ejemplo se manejan distancias, los elementos más parecidos serán seleccionados a través de la menor distancia ($\min \{d_{ij}\}$), entonces el valor sería el 0.73:

	1	2	3	4	5
1	0				
2	1.61	0			
3	0.73	1.39	0		
4	0.98	2.58	1.40	0	
5	2.57	0.96	2.31	3.54	0

Una vez seleccionada la distancia de los elementos que se van a agrupar, se detecta quiénes son las personas; al seguir por renglón y columna vemos que son las personas 1 y 3, como se muestra en la siguiente matriz:

	1	2	3	4	5
1	0				
2	1.61	0			
3	0.73	1.39	0		
4	0.98	2.58	1.40	0	
5	2.57	0.96	2.31	3.54	0

El nuevo grupo (1, 3) se pone en primer lugar dentro de una nueva matriz, cuyas dimensiones son reducidas de 5×5 a 4×4 , como se muestra a continuación:

	(1, 3)	2	4	5
(1, 3)	0			
2		0		
4			0	
5				0

El siguiente paso es empezar a eslabonar; para eso es necesario escoger un criterio de vinculación. Supóngase que se eligió el de eslabonamiento simple, que a continuación se detalla.

4.9.1.2 Eslabonar o vincular

Como se escogió el criterio del vecino más cercano, al momento de eslabonar se elegirá la distancia más pequeña ($D_{[U,V],W} = \text{Mín} \{d_{U,W}, d_{V,W}\}$), es decir, se compara al nuevo grupo (1, 3) con el resto de los elementos; al confrontar a la persona 2 con la persona 1 se observa que tiene una distancia de 1.61, al comparar a la persona 2 con la 3 se ve que hay una distancia de 1.39; al eslabonar se selecciona la distancia más pequeña, que es la de 1.39; a manera de resumen esto sería:



El valor eslabonado se incluye en la matriz reducida:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.39	0		
4			0	
5				0

Nuevamente se usa el mismo criterio para eslabonar el elemento 4 con la pareja de las personas (1, 3):



Al incluir este valor en la matriz se tiene:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.39	0		
4	0.98		0	
5				0

Ya por último se toman las distancias del elemento 5 con las personas (1, 3):



Nuevamente el valor se incluye en la matriz:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.39	0		
4	0.98		0	
5	2.31			0

Los valores faltantes de la matriz se llenan con los mismos datos de la matriz original, es decir, la anterior.

	(1, 3)	2	4	5
(1, 3)	0			
2	1.39	0		
4	0.98	2.58	0	
5	2.31	0.96	3.54	0

Una vez que la matriz está completa nuevamente se forma la próxima pareja; hay que seleccionar a la pareja más parecida, que en este caso serían las personas 2 y 5, que tienen la distancia más pequeña de 0.96 y así se continúa.

	(1, 3)	2	4	5
(1, 3)	0			
2	1.39	0		
4	0.98	2.58	0	
5	2.31	0.96	3.54	0

4.9.1.3 Historial del eslabonamiento

La información de todo lo que se realizó se puede resumir en la siguiente tabla:

Tabla 4-7 Resumen de todo el proceso de eslabonamiento simple

Etapa	Objetos agrupados		Coeficiente: distancia	Etapa donde aparecieron		Próxima etapa donde aparecerán
	Grupo 1	Grupo 2		Grupo 1	Grupo 2	
1	1	3	0.73	0	0	3
2	2	5	0.96	0	0	4
3	(1,3)	4	0.98	1	0	4
4	[(1,3),4]	(2,5)	1.39	3	2	0

En la tabla anterior se indica que en la primera etapa se agrupó el elemento 1 y el 3, a una distancia de 0.73; en las siguientes dos columnas se muestra en qué etapa aparecieron con anterioridad, el valor de cero indica que no habían aparecido antes; la última columna señala en qué próxima etapa volverán a aparecer, en este caso sería en la etapa 3. En la segunda etapa se unieron los grupos 2 y 5 a una distancia de 0.96, ninguno de los 2 elementos han aparecido antes y volverán a aparecer en la etapa 4. En la tercera etapa se unieron la pareja (1, 3) con el elemento 4 a una distancia de 0.98, la pareja (1, 3) apareció con anterioridad en la etapa 1, pero el elemento 4 no había aparecido, los 3 elementos volverán a utilizarse en la etapa 4. En la etapa 4 se agruparon el segmento (1, 3, 4) con la pareja (2, 5) a una distancia de 1.39, dichas parejas aparecieron en la etapa 3 y 2, respectivamente, y ninguno de los 2 grupos aparecerá posteriormente. El SPSS™ presenta la misma información en la siguiente tabla:

Tabla 4-8 Resumen de todo el proceso de eslabonamiento simple arrojado por el SPSS™

Historial de conglomerado						
Etapa	Conglomerado que se combina		Coeficientes	Etapa en la que el conglomerado aparece por primera vez		Próxima etapa
	Conglomerado 1	Conglomerado 2		Conglomerado 1	Conglomerado 2	
1	1	3	.728	0	0	3
2	2	5	.963	0	0	4
3	1	4	.984	1	0	4
4	1	2	1.391	3	2	0

Como se ve es la misma tabla sólo que al momento de volver a nombrar un elemento o grupo únicamente se agrega la etiqueta de la primera persona que agrupó; por ejemplo en la etapa 4, en las columnas de los conglomerados que se combinan, puso la etiqueta de 1 y de 2, eso significa que se deben repasar los demás pasos para saber a quiénes está nombrando; en este caso al decir 1 significa que etiquetó el segmento que contiene a las personas [(1, 3), 4] y cuando puso 2 significa que es el grupo (2, 5).

Una vez terminado el proceso de agrupar y eslabonar (vinculación), los resultados se pueden representar a través de un diagrama de témpanos o un dendograma.

4.9.1.4 Diagrama de témpanos o de carámbanos

El **diagrama de témpanos o de carámbanos** simplifica los elementos que se agruparon paso a paso, en este caso se tiene el número total de elementos, es decir 5, los cuales son enlistados en las columnas de la forma en que se agruparon; este diagrama puede ser horizontal o vertical.

Diagrama de témpanos o de carámbanos. Simplifica los elementos que se agruparon paso a paso.

- Primero se agruparon (1, 3).
- Luego se agruparon (2, 5).
- Posteriormente se agruparon [(1, 3), 4] por lo que estos últimos 3 elementos no pueden estar separados.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)].

El número de pasos que se realizaron fueron:

$$\# \text{ de pasos} = n - 1$$

donde: n es el número de elementos con que se inicia el problema.

En el ejemplo que se resolvió, el número de elementos son 5, por lo que el número de pasos sería:

$$\# \text{ de pasos} = n - 1 = 5 - 1 = 4$$

Todo lo anterior se muestra a continuación:

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1									
2									
3									
4									

Las columnas donde se encuentran los elementos se llenan de cruces o con la letra X, como lo muestra la siguiente tabla:

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1	X		X		X		X		X
2	X		X		X		X		X
3	X		X		X		X		X
4	X		X		X		X		X

De 5 elementos se agrupó la pareja (1, 3), lo que significa que quedan 4 grupos, los cuales son: (1, 3), (2), (4) y (5).

Eso significa que la columna que se encuentra entre el elemento 1 y 3 deberá de llenarse también con X:

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1	X	X	X		X		X		X
2	X	X	X		X		X		X
3	X	X	X		X		X		X
4	X	X	X		X		X		X

Posteriormente se agrupó la pareja (2, 5) por lo que ahora se tiene un conglomerado menos; quedan 3: (2, 5), (1, 3) y (4).

Eso implica que la columna que se encuentra entre el elemento 2 y 5 deberá llenarse también con X, aunque esto debe ponerse hasta completar el número de conglomerados, en este caso son 3, por lo que se llena sólo una parte, esto se muestra a continuación:

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1	X	X	X		X		X	X	X
2	X	X	X		X		X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

En el siguiente paso se agrupa el elemento 4 con la pareja (1, 3) por lo que quedan sólo 2 segmentos: [(1, 3), 4] y (2, 5).

Eso significa que la columna que se encuentra entre el elemento 4 (1, 3) deberá llenarse también con X, pero sólo hasta el número de conglomerados, en este caso son 2, por lo que se llena sólo una parte, esto se muestra a continuación:

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1	X	X	X	X	X		X	X	X
2	X	X	X	X	X		X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

En el siguiente paso se agrupó [(1, 3), 4] con la pareja (2, 5) por lo que queda sólo un segmento: [(1, 3, 4), (2, 5)].

Eso significa que la columna que se encuentra entre el conglomerado [(1, 3), 4] con (2, 5) deberá llenarse también con X, aunque debe ser sólo hasta el número de conglomerados, en este caso es 1 por lo que se llena sólo una parte, esto se muestra a continuación en el que sería el diagrama final.

Número de grupos o conglomerados	Elementos								
	1		3		4		2		5
1	X	X	X	X	X	X	X	X	X
2	X	X	X	X	X		X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

El resultado del diagrama de témpanos en el SPSS™ se presenta a continuación:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		4		3		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X		X		X		X	X	X

Figura 4-27 Diagrama de carámbanos o témpanos vertical que arroja el SPSS™.

Note que los elementos se encuentran en diferente orden, de hecho éste puede ser de muchas maneras. El diagrama de carámbanos horizontal en el SPSS™ sería el siguiente:

Diagrama de témpanos horizontal				
Número de conglomerados				
Caso	1	2	3	4
5	X	X	X	X
	X	X	X	
2	X	X	X	X
	X			
4	X	X	X	X
	X	X		
3	X	X	X	X
	X	X	X	X
1	X	X	X	X

Figura 4-28 Diagrama de carámbanos o témpanos horizontal que pone como solución el SPSS™.

4.9.1.5 Dendograma


El **dendograma** es un diagrama en cuyo eje horizontal aparecen los elementos agrupados, de preferencia en el orden en que se unieron; de acuerdo con el ejemplo se tiene que:

- Primero se agruparon (1, 3).
- Luego se agruparon (2, 5).
- Posteriormente se agruparon [(1, 3), 4] por lo que estos últimos 3 elementos no pueden estar separados.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)].


Dendograma. Diagrama en cuyo eje horizontal aparecen los elementos agrupados, de preferencia en el orden en que se unieron.

Ése sería el orden en que estarían acomodados; el lector podría pensar muchas formas diferentes para hacerlo, pero recuérdese que siempre deberán estar juntos los elementos que fueron agrupados en un segmento.


En el eje vertical se manejan las medidas de distancia (o de similitud, según sea el caso) en donde el punto inicial es el cero, debido a que se supone que cada elemento es un grupo y la relación de distancia consigo mismo es cero; las demás distancias se ordenan (hacia arriba del eje) según se unieron los diferentes segmentos, es decir: 0.73, 0.96, 0.98 y 1.39. Si se tratara de medidas de similitud, en el eje vertical el punto inicial sería el 1 o el infinito (dependiendo de la medida de similitud utilizada) y hacia arriba del eje disminuirían los valores lo cual indicaría que los elementos serían los menos parecidos que se agrupan conforme avanza el proceso de segmentación; lo anterior se muestra a continuación:




El dendograma está formado por líneas rectángulos que unen a los elementos que se eslabonan en sus esquinas inferiores, dichas líneas tienen una altura, la cual indica el grado de similitud, es decir, es la distancia a la cual se unieron dichos elementos; al seguir con el ejemplo, los primeros que se agruparon fueron (1, 3) a una distancia de 0.73, por lo que el dendograma empezaría con líneas que salgan del eje horizontal de los elementos 1 y 3; dichas líneas tienen que dibujarse hacia arriba hasta que lleguen a una distancia de 0.73, en donde se cierran en forma de rectángulo, lo cual se vería de la siguiente forma:




Es importante comentar que aquí se graficaron rectángulos con el fin de que el lector entienda la manera en que se trazan las uniones de los elementos. Posteriormente se agruparon (2, 5) a una distancia de 0.96, por lo que el dendograma continuaría de la siguiente forma:



Los siguientes en agruparse fueron $[(1, 3), 4]$; se traza una línea desde el elemento 4 a la mitad del grupo $(1, 3)$, es decir, a la mitad del rectángulo gris oscuro, esto quedaría de la siguiente manera:



Los últimos en agruparse fueron $[(1, 3, 4), (2, 5)]$, se traza una línea desde la mitad del grupo $[(1, 3), 4]$, es decir, desde la mitad del segundo rectángulo, a la mitad del grupo $(2, 5)$, es decir, del rectángulo gris claro; esto quedaría de la siguiente manera:



A continuación se muestra el dendrograma completamente terminado y sin colores:





Figura 4-29 Dendrograma terminado.


Es importante comentar que la mayoría de los paquetes colocan el dendrograma de forma horizontal por lo que se rotará 90 grados para que quede de la misma manera como lo presentaría el SPSS™:



4.9.1.6 Número de conglomerados a dejar como solución


A partir del dendrograma se puede determinar tentativamente cuántos grupos se podrían tener como solución. Dejar a todos los elementos en un solo grupo no tiene caso, a menos que la solución sea homogénea; tampoco tiene sentido dejar tantos grupos como elementos. En ambos casos no conviene realizar el análisis de conglomerados.

Ahora la pregunta sería: ¿cuántos grupos conservar?, para responder es necesario analizar la información del dendrograma, por ejemplo, ¿cuántos grupos existen a una distancia de 0.5?, para saberlo se traza una línea recta a esa distancia, como lo indica la siguiente figura:




Nota: Esto se explicará en el dendograma no rotado.


En la figura anterior, a la distancia de 0.5 se traza una línea para saber cuántos grupos existen a esa distancia, después se cuentan las líneas que se cruzan, en este caso existen 5 grupos puesto que se están atravesando 5 líneas. Ahora, por ejemplo, a una distancia de 0.90, ¿cuántos grupos existen? Para saberlo otra vez se traza una línea y se ve cuántos conglomerados existen con base en las líneas que se cruzan, en este caso sólo existen 4 segmentos, como lo muestra la siguiente figura:




Si se deseara saber cuántos grupos existen a una distancia de 0.97, otra vez se traza una línea a esa distancia y, como se mencionó, según las líneas que se crucen se ve cuántos grupos existen, en este caso sólo hay 3 segmentos, como lo muestra la siguiente figura:




Ahora supóngase que se desea saber cuántos grupos existen a una distancia de 1.00; nuevamente se traza una línea a esa distancia y según las líneas que se crucen se ve cuántos conglomerados existen, en este caso sólo hay 2 segmentos, como lo muestra la siguiente figura:



Desde la distancia de 0.98 a antes del 1.39 existen sólo 2 segmentos, desde 1.39 a distancias mayores de 1.39 sólo hay un conglomerado; esto se muestra en el siguiente dendograma:



Debido a la distancia que existe entre los conglomerados, la solución más factible es la de 2 grupos (1, 3, 4) y (2, 5), dichas distancias se muestran en la siguiente figura, en donde se pusieron las llaves del mismo tamaño para que el lector vea cuál es la mayor distancia entre segmentos, es decir, marca cuándo se forma el siguiente grupo:



Como se mostró en la figura anterior la mayor distancia es la que existe cuando se unen los segmentos (1, 3, 4) con (2, 5), por lo que se decide dejar sólo 2 conglomerados, pero este número es sólo tentativo, no hay que olvidar que será el análisis discriminante el que verificará si esta solución es la correcta, esto se verá más a detalle en el siguiente capítulo.

4.9.1.7 Etiquetado de los conglomerados

Si se decidió dejar sólo 2 conglomerados, al finalizar todo el proceso, lo que continúa es el etiquetado de los grupos. Un segmento está formado por las personas 1, 3 y 4, a éste lo llamaremos grupo 1; el otro segmento está formado por las personas 2 y 5, que se llamará grupo 2. Para conocer el tipo de individuos que se encuentran en cada grupo se debe obtener la media de los datos originales de quienes los conforman. Esto se hace por grupo, por variable, como a continuación se muestra:

Tabla 4-9 Información sobre la altura (en centímetros) y el peso (en kilogramos) de 5 personas

Personas	Altura (cm)	Peso (kg)
1	173	64
2	185	84
3	170	75
4	164	54
5	193	95
Promedio =	177.00	74.40
Desviación estándar =	11.77	16.13

- La media de altura para el grupo 1 es de: $173 + 170 + 164/3 = 169$ cm.
- La media de peso para el mismo grupo es: $64 + 75 + 54/3 = 64.33$ kg.

Ahora se hace el mismo procedimiento para el grupo 2.

- La media de altura del grupo 2 es: $185 + 193/2 = 189$ cm.
- La media de peso del grupo 2 es: $84 + 95/2 = 89.5$ kg.

Según los resultados el grupo 1 es el segmento de los bajitos y delgados por lo que se puede etiquetar como “grupo pequeñitos” y el grupo 2 es el de personas altas y gorditas, por lo que se puede etiquetar como “grupo grandecitos”.


Como ya se mencionó, este problema será resuelto por eslabonamiento completo y promedio para mostrar su aplicación. El procedimiento de agrupamiento es siempre el mismo; el próximo grupo a formar es el más parecido, por lo que siempre se escoge la menor distancia; lo único que cambia es la forma de eslabonar o vincular, es decir, la decisión al determinar el grado de proximidad entre un nuevo segmento y los elementos no agrupados con ese nuevo grupo, como se muestra a continuación.

¿Cuántos segmentos?

No existe una respuesta exacta de cuántos grupos se tienen; hay algunos criterios que son muy complejos en sus cálculos y pueden ayudar a decidir la cantidad de segmentos a dejar como solución; es importante recalcar que sólo los resultados estadísticos unidos al conocimiento del mercado, la experiencia e intuición del cliente permitirán decidir cuántos grupos conservar al finalizar el análisis de conglomerados.

Una de las formas para decidir cuántos segmentos dejar es la que se explicó antes: al observar el dendrograma se puede definir la cantidad de segmentos a conservar. Este método es el más recomendado, pues es el único que se puede realizar en el paquete estadístico SPSS™. Por supuesto que existen otros métodos, pero éstos se realizan sin el paquete, por lo que sólo se mencionará el siguiente:

- Alternativa que requiere graficar la distancia entre los conglomerados: la idea es graficar los conglomerados con sus respectivas distancias; una distancia muy alta entre conglomerados indica que son 2 grupos muy heterogéneos entre sí, por lo que no se recomienda fusionarlos.

**Figura 4-30** Distancia entre conglomerados contra número de conglomerados.

Al ver la gráfica se puede trazar una línea imaginaria que pase lo más cerca posible entre los puntos, desde donde hay de 4 grupos hasta 1, siguiendo una pendiente; cuando alguna línea se dispare de esta pendiente se tiene que hacer un corte y quedarse con ese número de grupos; como se puede observar el cambio en la pendiente en esta gráfica se presenta en una solución de 2 grupos, por lo que aquí se propondría tentativamente una solución con ese número de segmentos.

Otra forma de decidir el número de grupos a dejar es mediante el incremento en el cambio porcentual de los coeficientes de distancia, como a continuación se muestra:

Tabla 4-10 Historial de conglomeración

Etapa	Conglomerado que se combina		Coeficiente	Etapa en la que el conglomerado aparece por primera vez		Próxima etapa
	Conglomerado 1	Conglomerado 2		Conglomerado 1	Conglomerado 2	
1	1	3	0.728	0	0	3
2	2	5	0.963	0	0	4
3	1	4	0.984	1	0	4
4	1	2	1.391	3	2	0

Cuando el cambio porcentual es más evidente o es mayor, indica que ese número de grupos es el óptimo para trabajar; en este caso el mayor incremento se observa en el paso 3, que es cuando se tienen 2 grupos.

Independientemente del método elegido para encontrar el óptimo de segmentos, se recomienda que no haya grupos con un número pequeño de integrantes, ya que demasiados segmentos suelen confundir la toma de decisiones para el desarrollo de campañas, de promociones o de nuevos productos, etc. Lo que se debe tomar en cuenta es:

1. Utilizar sólo variables que sean fáciles de medir y que tengan trascendencia en el estudio para identificar rápidamente a qué segmento pertenece cierto individuo.
2. Que los segmentos sean lo suficientemente grandes para que la inversión que se realice sea redituable, por ejemplo, para el lanzamiento de un nuevo producto.
3. Que la estrategia elegida sea aplicable y alcanzable en los segmentos con los que se trabajará; por ejemplo, si se lanza una campaña publicitaria de alguna línea de ropa que sólo compra la clase socioeconómica A es posible que dicha campaña no logre impactar al nivel D.
4. Saber por qué y en qué son claramente diferenciables los segmentos, ya que con eso se podrá decidir qué grupo es más conveniente aprovechar y en qué forma.

4.9.2 Vinculación o eslabonamiento completo

El procedimiento del vecino más lejano es similar al del vecino más cercano sólo que en el eslabonamiento se escogerá la distancia mayor, es decir $D_{[(U,V),W]} = \text{Máx} \{d_{U,W}, d_{V,W}\}$, pero recuerde que primero hay que agrupar.

4.9.2.1 Agrupar

Al **agrupar** siempre se selecciona a los elementos más parecidos, es decir, por la mínima distancia. En el ejemplo es:

Agrupar. Selección de los elementos más parecidos entre sí.

Tabla 4-11 Matriz inicial, se agrupa

	1	2	3	4	5
1	0				
2	1.61	0			
3	0.73	1.39	0		
4	0.98	2.58	1.40	0	
5	2.57	0.96	2.31	3.54	0

Se eligen los elementos más parecidos de la matriz inicial, que son el 1 y el 3, por la menor distancia que es de 0.73 y se forma un grupo, el cual se coloca en primer lugar dentro de la matriz para así eslabonar:

	(1, 3)	2	4	5
(1, 3)	0			
2		0		
4			0	
5				0

Una vez que se agrupó la primera pareja se realiza la vinculación.

4.9.2.2 Eslabonar

En seguida se empieza el eslabonamiento, en este caso se escogerá la distancia más grande, es decir, se compara a la persona 2 con el grupo recién formado, se compara con 1 y 3, la distancia de 2 con 1 es 1.61 y la de la persona 2 con la 3 es de 1.39; se escoge la distancia mayor, como se muestra en la siguiente figura:



En este caso se escoge la distancia más grande, que es 1.61, este valor se acomoda en la matriz reducida (este procedimiento no será mostrado) y se seguirá eslabonando hasta completar dicha matriz, por lo que ahora se compara el elemento 4 con la pareja (1, 3), como se muestra en la siguiente figura:



Al comparar las distancias 0.98 y 1.40 se escoge la mayor, que sería 1.40, dicho valor se acomoda en la matriz reducida y se compara el último elemento, que es el 5 con la pareja (1, 3); este proceso se muestra en la siguiente figura:



En la comparación anterior se escogería 2.57; al acomodar los valores anteriormente eslabonados la matriz reducida quedaría como sigue:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.61	0		
4	1.40		0	
5	2.57			0

Los valores faltantes se toman de la matriz original, por lo que la matriz reducida final quedaría de la siguiente manera:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.61	0		
4	1.40	2.58	0	
5	2.57	0.96	3.54	0

Nuevamente se escoge la pareja más parecida, recuerde que al agrupar se elige la próxima pareja a formar, cuyos elementos son los más parecidos, por lo que se selecciona la mínima distancia y así se continúa, como con el ejemplo anterior.

	(1, 3)	2	4	5
(1, 3)	0			
2	1.61	0		
4	1.40	2.58	0	
5	2.57	0.96	3.54	0

4.9.2.3 Historial del eslabonamiento

Recuerde que el siguiente paso es formar la tabla del historial, del cual se mostrará sólo la salida que da el SPSS™, si el lector desea saber cómo formar la tabla puede hacerlo al revisar el procedimiento del eslabonamiento simple. El historial quedaría de la siguiente manera:

Tabla 4-12 Resumen de todo el proceso de eslabonamiento completo dado por el SPSS™

Historial de conglomeración						
Etapa	Conglomerado que se combina		Coeficiente	Etapa en la que el conglomerado aparece por primera vez		Próxima etapa
	Conglomerado 1	Conglomerado 2		Conglomerado 1	Conglomerado 2	
1	1	3	0.728	0	0	3
2	2	5	0.963	0	0	4
3	1	4	1.398	1	0	4
4	1	2	3.540	3	2	0

Ya que se realizó el historial se traza el diagrama de témpano.

4.9.2.4 Diagrama de témpanos o de carámbanos

Recuerde que el diagrama de carámbanos o témpanos puede ser vertical u horizontal, éstos quedarían de la siguiente manera:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		4		3		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X		X		X		X	x	X

Figura 4-31 Diagrama de carámbanos o témpanos vertical que el SPSS™ da como solución.

Diagrama de témpanos horizontal				
Caso	Número de conglomerados			
	1	2	3	4
5	X	X	X	X
	X	X	X	
2	X	X	X	X
	X			
4	X	X	X	X
	X	X		
3	X	X	X	X
	X	X	X	X
1	X	X	X	X

Figura 4-32 Diagrama de carámbanos o témpanos horizontal que pone como solución el SPSS™.

Nota: Si el lector desea conocer cómo se construye este diagrama puede hacerlo en el apartado de eslabonamiento simple.

Y por último se forma el dendograma como se indica en el siguiente apartado.

4.9.2.5 Dendograma

El dendograma sin rotar quedaría de la siguiente manera:

- Primero se agruparon (1, 3) a una distancia de 0.73.
- Luego se agruparon (2, 5) a una distancia de 0.96.
- Después se agruparon [(1, 3), 4] a una distancia de 1.40.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)] a una distancia de 3.54.

Por lo que el dendograma quedaría como lo muestra la siguiente figura:




Figura 4-33 Dendograma sin rotar, con la solución del eslabonamiento completo.

Como se ve, la solución es la misma sólo que se llega a ella de otra manera.

4.9.2.6 Número de conglomerados a dejar como solución

Para dar una solución lo único que resta es analizar la cantidad de grupos que hay a cierta distancia; el siguiente dendograma muestra las posibles soluciones:




Figura 4-34 Dendograma sin rotar con la solución del eslabonamiento completo.

Al medir las distancias entre los segmentos formados se tienen las siguientes posibles soluciones:




Figura 4-35 Las distancias.

La mayor distancia, según los corchetes, se presenta cuando se tienen 2 grupos; por lo que de nuevo se recomiendan 2 conglomerados, los cuales serían (1, 3, 4) y (2, 5).

Una vez que se decidió el número de segmentos se etiquetan los grupos.

4.9.2.7 Etiquetar los conglomerados

Para etiquetar se usa el mismo proceso que para el eslabonamiento simple, ya que se agruparon de la misma manera.

Nota: Si se desea más información sobre el etiquetado, se recomienda consultar el apartado de eslabonamiento simple.

El análisis discriminante es la técnica utilizada para probar si en verdad existen esos 2 segmentos.

4.9.3 Eslabonamiento promedio entre grupos

El agrupamiento en este caso se basará en el criterio de **eslabonamiento promedio**, es decir, el grado de lo parecido que llegaría a ser un nuevo grupo con respecto a otros elementos no agrupados; esto

será el promedio de las relaciones antes de agruparse al utilizar la fórmula $D_{[(U,V),W]} = \frac{\sum_{i,k} d_{i,k}}{N_{(U,V)}N_{(W)}}$.

Eslabonamiento promedio. Grado de similitud que tiene un nuevo grupo respecto a otros elementos no agrupados.

4.9.3.1 Agrupar

Tomaremos nuevamente la matriz de distancia del ejemplo anterior y se agrupará; recuerde que al manejar distancias siempre se buscará la menor.

Tabla 4-13 Agrupar la primera pareja a formar

	1	2	3	4	5
1	0				
2	1.61	0			
3	0.73	1.39	0		
4	0.98	2.58	1.40	0	
5	2.57	0.96	2.31	3.54	0

El nuevo grupo (1, 3) se pone en primer lugar dentro de una nueva matriz cuyas dimensiones son reducidas de 5×5 a 4×4 , como se muestra a continuación:

	(1, 3)	2	4	5
(1, 3)	0			
2		0		
4			0	
5				0

El siguiente paso es eslabonar, el cual se estudiará en el siguiente apartado.

4.9.3.2 Eslabonar o vincular

Como se escogió el criterio del promedio para eslabonar se elegirá la distancia promedio, la cual se calcula con la siguiente fórmula:

$$D_{[(U,V),W]} = \frac{\sum_{i,k} d_{i,k}}{N_{(U,V)} N_{(W)}}$$

Es necesario comparar a la persona 2 con la 1, se observa que tiene una distancia de 1.61; ahora se compara al individuo 2 con el 3, se ve que hay una distancia de 1.39; al eslabonar se encuentra el promedio, esto se resumiría de la siguiente manera:



La distancia promedio se obtiene con la siguiente ecuación:

$$D_{[(1,3),2]} = \frac{\sum_{i,k} d_{i,k}}{N_{(1,3)} N_{(2)}} = \frac{1.61 + 1.39}{2 * 1} = 1.50$$

En la fórmula anterior las distancias 1.61 y 1.39 provienen de la matriz original, el número 2 ($N_{(1,3)} = 2$) y 1 ($N_{(2)} = 1$) son el número de elementos que cada pareja comparada tiene, es decir, el 2 proviene de la pareja (1, 3) y el 1 del elemento 2. El valor eslabonado se acomoda en la matriz reducida; ahora sigue comparar a la persona 4 con el segmento (1, 3):



De la comparación anterior, el 1.19 proviene de la siguiente fórmula:

$$D_{[(1,3),4]} = \frac{\sum_{i,k} d_{i,k}}{N_{(1,3)} N_{(4)}} = \frac{0.98 + 1.40}{2 * 1} = 1.19$$

Al comparar el 4 (su $N = 1$) y la pareja (1, 3) su $N = 2$ y las distancias provienen de la matriz original; el valor eslabonado de 1.19 se acomoda en la matriz reducida; lo siguiente es comparar al elemento 5 con el segmento (1, 3):



El valor 2.44 procede de la fórmula siguiente:

$$D_{[(1,3),5]} = \frac{\sum_{i,k} d_{i,k}}{N_{(1,3)} N_{(5)}} = \frac{2.57 + 2.31}{2 * 1} = 2.44$$

Los 3 valores que fueron encontrados en el eslabonamiento se acomodan en la matriz reducida, la cual quedaría de la siguiente manera:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.50	0		
4	1.19		0	
5	2.44			0

Los valores faltantes de la matriz se llenan con los datos de la matriz original, es decir la anterior; ya que no se realiza comparación o eslabonamiento alguno, la nueva matriz quedaría de la siguiente manera:

	(1, 3)	2	4	5
(1, 3)	0			
2	1.50	0		
4	1.19	2.58	0	
5	2.44	0.96	3.54	0

Una vez que la matriz está completa, nuevamente se agrupa (la próxima pareja a formar); se escoge a la pareja más similar, que en este caso serían las personas 2 y 5, pues tienen la distancia más pequeña: 0.96, y así se continúa como en el ejemplo anterior.

	(1, 3)	2	4	5
(1, 3)	0			
2	1.50	0		
4	1.19	2.58	0	
5	2.44	0.96	3.54	0

4.9.3.3 Historial del eslabonamiento

El siguiente paso es formar la tabla del historial, el cual se mostrará con la salida que da el SPSS™; si el lector desea saber cómo formar la tabla puede revisar el proceso del eslabonamiento simple. La tabla del historial quedaría de la siguiente manera:

Tabla 4-14 Resumen de todo el proceso de eslabonamiento promedio dado por el SPSS™

Historial de conglomeración						
Etapa	Conglomerado que se combina		Coeficiente	Etapa en la que el conglomerado aparece por primera vez		Próxima etapa
	Conglomerado 1	Conglomerado 2		Conglomerado 1	Conglomerado 2	
1	1	3	0.728	0	0	3
2	2	5	0.963	0	0	4
3	1	4	1.191	1	0	4
4	1	2	2.332	3	2	0

Ya que se realizó el historial se traza el diagrama de témpanos o de carámbanos.

4.9.3.4 Diagrama de témpanos o de carámbanos

Recuerde que el diagrama de carámbanos o témpanos puede ser vertical u horizontal; los resultados arrojados por el SPSS™ quedarían de la siguiente manera:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		4		3		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X		X		X		X	x	X

Figura 4-36 Diagrama de carámbanos o témpanos vertical que el SPSS™ da como solución.

Diagrama de témpanos horizontal				
Número de conglomerados				
Caso	1	2	3	4
5	X	X	X	X
	X	X	X	
2	X	X	X	X
	X			
4	X	X	X	X
	X	X		
3	X	X	X	X
	X	X	X	X
1	X	X	X	X

Figura 4-37 Diagrama de carámbanos o témpanos horizontal que arroja como solución el SPSS™.


Nota: Si el lector desea conocer cómo se construye este diagrama puede revisar el apartado del eslabonamiento simple.

Por último se forma el dendograma como se indica en el siguiente apartado.

4.9.3.5 Dendograma


- Primero se agruparon (1, 3) a una distancia de 0.73.
- Luego se agruparon (2, 5) a una distancia de 0.96.
- Después se agruparon [(1, 3), 4] a una distancia de 1.19.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)] a una distancia de 2.33.

Por lo que el dendograma quedaría como lo muestra la siguiente figura:




4.9.3.6 Número de conglomerados a dejar como solución

Si se decide dejar alguna solución, lo único que resta es analizar la cantidad de grupos que existen a diferentes distancias; el siguiente dendograma muestra todos los segmentos posibles:



Si se miden las distancias con los segmentos formados se tienen las siguientes posibles soluciones:



Al ver los corchetes, la mayor distancia existe cuando se tienen 2 grupos; por lo que de nuevo se recomiendan 2 conglomerados, los cuales serían (1, 3, 4) y (2, 5); una vez que se decidió el número de grupos se etiquetan.

4.9.3.7 Etiquetar los conglomerados

El etiquetado en este eslabonamiento queda igual que el que se explicó para el eslabonamiento simple, ya que se agruparon de la misma manera.

Nota: Si se desea más información sobre el etiquetado revisar el apartado sobre eslabonamiento simple.

El análisis discriminante sirve para corroborar que en verdad existen esos 2 segmentos.

Así como se presentó la información para la matriz de distancia, de igual manera se podría trabajar con los 3 criterios: vecino más cercano, vecino más lejano y promedio, pero con similitudes; dado que el procedimiento es muy similar para los 3 nos concretaremos en el primero, los demás no se desarrollarán.

Para tener una idea más clara de estos conceptos es conveniente aplicarlos en un problema.

4.10 Problema de similitud

A continuación se presenta parte de un cuestionario y las respuestas de 5 familias que están aplicando para obtener un crédito bancario; parte de la información recabada fue para conocer si contaban con casa propia, auto propio y a cuánto ascendía el ingreso mensual.



Ejemplo

1. ¿Cuenta con casa propia? Sí ____ No ____
Sí ____ (1) Presencia No ____ (0) Ausencia
2. ¿Cuenta con auto propio? Sí ____ No ____
Sí ____ (1) Presencia No ____ (0) Ausencia
3. Ingreso _____
Ingreso mayor a \$10 000 (1)
Ingreso menor o igual a \$10 000 (0)

4.10.1 Codificación de variables

Las 2 primeras variables son dicotómicas (con ausencia y presencia), si se registra un 1 significa que la familia cuenta con “casa propia” y 0 significa que no es así, de igual manera para la variable “auto”, si tiene vehículo es 1 y si no 0.

Por otra parte, la variable “ingreso” se mide en escala de razón, ya que se le preguntó directamente a la familia cuánto ganaba al mes; recuérdese que cualquier variable se puede convertir a *dummy*, por ejemplo: si la familia tiene un ingreso superior a \$10 000 se asigna un 1, es decir, el atributo está presente, y si el ingreso es menor o igual a esta cantidad se coloca un 0 que indica la ausencia de un ingreso superior a \$10 000.

Los datos de las 5 familias se muestran en la siguiente tabla:

Tabla 4-15 Datos para el ejemplo

Familia	Casa	Auto	Ingreso (\$)
1	no	no	9 000
2	sí	sí	15 000
3	no	sí	5 000
4	no	no	8 000
5	sí	sí	17 000

Los datos recodificados quedaron como sigue:

Tabla 4-16 Respuestas de las 5 familias

Familia	Casa	Auto	Ingreso
1	0	0	0
2	1	1	1
3	0	1	0
4	0	0	1
5	1	1	1

4.10.2 Número de similitudes a encontrar

Inicialmente se desea saber cuántas similitudes se calcularán:

Ecuación 4-49 El número de similitudes a encontrar

$$\text{Número}(S_{ij}) = \frac{n * (n - 1)}{2}$$

En el ejemplo $n = 5$ familias, por lo que el resultado sería el siguiente:

$$\text{Número}(d_{ij}) = \frac{5 * (5 - 1)}{2} = 10$$

4.10.3 Cálculo de las similitudes a encontrar

El coeficiente de similitud que se usará para resolver este problema es el de parejas simples, aunque pudo elegirse cualquier otro. El coeficiente es:

Ecuación 4-16 Coeficiente de parejas simples

$$PS_{ij} = \frac{a + d}{a + (b + c) + d}$$

Se debe cuantificar la similitud entre las familias basándose en este coeficiente, es necesario recordar que a es la presencia de los atributos en ambos elementos (familias), d es la ausencia del atributo en ambos, $(b + c)$ son las diferencias y $a + b + c + d$ es el total de características (o variables) a evaluar; esto fue resumido en la siguiente tabla:

Tabla 4-17 Nomenclatura a utilizar en los coeficientes de similitud

Respuesta de los objetos		Objeto i		Total
		1	0	
Objeto j	1	a	b	$a + b$
	0	c	d	$c + d$
Total		$a + c$	$b + d$	$p = a + b + c + d$

Se empieza a comparar por pareja, por ejemplo, para las familias 1 y 2 no hay ninguna característica común presente en las dos (a) ni ausente en ambas (d) entonces tanto a como d tienen valor de 0 en el coeficiente, sin embargo, ($b + c$) marca la ausencia en uno y la presencia en el otro, es decir 0 y 1 o 1 y 0 tienen 3 ocurrencias; en cuanto a $a + b + c + d$ hay 3 características para evaluar (casa, carro e ingreso). La similitud entre las familias 1 y 2 es de 0 como a continuación se presenta:

Tabla 4-18 Comparación entre las familias 1 y 2

Variable	Familia 1	Familia 2	Letra	
1. Casa	0	1	c	$a = 0$
2. Auto	0	1	c	$d = 0$
3. Ingreso	0	1	c	$b + c = 3$

Al sustituir los valores en la fórmula de las parejas simples se tiene que:

$$PS_{12} = \frac{a + d}{a + (b + c) + d} = \frac{0 + 0}{0 + (3) + 0} = 0$$

De igual manera se procede con las familias 1 y 3.

Tabla 4-19 Comparación entre las familias 1 y 3

Variable	Familia 1	Familia 3	Letra	
1. Casa	0	0	d	$a = 0$
2. Auto	0	1	c	$b = 2$
3. Ingreso	0	0	d	$b + c = 1$

Para los elementos 1 y 3 no hay ningún atributo presente en ambos (a), hay 2 atributos ausentes en ambos (d), el resto son de ($b + c$), es decir 1; por lo tanto, la similitud entre estas 2 familias es de $2/3$:

$$PS_{13} = \frac{a + d}{a + (b + c) + d} = \frac{0 + 2}{0 + (1) + 2} = \frac{2}{3} = 0.67$$

De la misma forma se continúa con las familias 1 y 4:

Tabla 4-20 Comparación entre las familias 1 y 4

Variable	Familia 1	Familia 4	Letra	
1. Casa	0	0	d	$a = 0$
2. Auto	0	0	d	$d = 2$
3. Ingreso	0	1	c	$b + c = 1$

Para las familias 1 y 4 no hay ningún atributo presente en ambas (a), hay 2 atributos ausentes en las dos (d), el resto son de ($b + c$), es decir 1; por lo tanto, la similitud entre estos 2 elementos es de $2/3$:

$$PS_{14} = \frac{a + d}{a + (b + c) + d} = \frac{0 + 2}{0 + (1) + 2} = \frac{2}{3} = 0.67$$

La pareja que seguiría es la que forman la familia 1 con la 5:

Tabla 4-21 Comparación entre las familias 1 y 5

Variable	Familia 1	Familia 5	Letra	
1. Casa	0	1	c	$a = 0$
2. Auto	0	1	c	$d = 0$
3. Ingreso	0	1	c	$b + c = 3$

Para los elementos 1 y 5 no hay ningún atributo presente en ambos (a), tampoco existen atributos ausentes (d), el resto son de ($b + c$), es decir 3; por lo tanto la similitud entre estas 2 familias es de 0:

$$PS_{15} = \frac{a + d}{a + (b + c) + d} = \frac{0 + 0}{0 + (3) + 0} = 0$$

De igual manera se procede para las familias 2 y 3:

Tabla 4-22 Comparación entre las familias 2 y 3

Variable	Familia 2	Familia 3	Letra	
1. Casa	1	0	b	$a = 1$
2. Auto	1	1	a	$d = 0$
3. Ingreso	1	0	b	$b + c = 2$

Para las familias 2 y 3 existe un atributo presente en ambas (a), no hay atributos ausentes (d), el resto son ($b + c$), es decir 2, por lo tanto, la similitud entre estas 2 familias es de $1/3$:

$$PS_{23} = \frac{a + d}{a + (b + c) + d} = \frac{1 + 0}{1 + (2) + 0} = \frac{1}{3} = 0.33$$

La pareja que continúa sería la formada por las familias 2 y 4:

Tabla 4-23 Comparación entre las familias 2 y 4

Variable	Familia 2	Familia 4	Letra	
1. Casa	1	0	b	$a = 1$
2. Auto	1	0	b	$d = 0$
3. Ingreso	1	1	a	$b + c = 2$

Para los elementos 2 y 4 existe un atributo presente en ambos (a), no hay atributos ausentes (d), el resto son de ($b + c$), es decir 2; por lo tanto, la similitud entre estas 2 familias es de $1/3$:

$$PS_{24} = \frac{a + d}{a + (b + c) + d} = \frac{1 + 0}{1 + (2) + 0} = \frac{1}{3} = 0.33$$

Las familias que siguen son la 2 y 5, como se muestra en la tabla siguiente:

Tabla 4-24 Comparación entre las familias 2 y 5

Variable	Familia 2	Familia 5	Letra	
1. Casa	1	1	<i>a</i>	$a = 3$
2. Auto	1	1	<i>a</i>	$d = 0$
3. Ingreso	1	1	<i>a</i>	$b + c = 0$

Para las familias 2 y 5 existen 3 atributos presentes en ambas (*a*), no hay atributos ausentes (*d*), el resto son de (*b* + *c*), es decir 0; por lo tanto la similitud entre estos 2 elementos es de 1:

$$PS_{25} = \frac{a + d}{a + (b + c) + d} = \frac{3 + 0}{3 + (0) + 0} = 1$$

La pareja que continúa sería la formada por las familias 3 y 4:

Tabla 4-25 Comparación entre las familias 3 y 4

Variable	Familia 3	Familia 4	Letra	
1. Casa	0	0	<i>d</i>	$a = 0$
2. Auto	1	0	<i>b</i>	$d = 1$
3. Ingreso	0	1	<i>c</i>	$b + c = 2$

Para los elementos 3 y 4 no existen atributos presentes en ambos (*a*), hay un atributo ausente (*d*), el resto son de (*b* + *c*), es decir 2; por tanto, la similitud entre estas 2 familias es de 1/3:

$$PS_{34} = \frac{a + d}{a + (b + c) + d} = \frac{0 + 1}{0 + (2) + 1} = \frac{1}{3} = 0.33$$

Las familias que siguen son la 3 y la 5 como se detalla en la tabla siguiente:

Tabla 4-26 Comparación entre las familias 3 y 5

Variable	Familia 3	Familia 5	Letra	
1. Casa	0	1	<i>c</i>	$a = 1$
2. Auto	1	1	<i>a</i>	$d = 0$
3. Ingreso	0	1	<i>c</i>	$b + c = 2$

Para las familias 3 y 5 existe un atributo presente en ambas (*a*), no hay atributos ausentes (*d*), el resto son de (*b* + *c*), es decir 2; por lo tanto, la similitud entre estos 2 elementos es de 1/3:

$$PS_{35} = \frac{a + d}{a + (b + c) + d} = \frac{1 + 0}{1 + (2) + 0} = \frac{1}{3} = 0.33$$

La pareja que continúa es la formada por las familias 4 y 5:

Tabla 4-27 Comparación de las familias 4 y 5

Variable	Familia 4	Familia 5	Letra	
1. Casa	0	1	<i>c</i>	$a = 1$
2. Auto	0	1	<i>c</i>	$d = 0$
3. Ingreso	1	1	<i>a</i>	$b + c = 2$

Para los elementos 4 y 5 existe un atributo presente en ambos (a), no hay atributos ausentes (d), el resto son de ($b + c$), es decir 2; por lo que la similitud entre estas 2 familias es de $1/3$:

$$PS_{45} = \frac{a + d}{a + (b + c) + d} = \frac{1 + 0}{1 + (2) + 0} = \frac{1}{3} = 0.33$$

Posteriormente toda la información que se acaba de encontrar se vacía en una matriz cuadrada, la cual es referida como matriz de similitud, que a continuación se presenta:

Tabla 4-28 Matriz de similitud

	1	2	3	4	5
1	1				
2	0	1			
3	0.67	0.33	1		
4	0.67	0.33	0.33	1	
5	0	1	0.33	0.33	1

Como se puede observar la diagonal de esta matriz, a diferencia de la matriz de distancia, está formada por números 1, ya que al comparar a una familia consigo misma su similitud es de 1; esto quiere decir que mientras la relación o similitud entre 2 elementos se acerque más a 1 hay más parecido entre ellos.

En esta matriz podemos concluir que las familias más parecidas son la 5 y la 2 con una medida de similitud de 1 (mayor similitud) y las parejas menos parecidas son la 2 y 1 y la 1 y 5 con una medida de similitud de 0 (menor similitud, nula).

4.10.4 Vinculación o eslabonamiento simple

La vinculación o eslabonamiento simple también se denomina *criterio simple* o del *vecino más cercano*. Para realizar este eslabonamiento tomaremos la matriz de similitud que ya teníamos del ejemplo anterior y con ella trabajaremos.

4.10.4.1 Agrupar

El primer paso es agrupar; como se manejan similitudes deberá buscarse la proximidad mayor entre 2 elementos ($\max\{S_{ij}\}$), que en este caso es 2 y 5 con un valor de 1, ya que es la pareja más parecida.

Tabla 4-29 Agrupar a la pareja más parecida


	1	2	3	4	5
1	1				
2	0	1			
3	0.67	0.33	1		
4	0.67	0.33	0.33	1	
5	0	1	0.33	0.33	1

La nueva pareja se coloca al inicio de la matriz, la diagonal se llena con los valores de 1, pues recuérdese que se está comparando el elemento consigo mismo.

	(2, 5)	1	3	4
(2, 5)	1			
1		1		
3			1	
4				1

4.10.4.2 Eslabonar o vincular

Se inicia el eslabonamiento y como se escogió el criterio del vecino más cercano, al momento de eslabonar se escogerá la similitud más grande $S_{[(U,V),W]} = \text{Mín}\{S_{U,W}, S_{V,W}\}$, es decir, se compara al nuevo grupo (2, 5) con el resto; se confronta al elemento 1 con el 2 y se observa que tienen una similitud de 0, luego se compara al 1 con el 5 y se constata que tienen una similitud de 0; en este caso la similitud en las 2 parejas es la misma.



El valor eslabonado se acomoda en la matriz reducida:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3			1	
4				1

Nuevamente bajo el mismo criterio se eslabona el elemento 3 con la pareja de las familias (2, 5):



Otra vez, en este proceso se deja la similitud de 0.33 porque es la misma en ambos casos y de nuevo se acomoda este valor en la matriz reducida:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33		1	
4				1

Ya por último se toma la similitud del elemento 4 con el grupo formado por las familias (2, 5):



Y el valor se acomoda en la matriz reducida:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33		1	
4	0.33			1

Los valores faltantes de la matriz se llenan con los datos de la matriz original.

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

Una vez que la matriz está completa, nuevamente se agrupa la próxima pareja a formar y se escoge a la más parecida que, en este caso, serían los elementos 1 y 4 que tienen la similitud más grande que es de 0.67; también pudo elegirse la pareja formada por las familias 1 y 3 ya que su similitud es igual a 0.67.

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

4.10.4.3 Historial del eslabonamiento

Recuerde que la información de todo lo que se realizó se puede resumir en la siguiente tabla:

Tabla 4-30 Resumen de todo el proceso de eslabonamiento simple para similitudes

Etapa	Objetos agrupados		Coeficiente: distancia	Etapa donde aparecieron		Próxima etapa donde aparecerán
	Grupo 1	Grupo 2		Grupo 1	Grupo 2	
1	2	5	1.00	0	0	4
2	1	4	0.67	0	0	3
3	(1,4)	3	0.67	2	0	4
4	[(1,3),4]	(2,5)	0.33	3	1	0

La tabla anterior muestra que en la primera etapa se agrupó el elemento 2 y el 5, con una similitud de 1.00; en las siguientes 2 columnas se presenta en qué etapa habían aparecido con anterioridad, el valor de cero indica que no habían aparecido antes, la última columna indica en qué próxima etapa volverán a aparecer, en este caso sería en la 4. En la segunda etapa se unieron las familias 1 y 4, con una similitud de 0.67, ninguno de los 2 elementos había aparecido antes, y volverán a aparecer en la siguiente etapa, es decir en la 3. En la tercera etapa se unieron la pareja (1, 4) con el elemento 3, con

una similitud de 0.67, la pareja (1, 4) apareció con anterioridad en la etapa 2, pero el elemento 3 no lo había hecho, los 3 elementos aparecerán en la etapa 4; el resto de la tabla se sigue interpretando de la misma manera.

La información que el SPSS™ reporta de esa matriz es la siguiente:

Tabla 4-31 Resumen de todo el proceso de eslabonamiento simple para similitudes arrojado por el SPSS™

Historial de conglomeración						
	Conglomerado que se combina			Etapa en la que el conglomerado aparece por primera vez		
Etapa	Conglomerado 1	Conglomerado 2	Coficiente	Conglomerado 1	Conglomerado 2	Próxima etapa
1	2	5	1.000	0	0	4
2	1	4	0.667	0	0	3
3	1	3	0.667	2	0	4
4	1	2	0.333	3	1	0

Como se observa es la misma tabla sólo que al momento de volver a nombrar un elemento o *cluster* pone únicamente la etiqueta de la primera familia que agrupó; por ejemplo, en la etapa 3 en las columnas de los conglomerados que se combinan puso la etiqueta de 1 y de 3; eso significa que se deben revisar los demás pasos para saber a quiénes está nombrando, en este caso al decir 1 significa que etiquetó el *cluster* que contiene a las familias (1, 4) y el elemento 3.

Una vez terminado el proceso de agrupar y eslabonar, es decir la vinculación, los resultados se pueden representar a través de un diagrama de témpanos y de un dendograma.

4.10.4.4 Diagrama de témpanos o de carámbanos

Recuerde que el diagrama de témpanos simplifica y muestra quiénes se fueron agrupando paso a paso, en este caso se tiene el número total de elementos, es decir 5, los cuales son enlistados en las columnas de la forma en que se fueron agrupando:

- Primero se agruparon (2, 5).
- Luego se agruparon (1, 4).
- Después se agruparon [(1, 4), 3].
- Posteriormente se agruparon [(1, 3, 4), (2, 5)].

El número de pasos que se realizó fue:

$$\# \text{ de pasos} = n - 1$$

Recuerde que n es el número de elementos con que se inicia el problema.

En el ejemplo que se resolvió, el número de elementos o familias fue 5, por lo que el número de pasos sería:

$$\# \text{ de pasos} = n - 1 = 5 - 1 = 4$$

Todo lo anterior se muestra continuación:

	Elementos							
Número de grupos o conglomerados	2		5		1		4	3
1	X		X		X		X	X
2	X		X		X		X	X
3	X		X		X		X	X
4	X		X		X		X	X

De los 5 elementos se agrupó la pareja (2, 5) y que quedaron 4 grupos, los cuales fueron: (2, 5), (1), (3) y (4).

La columna que se encuentra entre el elemento 2 y 5 deberá llenarse con X.

Número de grupos o conglomerados	Elementos								
	2		5		1		4		3
1	X	X	X		X		X		X
2	X	X	X		X		X		X
3	X	X	X		X		X		X
4	X	X	X		X		X		X

Posteriormente se agrupó la pareja (1, 4) y quedaron sólo 3 conglomerados: (2, 5), (1, 4) y (3).

Eso implica que la columna que se encuentra entre el elemento 1 y el 4 deberá llenarse también con X, pero sólo hasta el número de conglomerados, en este caso 3; esto se muestra a continuación:

Número de grupos o conglomerados	Elementos								
	2		5		1		4		3
1	X	X	X		X	X	X		X
2	X	X	X		X	X	X		X
3	X	X	X		X	X	X		X
4	X	X	X		X		X		X

En el siguiente paso se agrupó el elemento 3 con la pareja (1, 4) por lo que quedaron sólo 2 segmentos: [(1, 4), 3] y (2, 5).

La columna que se encuentra entre el elemento 3 y la pareja (1, 4) deberá llenarse con X, pero sólo hasta el número de conglomerados, en este caso 2, como se muestra a continuación:

Número de grupos o conglomerados	Elementos								
	2		5		1		4		3
1	X	X	X		X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X	X	X		X
4	X	X	X		X		X		X

En el siguiente paso se agrupó el conglomerado [(1, 4), 3] con la pareja (2, 5) por lo que quedó sólo un segmento: [(1, 3, 4), (2, 5)].

Eso significa que la columna que se encuentra entre el conglomerado [(1, 4), 3] con (2, 5) deberá llenarse con X, pero sólo hasta el número de conglomerados, que en este caso es 1; esto se muestra a continuación, el cual sería el diagrama final:

Número de grupos o conglomerados	Elementos									
	2		5		1		4		3	
1	X	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X	X
3	X	X	X		X	X	X			X
4	X	X	X		X		X			X

Al anterior esquema se le denomina *diagrama de carámbanos vertical*. El resultado del diagrama de témpanos en el SPSS™ se presenta a continuación:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		3		4		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

Figura 4-38 Diagrama de carámbanos o témpanos vertical que arroja el SPSS™.

De nuevo note que los elementos se encuentran en diferente orden; el SPSS™ escogió éste. El diagrama de carámbanos horizontal en el SPSS™ sería el siguiente:

Diagrama de témpanos horizontal				
Número de conglomerados				
Caso	1	2	3	4
5	X	X	X	X
	X	X	X	X
2	X	X	X	X
	X			
3	X	X	X	X
	X	X		
4	X	X	X	X
	X	X	X	
1	X	X	X	X

Figura 4-39 Diagrama de carámbanos o témpanos horizontal que pone como solución el SPSS™.


4.10.4.5 Dendograma

Recuerde que el dendograma en similitudes debe empezar con el valor máximo, que es el valor de la diagonal de la matriz de similitud, el cual es 1; es necesario recordar el orden en que se agruparon los elementos y sus similitudes. En el eje horizontal del diagrama se colocan los elementos que se están agrupando, de preferencia en el orden en que se fueron uniendo, en este caso:


- Primero se agruparon (2, 5) con una similaridad de 1.00.
- Luego se agruparon (1, 4) con una similaridad de 0.67.
- Después se agruparon [(1, 4), 3] con una similaridad de 0.67, por lo que estos últimos 3 elementos no pueden estar separados.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)] con una similaridad de 0.33.

Éste podría ser el orden para acomodar los elementos, pero no es la única opción; recuerde que siempre deberán estar juntos los elementos que fueron agrupados en un segmento.


En el eje vertical se manejan las medidas de similaridad, el punto inicial es el valor máximo, debido a que se supone que cada elemento es un grupo y la relación de similitud consigo mismo es 1; las demás similaridades se ponen en orden (hacia arriba del eje) como se unieron los diferentes segmentos, es decir: 1.00, 0.67 y 0.33. Aquí se debe tener cuidado con la elección del coeficiente de similaridad, ya que el valor de la diagonal depende de éste, entonces en el eje vertical el punto inicial sería el 1 o el infinito (según el coeficiente de similitud utilizado) y hacia arriba del eje disminuirían los valores, que indican que los elementos son cada vez menos parecidos conforme se avanza en el proceso del agrupamiento; todo lo anterior se muestra a continuación:




Al trazar las líneas de cada pareja nueva al agruparse, se tiene que la primera pareja se formó a una similaridad de 1.00:




Nuevamente es importante recalcar que se pusieron las barras en diferentes tonalidades de gris para que el lector distinga entre un grupo y otro, al final dichos tonos se quitarán para que se ponga en su forma correcta. Posteriormente se agruparon las familias 1 y 4 a una similaridad de 0.67:



Después se agruparon la pareja (1, 4) y la familia 3 a una similitud de 0.67:



Y por último se agruparon el segmento (1, 3, 4) con la pareja (2, 5) a una similitud de 0.33:



A continuación se muestra el dendograma completamente terminado y tonalidades de gris:




Figura 4-40 Dendograma terminado.

Es importante señalar que en el dendograma no se deben cruzar las líneas que definen el número de segmentos; aunque podría pensarse que en el segmento (1, 3, 4) se están cruzando, esto no es así.

De nuevo se rota 90 grados el dendograma para que quede de la misma manera en que la mayoría de los software estadísticos lo presentan, incluyendo el SPSS™, y esto quedaría de la siguiente forma:




Figura 4-41 Dendograma terminado y rotado.

4.10.4.6 Número de conglomerados a dejar como solución

Ahora se verá cuántos grupos se deberán proponer, según la similaridad a la que se unieron los diferentes segmentos; el lector podrá trazarlos en el dendograma (rotado o no rotado); en resumen los grupos formados fueron:





Figura 4-42 Muestra de todos los grupos posibles a formarse y tomarse en cuenta, en el dendrograma.

Nota: Se decidió explicar esto en el dendrograma no rotado.

Debido a la similitud que existe entre los conglomerados, la solución más factible es la de 2 grupos (1, 3, 4), y (2, 5), sus similitudes se muestran en la siguiente figura, en donde se pusieron las llaves del mismo tamaño para que el lector vea cuál es la menor similitud, recuerde que es la similitud entre segmentos, es decir, cuándo se forma el siguiente grupo, lo cual significa que a mayor distancia entre las llaves es menor la similitud, por lo que los segmentos en este caso son los menos parecidos:



Como se mostró en la figura anterior la menor similitud es la que existe cuando se unen los segmentos (1, 3, 4) con (2, 5), por lo que se decide dejar sólo 2 conglomerados. Pero este número de grupos que se está dejando como solución es sólo tentativo, no hay que olvidar que el análisis discriminante verificará si esta opción es la correcta, esto se verá más a detalle en el siguiente capítulo.

4.10.4.7 Etiquetado de los conglomerados

Después de definir el número de conglomerados, el paso que sigue es etiquetarlos; si las variables son no métricas se realiza a través de una moda y si son métricas con la media. En el siguiente cuadro se muestra el etiquetado de cada grupo:

Tabla 4-32 Etiquetas de las variables que entraron en el análisis de similitud

Familia	Casa	Auto	Ingreso
1	No	No	9 000
2	Sí	Sí	15 000
3	No	Sí	5 000
4	No	No	8 000
5	Sí	Sí	17 000

Por ejemplo si las familias 1, 3 y 4 están en un grupo se obtiene la moda de cada variable, en este caso en la variable “casa” la moda es “no”,⁷ lo mismo ocurre con la variable “auto” y en la variable “ingreso” la media es \$7 333, por lo que se puede definir o etiquetar como un segmento de clase baja, pues no cuentan con casa, ni con auto y su ingreso promedio es de \$7 333.

En el grupo formado por las familias 2 y 5 la moda de “casa” es “sí”, en “auto” la moda es “sí” y en la variable ingreso la media es \$16 000. Por lo que este grupo podría etiquetarse como un segmento de clase media o alta, pues cuenta con casa, con carro y su ingreso promedio es de \$16 000.

Como ya se mencionó, este problema se resolverá también por el eslabonamiento completo y promedio para mostrar su aplicación. El proceso de agrupamiento es siempre el mismo, la próxima pareja a formar es la más parecida, por lo que siempre se escoge la menor distancia o mayor similitud; lo único que cambia es la forma de eslabonar o vincular, es decir, la decisión al determinar el grado de proximidad entre un nuevo segmento y los elementos no agrupados en él.

4.10.5 Vinculación o *eslabonamiento completo*

A la vinculación también se le conoce como el *vecino más lejano*. En este caso se inicia con la selección de la pareja más parecida, es decir, la que tenga la mayor similitud (porque se está usando una matriz de similitud); después se aplica el criterio de vinculación, que en este caso es:

$$S_{[(U,V),W]} = \text{Mín}\{S_{U,W}, S_{V,W}\}$$

4.10.5.1 Agrupar

Se agrupa por la máxima similitud entre objetos, personas o categorías; es decir, siempre es la pareja más parecida:

Tabla 4-33 Agrupar a los elementos 2 y 5

	1	2	3	4	5
1	1				
2	0.00	1			
3	0.67	0.33	1		
4	0.67	0.33	0.33	1	
5	0.00	1.00	0.33	0.33	1

Así que en este caso la más grande es la similitud entre las familias 2 y 5; recuerde que el nuevo grupo formado se coloca en una nueva matriz reducida, de 5×5 queda en 4×4 como se muestra a continuación:

⁷ La moda es el valor que más se repite y como el “no” es el valor que tiene la mayor frecuencia (3), ésta es la moda.

	(2, 5)	1	3	4
(2, 5)	1			
1		1		
3			1	
4				1

Una vez que se formó el nuevo grupo se realiza la vinculación.

4.10.5.2 Eslabonar

El siguiente paso consiste en completar los valores faltantes de la matriz (o eslabonar), se empezará con la comparación de la familia 1 con el grupo (2, 5):



En este caso el valor a escoger fue 0; sigue eslabonar a la familia 3 con el grupo (2, 5):



El valor eslabonado fue 0.33; sigue vincular la familia 4 con el grupo (2, 5):



Los 3 valores resultantes se acomodan en la matriz reducida:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33		1	
4	0.33			1

Los valores restantes se toman de la matriz original hasta completar la matriz triangular:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

Ahora que la matriz está completa se agrupan los elementos, recuerde que se busca el mayor valor; en este caso las familias más parecidas son la 1 y 4 o la 1 y 3, ya que tienen los mismos valores; se podría seleccionar cualquiera de las 2. Suponga que se eligió la 1 y la 4 y así se continúa como con el ejemplo anterior.

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

4.10.5.3 Historial del eslabonamiento

El siguiente paso es formar la tabla del historial, sólo se mostrará la salida que da el SPSS™, si el lector desea saber cómo formar la tabla puede revisar el procedimiento del eslabonamiento simple. El historial quedaría de la siguiente manera:

Tabla 4-34 Resumen de todo el proceso de eslabonamiento completo dado por el SPSS™

Historial de conglomeración						
	Conglomerado que se combina			Etapa en la que el conglomerado aparece por primera vez		
Etapa	Conglomerado 1	Conglomerado 2	Coeficiente	Conglomerado 1	Conglomerado 2	Próxima etapa
1	2	5	1.000	0	0	4
2	1	4	0.667	0	0	3
3	1	3	0.333	2	0	4
4	1	2	0.000	3	1	0

Ya que se realizó el historial se traza el diagrama de témpanos o de carámbanos, como veremos a continuación.

4.10.5.4 Diagrama de témpanos o de carámbanos

Recuerde que el diagrama de carámbanos o témpanos puede ser vertical u horizontal y quedaría de la siguiente manera:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		3		4		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

Figura 4-43 Diagrama de carámbanos o témpanos vertical que el SPSS™ da como solución.

Diagrama de témpanos horizontal				
Número de conglomerados				
Caso	1	2	3	4
5	X	X	X	X
	X	X	X	X
2	X	X	X	X
	X			
3	X	X	X	X
	X	X		
4	X	X	X	X
	X	X	X	
1	X	X	X	X

Figura 4-44 Diagrama de carámbanos o témpanos horizontal que pone como solución el SPSS™.

Nota: Si el lector desea conocer cómo se construye este diagrama puede consultar el apartado de eslabonamiento simple.

Y por último se forma el dendograma como se verá en el apartado siguiente.

4.10.5.5 Dendograma

El dendograma sin rotar quedaría de la siguiente manera:

- Primero se agruparon (2, 5) con una similitud de 1.00.
- Luego se agruparon (1, 4) con una similaridad de 0.67.
- Después se agruparon [(1, 4), 3] con una similitud de 0.33.
- Posteriormente se agruparon [(1, 3, 4), (2, 5)] con una similaridad de 0.00.

Por lo que el dendograma quedaría como lo muestra la siguiente figura:





Figura 4-45 Dendograma sin rotar, con la solución del eslabonamiento completo.


Como se ve la solución es la misma.

4.10.5.6 Número de conglomerados a dejar como solución

Si se decide dejar alguna solución, lo único que resta es analizar la cantidad de grupos que existe en cada distancia, el siguiente dendograma muestra algunos segmentos:



Ahora se verá cuántos grupos posibles deberán formarse:



Como en similitudes se debe tomar en cuenta la menor, de nuevo se recomiendan 2 conglomerados, los cuales serían (1, 3, 4) y (2, 5). Una vez que se decidió el número de segmentos a dejar se etiquetan.

4.10.5.7 Etiquetado de los conglomerados

El etiquetado en este caso sería el mismo, ya que se agruparon de la misma manera que en el eslabonamiento simple.

Nota: Si el lector desea más información sobre el etiquetado puede consultar el apartado de eslabonamiento simple.

Recuerde que con el análisis discriminante se puede comprobar si en realidad existen esos 2 segmentos.

4.10.6 Eslabonamiento promedio entre grupos

El agrupamiento en este caso se basará en el criterio de eslabonamiento promedio, para evaluar el grado de similitud que tendrá el nuevo grupo con otros elementos no agrupados. El promedio de las relaciones antes de agruparse se obtendrá con la fórmula siguiente:

$$S_{[(U,V),W]} = \frac{\sum_{i,k} S_{i,k}}{N_{(U,V)} N_{(W)}}.$$

4.10.6.1 Agrupar

Para agrupar se tomará la matriz de similitud del ejemplo anterior; recuerde que en similitudes la relación de los elementos a unirse siempre es con el valor mayor.

Tabla 4-34 Agrupar la primera pareja que se formará

	1	2	3	4	5
1	1				
2	0.00	1			
3	0.67	0.33	1		
4	0.67	0.33	0.33	1	
5	0.00	1.00	0.33	0.33	1

El nuevo grupo (2, 5) se ubica en primer lugar en la nueva matriz reducida, la cual pasó de 5×5 a 4×4 , como se muestra a continuación:

	(2, 5)	1	3	4
(2, 5)	1			
1		1		
3			1	
4				1

El siguiente paso es eslabonar.

4.10.6.2 Eslabonar o vincular

Como se escogió el criterio del eslabonamiento promedio, se necesita escoger la similitud promedio, la cual se calcula con la siguiente fórmula:

$$S_{[(U,V),W]} = \frac{\sum_{i,k} S_{i,k}}{N_{(U,V)} N_{(W)}}$$

Es necesario comparar la familia 1 con el elemento 2, se observa que tiene una similitud de 0; se compara el elemento 1 con el 5 y se ve que tiene una similitud de 0. Al momento de eslabonar se calcula el promedio, esto se resumirá de la siguiente manera:



El promedio se obtiene con la siguiente fórmula:

$$S_{[(2,5),(1)]} = \frac{\sum_{i,k} S_{i,k}}{N_{(2,5)} N_{(1)}} = \frac{0+0}{2*1} = 0$$

De la fórmula anterior ambas similitudes de 0 provienen de la matriz original, el número 2 y 1 proceden del número de elementos que cada segmento contiene, es decir, el 2 viene de la pareja (2, 5) y el 1 del elemento 1. El valor eslabonado se acomoda en la matriz reducida. Sigue comparar la familia 3 con el segmento (2, 5).



Si no se desea realizar la comparación anterior, el 0.33 proviene de:

$$S_{[(2,5),(3)]} = \frac{\sum_{i,k} S_{i,k}}{N_{(2,5)} N_{(3)}} = \frac{0.33 + 0.33}{2*1} = 0.33$$

Al comparar el 3 con $N = 1$ y la pareja (2, 5) con $N = 2$, las similitudes provienen de la matriz original; el valor eslabonado es de 0.33, el cual se acomoda en la matriz reducida. Sigue comparar el elemento 4 con el segmento (2, 5):



El valor de 0.33 procede de:

$$S_{[(2,5),(4)]} = \frac{\sum_{i,k} d_{i,k}}{N_{(2,5)} N_{(4)}} = \frac{0.33 + 0.33}{2*1} = 0.33$$

Los 3 valores eslabonados con anterioridad se acomodan en la matriz reducida, la cual quedaría de la siguiente manera:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33		1	
4	0.33			1

Los valores faltantes se retoman de la matriz anterior y la nueva quedaría de la siguiente manera:

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

Una vez que la matriz está completa, nuevamente se agrupan los elementos; se selecciona a la pareja más parecida, que en este caso sería la formada por las familias 1 y 4, pues tienen la similaridad más grande que es de 0.67 y así se continúa como con el ejemplo anterior.

	(2, 5)	1	3	4
(2, 5)	1			
1	0	1		
3	0.33	0.67	1	
4	0.33	0.67	0.33	1

4.10.6.3 Historial del eslabonamiento

El siguiente paso es formar la tabla del historial, el cual se mostrará con la salida que da el SPSS[™], si el lector desea saber cómo formar la tabla puede revisar el proceso del eslabonamiento simple. La tabla del historial quedaría de la siguiente manera:

Tabla 4-36 Resumen de todo el proceso de eslabonamiento promedio dado por el SPSS[™]

Historial de conglomeración						
	Conglomerado que se combina			Etapas en la que el conglomerado aparece por primera vez		
Etapas	Conglomerado 1	Conglomerado 2	Coefficiente	Conglomerado 1	Conglomerado 2	Próxima etapas
1	2	5	1.000	0	0	4
2	1	4	0.667	0	0	3
3	1	3	0.500	2	0	4
4	1	2	0.222	3	1	0

Ya que se realizó el historial se traza el diagrama de témpanos o de carámbanos como se verá en el apartado siguiente.

4.10.6.4 Diagrama de témpanos o de carámbanos

Recuerde que el diagrama de carámbanos o témpanos puede ser vertical u horizontal, los resultados arrojados por el SPSS[™] quedarían de la siguiente manera:

Diagrama de témpanos vertical									
Caso									
Número de conglomerados	5		2		3		4		1
1	X	X	X	X	X	X	X	X	X
2	X	X	X		X	X	X	X	X
3	X	X	X		X		X	X	X
4	X	X	X		X		X		X

Figura 4-46 Diagrama de carámbanos o témpanos vertical que el SPSS[™] da como solución.

Diagrama de témpanos horizontal				
Número de conglomerados				
Caso	1	2	3	4
5	X	X	X	X
	X	X	X	X
2	X	X	X	X
	X			
3	X	X	X	X
	X	X		
4	X	X	X	X
	X	X	X	
1	X	X	X	X

Figura 4-47 Diagrama de carámbanos o témpanos horizontal que pone como solución el SPSS™.

Nota: Si el lector desea conocer cómo se construye el diagrama anterior puede revisar el apartado de eslabonamiento simple.


Por último se forma el dendograma como se indica en el siguiente apartado.

4.10.6.5 Dendograma

El dendograma sin rotar quedaría de la siguiente manera:


- Primero se agruparon (2, 5) con una similaridad de 1.00.
- Luego se agruparon (1, 4) con una similitud de 0.67.
- Después se agruparon [(1, 4), 3] con una similaridad de 0.50.
- Posteriormente se agruparon [(1, 4, 3), (2, 5)] a una distancia de 0.22.

Por lo que el dendograma quedaría como lo muestra la siguiente figura:




4.10.6.6 Número de conglomerados a dejar como solución

Si se decide dejar alguna solución, lo único que resta es analizar la cantidad de grupos que existe en cada similaridad, el siguiente dendrograma muestra todos los segmentos posibles:



Si se miden las distancias de los segmentos formados se tienen las siguientes posibles soluciones:



Como se puede ver en los corchetes, la menor similitud existe cuando se tienen 2 grupos; por lo que de nuevo se recomienda que haya 2 conglomerados, los cuales serían (1, 3, 4) y (2, 5); tras decidir el número de segmentos a dejar se etiquetan.

4.10.6.7 Etiquetar los conglomerados

El etiquetado en este caso sería el mismo ya que se agruparon de la misma manera que en el eslabonamiento simple y completo.

Nota: Si el lector desea más información sobre el etiquetado, consulte el apartado de eslabonamiento simple.

El análisis discriminante sirve para comprobar si en realidad existen esos 2 segmentos.

4.11 Métodos de agrupamiento no jerárquico

La mayoría de las técnicas de los métodos no jerárquicos no requieren tener como información una matriz de distancia o similitud, además no es necesario seguir un orden en la formación de los conglomerados, como en los métodos jerárquicos. Estas técnicas son muy utilizadas cuando en la investigación se tiene un gran número de variables o un gran número de elementos.

Los métodos no jerárquicos se subdividen en:




Figura 4-48 Técnicas de los métodos no jerárquicos.

4.11.1 Método de reasignación o basados en el centroide

El **método de reasignación** permite que un individuo asignado a un grupo en un determinado paso del proceso sea reasignado a otro conglomerado en un paso posterior, ya que el grupo en el que originalmente estaba no era el adecuado; al reasignarse se optimiza el criterio de selección. El proceso termina cuando todos los elementos quedan asignados en un grupo y no existe una mejor forma de acomodarlos. Algunos de los algoritmos más conocidos dentro de estos métodos son: k-promedios y k-medianas, su diferencia estriba en cómo se encuentra el centroide de cada grupo.

Método de reasignación. Permite que un individuo asignado a un grupo sea reasignado a otro en un paso posterior del proceso, ya que no estaba en el grupo adecuado; al reasignarse se optimiza el criterio de selección.

4.11.2 Método de búsqueda de la densidad

Existen dos métodos de búsqueda de la densidad: aproximación tipológica y aproximación probabilística; en el presente texto sólo se mencionará el último.

La aproximación probabilística se basa en que cada objeto posee una distribución probabilística, la cual le da la probabilidad particular de pertenecer a cada uno de los segmentos; cada objeto es asignado a un grupo basándose en el valor más alto de la probabilidad de pertenencia.

4.11.3 Método de reducción de dimensiones

El **método de reducción de dimensiones** consiste en buscar dimensiones latentes en un conjunto de individuos según sus características y con base en ellas determina un calificativo que describa al conglomerado; el algoritmo de este método es el análisis de factores tipo Q.⁸

En este libro se ejemplificará solamente una de las técnicas explicadas y será la de k-promedios.

Método de reducción de dimensiones. Busca dimensiones latentes en un conjunto según sus características y con base en ellas determina un calificativo que describa al conglomerado.

4.12 Técnicas de k-promedios

La **técnica de k-promedios** también denominada *k-means* requiere que el investigador especifique el número de grupos que se desea tener como solución final. La técnica agrupa los elementos, ya sea en forma aleatoria o bien de acuerdo con algún criterio propio del investigador. Posteriormente se obtiene el promedio para cada grupo de cada una de las características (o variables) usadas al segmentar para verificar si la asignación de los elementos en los conglomerados es la correcta; esto se muestra en la siguiente figura:



Figura 4-49 Búsqueda de promedios o centroides de cada grupo.

Técnica de k-promedios. Agrupa los elementos para obtener el promedio de cada característica usada al segmentar en cada grupo y verificar que la asignación de los elementos en los conglomerados sea correcta.

⁸ Técnica mencionada en el capítulo 3 "Análisis de factores".

Lo anterior se lleva a cabo con el fin de obtener la distancia de cada uno de los objetos con respecto al valor promedio de su propio grupo, como se muestra en la siguiente figura:



Figura 4-50 Búsqueda de la distancia de cada uno de los elementos con su propio grupo o con el centro de éste.

Posteriormente se evalúa la distancia con respecto a los restantes conglomerados. Como en el ejemplo que se está manejando se tienen 2 grupos, sólo existe una distancia, como se muestra a continuación:




Figura 4-51 Búsqueda de la distancia de uno de los elementos con el otro grupo o con el centro del otro grupo.

Después se comparan todas las distancias del objeto y se escoge la menor; si la menor es respecto a su grupo, como en este caso, entonces la asignación es correcta; si no es así, es decir, si la distancia con su grupo fue la más grande, entonces el elemento se encuentra mal asignado, ya que sus características son más afines al otro grupo, como lo muestra la siguiente figura:




Figura 4-52 Elemento mal asignado.

El camino a seguir en estos casos es que ese objeto o persona deberá cambiarse o reasignarse al grupo en donde se obtuvo la menor distancia, es decir, con el que se identifica mejor. Así, el proceso se repite hasta que todas y cada una de las asignaciones sean probadas y estén correctamente asignadas.

Para que este procedimiento quede claro se aplicará en un ejemplo, recuerde que la técnica usada es la k-promedios.



Ejemplo

Se realiza un estudio sobre los últimos hechos de violencia que se han generado en la ciudad, por lo que se les preguntó a las personas lo siguiente:

1. ¿Considera usted que los padres son los responsables directos del comportamiento de los hijos?
CA _____ CD _____
2. ¿Cree usted que los medios de comunicación influyen ampliamente en el comportamiento de los jóvenes?

CA _____ CD

3. ¿Piensa usted que actualmente los jóvenes tienen muy poco respeto por la autoridad?

CA _____ CD

4. ¿Considera usted que las escuelas deben ser copartícipes en la educación de los valores?

CA _____ CD

5. ¿Está de acuerdo en que las amistades influyen fuertemente en el comportamiento de los jóvenes?

CA _____ CD

Nota: Donde 1 = CA (completamente de acuerdo) y 5 = CD (completamente en desacuerdo).

Las respuestas de 5 personas fueron las siguientes:⁹

Tabla 4-37 Respuesta a las 5 variables de 5 personas

Variables	Personas				
	1	2	3	4	5
X_1	1	4	4	1	4
X_2	1	3	5	2	3
X_3	2	5	4	2	4
X_4	1	4	4	1	3
X_5	1	4	3	1	3

4.12.1 Estandarizar las variables

El primer paso es estandarizar los datos de las variables para quitarles los efectos de las unidades y que sean comparables. Los datos estandarizados son los siguientes:

Tabla 4-38 Respuestas estandarizadas de las 5 personas

Variables	Personas				
	1	2	3	4	5
X_1	-1.10	0.73	0.73	-1.10	0.73
X_2	-1.21	0.13	1.48	-0.54	0.13
X_3	-1.04	1.19	0.45	-1.04	0.45
X_4	-1.06	0.92	0.92	-1.06	0.26
X_5	-1.04	1.19	0.45	-1.04	0.45

4.12.2 Promedios de los grupos

Como segundo paso se escoge una semilla,¹⁰ el investigador deberá decidir de primera instancia con cuántos grupos iniciar, es decir, la base del número de grupos (k) que se desea tener como solución. En este ejemplo se dará comienzo con 2 grupos, se deberá escoger cualquier par de individuos por lo que se iniciará con los 2 primeros, es decir, persona 1 y persona 2 y se comparará la distancia entre ellas, la cual es de 4.366. (Esta distancia se obtiene con la fórmula de distancia euclidiana previamente explicada.)

⁹ Datos generados para efecto de este texto.

¹⁰ La semilla o arrancador será el promedio de los grupos con los cuales se inicia el análisis.

$$D_{[1,2]} = [-1.10 - 0.73]^2 + (-1.21 - 0.13)^2 + (-1.04 - 1.19)^2 + (-1.06 - 0.92)^2 + (-1.04 - 1.19)^2]^{\frac{1}{2}} = 4.366$$


La idea es que se queden las 2 personas que tengan su distancia más lejana y sean las semillas para formar los grupos totalmente heterogéneos.

Ahora se comparan las distancias de las personas 1 y 2 con la siguiente, en este caso la 3.

$$D_{1,3} = [.73 + 1.09]^2 + (1.48 + 1.21)^2 + (.44 + 1.04)^2 + (.923 + 1.05)^2 + (.44 + 1.04)^2]^{\frac{1}{2}} = 4.355$$

$$D_{2,3} = [(.73 - .73)^2 + (1.48 - .134)^2 + (.44 - 1.19)^2 + (.923 - .923)^2 + (.44 - 1.19)^2]^{\frac{1}{2}} = 1.712$$

Al explicar esto de manera gráfica se tiene lo siguiente:




Como se puede observar la distancia más grande está entre las personas 1 y 2, por lo que esta pareja es la semilla o arrancador.

El siguiente paso es observar la distancia entre la persona 4 y las personas 1 y 2, la cual es:

$$D_{4,1} = [-1.09 + 1.09]^2 + (-.539 + 1.21)^2 + (-1.04 + 1.04)^2 + (-1.05 + 1.05)^2 + (-1.04 + 1.04)^2]^{\frac{1}{2}} = .674$$

$$D_{4,2} = [(-1.09 - .73)^2 + (-.539 - .134)^2 + (-1.04 - 1.19)^2 + (-1.05 - .923)^2 + (-1.04 - 1.19)^2]^{\frac{1}{2}} = 4.20$$

Gráficamente es:




Otra vez la distancia más grande está entre las personas 1 y 2, por lo que finalmente se compara con la persona 5; sus distancias serían:

$$D_{5,1} = [.73 + 1.09]^2 + (.134 + 1.21)^2 + (.44 + 1.04)^2 + (.26 + 1.05)^2 + (.44 + 1.04)^2]^{\frac{1}{2}} = 3.367$$

$$D_{5,2} = [(.73 - .73)^2 + (.134 - .134)^2 + (.44 - 1.19)^2 + (.26 - .923)^2 + (.44 - 1.19)^2]^{\frac{1}{2}} = 1.24$$

La gráfica quedaría de la siguiente manera:



Se observa que la mayor distancia prevaleció entre las personas 1 y 2, por lo que el análisis inicia con dichos grupos y con los datos estandarizados de estos 2 individuos. Ésta sería la semilla y queda como sigue:

	Grupo 1	Grupo 2
x_1	-1.10	.73
x_2	-1.21	.134
x_3	-1.04	1.19
x_4	-1.06	.923
x_5	-1.04	1.19

A partir de aquí se calcula la distancia de todas las personas con los grupos anteriores, es decir, con los grupos formados en la semilla, por lo que se compara cada elemento con los grupos 1 y 2, y donde esté la menor distancia, a ese grupo deberá asignarse la persona que se está comparando.

$$D_{[1(1)]} = [(-1.10 + 1.10)^2 + (-1.21 + 1.21)^2 + (-1.04 + 1.04)^2 + (-1.06 - 1.06)^2 + (-1.04 + 1.04)^2]^{\frac{1}{2}} = 0 \checkmark$$

$$D_{[1(2)]} = [(-1.10 - 0.73)^2 + (-1.21 - .134)^2 + (-1.04 - 1.19)^2 + (-1.06 - 0.923)^2 + (-1.04 - 1.19)^2]^{\frac{1}{2}} = 4.366$$

Al comparar a la persona 1 con los grupos 1 y 2 se encuentra que la mejor asignación es dejar a 1 con el grupo 1; ahora se compara a la siguiente persona:

$$D_{[2(1)]} = [(-1.10 - .73)^2 + (-1.21 - .134)^2 + (-1.04 - 1.19)^2 + (-1.06 - .923)^2 + (-1.04 - 1.19)^2]^{\frac{1}{2}} = 4.366$$

$$D_{[2(2)]} = [.73 - .73]^2 + (.134 - .134)^2 + (1.19 - 1.19)^2 + (.923 - .923)^2 + (1.19 - 1.19)^2]^{\frac{1}{2}} = 0 \checkmark$$

Al comparar a la persona 2 con los grupos 1 y 2 se encuentra que la mejor asignación es dejarla en el grupo 2; ahora se compara a la siguiente persona:

$$D_{[3(1)]} = [.73 + 1.10]^2 + (1.48 + 1.21)^2 + (.44 + 1.04)^2 + (.923 + 1.06)^2 + (.44 + 1.04)^2]^{\frac{1}{2}} = 4.355$$

$$D_{[3(2)]} = [.73 - .73]^2 + (1.48 - .134)^2 + (.44 - 1.19)^2 + (.923 - .923)^2 + (.44 - 1.19)^2]^{\frac{1}{2}} = 1.712 \checkmark$$

Como se puede ver, la persona 3 tiene la menor distancia con el grupo 2.

$$D_{[4(1)]} = [-1.10 + 1.10]^2 + (-.539 + 1.21)^2 + (-1.04 - 1.104)^2 + (-1.06 + 1.06)^2 + (-1.04 + 1.04)^2]^{\frac{1}{2}} = .674 \checkmark$$

$$D_{[4(2)]} = [-1.10 - .73]^2 + (-.539 - .134)^2 + (-1.04 - 1.19)^2 + (-1.06 - .923)^2 + (-1.04 - 1.19)^2]^{\frac{1}{2}} = 4.20$$

La persona 4 tiene la mínima distancia con el grupo 1.

$$D_{[5(1)]} = [-.73 + 1.10]^2 + (.134 + 1.21)^2 + (.44 + 1.04)^2 + (.26 + 1.06)^2 + (.44 + 1.04)^2]^{\frac{1}{2}} = 3.367$$

$$D_{[5(2)]} = [.73 - .73]^2 + (.134 - .134)^2 + (.44 - 1.19)^2 + (.26 - .923)^2 + (.44 - 1.19)^2]^{\frac{1}{2}} = 1.24 \checkmark$$

La persona 5 tiene la mínima distancia con el grupo 2.

Como se observa la persona 4 quedó agrupada con la persona 1 y las personas 3 y 5 con la 2, por lo que ahora se necesitan calcular las medias de los nuevos grupos y comprobar si esta asignación es la correcta.

4.12.3 Encontrar las distancias

En la tabla siguiente se muestran los nuevos promedios de los grupos reasignados, es decir, en el grupo 1, las personas 2, 3 y 5 y en grupo 2, las personas 1 y 4.

Tabla 4-39 Nuevo grupo 1 con un elemento menos

		Grupo 1				
		X_1	X_2	X_3	X_4	X_5
Personas	2	0.73	0.13	1.19	0.92	1.19
	3	0.73	1.48	0.45	0.92	0.45
	5	0.73	0.13	0.45	0.26	0.45
Promedios =		0.73	0.58	0.70	0.70	0.70

Tabla 4-40 Nuevo grupo 2 con un elemento más

		Grupo 2				
		X_1	X_2	X_3	X_4	X_5
Personas	1	-1.10	-1.21	-1.04	-1.06	-1.04
	4	-1.10	-0.54	-1.04	-1.06	-1.04
Promedios =		-1.10	-0.88	-1.04	-1.06	-1.04

Con las nuevas medias se inicia el cálculo de distancias de las personas con su grupo y con el otro para verificar que estén en el grupo correcto. Se inicia con la persona 1.

$$D_{[1(1,4)]} = [(-1.10 + 1.10)^2 + (-1.21 + 0.88)^2 + (-1.04 + 1.04)^2 + (-1.06 - 1.06)^2 + (-1.04 + 1.04)^2]^{\frac{1}{2}} = 0.34 \checkmark$$

$$D_{[1(2,3,5)]} = [(-1.10 - 0.73)^2 + (-1.21 - 0.58)^2 + (-1.04 - 0.70)^2 + (-1.06 - 0.70)^2 + (-1.04 - 0.70)^2]^{\frac{1}{2}} = 3.96$$

La distancia más pequeña la tiene con su grupo por lo que este elemento se encuentra correctamente asignado; se continúa con la persona 2:

$$D_{[1(2,3,5)]} = [(0.73 - 0.73)^2 + (0.13 - 0.58)^2 + (1.19 - 0.70)^2 + (0.92 - 0.70)^2 + (1.19 - 0.70)^2]^{\frac{1}{2}} = 0.86 \checkmark$$

$$D_{[2(1,4)]} = [(0.73 + 1.10)^2 + (0.13 + 0.88)^2 + (1.19 + 1.04)^2 + (0.92 + 1.06)^2 + (1.19 + 1.04)^2]^{\frac{1}{2}} = 4.27$$

Al confrontar las distancias, la más pequeña la tiene con su grupo por lo que la persona 2 se encuentra bien asignada; ahora sigue el elemento 3:

$$D_{[1(2,3,5)]} = [(0.73 - 0.73)^2 + (1.48 - 0.58)^2 + (0.45 - 0.70)^2 + (0.92 - 0.70)^2 + (0.45 - 0.70)^2]^{\frac{1}{2}} = 0.99 \checkmark$$

$$D_{[2(1,4)]} = [(0.73 + 1.10)^2 + (1.48 + 0.88)^2 + (0.45 + 1.04)^2 + (0.92 + 1.06)^2 + (0.45 + 1.04)^2]^{\frac{1}{2}} = 4.15$$

Al comparar las distancias la más pequeña la tiene con su grupo por lo que esta persona se encuentra bien asignada; se continúa con el elemento 4:

$$D_{[1(1,4)]} = [(-1.10 + 1.10)^2 + (-0.54 + 0.88)^2 + (-1.04 + 1.04)^2 + (-1.06 - 1.06)^2 + (-1.04 + 1.04)^2]^{\frac{1}{2}} = 0.34 \checkmark$$

$$D_{[4(2,3,5)]} = [(-1.10 - 0.73)^2 + (-0.54 - 0.58)^2 + (-1.04 - 0.70)^2 + (-1.06 - 0.70)^2 + (-1.04 - 0.70)^2]^{\frac{1}{2}} = 3.71$$

La distancia más pequeña la tiene la persona 4 con su grupo, por lo que se encuentra bien asignado; sigue el último elemento que es el 5:

$$D_{[5(2,3,5)]} = [(0.73 - 0.73)^2 + (0.13 - 0.58)^2 + (0.45 - 0.70)^2 + (0.26 - 0.70)^2 + (0.45 - 0.70)^2]^{\frac{1}{2}} = 0.72 \checkmark$$

$$D_{[5(0,4)]} = [(0.73 + 1.10)^2 + (0.13 + 0.88)^2 + (0.45 + 1.04)^2 + (0.26 + 1.06)^2 + (0.45 + 1.04)^2]^{\frac{1}{2}} = 3.25$$

Al confrontar las distancias, la más pequeña la tiene con su grupo por lo que la persona 5 se encuentra bien asignada. Después de comparar las distancias de los elementos con los diferentes grupos se terminó con el proceso; los 2 grupos quedan formados con los elementos:

- Grupo 1: (2, 3, 5).
- Grupo 2: (1, 4).

En caso de que alguna persona no hubiera estado correctamente asignada en su grupo, se necesita poner a este elemento en el nuevo grupo y recalculer medias y con los nuevos promedios volver a verificar desde la persona 1 que todas quedan correctamente asignadas en su grupo.

4.12.4 Buscar el perfil de los conglomerados

Con los datos de las personas podemos definir cada segmento de mercado e incluso ponerle un nombre a cada grupo, es decir, encontrar, analizar y concluir sobre los perfiles de cada uno, y eso se logra con los promedios de cada grupo, la información disponible son las medias de las variables originales; dichos promedios se muestran a continuación:

Tabla 4-41 Promedios no estandarizados de las variables en el grupo 1

	Grupo 1				
	X_1	X_2	X_3	X_4	X_5
Promedios de las variables no estandarizadas	4.00	3.67	4.33	3.67	3.33

Los promedios de los datos originales del grupo 2 son los siguientes:

Tabla 4-42 Promedios no estandarizados de las variables en el grupo 2

	Grupo 2				
	X_1	X_2	X_3	X_4	X_5
Promedios de las variables no estandarizadas	1.00	1.50	2.00	1.00	1.00

Con los promedios de los datos originales se pueden encontrar los perfiles de los grupos pero, para concluir, es necesario volver a la escala original que se utiliza en este problema: los valores originales (de 1 a 5), en donde 1 significa “CA” (completamente de acuerdo) y 5 “CD” (completamente en desacuerdo), de tal manera que si nos encontramos medias cercanas al 1 podemos concluir que ese grupo está completamente de acuerdo con la variable en cuestión y si la media está cercana a 4, por ejemplo, está en desacuerdo. Por lo que las etiquetas quedan como sigue.

4.12.5 Número de conglomerados a dejar como solución

Para el análisis *cluster* no jerárquico se traza un gráfico que compare el número de grupos con la relación entre la varianza total de éstos y la varianza entre los conglomerados. El punto del gráfico donde se presente un cambio marcado indicará el número apropiado de grupos.

4.12.6 Etiquetar los conglomerados

A continuación se detalla cómo se debe etiquetar cada uno de los grupos:

Grupo 1:

Con respecto a cada una de las variables:

1. Están en desacuerdo (4.00) en que los “padres” son los responsables directos del comportamiento de los hijos.
2. No están de acuerdo (3.67) en que los “medios” han influido en el comportamiento de los jóvenes.
3. Se encuentran en desacuerdo (4.33) en que los jóvenes tienen muy poco respeto por la “autoridad”.
4. Están en desacuerdo (3.67) que las “escuelas” sean copartícipes en la educación sobre valores.
5. Y les es indiferente (3.33) que las “amistades” influyen en el comportamiento de los jóvenes.

Por lo anterior, a este grupo se le podría llamar “padres sobreprotectores”.

Grupo 2:

Con respecto a cada una de las variables:

1. Están completamente de acuerdo (1.00) en que los “padres” son los responsables directos del comportamiento de los hijos.
2. Se encuentran de acuerdo (1.5) en que los “medios” han influido en el comportamiento de los jóvenes.
3. Están de acuerdo (2.00) en que los jóvenes tienen muy poco respeto por la “autoridad”.
4. Se encuentran completamente de acuerdo (1.00) en que las “escuelas” deben ser copartícipes en la educación sobre valores.
5. Están completamente de acuerdo (1.00) en que las “amistades” influyen en el comportamiento de los jóvenes.

Por lo que a este grupo se le podría citar como “padres necesitados de ayuda”.

4.13 Análisis posteriores

Ahora la pregunta sería ¿qué se puede hacer para entender mejor a los segmentos formados? La respuesta es probar la segmentación.

4.13.1 Probar la segmentación

Primero es necesario saber si en realidad, con el número de segmentos encontrados, existe una verdadera diferencia entre ellos; esto se puede probar por medio del análisis discriminante, el cual puede responder la pregunta anterior y otras más, entre ellas: ¿qué variables en realidad ayudan a que la segmentación se dé más claramente?, ¿qué tanto impactan dichas variables?, con las características de un individuo, ¿se puede averiguar a qué segmento es más factible que pertenezca?, etcétera.

4.13.2 Conocer los perfiles

Segundo, por medio del detector automático de interacción (CHAID del cual se habló en el capítulo 1 “Introducción al análisis multivariante” de este libro) se puede tener un perfil más exacto de cada uno

de los segmentos formados con respecto a variables sociodemográficas y otras más como hábitos, atributos únicos dentro de cada segmento o fuera de cada segmento, etcétera.

4.14 Ejercicios de análisis de agrupamiento

Problema 1:

Las alumnas de psicología organizacional tienen que hacer una investigación acerca de si trae mejores resultados (en este caso calificación) el que dos personas que tengan parecido en algún aspecto trabajen juntas que otras que son diferentes en tal aspecto.

Las alumnas tienen una serie de datos relacionados con las calificaciones de 5 personas, pero no saben cuál es la pareja más parecida y cuál es la menos parecida, por lo que piden a los alumnos de análisis multivariante que les ayuden a seleccionar a la pareja con la cual van a trabajar en la investigación.

Persona	Calificación 1	Calificación 2
1	5.5	4.9
2	9.6	6.3
3	8.1	9.8
4	3.8	7.3
5	8.6	7.0
Media	7.12	7.06
Desviación estándar	2.14	1.60

Problema 2:

Las alumnas de mercadotecnia hicieron una investigación de mercado y de ahí se obtuvo la siguiente matriz de distancia. A partir de ésta, se pide que se obtenga un eslabonamiento simple y uno promedio para saber la solución de agrupamiento en 2 conglomerados que estas chicas utilizaron en su investigación.

Matriz de proximidad							
Distancia euclidiana							
Casos	1: caso 1	2: caso 2	3: caso 3	4: caso 4	5: caso 5	6: caso 6	7: caso 7
1: caso 1	0.000	2.000	1.000	4.000	4.000	6.000	5.000
2: caso 2	2.000	0.000	7.000	8.000	2.000	11.000	2.695
3: caso 3	1.000	7.000	0.000	1.000	4.000	2.000	8.000
4: caso 4	4.000	8.000	1.000	.000	3.000	11.000	9.000
5: caso 5	4.000	2.000	4.000	3.000	0.000	5.000	7.000
5: caso 6	6.000	11.000	2.000	11.000	5.000	.000	8.000
7: caso 7	5.000	4.000	8.000	9.000	7.000	8.000	.000

Problema 3:

Con el fin de ser más objetivas en el resultado, las alumnas de psicología organizacional agregaron otra calificación; con la medida de similitud obtenga nuevamente cuál es la pareja más parecida, recodifique los datos, si es calificación aprobatoria se cambia por 1 y si es calificación reprobada cambie por 0.

Persona	Calificación 1	Calificación 2	Calificación 3
1	5.5	4.9	7.3
2	9.6	6.3	6.8
3	8.1	9.8	9.1
4	3.8	7.3	8.2
5	8.6	7.0	8.3

Calificación:

- 1 Aprobó.
- 0 Reprobó.

Problema 4:

En una investigación realizada para el CEA se encontró que características como (F1) participación, (F2) investigación, (F3) habilidad académica y (F4) sentido de organización hacen que la opinión acerca de un buen director de departamento se divida en 2 tendencias: una a favor de que los directores de departamento actuales son buenos y la otra en contra; con estas variables se realizó un análisis de agrupamiento. La información, previamente estandarizada, de 5 entrevistados es la siguiente:

A	B	C	D	E	F	G	H	I	J	K
-0.26	-0.60	0.18	0.79	0.20	0.38	0.18	0.76	0.06	0.88	0.59
0.14	-0.42	-0.03	-0.13	0.90	0.72	0.18	0.62	-0.70	0.60	0.06
-0.05	0.09	0.79	-0.19	0.17	0.64	0.70	0.94	-0.26	0.37	-0.03
0.52	-0.37	0.59	0.69	0.54	0.73	-0.64	0.22	-0.07	0.11	-0.42
0.60	0.94	0.33	0.10	0.25	0.66	0.24	-0.36	0.69	0.19	0.12

De acuerdo con el CEA, se utilizarían como puntajes de la participación los datos de la variable *D*; para la investigación, los de la *J*; para la habilidad académica, los de la *G*, y para el sentido de organización, los de la *A*.

Se le pide realice un agrupamiento jerárquico aglomerativo con el eslabonamiento completo y representar el procedimiento en un dendograma. Además especifique cómo quedaría la solución en 3 segmentos.

Problema 5:

Las presentes noticias hablan acerca del aumento de peso que han tenido las personas en las sociedades occidentales. Esto ha traído como consecuencia que hombres y mujeres presenten problemas de sobrepeso y obesidad y a su vez enfermedades como diabetes, hipertensión y padecimientos coronarios, entre otras.

A continuación se registran los datos de 6 personas y se le pide que realice la matriz correspondiente, un eslabonamiento completo y un dendograma.

Personas	Índice de masa corporal (kg/m ²)	Herencia de obesidad	Enfermedad dominante presente en la persona
1	35	Papás obesos	Hipertensión
2	23	Papás sólo con sobrepeso	Problemas del corazón
3	29	Papás sólo con sobrepeso	Hipertensión
4	42	Papás obesos	Diabetes
5	31	Papás sólo con sobrepeso	Diabetes
6	34	Papás sólo con sobrepeso	Hipertensión

De los datos anteriores se tiene lo siguiente:

- IMC (índice de masa corporal) se tiene (1) si es mayor o igual a 30.
- IMC no se tiene (0) si es menor a 30.
- Herencia de obesidad se tiene (1) si papás fueron obesos.
- Herencia de obesidad no se tiene (0) si papás no fueron obesos.
- Enfermedad dominante de la persona se tiene (1) si presenta hipertensión.
- Enfermedad dominante de la persona no se tiene (0) si no presenta hipertensión.

Problema 6:

El gerente de mercadotecnia de la compañía Multiproductos, S.A., se ha dado cuenta que el presupuesto en publicidad ha sido muy alto en los últimos meses y las ventas no han reflejado estos gastos. Debido a esto piensa que tal vez la publicidad se está dirigiendo en forma inadecuada al mercado meta. La empresa cuenta con 4 marcas específicas y actualmente se realiza publicidad de manera independiente para cada una. El gerente cree que tal vez las marcas Spull y Hannis poseen características similares entre sí, al igual que las marcas Tacs y Pink; si esto es así, podría llegar a realizarse publicidad conjunta para un grupo y otro.

Para comprobar esto se evalúa el parecido entre las marcas con base en el precio y tamaño, los datos estandarizados se muestran a continuación:

	Spull	Hannis	Tacs	Pink
Precio	6	4	-2	-1
Tamaño	5	-3	1	2

Se le pide que ayude a este gerente a comprobar su hipótesis a través del método de k-promedios:

- ¿Cuál sería la semilla?
- Asigne las marcas a los grupos.
- Compruebe que la asignación es óptima.

Problema 7:

El Instituto Nacional del Consumidor realiza un estudio sobre marcas de agua del mercado para lo cual se analizan 7 variables; según los resultados de un análisis de factores se han agrupado en 3 factores. Las variables que se han identificado más con cada uno de los factores son las siguientes: con el factor 1, la variable X_1 ; con el factor 2, la variable X_2 y con el factor 3, la variable X_4 .

Suponga usted que dichos factores se utilizarán para realizar una segmentación de mercado, para lo cual se proporcionan los datos estandarizados de 5 entrevistas.

Entrevista	X_1	X_2	X_3	X_4	X_5	X_6	X_7
1	1.1	1.1	2.1	3.1	5.5	5.5	4.2
2	1.1	2.1	1.1	2.2	4.4	4.3	2.3
3	3.2	2.1	2.1	5.1	1.1	2.5	1.4
4	5.1	4.2	5.1	2.2	4.3	3.1	3.5
5	5.1	5.2	4.1	3.1	5.4	2.5	4.5

- Tome como base la información anterior y elabore una matriz de distancia para evaluar el parecido entre los entrevistados.

- Aplique el eslabonamiento completo para realizar el agrupamiento y muestre la solución en un dendograma.
- Si usted sabe que el mercado puede dividirse en 2 segmentos, describa la forma de pensar de cada uno de ellos al considerar que el factor 1 se ha denominado “Pureza”, al factor 2 “Cantidad de sodio” y al factor 3 “Tamaño de la botella”. (Tome como intervalo para las variables: 1=Muy importante y 5=Nada importante.)

Problema 8:

El dueño de un vivero está clasificando 5 plantas de sombra que acaba de adquirir en Canadá. Las variables para realizar la agrupación son: cantidad de agua que necesitan y altura de la planta, ambas estandarizadas.

Desea hacer los grupos para saber en qué lugar del vivero colocarlas. El dueño supone que las plantas 1 y 5 deben estar juntas y las plantas 2, 3 y 4 forman otro grupo. Éstos son los datos estandarizados de las 5 plantas:

	Cantidad de agua	Altura de la planta
Planta 1	−0.84	−1.22
Planta 2	0.35	0.53
Planta 3	1.55	−0.35
Planta 4	−0.24	1.40
Planta 5	−0.84	−0.35

Por medio de la técnica de k -promedios se pide:


- Asignar las marcas a los grupos.
- Comprobar que la asignación es óptima.

Problema 9:

Se realiza un estudio sobre autos; se entrevistó a 10 personas y los resultados fueron los siguientes:

Historial de aglomeración						
	Cluster combinado			Etapas del conglomerado donde aparece por primera vez		
Etapas	Cluster 1	Cluster 2	Coefficientes	Cluster 1	Cluster 2	Siguiente etapa
1	1	4	.760	0	0	4
2	2	8	1.252	0	0	5
3	3	9	1.433	0	0	5
4	1	10	1.487	1	0	6
5	2	3	1.487	2	3	7
6	1	6	1.781	4	0	9
7	2	7	1.974	5	0	8
8	2	5	2.361	7	0	9
9	1	2	2.372	6	8	0


- Al ver la tabla anterior, ¿cómo quedaron organizadas las personas en 4 grupos?



- Al observar el dendograma anterior mencione cómo quedaron agrupadas las personas en 7 conglomerados.

Problema 10:

- Al ver el siguiente dendograma mencione cómo se fueron agrupando las personas.



- Con el siguiente diagrama de témpanos indique cómo se formaron los grupos.

Diagrama de témpanos													
Caso													
Número de grupos	5: caso 5		7: caso 7		3: caso 3		4: caso 4		6: caso 6		2: caso 2		1: caso 1
1	X	X	X	X	X	X	X	X	X	X	X	X	X
2	X		X	X	X	X	X	X	X	X	X	X	X
3	X		X		X	X	X	X	X	X	X	X	X
4	X		X		X	X	X	X	X	X	X		X
5	X		X		X		X	X	X	X	X		X
6	X		X		X		X		X	X	X		X

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 5

Análisis discriminante

Objetivo general:

Conocer una de las técnicas avanzadas para analizar la asociación-pronóstico, juicio o predicción-criterio y saber cómo se aplica a la solución de problemas del área administrativa.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Describir con sus propias palabras en qué consiste el análisis discriminante.
- Aplicar la técnica del análisis discriminante para 2 grupos a un problema del área administrativa, indicando el cálculo de los pesos discriminantes para la función lineal establecida para cada eje de variable.
- Explicar el criterio discriminante para clasificar nuevas observaciones.
- Utilizar la ecuación discriminante para clasificar nuevas observaciones.
- Explicar el criterio utilizado para validar la ecuación discriminante en ejemplos del área administrativa y ser capaz de calcularlo.
- Determinar la significancia de la ecuación discriminante para clasificar nuevas observaciones.
- Definir la importancia relativa de cada variable para discriminar en un ejemplo del área administrativa.
- Describir con sus propias palabras en qué consiste el análisis discriminante múltiple.
- Mencionar los supuestos básicos del análisis discriminante.
- Reconocer cuándo es posible aplicar la técnica del análisis discriminante en la solución de problemas del área administrativa.
- Aplicar el SPSS™ para la solución de problemas del análisis discriminante.

5.1 Antecedentes

El análisis discriminante pertenece al grupo de las técnicas funcionales y, por lo tanto, su uso principal es para hacer pronósticos. Esta técnica utiliza “m” variables independientes, todas ellas métricas y una sola variable dependiente no métrica, nominal (categórica).

$$Y = f(X_1, X_2, \dots, X_m)$$

La historia del análisis discriminante inicia en 1920 con los trabajos del estadístico inglés Karl Pearson, pero es en 1930, con el estadístico R. A. Fisher, que se propone una metodología para ob-

tener la combinación lineal de variables (la ecuación discriminante de Fisher), que hasta la fecha se utiliza como parte del proceso de este análisis. Metodólogos de la universidad de Harvard realizaron aplicaciones del análisis discriminante en el área de educación y psicología en las décadas de los 50 y 60. El tipo de análisis discriminante más utilizado en las primeras décadas del siglo pasado fue el discriminante predictivo, del cual se hablará más adelante, y sólo a partir de la década de los 60 fue cuando se empezó a utilizar el discriminante descriptivo.

El objetivo del análisis discriminante es encontrar la combinación lineal de las variables independientes que permita diferenciar de la mejor manera a los grupos o niveles que la variable dependiente tiene. Una vez que se encuentra la función, ésta puede utilizarse para clasificar nuevos elementos, es decir pronosticar.

5.2 Áreas de aplicación

El campo de aplicación del análisis discriminante es muy amplio, por ejemplo, en la medicina sirve para diagnosticar enfermedades a pacientes según sus síntomas o bien para decidir qué tipo de tratamiento se podría ofrecer; en psicología ayuda a evaluar si una persona sufre algún trastorno según sus patologías o perfil mental. En recursos humanos sirve para realizar un filtro previo a una entrevista; en finanzas para decidir si se otorga o no un crédito a una persona o bien el tipo de financiamiento que se le debe proporcionar; en mercadotecnia qué tipo de servicio o producto ofrecerle a un cliente o bien estudiar la eficacia de alguna campaña. En antropología ayuda para saber la antigüedad, el tipo, la raza o el género de un fósil. En política, para realizar estudios anteriores a las elecciones con el fin de determinar la eficacia de las campañas políticas o para buscar por qué las personas tienen mayor preferencia por algún partido; en sociología para determinar la razón del comportamiento humano o bien de las razas. En seguros para predecir el tipo de cobertura que se le podría ofrecer a un cliente o bien para pronosticar el tipo de siniestros, entre muchas otras aplicaciones.

5.3 Definición

Análisis discriminante. Es una técnica de clasificación o asignación de un elemento a un grupo del cual se conocen sus atributos.

El **análisis discriminante** busca identificar las diversas opciones o situaciones que se pueden dar en una variable, además explica las razones de esas diferencias. Para que sea más claro el propósito de esta técnica, se planteará un ejemplo: suponga que del análisis de conglomerados¹ se obtuvo que ciertos entrevistados pueden dividirse en 2 grupos: los que son y los que no son clientes para un producto; a través del análisis discriminante se comprobará si realmente los entrevistados se clasifican en esos 2 grupos y además se conocerá qué variables son las que determinan la diferencia entre la gente como ingreso, edad, forma de pensar, etcétera. Otro objetivo que se persigue es pronosticar a qué grupo pertenecerían las personas de acuerdo con sus características.

Se trata de una técnica de clasificación o asignación de un elemento a un grupo del cual se conocen sus atributos; la clasificación del elemento al grupo se realiza mediante una función de carácter lineal o cuadrático que combina las variables que más influyen en dicha asignación, de manera que se pueden realizar clasificaciones, interpretar las razones de su agrupamiento y pronosticar su comportamiento con relación a un grupo.

Estas características permiten aplicar el análisis discriminante tanto para fines descriptivos como para predictivos. El análisis discriminante descriptivo se usa para verificar si existe diferencia en el comportamiento de los grupos con respecto a las variables utilizadas para realizar una segmentación, mientras que el análisis discriminante predictivo se usa para saber en qué grupo quedaría un elemento de acuerdo con sus características o el valor que tomen las variables discriminantes. Esta técnica es muy similar al análisis de regresión múltiple,² excepto que en el discriminante se utiliza una variable dependiente de carácter categórico.

¹ Técnica vista en el capítulo 4 "Análisis de conglomerados".

² El análisis de regresión múltiple se estudió en el capítulo 2 "Análisis de regresión múltiple".

El discriminante genera una ecuación que permitirá realizar pronósticos y que determinará la existencia de grupos en la población. Dicha ecuación está representada por la función discriminante lineal de Fisher, la cual tiene la siguiente expresión:

$$Z = K_1X_1 + K_2X_2 + K_3X_3 + \cdots K_mX_m$$

donde:

Z : representa el puntaje discriminante o puntaje discriminatorio (número que servirá para efectuar la clasificación)

K_i : es el factor de ponderación o de importancia que tiene la variable i para discriminar.

X_i : son las variables independientes

El análisis discriminante maneja variables significativas en la diferenciación de los grupos; y para esto encuentra los pesos de las variables independientes que se nombrarán K . Esto puede compararse con el procedimiento que se sigue en el análisis de regresión, en el cual se tenía como modelo la siguiente función:

$$\hat{Y} = \beta_0 + \beta_1X_1 + \beta_2X_2 + \beta_3X_3 + \cdots + \beta_mX_m$$

En regresión se obtienen los valores de las β bajo el criterio de mínimos cuadrados, el cual consiste en minimizar el error al pronosticar. Este criterio se representa mediante la siguiente expresión:

$$\text{Mín}(\epsilon) = \Sigma \epsilon^2 = \Sigma (Y - \hat{Y})^2$$

Ahora bien, en el análisis discriminante el objetivo a seguir para el cálculo de los coeficientes de las variables independientes estará en función de buscar la máxima diferencia entre los datos.

Mediante el análisis de las siguientes figuras se buscará explicar el concepto anterior:




Figura 5-1 Diferencia entre grupos.

Como se puede observar en la figura anterior la variable X_1 contrasta mejor a los grupos porque separa o discrimina en mayor distancia a los promedios (centros o centroides) de los mismos; es decir, X_1 diferencia más a los promedios de los grupos que X_2 . La X_1 separa a los grupos por una diferencia de 30 y la X_2 aísla a los grupos en 1 unidad, además ambos grupos están muy mezclados, a esta zona se le llama *zona de confusión* y como se puede ver los grupos están dispersos, así que se puede decir que existe mucha dispersión en cada grupo. En caso de que la situación fuera la siguiente:




Figura 5-2 Diferencia entre grupos.

En la figura 5-2 sucede lo mismo que en la primera, pero al revés, es decir, la X_2 discrimina o separa mejor a los grupos por una diferencia de 10; además ambos grupos no están tan mezclados como en la figura 5-1 y están menos dispersos, así que existe poca dispersión en cada grupo.

Ahora al comparar las 2 figuras para ver en cuál de los casos se está discriminando de una forma más clara a los grupos, se ve que en la figura 5-2 se discrimina mejor, a pesar de que la diferencia que se logra hacer (10) es menor que la de la figura 5-1 (30). Esto que parece una contradicción se debe a que en la primera figura se da una mayor dispersión entre los datos haciendo que los grupos se mezclen mucho más que los de la segunda figura, en donde se ve claramente que los grupos no están mezclados y que la dispersión es menor; mientras mayor dispersión de datos haya, mayor será la confusión en los datos y existirá una discriminación pobre.

Por lo tanto, para determinar cuál caso discrimina mejor a los grupos es necesario tomar en cuenta la dispersión o variación de los datos, además de la distancia entre los promedios. Entonces el criterio consiste en maximizar las distancias entre los promedios, pero con respecto a su variación y se expresa de la siguiente manera:

$$\text{Máx} \frac{(\mu_{1y} - \mu_{2y})}{\sigma_y^2}$$

donde:

μ : es el promedio

μ_{iy} : es el promedio de la variable en el grupo i de la variable Y

σ_y^2 : es la dispersión o variabilidad

5.4 Diferencia entre el análisis discriminante y otras técnicas

A continuación estableceremos las diferencias que existen entre el análisis discriminante y otros tipos de análisis como el de factores y el de conglomerados, entre otros:

Análisis de factores frente al análisis discriminante

- En el análisis de factores³ se obtienen nuevas variables que pueden explicar con más éxito alguna estructura⁴ y en el discriminante se puede hablar de una variable nueva, la Y , pero ésta no explica alguna estructura sino que muestra las razones de la separación de los grupos.
- En el análisis de factores las nuevas variables son independientes métricas y en el discriminante la nueva variable es dependiente no métrica.

³ Técnica vista en el capítulo 3 "Análisis de factores".

⁴ Al resumir las variables y obtener los puntajes de los factores, éstos forman las nuevas variables.

Análisis de conglomerados frente al análisis discriminante

- En el análisis de conglomerados⁵ el objetivo es formar los grupos, mientras que en el discriminante los grupos ya están formados *a priori*, es decir, antes de realizar el análisis discriminante.
- En el análisis de conglomerados es esencial entender la distancia (la similitud o la correlación) para formar los grupos maximizando o minimizando esas distancias (la similitud o la correlación) y en el discriminante se puede hablar de maximizar las distancias al tomar en cuenta la dispersión o variabilidad de los grupos.
- En el análisis de conglomerados no se construye una ecuación, ya que la técnica es estructural y en el discriminante se calcula la función discriminante.
- El análisis discriminante puede ser complementario del de conglomerados, es decir, primero se lleva a cabo el agrupamiento y luego se puede probar esa segmentación por medio del análisis discriminante, explicando los motivos de la segmentación.

Análisis de regresión *versus* análisis discriminante

- En el análisis de regresión⁶ la variable dependiente es métrica y en el discriminante es no métrica.
- En el análisis de regresión considerando el patrón de conducta existente en los datos se traza una línea recta; en el análisis discriminante también se crea una función que, junto con los centroides⁷ de cada grupo, sirven para delimitar sus fronteras, mientras que para saber cuáles son los centroides de cada grupo se toma en cuenta cada observación.
- Para predecir la variable dependiente en el análisis de regresión, se sustituye en la ecuación la información que se posee de las variables independientes y en el análisis discriminante también se sustituye en cada variable independiente, pero la información obtenida de la variable dependiente se deberá comparar con las fronteras obtenidas para saber o predecir en qué grupo o segmento se está.

5.5 Requerimientos estadísticos para llevar a cabo un análisis discriminante

Los grupos o segmentos deben formarse *a priori*, esto debe ser de forma natural o por alguna técnica anterior.⁸

- A los grupos los define una serie de características o atributos,⁹ pues no están formados al azar; éstas pueden ser conocidas o desconocidas.
- Las zonas que delimitan a los grupos pueden estar bien definidas o pueden existir zonas de confusión; en este caso no se sabe a qué grupo pertenecen ciertos individuos u objetos.
- Ninguna variable discriminante puede ser combinación lineal de otras variables discriminantes, es decir, no debe existir dependencia¹⁰ o multicolinealidad entre ellas.
- El número máximo de funciones discriminantes que se pueden calcular podrá ser igual al número de variables discriminantes siempre y cuando éste no sea mayor que el número de grupos menos 1.
- Las matrices de varianzas-covarianzas de cada grupo deben ser aproximadamente iguales, es decir, constantes.

⁵ Técnica vista en el capítulo 4 "Análisis de conglomerados".

⁶ Técnica vista en el capítulo 2 "Análisis de regresión múltiple".

⁷ El concepto de *centroide* es el promedio o centro de los grupos; ver las figuras 5-1 y 5-2.

⁸ Dicha técnica puede ser el análisis de conglomerados.

⁹ Los atributos o características son las variables independientes o variables discriminantes.

¹⁰ El problema de colinealidad o multicolinealidad se explicó en el capítulo 2 "Análisis de regresión múltiple".

Linealidad o aditividad. Suma de los efectos de cada una de las variables independientes.

- Las variables discriminantes deben comportarse de forma normal, es decir, deben provenir de poblaciones que sigan una distribución normal.
- Todos los casos deben ser independientes; no deben existir casos correlacionados.
- La desviación estándar no debe ser cero en 1 o más de los grupos que forman la variable dependiente, es decir, deberá existir dispersión o variabilidad dentro de cada grupo.
- La variabilidad de cada variable independiente sobre la dependiente deberá ser la misma, lo cual significa que cada grupo que la variable discriminante forme con respecto a la dependiente tendrá una dispersión constante, aunque las variabilidades entre las mismas variables independientes sean diferentes.
- La dispersión de los datos (las varianzas y covarianzas) deberán ser iguales entre los grupos, lo cual significa que el experimento se realice en las mismas circunstancias, que no haya diferentes fuentes de variación que hagan que los grupos sean diferentes.
- El análisis discriminante es muy sensible a datos extremos, la falta de homoscedasticidad¹¹ de las varianzas podría significar pruebas no confiables, especialmente cuando el tamaño de la muestra sea muy pequeño.
- Dentro de cada grupo de la variable dependiente la covarianza entre 2 variables predictivas deberá ser igual que la covarianza de otros grupos.
- Se asume linealidad, por lo que no debe darse transformación de variables, ni exponenciales.
- **Linealidad o aditividad** es la suma de los efectos de cada una de las variables independientes.
- Al llevar a cabo una clasificación se supone *a priori* que el resultado obtenido es tan confiable como lo indica el porcentaje de clasificaciones correctas obtenidas en la etapa de validación del modelo.

5.6 Etapas para realizar un análisis discriminante

Para llevar a cabo el análisis discriminante se deben seguir las siguientes etapas:

1. Seleccionar las variables independientes métricas y la variable dependiente no métrica a utilizar.
2. Seleccionar el tamaño de la muestra.
3. Dividir la muestra.
4. Obtener las constantes del modelo.
5. Probar el modelo.
6. Evaluar la contribución de las variables.
7. Valorar de forma predictiva el modelo para verificar el grado de error que tendría al efectuar pronósticos.
8. Interpretar los resultados del modelo de donde se obtienen las estrategias concretas para el problema que se haya planteado.

Estos pasos se resumen en la figura 5-3.

5.6.1 Formulación del problema o detección de áreas de oportunidad

Para la elaboración de un análisis discriminante es necesario establecer los objetivos, los cuales pueden ser:

- Probar la segmentación que se hizo *a priori* o corroborar la existencia de los grupos que una persona de manera natural supone que hay.
- ¿Qué variables en realidad están ayudando a dicha segmentación?
- Pronosticar en qué grupo se encuentran los nuevos individuos.

¹¹ El tema de homoscedasticidad u homogeneidad de varianza se vio en el capítulo 2 “Análisis de regresión múltiple”.




Figura 5-3 Pasos a seguir.

5.6.2 Selección de las variables independientes y dependientes

Deben existir por lo menos 2 grupos en la variable dependiente. Es muy importante que se haga una lista exhaustiva de todos los grupos posibles de la variable dependiente; los grupos que forman a dicha variable deben ser mutuamente excluyentes,¹² y si se desea un estudio muy relevante deberán ser colectivamente exhaustivos.¹³ Es importante mencionar que se puede utilizar cualquier número de variables discriminantes, siempre y cuando su número sea inferior al de casos o entrevistas menos 2.

Si los grupos fueron formados *a priori* se recomienda que en el análisis se incluyan las variables que puedan discriminar o explicar a los segmentos, entre más variables se utilicen será mejor; si los grupos se integraron de forma natural, se deberá tener una idea de qué atributos o características segmentan o discriminan. Por último, si el investigador puede manejar la información se recomienda reunir a las variables y a los elementos más representativos de cada grupo.

5.6.3 Consideraciones sobre el tamaño de la muestra

La muestra mínima sería de 5 observaciones por variable, aunque se recomiendan 20 observaciones por cada una de ellas. De preferencia los grupos deben tener el mismo porcentaje¹⁴ que la población, mientras que la cantidad de datos del grupo más pequeño debe ser mayor que el número de variables; por ejemplo, si se realiza un estudio sobre lentes y la población del grupo de quienes usan lentes de contacto blandos es de 55% y quienes utilizan lentes de contacto duro es de 45%; si la muestra es de 20 personas quedaría de la siguiente manera:




Figura 5-4 Muestra representativa.

Si los grupos son nítidos u homogéneos no es necesario que la muestra sea grande; sin embargo, si los grupos son confusos o heterogéneos, sí es importante que sea una muestra grande.

5.6.3.1 División de la muestra

La muestra deberá separarse en 2 y para la etapa de derivación se utilizarán 60 o 70% de los datos, y el restante 40 o 30% se dejará para la etapa de validación del modelo, ya que no sería válido el grado de error encontrado al pronosticar con los mismos datos con los que se derivó la ecuación.

Al dividir la muestra deben conservarse las proporciones de la población para mantener su representatividad; por ejemplo, si en la población hay un segmento con una proporción de 50%, entonces

¹² El término *mutuamente excluyentes* significa que los grupos no deben contener información de otros grupos.

¹³ Es decir, que abarque todos los grupos posibles.

¹⁴ Cumplir con el mismo porcentaje de la población significa que se debe tener una muestra representativa.

en la muestra dicho grupo debe conservar la misma proporción. Supóngase que se tiene una muestra de 20 personas, la división quedaría de la siguiente manera:




Figura 5-5 Conservar las proporciones en la muestra.

5.6.4 Tipos de análisis discriminante

Existen 2 tipos de análisis discriminante de acuerdo con el número de grupos que se tienen en la variable dependiente:

- Simple. La técnica de discriminante será simple si la variable dependiente está formada por sólo 2 grupos; un ejemplo podrían ser quienes utilizan lentes de contacto blandos y quienes los usan duros.
- Múltiple. El análisis discriminante se considerará como múltiple cuando la variable dependiente tenga más de 2 grupos; un ejemplo podrían ser las personas que utilizan lentes de contacto blandos, las que usan lentes de contacto duro y las que portan lentes de armazón; como en este caso se tienen 3 grupos entonces es discriminante múltiple.

Se puede concluir que el número de variables independientes no tiene nada que ver con el hecho de que se considere simple o múltiple el modelo discriminante.

Antes de continuar con las etapas de esta técnica se mencionarán algunos aspectos estadísticos que serán requeridos.

Como ya se dijo, la ecuación discriminante se representa mediante la siguiente expresión:

$$Z = K_1X_1 + K_2X_2 + K_3X_3 + \dots + K_mX_m$$

En la derivación del modelo se pretende encontrar los valores de los pesos que tienen las variables para discriminar, es decir, los valores de las constantes (k). Se debe recordar que se tiene como criterio maximizar la relación entre las diferencias de los grupos con respecto a la variabilidad en los datos.

Cada observación de las " n " que conforman la muestra se puede expresar en términos de las variables discriminantes y en forma matricial, como a continuación se describe:

$$\begin{bmatrix} Z_1 \\ Z_2 \\ \dots \\ Z_n \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1m} \\ x_{21} & x_{22} & \dots & x_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nm} \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \\ \dots \\ K_m \end{bmatrix}$$

donde:

Z_i : representa el puntaje discriminante o puntaje discriminatorio en la observación i (número que servirá para efectuar la clasificación)

K_j : representa el factor de ponderación o de importancia que se tiene para la variable j que sirve para discriminar

X_{ij} : es la variable j en la observación i

O en notación matricial más compacta:

$$Z = XK$$

donde:

Z : representa todas las “n” observaciones a clasificar

K : representa todos los factores de ponderación

X : son todas las variables discriminantes

El criterio para la obtención de la función discriminante mencionada es:

$$\text{Maximización de} = \frac{\text{Variabilidad entre grupos}}{\text{Variabilidad dentro de los grupos}}$$

El resultado de esta división se interpreta como el valor propio o eigenvalor¹⁵ (λ), el cual se interpreta como la cantidad de variación explicada por la ecuación. El objetivo es la maximización del valor propio, por lo tanto, el manejo de la mayor información o variación posible a través del modelo.

Si la varianza entre los grupos es grande, es decir, si hay grandes diferencias entre los valores que toman los datos al compararlos entre los segmentos; pero la varianza dentro de los grupos es pequeña, es decir, los valores de los datos dentro de un mismo segmento son muy similares, entonces se dice que la función discriminante separa bien a los grupos, esto es, internamente son muy homogéneos y a la vez muy diferentes entre sí.

Con este criterio se busca determinar un puntaje o valor para que las distribuciones que se formulan al proyectarse sobre él estén lo más separadas posible entre sí (mayor variabilidad entre grupos) y al mismo tiempo que cada una de las distribuciones esté lo menos dispersa (menor variabilidad dentro de los grupos).

Para obtener los coeficientes (K) de la ecuación discriminante, dado que el objetivo implica una maximización de una relación, se deberá usar un proceso de derivación, solamente que los términos involucrados son expresiones matriciales. Dado que no se pretende profundizar en el proceso matemático se omitirá la demostración; el lector puede consultar el tema “Desigualdades de Cauchy Schwarz” para obtener información referente a la maximización de matrices.

Para un mejor entendimiento de la mecánica a seguir en el cálculo de las constantes se hará uso de un ejemplo:¹⁶ considérese que se tienen 16 empresas que se evaluaron por medio de 2 razones financieras, una de ellas la de ingresos entre el total invertido que se nombrará X_1 , a la cual se le pondrá como nomenclatura $R_{I,I}$ y la otra razón es la de activo circulante entre pasivo circulante que se nombrará X_2 , a la cual se le nombrará $R_{A,P}$. Los grupos en los que se clasifican las empresas dependiendo de sus resultados son: empresas sanas (etiqueta 1) y empresas en quiebra (etiqueta 2). A continuación se presentan los datos:

Tabla 5-1 Datos del ejemplo

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
1	Sana	1	0.345	4.817
2	Sana	1	0.243	3.994
3	Quiebra	2	0.05	2.778
4	Sana	1	0.378	4.036

(continúa)

¹⁵ La obtención de los eigenvalores o valor propio, fue explicada en el anexo 3.2 “Descomposición espectral”.

¹⁶ Los datos se obtuvieron de una investigación; por razones de confidencialidad se omitirán los nombres de las empresas.

Tabla 5-1 Datos del ejemplo (*continuación*)

Empresas	Resultado	Grupo	X_1	X_2
			$R_{i,j}$	$R_{A,P}$
5	Quiebra	2	0.04	1.256
6	Quiebra	2	0.05	1.377
7	Sana	1	0.18	4.87
8	Quiebra	2	0.04	1.143
9	Sana	1	0.22	3.635
10	Quiebra	2	0.001	1.987
11	Sana	1	0.47	3.567
12	Sana	1	0.039	1.275
13	Quiebra	2	0	1.225
14	Sana	1	0.33	7.523
15	Quiebra	2	0.03	2.083
16	Quiebra	2	0.0043	1.053

En la etapa de derivación, que busca la obtención y comprobación del modelo utilizado para discriminar, lo primero que se hace es partir la muestra, esto es, tomar 60 o 70% de los datos; en este caso se optó por usar 70%. Primero, es necesario saber cuántos elementos conforman cada grupo, nótese que existen 8 en el grupo 1 y otros 8 en el grupo 2, por lo que:

$$8 * 0.7 = 5.6 \cong 6$$

Es decir, se escogerán 6 de cada grupo y se dejarán 2 para la etapa de validación; sigue escoger en forma aleatoria los elementos que no se utilizarán en esta etapa, así se eliminan del modelo las empresas 1 y 12 del grupo 1 y las empresas 10 y 16 del grupo 2; éstas representan 30% de la muestra que se utilizará en la segunda etapa, la etapa de validación. Por lo que la información de la etapa de derivación sería la siguiente:

Tabla 5-2 Datos para la etapa de derivación

Empresas	Grupo	X_1	X_2
		$R_{i,j}$	$R_{A,P}$
2	1	0.243	3.994
3	2	0.05	2.778
4	1	0.378	4.036
5	2	0.04	1.377
6	2	0.05	4.87
7	1	0.18	1.143
8	2	0.04	3.635
9	1	0.22	3.567
11	1	0.47	1.225
13	2	0	7.523
14	1	0.33	2.083
15	2	0.03	2.083

La información necesaria para trabajar el problema parte del cálculo de 3 matrices de dispersión básicas: la matriz que contabiliza lo distinto que son los datos dentro de cada grupo, que se nombrará W ; la matriz total que se identificará como T , y la matriz que representa la diferencia de los datos al comparar un grupo con otro, la A .

A continuación se explicará cómo se obtienen las matrices mencionadas a partir de los datos escogidos para la etapa de derivación. Los datos del ejemplo se acomodarán por grupo (sólo 70% de ellos) y se presentan a continuación con sus descriptivos.

Tabla 5-3 Datos acomodados por grupos y sus descriptivos

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$	1.821	27.625
		$R_{I,I}$	$R_{A,P}$				$\Sigma X_1 I_1$	$\Sigma X_2 I_1$
2	1	0.243	3.994	0.059	15.952	0.971	0.3035	4.604
4	1	0.378	4.036	0.143	16.289	1.526	$\bar{X}_1 I_1$	$\bar{X}_2 I_1$
7	1	0.18	4.87	0.032	23.717	0.877	0.613	138.490
9	1	0.22	3.635	0.048	13.213	0.800	$\Sigma X_1^2 I_1$	$\Sigma X_2^2 I_1$
11	1	0.47	3.567	0.221	12.723	1.676	8.332	
14	1	0.33	7.523	0.109	56.596	2.483	$\Sigma X_1 X_2 I_1$	

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$	0.210	9.862
		$R_{I,I}$	$R_{A,P}$				$\Sigma X_1 I_1$	$\Sigma X_2 I_1$
3	2	0.05	2.778	0.003	7.717	0.139	0.035	1.644
5	2	0.04	1.256	0.002	1.578	1.050	$\bar{X}_1 I_1$	$\bar{X}_2 I_1$
6	2	0.05	1.377	0.003	1.896	0.069	0.009	18.337
8	2	0.04	1.143	0.002	1.306	0.046	$\Sigma X_1^2 I_1$	$\Sigma X_2^2 I_1$
13	2	0.000	1.225	0.000	1.501	0.000	0.366	
15	2	0.03	2.083	0.001	4.339	0.062	$\Sigma X_1 X_2 I_2$	

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
2	1	0.243	3.994	0.059	15.952	0.971
4	1	0.378	4.036	0.143	16.289	1.526
7	1	0.18	4.87	0.032	23.717	0.877
9	1	0.22	3.635	0.048	13.213	0.800
11	1	0.47	3.567	0.221	12.723	1.676
14	1	0.33	7.523	0.109	56.596	2.483
		18.21	27.625	0.613	138.490	8.332
		$\Sigma X_1 I_1$	$\Sigma X_2 I_1$	$\Sigma X_1^2 I_1$	$\Sigma X_2^2 I_1$	$\Sigma X_1 X_2 I_1$
		0.304	4.604			
		$X_1 I_1$	$X_2 I_1$			

(continúa)

Tabla 5-3 Datos acomodados por grupos y sus descriptivos (*continuación*)

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
3	2	0.05	2.778	0.003	7.717	0.139
5	2	0.04	1.256	0.002	1.578	1.050
6	2	0.05	1.377	0.003	1.896	0.069
8	2	0.04	1.143	0.002	1.306	0.046
13	2	0.000	1.225	0.000	1.501	0.000
15	2	0.03	2.083	0.001	4.339	0.062
		0.210	9.862	0.009	18.337	0.366
		$\sum X_1 I_1$	$\sum X_2 I_1$	$\sum X_1^2 I_1$	$\sum X_2^2 I_1$	$\sum X_1 X_2 I_2$
		0.035	1.644			
		$\bar{X}_1 I_1$	$\bar{X}_2 I_1$			

donde:

$\sum X_i /_g$: es la suma de la variable i en el grupo g

$\sum X_i^2 /_g$: es la suma de cuadrados de la variable i en el grupo g

$\sum X_i X_j /_g$: es la suma de los productos cruzados de la variable i y la variable j en el grupo g .

$\bar{X}_i /_g$: es el promedio de la variable i en el grupo g

Las 3 matrices antes mencionadas (T , A y W) son matrices cuadradas con un tamaño determinado por el número de variables independientes¹⁷ del modelo, deben ser simétricas, su diagonal principal está formada por la varianza de cada variable a la que se haga referencia y fuera de la diagonal se tendrán las correspondientes covarianzas.

Hay que recordar que una varianza y una covarianza es un promedio de una suma de cuadrados o un producto cruzado (dependiendo si es varianza o covarianza, respectivamente), es decir, es la suma de cuadrados dividido entre los grados de libertad, esta parte sería **varianza** y la suma de los productos cruzados dividido entre los grados de libertad sería la **covarianza**. Lo que interesa es la suma de cuadrados o la suma de productos cruzados.

Una suma de cuadrados para la variable X_i es:

Ecuación 5-1 Suma de cuadrados para la variable X_i

$$SSX_i = \sum (X_i - \bar{X}_i)^2 = \sum X_i^2 - n\bar{X}_i^2$$

Una suma de productos cruzados para la variable X_i y X_j es la que se muestra en seguida:

Ecuación 5-2 Suma de productos cruzados para la variable X_i y la X_j

$$SPX_i X_j = \sum (X_i - \bar{X}_i)(X_j - \bar{X}_j) = \sum X_i X_j - n\bar{X}_i \bar{X}_j$$

Varianza. Es el promedio de una suma de cuadrados, es decir, es la suma de cuadrados dividido entre los grados de libertad.

Covarianza. Es el promedio de la suma de los productos, es decir, es la suma de los productos cruzados dividido entre los grados de libertad.

¹⁷ Es decir, si se tienen 5 variables independientes las dimensiones de las matrices T , A y W deben ser de (5×5) ; como en este ejemplo sólo se tienen 2 variables discriminantes, las dimensiones de las matrices deben ser de (2×2) .

Así para el problema se tiene que: para conocer la matriz W es necesario obtener las sumas de cuadrados (SS) de cada una de las variables, para cada grupo, es decir que:

$$\text{Suma de cuadrados de la } X_{1|1,\dots,g} = SSX_{1|1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n x_1^2 - n\bar{X}_1^2$$

donde:

$SSX_{1|1,\dots,g}$: indica la suma de cuadrados de la variable 1 desde el grupo 1 al grupo g .

$\sum_{i=1}^n x_1^2 - n\bar{X}_1^2$: indica la suma de cuadrados para la variable 1.

$\sum_{j=1}^g \sum_{i=1}^n x_1^2 - n\bar{X}_1^2$: indica la suma de cuadrados para la variable 1, para cada uno de los grupos.

Por lo que para la X_1 se tiene que:

$$SSX_{1|1,2} = SSX_{1|1} + SSX_{1|2} = [0.613 - 6(0.304)^2] + [0.009 - 6(0.305)^2]$$

$$SSX_{1|1,2} = SSX_{1|1} + SSX_{1|2} = [0.060] + [0.002] = 0.062$$

donde:

$SSX_{1|1}$: es la suma de cuadrados para la variable 1 en el grupo 1

$SSX_{1|2}$: es la suma de cuadrados para la variable 1 en el grupo 2

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_{2|1,\dots,g} = SSX_{2|1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n x_2^2 - n\bar{X}_2^2$$

$$SSX_{2|1,2} = SSX_{2|1} + SSX_{2|2} = [138.49 - 6(4.604)^2] + [18.337 - 6(1.644)^2]$$

$$SSX_{2|1,2} = SSX_{2|1} + SSX_{2|2} = [11.300] + [2.127] = 13.427$$

Ahora se obtiene la suma de los productos cruzados para la variable X_1 y para X_2 :

$$\text{Suma de productos cruzados de } X_1 \text{ y } X_{2|1,\dots,g} = SPX_1X_{2|1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_1X_2 - n\bar{X}_1\bar{X}_2$$

$$SPX_1X_{2|1,2} = SPx_1x_2|_1 = SPx_1x_2|_1 = [8.332 - 6(0.304)(4.604)] + [0.366 - 6(0.035)(1.644)]$$

$$SPX_1X_{2|1,2} = SPx_1x_2|_1 + SPx_1x_2|_2 = [-0.053] + [0.021] = -0.032$$

Para la matriz W se colocan las sumas de los cuadrados de la siguiente manera:

$$W = \begin{bmatrix} SSX_1 & SPX_1X_2 \\ SPX_1X_2 & SSX_2 \end{bmatrix}$$

Por lo que los resultados en dicha matriz serían los siguientes:

$$W = \begin{bmatrix} 0.062 & -0.032 \\ -0.032 & 13.427 \end{bmatrix}$$

Para obtener la matriz T es necesario utilizar los datos, pero sin partición de los grupos, es decir 70% de ellos; la información de esto con sus descriptivos se presenta a continuación:

Tabla 5-4 Datos sin acomodar por grupos y sus descriptivos

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$		
		Ingreso/ inversión	Activo/ pasivo					
2	1	0.243	3.994	0.059	15.952	0.971	2.031	37.487
4	1	0.378	4.036	0.143	16.289	1.526	ΣX_1	ΣX_2
7	1	0.18	4.87	0.032	23.717	0.877	0.169	3.124
9	1	0.22	3.635	0.048	13.213	0.800	$\bar{x}_1$	$\bar{x}_2$
11	1	0.47	3.567	0.221	12.723	1.676	0.622	156.827
14	1	0.33	7.523	0.109	56.596	2.483	ΣX_1^2	ΣX_2^2
3	2	0.05	2.778	0.003	7.717	0.139	8.698	
5	2	0.04	1.256	0.002	1.578	0.050	$\Sigma X_1 X_2$	
6	2	0.05	1.377	0.003	1.896	0.069		
8	2	0.04	1.143	0.002	1.306	0.046		
13	2	0.000	1.225	0.000	1.501	0.000		
15	2	0.03	2.083	0.001	4.339	0.062		

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
2	1	0.243	3.994	0.059	15.952	0.971
4	1	0.378	4.036	0.143	16.289	1.526
7	1	0.18	4.87	0.032	23.717	0.877
9	1	0.22	3.635	0.048	13.213	0.800
11	1	0.47	3.567	0.221	12.723	1.676
14	1	0.33	7.523	0.109	56.596	2.483
3	2	0.05	2.778	0.003	7.717	0.139
5	2	0.04	1.256	0.002	1.578	0.050
6	2	0.05	1.377	0.003	1.896	0.069
8	2	0.04	1.143	0.002	1.306	0.046
13	2	0.000	1.225	0.000	1.501	0.000
15	2	0.03	2.083	0.001	4.339	0.062
		2.031 ΣX_1	37.487 ΣX_2	0.622 ΣX_1^2	156.827 ΣX_2^2	8.698 $\Sigma X_1 X_2$
		0.169 $\bar{x}_1$	3.124 $\bar{x}_2$			

Las fórmulas para obtener las varianzas y covarianzas son las mismas, pero sin los grupos, por lo que:

$$\text{Suma de cuadrados de la } X_1 = SSX_1 = \sum_{i=1}^n X_1^2 - n\bar{X}_1^2$$

En estas ecuaciones no existe la doble sumatoria y sólo se tiene que definir que:

$\sum_{i=1}^n X_1^2 - n\bar{X}_1^2$: indica la suma de cuadrados para la variable 1.

Por lo que para la X_1 se tiene que:

$$SSX_1 = [0.622 - 12(0.169)^2] = 0.278$$

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_2 = SSX_2 = \sum_{i=1}^n X_2^2 - n\bar{X}_2^2$$

$$SSX_2 = [156.877 - 12(3.124)^2] = 39.721$$

Ahora se obtiene la suma de los productos cruzados para las variables X_1 y para X_2 :

$$\text{Suma de productos cruzados de } X_1 \text{ y } X_2 = SPX_1X_2 = \sum_{i=1}^n X_1X_2 - n\bar{X}_1\bar{X}_2$$

$$SPX_1X_2 = [8.689 - 12(0.169)(3.124)] = 2.353$$

Suma de cuadrados. Representa la varianza de los datos de la variable sin considerar diferencia de grupos.

Productos cruzados. Son la covarianza de los datos de las variables, sin considerar los grupos.

La **suma de cuadrados** representa la varianza de los datos de la variable sin considerar diferencia de grupos y los **productos cruzados** son la covarianza de los datos de las variables, también sin considerar a los grupos. Es importante observar cómo en este caso se menciona la $\bar{X}$ como la media de los datos¹⁸ de la variable sin considerar a los diferentes grupos.

Para la matriz T se ponen las sumas de los cuadrados de la siguiente manera:

$$T = \begin{bmatrix} SSX_1 & SPX_1X_2 \\ SPX_1X_2 & SSX_2 \end{bmatrix}$$

Es decir, la matriz T y W se obtienen de la misma manera, pero la matriz W se conoce al calcular las varianzas y covarianzas de los grupos y la matriz T sin la diferenciación de los grupos, por lo que los resultados de la matriz T serían:

$$T = \begin{bmatrix} 0.278 & 2.353 \\ 2.353 & 39.721 \end{bmatrix}$$

Finalmente, la matriz A se obtiene de la diferencia entre la matriz T y la matriz W .

$$A = T - W = \begin{bmatrix} 0.278 & 2.353 \\ 2.353 & 39.721 \end{bmatrix} - \begin{bmatrix} 0.062 & -0.032 \\ -0.032 & 13.427 \end{bmatrix}$$

Para obtener la diferencia en las matrices¹⁹ se realiza el siguiente procedimiento: a 0.278 se le resta 0.062 y se obtiene: 0.216; a 2.353 se le resta -0.032 y da como resultado: 2.385, y a 39.721 se le resta 13.427 lo que resulta 26.294, por lo que queda la siguiente matriz:

$$A = T - W = \begin{bmatrix} 0.216 & 2.385 \\ 2.385 & 26.294 \end{bmatrix}$$

Como se puede observar la matriz total se descompone en 2 partes: la variación explicada por la diferencia entre los grupos (la matriz A) y otra que representa lo distinto que son los datos dentro

¹⁸ También se le denomina *la gran media* o *la media de las medias*.

¹⁹ Vea también diferencia entre matrices en la página 320.

de cada grupo, que es lo que no se puede explicar (la matriz W); por lo tanto, la matriz T , que es la variación total, se define por:

$$T = A + W$$

5.6.5 Prueba de igualdad de las medias

Con los datos mencionados se realizará la prueba de las variables para asegurar que se seleccionaron las mejores para discriminar. Esto se lleva a cabo a través de una prueba de hipótesis:

H_0 : la variable i (X_i) no es buena para discriminar.

H_a : la variable i (X_i) sí es buena para discriminar.

Estas hipótesis se comprueban a través de las siguientes ecuaciones, primero se tiene que calcular la lambda de Wilks, la cual tiene la siguiente fórmula:

Ecuación 5-3 Expresión de la lambda de Wilks para la prueba de hipótesis de las variables

$$\Lambda = \frac{\text{determinante de } W}{\text{determinante de } T} = \frac{|W|}{|T|}$$

Después la lambda de Wilks se convierte en una F por medio de la siguiente expresión:

Ecuaciones 5-4 Equivalente a una F de la lambda de Wilks anterior

$$F_c = \left(\frac{1 - \Lambda}{\Lambda} \right) \left(\frac{n - g}{g - 1} \right)$$

O lo que es lo mismo:

$$F_c = \frac{(1 - \Lambda) / (g - 1)}{\Lambda / (n - g)}$$

donde:

g : es el número de grupos en el análisis, por lo que $g - 1$ son los grados de libertad del numerador.

n : es el número de datos de las variables, en donde $n - g$ serían los grados de libertad del denominador.

Para realizar la prueba de hipótesis la F_c se compara con la F de tablas, la cual tiene la siguiente nomenclatura:

$$F_{t, \alpha, g-1, n-g}$$

Lo anterior está hecho para realizarse en forma global, pero cuando se hacen las pruebas para cada variable es necesario sacar la información de cada una de las matrices, para formar la lambda de Wilks de cada una de ellas; esto significaría tener lo siguiente:

$$\Lambda_i = \frac{|\text{Variación no explicada de la } X_i|}{|\text{Variación total de la } X_i|} = \frac{|W_{X_i}|}{|T_{X_i}|}$$

donde:

Λ_i : es la lambda de Wilks para la variable i

W_{X_i} : es la variación no explicada de la variable i , cuyo valor se toma de la matriz W

T_{X_i} : es la variación total de la variable i , cuyo valor se toma de la matriz T

Lo que significa que la variación de cada variable se encuentra en la matriz W y la matriz T , entonces la transformación a la F sería de la lambda de cada variable, es decir:

$$F_{C_{X_i}} = \left(\frac{1 - \Lambda_i}{\Lambda_i} \right) \left(\frac{n - g}{g - 1} \right)$$

O lo que es lo mismo que:

$$F_{C_{X_i}} = \frac{(1 - \Lambda_i) / (g - 1)}{\Lambda_i / (n - g)}$$

La primera variable que se probará será la razón del ingreso y la inversión ($R_{I,I}$) la cual es la variable 1 (X_1).

H_0 : la variable razón del ingreso y la inversión ($R_{I,I}$) no es buena para discriminar.

H_a : la razón del ingreso y la inversión ($R_{I,I}$) es buena para discriminar.

Para la variable X_1 los datos que se tomarán para llenar las fórmulas son aquellos diferentes a los datos que están dentro de cada grupo, que es el primer coeficiente de la matriz W , y la suma de cuadrados de la variable en la muestra total, que es el primer coeficiente de la matriz T , por lo que queda como sigue:

$$\Lambda_1 = \frac{\text{Variación no explicada de la } X_1}{\text{Variación total de la } X_1} = \frac{0.062}{0.278} = 0.222$$

Entre más pequeña una lambda de Wilks es mejor. Ahora la lambda de Wilks se convierte en una F ; al saber que hay 12 datos y 2 grupos se tiene que:

$$n - g = 12 - 2 = 10 \text{ y además que } g - 1 = 2 - 1 = 1$$

por lo que la F sería de la siguiente forma:

$$F_{C_{X_i}} = \frac{(1 - \Lambda_1) / (g - 1)}{\Lambda_1 / (n - g)} = \frac{(1 - 0.222) / (2 - 1)}{0.222 / (12 - 2)} = 35.104$$

Sigue el estadístico teórico que es definido por:


$$F_{t, \alpha, g-1, n-g}$$

Supóngase que el estudio se realiza con 95% de confianza, con 2 grupos y 12 datos, se tiene que:

$$F_{t, \alpha=0.05, g-1=2-1=1, n-g=12-2=10} = F_{t, \alpha=0.05, 1, 10} = 4.965$$

cuyo valor se obtiene de la siguiente manera:

Tabla 5-5 Tabla F^{20}



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
9	0.100	3.360	3.006	2.813	2.693	2.611	2.551	2.505	2.469	2.440	2.416	2.379	2.340	2.298	2.277	2.255
	0.050	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.073	3.006	2.936	2.900	2.864
	0.025	7.209	5.715	5.078	4.718	4.484	4.320	4.197	4.102	4.026	3.964	3.868	3.769	3.667	3.614	3.560
	0.010	10.561	8.022	6.992	6.422	6.057	5.802	5.613	5.467	5.351	5.257	5.111	4.962	4.808	4.729	4.649
	0.005	13.614	10.107	8.717	7.956	7.471	7.134	6.885	6.693	6.541	6.417	6.227	6.032	5.832	5.729	5.625
10	0.100	3.285	2.924	2.728	2.605	2.522	2.461	2.414	2.377	2.347	2.323	2.284	2.244	2.201	2.178	2.155

(continúa)

²⁰ Ver anexo 2.3, tabla F.

Tabla 5-5 Tabla F (continuación)

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
	0.050	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.913	2.845	2.774	2.737	2.700
	0.025	6.937	5.456	4.826	4.468	4.236	4.072	3.950	3.855	3.779	3.717	3.621	3.522	3.419	3.365	3.311
	0.010	10.044	7.559	6.552	5.994	5.636	5.386	5.200	5.057	4.942	4.849	4.706	4.558	4.405	4.327	4.247
	0.005	12.826	9.427	8.081	7.343	6.872	6.545	6.302	6.116	5.968	5.847	5.661	5.471	5.274	5.173	5.071
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941

Las hipótesis serían:

H_0 : la variable X_1 (ingreso/inversión) no es buena para discriminar.

H_a : la variable X_1 (ingreso/inversión) sí es buena para discriminar.


Para rechazar la H_0 es necesario que:

$$F_C > F_{t, \alpha, g-1, n-g}$$

por lo que:

$$35.104 > 4.965 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que la variable X_1 es buena para discriminar, es decir, que la razón ingreso e inversión es significativamente buena para separar en 2 grupos.

De la misma manera, se probará la variable razón del activo y pasivo (R_{API}) que es la variable 2 (X_2).

Para la variable X_2 ahora se tomará el cálculo de lo distintos que son los datos de la X_2 en la matriz W que es el cuarto coeficiente y la suma de cuadrados de la X_2 en la matriz T entonces:

$$\Lambda_2 = \frac{\text{Variación no explicada de la } X_2}{\text{Variación total de la } X_2} = \frac{13.427}{39.721} = 0.338$$

Ahora la lambda de Wilks se convierte en una F ; al saber que hay 12 datos y 2 grupos, se tiene que:

$$n - g = 12 - 2 = 10 \text{ y además que } g - 1 = 2 - 1 = 1$$

por lo que la F sería de la siguiente forma:

$$F_{C_{X_2}} = \frac{(1 - \Lambda_2)/(g - 1)}{\Lambda_2/(n - g)} = \frac{(1 - 0.338)/(2 - 1)}{0.338/(12 - 2)} = 19.582$$

Sigue el estadístico teórico que se define por:


$$F_{t, \alpha, g-1, n-g}$$

Supóngase que el estudio se realiza con 95% de confianza, con 2 grupos y 12 datos, se tiene que:

$$F_{t, \alpha=0.05, g-1=2-1=1, n-g=12-2=10} = F_{t, \alpha=0.05, 1, 10} = 4.965$$

cuyo valor se obtiene de la siguiente manera:

Tabla 5-6 Tabla F^{21}



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
9	0.100	3.360	3.006	2.813	2.693	2.611	2.551	2.505	2.469	2.440	2.416	2.379	2.340	2.298	2.277	2.255
	0.050	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.073	3.006	2.936	2.900	2.864
	0.025	7.209	5.715	5.078	4.718	4.484	4.320	4.197	4.102	4.026	3.964	3.868	3.769	3.667	3.614	3.560
	0.010	10.561	8.022	6.992	6.422	6.057	5.802	5.613	5.467	5.351	5.257	5.111	4.962	4.808	4.729	4.649
	0.005	13.614	10.107	8.717	7.956	7.471	7.134	6.885	6.693	6.541	6.417	6.227	6.032	5.832	5.729	5.625
10	0.100	3.285	2.924	2.728	2.605	2.522	2.461	2.414	2.377	2.347	2.323	2.284	2.244	2.201	2.178	2.155
	0.050	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.913	2.845	2.774	2.737	2.700
	0.025	6.937	5.456	4.826	4.468	4.236	4.072	3.950	3.855	3.779	3.717	3.621	3.522	3.419	3.365	3.311
	0.010	10.044	7.559	6.552	5.994	5.636	5.386	5.200	5.057	4.942	4.849	4.706	4.558	4.405	4.327	4.247
	0.005	12.826	9.427	8.081	7.343	6.872	6.545	6.302	6.116	5.968	5.847	5.661	5.471	5.274	5.173	5.071
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941

Las hipótesis serían:

H_0 : la variable X_2 (activo/pasivo) no es buena para discriminar.

H_a : la variable X_2 (activo/pasivo) sí es buena para discriminar.


Para rechazar la H_0 es necesario que:

$$F_C > F_{t, \alpha, g-1, n-g}$$

por lo que:

$$19.582 > 4.965 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



²¹ Ver anexo 2.3, tabla F.

Por lo que se rechaza H_0 y se concluye que la variable X_2 es buena para discriminar, es decir, que la razón activo y pasivo también es significativamente buena para separar en 2 grupos.

5.6.6. Prueba del modelo

Como las 2 variables del ejemplo son buenas para discriminar, el siguiente paso es obtener los eigenvalores²² (λ).

De acuerdo con el criterio mencionado anteriormente, es necesaria la:

$$\text{Maximización de: } \frac{\text{Variabilidad entre grupos}}{\text{Variabilidad dentro de los grupos}}$$

El resultado de esta división se interpreta como el valor propio o eigenvalor (λ) que es lo mismo que la cantidad de variación que se explica por medio de la ecuación. Entonces esta relación se deriva y se iguala a 0 con el objetivo de obtener las constantes correspondientes que maximicen esta relación.

La obtención de los correspondientes eigenvalores implica resolver el siguiente determinante:

$$|W^{-1}A - \lambda I| = 0$$

donde:

W^{-1} : indica la inversa de la matriz W que es la matriz de la variación no explicada

A : es la matriz de la variación explicada

λ : son los valores propios

I : es la matriz identidad

Primero se buscará la inversa de la matriz W , la cual se encontró anteriormente

$$W = \begin{bmatrix} 0.062 & -0.032 \\ -0.032 & 13.427 \end{bmatrix}$$

Se necesita calcular el determinante de la siguiente manera:

$$\text{Det}(W) = |W| = (0.062)(13.427) - (-0.032)(-0.032) = 0.826$$

Las sumas de cuadrados de las variables y del producto cruzado se dividen entre el determinante:

$$\begin{bmatrix} \frac{0.062}{0.826} & \frac{-0.032}{0.826} \\ \frac{-0.032}{0.826} & \frac{13.427}{0.826} \end{bmatrix}$$

dicha división da como resultado lo siguiente:

$$\begin{bmatrix} 0.075 & -0.038 \\ -0.038 & 16.251 \end{bmatrix}$$

Ahora intercambian de posición la suma de cuadrados de las variables X_1 y X_2 , es decir, la diagonal principal de la matriz se intercambia y en la diagonal secundaria se modifica el signo a los productos cruzados; la matriz inversa (W^{-1}) queda así:

$$W^{-1} = \begin{bmatrix} 16.251 & 0.038 \\ 0.038 & 0.075 \end{bmatrix}$$

²² En el anexo 3.2 "Descomposición espectral" se trató, de manera amplia, cómo encontrar los valores propios.

La inversa (W^{-1}) multiplica a la matriz A

$$W^{-1}A = \begin{bmatrix} 16.251 & 0.038 \\ 0.038 & 0.075 \end{bmatrix} \begin{bmatrix} 0.216 & 2.385 \\ 2.385 & 26.294 \end{bmatrix}$$

$$W^{-1}A = \begin{bmatrix} 3.606 & 39.760 \\ 0.186 & 2.052 \end{bmatrix}$$

Esto se realiza al multiplicar la primera columna por el primer renglón, lo que da el primer coeficiente, por ejemplo:

$$(16.251)(0.216) + (0.038)(2.385) = 3.606$$

el segundo producto es:

$$(16.251)(2.385) + (0.038)(26.294) = 39.760$$

y así los siguientes, el resultado sería:

$$W^{-1}A = \begin{bmatrix} 3.606 & 39.760 \\ 0.186 & 2.052 \end{bmatrix}$$

A esta matriz se le resta el eigenvalor por la matriz identidad. Como la matriz pasada es de dimensiones de (2×2) , la matriz identidad es la siguiente:

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

que al multiplicar por el eigenvalor queda:

$$\lambda I = \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix}$$

por lo que la diferencia de $W^{-1}A - \lambda I$ es:

$$W^{-1}A - \lambda I = \begin{bmatrix} 3.606 & 39.760 \\ 0.186 & 2.052 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3.606 - \lambda & 39.760 \\ 0.186 & 2.052 - \lambda \end{bmatrix}$$

Ahora bien es necesario resolver el determinante, el cual fue definido como:

$$|W^{-1}A - \lambda I| = 0$$

el determinante sería entonces:

$$|W^{-1}A - \lambda I| = (3.606 - \lambda)(2.052 - \lambda) - (39.760)(0.186)$$

el cual debe igualarse a cero; al resolver los productos y la diferencia se tiene que:

$$|W^{-1}A - \lambda I| = 7.399 - 3.606\lambda - 2.052\lambda - \lambda^2 - 7.399 = 0$$

al arreglar la información da como resultado una cuadrática:

$$\lambda^2 - 5.658\lambda - 0 = 0$$

Para encontrar los valores de λ se debe resolver la cuadrática, la cual está igualada a cero, es decir, se debe despejar la lambda de la ecuación:

$$\lambda^2 - 5.658\lambda = 0$$

al factorizar se tiene que:

$$\lambda(\lambda - 5.658) = 0$$

por lo que los 2 valores propios serían:

$$\lambda = 0 \text{ y además } (\lambda - 5.658) = 0$$

al despejar el segundo:

$$\lambda - 5.658 = 0$$

por lo que:

$$\lambda = 5.658$$

ahora los 2 se ordenan de mayor a menor, por lo que:

$$\lambda_1 = 5.658 \text{ y } \lambda_2 = 0$$

Como se mencionó en el capítulo 3 “Análisis de factores” el eigenvalor es sinónimo de la cantidad de variación o información manejada, entonces hay que saber si ésta es relevante o significativa. Se utiliza principalmente para evaluar la importancia de cada una de las funciones discriminantes. Aunque un autovalor tiene un mínimo de cero no tiene un máximo, lo cual lo hace difícil de interpretar por sí solo, pero el valor se utiliza para probar el modelo como se explicará.

Con el valor del eigenvalor (λ) ahora se probará el modelo para saber si es bueno para discriminar o no. Existen 2 métodos, 1 de ellos es el que maneja el paquete estadístico SPSS™ que a continuación se explicará y la otra prueba es a través del estadístico de Mahalanobis, que también se expondrá en páginas posteriores.

Para realizar la prueba del modelo se recurrirá al estadístico V de Bartlett, que es una función de la lambda de Wilks y tiene una distribución asintótica ji cuadrada, la fórmula es la siguiente:

Ecuación 5-5 La expresión de Bartlett para la prueba de hipótesis del modelo

$$V = \left\{ n - 1 - \frac{k + g}{2} \right\} \ln(1 + \lambda g)$$

donde:

n : es el número de datos

k : es el número de variables independientes o discriminantes

g : es el número de grupos en la variable dependiente

Las hipótesis para la prueba del modelo son:

H_0 : el modelo no es bueno para discriminar

H_a : el modelo sí es bueno para discriminar

Al sustituir los valores en la fórmula queda:

$$V = \left\{ 12 - 1 - \frac{2 + 2}{2} \right\} \ln(1 + 5.658) = 17.062$$

El estadístico V de Bartlett sigue una distribución ji cuadrada con los grados de libertad:

$$\chi^2_{(k-j)(g-j-1)}$$

donde:

k : es el número de variables independientes

g : es el número de grupos en la variable dependiente

j : es el número correspondiente a cada una de las funciones discriminantes generadas

Es importante recalcar que el número de ecuaciones discriminantes que se generan tienen que ver con el mínimo de:

- El número de grupos menos 1.
- El número de variables.

Por lo que:

$$\text{Mín}\{(g-1)(m)\}$$

donde:

g : es el número de grupos en la variable dependiente

m : es el número de variables independientes

Ahora bien, cuando sólo hay una función, como en este caso porque la variable dependiente tienen 2 grupos, $j = 0$. Por lo que:


$$\chi_C^2 = 17.062$$

y como se está utilizando 5% como nivel de significancia, el estadístico teórico sería:

$$\chi_{t, \alpha=0.05, (2-0)(2-0-1)=2}^2 = 5.991$$

el cual se encontró de la siguiente manera:

Tabla 5-7 Ji cuadrada²³



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.952	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264
12	11.340	12.584	14.011	15.812	18.549	21.026	23.337	24.054	24.963	26.217	28.300	32.909

Las hipótesis para la prueba del modelo son:

H_0 : el modelo no es bueno para discriminar.

H_a : el modelo sí es bueno para discriminar.

Para rechazar la H_0 es necesario que:


$$\chi_C^2 > \chi_{t, \alpha, (k-j)(g-j-1)}^2$$

²³ Ver anexo 3.1, tabla ji cuadrada.

por lo que:

$$17.062 > 5.991 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que el modelo sí es bueno para discriminar.

Dentro del análisis discriminante existe otra forma de hacer la prueba de hipótesis del modelo y es a través de la distancia de Mahalanobis, que se utiliza para evaluar si el modelo es bueno estadísticamente para diferenciar; su fórmula es la siguiente:

Ecuación 5-6 Distancia de Mahalanobis

$$d_{ij} = (n - g) [(\bar{X}_i - \bar{X}_j)^T \Sigma^{-1} (\bar{X}_i - \bar{X}_j)]^{\frac{1}{2}}$$

En esta prueba, las hipótesis establecen lo siguiente:

H_0 : el modelo o la función discriminante no es bueno para discriminar o clasificar las observaciones en los 2 grupos.

H_a : la ecuación o el modelo discriminante es bueno para discriminar o separar a los 2 grupos.

Al transformar la distancia de Mahalanobis para el análisis de los grupos, se tiene que:

$$D = (n - g) [(\bar{X}_{i|1, \dots, g} - \bar{X}_{j|1, \dots, g})^T W^{-1} (\bar{X}_{i|1, \dots, g} - \bar{X}_{j|1, \dots, g})]^{\frac{1}{2}}$$

o bien:

$$D = (n - g) \sqrt{(\bar{X}_{i|1, \dots, g} - \bar{X}_{j|1, \dots, g})^T W^{-1} (\bar{X}_{i|1, \dots, g} - \bar{X}_{j|1, \dots, g})}$$

Al sustituir en la fórmula queda como sigue:

$$D = (n - g) \sqrt{(\bar{X}_{i|1, 2} - \bar{X}_{j|1, 2})^T W^{-1} (\bar{X}_{i|1, 2} - \bar{X}_{j|1, 2})}$$

donde:

$$n - g = 12 - 2 = 10$$

además:

$$(\bar{X}_{i|1, 2} - \bar{X}_{j|1, 2}) = \begin{bmatrix} \bar{X}_{1|1} - \bar{X}_{1|2} \\ \bar{X}_{2|1} - \bar{X}_{2|2} \end{bmatrix} = \begin{bmatrix} 0.304 - 0.035 \\ 4.604 - 1.644 \end{bmatrix} = \begin{bmatrix} 0.269 \\ 2.961 \end{bmatrix}$$

por lo que la transpuesta sería:

$$(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T = [\bar{X}_{i|1} - \bar{X}_{j|1} \quad \bar{X}_{i|2} - \bar{X}_{j|2}]$$

entonces:

$$(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T = [0.304 - 0.035 \quad 4.604 - 1.644] = [0.269 \quad 2.961]$$

Ahora al seguir la fórmula:

$$(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T W^{-1} (\bar{X}_{i|1,2} - \bar{X}_{j|1,2}) = [0.269 \quad 2.961] \begin{bmatrix} 16.251 & 0.0038 \\ 0.038 & 0.075 \end{bmatrix} \begin{bmatrix} 0.269 \\ 2.961 \end{bmatrix}$$

se multiplica el vector por la matriz:

$$(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T W^{-1} (\bar{X}_{i|1,2} - \bar{X}_{j|1,2}) = [4.477 \quad 0.231] \begin{bmatrix} 0.269 \\ 2.961 \end{bmatrix}$$

al multiplicar los 2 vectores:

$$(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T W^{-1} (\bar{X}_{i|1,2} - \bar{X}_{j|1,2}) = [1.886]$$

por lo que finalmente la fórmula da el siguiente resultado:

$$D = (n - g) \sqrt{(\bar{X}_{i|1,2} - \bar{X}_{j|1,2})^T W^{-1} (\bar{X}_{i|1,2} - \bar{X}_{j|1,2})} = 10 \sqrt{1.886} = 13.733$$

Como se mencionó anteriormente, para hacer la prueba del modelo se utiliza la prueba Mahalanobis en la que se obtiene la D , la cual es un valor absoluto (positivo), ya que evalúa la distancia entre los promedios. La D se ajusta a una F para tomar la decisión de aceptar o rechazar la H_0 . La fórmula para transformar a la F es la siguiente:

Ecuación 5-7 El equivalente a la F de la expresión de la distancia de Mahalanobis

$$F_C = \frac{(n - g - 1)(n|_1 * n|_2) |D|}{[(n|_1 + n|_2 - 2)g](n|_1 + n|_2)}$$

donde:

n : es el número total de datos

$n|_1$: es el número de datos manejados en el grupo 1

$n|_2$: es el número de datos manejados en el grupo 2

g : es el número de grupos manejados en la variable dependiente

$|D|$: es el valor absoluto de la distancia de Mahalanobis

Al sustituir queda así:

$$F_C = \frac{(n - g - 1)(n|_1 * n|_2) |D|}{[(n|_1 + n|_2 - 2)g](n|_1 + n|_2)} = \frac{(12 - 2 - 1)(6 * 6)13.733}{[(6 + 6 - 2)2](6 + 6)} = 18.540$$

El estadístico de prueba, es decir, la F_C se compara contra F_t con grados de libertad:


$$F_{t,\alpha,g,n|_1+n|_2-g-1}$$

por lo que el estadístico teórico o de tablas sería el siguiente:

$$F_{t,\alpha,2,6+6-2-1=9} = F_{t,\alpha=0.05,2,9} = 4.256$$

el cual se encontró de la siguiente manera:

Tabla 5-8 Tabla F^{24}



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
9	0.100	3.360	3.006	2.813	2.693	2.611	2.551	2.505	2.469	2.440	2.416	2.379	2.340	2.298	2.277	2.255
	0.050	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.073	3.006	2.936	2.900	2.864
	0.025	7.209	5.715	5.078	4.718	4.484	4.320	4.197	4.102	4.026	3.964	3.868	3.769	3.667	3.614	3.560
	0.010	10.561	8.022	6.992	6.422	6.057	5.802	5.613	5.467	5.351	5.257	5.111	4.962	4.808	4.729	4.649
	0.005	13.614	10.107	8.717	7.956	7.471	7.134	6.885	6.693	6.541	6.417	6.227	6.032	5.832	5.729	5.625
10	0.100	3.285	2.924	2.728	2.605	2.522	2.461	2.414	2.377	2.347	2.323	2.284	2.244	2.201	2.178	2.155
	0.050	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.913	2.845	2.774	2.737	2.700
	0.025	6.937	5.456	4.826	4.468	4.236	4.072	3.950	3.855	3.779	3.717	3.621	3.522	3.419	3.365	3.311
	0.010	10.044	7.559	6.552	5.994	5.636	5.386	5.200	5.057	4.942	4.849	4.706	4.558	4.405	4.327	4.247
	0.005	12.826	9.427	8.081	7.343	6.872	6.545	6.302	6.116	5.968	5.847	5.661	5.471	5.274	5.173	5.071
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941

Las hipótesis serían:

H_0 : el modelo o la función discriminante no es bueno para discriminar o clasificar las observaciones en los 2 grupos.

H_a : la ecuación o el modelo discriminante es bueno para discriminar o separar en los 2 grupos.

Para rechazar la H_0 es necesario que:


$$F_C > F_{t,\alpha,g,n|1+n|2-g-1}$$

por lo que:

$$18.540 > 4.256 \text{ se rechaza } H_0$$

²⁴ Ver anexo 2.3, tabla F.

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que el modelo sí es bueno para discriminar, lo que apoya el resultado obtenido por el método anterior.

5.6.7 Indicadores del ajuste del modelo

Los indicadores que reporta el paquete estadístico SPSSTM con respecto al modelo son los siguientes:

5.6.7.1 Valores propios

La búsqueda de los eigenvalores correspondientes se explicó en la obtención del modelo a través de la siguiente expresión:

$$|W^{-1}A - \lambda I| = 0$$

Al realizar dicho procedimiento se obtuvieron 2 valores propios que fueron ordenados de mayor a menor, éstos fueron:

$$\lambda_1 = 5.658 \text{ y la } \lambda_2 = 0$$

El eigenvalor es sinónimo de la cantidad de variación o información manejada, por lo que entre mayor sea su valor es mejor; si se tienen varios valores propios siempre se escogerá el mayor.

5.6.7.2 Lambda de Wilks

La medida **lambda de Wilks** evalúa la capacidad discriminante de la función y expresa la proporción de la varianza total explicada por los puntajes discriminantes, mientras más cerca esté del cero mayor será el poder discriminante de las variables utilizadas en el estudio. Su fórmula es la siguiente:

Ecuación 5-8 La expresión de la lambda de Wilks

$$\Lambda = \frac{\text{determinante de } W}{\text{determinante de } T} = \frac{|W|}{|T|}$$

donde:

$|W|$: es el determinante de la matriz de varianzas y covarianzas dentro de cada grupo, es decir, es la variación no explicada

$|T|$: es el determinante de la matriz de varianzas y covarianzas del conjunto total de datos

Los valores de $|W|$ y $|T|$ se obtienen de los determinantes de las matrices correspondientes. El determinante de la matriz $|W|$ se obtuvo anteriormente cuando se calculó el eigenvalor, donde:

$$W = \begin{bmatrix} 0.062 & -0.032 \\ -0.032 & 13.427 \end{bmatrix}$$

Lambda de Wilks.
Medida que evalúa la capacidad discriminante de la función y expresa la proporción de la varianza total explicada por los puntajes discriminantes.

El determinante se obtuvo como sigue:

$$\text{Det}(W) = |W| = (0.062)(13.427) - (-0.032)(-0.032) = 0.826$$

Como la matriz T es:

$$T = \begin{bmatrix} 0.278 & 2.353 \\ 2.353 & 39.721 \end{bmatrix}$$

el determinante de T es el siguiente:

$$\text{Det}(T) = |T| = (0.278)(39.721) - (2.353)(2.353) = 5.501$$

por lo que lambda de Wilks da como resultado:

$$\Lambda = \frac{\text{determinante de } W}{\text{determinante de } T} = \frac{|W|}{|T|} = \frac{0.826}{5.501} = 0.150$$

Es importante saber que los valores de la lambda de Wilks varían entre 0 y 1, los próximos a 0 indican mucha discriminación, es decir, los grupos están muy separados, mientras que los cercanos a 1 representan escasa discriminación o poca diferencia entre los grupos, lo cual indica que los grupos están muy mezclados. Como conclusión, en este caso la $\Lambda = 0.150$ muestra que los grupos se encuentran muy poco mezclados.

5.6.7.3 Correlación canónica

Otro estadístico que se puede generar es la **correlación canónica**; este coeficiente mide, para cada función discriminante, el grado en que se diferencian las medias por cada una de las funciones. Un valor alto de correlación canónica indica una fuerte relación entre el grupo de pertenencia y los valores de la función discriminante correspondiente. Por el contrario, si los grupos no son muy diferentes entre sí las correlaciones serán bajas. La fórmula para encontrar la correlación canónica es:

Ecuación 5-9 Correlación canónica.

$$\text{Correlación canónica} = \sqrt{1 - \Lambda}$$

Al sustituir el valor de la lambda de Wilks se tiene que:

$$\text{Correlación canónica} = \sqrt{1 - \Lambda} = \sqrt{1 - 0.150} = 0.922$$

Otra forma de encontrar la correlación canónica es a través del valor propio con la fórmula de eta cuadrada (η^2), que es el coeficiente de determinación obtenido al realizar el modelo discriminante y que indica la pertenencia al grupo y las puntuaciones discriminantes; su fórmula está basada en el valor propio (λ).

Ecuación 5-10 Eta cuadrada utilizada para encontrar correlación canónica

$$\text{Correlación canónica} = \eta^2 = \sqrt{\frac{\lambda}{1 + \lambda}}$$

Al sustituir en la fórmula el resultado queda como sigue:

$$\eta^2 = \sqrt{\frac{\lambda}{1 + \lambda}} = \sqrt{\frac{5.658}{1 + 5.658}} = 0.922$$

La correlación canónica oscila entre cero y 1, un valor cercano a cero indica que no se puede explicar la existencia de los 2 grupos por medio de las variables discriminantes escogidas; un valor

Correlación canónica. Coeficiente que mide, para cada función discriminante, el grado en que se diferencian las medias por cada una de las funciones.

cercano a 1 indica una fuerte relación entre los grupos de pertenencia y los puntajes encontrados por la función discriminante.

Como en este caso la correlación canónica fue de 0.922, que es un valor alto, existe una relación fuerte entre el grupo de pertenencia y los valores de la función discriminante (puntajes discriminantes).

5.6.8 Obtención de las constantes del modelo

A continuación con 70% de los datos se debe encontrar la función discriminante. Con las fórmulas explicadas se buscarán los valores de las constantes²⁵ o K del modelo o ecuación. Con la siguiente fórmula:

$$|W^{-1}A - \lambda I| = 0$$

se encontraron los valores propios, pero para conocer las K es necesario obtener la siguiente expresión:

Ecuación 5-11 Forma matricial para los coeficientes

$$(W^{-1}A - \lambda I)K = 0$$

donde K es el vector de constantes que se desea encontrar:

$$W^{-1}A = \begin{bmatrix} 16.251 & 0.038 \\ 0.038 & 0.075 \end{bmatrix} \begin{bmatrix} 0.216 & .2385 \\ 2.385 & 26.294 \end{bmatrix}$$

y además:

$$\lambda I = \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix}$$

por lo que:

$$W^{-1}A - \lambda I = \begin{bmatrix} 3.606 & 39.760 \\ 0.186 & 2.052 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3.606 - \lambda & 39.760 \\ 0.186 & 2.052 - \lambda \end{bmatrix}$$

Donde el primer eigenvalor (λ_1) obtenido anteriormente fue de $\lambda_1 = 5.658$, el cual se sustituye y con esto se obtiene:

$$\begin{bmatrix} 3.606 - \lambda & 39.760 \\ 0.186 & 2.052 - \lambda \end{bmatrix} = \begin{bmatrix} 3.606 - 5.658 & 39.760 \\ 0.186 & 2.052 - 5.658 \end{bmatrix}$$

por lo que el resultado sería:

$$\begin{bmatrix} -2.052 & 39.760 \\ 0.186 & -3.606 \end{bmatrix}$$

Esta expresión se multiplica por el vector de constantes y se iguala a un vector de ceros; por lo que la expresión a resolver es:

$$(W^{-1}A - \lambda I)K = \begin{bmatrix} -2.052 & 39.760 \\ 0.186 & -3.606 \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Al multiplicar se generan 2 ecuaciones, las cuales son las siguientes:

$$-2.052K_1 + 39.760K_2 = 0$$

²⁵ Los términos *constantes*, *coeficientes* o K son sinónimos.

Se despeja alguna de las constantes, por ejemplo K_2 :

$$39.760K_2 = 2.052K_1$$

por lo que:

$$K_2 = \frac{2.052}{39.760}K_1$$

entonces K_2 es igual a:

$$K_2 = 2.052K_1$$

La segunda sería:

$$0.186K_1 - 3.606K_2 = 0$$

Se despeja alguna de las constantes; supóngase que la K_2 :

$$-3.606K_2 = -0.186K_1$$

por lo que:

$$K_2 = \frac{-0.186}{-3.606}K_1$$

entonces K_2 es igual a:

$$K_2 = 2.052K_1$$

Como se puede observar las 2 ecuaciones son iguales por la relación que guardan, por lo tanto no es posible resolver el sistema de ecuaciones y solamente se conservará una de ellas.

$$K_2 = 2.052K_1$$

Ahora es necesario encontrar la norma, la cual está definida como:

Ecuación 5-12 Norma del vector

$$\|X\| = \sqrt{X^T X}$$

Esta fórmula proviene del teorema de Pitágoras por lo que:

Ecuación 5-13 Teorema de Pitágoras

$$CO^2 + CA^2 = H^2$$

En este caso lo que se desea es conocer la suma de cuadrados de las K de la unidad, es decir:

$$K_1^2 + K_2^2 = 1^2 = 1$$

Se sabe que $K_2 = 2.052K_1$ y al sustituir el valor en la expresión anterior, se tiene que:

$$K_1^2 + (0.052K_1)^2 = 1$$

al elevar al cuadrado quedaría de la siguiente manera:

$$K_1^2 + 0.003K_1^2 = 1$$

al sumar las dos, da como resultado:

$$1.003K_1^2 = 1$$

ahora se despeja K_1 :

$$K_1^2 = \frac{1}{1.003}$$

por lo que finalmente se tiene:

$$K_1 = \sqrt{\frac{1}{1.003}} = 0.999$$

Ese valor se pone en la ecuación de $K_2 = 2.052K_1$ por lo que se tiene que:

$$K_2 = 2.052 (0.999)$$

da como resultado:

$$K_2 = 0.0515$$

así se conoce el vector normalizado de las K :

$$K \text{ normalizado} = K_N = \begin{bmatrix} 0.999 \\ 0.052 \end{bmatrix}$$

donde:

K_N : es el vector de las K normalizados

Estos valores de K reúnen la condición llamada *constantes normalizados*. La mayoría de los paquetes como el SPSSTM hacen un reescalamiento de los coeficientes, es decir, de K ; lo anterior se realiza con el procedimiento que explicaremos en seguida.

Para conseguir el reescalamiento es necesario seguir la siguiente forma matricial:

Ecuación 5-14 Procedimiento para obtener el escalar

$$B = K_N^T C_W K_N$$

donde:

B : es un escalar que se utiliza para reescalar las constantes

K_N^T : es la traspuesta del vector de constantes normalizados

C_W : es la matriz W promediada

K_N : es el vector de constantes normalizados

La matriz W se divide entre sus grados de libertad que son:

$$n - g$$

donde:

n : es el número de datos

g : es el número de datos en la variable dependiente

Por lo que en el ejemplo, los grados de libertad de la matriz W es: $n - 2 = 10$, a ésta se le llamará C_W y consiste de las varianzas y covarianzas promediadas²⁶ que presentan los datos dentro de cada grupo.

$$W = \begin{bmatrix} 0.062 & -0.032 \\ -0.032 & 13.427 \end{bmatrix}$$

se divide entre los grados de libertad:

$$C_W = \frac{W}{n - 2} = \frac{W}{10}$$

²⁶ Ya que fueron divididas entre los grados de libertad.

y da como resultado:

$$C_W = \frac{W}{10} = \begin{bmatrix} \frac{0.062}{10} & \frac{-0.032}{10} \\ \frac{-0.032}{10} & \frac{13.427}{10} \end{bmatrix} = \begin{bmatrix} 0.006 & -0.003 \\ -0.003 & 1.343 \end{bmatrix}$$

se sabe que:

$$K_N = \begin{bmatrix} 0.999 \\ 0.052 \end{bmatrix}$$

por lo que la K_N^T es:

$$K_N^T = [0.999 \quad 0.052]$$

Al llevar a cabo la operación $K_N^T C_W$ se tiene:

$$K_N^T C_W = [0.999 \quad 0.052] \begin{bmatrix} 0.006 & -0.003 \\ -0.003 & 1.343 \end{bmatrix} = [0.006 \quad 0.066]$$

El resultado se multiplica por el vector de las K normalizados, es decir, por K_N .

$$K_N^T C_W K_N = [0.006 \quad 0.066] \begin{bmatrix} 0.999 \\ 0.052 \end{bmatrix}$$

da como resultado un escalar,²⁷ el cual es:

$$B = K_N^T C_W K_N = [0.009]$$

y los K reescalados, los cuales serán definidos por:

Ecuación 5-15 Coeficientes reescalados

$$K_{\text{reescalados}} = K_R = K_N B^{-\frac{1}{2}} = K_N \frac{1}{\sqrt{B}}$$

Al seguir con el ejemplo, los K reescalados se obtienen de la siguiente manera:

$$K_R = K_N \frac{1}{\sqrt{B}} = \begin{bmatrix} 0.999 \\ 0.052 \end{bmatrix} \frac{1}{\sqrt{0.009}} = \begin{bmatrix} 10.308 \\ 0.532 \end{bmatrix}$$

lo encontrado se sustituye en la ecuación lineal discriminante la cual es:

Ecuación 5-16 Ecuación lineal discriminante

$$Z = K_1 X_1 + K_2 X_2 + \dots + K_m X_m$$

donde:

Z : es la variable dependiente de respuesta reescalada

K_i : es el coeficiente reescalado de la variable i

X_i : es la variable independiente o discriminante i

Como en el ejemplo sólo se tienen 2 variables independientes, la ecuación discriminante es:

$$Z = K_1 X_1 + K_2 X_2 = 10.308 X_1 + 0.532 X_2$$

²⁷ El término *escalar* se refiere a cualquier número o bien un vector o matriz de dimensiones (1×1) .

Pero dicha ecuación al ser reescalada se le necesita agregar una constante, a la cual se le denomina K_0 . Para obtener dicha constante es necesario conocer las Z promedio, las cuales están definidas por:

Ecuación 5-17 Ecuación de las Z promedio

$$\bar{Z}|_g = K_1 \bar{X}_1|_g + K_2 \bar{X}_2|_g + \dots + K_m \bar{X}_m|_g$$

donde:

$\bar{Z}|_g$: es la Z promedio del grupo g

K_m : es el coeficiente o constante reescalado de la variable m

$\bar{X}_m|_g$: es el promedio de la variable m en el grupo g

Ahora para obtener las K_0 es necesario que en la ecuación anterior se sustituyan los promedios de cada uno de los grupos de las variables discriminantes, es decir, de X_1 y de X_2 .

En el ejemplo, en el grupo 1, la media de X_1 es: $\bar{X}_1|_1 = 0.304$ y que el promedio de X_2 es: $\bar{X}_2|_1 = 4.604$ entonces al sustituir en Z promedio se tiene:

$$\bar{Z}|_1 = 10.308 \bar{X}_1|_1 + 0.532 \bar{X}_2|_1 = 10.308(0.304) + 0.532(4.604) = 5.578$$

Ahora en el grupo 2, el promedio de X_1 es: $\bar{X}_1|_2 = 0.035$ y la media de X_2 es: $\bar{X}_2|_2 = 1.644$; de nuevo al sustituir en Z promedio se tiene:

$$\bar{Z}|_2 = 10.308 \bar{X}_1|_2 + 0.532 \bar{X}_2|_2 = 10.308(0.035) + 0.532(1.644) = 1.235$$

La fórmula para encontrar K_0 es:

Ecuación 5-18 Ecuación de la constante de la ecuación discriminante

$$K_0 = -\frac{n|_1 \bar{Z}|_1 + n|_2 \bar{Z}|_2}{n}$$

donde:

$n|_i$: es el tamaño de la muestra del grupo i

$\bar{Z}|_i$: es la Z promedio del grupo i

n : es el número de datos en el total de la muestra de 70%

por lo que al calcularla se tiene:

$$K_0 = -\frac{n|_1 \bar{Z}|_1 + n|_2 \bar{Z}|_2}{n} = -\frac{6(5.578) + 6(1.235)}{12} = -3.407$$

El valor encontrado se sustituye en la ecuación lineal discriminante, la cual es:

Ecuación 5-19 Ecuación lineal discriminante canónica de Fisher

$$Z = K_0 + K_1 X_1 + K_2 X_2 + \dots + K_m X_m$$

Como el ejemplo sólo tiene 2 variables, la ecuación discriminante final es:

$$Z = K_0 + K_1 X_1 + K_2 X_2 = -3.407 + 10.308 X_1 + 0.532 X_2$$

Esta ecuación es la que sirve para pronosticar los diferentes elementos de la muestra en los distintos grupos.

5.6.9 Contribución de las variables

Aquí se evalúa la importancia relativa que posee cada una de las variables independientes para discriminar y sirve para indicar cuál variable ayuda más en la discriminación o separación de los grupos que se tienen en la variable dependiente. Para obtenerlo hay dos métodos: el método de las F parciales y el método de los pesos discriminantes estandarizados; ambos se explican a continuación.

5.6.9.1 Método de las F parciales

Este método ya se explicó en el punto 5.6.6 “Prueba del modelo” de este capítulo y se basa en el análisis de cada una de las variables manteniendo constantes los efectos de las restantes; por ejemplo, si se analiza la variable X_1 entonces X_2 queda constante ya que no varía. La F de la X_1 se encontró de la siguiente manera:

$$F_{\text{parcial}_{CX_1}} = \frac{(1 - \Lambda_1)/(g - 1)}{\Lambda_1/(n - g)} = \frac{(1 - 0.222)/(2 - 1)}{0.222/(12 - 2)} = 35.104$$

La F de la X_2 se encontró de la misma forma y su valor es el siguiente:

$$F_{\text{parcial}_{CX_2}} = \frac{(1 - \Lambda_2)/(g - 1)}{\Lambda_2/(n - g)} = \frac{(1 - 0.338)/(2 - 1)}{0.338/(12 - 2)} = 19.582$$

Mientras una variable tenga mayor F es más importante para discriminar. Como recordará, en el punto 5.6.6 “Prueba del modelo” se probaron las variables y se corroboró que eran significativas;²⁸ al comparar ambos valores se tiene que 35.104 es mayor que 19.582, por lo que la variable *ingreso/inversión* tiene una mayor F que la variable *activo/pasivo* (X_2) por lo que se concluye que la mejor variable para discriminar es la X_1 , la de *ingreso/inversión*.

5.6.9.2 Método de los pesos discriminantes estandarizados

Con este método se puede encontrar la contribución que tiene cada variable en el modelo discriminante, esto se realiza al comparar los coeficientes de cada variable; sin embargo, se necesitan estandarizar dichos coeficientes pues las variables suelen estar medidas en unidades distintas, lo cual dificulta su comparación; una vez efectuado esto, se puede concluir que mientras mayor sea el peso discriminante más importante será la variable para discriminar.

Para jerarquizar las variables con base en su importancia para discriminar se considera exclusivamente la magnitud del peso, no su signo, pues el signo sólo refleja la relación de la variable positiva o negativa con el puntaje discriminante. Este método requiere que las variables independientes no presenten problemas de multicolinealidad y considera la interacción entre ellos.

La fórmula para estandarizar las constantes, es la siguiente:

Ecuación 5-20 Estandarización de las constantes del modelo

$$K_i^{std} = K_{R_i}(S_i) = K_{R_i} \sqrt{\frac{SS_i}{gl_i}}$$

donde:

K_i^{std} : es la K estandarizada de la variable i

K_{R_i} : es la K reescalada de la variable i

S_i : es la desviación estándar de la variable i , la cual puede ser calculada dentro de cada grupo o en total

²⁸ Es decir, las 2 variables sirven para discriminar, ya que en el punto 5.6.6 “Prueba del modelo” se rechazó la hipótesis nula para ambas.

Se encuentra definida por:

Ecuación 5-21 Desviación estándar de la variable i

$$S_i = \sqrt{\frac{SS_i}{gl_i}}$$

donde:

SS_i : es la suma de cuadrados de la variable i

gl_i : son los grados de libertad de la variable i

Las K estandarizadas usando la SS dentro de cada grupo.

Las sumas de cuadrados (SS) dentro de cada grupo fueron calculadas cuando se encontró la matriz W ; sin embargo, se recordará su obtención con lo siguiente:

$$\text{Suma de cuadrados de la } X_1|_{1,\dots,g} = SSX_1|_{1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_1^2 - n\bar{X}_1^2$$

Por lo que para la X_1 se tiene que:

$$SSX_1|_{1,2} = SSX_1|_1 = SSX_1|_2 = [0.613 - 6(0.304)^2] + [0.009 - 6(0.035)^2]$$

$$SSX_1|_{1,2} = SSX_1|_1 = SSX_1|_2 = [0.60] + [0.002] = 0.062$$

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_2|_{1,\dots,g} = SSX_2|_{1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_2^2 - n\bar{X}_2^2$$

$$SSX_2|_{1,2} = SSX_2|_1 = SSX_2|_2 = [138.49 - 6(4.604)^2] + [18.337 - 6(1.644)^2]$$

$$SSX_2|_{1,2} = SSX_2|_1 = SSX_2|_2 = [11.300] + [2.127] = 13.427$$

En el caso del problema presentado las constantes estandarizadas son las siguientes:

Para la variable *ingreso/inversión* (X_1):

$$K_{X_1}^{std} = K_{R_{X_1}}(S_{X_1}) = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}}$$

por lo que:

$$K_{X_1}^{std} = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}} = 10.308 \sqrt{\frac{0.062}{6+6-2}} = 0.809$$

Para la variable *activo/pasivo* (X_2):

$$K_{X_2}^{std} = K_{R_{X_2}}(S_{X_2}) = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}}$$

por lo que:

$$K_{X_2}^{std} = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}} = 0.532 \sqrt{\frac{13.427}{6+6-2}} = 0.616$$

Como el valor 0.809 es mayor que 0.616 se concluye que la variable *ingreso/inversión* es la mejor para discriminar o bien que dicha variable discrimina más que la de *activo/pasivo*.

Es importante recalcar que si alguna constante es negativa su K estandarizada va a dar negativa, pero el signo sólo indica la relación; para ver qué variable es la que ayuda más a discriminar los grupos se deben obtener los valores absolutos de las K estandarizadas.

Ahora bien para saber cuánto aporta cada una de ellas a explicar la discriminación en los grupos se suman y se calcula el porcentaje basándose en dicha suma, el procedimiento se agrega en la siguiente tabla:

	K std de $SS_{1,2}$	Fracción	%
$X_1 =$	0.809	0.568	56.8
$X_2 =$	0.616	0.432	43.2
Total =	1.426	1	100

Primero se sumaron las K estandarizadas de ambas variables, posteriormente se dividió 0.809/1.426, lo que dio como resultado 0.568, dicho valor se multiplica por 100. Para la segunda variable se realizó el mismo procedimiento.

- Las K estandarizadas usando SS total.

La otra opción para encontrar la contribución de cada variable para discriminar es multiplicar cada peso discriminante por la desviación estándar de la muestra total de esa variable a estandarizar.

Para conocer la desviación estándar es necesario encontrar las sumas de cuadrados (SS) totales, las cuales ya fueron calculadas anteriormente cuando se encontró la matriz T ; sin embargo, se recordará el proceso.

$$\text{Suma de cuadrados de la } X_1 = SSX_1 = \sum_{i=1}^n X_1^2 - n\bar{X}_1^2$$

por lo que para la X_1 se tiene que:

$$SSX_1 = [0.062 - 12(0.169)^2] = 0.278$$

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_2 = SSX_2 = \sum_{i=1}^n X_2^2 - n\bar{X}_2^2$$

$$SSX_2 = [156.827 - 12(3.124)^2] = 39.721$$

En el caso del problema presentado, las constantes estandarizadas son las siguientes:

Para la variable *ingreso/inversión* (X_1):

$$K_{X_1}^{std} = K_{R_{X_1}}(S_{X_1}) = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}}$$

por lo que:

$$K_{X_1}^{std} = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}} = 10.308 \sqrt{\frac{0.278}{12-1}} = 1.638$$

Para la variable activo/pasivo (X_2):

$$K_{X_2}^{std} = K_{R_{X_2}}(S_{X_2}) = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}}$$

por lo que:

$$K_{X_2}^{std} = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{g_{X_2}^l}} = 0.532 \sqrt{\frac{39.721}{12-1}} = 1.011$$

Como el valor 1.638 es mayor que 1.011 se concluye que la variable *ingreso/inversión* es la mejor para discriminar o bien que dicha variable discrimina más que la de *activo/pasivo*.

De nuevo, si alguna constante es negativa su K estandarizada dará negativa, pero el signo sólo indica la relación; para saber qué variable ayuda más a discriminar los grupos se deben obtener los valores absolutos de las K estandarizadas.

Para saber cuánto aporta cada una de ellas al explicar la discriminación en los grupos, se suman y se calcula el porcentaje basándose en dicha suma; el procedimiento se agrega en la siguiente tabla:

	K std de SS Total	Fracción	%
$X_1 =$	1.638	0.618	61.8
$X_2 =$	1.011	0.382	38.2
Total =	2.649	1	100

Primero se sumaron las K estandarizadas de ambas variables, posteriormente se dividió 1.638/1.011, lo que dio como resultado 0.618, dicho valor se multiplica por 100. Para la segunda variable se realizó el mismo procedimiento.

Aunque los 2 métodos presentan valores numéricos diferentes, el resultado fue el mismo en ambos; se puede concluir que la variable que mejor discrimina o diferencia a un grupo de otro es la X_1 (*ingreso/inversión*) por su mayor K estandarizada.

5.6.10 Valoración predictiva del modelo

Valoración predictiva del modelo. Verificación del grado de error para efectuar pronósticos.

En la **valoración predictiva del modelo** se verifica el grado de error para efectuar pronósticos; otra de las bondades de una función discriminante es su capacidad para clasificar nuevos casos, es decir, estimar nuevos elementos para saber en qué grupo sería pronosticado.

Es importante dejar claro que si el modelo no es bueno para discriminar (conclusión a la que se llega por medio de las pruebas de hipótesis, es decir, cuando no se rechaza la hipótesis nula), entonces no tiene caso validar el modelo.

Por el contrario si se ha concluido que el modelo discriminante es bueno para segmentar (conclusión a la que se llega por medio de las pruebas de hipótesis, es decir, cuando sí se rechaza la hipótesis nula), se realiza la validación del mismo, que consiste en determinar el error que se tendrá al pronosticar con el modelo. Como en el ejemplo se concluyó que el modelo es bueno para segmentar se continúa con el análisis.

La función discriminante se utiliza para clasificar los casos que se separaron del proceso de derivación, esto permitirá comprobar el grado de eficacia de la función y obtener un indicador que evalúe lo acertado que es el modelo para clasificar como medio para obtener una medida de la confiabilidad al pronosticar. Dicha medida se llama **porcentaje de clasificaciones correctas**, que al ser mayor que el mínimo requerido dará como resultado un modelo bueno para pronosticar. Antes de explicar a detalle lo anterior, se describirá de manera breve lo que implica geométricamente haber realizado la combinación lineal de las variables y obtener así la ecuación discriminante.

Por lo anterior, es necesario visualizar los grupos con las 2 variables; es decir, en el eje de las abscisas²⁹ se graficará la variable X_1 , y en el eje de las ordenadas³⁰ se graficará la variable X_2 ; los datos de 70% se representan en la siguiente figura:

Porcentaje de clasificaciones correctas. Indicador que evalúa lo acertado que es el modelo para clasificar como medio para obtener una medida de la confiabilidad al pronosticar.

²⁹ Es la coordenada horizontal en el plano cartesiano y generalmente se representa por X y se le denomina *eje X*.

³⁰ Es la coordenada vertical en el plano cartesiano y se le denomina *eje Y*.




Figura 5-6 Ambos grupos.

Como se puede observar en la figura anterior se encuentran bien diferenciados los grupos, pues no existen elementos mezclados entre ellos y no se encuentra la variable Y pero está implícita. Ahora a la figura anterior se le agregarán los promedios de los grupos, lo cual se representa en la siguiente figura:




Figura 5-7 Promedios de los grupos.

En la figura anterior se puede ver que la variable X_1 diferencia o separa más a los grupos que la X_2 . A continuación se trazarán unas líneas que partirán de los promedios de los 2 grupos hacia un tercer eje, que se denominará *eje Z*; lo anterior se muestra a continuación:




Figura 5-8 Proyecciones de los promedios de los grupos.

Las proyecciones de los datos se reflejan gráficamente en el eje de las Z y tienen una forma normal.³¹ Aquí se observan las opiniones de los grupos que forman la variable dependiente, lo cual se presenta en la siguiente figura.




Figura 5-9 Proyecciones de las opiniones en el eje Z .

En esta figura la variable X_2 no discrimina tan bien como la X_1 . Esto se ve porque hay mayor diferencia entre los promedios de las X . En el análisis discriminante precisamente se trata de encontrar a las variables que mejor diferencien.

Ahora al separar el eje Z de los demás ejes se tendrían 2 curvas normales, una para cada grupo, lo cual fue puesto en la siguiente gráfica:




Figura 5-10 Eje Z .

El eje Z ayuda a decidir en qué zona se encuentra un elemento que se desee pronosticar. En las curvas normales los cruces o traslapes de las opiniones representan la zona en donde posiblemente al momento de pronosticar se caiga en un error; esa zona de traslape se muestra a continuación en color negro:




Figura 5-11 Zona de traslape.

³¹ Recuerde que uno de los supuestos de las variables independientes es que deben provenir de poblaciones normales.

Por esto es necesario que se establezca una línea divisoria entre las curvas normales. Al valor que marcará el punto de la línea divisoria se le llama: *Z-crítica*, la cual se muestra a continuación:




Figura 5-12 Z-crítica.

El objetivo es que los 2 extremos o las colas de las 2 curvas se crucen lo menos posible y así lograr una separación entre los promedios de los grupos, por lo que el área de traslape entre las curvas representa la probabilidad de error al pronosticar, es decir, son los datos clasificados incorrectamente.

Por último es importante señalar que en esta parte las curvas son casi idénticas pero es posible que los grupos sean unos más o menos dispersos y de diferente tamaño y además puede que se encuentren muy juntas o muy separadas, lo cual depende de qué tanto logren separar las variables discriminantes a los grupos.

5.6.10.1 Pasos para la etapa de validación

A continuación se presenta en forma detallada el procedimiento que se sigue para validar el modelo discriminante:

1. Obtener la Z promedio para cada grupo.
2. Calcular la Z-crítica.
3. Buscar el puntaje discriminante para cada observación y asignación a un grupo.
4. Realizar la matriz de clasificaciones o de confusión.
5. Calcular el porcentaje de clasificaciones correctas.
6. Comparar el porcentaje de clasificaciones correctas con el mínimo.
7. Verificar estadísticamente la relación entre la predicción y la clasificación real.

De acuerdo con el problema anterior se aplicará el procedimiento de validación para que quede más claro. Los casos no seleccionados en la etapa de derivación son los siguientes:

Tabla 5-9 Datos para validar

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
1	Sana	1	0.345	4.817
10	Quiebra	2	0.001	1.987
12	Sana	1	0.039	1.275
16	Quiebra	2	0.0043	1.053

Para validar la información se empezará con los siete pasos que se mencionaron antes.

Paso 1. Obtener las Z promedio

Se logra al sustituir en la ecuación discriminante los promedios de las variables independientes utilizados para la etapa de derivación para cada grupo. Una vez que se obtienen las Z promedio, se acomodan en orden de izquierda a derecha, del más negativo al más positivo, con el fin de proyectarlos en el eje Z. La fórmula para obtener las Z promedio se explicó en el reescalamiento de los coeficientes y en el proceso de la obtención de la constante, es decir de K_0 ; la ecuación es la siguiente:

Ecuación 5-22 Ecuación de las Z promedio

$$\bar{Z}|_g = K_0 + K_1 \bar{X}_1|_g + K_2 \bar{X}_2|_g + \dots + K_m \bar{X}_m|_g$$

donde:

$\bar{Z}|_g$: es la Z promedio del grupo g

K_0 : es la constante de la función

K_m : es el coeficiente o constante reescalado de la variable m

$\bar{X}_m|_g$: es el promedio de la variable m en el grupo g

Z promedio del grupo 1 ($\bar{Z}|_1$) (empresas sanas), se realiza de la siguiente manera:

$$\bar{Z}|_1 = K_0 + K_1 \bar{X}_1|_1 + K_2 \bar{X}_2|_1 = -3.407 + 10.308 \bar{X}_1|_1 + 0.532 \bar{X}_2|_1$$

donde los promedios del grupo 1 son los siguientes:

$$\bar{Z}|_1 = -3.407 + 10.308(0.304) + 0.532(4.604) = 2.171$$

Ahora, las Z promedio del grupo 2 ($\bar{Z}|_2$) (empresas en quiebra):

$$\bar{Z}|_2 = K_0 + K_1 \bar{X}_1|_2 + K_2 \bar{X}_2|_2 = -3.407 + 10.308 \bar{X}_1|_2 + 0.532 \bar{X}_2|_2$$

donde los promedios del grupo 2 son los siguientes:

$$\bar{Z}|_2 = -3.407 + 10.308(0.035) + 0.532(1.644) = -2.171$$

Es importante recalcar que las medias de cada grupo son con los 12 casos utilizados en la etapa de derivación.

Paso 2. Calcular la Z-crítica

Como se indicó, la Z-crítica sirve como frontera en el eje Z para dividir a los grupos que se tienen en la variable dependiente. Si $n|_1 = n|_2$, es decir, el número de datos en los 2 grupos es el mismo, la fórmula para obtener la Z-crítica es:

Ecuación 5-23 Z-crítica para grupos de tamaño igual

$$Z_c = \frac{(\bar{Z}|_1 + \bar{Z}|_2)}{2}$$

Si $n|_1 \neq n|_2$, es decir, el número de datos en los 2 grupos es diferente, la fórmula ahora sería de un promedio ponderado:

Ecuación 5-24 Z-crítica para grupos de tamaño diferente

$$Z_c = \frac{(n|_1 \bar{Z}|_1 + n|_2 \bar{Z}|_2)}{(n|_1 + n|_2)}$$

donde:

$\bar{Z}|_g$: es la Z promedio del grupo g

$n|_g$: es el número de datos en el grupo g

Z_c : es la Z -crítica

Ahora se busca la Z -crítica (que es la línea divisoria); se sabe que $n|_1 = n|_2$, por lo que la Z -crítica queda de la siguiente manera:

$$Z_c = \frac{(\bar{Z}|_1 + \bar{Z}|_2)}{2} = \frac{(2.171 - 2.171)}{2} = 0$$

Pero si se hubiera tenido que $n|_1 \neq n|_2$, la Z -crítica debía calcularse de la siguiente manera:

$$Z_c = \frac{(n|_1 \bar{Z}|_1 + n|_2 \bar{Z}|_2)}{(n|_1 + n|_2)} = \frac{6(2.171) + 6(-2.171)}{6 + 6} = 0$$

Entonces, la Z -crítica en el eje Z quedaría de la siguiente manera:




Figura 5-13 Z -crítica del ejemplo.

Esto significa que las posibles combinaciones de las variables utilizadas que den una Z menor que 0 implicará que la empresa se pronostique en quiebra, es decir, en el grupo 2; mientras que si es mayor que 0 serán clasificadas o pronosticadas como empresas sanas, esto debido a que se encuentra en el grupo 1.

Paso 3. Buscar el puntaje discriminante para cada observación y asignación a un grupo

Para obtener los puntajes es necesario utilizar los datos que se dejaron para la etapa de validación, que representan 30% restante, y se pronostica en cuál grupo cae cada una de las observaciones de acuerdo con la Z -calculada para cada empresa, se compara con la Z -crítica.

El valor de la Z calculada de cada observación, también denominado *puntaje discriminante* (en este caso para cada empresa utilizada en la etapa de validación) se obtiene al sustituir en la ecuación discriminante los valores originales de cada empresa en cada variable independiente; por ejemplo, para la empresa 1, cuyos valores son:

Tabla 5-10 Datos de la empresa 1

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
1	Sana	1	0.345	4.817

Para obtener el valor de la Z para la empresa 1 es necesario tener la ecuación lineal discriminante de Fisher, la cual se obtuvo anteriormente y es la siguiente:

$$Z = K_0 + K_1X_1 + K_2X_2 = -3.407 + 10.308X_1 + 0.532X_2$$

Al sustituir en la ecuación los valores de la empresa 1 se tiene:

$$Z_1 = -3.407 + 10.308(0.345) + 0.523(4.817) = 2.712$$

Dicho valor se compara con la Z crítica en el eje Z , lo cual se tiene en la siguiente figura:




Figura 5-14 Puntaje de la empresa 1.

Al concluir se tiene que la empresa 1 fue estimada en el grupo 1; lo mismo se realiza para cada una de las observaciones que se dejaron para la etapa de validación, éstas corresponden a 30% que se separó de la muestra al principio del estudio. Los resultados para los elementos fueron los siguientes:

Tabla 5-11 Datos de las empresas (30%)

Empresas	Resultado	Grupo real	X_1	X_2	Z o puntaje
			$R_{I,I}$	$R_{A,P}$	
1	Sana	1	0.345	4.817	2.712
10	Quiebra	2	0.001	1.987	-2.339
12	Sana	1	0.039	1.275	-2.326
16	Quiebra	2	0.0043	1.053	-2.802

Al comparar los valores en la figura del eje Z se tiene lo siguiente:




Figura 5-15 Puntaje de las empresas.

En resumen de los 4 casos, la empresa 1 se encuentra en el grupo 1 y se pronosticó en el mismo grupo, por lo que la clasificación fue correcta; la compañía 10 se encuentra en el grupo 2 y se estimó en el mismo grupo, por lo que el pronóstico fue correcto; la empresa 12 está en el grupo 1 y se clasificó en el 2, por lo que dicha empresa se clasificó en forma incorrecta y, por último, la empresa

16 forma parte del grupo 2 y se pronosticó en ese mismo grupo, por lo que la asignación fue correcta. De los 4 casos, sólo uno se clasificó de forma incorrecta. Todo lo anterior se representa en la siguiente tabla:

Tabla 5-12 Resumen

Empresas	Resultado	Grupo real	Z o puntaje	Grupo pronosticado	Clasificación	Clasificación	Clasificación
1	Sana	1	2.712	1	Correcta	✓	↶
10	Quiebra	2	-2.339	2	Correcta	✓	↶
12	Sana	1	-2.326	2	Incorrecta	✗	↷
16	Quiebra	2	-2.802	2	Correcta	✓	↶

Paso 4. Matriz de clasificación o confusión

La **matriz de clasificación o confusión** se utiliza a manera de resumen y en ella se presentan los datos reales contra los pronosticados; se basa en el conteo de lo que fue correcto o incorrectamente clasificado, como a continuación se muestra.

Matriz de clasificación o confusión. Presentan los datos reales contra los pronosticados y se basa en el conteo de lo correcta e incorrectamente clasificado.

Tabla 5-13 Posibilidades en la matriz de clasificación

			Grupo pronosticado	
			1	2
			Empresa sana	Empresa en quiebra
Grupo real	1	Empresa sana		
	2	Empresa en quiebra		

En seguida se contabiliza cada una de las empresas según su clasificación; por ejemplo, la empresa 1 se encuentra en el grupo 1 y se clasificó en el mismo grupo, se tiene entonces que escoger en el grupo real, es decir, en el renglón 1 de empresa sana; en el pronosticado también se selecciona la columna 1, que es nuevamente empresa sana, por lo que esto hace que la tabla ahora tenga el primer elemento, de la siguiente manera:

Tabla 5-14 Empresa 1

			Grupo pronosticado	
			1	2
			Empresa sana	Empresa en quiebra
Grupo real	1	Empresa sana	1	
	2	Empresa en quiebra		

La segunda empresa, la 10, pertenece al grupo 2 y se pronosticó en el mismo grupo, por lo que los resultados de la matriz serían los siguientes:

Tabla 5-15 Empresas 1 y 10

			Grupo pronosticado	
			1	2
			Empresa sana	Empresa en quiebra
Grupo real	1	Empresa sana	1	
	2	Empresa en quiebra		1

La empresa en turno sería la 12, la cual pertenece al grupo de las sanas, es decir al 1, y se pronosticó en el grupo de empresas en quiebra, por lo que se escoge el renglón de empresas sanas y la columna de empresas en quiebra; la matriz cambiaría de la siguiente manera:

Tabla 5-16 Empresas 1, 10 y 12

			Grupo pronosticado	
			1	2
			Empresa sana	Empresa en quiebra
Grupo real	1	Empresa sana	1	1
	2	Empresa en quiebra		1

Por último tenemos la empresa 16 que está en el grupo de las empresas en quiebra y se pronosticó en el mismo, por lo que finalmente se tiene la matriz de clasificaciones completa. Se recomienda asignar un cero a las casillas que hayan quedado sin elementos. La matriz quedaría entonces de la siguiente manera:

Tabla 5-17 Empresas 1, 10, 12 y 16

			Grupo pronosticado	
			1	2
			Empresa sana	Empresa en quiebra
Grupo real	1	Empresa sana	1	1
	2	Empresa en quiebra	0	2

La diagonal de esta matriz está formada por las clasificaciones adecuadas hechas por el modelo, es decir, son aquellos casos que fueron clasificados en forma correcta.

Paso 5. Porcentaje de clasificaciones correctas

Porcentaje de clasificaciones correctas. Medida de la confiabilidad o seguridad al pronosticar.

El **porcentaje de clasificaciones correctas**, que es una medida de la confiabilidad o seguridad al pronosticar, se obtiene de la suma de la diagonal de la matriz de clasificación entre el número total de datos utilizados en la etapa de validación,³² por 100, pues es un porcentaje.

Ecuación 5-25 Porcentaje de clasificaciones correctas

$$\%C_C = \frac{\sum ECC}{\sum n|_g} 100 = \frac{\sum \text{diagonal principal}}{n|_1 + n|_2 + \dots + n|_g} 100$$

donde:

$\%C_C$: es el porcentaje de clasificaciones correctas

$\sum ECC$: es la suma de los elementos correctamente clasificados³³

$\sum n|_g$: es la suma de los datos de cada uno de los grupos de la etapa de validación

³² El SPSS™ asigna 2 porcentajes, ya que encuentra los puntajes para 100% de los datos y acomoda la información en 2 matrices, obteniendo también 2 porcentajes que calcula con el número de datos de cada etapa, es decir, para los datos de derivación calcula el porcentaje con el número de datos de 70% escogido y saca el porcentaje de los datos de validación con 30% de los datos restantes.

³³ Los elementos correctamente clasificados siempre se encuentran en la diagonal principal de la matriz de clasificaciones correctas o matriz de confusión.

Por lo que el porcentaje de clasificaciones correctas sería:

$$\%C_c = \frac{\sum ECC}{n|_1 + n|_2} = \frac{1+2}{2+2} 100 = 75\%$$

En este caso, el porcentaje de clasificaciones correctas es 75%, por lo que se tendría 75% de seguridad para hacer algún pronóstico correcto.

Paso 6. Comparar el porcentaje de clasificaciones correctas *versus* el mínimo

En este paso se encontrará el porcentaje de clasificaciones mínimas aceptables, el cual indicaría lo mínimo que tolera el modelo y se calcula de la siguiente manera:

Ecuación 5-26 Porcentaje de clasificaciones mínimas

$$\%C_M = \left[\left(\frac{n|_1}{n} \right)^2 + \left(\frac{n|_2}{n} \right)^2 + \dots + \left(\frac{n|_g}{n} \right)^2 \right] * 100$$

donde:

$\%C_M$: es el porcentaje de clasificaciones mínimas aceptables

$\sum n|_g$: es el total de datos en el grupo g

n : es el total de datos en la etapa de validación o bien puede ponerse como $\sum n|_g$, lo cual sería la suma de todos los elementos en los grupos

Para seguir con el ejemplo:

Tabla 5-18 Totales de los grupos reales

			Grupo pronosticado		Total
			1	2	
			Empresa sana	Empresa en quiebra	
Grupo real	1	Empresa sana	1	1	2
	2	Empresa en quiebra	0	2	2
Total					4

Por lo que el porcentaje se calcularía de la siguiente manera:

$$\%C_M = \left[\left(\frac{n|_1}{n} \right)^2 + \left(\frac{n|_2}{n} \right)^2 \right] * 100 = \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] * 100 = 50\%$$

Dicho porcentaje sirve para compararse con el porcentaje de clasificaciones correctas por medio de una prueba de hipótesis, la cual se presenta a continuación:

$H_0 : \pi_{C_c} = \pi_{C_M}$: la proporción de clasificaciones correctas es igual a la proporción de clasificaciones mínimas

$H_a : \pi_{C_c} > \pi_{C_M}$: la proporción de clasificaciones correctas es mayor que la proporción de clasificaciones mínimas

En esta parte no interesa que el porcentaje de clasificaciones correctas sea menor que el mínimo, ya que se desea que sea mayor, esto con el fin de poder pronosticar mejor; esto último indicaría que si en algún análisis el $\%C_c < \%C_M$ no se realizaría esta prueba.

Para realizar la prueba de hipótesis es necesario encontrar el estadístico calculado, el cual sería el siguiente:

Fórmula 5-27 Estadístico calculado para 2 proporciones

$$Z_C = \frac{(\bar{P}_{C_C} - \bar{P}_{C_M}) - (\pi_{C_C} - \pi_{C_M})H_0}{\sqrt{\hat{P}(1-\hat{P})\left(\frac{1}{n_{C_C}} + \frac{1}{n_{C_M}}\right)}}$$

donde:

$$\hat{P} = \frac{n_{C_C}\bar{P}_{C_C} + n_{C_M}\bar{P}_{C_M}}{n_{C_C} + n_{C_M}}$$


por lo que $\hat{P}$ sería encontrada de la siguiente manera:

$$\hat{P} = \frac{4(0.75) + 4(0.50)}{4 + 4} = 0.625$$

donde la Z_C sería:

$$Z_C = \frac{(0.75 - 0.50) - (0)}{\sqrt{0.625(1 - 0.625)\left(\frac{1}{4} + \frac{1}{4}\right)}} = 0.730$$

Ahora es necesario encontrar el estadístico teórico (Z_t); el análisis se realiza con 95% de confianza, por lo que la Z_t se debe encontrar de la siguiente manera: utilizar 95% de confianza indica que en la tabla acumulada se debe encontrar 0.95, el cual está entre 0.9495 y 0.9505, esto se muestra en la siguiente tabla:

Tabla 5-19 Tabla Z

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767

Ahora se puede ver que el valor de Z_t es 1.6 y al subir por ambas columnas se ven los valores 0.04 y 0.05, que deben sumarse al 1.64, lo cual da:

$$Z_t = \frac{(1.6 + 0.04) + (1.6 + 0.05)}{2} = 1.645$$

A continuación, el estadístico calculado (Z_C) se compara con el teórico (Z_t), sabiendo que:

$$Z_C > Z_t \text{ se rechaza la } H_0$$

Por lo que:

$$0.730 < 1.645$$

Es por ello que se acepta la H_0 y se concluye entonces que ambos porcentajes son iguales, de ahí que dé lo mismo utilizar la fórmula de discriminante que lanzar una moneda, es decir, se tiene 50% de probabilidades de obtener un grupo o el otro, por lo que resulta lo mismo que pronosticar con la ecuación discriminante a cualquiera de los 2 grupos; por supuesto es más fácil pronosticar con una moneda.

Paso 7. Verificar estadísticamente la predicción y la clasificación real

La relación entre la clasificación de la predicción o el pronóstico y la condición real se deberá verificar estadísticamente, esto puede llevarse a cabo por medio de una prueba de hipótesis; para hacerlo es necesario que la matriz de confusión se convierta en una tabla cruzada y el problema se trabaja como una prueba de independencia estadística en la que las hipótesis establecen lo siguiente:

H_0 : es la relación entre lo predicho y lo real no existe, es decir son independientes, por lo que no hay evidencia de que esta discriminación sea la correcta.

H_a : es la relación entre lo predicho y lo real si existe, es decir, son dependientes, por lo que si hay evidencia de discriminación, entonces es la correcta, lo que indicaría que sí se logra discriminar.

Es necesario aclarar que, como en el paso que se acaba de explicar no se encontró diferencia estadística en los porcentajes, no es necesario realizar este paso para el ejemplo, pero se hará con el fin de explicar todo el análisis que se debe realizar en la técnica de análisis de discriminante.

Como la matriz de clasificaciones correctas es una tabla de 2×2 , para poder aplicar la ji cuadrada a dicha tabla es necesario usar la fórmula de corrección por continuidad de Yates:

Ecuación 5-28 Ji cuadrada calculada con corrección de Yates

$$\chi^2_c = \sum \frac{(|fo_{ij} - fe_{ij}| - 0.5)^2}{fe_{ij}}$$

donde:

fo_{ij} : es la frecuencia observada del renglón i con la columna j de la matriz de clasificaciones

fe_{ij} : es la frecuencia esperada del renglón i con la columna j de la matriz de confusión

Pero si no hubiera sido una tabla de 2×2 su fórmula sería:

Ecuación 5-29 Ji cuadrada calculada de Pearson

$$\chi^2_c = \sum \frac{(fo_{ij} - fe_{ij})^2}{fe_{ij}}$$

Se calculan las frecuencias esperadas de la matriz de confusión; ésta se pone a continuación:

Tabla 5-20 Totales de los grupos

			Grupo pronosticado		Total
			1	2	
			Empresa sana	Empresa en quiebra	
Grupo real	1	Empresa sana	1	1	2
	2	Empresa en quiebra	0	2	2
	Total		1	3	4

Se busca la frecuencia esperada con la siguiente fórmula:

Ecuación 5-30 Frecuencia esperada

$$fe_{ij} = \frac{\text{Total de renglón} * \text{Total de columna}}{\text{Total de datos en la muestra}}$$

La frecuencia esperada de la primera casilla, es decir, de renglón 1 con la columna 1, se calcula con los totales del renglón y de la columna, por lo que:

$$fe_{1,1} = \frac{1*2}{4} = 0.5$$

La frecuencia esperada de la segunda casilla, renglón 2 columna 1, es:

$$fe_{2,1} = \frac{1*2}{4} = 0.5$$

La frecuencia esperada de la tercera casilla es:

$$fe_{1,2} = \frac{3*2}{4} = 1.5$$

La frecuencia esperada de la cuarta casilla es:

$$fe_{2,2} = \frac{3*2}{4} = 1.5$$

El resultado se acomodó en la siguiente tabla:

Tabla 5-21 Frecuencia esperada y observada

		Grupo pronosticado		
		1	2	
		Empresa sana	Empresa en quiebra	
1	Empresa sana	1, 0.5	1, 1.5	2
2	Empresa en quiebra	0, 0.5	1, 1.5	2
Total		1	3	4

Encontrar la ji cuadrada calculada con la corrección por continuidad de Yates; se hace de la siguiente manera:

$$\chi_c^2 = \frac{(|1 - 0.5| - 0.5)^2}{0.5} + \frac{(|0 - 0.5| - 0.5)^2}{0.5} + \frac{(|1 - 1.5| - 0.5)^2}{1.5} + \frac{(|1 - 1.5| - 0.5)^2}{1.5}$$

Dando como resultado:


$$\chi^2_c = 0.000$$

Como en el ejemplo se está utilizando 5% como nivel de significancia, el estadístico teórico sería:

$$\chi^2_{t, \alpha = 0.05, (\# \text{ de renglones} - 1)(\# \text{ de columnas} - 1) = (2 - 1)(2 - 1) = 1} = 5.991$$

El cual se encontró de la siguiente manera:

Tabla 5-22 Tabla ji cuadrada³⁴



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264


Para rechazar la H_0 es necesario que:

$$\chi^2_c > \chi^2_{t, \alpha, (k-j)(g-j-1)}$$

por lo que:

$$0.000 < 3.841 \text{ no se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



³⁴ Ver anexo 3.1, tabla ji cuadrada.

Por lo tanto se acepta H_0 y se concluye que el porcentaje de clasificaciones correctas evidencia una buena clasificación. Es importante aclarar que la muestra que se maneja es muy reducida, por lo que no tiene la validez correspondiente.

Como no se rechazó la hipótesis nula, no es necesario realizar el siguiente procedimiento pero se explicará para su aplicación en análisis posteriores. Esta parte del proceso sirve para saber cuál casilla presenta diferencias significativas para así saber cuál de ellas evidencia una buena clasificación; esto se hace al analizar las celdas de la matriz a través de los residuales estandarizados, los cuales se obtienen con la siguiente fórmula:

Ecuación 5-31 Estandarización de las frecuencias

$$Z_{ij} = \frac{fo_{ij} - fe_{ij}}{\sqrt{fe_{ij}}}$$

Así se tiene que en la casilla 1, es decir, renglón 1 y columna 1:

$$Z_{11} = \frac{1 - 0.5}{\sqrt{0.5}} = 0.707$$

Ahora el renglón 2 y columna 1:

$$Z_{21} = \frac{0 - 0.5}{\sqrt{0.5}} = -0.707$$

Le sigue el renglón 1 y columna 2:

$$Z_{12} = \frac{1 - 1.5}{\sqrt{1.5}} = -0.408$$

Y por último el renglón 2 columna 2


$$Z_{22} = \frac{2 - 1.5}{\sqrt{1.5}} = 0.408$$

Dichos valores se tendrían que comparar con el estadístico Z de tablas o teórico, recuérdese que el nivel de confianza que se utiliza en el ejemplo es 95%, por lo que se tendría:

$$\frac{0.95}{2} = 0.475$$

Al buscar ese valor en la tabla de la Z se tiene que:

Tabla 5-23 Tabla normal estándar



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.5	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545

(continúa)

Tabla 5-23 Tabla normal estándar (continuación)

Z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.7	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
← 2.0	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.1	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.2	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.3	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.4	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936

Al sumar el 1.9 y el 0.06 dan como resultado 1.96 y, puesto que ninguno de los valores que se calcularon supera el ± 1.96 , se concluye que las predicciones son aleatorias, independientemente del grupo al que realmente las empresas pueden pertenecer.

Es importante aclarar que con este ejemplo se tiene una cantidad muy pequeña de datos (4), por lo tanto hay muy poca validez en la conclusión obtenida. Una muestra grande daría sustento a la conclusión; sin embargo, se puede observar cómo los valores de Z son positivos sobre la diagonal principal (casillas 11 y 22), que habla de observar más datos en éstas que fuera de la diagonal, lo cual es bueno ya que es ahí donde se darán las clasificaciones correctas.

5.6.11 Interpretación de los resultados y estrategias

Lo que se pretendería como estrategia es tratar de actuar sobre la variable dependiente, manejando a las independientes (*ingreso/inversión* y *activo/pasivo*). Para recordar, la ecuación discriminante es la siguiente:

$$Z = -3.407 + 10.308X_1 + 0.532X_2$$

En este caso, se sabe que la variable X_1 es la que ayuda más³⁵ a discriminar a los grupos; al ver la ecuación se tiene que si la X_1 (*ingreso/inversión*) aumenta, se incrementará a su vez el valor de la Z , ya que dicha variable tiene un signo positivo. Al analizar esto, en realidad ¿qué es lo que se desea: ser una empresa sana o una en quiebra? Generalmente se desea ser empresa sana, por lo que es necesario que las empresas pertenezcan al grupo 1; entonces se buscaría aumentar los valores de las Z para hacer que las empresas en quiebra sean sanas o rentables; para que esto suceda, las empresas deben tener mayores ingresos con la inversión realizada. Esto se puede ver mejor en el eje Z , el cual se muestra a continuación:




Figura 5-16 Empresa en quiebra o sana.

³⁵ Esto se sabe por medio de las F parciales y las K estandarizadas.

De las 2 variables, la primera que se debe atender es la de *ingreso/inversión*, ya que tiene una mayor importancia para discriminar entre los grupos, después podría hacerse alguna estrategia en cuanto a *activo/pasivo*, pero ya en un segundo plano de importancia y de igual manera por su relación directa con Z (signo positivo), una empresa sana deberá tener más activos con una cantidad fija de pasivos.

5.7 Análisis discriminante múltiple

El análisis discriminante múltiple se diferencia del análisis discriminante simple porque maneja más de 2 grupos en la variable dependiente, por lo que utilizar 3 o más grupos correspondería al discriminante múltiple. Esto permite obtener más de 1 ecuación o función discriminante, por lo que el número de funciones que se generan dependerá de lo siguiente:

Si se tienen m variables independientes y g grupos en la variable dependiente, el número de funciones a generar serán:

$$\text{Mín}\{(g-1)(m)\}$$

Lo anterior indica que la cantidad de funciones debe ser el número más pequeño que salga del número de grupos menos 1 ($g - 1$) y del número de variables independientes (m); por ejemplo: supóngase que se tienen 5 grupos y 6 variables independientes, lo que da como resultado:

$$g - 1 = 5 - 1 = 4 \text{ y que } m = 6$$

Por lo que el menor de los 2 números es 4, esto indicaría que se calcularán 4 ecuaciones discriminantes.

Para ejemplificar el análisis discriminante múltiple se usará el mismo estudio que se utilizó en el simple, sólo que se le agregará un grupo y quedaría así:

1. Empresas sanas.
2. Empresas en quiebra.
3. Empresas con problemas financieros.

A continuación se presentan todos los datos.

Tabla 5-24 Datos del ejemplo

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
1	Sana	1	0.345	4.81753
2	Sana	1	0.243	3.9947
3	Quiebra	2	0.05	2.778
4	Sana	1	0.378	4.0362
5	Quiebra	2	0.04	1.256
6	Quiebra	2	0.05	1.377
7	Sana	1	0.18	4.87
8	Quiebra	2	0.04	1.143
9	Sana	1	0.22	3.635
10	Quiebra	2	0.001	1.98733
11	Sana	1	0.47	3.567

(continúa)

Tabla 5-24 Datos del ejemplo (*continuación*)

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
12	Sana	1	0.039	1.27538
13	Quiebra	2	0	1.225
14	Sana	1	0.33	7.523
15	Quiebra	2	0.03	2.083
16	Quiebra	2	0.0043	1.05316
17	Problemas	3	0.187	2.054
18	Problemas	3	0.143	2.198
19	Problemas	3	0.115	2.043
20	Problemas	3	0.198	2.765
21	Problemas	3	0.106	2.098
22	Problemas	3	0.123	2.09
23	Problemas	3	0.178	2.761
24	Problemas	3	0.154	1.65

Recuerde X_1 es $R_{I,I}$ y es la razón de *inventario* entre *inversión* y la $R_{A,P}$ es razón del *activo circulante* entre *pasivo circulante* a la cual corresponde X_2 .

Se tienen 24 datos y cada grupo tiene 8 empresas, por lo que, nuevamente, sólo se tomó en cuenta 70% de los datos para derivar; esto es:

$$8 * 0.7 = 5.6 \cong 6$$

Es decir, se escogerán 6 empresas de cada grupo y se dejarán 2 para la etapa de validación; por lo que ahora se escogen de forma aleatoria los elementos que no se utilizarán en esta etapa; como ya se había hecho, aleatoriamente se eliminaron del modelo las empresas 1 y 12 del grupo 1, las empresas 10 y 16 del grupo 2 y ahora faltaría quitar 2 empresas del grupo 3, las cuales serían las compañías 23 y 24, que a su vez representan 30% de los datos que se utilizarán en la segunda etapa, la etapa de validación. De ahí que la información utilizada en la etapa de derivación y acomodada por grupo sería la siguiente:

Tabla 5-25 Datos para la etapa de derivación

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
2	Sana	1	0.243	3.9947
4	Sana	1	0.378	4.0362
7	Sana	1	0.18	4.87
9	Sana	1	0.22	3.635
11	Sana	1	0.47	3.567
14	Sana	1	0.33	7.523
3	Quiebra	2	0.05	2.778
5	Quiebra	2	0.04	1.256
6	Quiebra	2	0.05	1.377

(*continúa*)

Tabla 5-25 Datos para la etapa de derivación (continuación)

Empresas	Resultado	Grupo	X_1	X_2
			$R_{i,l}$	$R_{A,P}$
8	Quiebra	2	0.04	1.143
13	Quiebra	2	0	1.225
15	Quiebra	2	0.03	2.083
17	Problemas	3	0.187	2.054
18	Problemas	3	0.143	2.198
19	Problemas	3	0.115	2.043
20	Problemas	3	0.198	2.765
21	Problemas	3	0.106	2.098
22	Problemas	3	0.123	2.09

Ahora es necesario encontrar las 3 matrices, las cuales son: matriz total que se le llamó T , la matriz A que representa la diferencia de los datos al comparar un grupo contra otro y, por último, la matriz W que contabiliza lo distinto que son los datos dentro de cada grupo.

A continuación se explica cómo se obtienen las matrices mencionadas a partir de los datos escogidos para la etapa de derivación. Los datos del ejemplo se acomodarán por grupo, nuevamente sólo con 70% de éstos; los cuales se presentan a continuación con sus descriptivos:

Tabla 5-26 Datos acomodados por grupos y sus descriptivos

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{i,l}$	$R_{A,P}$			
2	1	0.243	3.994	0.059	15.952	0.971
4	1	0.378	4.036	0.143	16.289	1.526
7	1	0.18	4.87	0.032	23.717	0.877
9	1	0.22	3.635	0.048	13.213	0.800
11	1	0.47	3.567	0.221	12.723	1.676
14	1	0.33	7.523	0.109	56.596	2.483
		1.821	27.625	0.613	138.490	8.332
		$\Sigma X_{1 1}$	$\Sigma X_{2 1}$	$\Sigma X_1^2 _1$	$\Sigma X_2^2 _1$	$\Sigma X_1 X_2 _1$
		0.304	4.604			
		$\bar{X}_{1 1}$	$\bar{X}_{2 1}$			
Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{i,l}$	$R_{A,P}$			
3	2	0.05	2.778	0.003	7.717	0.139
5	2	0.04	1.256	0.002	1.578	0.050
6	2	0.05	1.377	0.003	1.896	0.069
8	2	0.04	1.143	0.002	1.306	0.046
13	2	0.000	1.225	0.000	1.501	0.000
15	2	0.03	2.083	0.001	4.339	0.062
		0.210	9.862	0.009	18.337	0.366
		$\Sigma X_{1 2}$	$\Sigma X_{2 2}$	$\Sigma X_1^2 _2$	$\Sigma X_2^2 _2$	$\Sigma X_1 X_2 _2$
		0.035	1.644			
		$\bar{X}_{1 2}$	$\bar{X}_{2 2}$			

(continúa)

Tabla 5-26 Datos acomodados por grupos y sus descriptivos (continuación)

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
17	3	0.187	2.054	0.035	4.219	0.384
18	3	0.143	2.198	0.020	4.831	0.314
19	3	0.115	2.043	0.013	4.174	0.235
20	3	0.198	2.765	0.039	7.645	0.547
21	3	0.106	2.098	0.011	4.402	0.222
22	3	0.123	2.09	0.015	4.368	0.257
		0.872	13.248	0.134	29.639	1.960
		$\Sigma X_1 _3$	$\Sigma X_2 _3$	$\Sigma X_1^2 _3$	$\Sigma X_2^2 _3$	$\Sigma X_1 X_2 _3$
		0.145	2.208			
		$\bar{X}_1 _3$	$\bar{X}_2 _3$			

Recuerde que:

$\Sigma X_i|_g$: es la suma de la variable i en el grupo g

$\Sigma X_i^2|_g$: es la suma de cuadrados de la variable i en el grupo g

$\Sigma X_i X_j|_g$: es la suma de los productos cruzados de la variable i y la variable j en el grupo g

$\bar{X}_i|_g$: es el promedio de la variable i en el grupo g

Como se recordará en el análisis discriminante simple, la matriz W se obtiene por medio de las sumas de cuadrados (SS) de cada una de las variables, pero para cada grupo, es decir que:

$$\text{Suma de cuadrados de la } X_i|_{1,\dots,g} = SSX_i|_{1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_i^2 - n\bar{X}_i^2$$

donde:

$SSX_i|_{1,\dots,g}$: indica la suma de cuadrados de la variable i desde el grupo 1 al grupo g

$\sum_{i=1}^n X_i^2 - n\bar{X}_i^2$: indica la suma de cuadrados para la variable i

$\sum_{j=1}^g \sum_{i=1}^n X_i^2 - n\bar{X}_i^2$: indica la suma de cuadrados para la variable i pero para cada uno de los grupos

Por lo que para la X_1 se tiene que encontrar para cada 1 de los 3 grupos, los cuales se representan por:

$$SSX_1|_{1,2,3} = SSX_1|_1 + SSX_1|_2 + SSX_1|_3$$

Al sustituir la información:

$$SSX_1| = [0.613 - 6(0.304)^2] + [0.009 - 6(0.035)^2] + [0.134 - 6(0.145)^2]$$

da como resultado:

$$SSX_1|_{1,2,3} = [0.060] + [0.002] + [0.007] = 0.069$$

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_2|_{1,\dots,g} = SSX_2|_{1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_2^2 - n\bar{X}_2^2$$

Esto sería para los 3 grupos, los cuales se representan por:

$$SSX_2|_{1,2,3} = SSX_2|_1 + SSX_2|_2 + SSX_2|_3$$

Al sustituir la información:

$$SSX_2|_{1,2,3} = [138.498 - 6(4.604)^2] + [18.337 - 6(1.644)^2] + [29.639 - 6(2.208)^2]$$

da como resultado:

$$SSX_2|_{1,2,3} = [11.299] + [2.127] + [0.387] = 13.814$$

Por último, se obtiene ahora la suma de los productos cruzados para la variable X_1 y para X_2 :

$$\text{Suma de productos cruzados de } X_1 \text{ y } X_2|_{1,\dots,g} = SPX_1X_2|_{1,\dots,g} = \sum_{j=1}^g \sum_{i=1}^n X_1X_2 - n\bar{X}_1\bar{X}_2$$

Lo cual para los 3 grupos sería:

$$SPX_1X_2|_{1,2,3} = SPX_1X_2|_1 + SPX_1X_2|_2 + SPX_1X_2|_3$$

Al sustituir la información:

$$SPX_1X_2|_{1,2,3} = [8.332 - 6(0.304)(4.604)] + [0.366 - 6(0.035)(1.644)] + [1.960 - 6(0.145)(2.208)]$$

da como resultado:

$$SPX_1X_2|_{1,2,3} = [-0.053] + [0.021] + [0.035] = 0.003$$

Para la matriz W se tienen que poner las sumas de cuadrados de la siguiente manera:

$$W = \begin{bmatrix} SSX_1 & SPX_1X_2 \\ SPX_1X_2 & SSX_2 \end{bmatrix}$$

por lo que los resultados en dicha matriz serían:

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Ahora para obtener la matriz T es necesario utilizar los datos, pero sin partición de los grupos, es decir, 70% de ellos; la información de esto con sus descriptivos se presenta a continuación:

Tabla 5-27 Datos sin acomodar por grupos y sus descriptivos

Empresas	Grupo	X_1	X_2	X_1^2	X_2^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
2	1	0.243	3.9947	0.059	15.956	0.971
4	1	0.378	4.0362	0.143	16.291	1.526
7	1	0.18	4.87	0.032	23.717	0.877
9	1	0.22	3.635	0.048	13.213	0.800
11	1	0.47	3.567	0.221	12.723	1.676
14	1	0.33	7.523	0.109	56.596	2.483
3	2	0.05	2.778	0.003	7.717	0.139
5	2	0.04	1.256	0.002	1.578	0.050
6	2	0.05	1.377	0.003	1.896	0.069
8	2	0.04	1.143	0.002	1.306	0.046
13	2	0	1.225	0.000	1.501	0.000
15	2	0.03	2.083	0.001	4.339	0.062

(continúa)

Tabla 5-27 Datos sin acomodar por grupos y sus descriptivos (*continuación*)

17	3	0.187	2.054	0.035	4.219	0.384
18	3	0.143	2.198	0.020	4.831	0.314
19	3	0.115	2.043	0.013	4.174	0.235
20	3	0.198	2.765	0.039	7.645	0.547
21	3	0.106	2.098	0.011	4.402	0.222
22	3	0.123	2.09	0.015	4.368	0.257
		2.903	50.736	0.756	186.473	10.658
		ΣX_1	ΣX_2	Σx_1^2	Σx_2^2	$\Sigma X_1 X_2$
		0.161	2.819			
		$\bar{X}_1$	$\bar{X}_2$			

Las fórmulas para obtener las varianzas y covarianzas son las mismas, pero sin los grupos, como se muestra a continuación:

$$\text{Suma de cuadrados de la } X_i = SSX_i = \sum_{i=1}^n X_i^2 - n\bar{X}_i^2$$

donde:

$$\sum_{i=1}^n X_i^2 - n\bar{X}_i^2 : \text{ indica la suma de cuadrados para la variable } i$$

Ahora para la X_1 se tiene que:

$$SSX_1 = [0.756 - 18(0.161)^2] = 0.288$$

De la misma manera se obtiene ahora la X_2 :

$$\text{Suma de cuadrados de la } X_2 = SSX_2 = \sum_{i=1}^n X_2^2 - n\bar{X}_2^2$$

$$SSX_2 = [186.473 - 18(2.819)^2] = 43.466$$

Ahora se obtiene la suma de los productos cruzados para la variable X_1 y para X_2 :

$$\text{Suma de productos cruzados de } X_1 \text{ y } X_2 = SPX_1 X_2 = \sum_{i=1}^n X_1 X_2 - n\bar{X}_1 \bar{X}_2$$

$$SPX_1 X_2 = [10.658 - 18(0.161)(2.819)] = 2.476$$

Con la información pasada se construye la matriz T ; se tienen que poner las sumas de cuadrados de la siguiente manera:

$$T = \begin{bmatrix} SSX_1 & SPX_1 X_2 \\ SPX_1 X_2 & SSX_2 \end{bmatrix}$$

por lo que los resultados de la matriz T serían:

$$T = \begin{bmatrix} 0.288 & 2.476 \\ 2.476 & 43.466 \end{bmatrix}$$

Finalmente, la matriz A se obtiene de la diferencia entre la matriz T y la matriz W .

$$A = T - W = \begin{bmatrix} 0.288 & 2.476 \\ 2.476 & 43.466 \end{bmatrix} - \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

La matriz A queda de la siguiente manera:

$$A = T - W = \begin{bmatrix} 0.219 & 2.472 \\ 2.472 & 29.653 \end{bmatrix}$$

5.7.1 Prueba de igualdad de las medias

Ahora se probará, con las siguientes hipótesis, si las variables son buenas para discriminar.

Esta prueba plantea las hipótesis de la siguiente forma:

H_0 : la variable i (X_i) no es buena para discriminar.

H_a : la variable i (X_i) sí es buena para discriminar.

La primera variable que se probará será la razón del *ingreso* y la *inversión* ($R_{I,I}$) que es la variable 1 (X_1).

H_0 : la variable razón del *ingreso* y la *inversión* ($R_{I,I}$) no es buena para discriminar.

H_a : la variable razón del *ingreso* y la *inversión* ($R_{I,I}$) sí es buena para discriminar.

Para la variable X_1 los datos provienen de la matriz W y de la matriz T , por lo que queda como sigue:

$$\Lambda_1 = \frac{\text{Variación no explicada de la } X_1}{\text{Variación total de la } X_1} = \frac{0.069}{0.288} = 0.240$$

Entre más pequeña una Wilks es mejor; ahora la Wilks se convierte en una F ; como hay 18 datos y 3 grupos se tiene que:

$$n - g = 18 - 3 = 15 \text{ y además que } g - 1 = 3 - 1 = 2$$

Por lo que la F sería de la siguiente forma:

$$F_{C_{X_1}} = \frac{(1 - \Lambda_1)/(g - 1)}{\Lambda_1/(n - g)} = \frac{(1 - 0.240)/(3 - 1)}{0.240/(18 - 3)} = 23.726$$

Ahora bien, el estadístico teórico se define por:


$$F_{t, \alpha, g-1, n-g}$$

Supóngase que el estudio se realiza con 95% de confianza, con 2 grupos y 12 datos, se tiene que:

$$F_{t, \alpha = 0.05, g-1 = 3-1 = 2, n-g = 18-3 = 15} = F_{t, \alpha = 0.05, 2, 15} = 3.682$$

cuyo valor se obtiene de la siguiente manera:

Tabla 5-28 Tabla F^{36}



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
15	0.100	3.073	2.695	2.490	2.361	2.273	2.208	2.158	2.119	2.086	2.059	2.017	1.972	1.924	1.899	1.873
	0.050	4.543	3.682	3.287	3.056	2.901	2.790	2.707	2.641	2.588	2.544	2.475	2.403	2.328	2.288	2.247
	0.025	6.200	4.765	4.153	3.804	3.576	3.415	3.293	3.199	3.123	3.060	2.963	2.862	2.756	2.701	2.644
	0.010	8.683	6.359	5.417	4.893	4.556	4.318	4.142	4.004	3.895	3.805	3.666	3.522	3.372	3.294	3.214
	0.005	10.798	7.701	6.476	5.803	5.372	5.071	4.847	4.674	4.536	4.524	4.250	4.070	3.883	3.786	3.687
16	0.100	3.048	2.668	2.462	2.333	2.244	2.178	2.128	2.088	2.055	2.028	1.985	1.940	1.891	1.866	1.839
	0.050	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591	2.538	2.494	2.425	2.352	2.276	2.235	2.194
	0.025	6.115	4.687	4.077	3.729	3.502	3.341	3.219	3.125	3.049	2.986	2.889	2.788	2.681	2.625	2.568

(continúa)

³⁶ Ver anexo 2.3, tabla F.

Tabla 5-28 Tabla F (continuación)

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
17	0.010	8.531	6.226	5.292	4.773	4.437	4.202	4.026	3.890	3.780	3.691	3.553	3.409	3.259	3.181	3.101
	0.005	10.575	7.514	6.303	5.638	5.212	4.913	4.692	4.521	4.384	4.272	4.099	3.920	3.734	3.638	3.539
	0.100	3.026	2.645	2.437	2.308	2.218	2.152	2.102	2.061	2.028	2.001	1.958	1.912	1.862	1.836	1.809
	0.050	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.381	2.308	2.230	2.190	2.148
	0.025	6.042	4.619	4.011	3.665	3.438	3.277	3.156	3.061	2.985	2.922	2.825	2.723	2.616	2.560	2.502
	0.010	8.400	6.112	5.185	4.669	4.336	4.102	3.927	3.791	3.682	3.593	3.455	3.312	3.162	3.084	3.003
	0.005	10.384	7.354	6.156	5.497	5.075	4.779	4.559	4.389	4.254	4.142	3.971	3.793	3.607	3.511	3.412


Para rechazar la H_0 es necesario que:

$$F_C > F_{t, \alpha, g-1, n-g}$$

por lo que:

$$23.726 > 3.682 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que la variable X_1 es buena para discriminar, es decir, que la razón *ingreso e inversión* es significativamente buena para separar en 2 grupos.

De la misma manera, ahora se probará la variable razón del *activo y pasivo* ($R_{A, pl}$) que es la variable 2 (X_2).

$$\Lambda_2 = \frac{\text{Variación no explicada de la } X_2}{\text{Variación total de la } X_2} = \frac{13.814}{43.466} = 0.318$$

Ahora la Wilks se convierte en una F ; con 12 datos y 2 grupos se tiene que:

$$n - g = 18 - 3 = 15 \text{ y además que } g - 1 = 3 - 1 = 2$$

por lo que la F sería de la siguiente forma:

$$F_{C_{X_2}} = \frac{(1 - \Lambda_2)/(g - 1)}{\Lambda_2/(n - g)} = \frac{(1 - 0.318)/(3 - 1)}{0.318/(18 - 3)} = 16.100$$


El estadístico teórico se define por:

$$F_{t, \alpha, g-1, n-g}$$

Supóngase que el estudio se realiza con 95% de confianza, con 2 grupos y 12 datos, se tiene que:

$$F_{t, \alpha=0.05, g-1=3-1=2, n-g=18-3=15} = F_{t, \alpha=0.05, 2, 15} = 3.682$$

cuyo valor se obtiene de la siguiente manera:

Tabla 5-29 Tabla F³⁷

gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
15	0.100	3.073	2.695	2.490	2.361	2.273	2.208	2.158	2.119	2.086	2.059	2.017	1.972	1.924	1.899	1.873
	0.050	4.543	3.682	3.287	3.056	2.901	2.790	2.707	2.641	2.588	2.544	2.475	2.403	2.328	2.288	2.247
	0.025	6.200	4.765	4.153	3.804	3.576	3.415	3.293	3.199	3.123	3.060	2.963	2.862	2.756	2.701	2.644
	0.010	8.683	6.359	5.417	4.893	4.556	4.318	4.142	4.004	3.895	3.805	3.666	3.522	3.372	3.294	3.214
	0.005	10.798	7.701	6.476	5.803	5.372	5.071	4.847	4.674	4.536	4.424	4.250	4.070	3.883	3.786	3.687
16	0.100	3.048	2.668	2.462	2.333	2.244	2.178	2.128	2.088	2.055	2.028	1.985	1.940	1.891	1.866	1.839
	0.050	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591	2.538	2.494	2.425	2.352	2.276	2.235	2.194
	0.025	6.115	4.687	4.077	3.729	3.502	3.341	3.219	3.125	3.049	2.986	2.889	2.788	2.681	2.625	2.568
	0.010	8.531	6.226	5.292	4.773	4.437	4.202	4.026	3.890	3.780	3.691	3.553	3.409	3.259	3.181	3.101
	0.005	10.575	7.514	6.303	5.638	5.212	4.913	4.692	4.521	4.384	4.272	4.099	3.920	3.734	3.638	3.539
17	0.100	3.026	2.645	2.437	2.308	2.218	2.152	2.102	2.061	2.028	2.001	1.958	1.912	1.862	1.836	1.809
	0.050	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.381	2.308	2.230	2.190	2.148
	0.025	6.042	4.619	4.011	3.665	3.438	3.277	3.156	3.061	2.985	2.922	2.825	2.723	2.616	2.560	2.502
	0.010	8.400	6.112	5.185	4.669	4.336	4.102	3.927	3.791	3.682	3.593	3.455	3.312	3.162	3.084	3.003
	0.005	10.384	7.354	6.156	5.497	5.075	4.779	4.559	4.389	4.254	4.142	3.971	3.793	3.607	3.511	3.412

Las hipótesis serían:

H_0 : la variable X_2 (*activo/pasivo*) no es buena para discriminar

H_a : la variable X_2 (*activo/pasivo*) sí es buena para discriminar


Para rechazar la H_0 es necesario que:

$$F_C > F_{t, \alpha, g-1, n-g}$$

por lo que:

$$16.100 > 3.682 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que la variable X_2 es buena para discriminar, es decir, que la razón *activo y pasivo* es significativamente buena para separar en 2 grupos.

La conclusión final es que las 2 variables del ejemplo son buenas para discriminar.

³⁷ Ver anexo 2.3, tabla F.

5.7.2 Prueba del modelo

Para poder encontrar el estadístico de esta prueba es necesario obtener los eigenvalores³⁸ (λ) correspondientes a cada una de las funciones discriminantes generadas. Este procedimiento es igual que el análisis discriminante simple con la fórmula ya conocida:

$$|W^{-1}A - \lambda I| = 0$$

Esto implica resolver el determinante cuya incógnita es λ . Se iniciará el procedimiento: Primero se encontrará la inversa de la matriz W .

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

para lo cual se necesita el determinante, que se obtiene como sigue:

$$\text{Det}(W) = |W| = (0.069)(13.814) - (0.003)(0.003) = 0.954$$

Las sumas de cuadrados de las variables y del producto cruzado se dividen entre el determinante:

$$\begin{bmatrix} \frac{0.069}{0.954} & \frac{0.003}{0.954} \\ \frac{0.003}{0.954} & \frac{13.814}{0.954} \end{bmatrix}$$

Dicha división da como resultado:

$$\begin{bmatrix} 0.072 & 0.003 \\ 0.003 & 14.474 \end{bmatrix}$$

Ahora se intercambian de posición la suma de cuadrados de las variables X_1 y X_2 , es decir, la diagonal principal de la matriz se intercambia y en la diagonal secundaria se le cambia el signo a los productos cruzados; la matriz inversa (W^{-1}) queda así:

$$W^{-1} = \begin{bmatrix} 14.474 & -0.003 \\ -0.003 & 0.072 \end{bmatrix}$$

Al seguir con la fórmula, se multiplica la matriz inversa (W^{-1}) por la matriz A :

$$W^{-1}A = \begin{bmatrix} 14.474 & -0.003 \\ -0.003 & 0.072 \end{bmatrix} \begin{bmatrix} 0.219 & 2.472 \\ 2.472 & 29.653 \end{bmatrix}$$

Se multiplica el primer renglón por la primera columna, lo que da el primer coeficiente, por ejemplo:

$$(14.474)(0.219) + (-0.003)(2.472) = 3.155$$

El segundo coeficiente es:

$$(14.474)(2.472) + (-0.003)(29.653) = 35.685$$

Y así sucesivamente, por lo que el producto de $W^{-1}A$ da:

$$W^{-1}A = \begin{bmatrix} 3.155 & 35.685 \\ 0.178 & 2.138 \end{bmatrix}$$

A esta matriz se le resta el eigenvalor por la matriz identidad. Como la matriz pasada es de dimensiones de (2×2) , la matriz identidad es la siguiente:

³⁸ En el anexo 3.2 "Descomposición espectral" se trató de manera amplia cómo encontrar los valores propios.

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Al multiplicarlo por el eigenvalor queda:

$$\lambda I = \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix}$$

por lo que la diferencia de $W^{-1}A - \lambda I$ es:

$$W^{-1}A - \lambda I = \begin{bmatrix} 3.155 & 35.685 \\ 0.178 & 2.138 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3.155 - \lambda & 35.685 \\ 0.178 & 2.138 - \lambda \end{bmatrix}$$

Para encontrar los valores de los λ se debe resolver el siguiente determinante y despejar la ecuación resultante para lambda (λ).

$$|W^{-1}A - \lambda I| = \begin{vmatrix} 3.155 - \lambda & 35.685 \\ 0.178 & 2.138 - \lambda \end{vmatrix}$$

El determinante se resolvería de la siguiente manera:

$$|W^{-1}A - \lambda I| = (3.155 - \lambda)(2.138 - \lambda) - (35.685)(0.178)$$

el cual debe ser igualado a cero. Al resolver los productos y la diferencia se tiene que:

$$|W^{-1}A - \lambda I| = 6.746 - 3.155\lambda - 2.138\lambda - \lambda^2 - 6.360 = 0$$

Al arreglar la información resulta una cuadrática:

$$\lambda^2 - 5.293\lambda + 0.386 = 0$$

Ahora, para encontrar los valores de λ se debe resolver la cuadrática, la cual se iguala a cero y tiene la forma $aX^2 + bX + c = 0$; la cual se resuelve de la siguiente manera:

$$X = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

Se despeja la X ; pero en el caso que se está resolviendo debe despejarse la lambda, por lo que al igualar ambas fórmulas se tiene que:

$$a = 1, \quad b = 5.293, \quad y \quad c = 0.386$$

Ahora al sustituir en la fórmula de la cuadrática se tiene:

$$\lambda = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} = \frac{-(-5.293) \pm \sqrt{(-5.293)^2 - 4(1)(0.386)}}{2(1)}$$

Lo anterior da como resultado 3 valores, los cuales se ordenan de mayor a menor, por lo que:

$$\lambda_1 = 5.219 \text{ y } \lambda_2 = 0.074$$

Una vez encontrados los valores propios se empieza con la prueba de hipótesis del modelo, que serían las siguientes:

H_0 : el modelo no es bueno para discriminar

H_a : el modelo sí es bueno para discriminar

Es necesario aclarar que en esta parte es importante ver cuántas funciones se formarán, al recordar que el número de funciones es:

$$\text{Mín}\{(g-1)(m)\}$$

donde:

g : es el número de grupos en la variable dependiente

m : es el número de variables independientes

$$\text{Mín}\{(g-1)(m)\} = \text{Mín}\{(3-1)(2)\} = 2$$

Esto indica que se deben formar 2 funciones, por lo que se hará la prueba de cada una (1 y 2).

5.7.2.1 Prueba del modelo 1

Para realizar la prueba del modelo se recomienda recurrir al estadístico V de Bartlett, que es una función de la lambda de Wilks, el cual tiene una distribución asintótica ji cuadrada; la fórmula es la siguiente:

Ecuación 5-32 Expresión de Bartlett para la prueba de hipótesis del modelo para un discriminante múltiple

$$V = \left\{ n - 1 - \frac{k+g}{2} \right\} \sum_{j=1}^{g-1} \ln(1 + \lambda_j)$$

donde:

n : es el número de datos

k : es el número de variables independientes o discriminantes

g : es el número de grupos en la variable dependiente

j : inicia con el valor de cero para representar a la primera función obtenida, ya que j es el número de funciones anteriormente calculadas

En este caso $j = 0$, por lo que la fórmula sustituida queda:

$$V = \left\{ n - 1 - \frac{k+g}{2} \right\} \sum_{j=1}^{g-1} \ln(1 + \lambda_j) = \left\{ 18 - 1 - \frac{2+3}{2} \right\} [\ln(1 + 5.365) + \ln(1 + 0.074)]$$

da como resultado:

$$V = \left\{ 18 - 1 - \frac{2+3}{2} \right\} [\ln(1 + 5.365) + \ln(1 + 0.074)] = 27.535$$

El estadístico V de Bartlett final corresponde a una ji cuadrada calculada, la cual dio como resultado:

$$\chi^2_c = 27.535$$

El estadístico V de Bartlett se distribuye como una ji cuadrada con los grados de libertad:

$$\chi^2_{(k-j)(g-j-1)}$$

donde:

k : es el número de variables independientes


g : es el número de grupos en la variable dependiente

j : es el número correspondiente a cada una de las funciones discriminantes generadas antes de ésta y como es la primera función $j = 0$

Como en el ejemplo se utiliza 5% como nivel de significancia, el estadístico teórico sería:

$$\chi^2_{t, \alpha = 0.05, (k-j)(g-j-1) = (2-0)(3-0-1) = 4} = 9.488$$

El cual se encontró de la siguiente manera:

Tabla 5-30 Tabla ji cuadrada³⁹

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264

Las hipótesis para la prueba del modelo son:

H_0 : el modelo 1 no es bueno para discriminar

H_a : el modelo 1 sí es bueno para discriminar


Para rechazar la H_0 es necesario que:

$$\chi^2_C > \chi^2_{t, \alpha, (k-j)(g-j-1)}$$

por lo que:

$$27.535 > 9.488 \text{ se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que se rechaza H_0 y se concluye que el modelo 1 sí es bueno para discriminar.

Ahora se realizará la prueba para la segunda función:

5.7.2.2 Prueba del modelo 2

Para la segunda función $j = 1$, pues antes se tiene la primera función; por lo que la fórmula sustituida queda:

³⁹ Ver anexo 3.4, tabla ji cuadrada.

$$V = \left\{ n - 1 - \frac{k+g}{2} \right\} \sum_{j=j+1}^{g-1} \ln(1 + \lambda_j) = \left\{ 18 - 1 - \frac{2+3}{2} \right\} [\ln(1 + 0.074)]$$

y da como resultado:

$$V = \left\{ 18 - 1 - \frac{2+3}{2} \right\} [\ln(1 + 0.074)] = 1.034$$

El estadístico V de Bartlett final dio como resultado:

$$\chi^2_c = 1.034$$

Ahora se encuentra la ji cuadrada teórica con los grados de libertad:

$$\chi^2_{(k-j)(g-j-1)}$$

donde:

k : es el número de variables independientes

g : es el número de grupos en la variable dependiente


j : es el número correspondiente a cada una de las funciones discriminantes generadas antes de ésta y como es la primera función $j = 0$

Como en el ejemplo se usa 5% como nivel de significancia, el estadístico teórico sería:

$$\chi^2_{t, \alpha=0.05, (k-j)(g-j-1)=(2-1)(3-1-1)=1} = 3.841$$

El cual se encontró de la siguiente manera:

Tabla 5-31 Tabla ji cuadrada⁴⁰



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.952	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264

Las hipótesis para la prueba del modelo son:

H_0 : el modelo 2 no es bueno para discriminar.

H_a : el modelo 2 sí es bueno para discriminar.

⁴⁰ Ver anexo 3.4, tabla ji cuadrada.


Para rechazar la H_0 es necesario que:

$$\chi^2_c > \chi^2_{t, \alpha, (k-j)(g-j-1)}$$

por lo que:

$$1.034 < 3.841 \text{ no se rechaza } H_0$$

O bien, para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo que no se rechaza H_0 y se concluye que el modelo 2 no es bueno para discriminar.

5.7.3 Indicadores del ajuste del modelo

Los indicadores que reporta el paquete estadístico SPSS™ con respecto al modelo son los siguientes:

5.7.3.1 Valores propios

El cálculo de los eigenvalores correspondientes se explicó en la obtención del modelo a través de la siguiente expresión:

$$|W^{-1}A - \lambda I| = 0$$

Al realizar dicho procedimiento se obtuvieron 2 valores propios, los cuales se ordenaron de mayor a menor y fueron:

$$\lambda_1 = 5.219 \text{ y la } \lambda_2 = 0.074$$

El eigenvalor es sinónimo de la cantidad de variación o información manejada, por lo que entre mayor sea su valor es mejor; si se tienen varios valores propios siempre se escogerá el mayor.

Como este ejemplo tiene más de un valor propio el porcentaje de varianza se puede captar por medio de cada uno, para ello es necesario sumarlos y convertirlos a porcentaje.

Ecuación 5-33 Porcentaje de varianza

$$\% \text{ de varianza} = \frac{\lambda_i}{\sum \lambda_i}$$

El porcentaje del primer autovalor sería:

$$\frac{\lambda_i}{\sum \lambda_i} = \frac{\lambda_1}{\sum \lambda_i} = \frac{5.219}{5.219 + 0.074} 100 = 98.6\%$$

Y el segundo valor propio es:

$$\frac{\lambda_i}{\sum \lambda_i} = \frac{\lambda_2}{\sum \lambda_i} = \frac{0.074}{5.219 + 0.074} 100 = 1.4\%$$

Esto indica que con el primero se explica 98.6% y con el segundo 1.4%, por lo que es mejor el primero ya que capta más de 98% y con el segundo se explica menos de 2%.

5.7.3.2 Lambda de Wilks

La medida lambda de Wilks, como se explicó en el discriminante simple, evalúa la capacidad discriminante de la función y expresa la proporción de la varianza total explicada por los puntajes discriminantes; mientras más cerca esté del cero, mayor será el poder discriminante de las variables utilizadas en el estudio; su fórmula es la siguiente:

$$\Lambda = \frac{\text{Determinante de } W}{\text{Determinante de } T} = \frac{|W|}{|T|}$$

Los valores de $|W|$ y $|T|$ se obtienen de los determinantes de las matrices correspondientes. El determinante de la matriz W se obtuvo anteriormente cuando se calculó el eigenvalor, donde:

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Para lo cual se necesita el determinante, que se obtiene como sigue:

$$\text{Det}(W) = |W| = (0.069)(13.814) - (0.003)(0.003) = 0.954$$

Como la matriz T es:

$$T = \begin{bmatrix} 0.288 & 2.476 \\ 2.476 & 43.466 \end{bmatrix}$$

el determinante de T sería:

$$\text{Det}(T) = |T| = (0.288)(43.466) - (2.476)(2.476) = 6.374$$

por lo que lambda de Wilks da como resultado:

$$\Lambda = \frac{\text{Determinante de } W}{\text{Determinante de } T} = \frac{|W|}{|T|} = \frac{0.954}{6.374} = 0.150$$

Es importante volver a mencionar que los valores de la lambda de Wilks varían entre 0 y 1, los valores próximos a 0 indican mucha separación en los grupos y que los valores cercanos a 1 señalan que los grupos están muy mezclados. Como conclusión, en este caso la $\Lambda = 0.150$ por lo que los grupos se encuentran muy poco mezclados.

5.7.3.3 Correlación canónica

La correlación canónica en discriminante múltiple se encuentra mediante los valores propios con la fórmula de eta cuadrada (η^2), que es el coeficiente de determinación obtenido para cada función discriminante; su fórmula se basa en los valores propios (λ_i). Lo anterior indica que es necesario encontrar una correlación canónica para cada autovalor encontrado, por lo que su fórmula sería la siguiente:

Ecuación 5-34 Eta cuadrada utilizada para encontrar correlación canónica

$$\text{Correlación canónica} = \eta_i^2 = \sqrt{\frac{\lambda_i}{1 + \lambda_i}}$$

En el ejemplo de discriminante múltiple se encontraron 2 valores propios, los cuales son:

$$\lambda_1 = 5.219 \text{ y } \lambda_2 = 0.074$$

Al sustituir en la fórmula el primer valor propio se tiene:

$$\eta_1^2 = \sqrt{\frac{\lambda_1}{1 + \lambda_1}} = \sqrt{\frac{5.219}{1 + 5.219}} = 0.916$$

Como en este caso la correlación canónica fue de 0.916 (que es un valor alto) significa que con el primer eigenvalor se logró captar 91.6% del comportamiento de los grupos.

Al sustituir en la fórmula el segundo valor propio se tiene:

$$\eta_2^2 = \sqrt{\frac{\lambda_2}{1 + \lambda_2}} = \sqrt{\frac{0.074}{1 + 0.074}} = 0.262$$

Como en este caso la correlación canónica fue de 0.262 (que es un valor bajo) significa que con el segundo autovalor se logró captar 26.2% del comportamiento de los grupos.

5.7.4 Obtención de las constantes de los modelos

Ahora se encontrarán las funciones discriminantes, aunque la segunda función no es buena también se buscará con la fórmula siguiente:

$$|W^{-1}A - \lambda I| = 0$$

Se encontraron los valores propios; pero para obtener las K es necesario obtener la siguiente expresión:

$$(W^{-1}A - \lambda I)K = 0$$

donde K es el vector de constantes que se desea encontrar; éstas se calculan para cada uno de los modelos, el proceso se explica a continuación.

5.7.4.1 Obtención de las constantes de la función 1

Para obtener las K en la función 1 se utiliza la inversa de la matriz W multiplicada por la matriz A menos el eigenvalor (λ) multiplicado por la matriz identidad (I); parte del proceso se muestra a continuación:

$$W^{-1}A = \begin{bmatrix} 14.474 & -0.003 \\ -0.003 & 0.072 \end{bmatrix} \begin{bmatrix} 0.219 & 2.472 \\ 2.472 & 29.653 \end{bmatrix}$$

y además:

$$\lambda I = \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix}$$

por lo que:

$$W^{-1}A - \lambda I = \begin{bmatrix} 3.155 & 35.685 \\ 0.178 & 2.138 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3.155 - \lambda & 35.685 \\ 0.178 & 2.138 - \lambda \end{bmatrix}$$

Al final lo que interesa es la siguiente expresión:

$$\begin{bmatrix} 3.155 - \lambda & 35.685 \\ 0.178 & 2.138 - \lambda \end{bmatrix} = 0$$

Además se sabe que los valores propios son:

$$\lambda_1 = 5.219 \text{ y } \lambda_2 = 0.074$$

Por lo que el eigenvalor 1, es decir la $\lambda_1 = 5.219$, al sustituirlo en la matriz anterior e igualándolo a cero, se tiene:

$$(W^{-1}A - \lambda I)K = \begin{bmatrix} 3.155 - 5.219 & 35.685 \\ 0.178 & 2.138 - 5.219 \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

La matriz se postmultiplicó por el vector de constantes. Al resolver las diferencias se tiene:

$$\begin{bmatrix} -2.064 & 35.685 \\ 0.178 & -3.081 \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Ahora se obtiene la multiplicación, por lo que con esto se calculan las 2 ecuaciones. La primera es:

$$-2.64K_1 + 35.685K_2 = 0$$

De la cual se despeja alguna de las constantes, por ejemplo K_2 :

$$35.685K_2 = 2.064K_1$$

por lo que:

$$K_2 = \frac{2.064}{35.685}K_1 = 0.058K_1$$

Y la segunda sería:

$$0.178K_1 - 3.081K_2 = 0$$

al despejar K_2 :

$$-3.081K_2 = -0.178K_1$$

por lo que:

$$K_2 = \frac{-0.178}{-3.081}K_1 = 0.058K_1$$

Las 2 ecuaciones son iguales por la relación que guardan; no es posible resolver el sistema de ecuaciones y solamente se conservará una de ellas.

$$K_2 = 0.058K_1$$

Ahora es necesario encontrar la normal que proviene del teorema de Pitágoras y se busca la suma de cuadrados de las K de la unidad, es decir:

$$K_1^2 + K_2^2 = 1^2 = 1$$

Se sabe que $K_2 = 0.058K_1$ y al sustituir el valor en la expresión anterior se tiene que:

$$K_1^2 + (0.058K_1)^2 = 1$$

Al elevar al cuadrado quedaría de la siguiente manera:

$$K_1^2 + 0.003 K_1^2 = 1$$

Al sumar las 2 da como resultado:

$$1.003K_1^2 = 1$$

Ahora se despeja K_1 :

$$K_1^2 = \frac{1}{1.003}$$

por lo que finalmente se tiene:

$$K_1 = \sqrt{\frac{1}{1.003}} = 0.998$$

Ahora ese valor se pone en la ecuación de $K_2 = 0.058K_1$ y se tiene que:

$$K_2 = 0.058 (0.998)$$

da como resultado:

$$K_2 = 0.058$$

también resulta el vector normalizado de las K :

$$K_{\text{normalizado}} = K_N = \begin{bmatrix} 0.998 \\ 0.058 \end{bmatrix}$$

donde:

K_N : es el vector de las K normalizados

Ahora se reescalarán los coeficientes.

Recuerde que para conseguir el reescalamiento es necesario seguir la forma matricial, la cual es la siguiente:

$$B = K_N^T C_W K_N$$

donde:

K_N^T : es la transpuesta del vector de constantes normalizados

C_W : es la matriz W promediada

K_N : es el vector de constantes normalizados

Para obtener la matriz W se divide entre sus grados de libertad que son:

$$n - g$$

donde:

n : es el número de datos

g : es el número de datos en la variable dependiente

En el ejemplo los grados de libertad de la matriz W son: $n - 3 = 18 - 3 = 15$, a esta matriz se le llamará C_W y está compuesta de las varianzas y covarianzas promediadas⁴¹ que presentan los datos dentro de cada grupo.

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Dividido entre los grados de libertad:

$$C_W = \frac{W}{18 - 3} = \frac{W}{15}$$

da como resultado:

$$C_W = \frac{W}{15} = \begin{bmatrix} \frac{0.069}{15} & \frac{0.003}{15} \\ \frac{0.003}{15} & \frac{13.814}{15} \end{bmatrix} = \begin{bmatrix} 0.005 & 0.0002 \\ 0.0002 & 0.921 \end{bmatrix}$$

Se sabe que:

$$K_N = \begin{bmatrix} 0.998 \\ 0.058 \end{bmatrix}$$

Por lo que la K_N^T es:

$$K_N^T = [0.998 \quad 0.058]$$

⁴¹ Ya que fueron divididas entre los grados de libertad.

Al realizar la operación $K_N^T C_W$ se tiene:

$$K_N^T C_W = [0.998 \quad 0.058] \begin{bmatrix} 0.005 & 0.0002 \\ 0.0002 & 0.921 \end{bmatrix} = [0.005 \quad 0.053]$$

El resultado se multiplica por el vector de las K normalizados, es decir por K_N :

$$K_N^T C_W K_N = [0.005 \quad 0.053] \begin{bmatrix} 0.998 \\ 0.058 \end{bmatrix}$$

y da como resultado un escalar,⁴² el cual es:

$$B = K_N^T C_W K_N = [0.008]$$

y los K reescalados, los cuales fueron definidos por:

$$K_{\text{reescalados}} = K_R = K_N B^{-\frac{1}{2}} = K_N \frac{1}{\sqrt{B}}$$

Al seguir con el ejemplo, los K reescalados se obtienen de la siguiente manera:

$$K_R = K_N \frac{1}{\sqrt{B}} = \begin{bmatrix} 0.998 \\ 0.058 \end{bmatrix} \frac{1}{\sqrt{0.008}} = \begin{bmatrix} 11.386 \\ 0.659 \end{bmatrix}$$

Lo encontrado se sustituye en la ecuación lineal discriminante, la cual quedaría de la siguiente manera:

$$Z = K_1 X_1 + K_2 X_2 = 11.386 X_1 + 0.659 X_2$$

Recuerde que la ecuación al ser reescalada debe agregársele una constante, la cual se conoce como K_0 ; para obtenerla es necesario conocer las K promedio, las cuales requieren los promedios de cada uno de los grupos, que son:

Grupo 1, la media de X_1 es: $\bar{X}_1|_1 = 0.304$ y el promedio de X_2 es: $\bar{X}_2|_1 = 4.604$, entonces al sustituir en Z promedio se tiene:

$$\bar{Z}|_1 = 11.386 \bar{X}_1|_1 + 0.659 \bar{X}_2|_1 = 11.386(0.304) + 0.659(4.604) = 6.489$$

Ahora en el grupo 2, el promedio de X_1 es: $\bar{X}_1|_2 = 0.035$ y la media de X_2 es: $\bar{X}_2|_2 = 1.644$, y de nuevo al sustituir en Z promedio se tiene:

$$\bar{Z}|_2 = 11.386 \bar{X}_1|_2 + 0.659 \bar{X}_2|_2 = 11.386(0.035) + 0.659(1.644) = 1.481$$

Ahora en el grupo 3, el promedio de X_1 es: $\bar{X}_1|_3 = 0.145$ y la media de X_2 es: $\bar{X}_2|_3 = 2.208$; al sustituir en Z promedio se tiene:

$$\bar{Z}|_3 = 11.386 \bar{X}_1|_3 + 0.659 \bar{X}_2|_3 = 11.386(0.145) + 0.659(2.208) = 3.109$$

Ahora para encontrar K_0 se sustituye en la fórmula:

Ecuación 5-35 Ecuación de la constante de la ecuación discriminante

$$K_0 = -\frac{n_1 \bar{Z}|_1 + n_2 \bar{Z}|_2 + n_3 \bar{Z}|_3}{n}$$

donde:

$n|_i$: es el tamaño de la muestra del grupo i

$\bar{Z}|_i$: es la Z promedio del grupo i

n : es el número de datos en el total de la muestra (70%)

⁴² El término *escalar* se refiere a cualquier número o bien un vector o matriz de dimensiones (1×1) .

Por lo que al calcularla se tiene:

$$K_0 = -\frac{n|_1\bar{Z}|_1 + n|_2\bar{Z}|_2 + n|_3\bar{Z}|_3}{n}$$

$$= -\frac{6(6.489) + 6(1.481) + 6(3.109)}{6 + 6 + 6}$$

por lo que la constante sería:

$$K_0 = -3.693$$

El valor encontrado se sustituye en la ecuación lineal discriminante:

$$Z = K_0 + K_1X_1 + K_2X_2 = -3.693 + 11.386X_1 + 0.659X_2$$

Dicha ecuación es la que sirve para pronosticar los diferentes elementos de la muestra en los distintos grupos.

5.7.4.2 Obtención de las constantes de la función 2

Al sustituir la $\lambda^2 = 0.074$ en la siguiente expresión:

$$W^{-1}A - \lambda I = \begin{bmatrix} 3.155 & 35.685 \\ 0.178 & 2.138 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 3.155 - 0.074 & 35.685 \\ 0.178 & 2.138 - 0.074 \end{bmatrix}$$

se tiene:

$$(W^{-1}A - \lambda I)K = \begin{bmatrix} 3.081 & 35.685 \\ 0.178 & 2.064 \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

La matriz se posmultiplicó por el vector de constantes. Al resolver las diferencias se tiene:

$$\begin{bmatrix} 3.081 & 35.685 \\ 0.178 & 2.064 \end{bmatrix} \begin{bmatrix} K_1 \\ K_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Ahora se multiplica y se obtienen las 2 ecuaciones. La primera sería:

$$3.081K_1 + 35.685K_2 = 0$$

De la cual se despeja alguna de las constantes; por ejemplo, K_1 :

$$3.081K_1 = -35.685K_2$$

por lo que:

$$K_1 = -\frac{35.685}{3.081}K_2 = -11.582K_2$$

Como las 2 ecuaciones son iguales, por la relación que guardan, solamente se conservará la que se encontró antes.

$$K_1 = -11.582K_2$$

Ahora es necesario encontrar la norma, la cual proviene del teorema de Pitágoras; se busca la suma de cuadrados de las K de la unidad, es decir:

$$K_1^2 + K_2^2 = 1^2 = 1$$

Se sabe que $K_2 = 0.058K_1$ y al sustituir el valor en la expresión anterior, se tiene que:

$$(-11.582K_2)^2 + K_2^2 = 1$$

al elevar al cuadrado quedaría de la siguiente manera:

$$K_2^2 + 134.132K_2^2 = 1$$

al sumar las 2 da como resultado:

$$135.132K_2^2 = 1$$

Ahora se despeja K_1 :

$$K_2^2 = \frac{1}{135.132}$$

Por lo que finalmente se tiene:

$$K_2 = \sqrt{\frac{1}{135.132}} = 0.086$$

Ahora ese valor se pone en la ecuación de $K_1 = -11.582K_2$ por lo que se tiene que:

$$K_1 = -11.582(0.086) = -0.996$$

lo que da como resultado el vector normalizado de las K :

$$K_{\text{normalizado}} = K_N = \begin{bmatrix} -0.996 \\ 0.086 \end{bmatrix}$$

Para reescalar los coeficientes es necesario seguir la forma matricial, la cual es la siguiente:

$$B = K_N^T C_W K_N$$

Para obtener C_W la matriz W se divide entre sus grados de libertad que son:

$$n - g = 18 - 3 = 15$$

por lo que W :

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Al dividirla entre los grados de libertad:

$$C_W = \frac{W}{18 - 3} = \frac{W}{15}$$

da como resultado:

$$C_W = \frac{W}{15} = \begin{bmatrix} \frac{0.069}{15} & \frac{0.003}{15} \\ \frac{0.003}{15} & \frac{13.814}{15} \end{bmatrix} = \begin{bmatrix} 0.005 & 0.0002 \\ 0.0002 & 0.921 \end{bmatrix}$$

Se sabe que:

$$K_N = \begin{bmatrix} -0.996 \\ 0.086 \end{bmatrix}$$

por lo que la K_N^T es:

$$K_N^T = [-0.996 \quad 0.086]$$

Al realizar la operación $K_N^T C_W$ se tiene:

$$K_N^T C_W = [-0.996 \quad 0.086] \begin{bmatrix} 0.005 & 0.0002 \\ 0.0002 & 0.921 \end{bmatrix} = [-0.005 \quad 0.079]$$

El resultado se multiplica por el vector de las K normalizados, es decir por K_N .

$$K_N^T C_W K_N = \begin{bmatrix} -0.005 & 0.079 \end{bmatrix} \begin{bmatrix} -0.996 \\ 0.086 \end{bmatrix}$$

lo que da como resultado un escalar,⁴³ el cual es:

$$B = K_N^T C_W K_N = [0.011]$$

Y los K reescalados, los cuales fueron definidos por:

$$K_{\text{reescalados}} = K_R = K_N B^{-\frac{1}{2}} = K_N \frac{1}{\sqrt{B}}$$

De acuerdo con el ejemplo, los K reescalados se obtienen de la siguiente manera:

$$K_R = K_N \frac{1}{\sqrt{B}} = \begin{bmatrix} -0.996 \\ 0.086 \end{bmatrix} \frac{1}{\sqrt{0.011}} = \begin{bmatrix} -9.3526 \\ 0.687 \end{bmatrix}$$

El valor encontrado se sustituye en la ecuación lineal discriminante, la cual quedaría así:

$$Z = K_1 X_1 + K_2 X_2 = -9.352 X_1 + 0.687 X_2$$

Al reescalar la ecuación se necesita agregarle una constante, la cual se conoce como K_0 . Para obtener la constante antes mencionada es necesario conocer las Z promedio, que necesitan los promedios de cada uno de los grupos, los cuales son:

Grupo 1, la media de X_1 es: $\bar{X}_1|_1 = 0.304$ y el promedio de X_2 es: $\bar{X}_2|_1 = 4.604$; entonces al sustituir en Z promedio se tiene:

$$\bar{Z}|_1 = -9.352 \bar{X}_1|_1 + 0.687 \bar{X}_2|_1 = -9.352(0.304) + 0.687(4.604) = 0.880$$

Ahora en el grupo 2, el promedio de X_1 es: $\bar{X}_1|_2 = 0.035$ y la media de X_2 es: $\bar{X}_2|_2 = 1.644$ y de nuevo al sustituir en Z promedio se tiene:

$$\bar{Z}|_2 = -9.352 \bar{X}_1|_2 + 0.687 \bar{X}_2|_2 = -9.352(0.035) + 0.687(1.644) = 1.000$$

Ahora en el grupo 3, el promedio de X_1 es: $\bar{X}_1|_3 = 0.145$ y la media de X_2 es: $\bar{X}_2|_3 = 2.208$ y de nuevo al sustituir en Z promedio se tiene:

$$\bar{Z}|_3 = -9.352 \bar{X}_1|_3 + 0.687 \bar{X}_2|_3 = -9.352(0.145) + 0.687(2.208) = 0.424$$

Ahora para encontrar K_0 se sustituye en la fórmula:

$$K_0 = -\frac{n_1 \bar{Z}|_1 + n_2 \bar{Z}|_2 + n_3 \bar{Z}|_3}{n}$$

por lo que al calcular se tiene:

$$\begin{aligned} K_0 &= -\frac{n_1 \bar{Z}|_1 + n_2 \bar{Z}|_2 + n_3 \bar{Z}|_3}{n} \\ &= -\frac{6(0.880) + 6(1.000) + 6(0.424)}{6 + 6 + 6} \end{aligned}$$

Así la constante sería:

$$K_0 = -0.768$$

El valor encontrado se sustituye en la ecuación lineal discriminante:

$$Z = K_0 + K_1 X_1 + K_2 X_2 = -0.768 - 9.352 X_1 + 0.807 X_2$$

⁴³ Como ya se mencionó, el término *escalar* se refiere a cualquier número o bien a un vector o matriz de dimensiones (1×1) .

Esta ecuación es la que sirve para pronosticar a los diferentes elementos de la muestra en los distintos grupos.

5.7.5 Contribución de las variables

Este punto sirve para indicar qué variable está ayudando más a discriminar o separar a los grupos que se tienen en la variable dependiente. Para obtenerlo hay 2 métodos, los cuales son:

1. Método de las F parciales.
2. Método de los pesos discriminantes estandarizados.

5.7.5.1 Método de las F parciales

Este método se explicó en el punto 5.7.2 “Prueba del modelo” de este mismo capítulo y, como se mencionó, se basa en el análisis de cada una de las variables, manteniendo constantes los efectos de las restantes. La F de la X_1 se encontró de la siguiente manera:

$$F_{\text{parcial}_{X_1}} = \frac{(1 - \Lambda_1)/(g - 1)}{\Lambda_1/(n - g)} = \frac{(1 - 0.240)/(3 - 1)}{0.240/(18 - 3)} = 23.726$$

La F de la X_2 se encontró de la misma forma y su valor es el siguiente:

$$F_{\text{parcial}_{X_2}} = \frac{(1 - \Lambda_2)/(g - 1)}{\Lambda_2/(n - g)} = \frac{(1 - 0.318)/(3 - 1)}{0.318/(18 - 3)} = 16.100$$

Mientras una variable tenga mayor F quiere decir que es más importante para discriminar. Además es necesario recordar que, para decidir qué variables discriminan más, éstas deben ser significativas;⁴⁴ al comparar ambos valores se tiene que 23.726 es mayor que 16.1, por lo que la variable *ingreso/inversión* (X_1) tiene una mayor F que la variable *activo/pasivo* (X_2), por lo que se concluye que la mejor variable para discriminar es la X_1 , la variable de *ingreso/inversión*.

5.7.5.2 Método de los pesos discriminantes estandarizados

Este método sólo se realizará para la función 1, puesto que ya se probó que es la única que sirve para discriminar. Los pesos discriminantes sirven para comparar los coeficientes de cada variable; sin embargo, para compararlos es necesario estandarizarlos, pues las variables pueden medirse en unidades distintas, lo cual dificulta su comparación; una vez efectuado esto, se puede concluir que mientras mayor sea el peso discriminante, más importante será la variable para discriminar.

Para jerarquizar las variables basándose en su importancia para discriminar, se considera exclusivamente la magnitud del peso, no su signo, ya que éste sólo refleja la relación de la variable positiva o negativa con el puntaje discriminante. Es importante recordar que este método requiere que las variables independientes no presenten problemas de multicolinealidad y considera la interacción entre ellas. La fórmula para estandarizar las constantes es la siguiente:

$$K_i^{std} = K_{R_i}(S_j) = K_{R_i} \sqrt{\frac{SS_i}{gl_i}}$$

donde la desviación estándar es:

$$S_i = \sqrt{\frac{SS_i}{gl_i}}$$

La estandarización se puede conseguir por medio de las SS dentro de los grupos o sin los grupos, ambos métodos se describen a continuación:

1. Las K estandarizadas al usar la SS dentro de cada grupo.

⁴⁴ Es decir las 2 variables sirven para discriminar, ya que en el punto 5.6.6 “Prueba del modelo” se rechazó la hipótesis nula para ambas variables.

Las sumas de cuadrados (SS) dentro de cada grupo, se calcularon cuando se encontró la matriz W , la cual se presenta a continuación:

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

La ecuación que sí sirve para discriminar es:

$$Z = -3.693 + 11.386X_1 + 0.659X_2$$

En el caso del problema presentado, las constantes estandarizadas serían encontradas como sigue.

Para la variable *ingreso/inversión* (X_1):

$$K_{X_1}^{std} = K_{R_{X_1}}(S_{X_1}) = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}}$$

por lo que:

$$K_{X_1}^{std} = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}} = 11.386 \sqrt{\frac{0.069}{6+6+6-3}} = 0.773$$

Para las variables *activo/pasivo* (X_2):

$$K_{X_2}^{std} = K_{R_{X_2}}(S_{X_2}) = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}}$$

por lo que:

$$K_{X_2}^{std} = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}} = 0.659 \sqrt{\frac{13.814}{6+6+6-3}} = 0.632$$

Como el valor de 0.773 es mayor que 0.632 se concluye que la variable *ingreso/inversión* es la mejor para discriminar o bien que dicha variable discrimina más que la de *activo/pasivo*.

Para saber cuánto aportan las variables en la discriminación de los grupos, se suman y se calcula el porcentaje basándose en dicha suma; el procedimiento se agrega en la siguiente tabla:

Tabla 5-32 Aportación de cada variable

	K^{std} de $SS_{1,2,3}$	Fracción	%
$X_1 =$	0.773	0.550	55.0
$X_2 =$	0.632	0.450	45.0
Total =	1.405	1	100

Primero se sumaron las K estandarizadas de ambas variables, posteriormente se dividió 0.773/1.405, lo que dio como resultado 0.550, dicho valor se multiplica por 100. Para la segunda variable se realizó el mismo procedimiento.

2. Las K estandarizadas al usar SS total.

La otra opción para encontrar la contribución de cada variable para discriminar es multiplicar cada peso discriminante por la desviación estándar de la muestra total de la variable a estandarizar.

Para calcular la desviación estándar es necesario encontrar las sumas de cuadrados (SS) totales, las cuales se calcularon al encontrar la matriz T , la cual se da a continuación:

$$T = \begin{bmatrix} 0.288 & 2.476 \\ 2.476 & 43.466 \end{bmatrix}$$

La ecuación que sí sirve para discriminar es:

$$Z = -3.693 + 11.386X_1 + 0.659X_2$$

Por lo que las constantes estandarizadas son las siguientes:

- Para la variable *ingreso/inversión* (X_1):

$$K_{X_1}^{std} = K_{R_{X_1}}(S_{X_1}) = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}}$$

por lo que:

$$K_{X_1}^{std} = K_{R_{X_1}} \sqrt{\frac{SS_{X_1}}{gl_{X_1}}} = 11.386 \sqrt{\frac{0.288}{18-1}} = 1.481$$

- Ahora, para la variable *activo/pasivo* (X_2):

$$K_{X_2}^{std} = K_{R_{X_2}}(S_{X_2}) = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}}$$

por lo que:

$$K_{X_2}^{std} = K_{R_{X_2}} \sqrt{\frac{SS_{X_2}}{gl_{X_2}}} = 0.659 \sqrt{\frac{43.466}{18-1}} = 1.053$$

Como el valor de 1.481 es mayor que 1.053 se concluye que la variable *ingreso/inversión* es la mejor para discriminar o bien que dicha variable discrimina más que la de *activo/pasivo*.

Si alguna constante es negativa, su K estandarizada va a ser negativa, pero el signo sólo indica la relación; para ver cuál variable es la que ayuda más a discriminar los grupos se deben obtener los valores absolutos de las K estandarizadas.

Ahora, para saber cuánto aporta cada una de ellas a la discriminación de los grupos se suman y se calcula el porcentaje basándose en dicha suma; el procedimiento se agrega en la siguiente tabla:

Tabla 5-33 Aportación de cada variable

	K std de SS_{total}	Fracción	%
$X_1 =$	1.481	0.584	58.4
$X_2 =$	1.053	0.416	41.6
Total =	2.534	1	100

Primero se sumaron las K estandarizadas de ambas variables, posteriormente se dividió 1.481/2.534, lo que da como resultado 0.584; dicho valor se multiplica por 100. Para la segunda variable se realizó el mismo procedimiento.

Se puede concluir que la variable que mejor discrimina o diferencia a un grupo de otro es la X_1 (*ingreso/inversión*) por su mayor K estandarizada.

5.7.6 Valoración predictiva del modelo

La validación es un paso que se aplicará únicamente con la ecuación 1, pues, como se observó, es la única que sirve para discriminar. La gráfica de los 3 grupos se presenta a continuación:




Figura 5-17 Grupos proyectados al eje Z.

Por lo que el eje Z se vería de la siguiente manera:




Figura 5-18 Eje Z para 3 grupos.

Paso 1. Obtención de las Z promedio.

Ahora se buscarán las Z promedio; por lo que la fórmula es la siguiente:

$$\bar{Z}|_{1,\dots,g} = K_0 + K_1 \bar{X}_1|_{1,\dots,g} + K_2 \bar{X}_2|_{1,\dots,g}$$

Con las constantes encontradas se tiene:

$$\bar{Z}|_{1,\dots,g} = -3.693 + 11.386 \bar{X}_1|_{1,\dots,g} + 0.659 \bar{X}_2|_{1,\dots,g}$$

donde los promedios del grupo 1 (empresas sanas) son los siguientes:

$$\bar{Z}|_1 = -3.693 + 11.386(0.304) + 0.659(4.604) = 2.796$$

Ahora, la Z promedio del grupo 2 $\bar{Z}|_2$ (empresas en quiebra):

$$\bar{Z}|_2 = -3.693 + 11.386(0.035) + 0.659(1.644) = -2.212$$

Y por último, la Z promedio del grupo 3 $\bar{Z}|_3$ (empresas con problemas):

$$\bar{Z}|_3 = -3.693 + 11.386(0.145) + 0.659(2.208) = -0.584$$

Es importante recalcar que las medias de cada grupo son con los 18 casos utilizados en la etapa de derivación. Las cuales quedarían de la siguiente manera:




Figura 5-19 Eje Z para 3 grupos.

Paso 2. Obtención de la Z crítica.

Para el cálculo de la Z crítica se toman los 2 primeros grupos del más negativo al más positivo; en este caso el grupo 2 (empresas en quiebra) y el 3 (empresas con problemas) y se obtiene la primer Z crítica. Posteriormente se toma el grupo que se encuentra en la parte media (grupo 3, empresas con problemas) y el último grupo de la derecha, el cual sería de las empresas sanas (grupo 1) y se calcula la segunda Z crítica, de acuerdo con caso que aplique: si los 2 grupos tienen igual n se debe obtener un promedio sencillo; si ambos grupos tienen n diferente deben obtener un promedio ponderado de acuerdo con las fórmulas antes mencionadas; por lo tanto las Z críticas quedan como sigue:

Se sabe que la Z crítica, que es la línea divisoria, queda de la siguiente forma:

$$n|_2 = n|_3$$

Por lo anterior, la Z crítica queda de la siguiente manera:

$$Z_c = \frac{(\bar{Z}|_2 + \bar{Z}|_3)}{2} = \frac{(-2.212 - 0.584)}{2} = -1.398$$




Figura 5-20 Obtención de Z crítica para los grupos 2 y 3.

El siguiente paso es obtener la Z crítica entre el grupo 3 y el 1. Se sabe que la Z crítica, que es la línea divisoria, queda de la siguiente forma:

$$n|_3 = n|_1$$

Por lo anterior, la Z crítica queda de la siguiente manera:

$$Z_c = \frac{(\bar{Z}|_3 + \bar{Z}|_1)}{2} = \frac{(-0.584 + 2.796)}{2} = -1.106$$




Figura 5-21 Obtención de Z crítica para el grupo 1 y 3.

Paso 3. Obtención de los puntajes y asignación a un grupo.

Para este paso es necesario utilizar los casos no seleccionados en la etapa de derivación y que fueron separados para la etapa de validación, los cuales son los siguientes:

Tabla 5-34 Datos para validar en discriminante múltiple

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
1	Sana	1	0.345	4.817534
10	Quiebra	2	0.00102	1.987328
12	Sana	1	0.039	1.275376
16	Quiebra	2	0.0043	1.053163
23	Problemas	3	0.178	2.761
24	Problemas	3	0.154	1.65


Para obtener el valor de la Z para cada una de las empresas es necesario tener la ecuación lineal discriminante de Fisher, la cual sería:

$$Z = K_0 + K_1X_1 + K_2X_2 = -3.693 + 11.386X_1 + 0.659X_2$$

Al sustituir en la ecuación los valores de la empresa 1 se tiene:

$$Z_1 = -3.693 + 11.386(0.345) + 0.659(4.817) = 3.408$$

Dicho valor se compara con las Z críticas, las cuales están en el eje Z , lo cual se muestra en la siguiente gráfica:

**Figura 5-22** Puntaje de la empresa 1.

Al concluir se tiene que la empresa 1 se estimó en el grupo 1 como una empresa sana; el mismo procedimiento se realiza para cada una de las restantes empresas que se dejaron para la etapa de validación, dichas observaciones son 30% de los datos que se separó de la muestra al principio del estudio. Los resultados para los elementos fueron los siguientes:

Tabla 5-35 Empresas (30% de los datos)


Empresas	Resultado	Grupo real	X_1	X_2	Z o puntaje
			$R_{I,I}$	$R_{A,P}$	
1	Sana	1	0.345	4.817	3.408
10	Quiebra	2	0.001	1.987	-2.373
12	Sana	1	0.039	1.275	-2.409

(continúa)

Tabla 5-35 Empresas (30% de los datos) (continuación)

Empresas	Resultado	Grupo real	X_1	X_2	Z o puntaje
			$R_{i,I}$	$R_{A,P}$	
16	Quiebra	2	0.0043	1.053	-2.950
23	Problemas	3	0.178	2.761	0.152
24	Problemas	3	0.154	1.65	-0.853

Al comparar los valores en la gráfica del eje Z se tiene lo siguiente:

**Figura 5-23** Puntaje de las empresas.

En los 6 casos que se presentan podemos observar que la empresa 1 se encuentra en el grupo 1 y se pronosticó en el mismo grupo, por lo que la clasificación fue correcta; la compañía 10 se encuentra en el grupo 2 y se estimó en el mismo grupo, por lo que el pronóstico fue correcto; la empresa 12 está en el grupo 1 y se clasificó en el 2 de forma incorrecta; la empresa 16 se encuentra en el grupo 2 y se pronosticó en el 2, por lo que en ésta se acertó; la empresa 23 está en el grupo 3 y se predijo en el mismo grupo, por lo que la clasificación fue correcta y por último la compañía 24 se encuentra en el segmento 3 y se pronosticó en el mismo grupo, por lo que la asignación es acertada. Esto indica que de los 6 casos, sólo 1 se clasificó de forma incorrecta. Todo lo anterior fue puesto en la siguiente tabla:

Tabla 5-36 Empresas (30% de los datos)

Empresas	Resultado	Grupo real	Z o puntaje	Grupo pronosticado	Clasificación	Clasificación	Clasificación
1	Sana	1	3.408	1	Correcta	✓	☺
10	Quiebra	2	-2.373	2	Correcta	✓	☺
12	Sana	1	-2.409	2	Incorrecta	✗	☹
16	Quiebra	2	-2.950	2	Correcta	✓	☺
23	Quiebra	3	0.152	3	Correcta	✓	☺
24	Quiebra	3	-0.853	3	Correcta	✓	☺

El puntaje discriminante (Z_i) de cada empresa permite asignar la observación al grupo correspondiente (1: empresa sana, 2: empresa en quiebra o 3: empresa con problemas financieros), es decir, ayuda a la asignación al grupo que se está pronosticando.

Paso 4. Matriz de clasificación o confusión.

Con la información encontrada se construye la matriz de clasificación, ésta se utiliza a manera de resumen de los datos reales contra los pronosticados, dicha matriz con los resultados del ejemplo⁴⁵ se presenta a continuación.

⁴⁵ Si desea saber cómo completar la matriz, puede consultar la sección "Tipos de discriminante" que se encuentra en este capítulo.

Tabla 5-37 Matriz de clasificación

			Grupo pronosticado		
			1	2	3
			Empresa sana	Empresa en quiebra	Empresa en problemas
Grupo real	1	Empresa sana	1	1	0
	2	Empresa en quiebra	0	2	0
	3	Empresa en problemas	0	0	2

La diagonal de esta matriz se forma por las clasificaciones correctas hechas por el modelo.

Paso 5. Porcentaje de clasificaciones correctas.

Porcentaje de clasificaciones correctas. Medida de la confiabilidad o seguridad que existe al pronosticar y que se obtiene con los datos empleados en la etapa de validación.

El **porcentaje de clasificaciones correctas** es una medida de la confiabilidad o seguridad que existe al pronosticar, el cual se obtiene con los datos utilizados en la etapa de validación;⁴⁶ la fórmula para la obtención de los datos del ejemplos es:

$$\%C_c = \frac{\sum ECC}{\sum n|g} 100 = \frac{1 + 2 + 2}{2 + 2 + 2} 100 = 83.33\%$$

Esto indica que se tendría una seguridad de 83.33% de hacer algún pronóstico correcto.

Paso 6. Porcentaje de clasificaciones correctas en oposición al mínimo.

El porcentaje de clasificaciones mínimas aceptables indica lo mínimo que tolera el modelo; para calcularlo con el ejemplo se necesita la matriz de confusión, a la cual se le anexaron los totales por columna y renglón:

Tabla 5-38 Matriz de clasificación con los totales

			Grupo pronosticado			Total
			1	2	3	
			Empresa sana	Empresa en quiebra	Empresa en problemas	
Grupo real	1	Empresa sana	1	1	0	2
	2	Empresa en quiebra	0	2	0	2
	3	Empresa en problemas	0	0	2	2
Total			1	3	2	6

Para calcular el mínimo porcentaje es necesario utilizar los datos totales reales de los grupos, por lo que para los 3 grupos se tendría:

$$\%C_M = \left[\left(\frac{n|_1}{n} \right)^2 + \left(\frac{n|_2}{n} \right)^2 + \left(\frac{n|_3}{n} \right)^2 \right] * 100$$

Al sustituir la información del ejemplo quedaría como sigue:

$$\%C_M = \left[\left(\frac{2}{6} \right)^2 + \left(\frac{2}{6} \right)^2 + \left(\frac{2}{6} \right)^2 \right] * 100 = 33.33\%$$

Dicho porcentaje sirve para compararse con el porcentaje de clasificaciones correctas por medio de una prueba de hipótesis, la cual se presenta a continuación:

⁴⁶ El SPSS™ indica 2 porcentajes pues encuentra los puntajes para 100% de los datos y acomoda la información en 2 matrices; obtiene también 2 porcentajes que calcula con el número de datos de cada etapa, es decir, 70% de los datos para la derivación y 30% de los datos para la validación.

$H_0: \pi_{C_C} = \pi_{C_M}$: la proporción de clasificaciones correctas es igual que la proporción de clasificaciones mínimas.

$H_a: \pi_{C_C} > \pi_{C_M}$: la proporción de clasificaciones correctas es mayor que la proporción de clasificaciones mínimas.

En esta parte, lo que interesa es que el porcentaje de clasificaciones correctas sea mayor que el mínimo para poder pronosticar.

Para realizar la prueba de hipótesis, es necesario encontrar la proporción media:

$$\hat{p} = \frac{n_{C_C} \bar{P}_{C_C} + n_{C_M} \bar{P}_{C_M}}{n_{C_C} + n_{C_M}} = \frac{6(0.8333) + 6(0.3333)}{6 + 6} = 0.5833$$

Ahora se calcula el estadístico, el cual sería el siguiente:


$$Z_C = \frac{(\bar{P}_{C_C} - \bar{P}_{C_M}) - (\pi_{C_C} - \pi_{C_M})_{H_0}}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_{C_C}} + \frac{1}{n_{C_M}} \right)}}$$

Al usar los datos del ejemplo se tiene que:

$$Z_C = \frac{(0.8333 - 0.3333) - (0)}{\sqrt{0.5833(1 - 0.5833) \left(\frac{1}{6} + \frac{1}{6} \right)}} = 1.757$$

Ahora el estadístico calculado (Z_C) se compara con el estadístico teórico (Z_t), es importante recordar que el análisis se realiza con 95% de confianza, por lo que la Z_t se debe encontrar de la siguiente manera; utilizar 95% de confianza indica que en la tabla acumulada se debe encontrar el 0.95, el cual está entre 0.9495 y 0.9505, esto se muestra en la siguiente tabla:

Tabla 5-39 Tabla Z



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8929	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9087	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9316
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767

Ahora bien, se ve que el valor de Z está en el renglón encontrado en la tabla anterior, el cual es 1.6 y, al subir por ambas columnas, se observa que los valores son 0.04 y 0.05, ambos se deben sumar al 1.64, lo cual daría:

$$Z_t = \frac{(1.6 + 0.04) + (1.6 + 0.05)}{2} = 1.645$$

A continuación el estadístico calculado (Z_C) se compara con el teórico (Z_t); se sabe que:

$$Z_C > Z_t \text{ se rechaza la } H_0$$

por lo que:

$$1.757 > 1.645$$

No se rechaza la H_0 y se concluye entonces que ambos porcentajes no son iguales, por lo que sí es bueno utilizar la ecuación para pronosticar, ya que el $\%C_C$ es mayor que el $\%C_M$.

Paso 7. Verificar estadísticamente la predicción y la clasificación real.

Bajo la hipótesis de:

H_0 : la relación entre lo predicho y lo real no existe, es decir, son independientes, por lo que no hay evidencia de que la discriminación sea correcta.

H_a : la relación entre lo predicho y lo real sí existe, es decir, son dependientes, por lo que sí existe evidencia de discriminación, entonces es correcta, lo que indicaría que sí se logra discriminar.

Es importante mencionar que la variable dependiente (Y) siempre debe tener relación con la variable pronosticada ($\bar{Y}$), ya que si no tiene dependencia se está pronosticando de forma aleatoria o incorrecta.

Para esta prueba es necesario utilizar la ji cuadrada de Pearson:

$$\chi^2_C = \sum \frac{(fo_{ij} - fe_{ij})^2}{fe_{ij}}$$

Primero se requieren calcular las frecuencias esperadas de la matriz de clasificación, la cual se muestra a continuación:

Tabla 5-40 Totales de los grupos

			Grupo pronosticado			Total
			1	2	3	
			Empresa sana	Empresa en quiebra	Empresa en problemas	
Grupo real	1	Empresa sana	1	1	0	2
	2	Empresa en quiebra	0	2	0	2
	3	Empresa en problemas	0	0	2	2
Total			1	3	2	6

La frecuencia esperada se busca por medio de la siguiente fórmula:

$$fe_{ij} = \frac{\text{Total de renglones} * \text{Total de columna}}{\text{Total de datos en la muestra}}$$

La frecuencia esperada de la primera casilla, es decir de renglón 1 con la columna 1, se calcula con los totales del renglón y de la columna, por lo que:

$$fe_{1,1} = \frac{1 \cdot 2}{6} = 0.5$$

El proceso continúa para cada una de las casillas, los resultados de esto se presentan en la siguiente tabla:

Tabla 5-41 Frecuencia esperada y observada

			Grupo pronosticado			Total
			1	2	3	
			Empresa sana	Empresa en quiebra	Empresa en problemas	
Grupo real	1	Empresa sana	1, 0.333	1.1	0, 0.667	2
	2	Empresa en quiebra	0, 0.333	2, 1	0, 0.667	2
	3	Empresa en problemas	0, 0.333	0, 1	2, 0.667	2
Total			1	3	2	6

Ahora se encuentra la ji cuadrada calculada de Pearson, lo cual sería de la siguiente manera:

$$\chi_c^2 = \frac{(1-0.333)^2}{0.333} + \frac{(0-0.333)^2}{0.333} + \dots + \frac{(2-0.667)^2}{0.667} = 8.000$$

da como resultado:


$$\chi_c^2 = 8.000$$

El valor encontrado se compara con el estadístico teórico y como en el ejemplo se utiliza 5% como nivel de significancia, entonces:

$$\chi_{r, \alpha=0.5, (\# \text{ de renglones}-1)(\# \text{ de columnas}-1)=(3-1)(3-1)=4}^2 = 9.488$$

el cual se encontró de la siguiente manera:

Tabla 5-42 Tabla ji cuadrada⁴⁷



gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
1	0.455	0.708	1.074	1.642	2.706	3.841	5.024	5.412	5.916	6.635	7.879	10.828
2	1.386	1.833	2.408	3.219	4.605	5.991	7.378	7.824	8.399	9.210	10.597	13.816
3	2.366	2.946	3.665	4.642	6.251	7.815	9.348	9.837	10.465	11.345	12.838	16.266
4	3.357	4.045	4.878	5.989	7.779	9.488	11.143	11.668	12.339	13.277	14.860	18.467
5	4.351	5.132	6.064	7.289	9.236	11.070	12.833	13.388	14.098	15.086	16.750	20.515
6	5.348	6.211	7.231	8.558	10.645	12.592	14.449	15.033	15.777	16.812	18.548	22.458
7	6.346	7.283	8.383	9.803	12.017	14.067	16.013	16.622	17.398	18.475	20.278	24.322

(continúa)

⁴⁷ Ver anexo 3.1, tabla ji cuadrada.

Tabla 5-42 Tabla ji cuadrada (continuación)

gl	0.50	0.40	0.30	0.20	0.10	0.05	0.025	0.020	0.015	0.010	0.005	0.001
8	7.344	8.351	9.524	11.030	13.362	15.507	17.535	18.168	18.974	20.090	21.955	26.124
9	8.343	9.414	10.656	12.242	14.684	16.919	19.023	19.679	20.513	21.666	23.589	27.877
10	9.342	10.473	11.781	13.442	15.987	18.307	20.483	21.161	22.021	23.209	25.188	29.588
11	10.341	11.530	12.899	14.631	17.275	19.675	21.920	22.618	23.503	24.725	26.757	31.264


Para rechazar la H_0 es necesario que:

$$\chi^2_C > \chi^2_{t, \alpha, (r-1)(C-1)}$$

por lo que:

$$8.000 < 9.488 \text{ no se rechaza } H_0$$

O bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



Por lo tanto se acepta H_0 y se concluye que el porcentaje de clasificaciones correctas no evidencia una buena clasificación o discriminación; con esta prueba se concluyó que tanto la variable dependiente (Y) como la pronosticada ($\bar{Y}$) son independientes porque no tienen relación.

Es importante recordar que la cantidad de datos es muy reducida para que se pueda hablar de una prueba con validez estadística aceptable.

Como no se rechazó la hipótesis nula no tiene caso realizar el siguiente procedimiento, que se utiliza para saber cuál casilla es la que presenta diferencias significativas o para saber cuál de ellas evidencia una buena clasificación; esto se hace al analizar las celdas de la matriz a través de los residuales estandarizados, los cuales se calculan con la siguiente fórmula:

$$Z_{ij} = \frac{fo_{ij} - fe_{ij}}{\sqrt{fe_{ij}}}$$

Así en la casilla 1, es decir renglón 1 y columna 1, se tiene:

$$Z_{11} = \frac{1 - 0.333}{\sqrt{0.333}} = 1.155$$

El proceso continúa para cada una de las casillas, esto se resume en la siguiente tabla:

Tabla 5-43 Residuales estandarizados

			Grupo pronosticado		
			1	2	3
			Empresa sana	Empresa en quiebra	Empresa en problemas
Grupo real	1	Empresa sana	1.155	0.000	-0.816
	2	Empresa en quiebra	-0.577	1.000	-0.816
	3	Empresa en problemas	-0.577	-1.000	1.633

En la matriz anterior los residuales estandarizados son positivos y negativos. Un valor positivo indicaría que la frecuencia observada es mayor a la esperada significativamente, es decir:

$$fo_{ij} > fe_{ij}$$

Esto indica que se pronosticó más de lo que se esperaba y es lo ideal. Un valor negativo muestra que:

$$fo_{ij} < fe_{ij}$$

Esto indica que se pronosticó menos de lo que se esperaba y eso no es lo ideal.


Al aplicar lo anterior, los residuales estandarizados siempre deben ser positivos en la diagonal principal⁴⁸ y los restantes, es decir fuera de dicha diagonal, deberán ser negativos.

Los valores de los residuales estandarizados se tendrían que comparar con el estadístico Z de tablas o teórico; recuerde que el nivel de confianza que se utiliza en el ejemplo es 95%, por lo que se tendría:

$$\frac{0.95}{2} = 0.475$$

Al buscar ese valor en la tabla de la Z se tiene que:

Tabla 5-44 Tabla normal estándar



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.5	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.7	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
2.0	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.1	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.2	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.3	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.4	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936

Al sumar el 1.9 y el 0.06 da como resultado 1.96 y como ninguno de los valores que se calcularon supera el ± 1.96 , se concluye que las predicciones son aleatorias, independientemente del grupo al que las empresas pueden pertenecer realmente. Es importante recordar que la cantidad de datos es muy reducida para que se pueda hablar de una prueba con validez estadística aceptable.

A pesar de la falta de validez de la prueba, si se observan los residuales se ve de forma clara cómo sobre la diagonal se acentúan los valores mayores, lo cual habla de una tendencia a pronosticar una observación con más probabilidad en el grupo en el que realmente se encuentra y por lo tanto se podría hablar de un buen modelo para clasificar observaciones.

⁴⁸ La diagonal principal muestra que el real y el pronosticado coinciden, fuera de la diagonal prueba que no coinciden. Lo deseable es que lo real y lo pronosticado sean iguales.

5.8 Prueba *MdeBox* transformada a una *F*

En 1949, Box propuso un estadístico denominado *MdeBox*, el cual puede transformarse a una ji cuadrada o a una *F*; para realizarla es necesario tener al menos 2 grupos; se utiliza para probar el supuesto de homoscedasticidad en varianzas y covarianzas. El estadístico de prueba transformado a una *F* se muestra a continuación:

Ecuación 5-36 Estadístico de prueba *MdeBox* transformado a *F*

$$F_C = \frac{MdeBox}{B}$$

donde:

MdeBox : es el estadístico *MdeBox*, el cual se definirá más adelante

B : es la expresión matemática en la que se involucran grados de libertad

Las hipótesis de esta prueba serían:

$H_0: \Sigma_{i,j} = \Sigma_{i,i}$: las varianzas de las variables y las covarianzas entre variables son iguales o constantes, por lo que el supuesto de homoscedasticidad se cumple.

$H_a: \Sigma_{i,j} \neq \Sigma_{i,i}$: las varianzas de las variables y las covarianzas entre variables no son iguales o constantes, por lo que el supuesto de homoscedasticidad no se cumple, lo que implica que existe heteroscedasticidad.

donde:

$\Sigma_{i,j}$: es la covarianza de la variable *i* con la variable *j*

$\Sigma_{i,i}$: es la varianza de la variable *i*

Primero se obtienen las varianzas de cada grupo, para esto es necesario conocer la suma de cuadrados, los productos cruzados y promedios de las variables involucradas. En el grupo 1 el proceso sería el siguiente:

Tabla 5-45 Grupo 1

Empresas	Grupo	X_1	X_2	X_1^1	X_1^2	$X_1 * X_2$
		$R_{i,j}$	$R_{A,P}$			
2	1	0.243	3.9947	0.059	15.958	0.971
4	1	0.378	4.0362	0.143	16.291	1.526
7	1	0.18	4.87	0.032	23.717	0.877
9	1	0.22	3.635	0.048	13.213	0.800
11	1	0.47	3.567	0.221	12.723	1.676
14	1	0.33	7.523	0.109	56.596	2.483
		1.821	27.625	0.613	138.498	8.332
		$\Sigma X_{1 1}$	$\Sigma X_{2 1}$	$\Sigma X_{1^2 1}$	$\Sigma X_{2^2 1}$	$\Sigma X_1 X_{2 1}$
		0.304	4.604			
		$\bar{X}_{1 1}$	$\bar{X}_{2 1}$			

La suma de cuadrados de cada una de las variables debe calcularse de la siguiente manera:

$$\text{Suma de cuadrados de la } X_{i|j} = SSX_{i|j} = \sum_{i=1}^{n_j} X_i^2 - n_j \bar{X}_i^2$$

donde:

$SSX_{i|j}$: indica la suma de cuadrados de la variable i en el grupo j

$\sum_{i=1}^{n_j} X_i^2 - n_j \bar{X}_i^2$: indica la suma de cuadrados para la variable i en el grupo j

Para el grupo 1 y la variable X_1 quedaría de la siguiente forma:

$$SSX_1|_1 = \sum_{i=1}^{n_1} X_i^2 - n_1 \bar{X}_1^2$$

Al sustituir la información:

$$SSX_1|_1 = [0.613 - 6(0.304)^2] = 0.060$$

Ahora, para la variable X_2 se tendría:

$$SSX_2|_1 = \sum_{i=1}^{n_1} X_i^2 - n_1 \bar{X}_2^2$$

Al sustituir la información:

$$SSX_2|_1 = [138.498 - 6(4.604)^2] = 11.299$$

Posteriormente se obtiene la suma de los productos cruzados para la variable X_1 y X_2 :

$$\text{Suma de productos cruzados de } X_1 \text{ y } X_2|_j = SPX_1X_2|_j = \sum_{i=1}^{n_j} X_1X_2 - n\bar{X}_1\bar{X}_2$$

donde:

$SPX_1X_2|_j$: indica la suma de productos cruzados de la variable 1 con la variable 2 en el grupo j

$\sum_{i=1}^{n_j} X_1X_2 - n\bar{X}_1\bar{X}_2$: indica la suma de productos cruzados de la variable 1 con la variable 2 en el grupo j

Lo cual para el grupo 1, sería:

$$SPX_1X_2|_1 = SPX_1X_2|_1 = \sum_{i=1}^{n_1} X_1X_2 - n\bar{X}_1\bar{X}_2$$

Al sustituir la información:

$$SPX_1X_2|_1 = [8.332 - 6(0.304)(4.604)] = -0.053$$

La matriz $W|_1$ está representada por:

$$W|_1 = \begin{bmatrix} SSX_1 & SPX_1X_2 \\ SPX_1X_2 & SSX_2 \end{bmatrix}$$

Quedaría de la siguiente manera:

$$W|_1 = \begin{bmatrix} 0.060 & -0.053 \\ -0.053 & 11.299 \end{bmatrix}$$

Ahora cada elemento de la matriz se divide entre los grados de libertad, los cuales son $n_1 - 1 = 6 - 1 = 5$; a cada uno de los elementos promediados se les denomina *varianza y covarianzas*, las cuales son:

$$\bar{W}|_1 = \begin{bmatrix} \frac{0.060}{5} & \frac{-0.053}{5} \\ \frac{-0.053}{5} & \frac{11.299}{5} \end{bmatrix}$$

Entonces las varianzas serían:

$$\bar{W}|_1 = \begin{bmatrix} 0.012 & -0.011 \\ -0.011 & 2.260 \end{bmatrix}$$

De la misma manera se procede para cada uno de los grupos, los resultados del grupo 2 serían:

Tabla 5-46 Grupo 2

Empresas	Grupo	X_1	X_2	X_1^1	X_1^2	$X_1 * X_2$
		$R_{I,I}$	$R_{A,P}$			
3	2	0.05	2.778	0.003	7.717	0.139
5	2	0.04	1.256	0.002	1.578	0.050
6	2	0.05	1.377	0.003	1.896	0.069
8	2	0.04	1.143	0.002	1.306	0.046
13	2	0	1.225	0.000	1.501	0.000
15	2	0.03	2.083	0.001	4.339	0.062
		0.210	9.862	0.009	18.337	0.366
		$\Sigma X_{1 2}$	$\Sigma X_{2 2}$	$\Sigma X_{1 2}^2$	$\Sigma X_{2 2}^2$	$\Sigma X_{1 2} X_{2 2}$
		0.035	1.644			
		$\bar{X}_{1 2}$	$\bar{X}_{2 2}$			

La suma de cuadrados de cada una de las variables se resume a continuación, la variable X_1 :

$$SSX_{1|2} = \sum_{i=1}^{n_2} X_i^2 - n_1 \bar{X}_1^2 = [0.009 - 6(0.035)^2] = 0.002$$

La variable X_2 se tendría:

$$SSX_{2|2} = \sum_{i=1}^{n_2} X_i^2 - n_2 \bar{X}_2^2 = [18.337 - 6(1.644)^2] = 2.127$$

Posteriormente se obtiene la suma de los productos cruzados para la variable X_1 y X_2 :

$$SPX_1 X_2|_2 = [0.366 - 6(0.035)(1.644)] = 0.021$$

La matriz $W|_1$ queda de la siguiente manera:

$$W|_2 = \begin{bmatrix} 0.002 & 0.021 \\ 0.021 & 2.127 \end{bmatrix}$$

Ahora se obtienen las varianzas y covarianzas, es decir, se divide entre los grados de libertad, los cuales son $n - 1 = 6 - 1 = 5$; y quedan así:

$$\bar{W}|_2 = \begin{bmatrix} \frac{0.002}{5} & \frac{0.021}{5} \\ \frac{0.021}{5} & \frac{2.127}{5} \end{bmatrix}$$

Entonces las varianzas serían:

$$\bar{W}|_2 = \begin{bmatrix} 0.0004 & 0.004 \\ 0.004 & 0.425 \end{bmatrix}$$

Lo mismo para el grupo 3, lo cual sería:

Tabla 5-47 Grupo 3

Empresas	Grupo	X_1	X_2	X_1^1	X_1^2	$X_1 * X_2$
		$R_{i,j}$	$R_{A,P}$			
17	3	0.187	2.054	0.035	4.219	0.384
18	3	0.143	2.198	0.020	4.831	0.314
19	3	0.115	2.043	0.013	4.174	0.235
20	3	0.198	2.765	0.039	7.645	0.547
21	3	0.106	2.098	0.011	4.402	0.222
22	3	0.123	2.09	0.015	4.368	0.257
		0.872	13.248	0.134	29.639	1.960
		$\Sigma X_{1 3}$	$\Sigma X_{2 3}$	$\Sigma X_{1^2 3}$	$\Sigma X_{2^2 3}$	$\Sigma X_1 X_{2 3}$
		0.145	2.208			
		$\bar{X}_{1 3}$	$\bar{X}_{2 3}$			

La suma de cuadrados de cada una de las variables se resume a continuación, las variables X_1 :

$$SSX_1|_3 = \sum_{i=1}^{n_3} X_i^2 - n_1 \bar{X}_1^2 = [0.134 - 6(0.145)^2] = 0.007$$

La variable X_2 se tendría:

$$SSX_2|_3 = \sum_{i=1}^{n_3} X_i^2 - n_2 \bar{X}_2^2 = [29.639 - 6(2.208)^2] = 0.077$$

Posteriormente se obtiene la suma de los productos cruzados para las variables X_1 y X_2 :

$$SPX_1 X_2|_3 = [1.96 - 6(0.145)(2.208)] = 0.146$$

La matriz $W|_2$ queda de la siguiente manera:

$$W|_3 = \begin{bmatrix} 0.007 & 0.146 \\ 0.146 & 0.077 \end{bmatrix}$$

Ahora se obtienen las varianzas y covarianzas, esto es, se divide entre los grados de libertad, los cuales son $n_3 - 1 = 6 - 1 = 5$, y quedan:

$$\bar{W}|_3 = \begin{bmatrix} \frac{0.007}{5} & \frac{0.146}{5} \\ \frac{0.146}{5} & \frac{0.077}{5} \end{bmatrix}$$

Entonces las varianzas serían:

$$\bar{W}|_3 = \begin{bmatrix} 0.001 & 0.007 \\ 0.007 & 0.077 \end{bmatrix}$$

Ahora se busca la varianza intra o dentro de los grupos, la cual ya se había encontrado y es:

$$W = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Ahora bien, una manera sencilla de construirla, teniendo la matriz W de cada grupo, sería como se muestra a continuación:

$$W|_1 = \begin{bmatrix} 0.060 & -0.053 \\ -0.053 & 11.299 \end{bmatrix}, \text{ el 2 } W|_2 = \begin{bmatrix} 0.002 & 0.021 \\ 0.021 & 2.127 \end{bmatrix} \text{ y para el 3 } W|_3 = \begin{bmatrix} 0.007 & 0.146 \\ 0.146 & 0.077 \end{bmatrix}$$

Al sumar los grupos:

$$W_T = \begin{bmatrix} 0.060 + 0.002 + 0.007 & -0.053 + 0.021 + 0.146 \\ -0.053 + 0.021 + 0.146 & 11.299 + 2.127 + 0.077 \end{bmatrix}$$

entonces la matriz intragrupos sería:

$$W_T = \begin{bmatrix} 0.069 & 0.003 \\ 0.003 & 13.814 \end{bmatrix}$$

Luego es necesario dividir cada término entre los grados de libertad, los cuales son $n - g = 18 - 3 = 15$; a cada uno de los elementos promediados se les denomina varianzas y covarianzas, las cuales son:

$$\bar{W}_T = \begin{bmatrix} \frac{0.069}{15} & \frac{0.003}{15} \\ \frac{0.003}{15} & \frac{13.814}{15} \end{bmatrix}$$

Las varianzas y covarianzas serían:

$$\bar{W}_T = \begin{bmatrix} 0.0046 & 0.0002 \\ 0.0002 & 0.9209 \end{bmatrix}$$

Ahora se busca el estadístico de prueba *MdeBox*, su fórmula es la siguiente:

Ecuación 5-37 Estadístico de prueba *MdeBox*

$$MdeBox = (n - g) \ln |\bar{W}_T| - \sum_{j=1}^g (n_j - 1) \ln |\bar{W}_j|$$

donde:

MdeBox : es el estadístico de prueba *MdeBox*.

n : es el número de datos u observaciones de la variable que se está probando

g : es el número de grupos que se tienen en la variable

$\ln |\bar{W}_T|$: es el logaritmo natural del determinante de la varianza intragrupos o dentro de los grupos

n_j : es el número de observaciones en el grupo j

$\ln |\bar{W}_j|$: es el logaritmo natural del determinante de la varianza intergrupos o dentro de los grupos

Entonces a cada varianza se le encuentra el determinante y posteriormente el logaritmo natural del valor a cada uno de los determinantes, las operaciones se resumen en la siguiente tabla:

Tabla 5-48 Determinante y logaritmo de las varianzas

	Grupo	Matrices de varianzas y covarianzas		Determinante	Logaritmo natural
Intergrupos = $W_i =$	1	0.0120 -0.0105	-0.0105 2.2599	0.02694	-3.614
	2	0.0004 0.0042	0.0042 0.4254	0.00013	-8.939
	3	0.0015 0.0070	0.0070 0.0775	0.00007	-9.608
	Intragrupos = $W_T =$	0.0046 0.0002	0.0002 0.9209	0.00424	-5.463

Los resultados que el SPSS™ pone al respecto se muestran en la siguiente tabla:

Tabla 5-49 Resultados de los logaritmos

Logaritmo de los determinantes		
Empresa	Rango	Logaritmo del determinante
Sana	2	-3.614
Quiebra	2	-8.939
Problemas	2	-9.608
Intragrupos combinada	2	-5.463

Los rangos y logaritmos naturales de los determinantes impresos son los de las matrices de covarianzas de los grupos.

Ahora se busca el estadístico de prueba *MdeBox*, al sustituir la información encontrada se tiene que:

$$MdeBox = (18 - 3)(-5.463) - [(6 - 1)(-3.614) + (6 - 1)(-8.939)(6 - 1)(-9.6608)]$$

lo que da como resultado:

$$MdeBox = 28.864$$

El estadístico *MdeBox*, por carecer de distribución, debe transformarse a una ji cuadrada o a una *F*; este último proceso requiere que se calculen varias expresiones matemáticas en las que se involucren los grados de libertad, que son A_1 , A_2 , f_1 , f_2 y B ; dichas expresiones dependen del número de variables y del número de grupos que se tienen.

Como en este caso hay 3 grupos y 2 variables independientes entonces:

El número de grupos sería $g = 3$ empresas: sana, con problemas y quiebra.

El número de variables es $K = 2$, en este caso serían ingresos financieros/total inversiones y activo circulante/pasivo circulante.

Entonces A_1 sería encontrada de la siguiente manera:

Ecuación 5-38 Expresión matemática en la que se involucran grados de libertad

$$A_1 = 1 - \left(\frac{2K^2 + 3K - 1}{6(K + 1)(g - 1)} \right) \left(\sum_{j=1}^g \frac{1}{n_j - 1} - \frac{1}{n - g} \right)$$

donde:

K : es el número de variables independientes

g : es el número de grupos que se tienen en la variable

n_j : es el número de datos que se tienen en el grupo j

n : es el número de datos u observaciones de la variable que se está probando

Recuerde que hay 12 datos, 2 grupos y en cada uno de éstos 6 observaciones; entonces la forma para encontrar la expresión sería la siguiente:

$$A_1 = 1 - \left(\frac{2 \cdot 2^2 + 3 \cdot 2 - 1}{6(2 + 1)(3 - 1)} \right) \left(\frac{1}{5 - 1} + \frac{1}{5 - 1} + \frac{1}{5 - 1} - \frac{1}{18 - 3} \right) = 0.8074$$

Ahora cuando $K > 1$ se tiene que calcular $A_2 \neq 0$ y la forma para encontrar el valor sería:⁴⁹

Ecuación 5-39 Expresión matemática en la que se involucran grados de libertad

$$A_2 = \left(\frac{(K+1)(K+2)}{6(g+1)} \right) \left(\sum_{j=1}^g \frac{1}{(n|_j - 1)^2} - \frac{1}{(n-g)^2} \right)$$

donde:

K : es el número de variables independientes

g : es el número de grupos que se tienen en la variable

$n|_j$: es el número de datos que se tienen en el grupo j

n : es el número de datos u observaciones de la variable que se está probando

Recuerde que se tienen 18 datos, 3 grupos y en cada uno de éstos hay 6 observaciones; entonces la forma de encontrar la expresión sería la siguiente:

$$A_2 = \left(\frac{(2+1)(2+2)}{6(3+1)} \right) \left(\frac{1}{(6-1)^2} + \frac{1}{(6-1)^2} + \frac{1}{(6-1)^2} - \frac{1}{(24-3)^2} \right) = 0.0385$$

Se sabe que si $K > 1$ entonces f_1 , que son los grados de libertad del numerador, sale del número de grupos menos 1, esto es:

Ecuación 5-40 Grados de libertad del numerador

$$f_1 = \frac{1}{2}(K-1)g(g+1)$$

donde:

K : es el número de variables independientes

g : es el número de grupos que se tienen en la variable

Entonces el valor sería el siguiente:

$$f_1 = \frac{1}{2}(2-1)3(3+1) = 6$$

Como $K > 1$ entonces f_2 , que son los grados de libertad del denominador, serían calculados de la siguiente manera:

Ecuación 5-41 Grados de libertad del denominador

$$f_2 = \frac{f_1 + 2}{|A_2 - (1 - A_1)^2|}$$

donde:

f_1 : son los grados de libertad del numerador

A_2 : es la expresión matemática en la que se involucran grados de libertad

A_1 : es la expresión matemática en la que se involucran grados de libertad

⁴⁹ Cuando se tiene una sola variable las expresiones matemáticas que se utilizan para la transformación a la F son distintas; se sugiere revisar la sección 2.6 "Supuestos en los errores" del capítulo 2 "Análisis de regresión múltiple" para conocer más sobre este caso.

por lo que:

$$f_2 = \frac{6 + 2}{\left| 0.0385 - (1 - 0.8074)^2 \right|} = 5\,607.6923$$

Por último cuando $K > 1$ entonces B se calcula de la siguiente manera:

Ecuación 5-42 Expresión matemática que involucra los grados de libertad y forma parte de la F

$$B = \frac{f_2}{1 - A_1 + \frac{f_1}{f_2}}$$

donde:

f_2 : son los grados de libertad del denominador

f_1 : son los grados de libertad del numerador

A_1 : es la expresión matemática en la que se involucran los grados de libertad

Entonces el valor sería el siguiente:

$$B = \frac{f_2}{\left| 1 - A_1 + \frac{f_1}{f_2} \right|} = \frac{5\,607.6923}{\left| 1 - 0.8074 + \frac{6}{5\,607.6923} \right|} = 7.4411$$

El valor del estadístico de prueba, el cual es la transformación de la *MdeBox* a la F , se muestra a continuación:

Ecuación 5-42 Transformación de la *MdeBox* a la F

$$F_c = \frac{MdeBox}{B}$$

Las hipótesis de esta prueba serían:

$H_0: \Sigma_{i,j} = \Sigma_{i,i}$: las varianzas de las variables y las covarianzas entre variables son iguales o constantes, por lo que el supuesto de homoscedasticidad se cumple.

$H_a: \Sigma_{i,j} \neq \Sigma_{i,i}$: las varianzas de las variables y las covarianzas entre variables no son iguales o constantes, por lo que el supuesto de homoscedasticidad no se cumple, lo que implica que existe heteroscedasticidad.

donde:

$\Sigma_{i,j}$: es la covarianza de la variable i con la variable j

$\Sigma_{i,i}$: es la varianza de la variable i

Sigue encontrar el valor del estadístico de prueba, el cual es:


$$F_c = \frac{MdeBox}{B} = \frac{28.8642}{7.4411} = 3.879$$

El paso siguiente es encontrar el estadístico teórico o de tablas; como el estudio se realiza con 95% de confianza, con los grados de libertad del numerador y denominador se tiene que:

$$F_{t,\alpha=0.05,6,5\,608}$$

El valor se buscaría en la tabla F de la siguiente manera:

Tabla 5-50 Tabla F^{50}



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
200	0.100	2.748	2.347	2.130	1.9921	1.89	1.824	1.767	1.722	1.684	1.652	1.601	1.545	1.482	1.447	1.409
	0.050	3.920	3.072	2.680	2.447	2.290	2.175	2.087	2.016	1.959	1.910	1.834	1.750	1.659	1.608	1.554
	0.025	5.152	3.805	3.227	2.894	2.674	2.515	2.395	2.299	2.222	2.157	2.055	1.945	1.825	1.760	1.690
	0.010	6.851	4.787	3.949	3.480	3.174	2.956	2.792	2.663	2.559	2.472	2.336	2.192	2.035	1.950	1.860
	0.005	8.179	5.539	4.497	3.921	3.548	3.285	3.087	2.933	2.808	2.705	2.544	2.373	2.188	2.089	1.984
∞	0.100	2.705	2.303	2.084	1.945	1.847	1.774	1.717	1.670	1.632	1.599	1.546	1.487	1.421	1.383	1.342
	0.050	3.841	2.996	2.605	2.372	2.214	2.099	2.010	1.938	1.880	1.831	1.752	1.666	1.571	1.517	1.459
	0.025	5.024	3.689	3.116	2.786	2.566	2.408	2.288	2.192	2.114	2.048	1.945	1.833	1.708	1.640	1.566
	0.010	6.635	4.605	3.782	3.319	3.017	2.802	2.639	2.511	2.407	2.321	2.185	2.039	1.878	1.791	1.696
	0.005	7.879	5.298	4.279	3.715	3.350	3.091	2.897	2.744	2.621	2.519	2.358	2.187	2.000	1.898	1.789

Como los grados de libertad se encuentran muy alejados de 200, lo anterior indica que:

$$f_{t, \alpha = 0.05, 6, 5608} = 2.099$$


Recuerde que para rechazar la hipótesis nula se sabe que:

$$F_C > F_t$$

Al comparar los valores se tiene que:

$$3.879 > 2.099$$

Por lo que no se rechaza la hipótesis nula; o bien para rechazar la H_0 es necesario que el estadístico de prueba esté en la zona de rechazo:



⁵⁰ Vea anexo 2.3, tabla F.

Se concluye entonces que hay evidencia estadística para rechazar la H_0 , lo que significa que las matrices de varianzas y covarianzas no son las mismas, así que se puede afirmar que existe diferencia en las variaciones de los 2 grupos, por lo tanto se dice que hay heteroscedasticidad, de tal manera que el supuesto de homoscedasticidad no se cumple.

Es importante comentar que este estadístico es muy sensible al no cumplimiento de la no normalidad y a los tamaños de la muestra.

Los resultados que el SPSS[™] pone al respecto son:

Tabla 5-51 Estadístico *MdeBox* transformado a la *F*

Resultados de la prueba		
<i>MdeBox</i>		28.864
<i>F</i>	Aprox.	3.879
	<i>g</i> 11	6
	<i>g</i> 12	5 607.692
	Sig.	.001

Contrasta la hipótesis nula de que las matrices de covarianzas poblacionales son iguales.

Para realizar la prueba de hipótesis también se puede utilizar el *p*-valor, el nivel de confianza es de 95%; se sabe que para rechazar la hipótesis nula se debe cumplir que:

$$p\text{-valor (Sig.)} < \alpha$$

Al comparar el *p*-valor (Sig.) con el nivel de significancia se tiene que:

$$0.001 < 0.05 \text{ por lo tanto se rechaza } H_0$$

Como se rechaza H_0 se concluye que las matrices de varianzas y covarianzas no son las mismas; se puede afirmar que existe diferencia en las variaciones de los 2 grupos, por lo tanto se dice que hay heteroscedasticidad, es importante comentar que el estadístico es muy sensible al no cumplimiento de la no normalidad y a los tamaños de la muestra.

5.9 Interpretación de los resultados

La primera estrategia es tratar de actuar sobre la variable dependiente al manejar a las independientes (*ingreso/inversión* y *activo/pasivo*). Esto se realiza a través de la siguiente ecuación:

$$Z = -3.693 + 11.386X_1 + 0.659X_2$$

Por medio de las *F* parciales y las *K* estandarizadas se sabe que la variable X_1 es la que ayuda más a discriminar a los grupos, al ver la ecuación se puede notar que si la X_1 (*ingreso/inversión*) aumenta, crecerá a su vez el valor de la *Z*, ya que dicha variable tiene un signo positivo. Al analizar esto, ¿qué es lo que se desea hacer en realidad: ser una empresa sana, una empresa problemática o una empresa en quiebra?; sin duda la respuesta es una empresa sana; para lograrlo es necesario que las empresas estén en el grupo 1 (compañía sana).

Lo que se desea lograr es aumentar los valores de las *Z* para hacer que las empresas en quiebra o con problemas sean sanas o rentables, es decir, que tengan mayores ingresos con la inversión realizada. Esto se puede ver mejor en el eje *Z*, el cual se pone a continuación:




Figura 5-24 Empresa en quiebra, problemática o sana.

Se desea que todas las empresas sean sanas y para que estén en ese grupo es necesario que la Z tenga un valor grande, entre mayor sea, la empresa pasará al grupo 1.

De las 2 variables, la primera que se debe atender es la de *ingreso/inversión*, ya que tiene mayor importancia para discriminar entre los grupos, después podría hacerse alguna estrategia en cuanto a *activo/pasivo*, pero ya en un segundo plano de importancia; de igual manera, por su relación directa con Z (signo positivo), una empresa sana deberá tener más activos con una cantidad fija de pasivos.

Como en el ejemplo anterior no se encontraron diferencias significativas en los porcentajes se decidió incluir otro en el que sí existen desigualdades. Es importante aclarar que son datos completamente distintos al ejemplo que se estaba revisando en el capítulo.

Se tiene la siguiente matriz de clasificación, en la cual hay 3 grupos en la variable dependiente.⁵¹

Tabla 5-52 Matriz de clasificación de 4 grupos

Resultados de la clasificación ^{a,b}								
				Grupo de pertenencia pronosticado				
Casos no seleccionados	Original	Recuento	Grupos. Número de casos	Exigentes en servicio	Exigentes en capacidad	Exigentes en estrenos	Exigentes en capacidad y estrenos	Total
			Exigentes en servicio	101	0	1	0	102
			Exigentes en capacidad	0	24	0	0	24
			Exigentes en estrenos	4	0	75	0	79
			Exigentes en capacidad y estrenos	6	0	6	43	55
		%	Exigentes en servicio	99.0	.0	1.0	.0	100.0
			Exigentes en capacidad	.0	100.0	.0	.0	100.0
			Exigentes en estrenos	5.1	.0	94.9	.0	100.0
			Exigentes en capacidad y estrenos	10.9	.0	10.9	78.2	100.0

^a Clasificados correctamente: 93.7% de los casos agrupados originales seleccionados.

^b Clasificados correctamente: 93.5% de los casos agrupados originales no seleccionados.

Se utilizaron únicamente los no seleccionados, la información para realizar la prueba de independencia se muestra en la siguiente tabla cruzada que se realizó por medio del SPSSTM:

⁵¹ Estudio realizado sobre la exigencia de los alumnos de profesional, dicho estudio fue hecho en el 2008.

Tabla 5-53 Prueba de independencia de la ji cuadrada.

Pruebas de chi cuadrado			
	Valor	gl	Sig. asintótica (bilateral)
Chi cuadrado de Pearson	6.674E2	9	.000
Razón de verosimilitudes	530.086	9	.000
Asociación lineal por lineal	207.309	1	.000
N de casos válidos	260		

^a 2 casillas (12.5%) tienen una frecuencia esperada inferior a 5. La frecuencia mínima esperada es 2.22.

Las hipótesis para este análisis serían:

H_0 : la relación entre lo predicho y lo real no existe, es decir, son independientes, por lo que no hay evidencia de que la discriminación sea correcta.

H_a : la relación entre lo predicho y lo real sí existe, es decir, son dependientes, por lo que sí hay evidencia de que la discriminación es correcta.

Dicho estudio fue realizado con 95% de confianza, para rechazar la H_0 es necesario que:

$$p\text{-valor} < 0.05$$

Al escoger el p -valor de la ji cuadrada de Pearson se tiene que:

$$0.000 < 0.05 \text{ se rechaza } H_0$$

Como se rechazó la H_0 se concluye que la relación entre lo predicho y lo real sí existe, es decir, son dependientes, por lo que sí existe evidencia de que la discriminación sea la correcta.

En la tabla de contingencia, que se muestra a continuación, se ve cuáles grupos logran discriminar de forma significativa.

Tabla 5-54 Tabla de contingencia

Tabla de contingencia real*pronóstico							
			Pronóstico				
			Exigentes en servicio	Exigentes en capacidad	Exigentes en estrenos	Exigentes en capacidad y estrenos	Total
Real	Exigentes en servicio	Recuento	101	0	1	0	102
		Frecuencia esperada	43.5	9.4	32.2	16.9	102.0
		Residuos tipificados	8.7	-3.1	-5.5	-4.1	
	Exigentes en capacidad	Recuento	0	24	0	0	24
		Frecuencia esperada	10.2	2.2	7.6	4.0	24.0
		Residuos tipificados	-3.2	14.6	-2.8	-2.0	
	Exigentes en estrenos	Recuento	4	0	75	0	79
		Frecuencia esperada	33.7	7.3	24.9	13.1	79.0
		Residuos tipificados	5.1	2.7	10.0	-3.6	
	Exigentes en capacidad y estrenos	Recuento	6	0	6	43	55
		Frecuencia esperada	23.5	5.1	17.3	9.1	55.0
		Residuos tipificados	-3.6	-2.3	-2.7	11.2	
	Total	Recuento	111	24	82	43	260
		Frecuencia esperada	111.0	24.0	82.0	43.0	260.0

Ahora se revisan los residuos tipificados o estandarizados y como regla todos aquellos que sean superiores a 1.96 deben considerarse para su análisis:

$$|r_{i,j}| > 1.96$$

donde: $|r_{i,j}|$ es el valor absoluto del residuo estandarizado del renglón i con la columna j .

Como todos los valores de los residuales de la diagonal principal tipificados son mayores a 1.96 y fuera de la diagonal son menores a -1.96 , se concluye que la predicción que se realiza no es aleatoria, ya que hay dependencia entre lo pronosticado y lo real; entonces la predicción de discriminación en todos los grupos es bastante fuerte.

Como ya se dijo con anterioridad, cuando los residuales estandarizados sean mayores a 1.96 y sean positivos quiere decir que la frecuencia observada es significativamente mayor a la esperada y que los valores positivos que se encuentran en la diagonal principal de dicha matriz indican que se están prediciendo correctamente más de lo esperado, por lo que los pronósticos están siendo dados de forma adecuada. Un valor negativo muestra que lo observado es menor a lo esperado, si dichos valores se encuentran fuera de la diagonal principal (que es lo deseado) indican que se está equivocando menos de lo que se espera.

Como se mencionó, los residuales estandarizados siempre deben ser positivos en la diagonal principal⁵² y los restantes, es decir fuera de dicha diagonal, deberán ser negativos; pero siempre y cuando los valores de los residuales estandarizados sean significativos, es decir, fuera del rango de ± 1.96 .

5.10 Mapa territorial

Otro de los temas que el SPSSTM arroja es el mapa territorial; éste se construye con las puntuaciones que se calculan de las 2 primeras funciones que se generan en el discriminante múltiple; lo anterior indicaría que en el discriminante simple no se puede realizar debido a que solamente se genera una función y este mapa se grafica con las 2 primeras funciones.

El proceso para realizar el mapa territorial es el siguiente; recuerde que las funciones que se calcularon en este ejemplo del discriminante múltiple fueron las siguientes:

Función 1:

$$Z = -3.693 + 11.386X_1 + 0.659X_2$$

Función 2:

$$Z = -0.768 - 9.352X_1 + 0.807X_2$$

Ahora se calculan los puntajes en cada una de las funciones de cada uno de los elementos o datos y sus promedios⁵³ de la muestra que se usó para la etapa de derivación; por ejemplo, las empresas 11 y 13 y el centroide del grupo 3 tienen los siguientes valores en las variables:

Tabla 5-55 Datos escogidos

Empresas	Resultado	Grupo	X_1	X_2
			$R_{I,I}$	$R_{A,P}$
11	Sana	1	0.470	3.567
13	Quiebra	2	0.000	1.225
Promedios	Problemas	3	0.145	2.208

⁵² La diagonal principal muestra que el real y el pronosticado coinciden, fuera de la diagonal prueba que no coinciden. Lo deseable es que lo real y el predicho sean iguales.

⁵³ Los términos *centros*, *promedios* o *centroides de los grupos* son sinónimos.

Al sustituir los valores de la empresa 11 en las 2 funciones se tiene que:

Función 1:

$$Z_{11} = -3.693 + 11.386(0.47) + 0.659(3.567) = 4.008$$

Función 2:

$$Z_{11} = -0.768 - 9.352(0.47) + 0.807(3.567) = -2.283$$

Ahora se escogerá la empresa 13, los valores son los siguientes:

Función 1:

$$Z_{13} = -3.693 + 11.386(0.0) + 0.659(1.225) = -2.886$$

Función 2:

$$Z_{13} = -0.768 - 9.352(0.0) + 0.807(1.225) = 0.221$$

A continuación se calcula el promedio del grupo 3, los valores son los siguientes:

Función 1:

$$\bar{Z}|_3 = -3.693 + 11.386(0.145) + 0.659(2.208) = -0.584$$

Función 2:

$$\bar{Z}|_3 = -0.768 - 9.352(0.145) + 0.807(2.208) = -0.334$$

Dichos valores se grafican en 2 ejes, los cuales son cada una de las funciones; generalmente en el eje de las abscisas se encuentra la función 1 y en el eje de las ordenadas la función 2; la gráfica se presenta a continuación:




Figura 5-25 Empresas escogidas.

Para obtener el mapa es necesario encontrar los puntajes de todas las observaciones en las 2 funciones; los valores encontrados se presentan a continuación:

Tabla 5-56 Datos de derivación

Empresas	Resultado	Grupo	X_1	X_2	Z de la función 1	Z de la función 2
			$R_{I,I}$	$R_{A,P}$		
2	Sana	1	0.243	3.994	1.705	0.185
4	Sana	1	0.378	4.036	3.270	-1.044
7	Sana	1	0.18	4.87	1.564	1.481
9	Sana	1	0.22	3.635	1.206	0.110
11	Sana	1	0.47	3.567	4.008	-2.283
14	Sana	1	0.33	7.523	5.020	2.221
Promedios	Sana	1	0.304	4.604	2.796	0.112
3	Quiebra	2	0.05	2.778	-1.294	1.008
5	Quiebra	2	0.04	1.256	-2.410	-0.128
6	Quiebra	2	0.05	1.377	-2.217	-0.123
8	Quiebra	2	0.04	1.143	-2.485	-0.219
13	Quiebra	2	0	1.225	-2.886	0.221
15	Quiebra	2	0.03	2.083	-1.979	0.634
Promedios	Quiebra	2	0.035	1.644	-2.212	0.232
17	Problemas	3	0.187	2.054	-0.211	-0.858
18	Problemas	3	0.143	2.198	-0.617	-0.330
19	Problemas	3	0.115	2.043	-1.038	-0.194
20	Problemas	3	0.198	2.765	0.383	-0.387
21	Problemas	3	0.106	2.098	-1.104	-0.065
22	Problemas	3	0.123	2.09	-0.916	-0.230
Promedios	Problemas	3	0.1453	2.208	-0.584	-0.344

Por lo que la gráfica de los puntajes discriminantes sería la siguiente:




Figura 5-26 Tres grupos.

En la figura anterior cada uno de los grupos tiene diferente marcador o forma, así como los centros de los grupos. Ahora se ponen los ejes en las orillas para ver de mejor manera si los grupos están mezclados o no.




Figura 5-27 Con ejes movidos.

A continuación se separan los grupos por medio de líneas, esto se muestra en la siguiente figura.




Figura 5-28 Mapa de los 3 grupos.

El SPSS™ da el siguiente mapa territorial de los grupos:





Figura 5-29 Mapa del SPSS™ de los 3 grupos.

Lo anterior muestra que los grupos están bien definidos y bastante bien diferenciados, esto se puede ver más claramente en un mapa territorial, sobre todo cuando hay muchas variables y grupos formados; al ver la gráfica se puede notar que el SPSS™ define y etiqueta cada grupo con números lo cual se puede identificar fácilmente en la parte inferior del mapa; sin embargo, esta situación no siempre se presenta así, por lo que se ha anexado un ejemplo totalmente diferente con el que se trabajó a lo largo del capítulo.

Para comparar, se mostrará el mapa de un estudio realizado en el 2009 en escuelas secundarias, en donde hay 10 programas educativos diferentes; los resultados se muestran a continuación.



Símbolos usados en el mapa territorial

Símbolo	Grupo	Etiqueta
1	1	Grupo 1
2	2	Grupo 2
3	3	Grupo 3
4	4	Grupo 4
5	5	Grupo 5
6	6	Grupo 6
7	7	Grupo 7
8	8	Grupo 8
9	9	Grupo 9
0	10	Grupo 10
*		Indica un centroide de grupo

En seguida se recortará el mapa anterior para ampliarlo y ver de mejor forma los grupos:




Figura 5-31 Mapa territorial del SPSS™ recortado.

En el mapa anterior se puede ver que los grupos 2 y 10, que fueron etiquetados con 2 y 0, respectivamente, están encerrados y que los centroides (marcados con asteriscos) no se encuentran en los grupos; por ejemplo, el centroide del grupo 8 está en el grupo 10 y el grupo 1 tiene 2 centroides, mas aún el grupo 9 no está; lo anterior indica que varios grupos se encuentran muy mezclados y que en lugar de tener los 10, se tienen menos programas.

Como se pudo observar, este mapa fue muy diferente al que resultó del ejemplo de las empresas, pues a diferencia del primero, donde los 3 grupos estaban totalmente identificados y diferenciados, en este último ejemplo los grupos que originalmente se tenían resultaron canibalizados unos con otros, por lo que se recomienda generar una nueva agrupación.

5.11 Ejercicios de análisis discriminante

Problema 1

Supongamos que la compañía Piscinas Jain ha reunido datos de ingreso y tamaño de terreno de grupos de propietarios de piscinas y no propietarios, quienes viven en el sureste de Pennsylvania. Además hay datos disponibles para cada grupo sobre actitudes hacia los baños de sol, en escala de “0 = detestar los baños de sol” hasta “10 = extremadamente aficionado a tomar baños de sol”. Los datos se resumen a continuación.

Propietario de piscina	Ingreso (en miles de dólares)	Tamaño de lote (miles de pies ²)	Medida de actitud
(Grupo 1)	x_1	x_2	x_3
1	9.3	30.2	8
2	10.2	40.1	10
3	9.7	35.3	6
4	11.5	45.1	4
5	12	38	5
6	14.2	50.1	9
7	18.6	60.2	10
8	28.4	100.4	3
9	13.2	25.1	2
10	10.8	40.7	7
11	22.7	68.4	9
12	12.3	60.3	8

Propietario de piscina	Ingreso (miles de dólares)	Tamaño de lote (miles de pies ²)	Medida de actitud
(Grupo 2)	x_1	x_2	x_3
1	8.2	30.2	2
2	7.8	40.2	0
3	11.4	44.8	1
4	16.3	50.6	4
5	12.4	42.5	8
6	11.5	60.3	0
7	6.8	39.7	6

(continúa)

(continuación)

Propietario de piscina	Ingreso (miles de dólares)	Tamaño de lote (miles de pies ²)	Medida de actitud
(Grupo 2)	x_1	x_2	x_3
8	10.4	35.4	4
9	14.4	42.6	3
10	11.6	38.4	2
11	8.4	30.2	4
12	9.1	25.7	5

Con la ayuda del paquete estadístico SPSS™ se pide que conteste lo siguiente:

- ¿Se logró segmentar?
- Probar si el modelo es bueno para pronosticar.
- En qué grupo caería una persona con las siguientes características: Ingreso anual = \$12 000

Tamaño de terreno = 42 000 pies cuadrados

Actitud = 8

- ¿Cuál es la mejor variable para discriminar?

Problema 2

La firma de créditos de Maheswari y Rao, Inc. está interesada en el posible uso de análisis discriminante en la selección preliminar de solicitudes de crédito. De registros anteriores la compañía ha reunido información sobre 3 clases de adjudicatarios de créditos: *a)* riesgos malos, *b)* riesgos dudosos y *c)* buenos riesgos. También se tiene información adicional sobre una muestra de adjudicatarios de crédito que a continuación se presenta.

Riesgos malos	Ingreso anual (miles de dólares)	Tarjetas (núm.)	Edad (años)	Hijos (núm.)
1	9.2	2	27	3
2	10.7	3	24	0
3	8.9	1	32	2
4	11.2	1	29	4
5	9.9	2	31	3
6	10.7	4	29	1
7	8.6	3	28	1
8	9.1	0	31	5
9	10.3	5	26	2
10	10.5	4	30	3

Riesgos dudosos	Ingreso anual (miles de dólares)	Tarjetas (núm.)	Edad (años)	Hijos (núm.)
1	14.4	4	34	4
2	14.7	7	33	2

(continúa)

(continuación)

Riesgos dudosos	Ingreso anual (miles de dólares)	Tarjetas (núm.)	Edad (años)	Hijos (núm.)
3	13.6	3	41	1
4	10.3	1	37	1
5	14.9	6	39	0
6	15.8	5	37	3
7	16	4	36	5
8	11.2	2	35	3
9	12.6	8	36	2
10	14.7	3	29	4

Riesgos buenos	Ingreso anual (miles de dólares)	Tarjetas (núm.)	Edad (años)	Hijos (núm.)
1	18.6	7	42	3
2	17.4	6	47	5
3	22.6	4	41	1
4	24.3	5	39	0
5	19.4	1	43	2
6	14.2	12	46	3
7	12.7	8	42	4
8	21.6	7	48	2
9	26.4	5	37	3
10	19.4	9	51	1

Con esta información y con la ayuda del SPSS™ obtenga lo siguiente:

- Calcule las funciones lineales discriminantes para un análisis múltiple.
- ¿Se logró segmentar?
- ¿Qué variable o variables discriminan mejor entre los 3 grupos?
- Calcule el porcentaje de clasificaciones correctas.
- ¿El modelo es bueno para pronosticar?
- En caso de que el modelo sí sea bueno para pronosticar, ¿en qué grupo quedaría una persona con un ingreso de 18 mil dólares, 3 tarjetas, 50 años y 2 hijos?

Problema 3

El Instituto Nacional del Consumidor elabora un estudio sobre agua, para lo cual realizó una pequeña encuesta donde la escala era “1 = MI” (Muy importante) hasta “5 = NI” (Nada importante) pasando por “3 = Ind.” (Indiferente). La encuesta es la siguiente:

	MI	I	IND	PI	NI
1. ¿Qué tan importante es la <i>claridad del agua</i> ? (1a)					
2. ¿Qué tan importante es la <i>cantidad de sodio</i> ? (1b)					
3. ¿Qué tan importante es el <i>tamaño de la botella</i> ? (1c)					

Con la segmentación de mercados se encontró que a una parte de la población le importan los 3 aspectos y otra parte coincidió en que no le interesaban. Para comprobar lo anterior se tomaron respuestas de 5 personas entrevistadas con el fin de validar la segmentación.

Los datos son:

Grupo	Entrevista	Variable 1a	Variable 1b	Variable 1c
Acuerdo	1	1	1	3
Acuerdo	2	1	3	2
Acuerdo	5	4	2	4
Media		2	2	3
Desacuerdo	3	3	3	4
Desacuerdo	4	1	5	2
Media		2	4	3

Grupo acuerdo		
$\sum 1a = 6$	$\sum (1a)^2 = 18$	$(\sum 1a)^2 = 36$
$\sum (1a)(1b) = 12$	$\sum (1a)(1c) = 21$	$\sum (1b)(1c) = 17$
$\sum 1b = 6$	$\sum (1b)^2 = 14$	$(\sum 1b)^2 = 36$
$\sum 1c = 9$	$\sum (1c)^2 = 29$	$(\sum 1c)^2 = 81$

Grupo desacuerdo		
$\sum 1a = 4$	$\sum (1a)^2 = 10$	$(\sum 1a)^2 = 16$
$\sum (1a)(1b) = 14$	$\sum (1a)(1c) = 14$	$\sum (1b)(1c) = 22$
$\sum 1b = 8$	$\sum (1b)^2 = 34$	$(\sum 1b)^2 = 64$
$\sum 1c = 6$	$\sum (1c)^2 = 20$	$(\sum 1c)^2 = 36$

- a) Obtenga la ecuación discriminante que le ayudará a comprobar la verdadera existencia de 2 mercados.
- b) Suponga que la ecuación anterior haya sido:

$$Z = -1/8(1a) + 1/4(1b) + 1/6(1c)$$

Pruebe estadísticamente la existencia de los segmentos de mercado anteriormente establecidos.

- c) Supóngase que una persona contesta que le es importante la *claridad del agua*, muy importante la *cantidad de sodio* y no le es importante el *tamaño de la botella*. Si la ecuación discriminante fuera $Z = 1/4(1b)$, ¿en qué grupo clasificaría a esta persona?

Problema 4

El gerente del Laredo Nacional Bank desea tener una mejor percepción de las características de las familias que giran un número sustancial de cheques; esta información ayudaría al gerente en la toma de decisiones sobre publicidad y en el diseño de mejoras en las opciones ofrecidas por el banco a sus clientes; sin embargo, el gerente no desea ofrecer estas mejoras a todos los clientes. Se trata de caracterizar estadísticamente las familias que giran un número sustancial de cheques. Una muestra

aleatoria de 45 cuentas corrientes y una llamada telefónica a cada cuentahabiente revela la siguiente información.

Promedio de número de cheques por mes	Edad promedio del jefe de familia (x_1)	Ingreso promedio (x_2)	Tamaño promedio de la familia (x_3)	Datos
Arriba de 20	41.88	19.6	3.46	26
Debajo de 20	32.94	9.91	2.84	19

Al realizar el estudio con el paquete estadístico se obtuvo la siguiente ecuación:

$$Z = 0.05 x_1 + 0.2 x_2$$

1. Pruebe estadísticamente la diferencia entre los 2 segmentos propuestos.
2. Si tenemos a un jefe de familia con edad de 35 años, un ingreso doméstico de 4.0 y del cual depende una familia de tamaño 2, ¿cuántos cheques se espera que gire en un mes?
3. Si el banco desea dar el trato especial sólo a aquellos clientes que giren más de 20 cheques al mes, ¿qué rasgos se tomarían en cuenta para identificarlos?

Problema 5

Se dice que en la Universidad de Texas no existen maestros intermedios, es decir, o son buenos o son malos, por lo que se analizaron a 20 de ellos con base en su capacidad docente, su experiencia en el área de la materia y su conocimiento en la misma; todo esto en una escala de 1 a 5, donde 1 significa “bueno” y 5 “malo”, para ver si realmente se segmentaban de esta forma. Los resultados obtenidos se muestran a continuación:

Maestros	Opinión	Capacidad	Experiencia	Conocimiento
1	Bueno	1	1	1
2		1	2	1
3		1	1	1
4		2	1	2
5		1	1	1
6		3	2	1
7		1	1	1
8		1	1	1
9		2	1	1
10		2	3	1
11	Malo	3	4	3
12		4	5	5
13		4	5	2
14		5	4	5
15		5	4	2
16		5	5	4
17		5	5	3
18		5	5	5
19		4	5	4
20		4	4	5

Con el paquete estadístico SPSS™ conteste lo siguiente:

- Obtener el modelo discriminante.
- ¿Existen realmente 2 segmentos?
- ¿Cuál es la mejor variable para discriminar?
- ¿El modelo es bueno para pronosticar?

Problema 6

Una asociación internacional de países está interesada en generar un mecanismo para clasificar a las naciones en 2 grupos distintos: países desarrollados (grupo 1) y países subdesarrollados (grupo 2), para lo cual inició un estudio. Las variables que tomó en cuenta son la población en millones, el Producto Interno Bruto también en millones de dólares y el ingreso *per cápita* en miles de dólares.

La información de 8 países es la siguiente:

País	Grupo	Población (en millones de personas)	PIB (en millones de dólares)	Ingreso <i>per cápita</i> (en miles de dólares)
Italia	1	59	1.7	6.7
México	1	106	1.3	6.1
Nigeria	1	133	0.29	.90
Colombia	1	44	0.30	1.9
Japón	2	127	4.2	32.5
Estados Unidos	2	305	13.8	34.9
Inglaterra	2	60	2.13	24.2
Alemania	2	82	2.8	22.4

El análisis discriminante dio los siguientes resultados:

Prueba de igualdad de las medias					
	Lambda de Wilks	F	gl1	gl2	Sig.
Población	.848	.720	1	4	.444
PIB	.624	2.405	1	4	.196
Ingreso	.076	48.512	1	4	.002

Variables incluidas/eliminadas ^{a,b,c,d}									
Paso	Incluidas	Estadístico	Lambda de Wilks						
			gl1	glw2	gl3	Prueba F			
						Estadístico	gl1	gl2	Sig.
1	Ingreso	.076	1	1	4.000	48.512	1	4.000	.002
2	PIB	.050	2	1	4.000	28.651	2	3.000	.011

^a Número máximo de pasos *B*.

^b *F* mínima a incluir 1.

^c Máxima *F* para eliminar .99.

^d Insuficiente *F*.

Eigenvalores				
Función	Eigenvalor	% de varianza	% acumulado	Correlación canónica
1	19.101 ^a	100.0	100.0	.975

^a La primera función discriminante canónica fue usada en el análisis.

Lambda de Wilks				
Funciones de prueba	Lambda de Wilks	Ji cuadrada	df	Sig.
1	.050	9.002	2	.011

Coeficientes estandarizados de la función canónica discriminante	
	Función
	1
PIB	-.892
Ingreso	1.454

Coeficientes de la función canónica discriminante	
	Función
	1
PIB	-.201
Ingreso	.318
(Constante)	-4.802

Coeficientes no estandarizados.

Conteste lo siguiente:

- ¿Existe diferencia entre las medias de las variables?
- ¿Se comprueba la existencia de 2 grupos de países?
- ¿Cuál es la mejor variable para discriminar?
- ¿Qué pasó con la variable *población*?

Problema 7

El organismo público de la vivienda está interesado en conocer un modelo que le ayude a pronosticar a qué empleado otorgarle vivienda. Para lo cual utilizó los siguientes datos:

Otorgar vivienda	Edad promedio del jefe de familia x_1	Años cotizando x_2	Ingreso promedio de la familia x_3	Datos
Sí	54.1	18.7	24.6	35
No	24.3	8.7	14.7	15

Al realizar el estudio con el paquete estadístico se obtuvo la siguiente ecuación:

$$Z = 0.34x_1 - 0.12x_3$$

- Pruebe estadísticamente la diferencia entre los 2 segmentos propuestos.
- Si tenemos a un jefe de familia con edad de 41 años, con 15 años cotizando y un ingreso promedio por familia de 20, ¿se le otorgaría la vivienda?

Problema 8

Se realizó un estudio sobre empresas mexicanas y se logró agruparlas en 3 diferentes segmentos, empresas prósperas (grupo 1), empresas con ventas medianas (grupo 2) y empresas con problemas financieros (grupo 3). En cada grupo quedaron 5 empresas, se realizó un análisis discriminante y los resultados son los siguientes:

Estadísticas de grupos					
Grupos		Media	Desv. Std.	Datos	
				Sin peso	Peso
1.00	Ventas	306.0000	25.50817	4	4 000
	Empleados	510.0000	141.65686	4	4 000
	Producción	48.5000	8.26640	4	4 000
2.00	Ventas	246.7500	18.31893	4	4 000
	Empleados	285.0000	12.90994	4	4 000
	Producción	48.5000	1.29099	4	4 000
3.00	Ventas	132.5000	38.44043	4	4 000
	Empleados	155.0000	42.03173	4	4 000
	Producción	33.7500	5.67891	4	4 000
Total	Ventas	228.4167	79.55154	12	12 000
	Empleados	316.6667	171.64092	12	12 000
	Producción	43.5833	8.97935	12	12 000

Prueba de igualdad de medias					
	Lambda de Wilks	F	df1	df2	Sig.
Ventas	.106	37.879	2	9	.000
Empleados	.204	17.595	2	9	.001
Producción	.346	8.511	2	9	.008

Variables que entraron/eliminarona ^{b,c,d}									
Paso	Entraron	Estadístico	Lambda de Wilks						
			df1	df2	df3	Prueba F			
						Estadístico	df1	df2	Sig.
1	Ventas	.106	1	2	9.000	37.879	2	9.000	.000
2	Empleados	.062	2	2	9.000	12.025	4	16.000	.000
3	Producción	.037	3	2	9.000	9.740	6	14.000	.000

^a Número máximo de pasos 6.

^b Mínima *F* para entrar 1.

^c Máxima *F* para remover .99.

^d Insuficiente *F*.

Eigenvalores				
Función	Eigenvalores	% de varianza	% acumulado	Correlación canónica
1	9.271 ^a	85.2	85.2	.950
2	1.607 ^a	14.8	100.0	.785

^a Primeras 2 funciones discriminantes canónicas fueron usadas en el análisis.

Lambda de Wilks				
Prueba de función	Lambda de Wilks	Ji cuadrada	df	Sig.
1 Prueba F	.037	26.299	6	.000
2	.384	7.665	2	.022

Función		
	1	2
Ventas	1.099	.389
Empleados	.228	−1.223
Producción	−.457	1.008

Coeficientes de la función canónica discriminante		
	Función	
	1	2
Ventas	.038	.014
Empleados	.003	−.014
Producción	−.078	.173
(Constante)	−6.194	−6.100

Coeficientes no estandarizados.

Centroides por grupo por función		
Grupos	Función	
	1	2
1.00	3.106	−.859
2.00	.234	1.549
3.00	−3.340	−.690

Medias de los grupos de la función discriminante canónica estandarizada.

Estadísticos por caso											
Caso	Grupo actual	Grupo predicho	Pronósticos de grupo				Segundos pronósticos			Puntaje discriminante	
			$P(D > d \mid G = g)$		$P(G > g \mid D = d)$	Centroide de la distancia de Mahalanobis	Grupo	$P(G > g \mid D = d)$	Distancia de Mahalanobis al cuadrado al centroide	Función 1	Función 2
			p	gl							
Original 1	1	1	.065	2	1.000	5.473	2	.000	35.376	4.083	-2.985
2	1	1	.898	2	.996	.216	2	.004	11.205	2.936	-.427
3	1	1	.257	2	.701	2.714	2	.299	4.415	1.831	.184
4	1	1	.725	2	.999	.643	2	.001	14.251	3.575	-.208
5 ^u	1	2 ^{**}	.047	2	.998	6.108	1	.002	18.230	2.010	3.268
6	2	2	.995	2	.999	.010	1	.001	14.217	.281	1.638
7	2	2	.813	2	.999	.415	1	.001	14.313	.663	2.030
8	2	2	.565	2	.989	1.143	3	.011	10.092	-.766	1.172
9	2	2	.856	2	.994	.311	1	.006	10.431	.758	1.358
10 ^u	2	2	.948	2	.998	.106	1	.001	13.261	.131	1.240
11	3	3	.750	2	1.000	.576	2	.000	24.661	-3.900	-1.203
12	3	3	.627	2	1.000	.933	2	.000	25.231	-4.302	-.608
13	3	2 ^{**}	.131	2	.597	4.068	3	.403	4.851	-1.504	.526
14	3	3	.699	2	1.000	.717	2	.000	24.274	-3.654	-1.476
15 ^u	3	3	.448	2	1.000	1.605	2	.000	29.467	-4.127	-1.684

^u Caso no seleccionado.^{**} Caso mal clasificado.

Resultados de clasificación ^{a,b}							
			Grupos	Miembro del grupo predicho			Total
				1.00	2.00	3.00	
Casos seleccionados	Original	Núm. de casos	1.00	4	0	0	4
			2.00	0	4	0	4
			3.00	0	1	3	4
		%	1.00	100.0	.0	.0	100.0
			2.00	.0	100.0	.0	100.0
			3.00	.0	25.0	75.0	100.0
Casos no seleccionados	Original	Núm. de casos	1.00	0	1	0	1
			2.00	0	1	0	1
			3.00	0	0	1	1
		%	1.00	.0	100.0	.0	100.0
			2.00	.0	100.0	.0	100.0
			3.00	.0	.0	100.0	100.0

^a 91.7% de clasificaciones correctas de casos seleccionados.^b 66.7% de clasificaciones correctas de casos no seleccionados.

Se pide lo siguiente:

- ¿Existen realmente 3 tipos de empresas en México?
- ¿Cuál o cuáles variables entraron al modelo?
- ¿Cuál es la mejor variable para discriminar?
- ¿Cuál es el porcentaje de clasificaciones correctas?
- ¿Usarías este modelo para pronosticar?
- Si se obtuviera información de una empresa nueva donde se vende 190 pesos, tiene 450 empleados y una producción de 100 piezas armadas, ¿en qué grupo de empresas quedaría?

Problema 9

La Federación Mexicana de Fútbol está haciendo una selección de equipos para lo cual conoce que los equipos del 1 al 5 pasarán a la liguilla (grupo 1) y los equipos del 6 al 10 no pasarán (grupo 2); esto basado en las siguientes estadísticas.

Equipos	Goles promedio en cada partido	Tiros promedio a gol en cada partido
1	4	8
2	5	9
3	3	7
4	6	10
5	2	5
6	1	4
7	0	3
8	2	5
9	3	7
10	1	5

- Obtener las matrices A , T y W .
- Realizar la prueba de variables.
- Obtener los eigenvalores.
- Calcular las constantes de la ecuación.
- Probar si el modelo es bueno para discriminar.
- Probar si hay relación entre el dato pronosticado y el dato real, a partir de la matriz de clasificación.

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo 6

Análisis de varianza

2.832
2.935
2.95
2.959
2.968

Objetivo general:

Entender y aplicar los conceptos del análisis de varianza univariado y multivariado, en el área administrativa.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Describir con sus propias palabras la naturaleza general de la experimentación dentro del marco de un modelo de decisión dado.
- Estudiar la diferencia entre un experimento clásico y un experimento estadísticamente diseñado.
- Discutir la dificultad del control de un experimento y las diferencias entre los objetos prueba que se tratan en el área administrativa.
- Conocer los dos aspectos principales del diseño experimental.
- Describir con sus propias palabras en qué consiste la técnica análisis de varianza.
- Ilustrar, con un ejemplo del área administrativa, el significado del análisis de varianza.
- Explicar, a través de un ejemplo del área de administración o ciencias sociales, en qué consiste el análisis de varianza de un solo factor, indicando los supuestos estadísticos que se hacen en este tipo de análisis.
- Describir en qué consiste la prueba de Scheffé que se utiliza para probar la significancia de dos medias muestrales; usar un ejemplo administrativo en el que se involucre un análisis de varianza de un solo factor.
- Explicar con sus propias palabras en qué consiste la técnica de diseño factorial.
- Establecer el modelo matemático utilizado en el experimento factorial y explicar cada uno de los términos que aparecen en él.
- Aplicar el modelo del experimento factorial a un problema del área administrativa.
- Describir con sus propias palabras en qué consiste la técnica de cuadrados latinos y establecer el modelo matemático que le corresponde.
- Aplicar la técnica de cuadrados latinos en un problema del área administrativa.
- Definir con sus propias palabras en qué consiste la técnica de bloques al azar y establecer el modelo matemático correspondiente.
- Utilizar la técnica de bloques al azar en un problema del área de administración y ciencias sociales.
- Explicar con sus propias palabras en qué consiste el análisis de covarianza.
- Ilustrar a través de un ejemplo del área administrativa, la aplicación del análisis de covarianza y, especificar el modelo matemático correspondiente.
- Definir con sus propias palabras en qué consiste la técnica del análisis de varianza multivariado de un solo factor.
- Aplicar la técnica del análisis de varianza multivariado de un solo factor a un problema específico del área administrativa.

6.1 Antecedentes

Ronald Fisher fue innovador del uso de los métodos estadísticos en el diseño de experimentos (Montgomery, 1991). Durante algunos años estuvo a cargo de la estadística y el análisis de datos en una estación agrícola en Londres y fue ahí donde inició su aplicación. Fue él quien desarrolló y usó por primera vez el análisis de varianza como herramienta primaria para el análisis estadístico en el diseño experimental. Muchas de las primeras aplicaciones de los métodos del diseño experimental se dieron en el área de agricultura y ciencias biológicas; sin embargo, sus primeras aplicaciones industriales se hicieron en la década de 1930 en las industrias textil y de lana británica.

6.2 Áreas de aplicación

El análisis de varianza tiene una amplia aplicación en muchas disciplinas; su uso es muy importante para la mejora de procesos de manufactura, el desarrollo de nuevos procesos, el desarrollo de nuevos productos y la mejora de otros ya existentes.

El análisis de varianza descompone la variabilidad del resultado de un experimento en componentes independientes. Por ejemplo, se puede considerar la productividad de 3 máquinas compradas a un mismo proveedor que, aunque provienen de la misma empresa, pueden producir cantidades distintas de piezas. Esta variabilidad puede producirse por muchos factores controlables (ajuste de máquinas, presión ejercida, etc.), donde cada uno puede presentar diferentes niveles (ajuste de primer nivel, de segundo o cantidades distintas de presión), o bien por factores no controlables (clima, cansancio del operador, etcétera).

También es útil para conocer qué campaña publicitaria tiene más impacto en las ventas de algún producto, qué tipo de aprendizaje repercute en las calificaciones de los alumnos de ciertas carreras o cuál dieta ayuda a bajar más de peso. Se pueden modelar los fenómenos que surjan en los procesos productivos, procedimientos de manufactura, métodos de aprendizaje y sobre todo cuando a los individuos, servicios o productos se les aplican diferentes tratamientos como en medicina y psicología, entre otros usos.

6.3 Definición

Análisis de varianza. Técnica funcional que utiliza una o más variables independientes, todas ellas no métricas, y trata de explicar el comportamiento de una o más variables dependientes métricas.

El **análisis de varianza** es una técnica funcional que se emplea básicamente en la experimentación; esta técnica utiliza una o más variables independientes, todas ellas no métricas, y trata de explicar el comportamiento de una o más variables dependientes métricas.

En este tipo de técnicas o métodos se descompone el comportamiento de las variables dependientes en 3 o más variaciones, las cuales indican qué tanto se logró explicar dicho comportamiento. Es por ello que el análisis de varianza es el estudio de la variabilidad del resultado de un experimento y se puede dividir en 2 partes: una que se origina por los factores que influyen directamente en el resultado del experimento y otra que es producida por el resto de los factores que también influyen en el resultado del experimento con variabilidad no controlable, que se conoce como *error muestral*, el cual se explicará más adelante.

6.4 Diferenciación

El análisis de varianza se diferencia de otras técnicas porque:

1. La variable dependiente forzosamente es métrica y las independientes no métricas; aunque esto último puede variar.
2. Hay al menos 3 variaciones.
3. Se puede llevar a cabo bajo experimentación.

6.5 Etapas del análisis de varianza

El análisis de varianza está conformado por cinco etapas que son las siguientes:

1. Formulación del problema.
2. Selección de las variables.
3. Selección del tipo de análisis de varianza.
4. Análisis de la información.
5. Interpretación de los resultados.

Dichas etapas se muestran en la figura 6-1 que detalla los pasos a seguir.




Figura 6-1 Pasos del análisis de varianza.

Experimentación. Es un proceso para descubrir algo acerca de un sistema en particular.

Experimento. Es una prueba en la cual se inducen cambios en los datos de entrada para observar las causas de los cambios en los datos de salida.

Experimentos naturales. El investigador actúa como observador, sin poder seleccionar las unidades de prueba.

Experimentos controlados. El investigador puede manipular el medio en el que se lleva a cabo el experimento, así como a los participantes.

Diseño estadístico de experimentos. Es el proceso de planeación de un experimento que puede analizarse mediante métodos estadísticos con el objetivo de encontrar soluciones apropiadas.

Metodología estadística. Es el único enfoque objetivo que analiza problemas que involucren datos sujetos a errores experimentales.

Análisis de varianza univariado. Es un análisis de varianza cuyo objetivo es explicar una variable dependiente a partir de “ m ” variables independientes.

Análisis de varianza multivariado. Es un análisis de varianza cuyo objetivo es explicar “ n ” variables dependientes a partir de “ m ” independientes.

6.6 Experimentación

La **experimentación** es un proceso que se puede realizar en casi todas las áreas del conocimiento, se utiliza para descubrir algo acerca de un sistema en particular. Por otra parte, el **experimento** es una prueba o ensayo en el cual se inducen cambios en los datos de entrada para observar las causas de los cambios en los datos de salida.

Los experimentos pueden ser de dos tipos:

1. **Experimentos naturales.** El investigador solamente actúa como observador, sin poder seleccionar las unidades de prueba, o participantes del experimento, en forma aleatoria y mucho menos asignar las distintas circunstancias a analizar en el experimento.
2. **Experimentos controlados.** El investigador puede manipular el medio en el que se realiza el experimento, así como seleccionar, manejar y asignar en forma aleatoria a los participantes.

Para efectos de estudio, las referencias a experimentos se deberán entender como experimentos controlados.

El **diseño estadístico de experimentos** es el proceso de planeación de un experimento que puede analizarse mediante métodos estadísticos con el objetivo de encontrar soluciones apropiadas.

La **metodología estadística** es el único enfoque objetivo que analiza problemas que involucran datos sujetos a errores experimentales; existen 2 áreas en cualquier problema experimental: el diseño del experimento y el análisis estadístico.

6.7 Terminología

Antes de explicar los diferentes modelos, es necesario especificar una parte de la terminología universal:

- Cuando el objetivo de un análisis de varianza es explicar una variable dependiente a partir de “ m ” variables independientes, la técnica se llama **análisis de varianza univariado** y también se conoce como ANOVA o ANDEVA; es decir:

$$Y = f(X_1, X_2, \dots, X_m)$$

- Cuando el objetivo del análisis de varianza es explicar “ n ” variables dependientes a partir de “ m ” independientes, la técnica se llama **análisis de varianza multivariado** o MANOVA; en este caso sería:

$$Y_1, Y_2, \dots, Y_n = f(X_1, X_2, \dots, X_m)$$

- Los **factores o tratamientos** son las variables independientes del experimento; se llaman *factores* porque las variables independientes son características, y también se les conoce como *tratamiento* por la manipulación que se puede hacer de esas variables independientes para ver cómo afectan a la variable dependiente.
- Los **niveles de factor** son los valores que toman las variables independientes.
- Un **error muestral** es el error debido a la aleatoriedad en la selección de los elementos muestrales.

Las variables independientes deben ser no métricas, aunque hay excepciones que se explicarán más adelante. A dichas variables, como ya se dijo, se les denomina *factores* o *tratamientos* y a los valores de éstas se les llama **niveles**. Un ejemplo para explicar mejor lo anterior es saber si el tipo de figura en ciertos chocolates influye en las ventas, se tienen 4 figuras que se muestran a continuación.



Figura 6-2 Figuras de chocolate.

Para cada una de estas figuras se midieron las ventas, que se muestran en la siguiente tabla.

Tabla 6-1 Tabla de las ventas

			
50	58	47	63
55	47	44	60
40	45	37	50
48	52	49	53
52	40	49	45
45			

Como se ve en la tabla anterior, hay diferentes ventas en las 4 columnas. Las figuras son los valores de la variable independiente y también son los niveles del factor;¹ nótese también que en la primera columna hay 6 valores en las ventas mientras que en las demás sólo hay 5, por lo que se puede hablar de un caso desbalanceado; si sólo se deseara comparar las últimas 3 columnas se le denominaría *caso balanceado*.

Ahora se estudiarán las diferentes variantes que se pueden tener.

6.8 Tipos de modelos de análisis de varianza

Existen diferentes modelos de análisis de varianza, los cuales se analizarán en las siguientes secciones.

6.8.1 Análisis de varianza de un factor

El **análisis de varianza de un factor** se puede utilizar cuando se requiere analizar una respuesta cuantitativa, llamada comúnmente *variable dependiente*, medida en cierta condición experimental identificada por una variable categórica conocida como *variable independiente*.

6.8.2 Diseño factorial o de dos factores

Cuando se tienen dos factores con un número diferente de niveles y las interacciones entre ambos no son nulas se utiliza el **diseño factorial o de dos factores**.

6.8.3 Diseño aleatorizado por bloques

Al estudiar la influencia de un factor sobre una variable cuantitativa es frecuente que aparezcan otras variables o factores que también influyen y que se deben controlar. A estas variables se les denomina **variables bloque** y se caracterizan por no ser el motivo de estudio, sino que aparecen de forma natural y obligada y se asume que no tienen interacción con el factor que se estudia.

¹ Para el manejo de los niveles, el investigador decide en qué forma se deben codificar, es decir, debe darle valores numéricos a dichos niveles.

Factores o tratamientos. Son las variables independientes del experimento.

Niveles de factor. Son los valores que toman las variables independientes.

Error muestral. Es el error debido a la aleatoriedad en la selección de los elementos muestrales.

Niveles. Valores que poseen las variables.

Análisis de varianza de un factor. Analiza una variable dependiente medida en cierta condición experimental identificada por una variable independiente.

Diseño factorial o de dos factores. Modelo de análisis que se utiliza cuando se tienen dos factores con un número diferente de niveles y las interacciones entre ambos no son nulas.

Variables bloque. Variables que aparecen de forma natural y obligada sin interactuar con el factor que se estudia.

Diseño de tres factores. Diseño en el que se tienen tres factores con un número diferente de niveles y las interacciones entre ellos no son nulas.

Cuadrados latinos. Modelo que aprovecha la simetría del experimento factorial al seleccionar un conjunto de condiciones experimentales con la condición de que cada nivel de un factor aparezca una vez con cada uno de los niveles de los otros factores.

Cuadrado grecolatino. Aumento del número de factores bloque en la extensión del cuadrado latino.

Diseño por bloques incompletos. Técnica que se emplea cuando algunos experimentos que usan diseños por bloques no pueden realizar los ensayos o mediciones de todas las combinaciones de tratamientos dentro de cada bloque

Cuadrado de Youden. Técnica que permite dos fuentes experimentales de variabilidad y que es menos restrictiva que los cuadrados latinos.

Diseño reticular. Técnica que se realiza del mismo modo que un diseño de bloques incompleto y que se utiliza cuando hay muchas combinaciones de tratamientos.

Diseño factorial 2^2 . Técnica de análisis de varianza que sólo utiliza dos factores con dos niveles cada uno.

6.8.4 Diseño de tres factores

En el **diseño de tres factores** se tienen tres factores con un número diferente de niveles y las interacciones entre ellos no son nulas; algunas variantes de éstos se describen a continuación, es necesario tener K niveles, K^3 observaciones, lo cual dificulta mucho el análisis.

6.8.5 Cuadrados latinos

El nombre de *cuadrados latinos* se origina con Leonhard Euler, quien utilizó caracteres latinos como símbolos. Un diseño de experimentos completo de tres factores, todos ellos con K niveles, necesita K^3 observaciones, número elevado si K es grande. Un diseño más eficaz que sólo utiliza K^2 observaciones para el mismo problema es el de **cuadrados latinos**. Este modelo se basa en aprovechar la simetría del experimento factorial al seleccionar un conjunto de condiciones experimentales con la condición de que cada nivel de un factor aparezca una vez con cada uno de los niveles de los otros factores. Por tanto, el diseño de los cuadrados latinos se puede utilizar si se cumplen las siguientes condiciones:

1. Es un diseño de experimento con tres factores.
2. Los tres factores tienen el mismo número de niveles K .
3. No hay interacciones entre los tres factores.

6.8.6 Cuadrados grecolatinos

Si se aumenta el número de factores bloque, en la extensión del cuadrado latino se le denomina **grecolatino**, que permite con K^2 observaciones estudiar cuatro factores de K niveles sin interacciones (un factor-tratamiento y tres factores bloque); si se utiliza el diseño completo es necesario utilizar K^4 observaciones. Usa caracteres griegos, de ahí su nombre.

6.8.7 Diseño por bloques incompletos

Cuando algunos experimentos que usan diseños por bloques no pueden realizar los ensayos o mediciones de todas las combinaciones de tratamientos dentro de cada bloque, debido a la escasez en los recursos del experimento o por el tamaño físico de los bloques, se recurre al **diseño por bloques incompletos** para solucionar el problema.

6.8.8 Cuadrados de Youden

Esta técnica, al igual que cuadrados latinos, permite dos fuentes experimentales de variabilidad. Las condiciones para utilizar el **cuadrado de Youden** son menos restrictivas que en cuadrados latinos, ya que esta última técnica limita a que el número de renglones, columnas y tratamientos sea el mismo, en cambio en los cuadrados de Youden se debe tener el mismo número de columnas que de tratamientos, pero no de renglones.

6.8.9 Diseño reticular

El **diseño reticular** es una técnica que se realiza del mismo modo que un diseño de bloques incompleto y usualmente se utiliza en situaciones en las que existe un gran número de combinaciones de tratamientos.

6.8.10 Diseño factorial 2^2

El **diseño factorial 2^2** es una técnica de análisis de varianza que sólo utiliza dos factores con dos niveles cada uno.

6.8.11 Diseño factorial 2^k en dos bloques

Cuando la técnica de diseño factorial 2^2 necesita más de un bloque para su realización se recurre al **diseño factorial 2^k en dos bloques**.

6.8.12 Diseño factorial fraccionario de dos niveles

El diseño factorial fraccionario de dos niveles es un diseño con K factores con dos niveles que mantienen la propiedad de ortogonalidad entre los factores y donde se suponen nulas las interacciones de orden alto.

6.8.13 Diseño jerárquico o anidado

En el **diseño jerárquico** o **anidado** existen dos factores bloque que se dicen anidados cuando observaciones pertenecientes a dos niveles distintos de un factor bloque están automáticamente en dos niveles distintos del segundo factor bloque.

6.8.14 Diseño factorial $3k$

El **diseño factorial $3k$** es una variación del diseño 2^2 que consta de k factores con tres niveles cada uno.

6.9 Supuestos del análisis de varianza

Antes de introducir algunos de los tipos del análisis de varianza es necesario saber que, al igual que en cada técnica, aquí también se tienen supuestos, los cuales, son los dos siguientes:

$$\varepsilon \sim Niid(\mu = 0, \sigma^2 \text{ constantes})$$

Es decir, los errores deben seguir una distribución normal, idénticamente distribuidos, independientes, con un valor esperado (media) de cero y varianza desconocida pero constante; por inferencia de los errores, la distribución de la variable dependiente sería:

$$Y | X \sim Niid(\mu, \sigma^2 \text{ constantes})$$

Es lo mismo que los errores, pero se indica la distribución de Y dado que X . Para la mejor comprensión de lo anterior, a continuación se hace una descripción.

Cada una de las observaciones de la variable dependiente son independientes entre ellas; por ejemplo, las ventas de hoy no afectan a las de mañana.

1. Las fuentes de variación en el experimento deberán permanecer constantes o ser iguales, a esto se le conoce como **homoscedasticidad** u **homogeneidad de varianzas**.
2. Los datos deben distribuirse normalmente, para esto se sugiere hacer un histograma de los residuos. Dicha gráfica debe parecerse a una muestra extraída de una distribución normal. Otro procedimiento consiste en realizar una gráfica de probabilidad normal de los residuos, para su construcción los residuos deben colocarse en orden ascendente y graficar el k -ésimo de estos residuos ordenados contra su punto de probabilidad acumulada sobre la probabilidad normal. Si la distribución de los errores es normal, la gráfica será una línea recta.
3. Se supone que un **modelo aditivo** es el que mejor explica el comportamiento de la variable dependiente.

Si se tiene cuidado en el manejo de un mismo número de datos para cada uno de los niveles del factor, los supuestos mencionados se pueden considerar cubiertos aunque no se verifiquen. Como ya se dijo, al manejo del mismo número de datos en cada uno de los niveles del factor se le llama **caso balanceado**. Por último cabe mencionar que aunque el supuesto de homoscedasticidad no se cumpla puede realizarse este análisis, pero con sus variantes.

Diseño factorial 2^k en dos bloques. Técnica que se emplea cuando el diseño factorial 2^2 necesita más de un bloque para su realización.

Diseño factorial fraccionario de dos niveles. Diseño con K factores con dos niveles que mantienen la propiedad de ortogonalidad entre los factores y donde se suponen nulas las interacciones de orden alto.

Diseño jerárquico o anidado. Diseño en el que existen dos factores bloque anidados.

Diseño factorial $3k$. Variación del diseño 2^2 que consta de k factores con tres niveles cada uno.

Homoscedasticidad u homogeneidad de varianzas. Es cuando las fuentes de variación de un experimento son constantes o iguales.

Modelo aditivo. Es el que explica mejor el comportamiento de la variable dependiente.

Caso balanceado. Manejo del mismo número de datos en cada uno de los niveles del factor.

Si el lector desea saber cómo realizar una verificación de los supuestos, puede revisar el capítulo 2 “Análisis de regresión múltiple” en el cual se tratan más a fondo.

6.10 ANOVA de un solo factor

El modelo unifactorial se presenta cuando se tiene un solo factor con diferentes niveles, que influye sobre una variable dependiente que mide el resultado del experimento, es decir:

$$Y = f(X_1)$$

La hipótesis que se prueba en el análisis de varianza de un factor es que las medias poblacionales, esto es las medias de la variable dependiente en cada nivel de las variables independientes, son iguales. Si las medias poblacionales son iguales significa que el comportamiento de la variable dependiente es el mismo en las diferentes alternativas que se manejan en el experimento y que, por lo tanto, el factor es independiente de la variable dependiente, con lo cual se concluiría que el factor no afecta a la dependiente.

Para poner a prueba la hipótesis de igualdad de medias se debe obtener un estadístico llamado F que refleja el grado de diferencia entre las medias que se comparan.

Un ejemplo de un experimento para ANOVA de un factor podría ser el siguiente: explicar las ventas de una salsa por medio del color del envase. Se plantea una supuesta influencia del color del envase en las ventas, entonces:

$$\text{Ventas} = f(\text{color de envase})$$

Se tratará de probar esta relación sin considerar otras variables que también pudieron afectar las ventas; precisamente por esta razón se dice que es un experimento de un solo factor.

Problema de ANOVA de un factor

Se supone que se cuenta con los siguientes registros de ventas² para las presentaciones del envase en los 3 colores. Los 3 colores son los niveles del factor y el factor es el envase.

Tabla 6-2 Datos para utilizar ANOVA de un factor

Envase		
Azul	Rojo	Amarillo
77	88	85
82	94	85
86	93	87
78	90	81
81	91	80
86	94	79
77	90	87
81	87	93

Por medio de esta técnica se determina el grado de influencia que pueden tener los colores en las ventas, lo cual se hará al analizar las diferentes variaciones o desviación que se presentan en las ventas de los 3 colores del envase.

Antes de mencionar las variaciones, es necesario entender el arreglo que se debe hacer, el cual se muestra en la siguiente tabla.

² Datos generados para efecto del texto.

Tabla 6-3 Datos

Nivel 1	Nivel 2	Nivel 3	...	Nivel a
Y_{11}	Y_{21}	X_{31}	...	X_{a1}
Y_{12}	Y_{22}	X_{32}	...	X_{a2}
Y_{13}	Y_{23}	X_{32}	...	X_{a3}
...	...	...	Y_{ij}	...
Y_{1n}	Y_{2n}	X_{3n}	...	X_{an}

Donde:

a : el número de niveles del factor

n_i : el número de datos por nivel, en este caso se tienen “ n ” datos en cada nivel

Y_{ij} : cada una de las observaciones de la variable dependiente, dicho dato ocupa el j -ésimo lugar del nivel i de factor

Por ejemplo, Y_{23} indica que el dato ocupa el tercer lugar del nivel 2 del factor, ahora bien si se suman las observaciones y se promedia cada nivel se tendría lo siguiente.

Tabla 6-4 Suma y promedios

	Nivel 1	Nivel 2	Nivel 3	...	Nivel a
	Y_{11}	Y_{21}	X_{31}	...	X_{a1}
	Y_{12}	Y_{22}	X_{32}	...	X_{a2}
	Y_{13}	Y_{23}	X_{32}	...	X_{a3}
	...	...	...	Y_{ij}	...
	Y_{1n}	Y_{2n}	X_{3n}	...	X_{an}
Suma =	$Y_{1.}$	$Y_{2.}$	$Y_{3.}$		$Y_{a.}$
Media	$\bar{Y}_{1.}$	$\bar{Y}_{2.}$	$\bar{Y}_{3.}$		$\bar{Y}_{a.}$

$\bar{Y}_{i.}$: la suma de las observaciones de la variable dependiente para el nivel i del factor.

$\bar{Y}_{i.}$: el promedio del nivel i del factor.

Nótese que ahora esta nomenclatura tiene en el subíndice un punto, lo cual significa que se pasó por todos los valores; por ejemplo $Y_{3.}$ indica que se sumaron todas las observaciones del nivel 3; sin embargo, $\bar{Y}_{2.}$ significa que es el promedio del nivel 2 del factor, por lo que si se tuviera lo siguiente, $\bar{Y}_{.}$ quiere decir que es el promedio de todos los datos, es decir el promedio total.

Al hablar de variación se refiere a lo distinto o diferente que son los datos comparados con el promedio de los mismos. En ANOVA de un factor hay 3 tipos de variaciones a considerar:

1. **Variación total (SS_T).** Se refiere a lo distinto que son los datos, sin considerar que pertenecen a diferentes niveles del factor, es decir sin clasificarlos. Esta variación resulta de comparar cada dato con respecto al promedio general de los datos.

Variación total (SS_T).
Se refiere a lo distinto que son los datos sin clasificarlos.

Ecuación 6-1 Variación total

$$SS_T = \sum_{i=1}^a \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2$$

Donde:

Y_{ij} : el valor de cada dato

$\bar{Y}_{..}$: el promedio general de los datos, es decir $\Sigma Y / \text{núm. datos}$

Esta variación total se forma por la variación explicada y la variación no explicada.

Variación explicada (SS_B). Esta variación muestra lo distinto que son los datos y resulta de comparar cada promedio de cada nivel con el promedio general de los datos.

2. **Variación explicada (SS_B).** Se encuentra al comparar los datos de los diferentes niveles del factor, es decir, muestra lo distinto que son los datos debido a que pertenecen a diferentes colores de envase. Esta variación resulta de comparar cada promedio de cada nivel con el promedio general de los datos.

Ecuación 6-2 Variación explicada

$$SS_B = n_i \sum_{i=1}^a (\bar{Y}_{i.} - \bar{Y}_{..})^2$$

Donde:

n_i : el número de datos por nivel

$\bar{Y}_{i.}$: el promedio del nivel i del factor

$\bar{Y}_{..}$: el promedio general de los datos

Variación no explicada (SS_W). Es la diferencia de los datos dentro del mismo nivel de factor y es el resultado de la comparación de cada dato de cada nivel de factor con respecto a su correspondiente promedio de nivel de factor.

3. **Variación no explicada (SS_W).** Es la que existe entre los datos dentro del mismo factor y no se considera en el experimento; en el ejemplo son las variables diferentes al color del envase y por ello se le llama *no explicada*. Puede verse en lo distinto que son los datos dentro del mismo nivel de factor y es el resultado de la comparación de cada dato de cada nivel de factor con respecto a su correspondiente promedio de nivel de factor:

Ecuación 6-3 Variación no explicada

$$SS_W = \sum_{i=1}^a \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2$$

Donde:

Y_{ij} : el valor de cada dato

$\bar{Y}_{i.}$: el promedio del nivel i del factor

Así entonces:

$$SS_T = SS_B + SS_W$$

Generalmente, la mayoría de los software acomoda la información en una tabla denominada tabla ANOVA, la cual se presenta a continuación.

Cuadro 6-1 Fórmulas de definición ANOVA de un factor

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadrados medios (CM)	Prueba F
Variación explicada (SS_B)	$SS_B = n_i \sum_{i=1}^a (\bar{Y}_{i.} - \bar{Y}_{..})^2$	$a - 1$	$CM_B = \frac{SS_B}{a - 1}$	$F_c = \frac{CMB}{CMW}$
Variación no explicada (SS_W)	$SS_W = \sum_{i=1}^a \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2$	$N - a$	$CM_W = \frac{SSW}{N - a}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^a \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2$	$N - 1$		

El cuadro anterior presenta las fórmulas generales, pero en el siguiente cuadro se presentan las reducidas para el cálculo ANOVA de un factor.

Cuadro 6-2 Fórmulas de definición ANOVA de un factor

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadrados medios	Prueba F
Variación explicada (SS_B)	$SS_B = \sum_{i=1}^a \frac{y_i^2}{n_i} - N\bar{y}^2$	$a - 1$	$CM_B = \frac{SSB}{a - 1}$	$F_c = \frac{CMB}{CMW}$
Variación no explicada (SS_W)	$SS_W = \sum_{i=1}^a \left[\sum_{j=1}^{n_i} y_{ij}^2 - n_i \bar{y}_i^2 \right]$	$N - a$	$CM_W = \frac{SSW}{N - a}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij}^2 - N\bar{y}^2$	$N - 1$		

Donde:

a : número de niveles del factor

N : número total de datos

n_i : número de datos por nivel

$\bar{Y}_i$: media de cada nivel

$\bar{Y}..$: media total

Y_{ij} : cada una de las observaciones de la variable dependiente

Y_i : suma de las observaciones de la variable dependiente para el nivel i del factor

Entre mayor variación explicada se tenga, significa que la variable independiente afecta más a la dependiente; en este caso, las ventas se verían afectadas por el color del envase.

A continuación se obtiene toda la información necesaria para el cálculo de las variaciones para el problema de ANOVA de un factor.

Tabla 6-5 Datos para realizar ANOVA de un factor

	Azul	Rojo	Amarillo	
	77	88	85	
	82	94	85	
	86	93	87	
	78	90	81	
	81	91	80	
	86	94	79	
	77	90	87	
	81	87	93	Total
ΣY	648	727	677	2 052
ΣY^2	52 580	66 115	57 439	176 134
$\bar{Y}$	81	90.875	84.625	85.5

Una vez que se obtiene la información se calculan las variaciones.

$$SS_T = 176\,134 - 24 \left(\frac{2\,052}{24} \right)^2 = 688$$

$$SS_B = 8(81 - 85.5)^2 + 8(90.87 - 85.5)^2 + (84.62 - 85.5)^2 = 399.25$$

$$SS_{W_{\text{azul}}} = 52\,580 - 8(81)^2 = 92$$

$$SS_{W_{\text{rojo}}} = 66\,115 - 8(90.875)^2 = 48.875$$

$$SS_{W_{\text{amarillo}}} = 57\,439 - 8(84.625)^2 = 147.875$$

$$SS_W = 92 + 48.875 + 147.875 = 288.75$$

La $SS_T = SS_B + SS_W$ también se pudo obtener de la siguiente manera:

$$SS_W = SS_T - SS_B = 688 - 399.25 = 288.75$$

Además se sabe que: $a = 3$ y que $N = 24$; por lo que $a - 1 = 3 - 1 = 2$, además $N - 1 = 24 - 3 = 21$ y que $N - 1 = 24 - 1 = 23$.

A continuación se obtiene la F_c :

Cuadro 6-3 Obtención de F calculada para ANOVA de un factor

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F
SS_B	399.25	2	199.625	14.518
SS_W	288.75	21	13.75	
SS_T	688	23		

A continuación se realiza la prueba de hipótesis:

$H_0: \mu_1 = \mu_2 = \mu_3$: las ventas promedio son las mismas con los diferentes colores del envase, es decir, el factor color del envase no influye en las ventas promedio.

$H_a: \mu_1 \neq \mu_2 \neq \mu_3$: las ventas promedio no son las mismas con los diferentes colores del envase, es decir, el factor color del envase sí influye en las ventas promedio; o en al menos en 1 de los 3 colores de envases se obtiene diferentes ventas promedio.

Donde:


μ_i : es la venta promedio en el nivel i del factor

Si se realiza esta prueba con el ejemplo con un nivel de confianza de 95%, el estadístico de tablas sería:

$$F_{t, \alpha=0.05, a-1=3-1=2, N-a=24-3=21} = 3.467$$

El valor del estadístico teórico fue encontrado en la tabla F, la cual se encuentra en el anexo 2.2, tabla t; parte de la tabla y cómo encontrar el valor se muestra a continuación:


Tabla 6-6 Parte de la tabla F³



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
21	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719	1.689	1.657	1.623	1.586
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010	1.965	1.916	1.866	1.812
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	2.637	2.534	2.425	2.368	2.308	2.246	2.182	2.114	2.042
	0.010	8.017	5.780	4.874	4.369	4.042	3.812	3.640	3.506	3.398	3.310	3.173	3.030	2.880	2.801	2.720	2.636	2.548	2.457	2.360
22	0.005	9.830	6.891	5.730	5.091	4.681	4.393	4.179	4.013	3.880	3.771	3.602	3.427	3.243	3.147	3.049	2.947	2.841	2.730	2.614
	0.100	2.949	2.561	2.351	2.219	2.128	2.060	2.008	1.967	1.933	1.904	1.859	1.811	1.759	1.731	1.702	1.671	1.639	1.604	1.567
	0.050	4.301	3.443	3.049	2.817	2.661	2.549	2.464	2.397	2.342	2.297	2.226	2.151	2.071	2.028	1.984	1.938	1.889	1.838	1.783
	0.025	5.786	4.383	3.783	3.440	3.215	3.055	2.934	2.839	2.763	2.700	2.602	2.498	2.389	2.331	2.272	2.210	2.145	2.076	2.003
	0.010	7.945	5.719	4.817	4.313	3.988	3.758	3.587	3.453	3.346	3.258	3.121	2.978	2.827	2.749	2.667	2.583	2.495	2.403	2.305
	0.005	9.727	6.806	5.652	5.017	4.609	4.322	4.109	3.944	3.812	3.703	3.535	3.360	3.176	3.081	2.982	2.880	2.774	2.663	2.546

³ La tabla completa aparece en el anexo 2.3, tabla F.

Al realizar esta prueba se tiene que el estadístico de prueba cae en la zona de rechazo:



Como se rechazó la hipótesis nula se concluye que las ventas promedio no son las mismas en los diferentes colores de los envases o bien en al menos 1 de los 3 niveles se tiene diferente venta promedio, ahora bien, esta prueba también se podría realizar de otra forma. Se sabe que:

$$\text{Si } F_c > F_t \text{ se rechaza } H_0$$

Al comparar el estadístico de prueba con el teórico se tiene que:

$$14.518 > 3.467 \text{ por lo tanto se rechaza } H_0$$

Como se rechazó H_0 entonces se concluye que en al menos 1 de los 3 *colores de envases* se obtuvo diferente venta promedio.

6.10.1 Coeficiente de determinación

Coeficiente de determinación. Se utiliza para saber cuánto se logró captar o explicar del comportamiento de la variable dependiente.

El **coeficiente de determinación** se utiliza para saber cuánto se logró captar o explicar del comportamiento de la variable dependiente, la forma de calcularlo es:

Ecuación 6-4 Coeficiente de determinación

$$R^2 = \frac{SST - SSW}{SST} = 1 - \frac{SSW}{SST}$$

La información encontrada del ejemplo se resume en la siguiente tabla:

Cuadro 6-4 Tabla ANOVA

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F
SS_B	399.25	2	199.625	14.518
SS_W	288.75	21	13.75	
SS_T	688	23		

Por lo que el coeficiente de determinación sería el siguiente:

$$R^2 = 1 - \frac{288.75}{688} = 0.5803$$

Esto indica que se logró explicar a las ventas 58.03%.

6.10.2 Modelo general de ANOVA de un factor

El ANOVA de un solo factor asume que los datos de la variable dependiente están formados por tres elementos: el primero es un promedio general, por la naturaleza misma de la variable; el segundo es el efecto que pudieran tener los niveles del factor y el tercero todos los demás elementos que incidan en la variable dependiente y no se consideran en el experimento. Estos tres elementos dentro de un modelo aditivo se juntan y forman los datos de la variable dependiente; el modelo utilizado para representar lo anterior es:

$$Y_{ij} = \mu + \tau_j + \varepsilon_{ij}$$

Donde:

Y_{ij} : observación i de la variable dependiente medida bajo los efectos del nivel j del factor manejado en el experimento

μ : promedio general de la variable dependiente

τ_j : efecto del nivel j del factor manejado en el experimento

ε_{ij} : error de cada una de las observaciones de la variable dependiente

6.10.3 Seguimiento de la variable dependiente a través de otra técnica funcional

Como en el ANOVA de un factor se concluyó que el efecto del factor está presente en las ventas, se puede llevar esta conclusión a una técnica como la de la regresión para realizar un pronóstico de las ventas. Para construir la ecuación por medio matricial se usan los mínimos cuadrados⁴ y la forma de calcular los coeficientes de dicha ecuación es:

$$\tau = (X^T X)^{-1} (X^T Y) \text{ o bien por medio de } \tau = (X^T X)^{IG} (X^T Y)$$

Donde:

τ : vector de parámetros a estimar

X : la matriz de valores de la o las variables independientes

X^T : la matriz transpuesta de valores de la o las variables independientes

Y : vector que contiene los valores de la variable dependiente

$(X^T X)^{-1}$: el símbolo -1 indica la inversa

$(X^T X)^{IG}$: el símbolo IG indica la inversa generalizada⁵

De acuerdo con el ejemplo, la matriz X debe estar formada por valores de 1 y 0 para indicar en qué nivel de color de envase se encuentra la información, esto se muestra en la siguiente figura:

⁴ Este método se explicó de manera amplia en el capítulo 2 "Análisis de regresión múltiple".

⁵ A veces para poder encontrar la inversa es necesario que se realice por medio de la inversa generalizada, la cual se utiliza cuando se repite la información.

Nótese que la matriz X tiene una columna de unos al principio, esto con el fin de encontrar el estimador de τ_0 y además no se incluyó la columna para el color amarillo, debido a que la información se repetiría, por lo que el efecto en la ecuación de este color de envase se le deja a τ_0 . A continuación se pondrán los resultados de $(X^T X)$.

$$(X^T X) = \begin{bmatrix} 24 & 8 & 8 \\ 8 & 8 & 0 \\ 8 & 0 & 0 \end{bmatrix} \quad \text{además} \quad (X^T X)^{-1} = \begin{bmatrix} 0.125 & -0.125 & -0.125 \\ -0.125 & 0.25 & 0.25 \\ -0.125 & 0.125 & 0.125 \end{bmatrix}$$

$$(X^T Y) = \begin{bmatrix} 2052 \\ 648 \\ 727 \end{bmatrix} \quad \text{por lo que} \quad (X^T X)^{-1} (X^T Y) = \begin{bmatrix} 84.625 \\ -3.625 \\ 6.25 \end{bmatrix} = \begin{bmatrix} \hat{\tau}_0 \\ \hat{\tau}_1 \\ \hat{\tau}_2 \end{bmatrix}$$

La ecuación para estimar las ventas a través de los colores sería la siguiente:

$$\hat{Y} = 84.625 - 3.625 * \text{Azul} + 6.25 * \text{Rojo}$$

Los resultados que el SPSS™ arroja son:

Parámetro	B	Error típ.	t	Significación	Intervalo de confianza (95%)	
					Límite inferior	Límite superior
Intersección	84.625	1.311	64.549	.000	81.899	87.351
[Color=1]	-3.625	1.854	-1.955	.064	-7.481	.231
[Color=2]	6.250	1.854	3.371	.003	2.394	10.106
[Color=2]	0 ^b					

^a Calculado con alfa = .05.

^b Se le asigna el valor de cero al parámetro porque es redundante.

Figura 6-3 Resultados del SPSS™.

Al concluir que al menos un nivel es diferente se debe averiguar cuál es para saber en cuál de ellos se vende más. El estadístico F únicamente permite contrastar la hipótesis general de que los diferentes niveles comparados no son iguales, pero no permite precisar dónde se encuentran las diferencias detectadas, ya que es una prueba global.

6.11 Pruebas post-hoc

Para saber qué media difiere de otra se debe utilizar un tipo particular de contraste denominado **pruebas post-hoc**, *comparaciones múltiples*, o *comparaciones a posteriori*. Dichas pruebas se realizan únicamente cuando se detecta la influencia del factor en la variable dependiente, es decir, cuando se rechaza la hipótesis nula por medio de la prueba F.

Pruebas post-hoc.

Tipo particular de contraste que se emplea para saber qué media difiere de otra.

6.11.1 Prueba de intervalos múltiples de Duncan

La **prueba de intervalos múltiples de Duncan** se propuso en 1955; en ella las “r” medias muestrales se ordenan en forma creciente de magnitud y después se calculan las diferencias entre las medias muestrales adyacentes. Este método tiene un nivel de confianza superior o igual a $1 - \alpha$ con lo cual existen más posibilidades de juzgar erróneamente las diferencias significativas entre 2 medias que con la prueba de Tukey (del cual se hablará en seguida); sin embargo, desde un punto de vista práctico, resulta un método que discrimina más los factores que la prueba de Tukey.

Prueba de intervalos múltiples de Duncan.

Se ordenan las “r” medias muestrales en forma creciente de magnitud y después se calculan las diferencias entre las medias muestrales adyacentes.

6.11.2 Prueba de Tukey

Prueba de Tukey. Método que se basa en la construcción de intervalos de confianza de las diferencias por pares.

La prueba de Tukey (1953) de comparaciones múltiples se aplica cuando se quieren comparar todos los pares posibles de medias de todas las poblaciones. Cuando todos los tamaños muestrales son iguales, el nivel de confianza para esta prueba es $1 - \alpha$. Cuando los tamaños muestrales son diferentes, el nivel de confianza para todas las comparaciones por parejas es superior a $1 - \alpha$. La **prueba de Tukey** es conservador y proporciona estimaciones menos precisas, se basa en la construcción de intervalos de confianza de las diferencias por pares. Si estos intervalos incluyen al 0, entonces se acepta la hipótesis nula.

Mínimas diferencias significativas. Determina el valor mínimo necesario para que dos tratamientos se consideren diferentes y lo utiliza para comparar los pares de medias que se deseen evaluar.

6.11.3 Mínimas diferencias significativas

El método de **mínimas diferencias significativas** fue propuesto inicialmente por Fisher en 1935; determina el valor mínimo necesario para considerar diferentes a dos tratamientos y lo utiliza para comparar los diversos pares de medias que se deseen evaluar. Los pares de medias que se comparan son los que se planearon antes de ejecutar el experimento, por ello es una prueba para comparaciones planeadas. Es la diferencia entre dos medias basadas en la prueba *t* de *student*, se emplea el valor de la varianza del error.

Prueba de Newman-Keuls. Método ordena las “*r*” medias muestrales de forma decreciente según su magnitud y su nivel de significancia para cada conjunto de medias separadas “*r*” pasos es siempre α .

6.11.4 Prueba de Newman-Keuls

Este método fue diseñado por Newman en 1939 y Keuls, en 1952, generó un nuevo interés en ésta por ello el procedimiento se conoce como *prueba de Newman-Keuls*. Este método ordena las “*r*” medias muestrales de forma decreciente según su magnitud y su nivel de significancia para cada conjunto de medias separadas “*r*” pasos es siempre α . Cuantos más pasos hay entre dos medias mayor es la diferencia mínima necesaria para considerar que esas medias difieren significativamente. Esta prueba es similar a la prueba de Duncan que se estudiará más adelante, excepto que las diferencias críticas entre las medias se calculan de manera diferente.

Método Bonferroni. Técnica estadística que ajusta el nivel de significancia en relación con el número de pruebas estadísticas realizadas simultáneamente sobre un conjunto de datos.

6.11.5 Método Bonferroni

El **método Bonferroni** es la técnica estadística que ajusta el nivel de significancia en relación con el número de pruebas estadísticas realizadas simultáneamente sobre un conjunto de datos.

Método Sidak. Método basado en la distribución *t* de *student* que controla la tasa de error al evaluar cada comparación con un nivel de significancia

6.11.6 Método Sidak

El **método Sidak** fue propuesto en 1967, al igual que el de Bonferroni, se basa en la distribución *t* de *student*, pero controla la tasa de error al evaluar cada comparación con un nivel de significancia

$\alpha = 1 - (1 - \alpha)^{\frac{1}{k}}$. Esta solución es menos conservadora que el método de Bonferroni.

$\alpha = 1 - (1 - \alpha)^{\frac{1}{k}}$.

6.11.7 Método de R-E-G-W F

Método de R-E-G-W F. Se basa en la distribución *F*; es un método que no resulta apropiado cuando los grupos tienen datos diferentes o en un caso no balanceado.

El método de Ryan (1960), Einot-Gabriel (1975) y Welsch (1977) o **método de R-E-G-W F** se basa en la distribución *F* y se trata de un método por pasos: después de ordenar de forma ascendente las diferentes medias por su tamaño, se efectúan todas las comparaciones posibles entre los pares de medias teniendo en cuenta el número de escalones (*r*) que las separan: con diferentes (*j*) medias, la media más pequeña y la más grande están separadas $r = j - 1$ escalones; la media más pequeña y la tercera más grande están separadas $r = j - 2$ escalones; etc. 2 medias adyacentes tras la ordenación están separadas 2 escalones. El número de escalones existentes entre las medias comparadas condiciona el grado de significancia de cada comparación, éste es mayor cuanto más alejadas se encuentran las medias después de ser ordenadas. Es un método por pasos más potente que el de Duncan y la prueba de Newman-Keuls, pero no es apropiado cuando los grupos tienen datos diferentes o en un caso no balanceado.

6.11.8 Método de R-E-G-W Q

El método de Ryan (1960), Einot-Gabriel (1975) y Welsch (1977), o **método de R-E-G-W Q** se basa en la distribución del rango estudentizado. Se trata de un método por pasos que utiliza el mismo estadístico que la prueba de Newman-Keuls o la prueba de Tukey, pero controla el nivel de significancia de cada comparación del mismo modo que el método R-E-G-W F. Es un método por pasos más potente que el de Duncan y la prueba de Newman-Keuls, pero no resulta apropiado cuando los grupos poseen datos diferentes o en un caso no balanceado.

6.11.9 Método de GT2 de Hochberg

El **método GT2 de Hochberg** es un método muy similar a la prueba de Tukey, pero se basa en la distribución del módulo máximo estudentizado. Este método es menos potente que la de Tukey.

6.11.10 Método Gabriel

El **método Gabriel** también se basa en la distribución del módulo máximo estudentizado. Al aplicarlo en grupos del mismo tamaño, este método es más potente que el de Hochberg, pero con niveles con número de datos muy desiguales (o caso no balanceado) ocurre lo contrario.

6.11.11 Método Waller-Duncan

El **método Waller-Duncan** utiliza la distribución *t-student* y una aproximación bayesiana; si los tamaños muestrales son distintos utiliza la media armónica para calcular el estadístico *t*.

6.11.12 Método Dunnett

El **método Dunnett** es útil para comparar cada grupo con un grupo de control. Por tanto, controla la tasa de error para $k - 1$ comparaciones. En su diseño se considera que la última categoría del factor es la que define el grupo control, pero puede seleccionarse la primera categoría.

6.11.13 Prueba de Scheffé

La **prueba de Scheffé** se basa en la distribución F y permite controlar la tasa de error para el conjunto total de comparaciones que se pueden plantear con j medias. Se utiliza sólo para efectuar comparaciones por pares; es un método muy conservador.

Todos los métodos explicados se pueden utilizar cuando el supuesto de homoscedasticidad se cumple, pero en el caso de que no pueda asumirse dicho supuesto, es decir, que las varianzas poblacionales no sean iguales, se puede elegir alguno de los 4 métodos siguientes.

6.11.14 Método T2 de Tamhane

El **método T2 de Tamhane** es un método conservador basado en la distribución *t* que utiliza comparaciones por parejas.

6.11.15 Método T3 de Dunnett

El **método T3 de Dunnett** es una modificación propuesta por Dunnett al estadístico T2 de Tamhane y se basa también en comparaciones por parejas, utiliza la distribución del módulo máximo estudentizado.

6.11.16 Método Games-Howell

El **método Games-Howell** es similar a la prueba de Tukey. Realiza también comparaciones por parejas, se basa en la distribución del rango estudentizado y en un estadístico T en el que, tras estimar las varianzas poblacionales suponiendo que son distintas, se corrigen los grados de libertad mediante la

Método R-E-G-W

Q. Método que utiliza el mismo estadístico que la prueba de Newman-Keuls o la de Tukey, pero controla el nivel de significancia de cada comparación.

Método GT2 de Hochberg

berg. Método similar a la prueba de Tukey que se basa en la distribución del módulo máximo estudentizado.

Método Gabriel.

Método que se basa en la distribución del módulo máximo estudentizado.

Método Waller-Duncan.

Utiliza la distribución *t* de *student* y una aproximación bayesiana.

Método Dunnett.

Método que sirve para comparar cada grupo con un grupo de control pues controla la tasa de error para $k - 1$ comparaciones.

Prueba de Scheffé.

Se basa en la distribución F y permite controlar la tasa de error para el conjunto total de comparaciones que se plantean con j medias.

Método T2 de

Tamhane. Método conservador basado en la distribución *t* que utiliza comparaciones por parejas.

Método T3 de Dun-

nett. Modificación del estadístico T2 de Tamhane que utiliza la distribución del módulo máximo estudentizado.

Método Games-Howell. Se basa en la distribución del rango estudentizado y en un estadístico T en el que se corrigen los grados de libertad mediante la ecuación de Welch.

Método C de Dunnett. Es idéntico al de Games-Howell excepto en la forma de corregir los grados de libertad de la distribución del rango estudentizado.

ecuación de Welch. Éste es el método que mejor controla la tasa de error en diferentes situaciones, aunque no es conservador.

6.11.17 Método C de Dunnett

El **método C de Dunnett** es idéntico al de Games-Howell excepto en la forma de corregir los grados de libertad de la distribución del rango estudentizado. Esta solución es más conservadora que la del método Games-Howell.

A modo de resumen presentamos algunas de las pruebas de comparaciones múltiples clasificadas según la distribución estadística que utilizan en su cálculo.

Tabla 6-8 Resumen de las pruebas de comparaciones múltiples

Tipo de prueba	Nombre de la prueba
Basadas en la distribución <i>t</i>	Dunn-Bonferroni (Dunn, 1961).
	Dunn-Sidak (Dunn, 1958 y Sidak, 1967).
	Holm-Shaffer (Holm, 1979 y Shaffer, 1986).
Basadas en la distribución del rango estudentizado	Tukey (Tukey, 1953).
	Newman-Keuls (Newman, 1932 y Keuls 1952).
	Duncan (Duncan, 1955).
	Ryan (Ryan, 1960; Einot y Gabriel, 1975).
	Peritz (Peritz, 1970).
Basadas en la distribución F	Scheffé (Scheffé, 1953, 1959).
	F de Newman-Keuls.
	F de Ryan.
Basadas en una prueba <i>t</i> protegida	LSD de Fisher (Fisher, 1935).
	Shaffer-Ryan (Shaffer, 1979).
	Fisher-Hayter (Hayter, 1986).
Basadas en la comparación con un control	Dunnet (Dunnett, 1955).

¿Qué método usar?

Realmente no existe una respuesta a esta pregunta y muchos profesionales de la estadística no están de acuerdo en cuanto a la utilidad de estos procedimientos. El método de mínima diferencia significativa es una prueba muy eficiente para detectar diferencias verdaderas en las medias si se aplica hasta después que la prueba F del análisis de varianza ha sido significativa a 5%. También informan de un buen desempeño para detectar diferencias reales al usar la prueba de intervalos múltiples de Duncan. Esto no debe sorprender, ya que estos 2 métodos son los mejores que se han diseñado. La prueba de intervalos múltiples de Duncan también está disponible en muchos programas de computadoras para el análisis de varianza. Sin embargo no hay forma de establecer una prueba que resulte mejor que otra, pues eso dependerá del tipo de variables y estudio que se realice.

En este libro se verá únicamente la prueba de Scheffé, la cual se explica a continuación.

6.12 Prueba de Scheffé

La **prueba de Scheffé** busca determinar si la diferencia entre 2 promedios es lo suficientemente grande para considerarse diferentes. Esta prueba se dificulta cuando hay varios niveles porque se tienen que comparar todos los pares posibles de grupos. Para facilitar esto es preferible comenzar la prueba con aquella pareja de niveles cuya diferencia sea más pequeña y, de acuerdo con la conclusión, se probarían los siguientes pares. Si se encuentra diferencia en uno de ellos, por ir éstas de menores

Prueba de Scheffé. Busca determinar si la diferencia entre 2 promedios es lo suficientemente grande para considerarse diferentes.

a mayores, las siguientes diferencias a probar serían aún mayores que las primeras y por ello ya no se seguirían probando.

Es necesario que alguna de las pruebas de las diferencias de los pares rechace H_0 , es decir, que si hubo diferencia al concluir que el factor (al menos en uno de sus niveles) afectó a la variable dependiente.

La fórmula de F_C en esta prueba es:

$$F_C = \frac{\frac{(\mu_j - \mu_k)^2}{(a-1)}}{\frac{1}{SSW} * \frac{\frac{1}{n_j} + \frac{1}{n_k}}{(N-a)}} F_C = \frac{(\mu_1 - \mu_2)^2(a-1)}{SSW * (1/n_1 + 1/n_2)(N-a)}$$

Donde:

μ_j : promedio del nivel j

μ_k : promedio del nivel k

a : número de niveles en el factor

SSW : variación no explicada

n_j : número de datos del nivel j

n_k : número de datos del nivel k

N : total de datos en la variable dependiente

Con información del ejemplo acerca de si el *envase* del producto afectaba las *ventas* se realizó la siguiente tabla.

Tabla 6-9 Datos

	Envase		
	Azul	Rojo	Amarillo
	77	88	85
	82	94	85
	86	93	87
	78	90	81
	81	91	80
	86	94	79
	77	90	87
	81	87	93
Medias =	81	90.875	84.625

Las diferencias entre los promedios de los niveles por pares son las siguientes:

$$\text{azul-amarillo} = 84.625 - 81 = 3.625$$

$$\text{rojo-amarillo} = 6.25$$


$$\text{rojo-azul} = 9.875$$

Lo primero es aplicar la prueba de Scheffé al par con la diferencia menor, por lo que se compara la pareja azul-amarillo.

$H_0: \mu_{\text{azul}} = \mu_{\text{amarillo}}$ o bien, las *ventas promedio* con los *colores azul y amarillo* son iguales.

$H_a: \mu_{\text{azul}} \neq \mu_{\text{amarillo}}$ o bien no lo son.

Tabla 6-10 Parte de la tabla F⁶



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
21	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719	1.689	1.657	1.623	1.586
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010	1.965	1.916	1.866	1.812
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	2.637	2.534	2.425	2.368	2.308	2.246	2.182	2.114	2.042
	0.010	8.017	5.780	4.874	4.369	4.042	3.812	3.640	3.506	3.398	3.310	3.173	3.030	2.880	2.801	2.720	2.636	2.548	2.457	2.360
22	0.100	2.949	2.561	2.351	2.219	2.128	2.060	2.008	1.967	1.933	1.904	1.859	1.811	1.759	1.731	1.702	1.671	1.639	1.604	1.567
	0.050	4.301	3.443	3.049	2.817	2.661	2.549	2.464	2.397	2.342	2.297	2.226	2.151	2.071	2.028	1.984	1.938	1.889	1.838	1.783
	0.025	5.786	4.383	3.783	3.440	3.215	3.055	2.934	2.839	2.763	2.700	2.602	2.498	2.389	2.331	2.272	2.210	2.145	2.076	2.003
	0.010	7.945	5.719	4.817	4.313	3.988	3.758	3.587	3.453	3.346	3.258	3.121	2.978	2.827	2.749	2.667	2.583	2.495	2.403	2.305
23	0.100	2.937	2.549	2.339	2.207	2.116	2.048	1.996	1.955	1.921	1.892	1.847	1.799	1.747	1.719	1.690	1.659	1.627	1.592	1.555
	0.050	4.285	3.427	3.033	2.801	2.645	2.533	2.448	2.381	2.326	2.281	2.210	2.135	2.055	2.012	1.968	1.922	1.873	1.822	1.767
	0.025	5.773	4.370	3.770	3.427	3.202	3.042	2.921	2.826	2.750	2.687	2.589	2.485	2.376	2.318	2.259	2.197	2.132	2.063	1.989
	0.010	7.913	5.687	4.785	4.281	3.962	3.732	3.561	3.427	3.320	3.232	3.095	2.952	2.801	2.723	2.641	2.557	2.469	2.377	2.279
24	0.100	2.925	2.537	2.327	2.195	2.104	2.036	1.984	1.943	1.909	1.880	1.835	1.787	1.735	1.707	1.678	1.647	1.615	1.580	1.543
	0.050	4.273	3.415	3.021	2.789	2.633	2.521	2.436	2.369	2.314	2.269	2.198	2.123	2.043	2.000	1.956	1.910	1.861	1.810	1.755
	0.025	5.761	4.358	3.758	3.415	3.190	3.030	2.909	2.814	2.738	2.675	2.577	2.473	2.364	2.306	2.247	2.185	2.120	2.051	1.977
	0.010	7.881	5.655	4.753	4.249	3.930	3.700	3.529	3.395	3.288	3.199	3.062	2.919	2.768	2.690	2.608	2.524	2.436	2.344	2.246
25	0.100	2.913	2.525	2.315	2.183	2.092	2.024	1.972	1.931	1.897	1.868	1.823	1.775	1.723	1.695	1.666	1.635	1.603	1.568	1.531
	0.050	4.261	3.403	3.009	2.777	2.621	2.509	2.424	2.357	2.302	2.257	2.186	2.111	2.031	1.988	1.944	1.898	1.849	1.798	1.743
	0.025	5.749	4.346	3.746	3.403	3.178	3.018	2.897	2.802	2.726	2.663	2.565	2.461	2.352	2.294	2.235	2.173	2.108	2.039	1.965
	0.010	7.851	5.625	4.723	4.219	3.900	3.670	3.499	3.365	3.258	3.169	3.032	2.889	2.738	2.660	2.578	2.494	2.406	2.314	2.216
26	0.100	2.901	2.513	2.303	2.171	2.080	2.012	1.960	1.919	1.885	1.856	1.811	1.763	1.711	1.683	1.654	1.623	1.591	1.556	1.519
	0.050	4.249	3.391	2.997	2.765	2.609	2.497	2.412	2.345	2.290	2.245	2.174	2.099	2.019	1.976	1.932	1.886	1.837	1.786	1.731
	0.025	5.737	4.334	3.734	3.391	3.166	3.006	2.885	2.790	2.714	2.651	2.553	2.449	2.340	2.282	2.223	2.161	2.096	2.027	1.953
	0.010	7.821	5.595	4.693	4.189	3.870	3.640	3.469	3.335	3.228	3.139	3.002	2.859	2.708	2.630	2.548	2.464	2.376	2.284	2.186
27	0.100	2.889	2.501	2.291	2.159	2.068	1.999	1.947	1.906	1.872	1.843	1.798	1.750	1.698	1.670	1.641	1.610	1.578	1.543	1.506
	0.050	4.237	3.379	2.985	2.753	2.597	2.485	2.400	2.333	2.278	2.233	2.162	2.087	2.007	1.964	1.920	1.874	1.825	1.774	1.719
	0.025	5.725	4.322	3.722	3.379	3.154	2.994	2.873	2.778	2.702	2.639	2.541	2.437	2.328	2.270	2.211	2.149	2.084	1.995	1.921
	0.010	7.791	5.565	4.663	4.159	3.840	3.610	3.439	3.305	3.198	3.109	2.972	2.829	2.678	2.600	2.518	2.434	2.346	2.254	2.156
28	0.100	2.877	2.489	2.279	2.147	2.056	1.987	1.935	1.894	1.860	1.831	1.786	1.738	1.686	1.658	1.629	1.598	1.566	1.531	1.494
	0.050	4.225	3.367	2.973	2.741	2.585	2.473	2.388	2.321	2.266	2.221	2.150	2.075	1.995	1.952	1.908	1.862	1.813	1.762	1.707
	0.025	5.713	4.310	3.710	3.367	3.142	2.982	2.861	2.766	2.690	2.627	2.529	2.425	2.316	2.258	2.199	2.137	2.072	1.983	1.909
	0.010	7.761	5.535	4.633	4.129	3.810	3.580	3.409	3.275	3.168	3.079	2.942	2.799	2.648	2.570	2.488	2.404	2.316	2.224	2.126
29	0.100	2.865	2.477	2.267	2.135	2.044	1.975	1.923	1.882	1.848	1.819	1.774	1.726	1.674	1.646	1.617	1.586	1.554	1.519	1.482
	0.050	4.213	3.355	2.961	2.729	2.573	2.461	2.376	2.309	2.254	2.209	2.138	2.063	1.983	1.940	1.896	1.850	1.801	1.750	1.695
	0.025	5.701	4.298	3.698	3.355	3.130	2.970	2.849	2.754	2.678	2.615	2.517	2.413	2.304	2.246	2.187	2.125	2.060	1.971	1.897
	0.010	7.731	5.505	4.603	4.099	3.780	3.550	3.379	3.245	3.138	3.049	2.912	2.769	2.618	2.540	2.458	2.374	2.286	2.194	2.096
30	0.100	2.853	2.465	2.255	2.123	2.032	1.963	1.911	1.870	1.836	1.807	1.762	1.714	1.662	1.634	1.605	1.574	1.542	1.507	1.470
	0.050	4.201	3.343	2.949	2.717	2.561	2.449	2.364	2.297	2.242	2.197	2.126	2.051	1.971	1.928	1.884	1.838	1.789	1.738	1.683
	0.025	5.689	4.286	3.686	3.343	3.118	2.958	2.837	2.742	2.666	2.603	2.505	2.401	2.292	2.234	2.175	2.113	2.048	1.959	1.885
	0.010	7.701	5.475	4.573	4.069	3.750	3.520	3.349	3.215	3.108	3.019	2.882	2.739	2.588	2.510	2.428	2.344	2.256	2.164	2.066
31	0.100	2.841	2.453	2.243	2.111	2.020	1.951	1.899	1.858	1.824	1.795	1.750	1.702	1.650	1.622	1.593	1.562	1.530	1.495	1.458
	0.050	4.189	3.331	2.937	2.705	2.549	2.437	2.352	2.285	2.230	2.185	2.114	2.039	1.959	1.916	1.872	1.826	1.777	1.726	1.671
	0.025	5.677	4.274	3.674	3.331	3.106	2.946	2.825	2.730	2.654	2.591	2.493	2.389	2.280	2.222	2.163	2.101	2.036	1.947	1.873
	0.010	7.671	5.445	4.543	4.039	3.720	3.490	3.319	3.185	3.078	2.989	2.852	2.709	2.558	2.480	2.398	2.314	2.226	2.134	2.036
32	0.100	2.829	2.441	2.231	2.099	2.008	1.939	1.887	1.846	1.812	1.783	1.738	1.690	1.638	1.610	1.581	1.550	1.518	1.483	1.446
	0.050	4.177	3.319	2.925	2.693	2.537	2.425	2.340	2.273	2.218	2.173	2.102	2.027	1.947	1.904	1.860	1.814	1.765	1.714	1.659
	0.025	5.665	4.262	3.662	3.319	3.094	2.934	2.813	2.718	2.642	2.579	2.481	2.377	2.268	2.210	2.151	2.089	2.024	1.935	1.861
	0.010	7.641	5.415	4.513	4.009	3.690	3.460	3.289	3.155	3.048	2.959	2.822	2.679	2.528	2.450	2.368	2.284	2.196	2.104	2.006
33	0.100	2.817	2.429	2.219	2.087	2.006	1.937	1.885	1.844	1.810	1.781	1.736	1.688	1.636	1.608	1.579	1.548	1.516	1.481	1.444
	0.050	4.165	3.307	2.913	2.681	2.525	2.413	2.328	2.261	2.206	2.161	2.090	2.015	1.935	1.892	1.848	1.802	1.753	1.702	1.647
	0.025	5.653	4.250	3.650	3.307	3.082	2.922	2.801	2.706	2.630	2.567	2.469	2.365	2.256	2.198	2.139	2.077	2.012	1.923	1.849
	0.010	7.611	5.385	4.483	3.979	3.660	3.430	3.259	3.125	3.018	2.929	2.792	2.649	2.498	2.420	2.338	2.254	2.166	2.074	1.976
34	0.100	2.805	2.417	2.207	2.075	2.004	1.935	1.883	1.842	1.808	1.779	1.734	1.686	1.634	1.606	1.577	1.546	1.514	1.479	1.442
	0.050	4.153	3.295	2.901	2.669	2.513	2.401	2.316	2.249	2.194	2.149	2.078	2.003	1.923	1.880	1.836	1.790	1.741	1.690	1.635
	0.025	5.641	4.238	3.638	3.295	3.070	2.910	2.789	2.694	2.618	2.555	2.457	2.353	2.244	2.186	2.127	2.065	1.999	1.911	1.837
	0.010	7.581	5.355	4.453	3.949	3.630	3.400	3.229	3.095	2.988	2.899	2.762	2.619	2.468	2.390	2.308	2			


Se obtiene F_C

$$F_C = \frac{\frac{(81 - 84.625)^2}{3 - 1}}{288.75 \left(\frac{1}{8} + \frac{1}{8} \right)} = 1.99$$

El valor F_t fue obtenido con anterioridad.

Por lo que:

$$F_{t, \alpha=0.05, a-1=3-1=2, N-a=24-3=21} = 3.467$$



Por lo que se rechaza la hipótesis nula o bien se sabe que:

$$F_C > F_t \text{ se rechaza } H_0$$

en este caso:

$$1.99 < 3.467 \text{ no se rechaza } H_0$$

Se concluye que las *ventas promedio* en los *colores azul y amarillo* son iguales.

Se aceptó H_0 , pero todavía no se sabe en dónde está la diferencia, entonces hay que seguir probando hasta que se rechace H_0 en alguna comparación.

El siguiente par a probar es *rojo y amarillo* porque es la diferencia inmediatamente mayor del par anterior:

$\mu_{\text{rojo}} = \mu_{\text{amarillo}}$ o bien, las *ventas promedio* con los *colores rojo y amarillo* son iguales.


$H_a: \mu_{\text{rojo}} \neq \mu_{\text{amarillo}}$ o bien no lo son.

Se obtiene F_C :

$$F_C = \frac{\frac{(84.625 - 90.875)^2}{(3 - 1)}}{288.75 \left(\frac{1}{8} + \frac{1}{8} \right)} = 5.681$$

El valor F_t se obtuvo con anterioridad:

$$F_{t, \alpha=0.05, a-1=3-1=2, N-a=24-3=21} = 3.467$$



Por lo que se rechaza la hipótesis nula, o bien se sabe que:

$$F_C > F_t \text{ se rechaza } H_0$$

en este caso:

$$5.681 > 3.467 \text{ se rechaza } H_0$$

Se concluye que las *ventas promedio* en los *colores rojo y amarillo* son diferentes. Hasta aquí se dejan de hacer pruebas de pares, porque ya se encontró que sí se presenta diferencia entre niveles.

Como conclusión general se sabe que el *color* que tiene *ventas* diferentes es el *rojo*; los promedios se acomodaron de la siguiente manera:




Figura 6-4 Promedios de los envases.

Primero se comparó el *amarillo* con el *azul* y gracias a la prueba realizada se supo que eran iguales, esto se muestra a continuación:




Figura 6-5 Azul y amarillo tienen las mismas ventas promedio.

El círculo indica que las *ventas promedio* en ambas son iguales. Luego al compararse con el *rojo* resultó diferente, lo cual se muestra a continuación:




Figura 6-6 Amarillo y rojo tienen diferentes ventas promedio.

Con los círculos separados se indica que las *ventas promedio* en el *amarillo* y el *rojo* son diferentes. La siguiente prueba hubiera sido la comparación entre *azul* y *rojo* pero no se realizó ya que también hubieran sido diferentes; esto se muestra a continuación:




Figura 6-7 Azul y rojo tienen diferentes ventas promedio.

Al combinar las figuras anteriores se tiene que:





Figura 6-8 Azul y amarillo tienen diferentes ventas promedio que rojo.

Ahora se puede afirmar que el *color rojo* es el que vende más, mientras que los *colores azul y amarillo* están en segundo lugar en ventas promedio. Gráficamente se podría representar de la siguiente manera:



Gráfica 6-1 Azul y amarillo tienen diferentes ventas promedio que rojo.

Nótese que los *colores del envase* en azul y en amarillo tienen las mismas ventas promedio, debido a que ése fue el resultado de la prueba de Scheffé. Dicha prueba indica que cuando la $F_C \cong F_p$, es decir cuando el valor del estadístico de prueba es casi igual al teórico, es posible que la prueba de Scheffé

no encuentre diferencias en los promedios, ya que es una prueba conservadora, por lo que se recomienda utilizar otro tipo de prueba *post-hoc*.

6.13 ANOVA de 2 factores

Técnica de análisis de varianza. En esta técnica se manejan los efectos de 2 factores, cada uno de ellos con un número diferente de niveles.

Efectos principales. Efectos que los factores pueden tener sobre la variable dependiente.

La **técnica de análisis de varianza** de 2 factores es conocida como *diseño factorial*. En esta técnica se manejan los efectos de 2 factores, cada uno de ellos con un número diferente de niveles. A los efectos que estos factores pueden tener sobre la variable dependiente se les conoce como **efectos principales**.

Esta técnica contempla un efecto más que se conoce como *efecto interacción*. En algunos experimentos puede encontrarse que la respuesta entre los niveles de un factor no es la misma, cuando esto ocurre se habla del efecto interacción entre los factores, lo cual se muestra en la siguiente figura:




Figura 6-9 Efectos principales e interacción.

En un análisis de varianza factorial existe una hipótesis nula por cada factor y otra para la interacción de los factores. La hipótesis nula referida a un factor afirma que las medias de las poblaciones definidas por los diferentes niveles del factor son iguales. Así pues, para cada efecto existe una hipótesis y para cada hipótesis un estadístico F que permite contrastarla. Al igual que en el ANOVA de un factor, el nivel crítico asociado a cada estadístico F es el que permite decidir si se puede mantener o se debe rechazar una hipótesis. La ecuación que explica las fuentes de variación de este diseño factorial es la siguiente:

$$SS_T = SS_1 + SS_2 + SS_{1*2} + SS_W$$

Donde:

SS_T : variabilidad total

SS_1 y SS_2 : variabilidad por los efectos principales

SS_{1*2} : variabilidad por el efecto interacción

SS_W : variabilidad por el error

Como se puede apreciar es necesario calcular las 5 variaciones, las cuales se encuentran de la siguiente manera:

Cuadro 6-5 Fórmulas de definición ANOVA de 2 factores o diseño factorial (caso balanceado)

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadrados medios (CM)	Prueba F
Variación del factor 1 (SS_1)	$SS_1 = cn \sum_{i=1}^r (\bar{y}_{i..} - \bar{y}...)^2$	$r - 1$	$CM_1 = \frac{SS_1}{r - 1}$	$F_c = \frac{CM_1}{CMW}$
Variación del factor 2 (SS_2)	$SS_2 = rn \sum_{j=1}^c (\bar{y}_{.j.} - \bar{y}...)^2$	$c - 1$	$CM_2 = \frac{SS_2}{c - 1}$	$F_c = \frac{CM_2}{CMW}$
Variación del efecto interacción (SS_{1*2})	$SS_{1*2} = n \sum_{i=1}^r \sum_{j=1}^c (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}...)^2$	$(r - 1)(c - 1)$	$CM_{1*2} = \frac{SS_{1*2}}{(r - 1)(c - 1)}$	$F_c = \frac{CM_{1*2}}{CMW}$
Variación del error (SS_W)	$SS_W = \sum_{i=1}^r \sum_{j=1}^c \sum_{k=1}^n (\bar{y}_{ijk} - \bar{y}_{ij.})^2$	$rc(n - 1)$	$CM_W = \frac{SS_W}{rc(n - 1)}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^r \sum_{j=1}^c \sum_{k=1}^n (\bar{y}_{ijk} - \bar{y}...)^2$	$rcn - 1$		

Por lo que las fórmulas reducidas serían las siguientes:

Cuadro 6-6 Fórmulas de definición ANOVA de 2 factores o diseño factorial (caso balanceado).

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadrados medios (CM)	Prueba F
Variación del factor 1 (SS_1)	$SS_1 = \sum_{i=1}^r \frac{y_{i..}^2}{cn} - rcn\bar{y}...^2$	$r - 1$	$CM_1 = \frac{SS_1}{r - 1}$	$F_c = \frac{CM_1}{CMW}$
Variación del factor 2 (SS_2)	$SS_2 = \sum_{j=1}^c \frac{y_{.j.}^2}{rn} - rcn\bar{y}...^2$	$c - 1$	$CM_2 = \frac{SS_2}{c - 1}$	$F_c = \frac{CM_2}{CMW}$
Variación del efecto interacción (SS_{1*2})	$SS_{1*2} = \sum_{i=1}^r \sum_{j=1}^c n\bar{y}_{ij.}^2 - \sum_{i=1}^r \bar{y}_{i..}^2 - \sum_{j=1}^c n\bar{y}_{.j.}^2 + rn\bar{y}...^2$	$(r - 1)(c - 1)$	$CM_{1*2} = \frac{SS_{1*2}}{(r - 1)(c - 1)}$	$F_c = \frac{CM_{1*2}}{CMW}$
Variación del error (SS_W)	$SS_W = \sum_{i=1}^r \sum_{j=1}^c \left[\sum_{k=1}^n y_{ijk}^2 - n\bar{y}_{ij.}^2 \right]$	$rc(n - 1)$	$CM_W = \frac{SS_W}{rc(n - 1)}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^r \sum_{j=1}^c \sum_{k=1}^n y_{ijk}^2 - rcn\bar{y}...^2$	$rcn - 1$		

6.13.1 Nomenclatura

La nomenclatura que maneja esta técnica es la siguiente:

- r : es el número de niveles del factor 1
- c : es el número de niveles del factor 2
- n : es el número de datos que se tienen en el nivel i del factor 1 y el nivel j del factor 2
- $Y_{i..}$: es la suma de las observaciones de la variable dependiente en el nivel i
- $Y_{.j.}$: es la suma de las observaciones de la variable dependiente en el nivel j
- $Y_{ij.}$: es la suma de las observaciones de la variable dependiente para el nivel i del factor 1 y el nivel j del factor 2
- $\bar{Y}...$: es el promedio de todos los datos

En cada uno de los renglones que se muestran arriba se indica la combinación de niveles de ambos factores. Se deben tener como mínimo 2 observaciones en cada combinación de niveles para evaluar la interacción entre factores y, para tener un caso balanceado, deben ser el mismo número de datos en las combinaciones.

6.13.2 Modelo general de la técnica factorial

Este modelo explica cómo se integra cada dato de la variable dependiente; su fórmula es:

$$Y_{ijk} = \mu + \alpha_{i.} + \beta_{.j} + (\alpha * \beta)_{ij} + \varepsilon_{ijk}$$

Donde:

- Y_{ijk} : es la observación k de la variable dependiente medida bajo los efectos del nivel i del factor 1 y el nivel j del factor 2 manejado en el experimento
- μ : es el promedio general de la variable dependiente
- $\alpha_{i.}$: es el efecto del nivel i del factor 1 manejado en el experimento
- $\beta_{.j}$: representa el efecto del nivel j del factor 2 manejado en el experimento
- $(\alpha * \beta)_{ij}$: representa el efecto de la interacción de los niveles i y j del factor 1 y 2, respectivamente, manejados en el experimento
- ε_{ijk} : representa el error de cada una de las observaciones de la variable dependiente

Problema de diseño factorial

Durante una investigación en la que se estudió el efecto de la *altura* a la que se coloca un producto en el *anaquel* sobre las ventas, se consideró que la *posición o ubicación del anaquel* en la tienda también afectaría a las *ventas* del producto, así pues se plantearon 2 situaciones: 1) el anaquel a la *entrada* de la tienda y 2) el anaquel *cerca de la caja*. Se requiere determinar si la *posición*, la *altura* y la interacción de ambas afecta a las *ventas* del producto. A continuación se presenta la información referente al problema:⁷

Tabla 6-11 Datos

Altura							
Promedio	Inferior	Total	Medio	Total	Superior	Total	Total
En la entrada	70	224	85	266	71	250	720
	75		88		51		
	79		93		78		
En las cajas	90	258	94	284	87	267	819
	91		97		90		
	87		93		90		
Total	492		550		497		1 539

Existen 3 cuestiones a responder: ¿influye la *altura* en las *ventas*?, ¿influye la *posición* en las *ventas*?, ¿Influye la combinación de ambos factores en las ventas? Para iniciar deben calcularse las 5 variaciones:

Variación total

$$SS_T = 70^2 + 75^2 + \dots + 90^2 - 18 \left(\frac{1\,539}{18} \right)^2 =$$

$$SS_T = 1\,098.5$$

El objetivo principal de esta técnica es resumir la información para describirla más fácilmente; en este proceso se reducen las dimensiones o variables. Esta técnica exige que la mayoría de las variables sea independiente en cierto grado y métricas o medidas en escala de intervalo o razón.

Variación de los efectos principales

Variación explicada por el factor 1 (*posición*):

$$SS_1 = 9 \left[\left(\frac{720}{9} \right)^2 - \left(\frac{1\,539}{18} \right)^2 \right] + 9 \left[\left(\frac{819}{9} \right)^2 - \left(\frac{1\,539}{18} \right)^2 \right]$$

$$= SS_1 = 544.5$$

⁷ Datos generados para efecto de este texto.

Variación explicada por el factor 2 (*altura*):

$$SS_2 = 6 \left[\left(\frac{492}{6} \right)^2 - \left(\frac{1539}{18} \right)^2 \right] + 6 \left[\left(\frac{550}{6} \right)^2 - \left(\frac{1539}{18} \right)^2 \right] + 6 \left[\left(\frac{497}{6} \right)^2 - \left(\frac{1539}{18} \right)^2 \right]$$

$$= SS_2 = 344.333$$

Variación no explicada

Variación no explicada por el nivel 1 del factor 1 y el nivel 1 del factor 2 (en la *entrada e inferior*):

$$SS_{W_{1,1}} = 70^2 + 75^2 = 79^2 - 3 \left(\frac{224}{3} \right)^2 = 40.667$$

Variación no explicada por el nivel 1 del factor 1 y el nivel 2 del factor 2 (en la *entrada y media*):

$$SS_{W_{1,2}} = 85^2 + 88^2 + 93^2 - 3 \left(\frac{226}{3} \right)^2 = 32.667$$

Variación no explicada por el nivel 1 del factor 1 y el nivel 3 del factor 2 (en la *entrada y superior*):

$$SS_{W_{1,3}} = 71^2 + 81^2 = 78^2 - 3 \left(\frac{230}{3} \right)^2 = 52.667$$

Variación no explicada por el nivel 2 del factor 1 y el nivel 1 del factor 2 (en las *cajas e inferior*):

$$SS_{W_{2,1}} = 90^2 + 91^2 + 87^2 - 3 \left(\frac{268}{3} \right)^2 = 8.667$$

Variación no explicada por el nivel 2 del factor 1 y el nivel 2 del factor 2 (en las *cajas y media*):

$$SS_{W_{2,2}} = 94^2 + 97^2 + 93^2 - 3 \left(\frac{284}{3} \right)^2 = 8.667$$

Variación no explicada por el nivel 2 del factor 1 y el nivel 3 del factor 2 (en las *cajas y superior*):

$$SS_{W_{2,3}} = 87^2 + 90^2 + 90^2 - 3 \left(\frac{267}{3} \right)^2 = 6$$

Entonces la variación no explicada finalmente se calcula como sigue:

$$SS_W = 40.667 + 32.667 + 52.667 + 8.667 + 8.667 + 6 = 149.333$$

Las diferencias se deben al redondeo

Variación de la interacción

$$SS_{1 \times 2} = SS_T - SS_1 - SS_2 - SS_W$$

$$SS_{1 \times 2} = 1\,098.5 - 544.5 - 344.333 - 149.333 = 60.333$$

Una vez determinadas las variaciones, se realizan las pruebas de hipótesis para conocer si hay o no influencia significativa de cada uno de los factores y la combinación de ambos en las *ventas*, la información fue resumida en la siguiente tabla.

Tabla 6-12 Prueba de los efectos

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Posición	544.5	1	544.5	43.755
Altura	344.33	2	172.165	13.835
Posición*altura	60.33	2	30.165	2.424
Error	149.33	12	12.444	
Total	1098.5	17		

En la columna suma de cuadrados se acomodaron las 5 variaciones, en la de grados de libertad se tiene lo siguiente:

Para el factor 1: $r - 1 = 2 - 1 = 1$.

Para el factor 2: $c - 1 = 3 - 1 = 2$.

Para el efecto interacción: $(r - 1)(c - 1) = (2 - 1)(3 - 1) = 2$.

Para la variación no explicada: $r * c * (n - 1) = 2 * 3 * (3 - 1) = 12$.

Para la variación total: $r * c * n - 1 = (N - 1) = 2 * 3 * 3 - 1 = 24 - 1 = 17$.

En la columna de media cuadrática se dividió la suma de cuadrados entre los grados de libertad y por último la columna F calculada es el cociente de cada media cuadrática explicada entre la media cuadrática del error.

Prueba de hipótesis para la variable *posición*:

$H_0: \mu_1 = \mu_2$: las *ventas promedio* son las mismas en las distintas *posiciones* en la tienda, es decir, el factor *posición* no influye en las *ventas promedio*


$H_a: \mu_1 \neq \mu_2$: las *ventas promedio* no son las mismas en las distintas *posiciones* en la tienda, es decir, el factor *posición* sí influye en las *ventas promedio*

Donde:

μ_i : es la *venta promedio* en el nivel i del factor

De la tabla anterior, que tiene los datos del ejemplo, se escoge el valor de la F que se calculó del factor *posición*, el cual es 43.754 y se compara con el estadístico teórico F. Si se fija 99% de confianza, el valor de tablas se busca de la siguiente manera:

Tabla 6-13 Parte de la tabla F⁸



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
12	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
13	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958

⁸ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha=0.01, 1, 12} = 9.330$$

ahora se sabe que:


$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar los valores se tiene que:

$$43.754 > 9.330 \text{ por lo tanto se rechaza } H_0$$

Como se rechazó H_0 entonces se concluye que en las 2 *posiciones*⁹ en la tienda se obtienen diferentes *ventas promedio*, o bien que la *posición* sí afecta de manera significativa las *ventas promedio* del producto.

O bien gráficamente se tendría que:



Se concluye lo mismo; rechazar H_0 significa que la *posición* sí afecta de manera significativa las *ventas* del producto; es decir, sí se encontró diferencia en al menos 1 de los niveles de la posición en la tienda.

Prueba de hipótesis para la variable altura:

$H_0: \mu_1 = \mu_2 = \mu_3$: las *ventas promedio* son las mismas en las diferentes *alturas del anaquel*, es decir, el factor *altura* no influye en las *ventas promedio*

$H_a: \mu_1 \neq \mu_2 \neq \mu_3$: las *ventas promedio* no son las mismas en las diferentes *alturas del anaquel*, es decir, el factor *altura* sí influye en las *ventas promedio* o en al menos 1 de las 3 *alturas del anaquel* se obtienen diferentes *ventas promedio*


Donde:

μ_i = la *venta promedio* en el nivel i del factor

De la tabla anterior, que tiene los datos del ejemplo, se escoge el valor de la F que se calculó del factor *altura*, el cual es 13.835 y se compara con el estadístico teórico F. Si se fija 99% de confianza, el valor de tablas se busca de la siguiente manera:

⁹ Como sólo son 2 niveles del factor *posición*, al rechazar la hipótesis nula se puede concluir que en las 2 se tienen diferentes *ventas promedio*.

Tabla 6-14 Parte de la tabla F¹⁰



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
12	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
13	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958

¹⁰ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 2, 12} = 6.927$$

Ahora se sabe que:


$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar los valores se tiene que:

$$13.835 > 6.927 \text{ por lo tanto se rechaza } H_0$$

Como se rechazó H_0 entonces se concluye que en al menos 1 de las 3 *alturas en el anaquel* se obtienen diferentes *ventas promedio*,¹¹ o bien que la *altura* sí afecta de manera significativa las *ventas promedio* del producto.

O bien gráficamente se tendría que:



Se concluye lo mismo; rechazar H_0 significa que la *altura* sí afecta de manera significativa a las *ventas del producto*. Es decir, sí se encontró diferencia en al menos 1 de los niveles de la *altura del anaquel*. Como se rechazó H_0 es necesario realizar pruebas post-hoc para saber cuál o cuáles niveles están ocasionando diferentes *ventas promedio*.

Prueba de hipótesis para el efecto interacción

$H_0: \mu_{1,1} = \mu_{1,2} = \dots = \mu_{2,3}$: la combinación de una *altura* con una *posición* no produce un valor agregado a las *ventas promedio*

$H_a: \mu_{1,1} \neq \mu_{1,2} \neq \dots \neq \mu_{2,3}$: la combinación de una *altura* con una *posición* sí produce un valor agregado a las *ventas promedio*


Donde:

μ_{ij} : es *ventas promedio* en el nivel i del factor 1 con el nivel j del factor 2

De la tabla anterior, que tiene los datos del ejemplo, se escoge el valor de la F que se calculó del factor *altura*, el cual es 2.424 y se compara con el estadístico teórico F. Si se fija 99% de confianza, el valor de tablas se busca de la siguiente manera:

¹¹ Para saber en cuál de los tres niveles se obtienen diferentes ventas promedio, es necesario realizar pruebas post-hoc.

Tabla 6-15 Parte de la tabla F¹²



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
12	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
13	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958

¹² La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 2, 12} = 6.927$$

Ahora se sabe que:


$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar los valores se tiene que:

$$2.424 < 6.927 \text{ por lo tanto no se rechaza } H_0$$


Como no se rechazó H_0 entonces se concluye que la combinación de ambos factores (*altura y posición*) no afectan las ventas, la sinergia de los factores no genera un valor agregado a las *ventas promedio* del producto.

O bien gráficamente se tendría que:



Se concluye lo mismo; no rechazar H_0 significa que la combinación de ambos factores (*altura y posición*) no afectan las *ventas*, la sinergia de los factores no genera un valor agregado a las *ventas promedio* del producto.


Si el efecto interacción fuera representado gráficamente y suponiendo que sí se tuviera un efecto significativo en las *ventas*, se vería algo como lo siguiente:



Gráfica 6-2 Efecto interacción.


Nota: Los datos graficados no tienen relación con el problema anterior.

Al tomar como referencia la opción *en la entrada*, la línea punteada de la siguiente figura representa cómo se debería presentar el efecto en la variable dependiente *en las cajas* si no se diera la interacción. El efecto interacción tuvo influencia significativa en forma negativa, esto lo muestra la flecha, al disminuir las *ventas* de 75 a 50.




Gráfica 6-3 Sinergia negativa.

Al tomar como referencia *en las cajas*, la línea punteada representa lo que debería de resultar; sin embargo, el efecto interacción también tuvo influencia significativa, pero en este caso en forma positiva al elevar las *ventas* de menos de cero a 45.



Gráfica 6-4 Sinergia positiva.


Si el efecto interacción no afectara significativamente las *ventas*, como sucedió en este caso, se tendrían gráficamente 2 líneas paralelas, como se muestra a continuación:




Gráfica 6-5 Sin sinergia.

En resumen en el diseño factorial (con 2 factores y repeticiones por casillas), se tendrían las siguientes posibles situaciones, las cuales se explican también en forma gráfica:

En esta primera gráfica se puede observar que no se están presentando ninguno de los 2 efectos principales y que tampoco se observa interacción, esto se traduce en un valor constante en la variable dependiente, lo cual equivale a aceptar que ni la *altura* ni la *posición*, así como tampoco la interacción entre ellas, tiene un efecto sobre las *ventas*. Esto deriva en un valor constante en la variable dependiente.




En la siguiente gráfica se muestra el efecto del factor 1 (*posición*) sobre la variable dependiente, a esta gráfica se le puede nombrar coincidencia, ya que los efectos del factor 2 (*altura*), al quedar empalmados, no muestran un efecto sobre la variable dependiente. Esto se traduce en aceptar que la *altura* no tiene efecto sobre las *ventas* y tampoco la interacción, no así la *posición* que sí muestra relación con las *ventas*.




Efecto de un factor.
Es el cambio en la variable dependiente producido por un cambio en el nivel del factor.

El **efecto de un factor** se define como el cambio en la variable dependiente producido por un cambio en el nivel del factor. Con esto se reconoce el efecto principal en ambos factores y dado el patrón paralelo de la siguiente gráfica, el efecto interacción no está presente. A este patrón se le denomina *paralelismo* y está presente al encontrar que tanto la *posición* como la *altura* tienen un efecto sobre la variable dependiente (*ventas*), no así la interacción.



Asimismo, el ANOVA contempla un efecto más que se conoce como *interacción*. En algunos experimentos puede encontrarse diferencia en la respuesta entre los niveles de un factor; cuando esto ocurre existe una interacción entre los factores, lo cual se muestra en la gráfica siguiente.



En este análisis se realizarán 3 pruebas, 2 de efectos principales y 1 de interacción.

6.14 Cuadrados latinos

Esta técnica se utiliza como alternativa para simplificar un experimento en el que se involucran 3 factores.¹³ La simplificación al experimento consiste en reducir el número de observaciones que deberían obtenerse si se manejara un modelo de diseño factorial con 3 factores. La técnica de **cuadrados latinos** supone, en su modelo general, que solamente existen los efectos principales de los factores; en cuanto a la interacción que pudiera llegar a presentarse entre ellos la considera que es mínima y por lo tanto la elimina del modelo.

Cuadrados latinos.

Técnica que supone, en su modelo general, que solamente existen los efectos principales de los factores.

Los requisitos para llevar a cabo un experimento mediante esta técnica son:

1. Que el número de niveles de los 3 factores se encuentre entre 5 y 8; de ser menor el número de niveles deberá manejarse mediante otra técnica denominada análisis ortogonal.

¹³ En el experimento se tendrían que calcular 9 variaciones y se tendrían que realizar 7 pruebas de hipótesis.

2. Los 3 factores involucrados en el experimento deberán manejar el mismo número de niveles.
3. No debe existir interacción entre los factores ni en la casilla, ni en los renglones, ni en las columnas, por ejemplo, un posible arreglo se muestra en la siguiente tabla:

Tabla 6-16 Posible arreglo en cuadrados latinos

Factor A	Factor B					Total
	B1	B2	B3	B4	B5	
A1	C1 = T_{111}	C2 = T_{122}	C3 = T_{133}	C4 = T_{144}	C5 = T_{155}	$T_{1.}$
A2	C5 = T_{215}	C4 = T_{224}	C1 = T_{231}	C2 = T_{242}	C3 = T_{253}	$T_{2.}$
A3	C3 = T_{313}	C5 = T_{325}	C4 = T_{334}	C1 = T_{341}	C2 = T_{352}	$T_{3.}$
A4	C2 = T_{412}	C3 = T_{423}	C5 = T_{435}	C4 = T_{444}	C1 = T_{451}	$T_{4.}$
A5	C4 = T_{514}	C1 = T_{521}	C2 = T_{532}	C3 = T_{543}	C5 = T_{555}	$T_{5.}$
Total	$T_{.1}$	$T_{.2}$	$T_{.3}$	$T_{.4}$	$T_{.5}$	Y_{TT}

Donde:

Y_{ijk} : son las observaciones de la variable dependiente en el nivel i del factor A, nivel j del factor B y nivel k del factor C

$T_{i.}$: es la suma de las observaciones de la variable dependiente en el nivel i del factor A

$T_{.j}$: es la suma de las observaciones de la variable dependiente en el nivel j del factor B

Y_{TT} : es la suma de las observaciones de la variable dependiente para todos los niveles de los 3 factores

Nótese en el cuadro anterior que no hay repeticiones por casilla; además el factor C no se repite ni por columna ni por renglón.

Lo que se busca en la técnica es que todos los niveles de las variables puedan combinarse y ver su efecto sobre la variable dependiente.

6.14.1 Modelo general de los cuadrados latinos

El modelo general de esta técnica es el siguiente:

$$Y_{ijk} = \mu + \alpha_{i..} + \beta_{.j.} + \beta_{..k} + \varepsilon_{ijk}$$

Donde:

Y_{ijk} : observación de la variable dependiente medida en el nivel i del factor A, en el nivel j del factor B y en el nivel k del factor C

μ : promedio general de la variable dependiente

$\alpha_{i..}$: efecto del nivel i del factor 1 (A) manejado en el experimento

$\beta_{.j.}$: efecto del nivel j del factor 2 (B) manejado en el experimento

$\beta_{..k}$: efecto del nivel k del factor 3 (C) manejado en el experimento

ε_{ijk} : el error de cada una de las observaciones de la variable dependiente

Cuadro 6-7 Fórmulas de definición para cuadros latinos

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadros medios (CM)	Prueba F
Variación del factor A (SS_A)	$SS_A = t \sum_{i=1}^t (\bar{y}_{i..} - \bar{y}...)^2$	$t - 1$	$CMA = \frac{SS_A}{t - 1}$	$F_C = \frac{CMA}{CMW}$
Variación del factor B (SS_B)	$SS_B = t \sum_{j=1}^t (\bar{y}_{.j.} - \bar{y}...)^2$	$t - 1$	$CMB = \frac{SS_B}{t - 1}$	$F_C = \frac{CMB}{CMW}$
Variación del factor C (SS_C)	$SS_C = t \sum_{k=1}^t (\bar{y}_{..k} - \bar{y}...)^2$	$t - 1$	$CMC = \frac{SS_C}{t - 1}$	$F_C = \frac{CMC}{CMW}$
Variación del error (SS_W)	$SS_W = SS_T - SS_A - SS_B - SS_C$	$(t - 1)(t - 2)$	$CMW = \frac{SS_W}{(t - 1)(t - 2)}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^t \sum_{j=1}^t \sum_{k=1}^t (y_{ijk} - \bar{y}...)^2$	$N - 1$		

Por lo que las fórmulas reducidas serían las siguientes.

Cuadro 6-8 Fórmulas de definición para cuadros latinos

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadros medios (CM)	Prueba F
Variación del factor A (SS_A)	$SS_A = \sum_{i=1}^t \frac{y_{i..}^2}{t} - N \bar{y}...^2$	$t - 1$	$CMA = \frac{SS_A}{t - 1}$	$F_C = \frac{CMA}{CMW}$
Variación del factor B (SS_B)	$SS_B = \sum_{j=1}^t \frac{y_{.j.}^2}{t} - N \bar{y}...^2$	$t - 1$	$CMB = \frac{SS_B}{t - 1}$	$F_C = \frac{CMB}{CMW}$
Variación del factor C (SS_C)	$SS_C = \sum_{k=1}^t \frac{y_{..k}^2}{t} - N \bar{y}...^2$	$t - 1$	$CMC = \frac{SS_C}{t - 1}$	$F_C = \frac{CMC}{CMW}$
Variación del error (SS_W)	$SS_W = SS_T - SS_A - SS_B - SS_C$	$(t - 1)(t - 2)$	$CMW = \frac{SS_W}{(t - 1)(t - 2)}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^t \sum_{j=1}^t \sum_{k=1}^t y_{ijk}^2 - N \bar{y}...^2$	$N - 1$		

$Y_{i..}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del factor A

$Y_{.j.}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del factor B

$Y_{..k}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del factor C

t : es el número de niveles manejados para cualquiera de los factores usados en el experimento.

N : es el número total de datos

Problema de cuadrados latinos

Se lleva a cabo un experimento para verificar si el uso de distintos *ambientes musicales* contribuye a mejorar la *productividad* del empleado. Fueron probados 5 programas musicales etiquetados como A, B, C, D y E, los cuales se probaron los 5 días de la semana, por 5 semanas consecutivas, se midió cada día la *productividad* de las personas en su trabajo. Los resultados fueron los siguientes:¹⁴

Tabla 6-17 Datos

Semanas	Días					Total
	Lunes	Martes	Miércoles	Jueves	Viernes	
1	A = 133	B = 139	C = 140	D = 140	E = 145	697
2	B = 136	C = 141	D = 143	E = 146	A = 139	705
3	C = 140	A = 138	E = 142	B = 139	D = 139	698
4	D = 129	E = 132	A = 137	C = 136	B = 140	674
5	E = 132	D = 144	B = 143	A = 142	C = 142	703
Total	670	694	705	703	705	3 477

Se busca encontrar el efecto del *programa musical* (factor C) sobre la *productividad*, el problema se resolverá completo para ejemplificar, se verán los efectos de todos los factores. Se empieza por calcular cada variación, las cuales se muestran a continuación.

Variación total:

$$SS_T = 133^2 + 136^2 + \dots + 142^2 - 25 \left(\frac{3\,477}{25} \right)^2$$

$$= SS_T = 433.84$$

Variación de semana:

Variación explicada por el factor A (*semana*):

$$SS_{A(\text{semanas})} = 5 \left[\left(\frac{697}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{705}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{698}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right]$$

$$+ 5 \left[\left(\frac{674}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{703}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right]$$

$$= SS_{A(\text{semanas})} = 123.44$$

Variación explicada por el factor B (*días*):

$$SS_{B(\text{días})} = 5 \left[\left(\frac{670}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{694}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{705}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right]$$

$$+ 5 \left[\left(\frac{703}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{705}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right]$$

$$= SS_{B(\text{días})} = 177.84$$

La suma de la productividad para cada uno de los ambientes musicales es:

¹⁴ Datos generados para efectos de este texto.

Tabla 6-18 Datos y niveles de factor C

	Programa musical				
	A	B	C	D	E
	133	136	140	129	132
	138	139	141	144	132
	137	143	140	143	142
	142	139	136	140	146
	139	140	142	139	145
Total	689	697	699	695	697

Variación explicada por el factor *C* (*ambientes musicales*):

$$\begin{aligned}
 SS_{C(\text{música})} &= 5 \left[\left(\frac{689}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{697}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{699}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] \\
 &\quad + 5 \left[\left(\frac{695}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] + 5 \left[\left(\frac{697}{5} \right)^2 - \left(\frac{3\,477}{25} \right)^2 \right] \\
 &= SS_{C(\text{música})} = 11.8
 \end{aligned}$$

Variación no explicada:

$$\begin{aligned}
 SS_W &= SS_T - SS_1 - SS_2 - SS_3 \\
 SS_W &= 433.84 - 123.44 - 177.84 - 11.84 = 120.72
 \end{aligned}$$

La información se acomodó en la siguiente tabla:

Tabla 6-19 Efectos principales

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Semana	123.44	4	30.86	3.068
Día	177.84	4	44.46	4.419
Música	11.84	4	2.96	0.294
Error	120.72	12	10.06	
Total	433.84	24		

En seguida se realizarán las pruebas de hipótesis para cada factor; se inicia con los programas musicales:

Prueba de hipótesis para el factor *música*:

Se prueba el factor *música*, que es el que interesa para este problema:

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$: los diferentes *programas musicales* no afectan la *productividad media* o no lo hacen de manera significativa


$H_a: \mu_1 \neq \mu_2 \neq \mu_3 \neq \mu_4 \neq \mu_5$: los diferentes *programas musicales* sí afectan la *productividad media* o sí lo hacen de manera significativa

Donde:

μ_i : la *productividad promedio* en el nivel *i* del factor *programa musical*

El nivel de confianza en el ejemplo fue de 99%, por lo que el estadístico teórico se buscaría de la siguiente manera (ver tabla 6-20 en la página siguiente).

Tabla 6-20 Parte de la tabla F¹⁵



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
12	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
13	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380

¹⁵ La tabla completa aparece en el anexo 2.3, tabla F.

El estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 4, 12} = 5.412$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar ambos estadísticos se tiene que:

$$0.294 < 5.412 \text{ no se rechaza } H_0$$

O bien en forma gráfica sería de la siguiente manera:



Como no se rechazó H_0 entonces se concluye que en ninguno de los 5 programas musicales se obtiene diferente *productividad promedio*, es decir, la *música* no influye para obtener diferente *productividad media*.

Prueba de hipótesis para el factor *semana*:

Se prueba el siguiente factor que es *semana*, a manera de práctica solamente, ya que no lo pide el problema:

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$: las diferentes *semanas* no afectan la *productividad media* o bien durante las *semanas* la *productividad promedio* es la misma


$H_a: \mu_1 \neq \mu_2 \neq \mu_3 \neq \mu_4 \neq \mu_5$: las diferentes *semanas* sí afectan la *productividad media* o bien durante las *semanas* la *productividad promedio* no es la misma

Donde:

μ_i : la *productividad promedio* en el nivel i del factor *semana*

El nivel de confianza del ejemplo es de 99%, por lo que el estadístico teórico se busca de la siguiente manera:

Tabla 6-21 Parte de la tabla F¹⁶



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
12	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
13	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380

¹⁶ La tabla completa aparece en el anexo 2.3, tabla F.

por lo que el estadístico de tablas sería:

$$F_{t, \alpha=0.01, 4, 12} = 5.412$$


Ahora se sabe que:

$$\text{Si } F_C = 3.068 > F_t \text{ se rechaza } H_0$$

Al comparar ambos estadísticos se tiene que:

$$3.068 < 5.412 \text{ no se rechaza } H_0$$

También se puede hacer de forma gráfica, la cual sería la siguiente:



Como no se rechazó H_0 entonces se concluye que en ninguna de las 5 *semanas* se obtiene diferente *productividad promedio*, es decir, la *semana* no influye para obtener diferente *productividad media*.

Prueba de hipótesis para el factor *día*:

Se prueba el siguiente factor: *días de la semana*, a manera de práctica solamente, ya que el problema no lo pide. Hipótesis:

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$: los diferentes *días de la semana* no afectan la *productividad media*, o bien los *días de la semana* tienen un efecto similar en la *productividad promedio*


$H_a: \mu_1 \neq \mu_2 \neq \mu_3 \neq \mu_4 \neq \mu_5$: los diferentes *días de la semana* sí afectan la *productividad media*, o bien los *días de la semana* no tienen un efecto similar en la *productividad promedio*

Donde:

μ_i : la *productividad promedio* en el nivel i del factor *día*

El nivel de confianza del ejemplo es de 99%, por lo que el estadístico teórico se busca de la siguiente manera.

Tabla 6-22 Parte de la tabla F¹⁷



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
12	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
13	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380

¹⁷ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 4, 12} = 5.412$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar ambos estadísticos se tiene que:

$$4.419 < 5.412 \text{ no se rechaza } H_0$$

O bien en forma gráfica sería de la siguiente manera:



Como no se rechazó H_0 entonces se concluye que en ninguno de los 5 días de la semana se obtiene diferente *productividad promedio*, es decir, el día no influye en la *productividad media*.

Como no se encontró diferencia entre los factores a medir, ya que en ninguno de los 3 factores se rechazó la hipótesis nula, no tiene caso que se hagan las pruebas post-hoc para cada factor.

6.15 Bloques al azar

La técnica de **bloques al azar** tiene por objeto eliminar posibles fuentes de variación que no pudieron controlarse durante el desarrollo del experimento y hacen suponer que tienen una influencia sobre las mediciones que se realizan en la variable dependiente. En esta técnica, los orígenes de las fuentes de variación se encuentran en las unidades de prueba, o lo que es lo mismo, en donde se realiza el experimento o con quienes se efectúa éste. A estas unidades de prueba que son incontrolables se les llama bloque, representan un grupo experimental y son equivalentes a los niveles de los factores; sin embargo, los bloques no se consideran factores a estudiar, sino una fuente de variabilidad a controlar. Por lo tanto el bloque tiene como característica el ser no métrica.

En el diseño por bloques se distinguen 2 tipos de factores, los del propio experimento y los del bloque; los primeros se utilizan para analizar el efecto sobre la variable dependiente y los segundos para reducir los errores en el experimento.

Bloques al azar. Técnica que elimina posibles fuentes de variación que no pudieron controlarse durante el experimento.

Bloque. Unidades de prueba incontrolables que representan un grupo experimental y son equivalentes a los niveles de los factores.

6.15.1 Modelo general de bloques al azar

En seguida se presenta el modelo general del diseño de bloques al azar:

$$Y_{ij} = \mu + \beta_{i.} + \tau_{.j} + \varepsilon_{ij}$$

Y_{ij} : es la observación de la variable dependiente medida en la unidad de prueba o bloque i bajo los efectos del nivel j del factor manejado en el experimento

μ : es el promedio general de la variable dependiente

β_i : es el efecto del bloque i sobre la variable dependiente

τ_j : es el efecto del nivel j del factor manejado en el experimento

ε_{ij} : es el error de cada una de las observaciones de la variable dependiente

La siguiente tabla representa el arreglo del experimento:

Tabla 6-23 Arreglo de bloques al azar

Bloque	Factor					Total
	1	2	3	...	k	
1	Y_{11}	Y_{12}	Y_{13}	...	Y_{1k}	$T_{1.}$
2	Y_{21}	Y_{22}	Y_{23}	...	Y_{2k}	$T_{2.}$
3	Y_{31}	Y_{32}	Y_{33}	...	Y_{3k}	$T_{3.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
r	Y_{r1}	Y_{r2}	Y_{r3}	...	Y_{rk}	$T_{r.}$
Total	$T_{.1}$	$T_{.2}$	$T_{.3}$	...	$T_{.k}$	Y_{TT}

Donde:

Y_{ij} : son las observaciones de la variable dependiente en el nivel i del bloque y el nivel j del factor

$T_{i.}$: es la suma de las observaciones de la variable dependiente en el nivel i del bloque

$T_{.j}$: es la suma de las observaciones de la variable dependiente en el nivel j del factor

Y_{TT} : es la suma de las observaciones de la variable dependiente para todos los niveles del factor y del bloque

Esta técnica puede confundirse con la de diseño factorial; sin embargo, hay que notar que en bloques al azar solamente hay una observación, es decir, no existen repeticiones por casilla, ya que eso daría la interacción. Cabe señalar que el bloque puede acomodarse por renglones o por columnas. A continuación se presentan las fórmulas para los bloques al azar.

Cuadro 6-9 Fórmulas de definición para bloques al azar

Fuentes de variación	Suma de cuadrados	Grados de libertad	Cuadrados medios (CM)	Prueba F
Variación del factor 1 (SS_1)	$SS_1 = r \sum_{j=1}^k (\bar{y}_{.j} - \bar{y}_{..})^2$	$k - 1$	$CM1 = \frac{SS_1}{k - 1}$	$F_c = \frac{CM1}{CMW}$
Variación de BLK (SS_{BLK})	$SS_{BLK} = k \sum_{i=1}^r (\bar{y}_{i.} - \bar{y}_{..})^2$	$r - 1$	$CMB = \frac{SS_{BLK}}{r - 1}$	$F_c = \frac{CMBLK}{CMW}$
Variación del error (SS_W)	$SS_W = SS_T - SS_1 - SS_{BLK}$	$(r - 1)(k - 1)$	$CMW = \frac{SS_W}{(r - 1)(k - 1)}$	
Variación total (SS_T)	$SS_T = \sum_{i=1}^r \sum_{j=1}^k (y_{ij} - \bar{y}_{..})^2$	$N - 1$		

Donde:

$Y_{..}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del factor y del bloque manejado en el desarrollo del experimento

$Y_{i.}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del bloque

$Y_{.j}$: es la suma de las observaciones de la variable dependiente para cada uno de los niveles del factor

r : es el número de unidades de prueba o bloques del experimento

k : es el número de niveles del factor

N : es el número total de datos

Problema de bloques al azar

Se desea realizar una campaña publicitaria con la cual se busca resaltar el menor *desgaste* que sufre una llanta de automóvil; el anuncio pretende hacer la comparación de esta marca en particular con otras 3 que se encuentran en el mercado, por lo que en el experimento se utilizaron 4 automóviles de una misma marca, en condiciones similares. Un factor a considerar en el desgaste es la forma en que el *conductor conduce el automóvil*, por lo que esta variable (bloque) se registra. A continuación se presentan los resultados:¹⁸

Tabla 6-24 Datos

Conductor	Marca del automóvil				Total
	A	B	C	D	
1	17	14	13	13	57
2	14	14	13	8	49
3	12	12	10	9	43
4	16	13	12	9	50
5	13	11	11	9	44
Total	72	64	59	48	243

El bloque es el *conductor del automóvil* porque es una variable que no se puede controlar, debido a que es imposible saber por dónde pasará cada uno y sería importante evaluar cómo afecta en el desgaste de la llanta del automóvil; algo interesante a tomar en cuenta es si el *desgaste promedio* sufrido en las llantas difiere entre las *marcas de automóviles*.

Se hacen los cálculos de las variaciones, es decir, la total, la del factor, la del bloque y la del error:

Variación total:

$$\begin{aligned}
 SS_T &= 17^2 + 14^2 + \dots + 9^2 - 29 \left(\frac{243}{20} \right)^2 \\
 &= SS_T = 106.55
 \end{aligned}$$

¹⁸ Datos generados para efecto de este texto.

Variación explicada:

Variación explicada por el bloque:

$$SS_{BLK} = 4 \left[\left(\frac{57}{4} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 4 \left[\left(\frac{49}{4} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 4 \left[\left(\frac{43}{4} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 4 \left[\left(\frac{50}{4} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 4 \left[\left(\frac{44}{4} \right)^2 - \left(\frac{243}{20} \right)^2 \right]$$

$$= SS_{BLK} = 31.3$$

Variación explicada por el factor marca del automóvil:

$$SS_{\text{automóvil}} = 5 \left[\left(\frac{72}{5} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 5 \left[\left(\frac{64}{5} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 5 \left[\left(\frac{59}{5} \right)^2 - \left(\frac{243}{20} \right)^2 \right] + 5 \left[\left(\frac{48}{5} \right)^2 - \left(\frac{243}{20} \right)^2 \right]$$

$$= SS_{\text{automóvil}} = 60.55$$

Variación no explicada:

Entonces la variación no explicada finalmente se calcula como sigue:

$$SS_W = SS_T - SS_{BLK} - SS_{\text{automóvil}}$$

$$SS_W = 105.55 - 31.3 - 60.55 = 14.70$$

La información se acomodó en la siguiente tabla:

Tabla 6-25 Efectos principales

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Conductor	31.3	4	7.285	6.388
Automóvil	60.55	3	20.183	16.476
Error	14.7	12	1.225	
Total	106.55	19		

En seguida se realizarán las pruebas de hipótesis; se inicia con el factor (marca):

Prueba de hipótesis para el factor *automóvil*:

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4$: el *desgaste promedio* es el mismo en las distintas *marcas* de coches, o bien cualquier *marca* sufre un *desgaste* en *promedio* similar, o también se podría decir que el factor *automóvil* no influye en el *desgaste promedio*


$H_a: \mu_1 \neq \mu_2 \neq \mu_3 \neq \mu_4$: el *desgaste promedio* no es el mismo en las distintas *marcas de coches*, o bien las *marcas* sufren diferente *desgaste promedio*; es decir, el factor *automóvil* sí influye en el *desgaste promedio*

Donde:

μ_i : es el *desgaste promedio* en el nivel *i* del factor

Como el nivel de confianza que se definió antes es 95%, el estadístico teórico se buscaría de la siguiente manera:

Tabla 6-26 Parte de la tabla F¹⁹



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
12	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
13	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380

¹⁹ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha=0.05, 3, 12} = 3.490$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

De la tabla de los efectos principales se escoge el valor de la F para el factor *automóvil*, el cual es 16.476 y al comparar ambos estadísticos se tiene que:

$$16.476 > 3.490 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que en las diferentes *marcas de automóviles* se obtienen diversos *desgastes promedio* y habría que hacer la prueba Scheffé para ver cuáles *marcas* son iguales y cuáles diferentes.

Prueba de hipótesis para el bloque *conductor*:

$H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$: el *desgaste promedio* es el mismo con los distintos *choferes*, es decir el factor *conductor* no influye en el *desgaste promedio*


$H_a: \mu_1 \neq \mu_2 \neq \mu_3 \neq \mu_4 \neq \mu_5$: el *desgaste promedio* no es el mismo en los distintos *choferes*, es decir el factor *conductor* sí influye en el *desgaste promedio*

Donde:

μ_i : es el *desgaste promedio* en el nivel i del factor

Como el nivel de confianza es de 95% (propuesto con anterioridad) el estadístico teórico se buscaría de la siguiente manera:

Tabla 6-27 Parte de la tabla F²⁰



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
11	0.100	3.225	2.860	2.660	2.536	2.451	2.389	2.342	2.304	2.274	2.248	2.209	2.167	2.123	2.100	2.076
	0.050	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.788	2.719	2.646	2.609	2.570
	0.025	6.724	5.256	4.630	4.275	4.044	3.881	3.759	3.664	3.588	3.526	3.430	3.330	3.226	3.173	3.118
	0.010	9.646	7.206	6.217	5.668	5.316	5.069	4.886	4.744	4.632	4.539	4.397	4.251	4.099	4.021	3.941
	0.005	12.226	8.912	7.600	6.881	6.422	6.102	5.865	5.682	5.537	5.418	5.236	5.049	4.855	4.756	4.654
12	0.100	3.177	2.807	2.606	2.480	2.394	2.331	2.283	2.245	2.214	2.188	2.147	2.105	2.060	2.036	2.011
	0.050	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.687	2.617	2.544	2.505	2.466
	0.025	6.554	5.096	4.474	4.121	3.891	3.728	3.607	3.512	3.436	3.374	3.277	3.177	3.073	3.019	2.963
	0.010	9.330	6.927	5.953	5.412	5.064	4.821	4.640	4.499	4.388	4.296	4.155	4.010	3.858	3.780	3.701
	0.005	11.754	8.510	7.226	6.521	6.071	5.757	5.525	5.345	5.202	5.085	4.906	4.721	4.530	4.431	4.331
13	0.100	3.136	2.763	2.560	2.434	2.347	2.283	2.234	2.195	2.164	2.138	2.097	2.053	2.007	1.983	1.958
	0.050	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.604	2.533	2.459	2.420	2.380

²⁰ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.05, 4, 12} = 3.259$$


De acuerdo con el ejemplo, de la tabla anterior se escoge el valor de la F para el bloque, el cual es 6.388 y se compara con el estadístico teórico. Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Al comparar ambos estadísticos se tiene que:

$$6.388 > 3.259 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que en al menos 1 de los 5 *conductores* se obtiene diferente *desgaste promedio*, o bien que el *conductor* del automóvil sí afecta en el *desgaste* de la llanta y por lo tanto esta variable debe controlarse.

6.16 Análisis de covarianza

Análisis de covarianza. Técnica que pretende aislar o controlar los efectos de una variable que durante el desarrollo del experimento no pudo controlarse y afecta las mediciones de la variable dependiente.

Análisis de regresión. Busca saber la cantidad de variación que la covariable pudo incluir en la variable dependiente.

Análisis de varianza. Examina el efecto que la variable no métrica tiene en la variable dependiente.

El **análisis de covarianza** es una técnica también llamada ANCOVA o ANDECOVA y tiene un objetivo similar al de bloques al azar, esto es, pretende aislar o controlar los efectos de una variable que durante el desarrollo del experimento no pudo controlarse y afecta las mediciones de la variable dependiente. Esta variable recibe el nombre de *covariable* y se mide a través de escalas de intervalo o razón. A diferencia de la técnica anterior, es decir de bloques al azar, en la cual la variable a controlar era de naturaleza no métrica (medida en escala nominal), en el análisis de covarianza la variable a controlar es de naturaleza métrica (medida en escala de intervalo o razón).

El análisis de covarianza es una mezcla de 2 técnicas: análisis de varianza y análisis de regresión. El **análisis de regresión** busca saber la cantidad de variación que la covariable pudo incluir en la variable dependiente, mientras que el **análisis de varianza** examina el efecto que la variable no métrica tiene en la variable dependiente.

El análisis de covarianza se utiliza para 2 fines: eliminar cualquier error sistemático que pueda sesgar los resultados y encontrar diferencias entre respuestas dependiendo de las respuestas de cada encuestado. Una covarianza correcta es aquella que está altamente relacionada con la variable dependiente, no así con las independientes.

Una pregunta habitual es cuántas covariables incluir en el análisis; aunque se quiera medir tantos efectos extraños como sea posible, la idea es no tener muchas para que no reduzcan la eficiencia estadística del estudio.

Para realizar el análisis de covarianza las covarianzas deben tener relación con la variable dependiente y efectos iguales entre los grupos de la variable dependiente.

6.16.1 Modelo general de covarianza

En seguida se presenta el modelo general del análisis de covarianza:

$$Y_{ij} = \mu + \tau_{.j} + \beta X_{ij} + \varepsilon_{ij}$$

Donde:

Y_{ij} : representa la observación i de la variable dependiente, medida bajo los efectos del nivel j del factor manejado en el experimento

μ : es el promedio general de la dependiente

$\tau_{.j}$: es el efecto del nivel j del factor manejado en el experimento

β : es el coeficiente de la pendiente de la ecuación de regresión obtenida en el modelo

X_{ij} : representa el efecto de la covariable i , cuando el nivel del factor se encuentra en el valor j

ε_{ij} : es el error de cada una de las observaciones de la variable dependiente

A continuación se presentan las fórmulas que por definición se tienen:

Cuadro 6-10 Fórmulas de definición para la variable dependiente y la covariable

Fuentes de variación	Suma de cuadrados
Variación explicada (SS_B)	$SS_B = r \sum_{i=1}^k (\bar{y}_{i.} - \bar{y}_{..})^2$
Variación no explicada (SS_W)	$SS_W = SS_T - SS_B$
Variación total (SS_T)	$SS_W = \sum_{i=1}^k \sum_{j=1}^r (y_{ij} - \bar{y}_{..})^2$

Cuadro 6-11 Fórmulas de definición para el producto cruzado entre la variable dependiente y la covariable (covarianza)

Fuentes de variación	Producto cruzado
Variación explicada (SS_{PCB})	$SS_{PCB} = r \sum_{i=1}^k (\bar{x}_{i.} - \bar{x}_{..})(\bar{y}_{i.} - \bar{y}_{..})^2$
Variación no explicada (SS_{PCW})	$SS_{PCW} = SS_{PCT} - SS_{PCB}$
Variación total (SS_{PCT})	$SS_{PCT} = \sum_{i=1}^k \sum_{j=1}^r (x_{ij} - \bar{x}_{..})(y_{ij} - \bar{y}_{..})$

Donde:

k : es el número de niveles del factor

N : es el número total de datos

r : es el número de datos por nivel

$\bar{Y}_{i.}$: es la media para la variable dependiente para cada nivel del factor

$\bar{Y}_{..}$: es la media total de la variable dependiente

$\bar{X}_{i.}$: es la media de la covariable para cada nivel del factor

$\bar{X}_{..}$: es la media total de la covariable

Y_{ij} : es cada una de las observaciones de la variable dependiente

X_{ij} : es cada una de las observaciones de la covariable

Las fórmulas de manera reducida son:

Cuadro 6-12 Fórmulas del cálculo para la variable dependiente y la covariable

Fuentes de variación	Suma de cuadrados
Variación explicada (SS_B)	$SS_B = \sum_{i=1}^k \frac{y_{i.}^2}{r} - N\bar{y}_{..}^2$
Variación no explicada (SS_W)	$SS_W = SS_T - SS_B$
Variación total (SS_T)	$SS_T = \sum_{i=1}^k \sum_{j=1}^r y_{ij}^2 - N\bar{y}_{..}^2$

Cuadro 6-13 Fórmulas del cálculo para el producto cruzado entre la variable dependiente y la covariable (covarianza)

Fuentes de variación	Producto cruzado
Variación explicada (SS_{PCB})	$SS_{PCB} = \sum_{i=1}^k \frac{(\bar{x}_{i.})(\bar{y}_{i.})}{r} - N(\bar{x}_{..})(\bar{y}_{..})$
Variación no explicada (SS_{PCW})	$SS_{PCW} = SS_{PCT} - SS_{PCB}$
Variación total (SS_{PCT})	$SS_{PCT} = \sum_{i=1}^k \sum_{j=1}^r (x_{ij})(y_{ij}) - N(\bar{x}_{..})(\bar{y}_{..})$

Con las fórmulas anteriores se realizará el arreglo matricial correspondiente a la variación total (T), a la variación explicada (B) y a la no explicada (W), tal y como se hizo en el capítulo 5 “Análisis discriminante”.

$$T = B + W$$

Después se calcula la suma de cuadrados del error del modelo del módulo de covarianza (SS_E)

$$SS_E^* = SS_{E(\text{dependiente})} - \frac{\left(SS_{PC_{E(\text{dependiente y covariable})}} \right)^2}{SS_{E(\text{covariable})}}$$

Luego se calcula la suma de cuadrados totales del modelo de regresión (SS_T).

$$SS_T^* = SS_{T(\text{dependiente})} - \frac{\left(SS_{PC_{T(\text{dependiente y covariable})}} \right)^2}{SS_{T(\text{covariable})}} =$$

Por último se realizan las pruebas de la forma acostumbrada; el cálculo de cada F se presenta a continuación:

Para las covariables:

$$F_C = \frac{\frac{(SSPC_{E(\text{dependiente y covariable})})^2}{SS_{E(\text{covariable})}}}{\frac{SS_E^*}{[k(r-1)-1]}}$$

Para el factor:

$$F_C = \frac{\frac{(SS_T^* - SS_E^*)^2}{(k-1)}}{\frac{SS_E^*}{[k(r-1)-1]}}$$

Ahora se verá un ejemplo para entender mejor el proceso.

Problema de ANCOVA:

Se realizó un experimento en una tienda comercial para conocer las *ventas* de cierto producto colocado en 3 *posiciones* distintas en el *anaquel*: *altura baja, media y alta*. Un factor importante y que afectó las ventas era el *tráfico de personas* que pasaron por el lugar donde se exhibía el artículo. Los datos registrados de *ventas, altura y personas* son los siguientes:²¹

Tabla 6-28 Datos

Altura	Ventas	Tráfico	Altura	Ventas	Tráfico	Altura	Ventas	Tráfico
Baja	87	5	Media	92	2	Alta	93	4
Baja	94	6	Media	96	1	Alta	103	9
Baja	92	3	Media	99	3	Alta	111	12
Baja	82	2	Media	98	4	Alta	85	2
Baja	95	7	Media	105	7	Alta	86	3
Baja	102	8	Media	106	6	Alta	83	6
Baja	87	5	Media	98	4	Alta	107	10
Baja	93	6	Media	91	2	Alta	109	8
Suma	732	42		785	29		777	54
Promedios	91.5	5.25		98.125	3.625		97.125	6.75
Promedio general	95.583	5.208						

Se calcula cada variación tanto de la variable dependiente como de la covariable:

Variación total para la variable *ventas*:

$$SS_{PCT_D} = 87^2 + 94^2 + \dots + 109^2 - 24(95.583)^2 = 1\,621.833$$

²¹ Datos generados para efectos de este texto.

Variación explicada de la variable *ventas*:

$$SS_{PCB_D} = 8(91.5)^2 + 8(98.125)^2 + 8(97.125)^2 + 24(95.583)^2 = 204.083$$

Variación no explicada de la variable *ventas*:

$$SS_{PCW_D} = SS_{PCT_D} - SS_{PCB_D} = 1\,621.83 - 204.083 = 1\,417.75$$

Variación total para la variable *tráfico*:

$$SS_{PCT_D} = 5^2 + 6^2 + \dots + 8^2 - 24(5.208)^2 = 185.958$$

Variación explicada para la variable *tráfico*:

$$SS_{PCB_D} = 8(5.25)^2 + 8(3.625)^2 + 8(6.75)^2 + 24(5.208)^2 = 39.083$$

Variación no explicada para la variable *tráfico*:

$$SS_{PCW_C} = SS_{PCT_C} - SS_{PCB_C} = 185.958 - 39.083 = 146.875$$

Covarianza total para las variables *ventas* y *tráfico*:

$$SS_{PCW_{D \times C}} = (87)(5) + (94)(6) + \dots + (109)(8) - 24(95.583)(5.208) = 378.083$$

Covarianza explicada para las variables *ventas* y *tráfico*:

$$SS_{PCB_{D \times C}} = 8[(91.5)(5.25)] + 8[(98.125)(3.625)] + 8[(97.125)(6.75)] - 24[(95.583)(5.208)] = -14.542$$

Covarianza no explicada para las variables *ventas* y *tráfico*:

$$SS_{PCW_{D \times C}} = SS_{PCT_{D \times C}} - SS_{PCB_{D \times C}} = 378.083 - 14.542 = 392.625$$

Al arreglar la información en las expresiones matriciales correspondientes se tiene que:

$$T = B + W$$

$$\begin{bmatrix} 1\,621.833 & 378.083 \\ 378.083 & 185.958 \end{bmatrix} = \begin{bmatrix} 204.083 & -14.542 \\ -14.542 & 39.083 \end{bmatrix} + \begin{bmatrix} 1\,417.75 & 392.625 \\ 392.625 & 146.875 \end{bmatrix}$$

Posteriormente se calcula la suma de cuadrados del error del modelo del módulo de covarianza (SS_E)

$$SS_E^* = SS_{E(\text{ventas})} - \frac{(SSPC_{E(\text{ventas y tráfico})})^2}{SS_{E(\text{tráfico})}}$$

$$SS_E^* = 1\,419.75 - \frac{(392.625)^2}{146.875} = 368.188$$

Después se calcula la suma de cuadrados totales del modelo de regresión (SS_T).

$$SS_T^* = SS_{T(\text{ventas})} - \frac{(SSPC_{T(\text{ventas y tráfico})})^2}{SS_{T(\text{tráfico})}} =$$

$$SS_T^* = 1\,621.833 - \frac{(378.083)^2}{185.958} = 853.129 =$$

Y por último se realizan las pruebas de la forma acostumbrada; el cálculo de cada F se presenta a continuación:

Para la covariable:

$$F_C = \frac{\frac{(SSPC_{E(\text{ventas y tráfico})})^2}{SS_{E(\text{tráfico})}}}{\frac{SS_E^*}{[k(r-1)-1]}}$$

Por lo que se tiene:

$$F_C = \frac{\frac{(392.625)^2}{\frac{146.875}{368.188}}}{\frac{1\,049.562}{18.409}} = \frac{1\,049.562}{18.409} = 57.012$$

Para el factor:

$$F_C = \frac{\frac{(SS_T^* - SS_E^*)^2}{(k-1)}}{\frac{SS_E^*}{[k(r-1)-1]}}$$

Esto quedaría de la siguiente forma:

$$F_C = \frac{\frac{(853.129 - 368.188)^2}{(3-1)}}{\frac{368.188}{[3(8-1)-1]}} = \frac{242.470}{18.409} = 13.171$$

Todo lo anterior se acomodó en la siguiente tabla:

Tabla 6-29 Efectos

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Tráfico	1 049.562	1	1 049.562	57.012
Altura	484.941	2	242.470	13.171
Error	368.188	20	18.409	
Total	1 621.833	23		

Ahora se realizarán las pruebas de hipótesis:

Prueba de hipótesis para la covariable:

$H_0 : \beta = 0$: la covariable *tráfico* no afecta a las *ventas promedio*

$H_a : \beta \neq 0$: la covariable *tráfico* sí afecta a las *ventas promedio*


Donde:

β : es el coeficiente de regresión

De acuerdo con el ejemplo:

Como el nivel de significancia es de 5% el estadístico teórico se encuentra de la siguiente manera:

Tabla 6-30 Parte de la tabla F²²



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40
19	0.100	2.990	2.606	2.397	2.266	2.176	2.109	2.058	2.017	1.984	1.956	1.912	1.865	1.814	1.787	1.759	1.730
	0.050	4.381	3.522	3.127	2.895	2.740	2.628	2.544	2.477	2.423	2.378	2.308	2.234	2.155	2.114	2.071	2.026
	0.025	5.922	4.508	3.903	3.559	3.333	3.172	3.051	2.956	2.880	2.817	2.720	2.617	2.509	2.452	2.394	2.333
	0.010	8.185	5.926	5.010	4.500	4.171	3.939	3.765	3.631	3.523	3.434	3.297	3.153	3.003	2.925	2.844	2.761
	0.005	10.073	7.093	5.916	5.268	4.853	4.561	4.345	4.177	4.043	3.933	3.763	3.587	3.402	3.306	3.208	3.106
20	0.100	2.975	2.589	2.380	2.249	2.158	2.091	2.040	1.999	1.965	1.937	1.892	1.845	1.794	1.767	1.738	1.708
	0.050	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447	2.393	2.348	2.278	2.203	2.124	2.082	2.039	1.994
	0.025	5.871	4.461	3.859	3.515	3.289	3.128	3.007	2.913	2.837	2.774	2.676	2.573	2.464	2.408	2.349	2.287
	0.010	8.096	5.849	4.938	4.431	4.103	3.871	3.699	3.564	3.457	3.368	3.231	3.088	2.938	2.859	2.778	2.695
	0.005	9.944	6.986	5.818	5.174	4.762	4.472	4.257	4.090	3.956	3.847	3.678	3.502	3.318	3.222	3.123	3.022
21	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719	1.689
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010	1.965
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	2.637	2.534	2.425	2.368	2.308	2.246

²² La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha=0.05, 1, 20} = 4.351$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

De la tabla de los efectos se escoge el valor de la F para la covariable *tráfico*, el cual es 57.012; al comparar ambos estadísticos se tiene que:

$$57.012 > 4.351 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que el *tráfico* sí afecta a las *ventas promedio*, por lo que se justifica el uso del modelo ANCOVA.

Prueba de hipótesis para el factor *altura*:

$H_0: \mu_1 = \mu_2 = \mu_3$: las diferentes *alturas* en el anaquel no afectan las *ventas promedio*, o bien las *ventas promedio* son las mismas a cualquier *altura* del estante

$H_a: \mu_1 \neq \mu_2 \neq \mu_3$: las diferentes *alturas* en el anaquel sí afectan las *ventas promedio*, o bien las *ventas promedio* no son las mismas y varían en alguna de las *alturas* del estante


Donde:

μ_i : son las ventas promedio en el nivel i del factor

De acuerdo con el ejemplo:

Como el nivel de significancia propuesto para esta prueba es 5%, el estadístico teórico se encuentra de la siguiente manera:

Tabla 6-31 Parte de la tabla F²³



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40
19	0.100	2.990	2.606	2.397	2.266	2.176	2.109	2.058	2.017	1.984	1.956	1.912	1.865	1.814	1.787	1.759	1.730
	0.050	4.381	3.522	3.127	2.895	2.740	2.628	2.544	2.477	2.423	2.378	2.308	2.234	2.155	2.114	2.071	2.026
	0.025	5.922	4.508	3.903	3.559	3.333	3.172	3.051	2.956	2.880	2.817	2.720	2.617	2.509	2.452	2.394	2.333
	0.010	8.185	5.926	5.010	4.500	4.171	3.939	3.765	3.631	3.523	3.434	3.297	3.153	3.003	2.925	2.844	2.761
	0.005	10.073	7.093	5.916	5.268	4.853	4.561	4.345	4.177	4.043	3.933	3.763	3.587	3.402	3.306	3.208	3.106
20	0.100	2.975	2.589	2.380	2.249	2.158	2.091	2.040	1.999	1.965	1.937	1.892	1.845	1.794	1.767	1.738	1.708
	0.050	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447	2.393	2.348	2.278	2.203	2.124	2.082	2.039	1.994
	0.025	5.871	4.461	3.859	3.515	3.289	3.128	3.007	2.913	2.837	2.774	2.676	2.573	2.464	2.408	2.349	2.287
	0.010	8.096	5.849	4.938	4.431	4.103	3.871	3.699	3.564	3.457	3.368	3.231	3.088	2.938	2.859	2.778	2.695
	0.005	9.944	6.986	5.818	5.174	4.762	4.472	4.257	4.090	3.956	3.847	3.678	3.502	3.318	3.222	3.123	3.022
21	0.100	2.961	2.575	2.365	2.233	2.142	2.075	2.023	1.982	1.948	1.920	1.875	1.827	1.776	1.748	1.719	1.689
	0.050	4.325	3.467	3.072	2.840	2.685	2.573	2.488	2.420	2.366	2.321	2.250	2.176	2.096	2.054	2.010	1.965
	0.025	5.827	4.420	3.819	3.475	3.250	3.090	2.969	2.874	2.798	2.735	2.637	2.534	2.425	2.368	2.308	2.246

²³ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.05, 2, 20} = 3.493$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

De la tabla de los efectos se escoge el valor de la F para la covariable *tráfico*, el cual es 57.012 y al comparar ambos estadísticos se tiene que:

$$13.171 > 3.493 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que las *ventas promedio* no son las mismas, es decir son distintas según las *alturas* del anaquel, para saber a qué *altura* se obtienen mayores ventas se pueden utilizar las pruebas post-hoc.

6.17 Análisis de varianza multivariado

El **análisis de varianza multivariado** es la técnica que se considera como el caso general del análisis de varianza y permite pronosticar simultáneamente 2 o más variables dependientes, las cuales representan un concepto o factor. Esta técnica se conoce como MANOVA o MANDEVA y maneja variables con las mismas características que el ANOVA.

Las variables dependientes tienen que estar relacionadas entre sí, si no lo están no tendría sentido realizar un MANOVA; en ese caso se sugiere un ANOVA para cada variable. Esta última es una técnica de dependencia que mide las diferencias en los promedios de 2 o más variables métricas dependientes basadas en un conjunto de variables no métricas que actúa como predictor.

Análisis de varianza multivariado. Técnica que permite pronosticar simultáneamente 2 o más variables dependientes, que representan un concepto o factor.

6.17.1 MANOVA de un solo factor (caso balanceado)

Las variables que maneja esta técnica son una independiente y 2 o más dependientes. Es importante señalar que un caso balanceado, en esta técnica, significa que en un nivel las variables dependientes tendrán el mismo número de observaciones y éste será el caso a ejemplificar.

En esta técnica se utilizarán conceptos similares a los de ANOVA de un solo factor; a continuación se presentan las fórmulas para el desarrollo de dicha técnica:

Cuadro 6-14 Fórmulas de definición para las variables dependientes

Fuentes de variación	Suma de cuadrados
Variación explicada (SS_B)	$SS_B = r \sum_{i=1}^k (y_{i.} - \bar{y}_{..})^2$
Variación no explicada (SS_W)	$SS_W = SS_T - SS_B$
Variación total (SS_T)	$SS_T = \sum_{i=1}^k \sum_{j=1}^r (y_{ij} - \bar{y}_{..})^2$

Además:

Cuadro 6-15 Fórmulas de definición para el producto cruzado entre las variables dependientes

Fuentes de variación	Producto cruzado
Variación explicada (SS_{PCB})	$SS_{PCB} = r \sum_{i=1}^k (\bar{x}_{i.} - \bar{x}_{..})(y_{i.} - \bar{y}_{..})$
Variación no explicada (SS_{PCW})	$SS_W = SS_{PCT} - SS_{PCB}$
Variación total (SS_{PCT})	$SS_{PCT} = \sum_{i=1}^k \sum_{j=1}^r (x_{ij} - \bar{x}_{..})(y_{ij} - \bar{y}_{..})$

Donde:

k : es el número de niveles del factor

N : es el número total de datos

r : es el número de datos por nivel

$\bar{Y}_{i.}$: es la media para la primera variable dependiente para el nivel i del factor

$\bar{Y}_{..}$: es la media total de la primera variable dependiente

$\bar{X}_{i.}$: es la media para la segunda variable dependiente para el nivel i del factor

$\bar{X}_{..}$: es la media total de la segunda variable dependiente

Y_{ij} : son cada una de las observaciones de la primera variable dependiente

X_{ij} : son cada una de las observaciones de la segunda variable dependiente

Las fórmulas reducidas serían las siguientes:

Cuadro 6-16 Fórmulas del cálculo de las variables dependientes

Fuentes de variación	Suma de cuadrados
Variación explicada (SS_B)	$SS_B = \sum_{i=1}^k \frac{y_{i.}^2}{r} - N \bar{y}_{..}^2$
Variación no explicada (SS_W)	$SS_W = SS_T - SS_B$
Variación total (SS_T)	$SS_T = \sum_{i=1}^k \sum_{j=1}^r y_{ij}^2 - N \bar{y}_{..}^2$

Cuadro 6-17 Fórmulas del cálculo de los productos cruzados entre las variables dependientes

Fuentes de variación	Producto cruzado
Variación explicada (SS_{PCB})	$SS_{PCB} = \sum_{i=1}^k \frac{(\bar{x}_{i.})(\bar{y}_{.i})}{r} - N(\bar{x}_{..})(\bar{y}_{..})$
Variación no explicada (SS_{PCW})	$SS_W = SS_{PCT} - SS_{PCB}$
Variación total (SS_{PCT})	$SS_{PCT} = \sum_{i=1}^k \sum_{j=1}^r (x_{ij})(y_{ij}) - N(\bar{x})(\bar{y})$

Con los resultados de estas fórmulas se construyen matrices cuadradas, igual que en el análisis de covarianza. Se construyen las 3 matrices: la explicada (B), la del error (W) y la matriz total (T).

Después se realiza la prueba de Wilks, donde se establecen las hipótesis respectivas y se obtiene el valor de lambda (λ), la cual se calcula de la siguiente manera:

$$(\lambda) = \frac{\text{Determinante de la matriz del error}}{\text{Determinante de la matriz total}} = \frac{|W|}{|T|}$$

El valor de la lambda se convierte a un valor F, cuya equivalencia dependerá del número de variables dependientes y del número de niveles en el factor.

Cuadro 6-18 Fórmulas para la conversión a la F

Núm. de variables dependientes	Núm. de niveles de factor	F calculada	F de tablas
$p = 1$	$k \geq 2$	$(\sum n_j - k)/(k - 1)[(1 - \Lambda)/\Lambda]$	$(\alpha, (k - 1), (\sum n_j - k))$
$p = 2$	$k \geq 2$	$(\sum n_j - k - 1)/(k - 1)[(1 - \sqrt{\Lambda})/\sqrt{\Lambda}]$	$(\alpha, 2(k - 1), 2(\sum n_j - k - 1))$
$p \geq 1$	$k = 2$	$\left[\frac{\sum n_j - p - 1}{p} \right] [(1 - \Lambda)/\Lambda]$	$(\alpha, p, (\sum n_j - p - 1))$
$p \geq 1$	$k = 3$	$\left[\frac{\sum n_j - p - 2}{p} \right] [(1 - \Lambda)/\Lambda]$	$(\alpha, 2p, 2(\sum n_j - p - 2))$

Donde:

n_j : es el número de parejas de datos para cada uno de los niveles del factor manejado en el experimento

p : es el número de variables dependientes

k : es el número de niveles del factor

Problema de MANOVA

En cierta empresa, el departamento de recursos humanos está midiendo la efectividad de 3 distintos programas de inducción para su personal, los cuales consisten en *dinámicas*, *casos* o *seminarios*. La

efectividad será medida basándose en el *grado de identificación* que el personal logra con su empresa. Este último concepto se evalúa a través de 2 criterios:

1. ¿Qué tanto el empleado llega a *conocer* los objetivos de la empresa? y,
2. ¿Qué tanta *motivación* se logró dar a la persona durante el programa de capacitación?

Los datos obtenidos son los siguientes:²⁴

Tabla 6-32 Datos

	Método de inducción					
	Dinámica		Casos		Seminarios	
	Conocimiento	Motivación	Conocimiento	Motivación	Conocimiento	Motivación
	9	3	0	4	6	8
	6	2	2	0	1	9
	9	7			2	7
Total	24	12	2	4	6	24
Promedio	8	4	1	2	2	8
Promedio general	4	5				

Para este caso el factor es *método de inducción*, sus niveles son *dinámicas*, *casos* y *seminarios*. Las variables a explicar son *conocimiento* y *motivación*.

Como se mencionó será como un ANOVA de un solo factor, pero en 2 partes:

1. Inducción para explicar a *conocimiento*.
2. Inducción para explicar a *motivación*.

De acuerdo con las fórmulas se tienen los siguientes resultados:

Variación total para la variable *conocimiento*:

$$SS_{T_C} = 9^2 + 6^2 + \dots + 2^2 - 8(4)^2 = 88$$

Variación explicada para la variable *conocimiento*:

$$SS_{B_C} = 3(8 - 4)^2 + 2(1 - 4)^2 + 3(2 - 4)^2 = 78$$

Variación no explicada para la variable *conocimiento*:

$$SS_{W_C} = SS_{T_C} - SS_{B_C} = 88 - 78 = 10$$

Variación total para la variable *motivación*:

$$SS_{T_M} = 3^2 + 2^2 + \dots + 7^2 + 8(5)^2 = 72$$

Variación explicada para la variable *motivación*:

$$SS_{B_M} = 3(4 - 5)^2 + 2(2 - 5)^2 + 3(8 - 5)^2 = 48$$

²⁴ Datos generados para efecto de este texto.

Variación no explicada para la variable *motivación*:

$$SS_{W_M} = SS_{T_M} - SS_{B_M} = 72 - 48 = 24$$

Covarianza total para las variables *conocimiento* y *motivación*:

$$SS_{T_{C \times M}} = (9)(3) + (6)(2) + \dots + (2)(7) - 8(4)(5) = -11$$

Covarianza explicada para las variables *conocimiento* y *motivación*:

$$SS_{B_{C \times M}} = 3(8-4)(4-5) + 2(1-4)(2-5) + (2-4)(8-5) = -12$$

Covarianza no explicada para las variables *conocimiento* y *motivación*:

$$SS_{W_{C \times M}} = SS_{T_{C \times M}} - SS_{B_{C \times M}} = 11(-12) = 1$$

Al arreglar la información en las expresiones matriciales correspondientes se tiene:

$$T = B + W$$

$$\begin{bmatrix} 88 & -11 \\ -11 & 72 \end{bmatrix} = \begin{bmatrix} 78 & -12 \\ -12 & 48 \end{bmatrix} + \begin{bmatrix} 10 & 1 \\ 1 & 24 \end{bmatrix}$$

Posteriormente se calcula la lambda de Wilks (λ)

$$(\lambda) = \frac{|W|}{|T|} = \frac{(10)(24) - (1)(1)}{(88)(72) - (-11)(-11)} = 0.038455$$

Ahora se transforma este valor a F , según su equivalencia. En este caso se tiene que $p = 2$ y $k \geq 2$, por lo tanto,

$$F_c = \frac{(\sum n_j - k - 1)(1 - \sqrt{\lambda})}{k - 1} = \frac{(3 + 2 + 3 - 3 - 1)1 - \sqrt{0.03845}}{(3 - 1)\sqrt{0.03845}} = 8.199$$

Ahora se realiza la prueba con la F encontrada:

Prueba de hipótesis para el factor *método de inducción*:

H_0 : el *grado de identificación promedio* del personal con la empresa es el mismo en cualquier *método de inducción*

H_a : al menos 1 de los *grados de identificación promedio* del personal con la empresa no es el mismo en cualquier *método de inducción*

De acuerdo con el ejemplo:


Como el nivel de significancia propuesto para esta prueba es 1%, el estadístico teórico se encuentra de la siguiente manera:

Los grados de libertad serían los siguientes:

$$F_{t, \alpha = 0.01, 2(3-1), 2(3+2+3-3-1)} = F_{t, \alpha = 0.01, 4, 8}$$

Al buscar en la tabla F se tiene lo siguiente:

Tabla 6-33 Parte de la tabla F²⁵



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
7	0.100	3.589	3.257	3.074	2.961	2.883	2.827	2.785	2.752	2.725	2.703	2.668	2.632	2.595	2.575	2.555
	0.050	5.591	4.737	4.347	4.120	3.972	3.866	3.787	3.726	3.677	3.637	3.575	3.511	3.445	3.410	3.376
	0.025	8.073	6.542	5.890	5.523	5.285	5.119	4.995	4.899	4.823	4.761	4.666	4.568	4.467	4.415	4.362
	0.010	12.246	9.547	8.451	7.847	7.460	7.191	6.993	6.840	6.719	6.620	6.469	6.314	6.155	6.074	5.992
8	0.100	16.236	12.404	10.882	10.050	9.522	9.155	8.885	8.678	8.514	8.380	8.176	7.968	7.754	7.645	7.534
	0.050	3.458	3.113	2.924	2.806	2.726	2.668	2.624	2.589	2.561	2.538	2.502	2.464	2.425	2.404	2.383
	0.025	5.318	4.459	4.066	3.838	3.687	3.581	3.500	3.438	3.388	3.347	3.284	3.218	3.150	3.115	3.079
	0.010	7.571	6.059	5.416	5.053	4.817	4.652	4.529	4.433	4.357	4.295	4.200	4.101	3.999	3.947	3.894
9	0.100	11.259	8.649	7.591	7.006	6.632	6.371	6.178	6.029	5.911	5.814	5.667	5.515	5.359	5.279	5.198
	0.050	14.688	11.042	9.596	8.805	8.302	7.952	7.694	7.496	7.339	7.211	7.015	6.814	6.608	6.503	6.396
	0.025	3.360	3.006	2.813	2.693	2.611	2.551	2.505	2.469	2.440	2.416	2.379	2.340	2.298	2.277	2.255
	0.010															

²⁵ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 4, 8} = 7.006$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

Como la $F_C = 8.199$ se tiene que:

$$8.199 > 7.006 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que al menos 1 de los *grados de identificación promedio* del personal con su empresa sí depende del *método de inducción* utilizado.

Sigue realizar las pruebas para ver si el *método de inducción* influye en los 2 *grados de identificación promedio*, para lo cual se hacen pruebas para cada variable dependiente; la información encontrada fue acomodada en la siguiente tabla:

Tabla 6-34 Efectos

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Motivación	48	2	24.0	5.0
Error _{motivación}	24	5	4.8	
Total _{motivación}	72	7		
Conocimiento	78	2	39.0	19.5
Error _{conocimiento}	10	5	2.0	
Total _{conocimiento}	88	7		

Prueba de hipótesis para *conocimiento*:

$H_0: \mu_1 = \mu_2 = \mu_3$: los diferentes *métodos de inducción* no afectan al *grado de conocimiento promedio* del personal, o bien el *conocimiento promedio* es el mismo con los diferentes *métodos de inducción*

$H_a: \mu_1 \neq \mu_2 \neq \mu_3$: los diferentes *métodos de inducción* sí afectan al *grado de conocimiento promedio* del personal, o bien el *conocimiento promedio* no es el mismo en los diferentes *métodos de inducción*

donde:

μ_i : son los *grados de conocimiento promedio* en el nivel i del factor

De acuerdo con el ejemplo:


Como el nivel de significancia propuesto para esta prueba es 1%, el estadístico teórico se encuentra de la siguiente manera:

Los grados de libertad sería los siguientes:

$$F_{t, \alpha = 0.01, (3-1), (8-2)} = F_{t, \alpha = 0.01, 2, 5}$$

Por lo que al buscar en la tabla F se tiene lo siguiente:

Tabla 6-35 Parte de la tabla F²⁶



gl	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
4	0.100	4.545	4.325	4.191	4.107	4.051	4.010	3.979	3.955	3.936	3.920	3.896	3.870	3.844	3.831	3.817
	0.050	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041	5.999	5.964	5.912	5.858	5.803	5.774	5.746
	0.025	12.218	10.649	9.979	9.605	9.364	9.197	9.074	8.980	8.905	8.844	8.751	8.657	8.560	8.511	8.461
	0.010	21.198	18.000	16.694	15.977	15.522	15.207	14.976	14.799	14.659	14.546	14.374	14.198	14.020	13.929	13.838
5	0.005	31.333	26.284	24.259	23.155	22.456	21.975	21.622	21.352	21.139	20.967	20.705	20.438	20.167	20.030	19.892
	0.100	4.060	3.780	3.619	3.520	3.453	3.405	3.368	3.339	3.316	3.297	3.268	3.238	3.207	3.191	3.174
	0.050	6.608	5.786	5.409	5.192	5.050	4.950	4.876	4.818	4.772	4.735	4.678	4.619	4.558	4.527	4.496
	0.025	10.007	8.434	7.764	7.388	7.146	6.978	6.853	6.757	6.681	6.619	6.525	6.428	6.329	6.278	6.227
6	0.010	16.258	<u>13.274</u>	12.060	11.392	10.967	10.672	10.456	10.289	10.158	10.051	9.888	9.722	9.553	9.466	9.379
	0.005	22.785	18.314	16.530	15.556	14.940	14.513	14.200	13.961	13.772	13.618	13.384	13.146	12.903	12.780	12.656
	0.100	3.776	3.463	3.289	3.181	3.108	3.055	3.014	2.983	2.958	2.937	2.905	2.871	2.836	2.818	2.800
	0.050	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147	4.099	4.060	4.000	3.938	3.874	3.841	3.808

²⁶ La tabla completa aparece en el anexo 2.3, tabla F.

Por lo que el estadístico de tablas sería:

$$F_{t, \alpha = 0.01, 2, 5} = 13.274$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

De la tabla de los efectos se escoge el valor de la F para *conocimiento*, el cual es 19.50 y al comparar ambos estadísticos se tiene que:

$$19.5 > 13.274 \text{ se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como se rechazó H_0 entonces se concluye que al menos 1 de los *métodos de inducción* afectan el *grado de conocimiento promedio*; para saber cuál o cuáles es necesario realizar pruebas post-hoc.

Prueba de hipótesis para *motivación*:

$H_0: \mu_1 = \mu_2 = \mu_3$: los diferentes *métodos de inducción* no afectan al *grado de motivación promedio* del personal, o bien la *motivación promedio* es la misma en los diferentes *métodos de inducción*

$H_a: \mu_1 \neq \mu_2 \neq \mu_3$: los diferentes *métodos de inducción* sí afectan al *grado de motivación promedio* del personal, o bien la *motivación promedio* no es la misma con los diferentes *métodos de inducción*

donde:

μ_i : son los *grados de motivación promedio* en el nivel i del factor

De acuerdo con el ejemplo:


Como el nivel de significancia propuesto para esta prueba es 1%, el estadístico teórico se encuentra de la siguiente manera:

Los grados de libertad serían:

$$F_{t, \alpha = 0.01, (3-1), (8-2)} = F_{t, \alpha = 0.01, 2, 5}$$

Por lo que al buscar en la tabla F se tiene lo siguiente:

Tabla 6-36 Parte de la tabla F²⁷



g\l	α	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30
4	0.100	4.545	4.325	4.191	4.107	4.051	4.010	3.979	3.955	3.936	3.920	3.896	3.870	3.844	3.831	3.817
	0.050	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041	5.999	5.964	5.912	5.858	5.803	5.774	5.746
	0.025	12.218	10.649	9.979	9.605	9.364	9.197	9.074	8.980	8.905	8.844	8.751	8.657	8.560	8.511	8.461
	0.010	21.198	18.000	16.694	15.977	15.522	15.207	14.976	14.799	14.659	14.546	14.374	14.198	14.020	13.929	13.838
5	0.005	31.333	26.284	24.259	23.155	22.456	21.975	21.622	21.352	21.139	20.967	20.705	20.438	20.167	20.030	19.892
	0.100	4.060	3.780	3.619	3.520	3.453	3.405	3.368	3.339	3.316	3.297	3.268	3.238	3.207	3.191	3.174
	0.050	6.608	5.786	5.409	5.192	5.050	4.950	4.876	4.818	4.772	4.735	4.678	4.619	4.558	4.527	4.496
	0.025	10.007	8.434	7.764	7.388	7.146	6.978	6.853	6.757	6.681	6.619	6.525	6.428	6.329	6.278	6.227
6	0.010	16.258	13.274	12.060	11.392	10.967	10.672	10.456	10.289	10.158	10.051	9.888	9.722	9.553	9.466	9.379
	0.005	22.785	18.314	16.530	15.556	14.940	14.513	14.200	13.961	13.772	13.618	13.384	13.146	12.903	12.780	12.656
	0.100	3.776	3.463	3.289	3.181	3.108	3.055	3.014	2.983	2.958	2.937	2.905	2.871	2.836	2.818	2.800
	0.050	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147	4.099	4.060	4.000	3.938	3.874	3.841	3.808

²⁷ La tabla completa aparece en el anexo 2.3, tabla E.

Por lo que el estadístico de tablas sería:

$$F_{t,\alpha=0.01,2,5}=13.274$$


Ahora se sabe que:

$$\text{Si } F_C > F_t \text{ se rechaza } H_0$$

De la tabla de los efectos se escoge el valor de la F para *motivación*, el cual es 5.0 y al comparar ambos estadísticos se tiene que:

$$5.0 < 13.274 \text{ no se rechaza } H_0$$

En forma gráfica sería de la siguiente manera:



Como no se rechazó H_0 entonces se concluye que ninguno de los *métodos de inducción* afectan el *grado de motivación promedio*; esto indica que no se justifica el uso del MANOVA, sino solamente el de ANOVA de un factor.

6.17.2 Coeficiente eta parcial al cuadrado

El coeficiente η^2 se utiliza para medir las estimaciones del tamaño del efecto en cada una de las variables por el factor, con el fin de decidir qué variable en el análisis impacta más el factor, su fórmula es la siguiente:

$$\eta^2 = \frac{SS_{\text{factor}}}{SS_{\text{total}}}$$

Esa fórmula indica qué proporción o porcentaje de la variación total de la variable dependiente explica o capta cada uno de los factores para explicarlo mejor; en la siguiente tabla se muestran las variaciones encontradas en el diseño factorial.

Tabla 6-37 Efectos

Fuente de variación	Suma de cuadrados	Grados de libertad	Media cuadrática	F calculada
Motivación	48	2	24.0	5.0
Error _{motivación}	24	5	4.8	
Total _{motivación}	72	7		
Conocimiento	78	2	39.0	19.5
Error _{conocimiento}	10	5	2.0	
Total _{conocimiento}	88	7		

Al utilizar las variaciones de *motivación* el coeficiente ETA^2 parcial sería el siguiente:

$$\eta^2 = \frac{SS_{motivación}}{SS_{total\ motivación}} = \frac{48}{72} = 0.667$$

Ahora con las variaciones de *conocimiento* el coeficiente ETA^2 parcial sería el siguiente:

$$\eta^2 = \frac{SS_{motivación}}{SS_{total\ motivación}} = \frac{78}{88} = 0.886$$

Por lo que se puede decir que el *método de inducción* explica mejor el *grado de conocimiento* que el de *motivación*.


La información que el SPSS™ muestra es la siguiente:

Tabla 6-38 Tabla que muestra el coeficiente

Pruebas de los efectos intersujetos							
Fuente	Variable dependiente	Suma de cuadrados tipo III	gl	Media cuadrática	F	Significación	Eta al cuadrado parcial
Modelo corregido	Conocimiento	78.000 ^a	2	39.000	19.500	.004	.886
	Motivación	48.000 ^b	2	24.000	5.000	.064	.667
Intersección	Conocimiento	103.714	1	103.714	51.857	.001	.912
	Motivación	168.000	1	168.000	35.000	.002	.875
Inducción	Conocimiento	78.000 ^a	2	39.000	19.500	.004	.886
	Motivación	48.000 ^b	2	24.000	5.000	.064	.667
Error	Conocimiento	10.000	5	2.000			
	Motivación	24.000	5	4.800			
Total	Conocimiento	216.000	8				
	Motivación	272.000	8				
Total corregido	Conocimiento	88.000	7				
	Motivación	72.000	7				

^a R cuadrado = .886 (R cuadrada corregida = .841).

^b R cuadrado = .667 (R cuadrada corregida = .533).



6.18 Ejercicios de análisis de varianza

Problema 1

Se quiere evaluar la eficacia de distintas *dosis* de un fármaco contra la hipertensión arterial, comparándola con la de una *dieta sin sal*. Para ello se seleccionan al azar 25 hipertensos y se distribuyen aleatoriamente en 5 grupos; al primero no se le suministra ningún *tratamiento*, al segundo una *dieta* con un contenido *pobre en sal*, al tercero una *dieta sin sal*, al cuarto el *fármaco* a una dosis determinada y al quinto el mismo *fármaco* a otra dosis. Las *presiones arteriales sistólicas* de los 25 sujetos al finalizar los tratamientos son:

Grupo	1	2	3	4	5
	180	172	163	158	147
	173	158	170	146	152
	175	167	158	160	143
	182	160	162	171	155
	181	175	170	155	160

- ¿Qué se puede concluir al respecto?
- Use la prueba de Scheffé para determinar qué grupos son los que presentan un patrón de respuesta promedio similar.

Problema 2

En un ensayo clínico para comparar los efectos de 2 *analgésicos* y un *placebo*, según el tiempo que tarda en desaparecer un *dolor de cabeza*, se obtuvieron los siguientes datos:

Placebo	Analgésico A	Analgésico B
35	20	22
40	35	42
60	50	30
50	40	35
50	30	22

- ¿Qué se puede concluir al respecto?
- Use la prueba de Scheffé para determinar qué grupos son los que presentan un patrón de respuesta promedio similar.

Problema 3

Suponga que usted experimentó con *levadura* para una receta de panes dulces. Parece ser que la *cantidad de azúcar* y la *temperatura del agua* afectan el *tamaño de los panes*. Basándose en los siguientes datos, usted realiza un análisis de varianza para averiguar lo que es significativo de estas recetas.

Levadura: tamaño de los panes dulces			
	Agua fría	Agua tibia	Agua caliente
Poca azúcar	75	83	60
	73	84	56
	78	87	63
Azúcar normal	74	82	55
	75	83	56
	79	87	53
Mucha azúcar	70	79	53
	68	74	69
	64	83	56

- ¿Qué se puede concluir al respecto?

Problema 4

Se desea comparar 3 *métodos de enseñanza* (A, B y C) se elige al azar una muestra de *estudiantes* de cada método y se le aplica una prueba final común. Los resultados son los siguientes:

A	B	C
89	78	64
45	85	69
59	93	82
46	81	74
64	79	79
71	98	
94		

- ¿Habrá evidencia suficiente para concluir que hay diferencia entre métodos?

Problema 5

Se realizó una investigación para probar distintos *métodos de entrenamiento* para el ensamble de un componente.

Método A	Método B	Método C	Método D
20.8	23.1	24.3	24.0
22.1	24.7	25.6	24.3
22.5	26.0	25.0	25.2
20.1	24.6	26.8	26.8
21.2	25.0	25.2	24.8
19.9	24.5	25.7	23.8
19.5	22.5	25.2	26.8
19.5	22.5	25.2	26.8
	22.7	24.9	
	22.9		

- Pruebe si el *método de entrenamiento* tiene influencia sobre el tiempo en que se ensambla el componente.
- ¿Cuál *método de entrenamiento* recomendaría utilizar si se quiere reducir el *tiempo de ensamble*?

Problema 6

Se toma una muestra de la *producción* de 36 fincas donde se han sembrado 4 *variedades de maíz* y se observan los siguientes resultados

Variedad de maíz			
1	2	3	4
29.5	30.1	23.7	35.7
34.7	29.0	26.4	36.9
28.0	26.6	26.5	35.0
315	36.4	37.5	36.5
39.8	36.6	34.6	34.9
29.8	35.3	35.6	48.2
33.8	54.7	39.7	41.3
37.7	53.2	46.2	43.3
35.5	31.4	34.2	51.7

- ¿Habrá diferencia entre las *producciones promedio* de cada *variedad de maíz*? Escribir las hipótesis y comentar sus resultados.
- Aplicar los métodos de comparaciones múltiples de Scheffé para identificar las *variedades de maíz* similares.

Problema 7

Los siguientes datos representan los *niveles de colesterol* para consumidores de 3 *tipos de carne*

Tipos de carne		
Res	Cerdo	Pollo/mariscos
241	245	249
218	197	222
261	199	221
190	162	215
238	191	207
256	182	193
248	160	205
224	180	227
225	208	203
238	227	180
178	174	200
185	209	154
194	225	211
224	271	204
221	187	169

- ¿Habrá diferencia en los *niveles de colesterol* entre los 3 *tipos de consumidores*? Escribir las hipótesis y comentar sus resultados.
- Comparar los *niveles de colesterol* por *tipo de consumidor* y detectar los que tienen un mayor *nivel promedio*.

Problema 8

Se hace un experimento para probar los efectos de 5 diferentes *dietas* en pavos. Se asignan al azar 6 pavos a cada una de las 5 dietas; se les alimentó por un periodo, luego se registró la *ganancia en peso* en libras. Los resultados son los siguientes.

Dieta a	Dieta b	Dieta c	Dieta d	Dieta e
4.1	5.2	6.3	6.5	9.5
3.3	4.8	6.5	6.8	9.6
3.1	4.5	7.2	7.3	9.2
4.2	6.8	7.4	7.5	9.1
3.6	5.5	7.8	6.9	9.8
4.4	6.2	6.7	7.0	9.1

- Probar si la *ganancia en peso* es la misma en todas las *dietas*. Justificar su contestación.
- Hacer comparaciones múltiples para detectar qué *dietas* producen igual *ganancia en peso*. Comentar sus resultados.

Problema 9

Los siguientes datos representan los *niveles de glucosa* en la sangre en 5 *grupos de pacientes* que fueron tratados con *químicos* diferentes

Tipo de químico				
A	B	C	D	E
12	64	130	82	123
74	56	136	51	113
63	42	137	72	138
67	39	107	77	126
68	29	155	45	135
58	42	137	85	138
77	61	138	80	124
55	67	120	51	102
80	40	138	76	125
78	89	165	95	103
87	47	138	82	124
89	44	163	92	128

- Probar si los *niveles de glucosa* son los mismos para los 5 *grupos*. Justificar su contestación.
- Hacer comparaciones múltiples para detectar qué *tipos de pacientes* tienen iguales *niveles de glucosa*. Comentar sus resultados.

Problema 10

Se seleccionaron al azar ministros de 3 *religiones*: 8 *metodistas*, 10 *católicos* y 9 *pentecostales*; se desea probar si poseen el mismo *conocimiento* sobre los problemas sociales actuales. Los resultados de un test para medir sus *conocimientos* son los siguientes

Religión		
Metodista	Católico	Pentecostal
32	32	28
30	32	21
30	26	15
29	26	15
26	22	14
23	20	14
18	14	09
19	16	11
14	08	
15		

- Probar si los ministros de las 3 *religiones* poseen igual conocimiento de enfermedades mentales.
- Usar comparaciones múltiples para comparar los 3 *grupos*. Comentar sus resultados.

Problema 11

Una panadería desea saber si hay un efecto de la *posición* (*abajo, en medio, arriba*) en que se colocan en los anaqueles y del *ancho de los anaqueles* (*normal, bastante ancho*) en la *venta* de sus panes. Se registra el número de bolsas de panes vendidas diariamente en 24 supermercados, y los datos que se obtienen son

Posición	Ancho del anaquel	
	Normal	Bastante ancho
Abajo	47 43	46 40
	50 55	41 38
En medio	62 68	67 71
	65 70	65 69
Arriba	41 39	42 46
	35 37	40 45

- Hacer una prueba de análisis de varianza para probar las hipótesis de que los *promedios de ventas* son los mismos para cada *posición*. Comentar sus resultados
- Hacer comparaciones de medias para identificar las *posiciones* en los anaqueles que producen en promedio iguales *ventas* de los panes.
- Analizar la posible interacción entre el *ancho del anaquel* en las *ventas promedio* según la posición. ¿A qué conclusión se llegará?

Problema 12

Se desea estudiar el efecto de 5 tipos diferentes de *música de fondo*: A, B, C, D y E sobre la *productividad* de los cajeros de un banco. A representa un tipo de música lenta, instrumental y vocal; B,

media, instrumental y vocal; *C*, rápida, instrumental y vocal; *D*, media instrumental únicamente y *E* música rápida e instrumental. Para lograr este objetivo, durante 5 semanas, un mismo *tipo de música* de fondo suena durante un día y la *productividad* de ese día es observada. El día de la semana y el número de la semana en que se realiza el experimento son consideradas bloques. Después de realizar una asignación aleatoria por semana y por día de los distintos *tipos de música*, de tal forma que no hubiese repetición por semana y por día, se obtuvieron los siguientes resultados. El valor observado, la *productividad*, es una medida de la eficiencia de todo el equipo de cajeros.

Semana	Lunes	Martes	Miércoles	Jueves	Viernes
1	D 18	C 17	A 14	B 21	E 17
2	C 13	B 34	E 21	A 16	D 15
3	A 7	D 29	B 32	E 27	C 13
4	E 17	A 13	C 24	D 31	B 25
5	B 21	E 26	D 26	C 31	A 7

- ¿Qué se puede concluir al respecto?

Problema 13

Después de una discusión sobre la evaluación, 4 profesores del departamento de matemáticas de cierta universidad, que llamaremos el As, el Superego, el Magnífico y el Ene2 deciden realizar una investigación para determinar cuál de ellos es *mejor profesor*. Diseñan un experimento completamente aleatorio, en el cual cada uno de ellos es un *tratamiento*, eligen aleatoriamente los estudiantes, dictan un capítulo de lineal y se someten a la evaluación de los estudiantes. Y ¡oh! sorpresa, del análisis de varianza del diseño se concluye que: no hay diferencia significativa entre los profesores. El Magnífico dice: “¡obvio! con el horario que me asignaron!”, definitivamente en el diseño hay que considerar el *horario* como un bloque. Se decide entonces replantear el experimento con 4 *horarios* posibles, cada uno de ellos dicta la consabida sección de lineal en cada uno de los *horarios* y el análisis de varianza nuevamente dice que: no hay diferencia significativa entre los *profesores*. El Superego piensa “claro mi fuerte es el cálculo” y comenta: “en realidad el bloque debe ser la *asignatura*”.

Después de un análisis concienzudo eligen como bloque 4 *asignaturas*: lineal, geometría, estadística y cálculo. Se repite la investigación y el resultado del análisis de varianza es: no hay diferencia significativa entre los profesores. El As, al ver los resultados de la última investigación sabiamente sugiere: “deben considerarse 2 tipos de bloque: *horario* y *asignatura*”; se implementa entonces un diseño en cuadrado latino. Cada *profesor* imparte una sección de cada una de las *asignaturas*, en cada uno de los posibles *horarios*. Al terminar de dictar la sección los estudiantes califican la *aptitud* docente. La nota promedio obtenida en la última investigación, por *profesor*, *asignatura* y *horario* aparece en la tabla siguiente.

Notación profesores: el As (As), el Magnífico (Mg), el Superego (Se) y el Ene2 (Eln).

Horario	Asignatura			
	Lineal	Geometría	Estadística	Cálculo
1	As 84	Mg 79	Se 81	Eln 94
2	Mg 75	Se 68	Eln 80	As 93
3	Se 59	Eln 70	As 77	Mg 80
4	Eln 75	As 91	Mg 91	Se 75

- ¿Podría en este caso concluir que existe diferencia en la *capacidad docente* de los profesores?
- ¿Cuáles serían sus conclusiones?

1.801
1.822
1.83
1.846
1.876
1.897
1.91
1.923
1.944
1.956
1.967
1.99
2.023
2.34
2.356
2.551
2.67
2.702
2.799
2.811
2.834
2.856
2.877
2.89
2.910
2.922
2.932
2.935
2.95
2.959
2.968

Capítulo

7

Análisis conjunto

Objetivo general:

Conocer una de las técnicas avanzadas para analizar la asociación—pronóstico, juicio o predicción—criterio y saber cómo se aplica a la solución de problemas del área administrativa.

Objetivos específicos:

Al terminar este capítulo, el lector será capaz de:

- Definir qué es un atributo, nivel de atributo, combinación de niveles de atributos y producto.
- Clasificar los atributos según su propia naturaleza.
- Definir el concepto de estímulo.
- Diferenciar los modelos de preferencia de componentes separados, lineales y cuadráticos (o de punto ideal).
- Explicar en qué consiste la utilidad.
- Definir la importancia de cada factor.
- Clasificar los métodos del análisis conjunto.
- Diferenciar los métodos del análisis conjunto tradicional, adaptativo y adaptativo basado en la elección y saber seleccionar el adecuado en función del número de atributos, el nivel de análisis deseado y la forma del modelo de preferencia de cada atributo.
- Determinar los atributos que deberían formar parte del análisis conjunto.
- Definir el número y tipo de niveles de cada atributo.
- Seleccionar la forma de presentación de las tarjetas a los encuestados.
- Estimar el modelo conjunto.
- Utilizar el SPSS™ para aplicar el análisis conjunto con un ejemplo de introducción a nuevos productos.
- Interpretar los resultados del análisis conjunto y obtener las conclusiones y recomendaciones respecto al nuevo producto que se desea introducir al mercado.

7.1 Antecedentes

La técnica de análisis conjunto¹ la utilizaron por primera vez Luce y Tukey en 1964 y fue introducida a la mercadotecnia por Green y Rao en 1971. La definición que estos 2 últimos autores le dan al análisis conjunto es la siguiente:

Conjunto de técnicas y modelos que buscan transformar las respuestas subjetivas de los consumidores en parámetros que sirvan para estimar la utilidad de cada nivel de los atributos en una respuesta a la preferencia manifestada por los consumidores.²

7.2 Áreas de aplicación

Esta técnica se utiliza principalmente en el desarrollo de novedades en: productos, tipos de tarjetas de crédito, formas de cobranza, medicamentos o tratamientos, rutas de caminos o vuelos a seguir, estrategias de precios, ampliación de líneas, segmentación de mercados y análisis de competencias, entre otros. Actualmente la técnica se ha diversificado tanto que ya se aplica en un sinnúmero de áreas y no sólo en mercadotecnia.

7.3 Definición

Análisis conjunto. Técnica multivariante que se utiliza para conocer las preferencias hacia productos o servicios por parte de los consumidores.

Utilidad. Valor asignado a cada uno de los niveles de los atributos escogidos para el producto.

El **análisis conjunto** es una técnica multivariante que se utiliza para conocer las preferencias hacia productos o servicios por parte de los consumidores para que éstos evalúen su valor o utilidad. En esta técnica la **utilidad** es el valor asignado a cada uno de los niveles de los atributos escogidos para el producto, el valor de cada nivel se suma a los otros niveles escogidos, lo cual da un resultado numérico para cada combinación, donde el valor más alto supone mayor preferencia por el consumidor. Es una técnica estadística utilizada para analizar la relación lineal o no lineal entre una variable dependiente generalmente ordinal (aunque también puede ser métrica) y varias variables independientes no métricas o métricas. La expresión funcional del análisis conjunto puede escribirse como sigue:

Ecuación 7-1 En función de quién se encuentran las variables

$$Y = f(X_1, X_2, X_3, \dots, X_i, \dots, X_K)$$

donde:

- Y : es la variable dependiente
- X_i : es la variable independiente
- i : es el número de variable
- K : es el número máximo de variables

La variable dependiente muestra la preferencia que el entrevistado le otorga al producto y las variables independientes son los atributos distintivos del producto, previamente escogidos por el investigador. Cabe aclarar que sólo la variable dependiente representa la información de gustos o preferencias del encuestado.

El análisis conjunto es el único de entre todos los métodos multivariantes en el que el investigador construye primero un conjunto de productos o servicios reales o hipotéticos por combinación de los niveles seleccionados de cada atributo. Un grave error sería evaluar cada atributo de manera individual y después sumar los más escogidos, lo cual no es válido pues cuando el consumidor se encuentra frente al anaquel compara los productos en su conjunto, no revisa atributo por atributo. Por eso el análisis conjunto busca mostrar toda la combinación de atributos al mismo tiempo.

¹ También se le conoce como análisis *conjoint*; el término del cual proviene es *conjoint analysis*.

² Green, Paul E. y Vithala R. Rao, "Conjoint Measurement for Quantifying Judgmental Data", *Journal of Marketing Research*, 8 de agosto de 1971, pp. 355-363.

El análisis conjunto separa las preferencias que el individuo expresa del producto para conocer qué valor le asigna a cada atributo, por lo que puede llamarse *técnica descomposicional*, a diferencia del análisis discriminante y la regresión donde la información del individuo se utiliza para conformar la preferencia hacia el producto (técnicas composicionales).

La manera de aplicar la técnica consiste en presentar a los entrevistados diversos estímulos, los cuales consisten en combinaciones de niveles de cada atributo. Los atributos pueden ser: precio, color, empaque, etc., y cada uno con diferentes niveles como por ejemplo color, el cual pudiera tener 3 niveles: rojo, blanco y azul. La combinación de todos los atributos con todos los niveles dan las diferentes alternativas de productos que se pueden encontrar en el mercado; a dichas combinaciones se les llamarán **estimaciones o estímulos**.

El investigador puede seleccionar los atributos y niveles ya sea por conocimiento anterior personal, por revisión de fuentes secundarias o por la realización de estudios previos para conocer los gustos y preferencias del mercado y de esa manera elegir. Una vez que se definen los atributos con sus niveles, se les pide a los entrevistados que evalúen estos estímulos en términos de su aceptación, otorgándoles un valor o utilidad.

Los encuestados sólo deben decir el nivel de importancia de un producto para ellos o bien, el grado de representatividad de un artículo por ciertos atributos. El análisis conjunto presenta información de cada individuo y una suma global de las preferencias de todos los entrevistados, lo que da una información global de los encuestados.

Estimaciones o estímulos. Combinación de todos los atributos con todos los niveles.

7.4 Usos y diferenciación

Con la información global el investigador puede hacer lo siguiente:

- Definir el producto ideal con la combinación de características óptimas.
- Mostrar las utilidades de cada atributo y de cada nivel en la evaluación global del producto.
- Generar segmentos de mercado con base en los gustos y preferencias referidos en el análisis.
- Identificar oportunidades de mercado.

El análisis conjunto se puede diferenciar de otras técnicas por su naturaleza de descomposición previamente explicada ya que los resultados del análisis se pueden revisar de manera individual o global, según se necesite en el estudio.

7.5 Etapas del análisis conjunto

El análisis conjunto consta de varias etapas que se enlistan a continuación:

1. Formulación del problema.
2. Selección de los atributos.
3. Decisión de la forma de recolección de los datos.
4. Selección del tipo de análisis conjunto.
5. Interpretación de los resultados.

Dichas etapas se muestran en la figura 7-1.

7.5.1 Formulación del problema

Para la elaboración de un análisis conjunto se tiene que establecer de manera muy clara cuáles son los objetivos que se persiguen, puede ser el desarrollo de un nuevo producto o una extensión de una línea existente y con base en eso decidir si se realiza el estudio.

7.5.2 Selección de atributos

Esta etapa es una de las más delicadas pues se tiene que definir cuáles atributos y niveles se estudiarán; es importante recordar que el análisis conjunto por sí sólo nunca dirá qué atributo relevante no




Figura 7-1 Pasos en el análisis conjunto.

estuvo presente en el estudio. El analista debe decidir qué atributos incluir, cuántos niveles se eligen para cada uno de ellos, cómo medir la preferencia, cómo recolectar los datos y qué procedimiento se utilizará en la estimación. Para seleccionar los atributos el investigador puede recurrir a:

- Investigaciones cualitativas.
- Contacto con otras personas con experiencia en investigaciones de mercado.
- Pláticas con expertos en la industria del estudio a realizar.
- Análisis de información secundaria.
- Estudios piloto, etcétera.

Según Tunbusch (1987) existen 3 tipos de atributos:

1. Físicos. Se relacionan con el producto mismo, entre los que se podrían nombrar color, tamaño, etcétera.
2. Beneficios del producto. Se refieren a los beneficios que se obtienen, como ejemplo: limpia, perfuma, suaviza, etcétera.
3. Posicionamiento psicológico. Se vinculan con la forma de sentir del entrevistado respecto al producto, entre los cuales podrían estar: seguridad, estatus, etcétera.

En seguida se presentan algunas recomendaciones al elegir los atributos:

- Deben ser distintos y claramente distinguirse uno de otro.
- No deben ser vagos, como la calidad.

- Debe ser fácil de comunicar; esto depende del tipo de tecnología utilizada, pues si se mide una fragancia en forma personal y la entrevista se hace en lápiz y papel, difícilmente el entrevistado podrá imaginarse el olor si no se lleva un prototipo.
- Deben ser importantes para el estudio que se realiza.
- Es preferible no excederse de 8 atributos, pues las combinaciones resultantes darían una gran cantidad de alternativas que dificultarían el proceso de selección por parte del encuestado.

Una vez que se identifican los atributos importantes, se deben seleccionar sus niveles. El número de niveles determina la cantidad de estímulos o estimaciones que evaluarán los entrevistados. Se recomienda que los niveles estén equilibrados o igualados para todos los factores, pues a veces el entrevistado se centra más en factores con más niveles y pierde objetividad el estudio. A continuación se presentan algunos consejos para la elección de los niveles:

- Que no sean ambiguos.
- Que sean relevantes.
- Que sean factibles y fáciles de comunicar.

7.5.3 Decisión de la forma de recolección de los datos

A continuación se muestran las decisiones que se deben tomar en este tipo de análisis y la forma de recolectar la información.

7.5.3.1 La muestra

La muestra se obtiene del mismo modo que para todos los estudios cuantitativos, con los mismos requisitos en cuanto a escoger 10% más en caso de que ocurran errores y lo más importante es que sea representativa de la población que se desea estudiar.

En el pasado, por lo difícil que era realizar el estudio, el investigador tenía que recoger los datos por medio de entrevistas personales para explicar al entrevistado algún punto de la encuesta que no entendiera; sin embargo, ahora es muy común realizar este tipo de análisis por computadora a través de paquetes o software especializados en el área; de una manera sencilla se alimenta el paquete con los atributos y niveles escogidos y éste realiza las combinaciones necesarias, además de las preguntas para el entrevistado y graba las respuestas.

7.5.3.2 Construcción de las tarjetas o estímulos

Una vez que se seleccionan los factores y se elige el método de presentación, empieza la tarea de creación de los tratamientos o estímulos para que los encuestados los evalúen. Éstos se presentan a los entrevistados a través de la combinación de los atributos y sus niveles, la cual puede ser por medio de tarjetas verbales o tarjetas visuales.

Por ejemplo, se desea conocer el noticiero ideal y los atributos o factores a medir podrían ser: *horario* y *género* del conductor. Para el atributo *horario* se tienen 3 estímulos: *mañana*, *mediodía* o *noche* y para el *género* sería *femenino* o *masculino*, la forma en que las tarjetas verbales quedarían expresadas sería como sigue:



Figura 7-2 Tarjetas.

Éste es un ejemplo de formación de tarjetas con pocos niveles; cuando se tiene gran cantidad de factores o niveles, lo ideal es que se recurra a la construcción de tarjetas mediante el uso del paquete SPSS™. Se puede encontrar un ejemplo en el apéndice al final del capítulo.

Dentro de las tarjetas verbales el orden de los atributos puede producir algo de sesgo por lo que se recomienda rotar las tarjetas, pues muchas veces el primer atributo y el último tienden a atraer más la

atención del encuestado y por último se debe recordar que si algún atributo tiene un mayor número de niveles que los otros, los encuestados lo pueden considerar como de mayor importancia y esto es falso.

Para la elaboración de las tarjetas visuales se pueden incluir dibujos, fotos o prototipos, esto si la descripción verbal pudiera confundir al entrevistado, por ejemplo, si se habla de un carro grande valdría la pena mostrar el dibujo para que el encuestado no se confunda, pues el nivel grande puede presentar diferentes connotaciones dependiendo del individuo.

La elección de las tarjetas, ya sea verbal o visual, depende del tipo de estudio que se realice, es decir, a partir de los atributos escogidos se decide cuál de los tipos de tarjetas es el más adecuado.

7.5.3.3 Recolección de los datos

La recolección de los datos puede realizarse de 2 formas:

1. Jerarquías (*rankings*). Se le dan al entrevistado las tarjetas o estímulos y éste tiene que ordenarlas de acuerdo con su preferencia de la más preferida a la menos predilecta. Si son muchas las tarjetas, una manera de ayudarlo es pedirle que escoja la que más le gusta y después la que menos le agrada; de las tarjetas que quedan se le pide nuevamente que escoja la más y luego la menos preferida y así hasta el final. De esa manera se le facilita a la persona su selección; si se continúa con el ejemplo del noticiero y el entrevistado escoge la *noche y mujer* como la opción más preferida, y en la menos preferida selecciona la *noche y hombre*, las tarjetas se acomodarían como muestra la siguiente figura:



Figura 7-3 Recolección de tarjetas por *rankings*.

La forma en que se pregunta da como resultado variables métricas. Las ventajas de este método es que el entrevistado se concentra y pone mayor atención a las tarjetas y es muy útil cuando el número de estímulos no es mayor a 24.

2. Puntuaciones (*ratings*). En este tipo de recolección se pide al entrevistado que califique cada tarjeta en función de una escala previamente establecida. Se pueden repartir 100 puntos o 10 puntos entre todas, donde las más preferidas llevarán una mayor cantidad de puntos por parte del encuestado. Las ventajas de este método es que es fácil de responder y puede asignarle un valor de 0 a la tarjeta que no desea, a esto se le conoce como *no compra*. A continuación se presentan las puntuaciones que un entrevistado asignó al ejemplo del noticiero:



Figura 7-4 Recolección de tarjetas por *ratings*.

La forma en que se preguntó da como resultado variables ordinales. La desventaja es que las tarjetas pueden tener la misma puntuación ya que se les puede otorgar la misma calificación a 2 o más estímulos, como lo muestra el ejemplo.

Green y Srinivasan (1978) indican que ambos métodos producen casi los mismos resultados.³

7.5.4 Selección del tipo de análisis conjunto

Una vez especificados los atributos y niveles, el analista decide cuál será el tipo de presentación de los estímulos, el tipo de variable respuesta y el método para recolectar datos. El objetivo es presentar

³ Green, P. y Srinivasan, V., "Conjoint analysis in consumer research: Issues and outlook", *Journal of Consumer Research*, vol. 5, septiembre de 1978, pp. 103-123.

al encuestado las combinaciones de atributos (estímulos) de la forma más realista y eficiente posible. Después de que se realiza todo esto, se elige el tipo de análisis conjunto: autoexplicativo (*self-explicated*), apareado (*trade off*) y el de perfil completo (*full-profile*).

- Método *self-explicated* o autoexplicado. Es un método aditivo con el cual se les pide a los entrevistados que califiquen de 0 a 100 cada nivel y cada atributo en una escala de preferencia. Después se les solicita que evalúen lo mismo, pero ahora con una escala de importancia. Así se multiplica el valor de la preferencia por el nivel de importancia. La desventaja del modelo es que se tiene que evaluar de manera individual cada nivel y cada atributo; la combinación final puede estar compuesta por atributos y niveles que no tengan relación, lo cual puede resultar en un mal modelo.
- Método *trade off* o *apareado*. En este método se le pide a las personas que califiquen con una escala de importancia cada atributo; los atributos que la persona escoja se seleccionan y se le vuelven a presentar en parejas para ver cuál elegiría. Para este método se necesita el apoyo de una computadora para recopilar los atributos seleccionados, hacer las parejas y presentarlas al encuestado para que elija las más importantes. Esto es, se le muestran 2 alternativas al mismo tiempo y la persona escoge 1 de ellas, después se le muestran otras 2 opciones y vuelve a elegir 1 de ellas y así sucesivamente. La desventaja del método es que la realidad difiere un poco de este proceso, pues una persona frente al anaquel no escoge entre 2 productos y desecha 1 y luego elige otros 2 y descarta otro para después seleccionar el definitivo de entre los 2 ganadores.
- Método *full-profile*. Éste es el método más utilizado pues es el más parecido a la realidad; para aplicar este método se supone que todos los atributos son ortogonales,⁴ es decir, independientes unos de otros. La ventaja es que los entrevistados evalúan todos los atributos y todos los niveles, como sucedería en una selección de cualquier producto en una compra real. La desventaja es que la cantidad de atributos se tiene que limitar, pues es un poco complicado para el entrevistado evaluarlos al mismo tiempo.

Aparte de las alternativas para la presentación y evaluación de los estímulos, existen 3 metodologías para realizar un análisis conjunto: el análisis conjunto tradicional, el método adaptativo conjunto y el método basado en la elección.

1. El análisis conjunto tradicional. Es el más común de todos y el único hasta hace algunos años; como maneja sólo 8 atributos se ha visto superado. Se desarrollaron 2 metodologías adicionales con la finalidad de mejorar el diseño de la investigación y sus resultados.
2. El método adaptativo. Se ideó para poder utilizar más atributos, incluso más de 30. Este método fue introducido al mercado en 1980 por Rich Johnson, el fundador de Sawtooth Software, con la idea de mejorar el método tradicional en la cantidad de atributos a evaluar.
3. El método basado en la elección. No muestra las estimaciones o combinaciones por niveles de atributos, sino todos en conjunto, esto es, presentan tarjetas con combinaciones de niveles sin que se evalúen todos. Por ejemplo: ¿Cuál de las siguientes computadoras compraría?

Memoria 1 Gb, procesador
Corel y disco duro 120 Gb

Memoria 800 Mb, procesador
Intel y disco duro 80 Gb

Memoria 2 Gb, procesador
Corel y disco duro 160 Gb

Figura 7-5 Combinación de atributos.

Como se puede observar se evalúan algunos atributos, pero no todos los niveles al mismo tiempo, lo cual es muy real pues es la forma natural de elección del consumidor. Sin embargo, la desventaja que tiene es que sólo se selecciona una opción y no se evalúa la importancia de cada atributo, ni cuál nivel es el mejor.

A la fecha el método más utilizado sigue siendo el análisis conjunto tradicional.

⁴ Para una mayor explicación de atributos ortogonales, revise el capítulo 3 "Análisis de factores".

7.5.5 Interpretación de resultados

El enfoque que se acostumbra utilizar para interpretar el análisis conjunto es el desagregado; es decir, se elabora un modelo independiente para cada sujeto y se examina el ajuste del modelo para cada uno; después se valora el comportamiento de cada encuestado. Esto tiene la ventaja de que se pueden eliminar entrevistas que muestren un resultado muy poco confiable. Una vez que el análisis presenta las estimaciones individuales, al final realiza un resumen con los datos de todos los encuestados para que el investigador pueda conocer de manera global sus preferencias y tomar decisiones de dicho análisis.

La interpretación de los resultados puede hacerse también a nivel agregado, esto es, se puede analizar primero el modelo a nivel individual y después se le agrega la interpretación de otro encuestado y así sucesivamente. También se puede estimar un conjunto de encuestados, aunque este proceso generalmente produce resultados pobres, si se intenta valorar el comportamiento de un sujeto y también si se desea interpretar los valores de cada atributo para cualquier individuo.

7.5.5.1 Análisis estadísticos

Para explicar los análisis estadísticos se usará un ejemplo hipotético donde lo que se busca es el televisor ideal. Los atributos escogidos son *tamaño* y *color* y los niveles de cada atributo son 21, 26 y 32 *pulgadas* para el primero, así como los colores *gris* y *negro*; si se desean evaluar todos los niveles de los estímulos, el número de tarjetas a medir serían 6 ya que las combinaciones quedarían de la siguiente manera:




Figura 7-6 Combinación de atributos.

Una vez que se definen los niveles, al entrevistado se le da la serie de tarjetas con las 6 combinaciones posibles de los niveles mencionados y se le pide que las acomode de la más preferida a la menos preferida, es decir, que utilice el método *ranking*. Este procedimiento se realiza con 150 personas, se codifica la información, se procesa en el paquete estadístico y la salida del programa se estudia a continuación.

7.5.5.2 Resultados de la salida del SPSS™

Al procesar la información mencionada en el SPSS™, el resultado es el siguiente:

Tabla 7-1 Tabla de las utilidades

Estadísticos globales			
Utilidades			
		Estimación de la utilidad	Error típico
Tamaño	1.00	.448	.114
	2.00	.078	.114
	3.00	-.526	.114
Color	1.00	.156	.081

(continúa)

Tabla 7-1 Tabla de las utilidades (*continuación*)

Estadísticos globales			
Utilidades			
		Estimación de la utilidad	Error típico
	2.00	-.156	.081
(Constante)		3.502	.081

Tabla 7-2 Tabla de los valores de importancia

Valores de importancia	
Tamaño	73.032
Color	26.968
Puntuación promediada de la importancia	

Tabla 7-3 Tabla de las correlaciones

Correlaciones ^a		
	Valor	Sig.
R de Pearson	.967	.001
Kendall's tau	.867	.007

^a Correlaciones entre las preferencias observadas y las estimadas.

7.5.5.3 Prueba hipótesis del análisis global

Las medidas de correlación pueden ser Pearson o Kendall's tau. Cuando se usen variables métricas lo más recomendado es observar el **coeficiente de correlación de Pearson**,⁵ el cual es un índice estadístico que mide la relación lineal entre 2 variables cuantitativas; por el contrario, si las variables son ordinales, lo más conveniente es que se utilice el de Kendall's tau.⁶

Como se mencionó, el valor del coeficiente de correlación de Pearson oscila entre +1 y -1. Recuerde que, si el valor de la correlación es igual a cero, no existe ninguna asociación o relación y dicho valor indica una independencia total entre las 2 variables, es decir, que la variación de 1 de ellas no influye en absoluto en la variabilidad que pueda presentar la otra. Si el valor del coeficiente de correlación es igual a 1 existe una asociación o relación positiva perfecta. El valor indica una dependencia total entre las 2 variables denominada **relación directa**, es decir, cuando una de ellas aumenta, la otra también lo hace en idéntica proporción. Si el valor del coeficiente de correlación es igual a -1 existe una asociación o relación negativa perfecta. El valor indica una dependencia total entre las 2 variables llamada **relación o asociación inversa** con la que, cuando una de ellas aumenta, la otra disminuye en idéntica proporción.

En el análisis conjunto se desea que las variables tengan una relación alta entre ellas, por lo que lo más recomendable es que la *r* de Pearson esté cercana a 1, ya sea positiva o negativa.

El **coeficiente de Kendall's tau** se utiliza cuando se mide la relación entre variables ordinales. Toma valores entre -1 y +1 y se interpreta igual que el coeficiente de correlación de Pearson.

Para saber si los atributos son los preferidos, es necesario realizar una prueba de hipótesis con las correlaciones, por lo que se explicará en seguida:

$H_0: p = 0$: ninguno de los atributos tiene asociación (correlación), por lo que los datos no se ajustan al modelo, es decir, los atributos no deben formar parte del nuevo producto.

⁵ Para obtener mayor información acerca del coeficiente de correlación de Pearson, revise el capítulo 2 "Análisis de regresión múltiple".

⁶ El coeficiente de correlación de Kendall's tau se utiliza para variables ordinales o de rango y, al igual que el de Pearson, proporciona una medida de asociación; sus valores también oscilan entre -1 y 1; el signo, como el de Pearson, indica la dirección de la relación y el valor indica la magnitud de dicha asociación; entre más grande es el valor, mejor es la relación.

Coeficiente de correlación de Pearson. Índice estadístico que mide la relación lineal entre 2 variables cuantitativas.

Relación directa. Dependencia total entre 2 variables: cuando una de ellas aumenta, la otra también lo hace en idéntica proporción.

Relación o asociación inversa. Dependencia total entre 2 variables: cuando una de ellas aumenta, la otra disminuye en idéntica proporción.

Coeficiente de Kendall's tau. Se utiliza cuando se mide la relación entre variables ordinales. Toma valores entre -1 y +1.

$H_a: p \neq 0$: los atributos tienen asociación (correlación), por lo que los datos se ajustan bien al modelo y los atributos sí deben formar parte del nuevo producto.

donde:

p : es el valor de la correlación poblacional

De acuerdo con el ejemplo de la televisión, los resultados de la correlación se presentan en la siguiente tabla:

Tabla 7-4 Muestra las correlaciones para ver el ajuste al modelo

Correlaciones ^a		
	Valor	Sig.
R de Pearson	.967	.001
Kendall's tau	.867	.007

^a Correlaciones entre las preferencias observadas y las estimadas.

Entonces se realiza la prueba de hipótesis:

Recuerde que:

Si $p\text{-valor} < 0.05$ se rechaza H_0

Al comparar el p -valor, como los estímulos se preguntaron en una escala de intervalo; estas variables se consideran métricas, por lo que al realizar la prueba de hipótesis se tiene que:

$0.001 < 0.05$ por lo tanto se rechaza H_0

Al comparar el p -valor, si las variables se preguntaran en forma ordinal, la prueba de hipótesis se haría de la siguiente manera; recuerde que éste no es el caso del ejemplo.

$0.007 < 0.05$ por lo tanto se rechaza H_0

Como se rechazó H_0 entonces se concluye que existe una fuerte relación o asociación, por lo que los atributos deben formar parte de la nueva televisión.

Al seguir con el análisis conjunto, el cuadro de importancia indica de manera porcentual el peso o importancia⁷ que tiene cada atributo, donde obviamente el más trascendente es el más preferido entre los entrevistados; en este caso la información de la siguiente tabla muestra la importancia relativa de los 2 atributos:

Tabla 7-5 Muestra los valores de importancia

Valores de importancia	
Tamaño	73.032
Color	26.968
Puntuación promediada de la importancia	

Al comparar los valores se observa que el atributo que diferenciaría más este tipo de televisión sería el *tamaño*, el cual tiene una importancia de 73.032, es decir 46.064% ($73.032 - 26.968$) por arriba del atributo *color*.


Sin embargo, si las importancias fueran semejantes se tendría que realizar una prueba de hipótesis para ver qué atributo es el que prefieren más los encuestados, por lo que se realizará este tipo de análisis y finalmente el cuadro de utilidades:

⁷ La importancia se encuentra al promediar la importancia de cada uno de los 150 individuos entrevistados.

Tabla 7-6 Tabla de las utilidades

Utilidades			
		Estimación de la utilidad	Error típico
Tamaño	1.00	.448	.114
	2.00	.078	.114
	3.00	-.526	.114
Color	1.00	.156	.081
	2.00	-.156	.081
(Constante)		3.502	.081

Lo que se puede observar son los atributos con sus respectivos niveles, donde el 1 en el atributo *tamaño* representa el nivel de *21 pulgadas*; el 2, *26 pulgadas*, y el 3, *32 pulgadas*. En el atributo *color* el 1 representa el *gris* y el 2, el *negro*. Por otra parte, las utilidades representan las preferencias de los entrevistados y al sumar las combinaciones, la estimación que resulta con mayor valor será la combinación más preferida, es decir:

**Figura 7-7** Suma de las utilidades de las combinaciones.

En este estudio la combinación con la mayor utilidad es la del tamaño 1 color 1, que significa que los entrevistados prefieren tener 6.04 veces más una televisión de *21 pulgadas* y de *color gris* que todas las restantes combinaciones.

Un signo negativo en la utilidad de los niveles del atributo no significa que es inservible, sino que el *color negro* tiene una importancia de -0.156 , es decir, fue 1.56 veces menos preferido que el *gris*; por lo que para el análisis global se tiene que el tamaño 3 con el color 2 se preferiría 6.82 veces menos que todas las restantes combinaciones.

7.6 Segmentación

Con lo anterior termina el análisis conjunto, pero con las preferencias generadas es posible realizar estudios de segmentación de mercados, a través de la técnica de análisis de conglomerados,⁸ esto podría llevarse a cabo al agrupar sujetos con utilidades similares o con valores de la importancia parecidos para identificar grupos homogéneos y las características o atributos que favorecerían o preferirían dichos segmentos.

7.7 Ejercicios

Responda las siguientes preguntas:

1. ¿La técnica de análisis conjunto fue utilizada por primera vez por Green y Rao en 1964?
2. ¿La técnica de análisis conjunto fue introducida a la mercadotecnia por Luce y Tukey en 1971?
3. ¿El análisis conjunto se utiliza en aplicaciones del área de mercadotecnia?
4. ¿El análisis conjunto se utiliza en el resumen de datos?
5. ¿El análisis conjunto es una técnica estadística utilizada para analizar la relación lineal o no lineal entre una variable independiente generalmente ordinal (aunque también puede ser métrica) y varias variables dependientes no métricas o métricas?
6. ¿El análisis conjunto es 1 de varios métodos en el que el investigador construye primero un conjunto de productos o servicios reales o hipotéticos por combinación de los niveles seleccionados de cada atributo?
7. ¿Un procedimiento del análisis conjunto es evaluar cada atributo de manera individual y después hacer la suma de los demás escogidos?
8. ¿El análisis conjunto presenta información de cada individuo y una suma global de las preferencias de todos los entrevistados, con esto da una información global de los encuestados?
9. ¿Con la información del análisis conjunto el investigador puede saber el conjunto de datos en resumen?
10. ¿Con la información del análisis conjunto el investigador puede saber el producto ideal con la combinación de características óptimas?
11. ¿Es preferible no excederse de 8 atributos, pues las combinaciones resultantes darían una gran cantidad de alternativas que dificultarían el proceso de selección por parte del encuestado?
12. ¿Un consejo para la elección de los niveles de atributos es que sean de poca relevancia?
13. ¿Muchas veces el primer atributo y el último no tienden a atraer más la atención del encuestado?
14. ¿La elección de las tarjetas, ya sea verbal o visual, depende del tipo de estudio que se realice, es decir, de los atributos escogidos y de ahí se decide cuál de los tipos de tarjetas es el más adecuado?
15. Método autoexplicado: ¿es un método aditivo donde se les pide a los entrevistados que califiquen de 0 a 100 cada nivel y cada atributo en una escala de preferencia?
16. Método *trade off*: ¿es un método aditivo donde se les pide a los entrevistados que califiquen de 0 a 100 cada nivel y cada atributo en una escala de preferencia?
17. ¿En el análisis conjunto se desea que las variables tengan una relación baja entre ellas, por lo que lo más recomendable es que la r de Pearson esté cercana a 1, ya sea positivo o negativo?
18. ¿El coeficiente de correlación tau se utiliza cuando se mide la relación entre variables ordinales?

⁸ El análisis de conglomerados o agrupamientos se cubrió en el capítulo 4 que lleva el mismo nombre.



Glosario

Agglomerativo. Significa que tiene muchos grupos, éstos se unen hasta formar un todo.

Agrupar. Selección de los elementos más parecidos entre sí.

Análisis conjunto. Técnica multivariante que se utiliza para conocer las preferencias hacia productos o servicios por parte de los consumidores.

Análisis de bloques al azar. Sirve para aislar el efecto después de realizado el experimento, pero su variable incontrolable es de naturaleza no métrica e influye en la variable dependiente.

Análisis de clases latentes o de segmentos latentes. Método para encontrar la variable no observada o latente, compuesta por subgrupos o segmentos, por lo que sus conglomerados son K distintas categorías de una variable latente nominal.

Análisis de conglomerados. Técnica del grupo estructural que tiene por objeto resumir información y que sirve para clasificar en grupos o categorías. // Técnica empleada en la segmentación de mercados, que se basa en formar grupos que contengan elementos lo más similares entre sí y diferentes al compararse entre grupos.

Análisis de conjunto. Técnica que estudia el efecto que tienen diversas variables independientes no métricas o métricas sobre una variable dependiente no métrica (ordinal).

Análisis de correlación. Cuantifica el grado de relación lineal que hay entre variables.

Análisis de correlación canónica. Consiste en determinar el grado de relación entre dos conjuntos de múltiples variables.

Análisis de correspondencia. Establece relaciones entre variables independientes cualitativas, enriqueciendo así la información de las tablas de contingencia.

Análisis de covarianza. Técnica que pretende aislar o controlar los efectos de una variable que durante el desarrollo del experimento no pudo controlarse y afecta las mediciones de la variable dependiente. // Busca cómo afecta la variable incontrolable (de naturaleza métrica) a la variable dependiente para aislar y controlar su efecto.

Análisis de factores o análisis factorial. Método mediante el cual se encuentran variables no observadas o latentes, las cuales son métricas. // Técnica estructural o de interdependencia en la que todas las variables tienen la misma importancia. // Método mediante el cual se encuentran variables no observadas o latentes. Reduce un sistema múltiple de variables métricas a un menor número llamado *componentes* o *factores*.

Análisis de perfiles latentes. Método que sirve para encontrar variables no observadas o latentes no métricas. Reduce un sistema múltiple de variables métricas a un menor número de perfiles latentes.

Análisis de rasgos latentes. Método por el cual se analizan datos categóricos de forma binaria para encontrar variables métricas no observadas o latentes.

Análisis de regresión. Busca saber la cantidad de variación que la covariable pudo incluir en la variable dependiente. // Es una técnica multivariante, cuyo objetivo es desarrollar un modelo matemático lineal. // Permite conocer la relación causa-efecto que hay entre varias variables independientes y una dependiente.

Análisis de supervivencia. Estudia el efecto de una variable independiente (tiempo, variable métrica) cuando la variable dependiente se expresa en tiempo que tarda en ocurrir un suceso.

Análisis de varianza. Técnica funcional que utiliza una o más variables independientes, todas ellas no métricas, y trata de explicar el comportamiento de una o más variables dependientes métricas. Examina el efecto que la variable no métrica tiene en la variable dependiente.

Análisis de varianza de un factor. Analiza una variable dependiente medida bajo cierta condición experimental identificada por una variable independiente.

Análisis de varianza multivariado. Es un análisis de varianza cuyo objetivo es explicar “ n ” variables dependientes a partir de “ m ” independientes. // Técnica que permite pronosticar simultáneamente 2 o más variables dependientes, que representan un concepto o factor.

Análisis de varianza univariado. Es un análisis de varianza cuyo objetivo es explicar una variable dependiente a partir de “ m ” variables independientes.

Análisis discriminante. Es una técnica de clasificación o asignación de un elemento a un grupo del cual se conocen sus atributos. // Técnica funcional que permite explicar las diferencias entre grupos de personas u objetos mediante variables independientes con el objetivo de pronosticar o clasificar nuevas observaciones entre los grupos.

Análisis multivariante. Métodos o técnicas de análisis e interpretación de un conjunto de variables que conservan su grado de interacción.

Bloque. Unidades de prueba incontrolables que representan un grupo experimental y son equivalentes a los niveles de los factores.

Bloques al azar. Técnica que elimina posibles fuentes de variación que no pudieron controlarse durante el experimento.

Carga del factor. Término que indica el grado de relación que llegan a tener cada una de las variables con cada uno de los factores.

Caso balanceado. Manejo del mismo número de datos en cada uno de los niveles del factor.

Centroide. Es el promedio o centro de los grupos.

Clasificación. Es uno de los procesos fundamentales de la ciencia que ordena los fenómenos para poderlos entender.

Coefficiente de correlación de Pearson. Índice estadístico que mide la relación lineal entre 2 variables cuantitativas.

Coefficiente de determinación. Se utiliza para saber cuánto se logró captar o explicar del comportamiento de la variable dependiente.

Coefficiente de Kendall's tau. Se utiliza cuando se mide la relación entre variables ordinales. Toma valores entre -1 y $+1$.

Colinealidad. Surge cuando dos variables independientes se relacionan entre sí, ya sea linealmente o no.

Componentes principales y factor común. Análisis que se usan para encontrar la interdependencia (dependencia interna) entre variables.

Comunalidad. Variación explicada por el conjunto de factores para cada variable.

Correlación canónica. Coeficiente que mide, para cada función discriminante, el grado en que se diferencian las medias por cada una de las funciones.

Covarianza. Es el promedio de la suma de los productos, es decir, es la suma de los productos cruzados dividido entre los grados de libertad.

Criterio completo o distancias máximas. Supone que cuando dos elementos se unen, el parecido de ese grupo a un tercer elemento estará dado por las características del elemento con el cual tenga más diferencias, es decir, se eslabona con la máxima de las distancias o la mínima de las similitudes.

Criterio simple o distancias mínimas. Asume que al fusionarse dos objetos se tomarán como características las de aquel elemento que sea más parecido a aquel con el que se compara.

Cuadrado de Youden. Técnica que permite dos fuentes experimentales de variabilidad y que es menos restrictiva que los cuadrados latinos.

Cuadrado grecolatino. Aumento del número de factores bloque en la extensión del cuadrado latino.

Cuadrados latinos. Modelo que aprovecha la simetría del experimento factorial al seleccionar un conjunto de condiciones experimentales con la condición de que cada nivel de un factor aparezca una vez con cada uno de los niveles de los otros factores. // Técnica que supone, en su modelo general, que solamente existen los efectos principales de los factores.

Dato. Colección de observaciones numéricas o no numéricas con una característica común.

Dendograma. Diagrama en cuyo eje horizontal aparecen los elementos agrupados, de preferencia en el orden en que se unieron.

Detector automático de interacción. Técnica del análisis multivariante que permite conocer la relación entre una variable dependiente en escala métrica (de intervalo o de razón) y varias variables independientes en escala métrica o no (nominales, de intervalo, de razón).

Diagrama de témpanos o de carámbanos. Simplifica los elementos que se agruparon paso a paso.

Dimensión. Variables simultáneas que hay en un conjunto.

Diseño de tres factores. Diseño en el que se tienen tres factores con un número diferente de niveles y las interacciones entre ellos no son nulas.

- Diseño estadístico de experimentos.** Es el proceso de planeación de un experimento que puede analizarse mediante métodos estadísticos con el objetivo de encontrar soluciones apropiadas.
- Diseño factorial o de dos factores.** Modelo de análisis que se utiliza cuando se tienen dos factores con un número diferente de niveles y las interacciones entre ambos no son nulas.
- Diseño factorial 2^2 .** Técnica de análisis de varianza que sólo utiliza dos factores con dos niveles cada uno.
- Diseño factorial 2^k en dos bloques.** Técnica que se emplea cuando el diseño factorial 2^2 necesita más de un bloque para su realización.
- Diseño factorial 3^k .** Variación del diseño 2^2 que consta de k factores con tres niveles cada uno.
- Diseño factorial fraccionario de dos niveles.** Diseño con k factores con dos niveles que mantienen la propiedad de ortogonalidad entre los factores y donde se suponen nulas las interacciones de orden alto.
- Diseño jerárquico o anidado.** Diseño en el que existen dos factores bloque anidados.
- Diseño por bloques incompletos.** Técnica que se emplea cuando algunos experimentos que usan diseños por bloques no pueden realizar los ensayos o mediciones de todas las combinaciones de tratamientos dentro de cada bloque.
- Diseño reticular.** Técnica que se realiza del mismo modo que un diseño de bloques incompleto y que se utiliza cuando hay muchas combinaciones de tratamientos.
- Disimilaridad.** Las proximidades se interpretan en términos de lo diferente.
- Distancia entre dos grupos.** Distancia que existe entre las medianas de las características de los individuos que componen los grupos.
- Efecto de un factor.** Es el cambio en la variable dependiente producido por un cambio en el nivel del factor.
- Efectos principales.** Efectos que los factores pueden tener sobre la variable dependiente.
- Eigenvalor.** Variación o cantidad de información que cada uno de los factores logra captar del conjunto de variables.
- Enfoque promedio.** Consiste en utilizar como puntajes los promedios de las variables que se agruparon con cada factor.
- Error estándar.** Valor de la distancia para un valor particular.
- Error muestral.** Es el error debido a la aleatoriedad en la selección de los elementos muestrales.
- Errores.** Son la diferencia entre el dato real y el dato pronosticado.
- Escala multidimensional.** Técnica que traduce los juicios del consumidor en similaridad o preferencia mediante distancias representadas en una gráfica.
- Eslabonamiento.** Consiste en volver a establecer el grado de parecido de un nuevo grupo con el resto de los elementos.
- Eslabonamiento promedio.** Grado de similitud que tiene un nuevo grupo respecto a otros elementos no agrupados.
- Estadística.** Conjunto de teorías y métodos desarrollados para la recolección, manejo y análisis de datos.
- Estimaciones o estímulos.** Combinación de todos los atributos con todos los niveles.
- Experimentación.** Es un proceso para descubrir algo acerca de un sistema en particular.
- Experimento.** Es una prueba en la cual se inducen cambios en los datos de entrada para observar las causas de los cambios en los datos de salida.
- Experimentos controlados.** El investigador puede manipular el medio en el que se lleva a cabo el experimento, así como a los participantes.
- Experimentos naturales.** El investigador actúa como observador, sin poder seleccionar las unidades de prueba.
- Factor.** Desde el punto de vista matemático, es una combinación lineal (aditiva) de las variables originales de la investigación.
- Factor de inflación de varianzas.** Es un indicador de cuánto las varianzas de los $\beta \cdot s$ crecen y se vuelven imprecisas.
- Factores o tratamientos.** Son las variables independientes del experimento.

Heteroscedasticidad. Es cuando las varianzas no son constantes.

Homoscedasticidad u homogeneidad de varianzas. Es cuando las fuentes de variación de un experimento son constantes o iguales. Indica homogeneidad de varianzas o que las varianzas son constantes.

Lambda de Wilks. Medida que evalúa la capacidad discriminante de la función y expresa la proporción de la varianza total explicada por los puntajes discriminantes.

Linealidad o aditividad. Suma de los efectos de cada una de las variables independientes.

Matriz de clasificación o confusión. Presentan los datos reales contra los pronosticados y se basa en el conteo de lo correcta e incorrectamente clasificado.

Matriz identidad. Es aquella que en su diagonal principal tiene 1 y fuera de ella, ceros; esto indicaría que no existen correlaciones entre las variables.

Matriz no rotada. Resultado de la descomposición espectral que muestra los eigenvectores correspondientes.

Metaanálisis. Conjunto de técnicas que permite revisar y combinar diversos resultados experimentales de distintos estudios previos para contestar una misma pregunta científica o emitir una misma conclusión.

Método Bonferroni. Técnica estadística que ajusta el nivel de significancia con relación al número de pruebas estadísticas realizadas simultáneamente sobre un conjunto de datos.

Método C de Dunnett. Es idéntico al de Games-Howell excepto en la forma de corregir los grados de libertad de la distribución del rango estudentizado.

Método de reasignación. Permite que un individuo asignado a un grupo sea reasignado a otro en un paso posterior del proceso, ya que no estaba en el grupo adecuado; al reasignarse se optimiza el criterio de selección.

Método de reducción de dimensiones. Busca dimensiones latentes en un conjunto según sus características y con base en ellas determina un calificativo que describa al conglomerado.

Método de R-E-G-W F. Se basa en la distribución F; es un método que no resulta apropiado cuando los grupos tienen datos diferentes o en un caso no balanceado.

Método de Ward. Busca a los dos grupos o conglomerados cuya unión conlleve el menor incremento de la varianza.

Método del centroide. Criterio que considera que, cuando dos elementos se unen y forman un grupo, las características que prevalecen respecto a un tercer elemento están dadas por el promedio de las características originales.

Método Dunnett. Método que sirve para comparar cada grupo con un grupo de control pues controla la tasa de error para $k - 1$ comparaciones.

Método Gabriel. Método que se basa en la distribución del módulo máximo estudentizado.

Método Games-Howell. Se basa en la distribución del rango estudentizado y en un estadístico T en el que se corrigen los grados de libertad mediante la ecuación de Welch.

Método GT2 de Hochberg. Método similar a la prueba de Tukey que se basa en la distribución del módulo máximo estudentizado.

Método jerárquico. Algoritmo que se sigue para formar grupos de personas u objetos similares entre sí.

Método jerárquico divisional. Supone que existe un solo grupo que contiene a todos los objetos y basándose en las diferencias los separa hasta terminar con tantos grupos como objetos se tienen.

Método R-E-G-W Q. Método que utiliza el mismo estadístico que la prueba de Newman-Keuls o la de Tukey, pero controla el nivel de significancia de cada comparación.

Método Sidak. Método basado en la distribución t de *student* que controla la tasa de error al evaluar cada comparación con un nivel de significancia $\alpha = 1 - (1 - \alpha)^{1/k}$.

Método T2 de Tamhane. Método conservador basado en la distribución t que utiliza comparaciones por parejas.

Método T3 de Dunnett. Modificación del estadístico T2 de Tamhane que utiliza la distribución del módulo máximo estudentizado.

Método Waller-Dundun. Utiliza la distribución t-*student* y una aproximación bayesiana.

Metodología estadística. Es el único enfoque objetivo que analiza problemas que involucren datos sujetos a errores experimentales.

Mínimas diferencias significativas. Determina el valor mínimo necesario para que dos tratamientos se consideren diferentes y lo utiliza para comparar los pares de medias que se deseen evaluar.

Modelo aditivo. Es el que explica mejor el comportamiento de la variable dependiente.

Multicolinealidad. Es cuando dos o más de dos variables independientes están correlacionadas, es decir, no son independientes entre sí.

Niveles. Valores que poseen las variables.

Niveles de factor. Son los valores que toman las variables independientes.

Path analysis. Permite encontrar valores esperados o reales, a partir de los cuales se pueden determinar caminos críticos a través del análisis de regresión y de un diagrama de flujo de las interdependencias.

Porcentaje de clasificaciones correctas. Indicador que evalúa lo acertado que es el modelo para clasificar como medio para obtener una medida de la confiabilidad al pronosticar. // Medida de la confiabilidad o seguridad que existe al pronosticar y que se obtiene con los datos empleados en la etapa de validación.

Porcentaje de variación explicada. Relación entre la variación explicada por el factor con respecto a la variación total manejada por el conjunto de variables.

Productos cruzados. Son la covarianza de los datos de las variables, sin considerar los grupos.

Promedio entre grupos. Define la distancia entre 2 grupos como el promedio de las distancias entre todas las combinaciones posibles por parejas, al combinar todos los grupos, en los cuales un miembro del par pertenece a cada uno de los grupos formados anteriormente.

Promedios intragrupos. Combinan grupos de manera que la media de las distancias entre todos los casos en el grupo resultante sea lo más pequeña posible.

Proximidad. Grado de similitud o diferencia que existe entre parejas de individuos, objetos y variables.

Prueba de intervalos múltiples de Duncan. Se ordenan las "r" medias muestrales en forma creciente de magnitud, y después se calculan las diferencias entre las medias muestrales adyacentes.

Prueba de Newman-Keuls. Método que ordena las "r" medias muestrales de forma decreciente según su magnitud y su nivel de significancia para cada conjunto de medias separadas "r" pasos es siempre α .

Prueba de Scheffé. Se basa en la distribución F y permite controlar la tasa de error para el conjunto total de comparaciones que se plantean con j medias. // Busca determinar si la diferencia entre 2 promedios es lo suficientemente grande para considerarse diferentes.

Prueba de Tukey. Método que se basa en la construcción de intervalos de confianza de las diferencias por pares.

Pruebas post-hoc. Tipo particular de contraste que se emplea para saber qué media difiere de otra.

Puntajes o puntuaciones. Nueva dimensión o variable que surge a partir del análisis de factores. // Datos con los que se manejaría cada factor como variable.

Raíz característica. Variación explicada por cada factor.

Redes neuronales o redes de neuronas. Dispositivos que representan propiedades de los sistemas neurológicos y se aplican al reconocimiento de esquemas.

Regresión logística. Estudia si una variable binomial (o dicotómica) depende o no de una o unas variables métricas.

Relación o asociación inversa. Dependencia total entre 2 variables: cuando una de ellas aumenta, la otra disminuye en idéntica proporción.

Relación directa. Dependencia total entre 2 variables: cuando una de ellas aumenta, la otra también lo hace en idéntica proporción.

Semilla inicial. Promedios de los grupos con los cuales se inicia un análisis.

Similaridad. Las proximidades se interpretan en términos de lo parecido.

Suma de cuadrados. Representa la varianza de los datos de la variable sin considerar diferencia de grupos.

Técnica de análisis de varianza. En esta técnica se manejan los efectos de 2 factores, cada uno de ellos con un número diferente de niveles.

Técnica de k-promedios. Agrupa los elementos para obtener el promedio de cada característica usada al segmentar en cada grupo y verificar que la asignación de los elementos en los conglomerados sea correcta.

Técnicas estructurales o interdependientes. A diferencia de las técnicas funcionales, que buscan relaciones causa-efecto entre las variables, éstas buscan algo en común entre las variables o personas para unirlos y así poder resumir la información.

Técnicas funcionales o dependientes. Son técnicas que implican un modelo, ecuación o función formada por las variables involucradas. En ellos intervienen variables dependientes e independientes.

Utilidad. Valor asignado a cada uno de los niveles de los atributos escogidos para el producto.

Valoración predictiva del modelo. Verificación del grado de error para efectuar pronósticos.

Valores atípicos. Son valores o muy grandes o muy chicos con respecto a los demás o a la mayoría de los residuales o errores; son valores muy alejados de todas las observaciones.

Variable. Símbolo que puede tomar un valor cualquiera y representar a un conjunto determinado de datos.

Variable latente. Variable que no puede ser medida u observada directamente, pero sí representada o medida por varias variables llamadas *indicadores*. Sirve para reducir a un número menor de variables.

Variables bloque. Variables que aparecen de forma natural y obligada sin interactuar con el factor que se estudia.

Variables cualitativas o no métricas. Miden cualidades que no se pueden medir porque las observaciones sobre ellas sólo se pueden clasificar o enumerar.

Variables cuantitativas o métricas. Identifican a un objeto o persona en forma cuantitativa o numérica, pues es diferente de otro en cantidad o grado.

Variación explicada (SS_B). Esta variación muestra lo distinto que son los datos y resulta de comparar cada promedio de cada nivel con el promedio general de los datos.

Variación no explicada (SS_W). Es la diferencia de los datos dentro del mismo nivel de factor y es el resultado de la comparación de cada dato de cada nivel de factor con respecto a su correspondiente promedio de nivel de factor.

Variación total (SS_T). Se refiere a lo distinto que son los datos sin clasificarlos.

Varianza. Es el promedio de una suma de cuadrados, es decir, es la suma de cuadrados dividido entre los grados de libertad.



Bibliografía

Introducción al análisis multivariante

- Alfonso Pitarque, Juan Carlos Ruiz y Juan Francisco Roy (2000), "Las redes neuronales como herramientas estadísticas no paramétricas de clasificación", Universidad de Valencia, disponible en: <http://www.psicothema.com/pdf/604.pdf>, consultado en febrero de 2006.
- Data Mining Institute, Estadístico.com (1997-2004), disponible en: <http://www.estadistico.com/arts.html?20010723>, consultado en enero de 2006.
- G. David Garson (2006), "Path Analysis", disponible en: <http://faculty.chass.ncsu.edu/garson/PA765/path.htm>, consultado en febrero de 2006.
- Luis M. Molinero (2003), Asociación de la Sociedad Española de Hipertensión, "La regresión logística", disponible en: <http://www.seh-lilha.org/rlogis1.htm>, consultado en enero de 2006.
- Marketing Dictionary, *Dictionary of Marketing Terms* (2000), por Barron's Educational Series, Inc., disponible en: <http://www.answers.com/topic/automatic-interaction-detector-analysis-aid-analysis>, consultado en marzo de 2006.
- Pearson, *Market and Opinion Intelligence*, "Path Analysis", n/d, disponible en: <http://www.pearson-research.com/divisiones-cuantitativa-path-analysis.phtml>, consultado en marzo de 2006.
- Ricardo Pascale (2000), "La predicción de serios problemas financieros con redes neuronales artificiales", Universidad de la República, disponible en: <http://www.um.edu.uy/docs/revistafcee/2002/laprediccionPascale.pdf>, consultado en marzo de 2006.
- Salvador Figueras, M. (2003), "Análisis de Correspondencias", 5campus.com, Estadística, disponible en: <http://www.5campus.com/leccion/correspondencias>, consultado en enero de 2006.
- Universidad de Málaga, Eumed.com, n/d, disponible en: <http://www.eumed.net/tesis/2008/mrl/Analisis%20de%20deteccion%20automatica%20de%20interacciones.htm>, consultado en febrero de 2006.

Análisis de regresión

- Anderson, T.W., *An Introduction to Multivariate Statistical Analysis*, Nueva York, John Wiley & Sons. Inc., 1958.
- Box, G.E.P., *A general distribution theory for a class of likelihood criteria*, Biometrika, vol. 36, pp. 317-346.
- Draper, N.R. y Smith, H., *Applied Regression Analysis*, Nueva York, John Wiley & Sons, Inc., 1966.
- Marquardt, D.W. y Snee, R.D., *Ridge Regression in Practice*, Amer. Statistician, 29: 3-20, 1975.
- Neter, J. y Wasserman W., *Applied Linear Statistical Models*, Homewood, Ill: Richard D. Irwin, Inc., 1974.
- Pope, P.T. y Webster J.T., *The Use of an F-Statistic in Stepwise Regression Procedures*, Technometrics, 14 (2): 327-340, 1972.
- Searle, S.R., *Linear Models*, Nueva York, John Wiley & Sons, Inc., 1971.
- Younger, Mary Sue, *Handbook for linear regression*, Duxbury Press Ed., 1979.

Análisis de factores

- Gorsuch, Richard, *Factor Analysis*, 2a. ed., Lawrence Erlbaum, 1983.
- Jens Grafarend (n/d), *12 Manage, the executive fast track*, "Factores críticos de análisis exploratorio", disponible en: http://www.12manage.com/methods_exploratory_factor_analysis_es.html consultado en diciembre de 2006.
- Levy Mangin, Jean-Pierre; Varela Mallou, Jesús, *Análisis Multivariable para las Ciencias Sociales*, Pearson, 2003.
- Pérez, César, *Técnicas Estadísticas con SPSS 12. Aplicaciones al análisis de datos*, Pearson, 2005.
- Tabachinick, Barbara G; Fidell, Linda S., *Using Multivariate Statistics*, 5a. ed., Pearson, 2007.

- Universidad de Oviedo (2000), Área de Metodología de las ciencias del comportamiento, “Matriz de correlación”, disponible en: http://www.psico.uniovi.es/Dpto_Psicologia/metodos/tutor.1/fac5.html, consultado en noviembre de 2006.

Análisis de agrupamiento

- Clustan a class act (n/d), “What is Cluster Analysis?”, disponible en: http://www.clustan.com/what_is_cluster_analysis.html, consultado en junio de 2007.
- Data International (n/d), “Cluster Analysis”, disponible en: http://www.datum.com.pe/Datum_english/cluster.pdf, consultado en mayo de 2007.
- G. David Garson, (1998), “Cluster Analysis”, disponible en: <http://faculty.chass.ncsu.edu/garson/PA765/cluster.htm>, consultado en mayo de 2007.
- Isabel Galaz, Pamela Maldonado y Paula Vergara (2003), “Análisis de Cluster”, disponible en: http://www.cybertesis.cl/tesis/uchile/2003/galaz_i/html/index-frames.html, consultado en junio de 2006.
- Statsoft Electronic Statistic textbook (n/d), “Cluster Analysis”, disponible en: <http://www.statsoft.com/textbook/stcluan.html>, consultado en mayo de 2007.

Análisis discriminante

- Diputación de Valladolid (n/d), “Capítulo 5”, disponible en: http://www.diputaciondevalladolid.es/extras/extras_accion_social/IIIFASE/capitulo_5.pdf, consultado en octubre de 2007.
- Juan Miguel Marín Diazaraque (n/d), Universidad Carlos III de Madrid, “Capítulo 6: Análisis Discriminante”, disponible en: <http://halweb.uc3m.es/esp/Personal/personas/jmmarin/esp/AMult/tema6am.pdf>, consultado en noviembre de 2007.
- Luis M. Molinero (2002), Asociación de la Sociedad Española de Hipertensión, “Métodos estadísticos de clasificación”, disponible en: www.seh-lelha.org/clasifica.htm, consultado en enero de 2008.
- Universidad de Cádiz (n/d), “Capítulo 23: Análisis Discriminante, el procedimiento discriminante”, disponible en: <http://www2.uca.es/serv/ai/formacion/spss/Pantalla/23discr.pdf>, consultado en diciembre de 2007.

Análisis de varianza

- Anderson, Virgil; McLean, Robert, *Design of experiments*, Marcel Dekker, 1974.
- Box, George E. P.; Hunter, William G.; Hunter, J. Stuart, *Estadística para Investigadores*, Reverté, 2005.
- Hoaglin, David; Mosteller, Frederick; Tukey, John, *Fundamentals of exploratory analysis of variance*, Wiley-Interscience Publication, 1991.
- Juan Vilar Fernández (2006), *Estadística 2*, “Fracciones factoriales, el cuadrado latino”, disponible en: www.udc.es/dep/mate/estadistica2/sec5_6.html, consultado en febrero de 2008.
- Montgomery, Douglas, *Diseño y Análisis de Experimentos*, Grupo Editorial Iberoamericana, 1991.

Análisis conjunto

- Gustafsson, Herrmann y Huber, *Conjoint Measurement*, 4a. ed., Springer 2007.
- Innovacion.com.es (2006), “Conjoint Analysis”, disponible en: http://www.innovacion.com.es/index.php?option=com_content&task=view&id=48&Itemid=28.
- Quick MBA (n/d), “Conjoint Analysis”, disponible en: <http://www.quickmba.com/marketing/research/conjoint/>.
- Sawtooth Software (n/d), “What is Conjoint Analysis?”, disponible en: <http://www.sawtoothsoftware.com/qs-whatisconjoint.shtml>, consultado en junio de 2008.



Bibliografía general

- Green y Tull, *Investigaciones de Mercadeo*, Prentice Hall, 1978.
- Hair, Black, Babin, Anderson, Tatham, *Multivariate Data Analysis*, 6a. ed., Prentice Hall,
- Johnson, Dallas, *Métodos multivariados aplicados al análisis de datos*, Thomson, 2000.
- Myers, Mullet, *Managerial Applications of Multivariate Analysis in Marketing*, Thomson, 2003.
- Uriel, Aldás, *Análisis Multivariante Aplicado*, Thomson, 2005.



Índice analítico

A

Aditividad, 484
Agrupamiento jerárquico aglomerativo, 474
Agrupamientos, 692
Agrupar, 417
Amplitud de cada clase, 121
Análisis
 conjunto, 682, 683, 687
 tradicional, 687
 de agrupamiento, 396, 473, 474
 métrico, 415
 de conglomerados, 22, 396-398, 403, 407, 426, 429, 480, 483, 692
 de conjunto, 16, 34
 de correlación, 63
 de correspondencia, 27
 de covarianza, 654, 655, 665
 de factores, 21, 24, 74, 331, 337, 341, 343, 357, 380, 465, 482, 687
 de regresión, 16, 30, 31, 42, 229, 274, 370, 480, 606, 654, 689
 múltiple, 30, 42, 370, 480, 606, 689
 de segmentación de datos, 396
 de supervivencia, 18, 19, 20
 de varianza, 14, 600, 604, 606, 654, 663
 de un factor, 603
 factorial, 624
 multivariado, 602, 663
 univariado, 602
discriminante, 14, 197-198, 201, 370, 396, 428, 435, 440, 454, 459, 464, 472, 479, 484, 518, 594, 656, 683
 descriptivo, 480
 múltiple, 487, 532
 predictivo, 480
 simple, 487, 532
estadístico, 600, 602
estadísticos, 688
 multivariante, 1, 17, 395, 473
ANCOVA, 654, 657
ANDECOVA, 654
ANDEVA, 602
ANOVA, 602, 663, 673
 de dos factores, 624
 de un factor, 613, 624, 666
Aproximación
 bayesiana, 617
 probabilística, 465
 tipológica, 465
Área de traslape entre las curvas, 519
Asignación de un elemento a un grupo, 480
Asociación
 entre variables, 61
 inversa, 689
 negativa perfecta, 689

 positiva perfecta, 689
Atributos, 483
 físicos, 684
 ortogonales, 687
Ausencias, 405
Autocorrelación, 164, 168, 169, 172, 266
 del primer rezago, 266
 de primer orden, 172, 266
 negativa, 169, 267
 positiva, 169, 267
Autovalor, 501
Autovalores, 74, 75
Autovectores, 74

B

Beneficios del producto, 684
Beta
 cero, 239
 estandarizada, 214
 subcero, 53
Between-groups linkage. Véase Promedio entre grupos
Bloques al azar, 647, 648, 654

C

Cálculo de la Z crítica, 559
Cambio porcentual, 430
Campo de aplicación del análisis discriminante, 480
Características, 483
Cargas de factor, 331, 355, 359, 364
Caso
 balanceado, 603, 605, 625, 663
 desbalanceado, 603
 no balanceado, 616, 617
Causalidad, 225
Centroid method. Véase Método del centroide
Centroides, 483, 586
City block metrica, 402
Cluster analysis, 396
Coeficiente(s)
 bivariado, 255
 de correlación, 253
 al cuadrado, 70
 de Kendall's tau, 689
 de Pearson, 689
 múltiple, 112, 254, 256, 257
 phi, 398, 407
 de determinación, 15, 70, 106, 108, 109, 112, 114, 253, 254, 256, 507, 547, 612, 613
 ajustado, 109, 253
 corregido, 109, 111
 de distancia, 430
 de Kendall's tau, 689
 de Pearson, 399

- de similaridad, 451
- de similitud, 441
- eta parcial al cuadrado, 673
- phi cuadrado, 403
- Shapiro-Wilk, 135, 139
- Colas de la distribución, 155, 157
- Colinealidad, 43, 60
- Columnas de la matriz, 313
- Combinación
 - de atributos, 682
 - lineal de variables, 480
- Comparaciones
 - a posteriori, 615
 - múltiples, 615, 616
- Complete linkage. Véase* Criterio completo
- Componentes principales, 21, 24, 74, 331, 348, 366
- Comunalidad, 331, 356, 362, 392, 394
- Concepto de
 - agrupar, 430
 - bloque, 647
 - centroide, 483
 - clasificación, 396
 - covarianza, 491
 - dendograma, 423
 - el vecino más lejano, 412
 - error, 118
 - eslabonamiento, 410
 - experimentación, 602
 - experimento, 602
 - proximidad, 398
 - utilidad, 682
 - varianza, 491
- Confusión en los datos, 482
- Conjoint análisis. Véase* Análisis conjunto
- Constante(s)
 - estandarizadas, 515
 - negativa, 516
 - normalizados, 510
- Construcción del mapa territorial, 580
- Corrección
 - de Yates, 527
 - por continuidad de Yates, 528
- Correlación
 - bivariada, 60, 71, 112, 172
 - canónica, 507, 508
 - en discriminante múltiple, 547
 - de los errores en el tiempo, 266
 - de Pearson, 112, 403
 - multivariante, 112
- Covariable, 654
- Covarianza, 569
 - correcta, 654
 - promediadas, 510, 550
- Creación de
 - los estímulos, 685
 - los tratamientos, 685
- Criterio
 - a priori, 373
 - Criterio
 - completo, 412
 - de eslabonamiento, 409
 - de eslabonamiento promedio, 460
 - de mínimos cuadrados, 481
 - de raíz latente, 357, 358
 - del promedio, 436, 438
 - del vecino más cercano, 411, 417, 418, 446
 - simple, 411, 445
 - Cuadrado medio
 - de la regresión, 90
 - del error, 95
 - Cuadrados
 - latinos, 604
 - medios, 90
 - medios del error, 116
 - Cuantiles, 151, 153
 - Cuarto momento, 154
 - Curtosis, 154, 155, 157, 159
 - igual a 3, 157
 - mayor a 3, 157
 - menor a 3, 157
- D**
 - Data mining*, 30
 - Dato
 - esperado, 229
 - observado, 229
 - pronosticado, 83, 118, 229
 - real, 83, 85, 118, 229, 230, 235
 - Datos
 - clasificados incorrectamente, 519
 - de corte longitudinal, 164
 - de corte transversal, 164
 - dicotómicos, 397
 - longitudinales, 164
 - sujetos a errores experimentales, 602
 - transversales, 165
 - Definición de
 - análisis conjunto, 682
 - análisis de varianza, 600
 - análisis discriminante, 480
 - efecto de un factor, 636
 - error, 229
 - matriz, 313
 - multicolinealidad, 48
 - Dendograma, 413, 421, 424, 448
 - Dependencia entre
 - los errores, 265
 - variables, 483
 - Descomposición
 - espectral, 74, 354, 384
 - singular, 74
 - Desviación estándar, 243, 260, 484, 513, 515
 - de los errores, 87
 - de los residuales, 260
 - Detector automático de interacción, 34, 472

- Determinante(s), 572
 - de la matriz W , 506
 - de T , 507
 - de una matriz, 319
 - Diagonal
 - principal, 567, 580
 - de la matriz, 313
 - secundaria de la matriz, 314
 - Diagrama(s) de
 - carámbanos, 413, 421, 433
 - horizontal, 450
 - vertical, 450
 - témpanos, 413, 421, 423, 433, 437, 448, 457, 462, 477
 - Diferencia(s), 405
 - binaria de forma, 407
 - de patrón, 407
 - de tamaño, 407
 - en las matrices, 494
 - entre matrices, 320
 - no métrica binaria de Lance y Williams, 407
 - Dimensionalidad del vector, 53
 - Dimensiones latentes, 465
 - Discriminante
 - múltiple, 560, 580
 - simple, 547, 580
 - Diseño(s)
 - de dos factores, 603
 - de experimentos completos de tres factores, 604
 - de tres factores, 604
 - estadístico de experimentos, 602
 - experimental, 600
 - factorial, 603, 605, 637, 648, 673
 - con 2 factores, 636
 - por bloques, 604, 647
 - incompletos, 604
 - Disimilaridad, 398, 410, 416
 - Dispersión, 407
 - alrededor de la línea de regresión, 257
 - de los datos, 484
 - Distancia(s)
 - de Chebychev, 402
 - de Mahalanobis, 402, 503, 504
 - de Manhattan, 402
 - de Minkowski métrica, 402
 - entre conglomerados, 429
 - entre dos grupos, 413
 - en un poder métrico absoluto, 402
 - euclidiana, 398, 402, 407, 414, 467
 - al cuadrado, 402
 - binaria, 407
 - binaria al cuadrado, 407
 - máximas, 412
 - mínimas, 411
 - promedio, 436
 - Distribución
 - asintótica ji cuadrada, 501
 - de frecuencia de los errores, 121
 - del módulo máximo estudentizado, 617
 - F , 616, 617
 - insesgada, 155
 - ji cuadrada, 501
 - normal
 - con variabilidad, 83
 - elevada al cuadrado, 88, 238
 - probabilística, 465
 - de los errores, 259
 - sesgada, 155
 - simétrica, 155
 - t , 616, 617
 - t de student, 616, 617
 - División de
 - la muestra, 486
 - matrices, 324
- ## E
- Ecuación
 - D de Anderbeg, 407
 - de Czekanowski-Sorensen-Dice, 406
 - de Hamman, 406
 - de Jacard, 406
 - de Kulezynski 1, 406
 - de Kulezynski 2, 406
 - de Ochiai, 407
 - de parejas simples, 406
 - de regresión, 51, 87, 91, 94, 106, 117
 - de Rogers y Tanimoto, 406
 - de Rusell y Rao, 406
 - de Sokal y Sneath 1, 406
 - de Sokal y Sneath 2, 406
 - de Sokal y Sneath 3, 406
 - de Sokal y Sneath 4, 407
 - de Sokal y Sneath (medida 5), 407
 - de Welch, 618
 - discriminante de Fisher, 480
 - lineal discriminante, 511
 - canónica de Fisher, 512
 - de Fisher, 522, 560
 - normal, 231, 232
 - Q de Yule, 407
 - Y de Yule, 407
 - Efecto interacción, 624, 628, 632, 634, 635, 636, 637
 - Efectos principales de los factores, 624
 - Eigenvalor(es), 74-75, 355, 488, 499, 500, 501, 506, 541, 546
 - de la matriz de varianzas-covarianzas, 74
 - Eigenvector(es), 74, 76, 77
 - Eje
 - de las abscisas, 516
 - de las ordenadas, 516
 - X , 516
 - Y , 516
 - Z , 517, 518, 520, 521, 522, 531, 560
 - Elaboración del análisis conjunto, 683
 - Elección del tipo de análisis conjunto, 687

Enfoque
agregado, 688
desagregado, 688

Error
de la observación, 51
en población, 52
estándar, 243, 244, 249, 260, 275
del estimado, 106, 113, 115, 116, 123, 243, 253, 257, 260, 275
estimado, 124
muestral, 600, 602
residual, 52

Errores
estándar de los betas, 60
estandarizados, 161, 163
negativos, 120
positivos, 120

Escala
de importancia, 687
de intervalo, 396, 402, 654, 690
de preferencia, 687
de razón, 396, 397, 402, 440
nominal, 654

Escalar, 313, 314, 551, 554

Escalas
de intervalo, 654
de medición, 1, 3, 10, 11
multidimensionales, 25

Eslabonamiento, 409, 411, 417, 429, 431, 433, 457, 458
completo, 429, 430, 455
promedio, 435
simple, 417

Eslabonar, 417, 418

Estadístico
calculado, 65, 172, 177, 178, 525, 527, 564
 Z_c , 563
de Bowman-Shelton, 159, 160
de Kolmogorov-Smirnov-Lilliefors, 141
de Mahalanobis, 501
de tablas, 64, 92, 178, 505
Durbin-Watson, 165, 168, 169, 266
F, 91, 92, 606, 615, 624
F de Fisher, 238
F parcial, 78
M de Box, 193
teórico, 66, 81, 83, 92, 142, 178, 505, 526, 529, 538, 539, 543, 545, 565, 575
 Z_p , 563
t-student, 94, 97
V de Bartlett, 501, 543

Estadístico de prueba, 64-66, 68, 83, 92, 97, 134, 135, 140-142, 149, 159, 160, 504, 575
de Shapiro-Wilk, 135
M de Box, 193, 572
transformado a una F, 568

Estandarización de una variable, 161

Estimaciones, 683

Estimadores
de los betas, 51, 53, 55, 60
puntuales de los betas, 53, 54
en regresión simple, 229

Estímulos, 683

Estudio de la variabilidad del resultado de un experimento, 600

Etapas de
derivación, 486, 489, 533
el análisis de regresión múltiple, 42
validación, 484, 486, 489, 521, 533, 560, 562
del modelo, 484, 486

Etiquetado de
los conglomerados, 428
los grupos, 428

Evaluación global del producto, 683

Experimento(s)
con variabilidad no controlable, 600
controlados, 602
de un solo factor, 606
naturales, 602

Expresión
de Bartlett, 501, 543
funcional del análisis conjunto, 682

Extensión del
cuadrado latino, 604
teorema de Chebyshev, 122

F

Factor
común, 21, 24, 331
de inflación de varianzas, 72
de inflación de varianzas FIV, 70
tratamiento, 604

Factores, 602
bloque, 604, 605
controlables, 600
de inflación de varianzas, 71
no controlables, 600

Filas, 313

Formas de recolectar los datos, 686

Fórmula de
corrección por continuidad de Yates, 527
distancia euclidiana, 467
eta cuadrada, 507, 547
la correlación canónica, 507
la cuadrática, 542
la distancia euclidiana, 402

Frecuencia retrasada en un valor, 147

Fuentes
de variación, 647
en el experimento, 605
experimentales de variabilidad, 604

Fuerza de asociación
entre dos variables, 61
lineal, 61

Función
 de la lambda de Wilks, 501
 de regresión, 104
 discriminante, 481, 483, 488, 503, 505, 507, 508,
 516, 532, 547
 discriminante lineal de Fisher, 481

G

Grado de
 error para efectuar pronósticos, 516
 proximidad, 429
 simetría, 155
 similitud, 398, 424, 460
 Grados de libertad, 87, 89, 550, 553, 569, 572, 617,
 628, 667, 669, 671
 de la variación total, 90
 Gráfica
 de histograma, 259
 de independencia, 166
 de los residuales, 165
 de probabilidad normal de los residuos, 605
 de tres dimensiones, 84
 P-P plot, 264
 Q-Q plot, 264
 Gran media, 494

H

Heteroscedasticidad, 180, 184, 270, 577
 Hipótesis
 alternativa, 64
 de igualdad de medias, 606
 nula, 64, 91, 94, 238, 516, 530, 555
 Histograma, 121, 127
 de los residuos, 605
 Historial del eslabonamiento, 432
 Homogeneidad
 de varianza, 160, 179, 484, 605
 en las varianzas, 270
 Homoscedasticidad, 160, 179, 180, 183, 193, 201, 270,
 272, 484, 605

I

Independencia de los residuales, 164, 165
 Indicio de la dispersión, 116
 Información global de los encuestados, 683
 Intervalo, 7-9, 17, 19, 25, 34, 98, 100, 101, 179, 209,
 251, 275, 332, 340, 396, 397
 de confianza, 97, 100, 246
 para la media, 205, 208, 275
 para la predicción individual, 208, 210, 275
 de predicción individual, 280
 externo, 209
 interno, 209
 para la media, 280

Inversa
 de la matriz W, 499
 de una matriz cuadrada, 324
 generalizada, 613

J

Ji cuadrada, 88, 127, 154, 159, 238, 399, 403, 527, 528,
 529, 543, 564, 565, 568, 573, 579
 con $p - 1$ grados de libertad, 88
 de Pearson, 133, 564, 579
 de tablas, 159
 teórica, 159

K

K-means, 465
 K-medianas, 465
 KMO, 345, 382
 K-promedios, 465, 476

L

Lambda de
 cada variable, 495
 la ecuación, 500
 Wilks, 495, 496, 506, 507, 547, 667
 Límite
 inferior del intervalo de confianza medio, 278
 superior del intervalo de confianza medio, 278
 Línea de regresión, 84, 87, 103, 114
 Linealidad, 484

M

Manejo de los niveles, 603
 MANOVA, 601, 602
 de un solo factor, 663
 Mapa territorial, 583, 584
 de los grupos, 583
 Matrices
 cuadradas, 491
 de varianzas-covarianzas, 483
 singulares, 324
 Matriz
 A, 494, 534
 antisimétrica, 316
 aumentada, 319
 cero, 315
 cuadrada, 314
 de orden 2, 315
 de orden 3, 315
 de ceros, 320
 de clasificación(es), 519, 523, 524, 527, 561, 564,
 578, 597
 de confusión, 519, 523, 524, 527, 561, 562
 de correlación, 30, 69, 71, 173, 175, 341, 343, 345,
 351, 352, 384, 385, 388, 389

- de disimilaridad, 416
- de distancia, 414, 416, 417, 435, 440, 445, 464, 473, 475
- de proximidad, 416
- de similitud, 445, 455
- del error, 665
- diagonal, 315
 - de orden 2, 315
 - de orden 3, 315
- dividida entre un escalar, 324
- 2-cuadrada, 315
- explicada, 665
- identidad, 173, 314, 541
- intragrupos, 572
- inversa W , 499, 541
- N por K , 313
- normal, 318
- no rotada, 354, 355, 356, 358, 359, 371, 376
- no singular, 324
- ortogonal, 317
- rotada, 358, 360, 361, 362, 363, 364, 367, 368
- sigma, 95
- simétrica, 316
- singular, 60
- T , 493, 494, 495, 507, 515, 534, 556
- total, 494, 534, 665
- 3-cuadrada, 315
- triangular inferior, 316
- triangular superior, 316
- W , 494, 495, 534
- X , 613, 614, 615
- Máxima de las distancias, 412
- Maximización de matrices, 488
- Mayor similitud, 445
- Media, 183
 - cuadrática, 628
 - de las medias, 494
 - de los datos, 494
 - de los errores, 116, 123
 - recortada, 183
- Median method*. Véase Método de la mediana
- Mediana, 183
- Medias
 - de la variable dependiente, 606
 - muestrales adyacentes, 615
 - poblacionales, 606
 - separadas r , 616
- Medida
 - de cosenos, 399
 - de disimilaridad, 398
 - de distancia, 399, 414, 417
 - de ϕ cuadrado, 399
 - de proximidad, 398
 - de similaridad, 398
 - lambda de Wilks, 547
- Medidas de
 - disimilaridades métricas, 402
 - distancia, 400, 402, 424
 - frecuencia, 403
 - similaridad binaria, 406
 - similaridad métrica, 403
 - similitud, 408, 424
- Menor similitud, 445
- Método
 - adaptativo, 687
 - conjunto, 687
 - aditivo, 687
 - apareado, 687
 - autoexplicado, 687
 - basado en el centroide, 465
 - basado en la elección, 687
 - Bonferroni, 616
 - C de Dunnett, 618
 - de cuadrados grecolatinos, 604
 - de cuadrados latinos, 604
 - de eslabonamiento, 409
 - de Gauss, 54
 - para resolver matrices, 324
 - de inducción, 674
 - de la mediana, 413
 - de las F parciales, 513, 555
 - de la varianza mínima, 412
 - del centroide, 413
 - de los pesos discriminantes estandarizados, 513, 555
 - de mínimas diferencias significativas, 616, 618
 - de mínimos cuadrados ordinarios (MCO), 42, 60, 176, 232, 269
 - de perfil completo, 687
 - de reasignación, 465
 - de reducción de dimensiones, 465
 - de R-E-G-W F , 616
 - de R-E-G-W Q , 617
 - de vinculación, 409
 - de Ward, 412
 - Dunnett, 617
 - full-profile*, 687
 - Gabriel, 617
 - Games-Howell, 617
 - GT2 de Hochberg, 617
 - jerárquico, 408
 - aglomerativo, 408
 - divisional, 409
 - self-explicated*, 687
 - Sidak, 616
 - T_2 de Tamhane, 617
 - trade off*, 687
 - T_3 de Dunnett, 617
 - Waller-Duncan, 617
- Metodología estadística, 602
- Métodos de búsqueda de la densidad, 465
- Mínima de las similitudes, 412
- Minimización, 55
- Mínimos cuadrados, 613
 - ordinarios (MCO), 42, 43, 53
 - ponderados (MCP), 43

Modelo(s)

- aditivo, 605, 613
- ANCOVA, 661
- autorregresivo de primer tiempo, 172
- de análisis de varianza, 603
- de polinomio avanzado, 50
- de regresión lineal múltiple, 79
- de regresión lineal simple, 79
- general de la técnica factorial, 625
- matemático lineal, 42
- unifactorial, 606

Momentos, 154, 156, 157, 158

- Muestra, 4, 17, 20, 23, 25, 26, 32, 35, 39, 47, 48, 51, 52, 54, 76, 80, 84, 86, 94, 95, 97, 100, 114, 118, 124, 129, 134, 146, 148, 154-158, 160, 164, 198, 229, 234, 236, 244, 249, 257, 340, 341, 345, 352, 354-356, 358-363, 368, 388, 434, 489, 602, 605, 606, 610, 613, 622, 634-636, 674. *Véase también* Varianza de los residuales grande, 531
- representativa, 486
- total, 496

Multicolinealidad, 43, 60

- entre variables, 483
- perfecta, 60

Multiplicación de

- dos matrices, 322
- matrices, 320
- una matriz por un escalar, 321
- un vector por otro, 321
- un vector por una matriz, 321

N

- Nivel de significancia, 659, 661, 667, 669, 671
- Niveles, 600, 601, 602, 603, 604, 605, 607, 624
 - de factor, 602
 - de los factores, 647
 - del factor, 603, 605
- No compra, 686
- No cumplimiento de la no normalidad, 577
- No normalidad, 577
- Nominal, 4, 5, 9, 14, 17, 22, 34, 42
- Norma del vector, 509
- Normalidad, 120, 122, 135, 160, 259, 340, 365, 577
- Número de escalones, 616

O

- Objetivo del análisis discriminante, 480
- Oblicuo, 353
- Obtención de la muestra, 685
- Operaciones matriciales, 313
- Oportunidades de mercado, 683
- Ordinal, 5, 7, 8, 16, 34
- Ortogonal, 353, 361, 362
- Outliers*, 160. *Véase también* Valores atípicos

P

- Paquete estadístico SPSS, 546
- Paralelismo, 636
- Parámetros, 43
- Pasos
 - del análisis de conglomerados, 396
 - para el agrupamiento jerárquico aglomerativo, 413
 - para multiplicar matrices, 327
- Percentiles (P-P plot), 150, 151, 153, 263, 264
- Peso
 - de los extremos de la distribución, 157
 - discriminante, 556
- Plano cartesiano, 516
- Porcentaje de
 - clasificaciones correctas, 516, 519, 524, 525, 530, 562, 563, 566
 - clasificaciones mínimas aceptables, 525, 562
 - variación explicada, 355, 357, 370
- Posicionamiento psicológico, 684
- P-P plot, 150, 153
- Presencia, 405
- Primer
 - momento, 154
 - residual, 124
- Probabilidad
 - acumulada, 142
 - de pertenencia, 465
 - por medio de Z, 145
 - teórica, 142
 - acumulada rezagada, 142
 - rezagada, 148
- Problemas de multicolinealidad, 48, 60, 555
- Procedimiento
 - del eslabonamiento simple, 432
 - para validar el modelo discriminante, 519
- Proceso
 - de planeación de un experimento, 602
 - para realizar el mapa territorial, 580
- Productos cruzados, 494, 568, 571
- Promedio
 - de la variable dependiente, 83
 - de los errores, 242
 - de todos los datos, 607
 - entre grupos, 410, 411, 435, 460
 - ponderado, 559
 - sencillo, 559
- Promedios
 - de las variables, 568
 - de los grupos, 580
 - intragrupos, 411
- Pronóstico, 230
 - por intervalo, 205
 - puntual, 202, 204
- Pronósticos
 - de punto, 273
 - por intervalo, 275
 - puntuales, 273, 274

- Propiedad
 - asociativa, 320
 - conmutativa, 318, 320
 - de ortogonalidad entre los factores, 605
 - del elemento nulo, 320
 - del inverso aditivo, 320
 - del valor esperado, 55
 - Propiedades
 - de las sumatorias, 230, 231
 - de la transpuesta, 319
 - del valor esperado, 229
 - Proximidad, 396, 397, 398, 404, 416
 - disimilar, 398
 - similar, 398
 - Prueba
 - de Bartlett, 172
 - de bondad de ajuste por la ji cuadrada, 127
 - de Bowman-Shelton, 154
 - de Duncan, 616
 - de igualdad de las medias, 495, 538
 - de independencia, 579
 - estadística, 527
 - de intervalos múltiples de Duncan, 615, 618
 - de Kolmogorov-Smirnov, 141, 264
 - de Kolmogorov-Smirnov-Lilliefors, 141
 - de la correlación, 64
 - de las variables, 495
 - de Levene, 183, 192, 272
 - de Newman-Keuls, 616, 617
 - de Scheffé, 617, 618, 623
 - de Shapiro-Wilk, 135, 264
 - de Tukey, 615, 617
 - de comparaciones múltiples, 616
 - de Wilks, 665
 - del modelo, 543, 544, 545
 - F, 77, 615
 - F del análisis de varianza, 618
 - global, 83, 615
 - del modelo de regresión, 234
 - M de Box, 193, 197, 568, 572, 573
 - Mahalanobis, 504
 - Scheffé, 652
 - t, 77
 - t de student, 616
 - Prueba de hipótesis, 63, 64, 67, 68, 78, 83, 91, 495, 525, 527, 543, 562, 577, 610
 - con las correlaciones, 689
 - de cada beta, 96
 - del modelo, 257, 501, 542
 - Durbin-Watson, 265
 - global, 83
 - t, 64
 - Pruebas
 - de comparaciones múltiples, 618
 - de hipótesis, 516
 - de hipótesis individuales, 94
 - de las diferencias de los pares, 619
 - Post-hoc, 615, 632, 647, 663, 671
 - Puntaje discriminante, 519, 521, 555, 561
 - Puntajes
 - de factores, 331, 365
 - discriminantes, 508
 - P-valor, 68, 90, 94, 100, 134, 141, 150, 341, 344, 577, 579, 690
- ## Q
- Q-Q plot, 150, 151, 153
 - Quantiles (Q-Q plot), 263, 264
- ## R
- Razón, 9, 10, 17, 32, 34, 77, 100, 332, 340, 396, 397, 488, 654
 - de la inversión, 496
 - del ingreso, 496
 - ingreso e inversión, 497
 - r de Pearson, 689
 - r medias muestrales, 615, 616
 - Recolección de datos por
 - jerarquías, 686
 - puntuaciones, 686
 - rankings, 686
 - ratings, 686
 - Redes neuronales, 28, 30
 - Reescalamiento de los coeficientes, 510
 - Reescalar la ecuación, 554
 - Regla
 - de Cramer, 232
 - empírica, 122, 126
 - Regresión, 42, 683
 - de Ridge, 77
 - logística, 16, 17
 - simple, 42, 243
 - Relación(es)
 - causa-efecto, 43
 - directa entre variables, 689
 - inversa entre variables, 61, 689
 - más comunes, 45
 - negativa perfecta, 689
 - no lineal, 166, 167
 - entre variables, 225, 682
 - polinomial de grado 3, 167
 - positiva perfecta, 689
 - Relación lineal, 83
 - bivariada, 61
 - casi perfecta, 62
 - entre variables, 61, 225, 254, 682
 - imperfecta, 229
 - perfecta, 61, 62
 - Renglones, 313
 - Residual, 86, 229, 236, 261
 - Residuales, 260
 - estandarizados, 566, 567, 580
 - Respuesta cuantitativa, 603

Rutina

- de pasos sucesivos, 79
- del *backward*, 78, 79
- del *forward*, 78, 79
- del *stepwise*, 78, 79

S

- Segundo momento, 154
- Sesgo, 150, 154, 155, 156, 157, 158
 - negativo, 155
 - positivo, 155
- Simetría del experimento factorial, 604
- Similitud, 404
- Single linkage*. Véase Criterio simple
- Suma de
 - dos matrices, 320
 - los errores, 229
 - los productos cruzados, 570
 - productos cruzados, 491, 569
- Suma de cuadrados, 86, 89, 106, 137, 236, 491, 494, 549, 568, 570, 571, 628, 656, 658
 - debida al error, 86
 - de los residuales, 195
 - intergrupos, 183, 185, 193
 - intragrupos, 183, 185, 190, 193
 - promediada, 116, 193
 - totales, 86
- Sumas de cuadrados, 556
 - de las desviaciones, 135
- Sum of Square*, 86
- Supuesto de
 - homoscedasticidad, 180, 184, 568, 575, 577, 605, 617
 - homoscedasticidad en varianzas y covarianzas, 568
 - independencia, 165, 168, 173, 176
 - la independencia de los errores, 164
 - media cero, 176, 269
 - normalidad, 120, 160, 167
- Supuestos
 - de los errores, 118, 119, 242, 259
 - en los errores de la regresión, 116

T

- Tabla
 - ANOVA, 156, 608
 - de coeficientes, 59
 - de contingencia, 579
 - del ANOVA, 90, 91, 95
 - F, 81, 92, 610, 620, 646, 667, 669, 670, 671
 - F, 191, 200, 241
- Tamaño(s) de la muestra, 484, 486, 577
- Tarjetas
 - verbales, 685
 - visuales, 685
- Tasa de error, 616, 617

Técnica

- composicional, 683
- de bloques al azar, 647
- de clasificación, 480
- de cuadrados de Youden, 604
- de cuadrados latinos, 637
- de dependencia, 663
- de *k*-promedios, 395, 465, 476
- de la regresión, 613
- del grupo estructural, 396
- de regresión logística, 42
- descomposicional, 683
- MANDEVA, 663
- MANOVA, 663
- Técnica de análisis
 - conjunto, 682
 - de conglomerados, 692
 - de discriminante, 527
 - de factores, 77
 - de regresión, 42
 - de varianza, 624
 - ortogonal, 637
- Técnica de diseño anidado, 605
 - factorial, 22, 604, 624
 - 2*k* en dos bloques, 605
 - 3*k*, 605
 - fraccionario de dos niveles, 605
 - jerárquico, 605
 - reticular, 604
- Técnicas
 - funcionales, 479
 - multivariadas, 313
- Teorema de
 - Gauss-Markov, 42
 - Pitágoras, 402, 509, 549
- Tercer momento, 154
- Tipo de
 - eslabonamiento, 417
 - presentación de los estímulos, 686
 - proximidad, 398
 - variable respuesta, 686
- Tipos
 - de atributos, 684
 - de matrices, 314
 - de vectores, 314
 - del análisis de varianza, 605
- Transformación
 - con raíz cuadrada, 50
 - inversa, 50
 - logarítmica, 50
- Transformaciones, 50
- Transpuesta de
 - un vector, 318
 - una matriz, 316, 318
- Traslapes de las opiniones, 518
- Tratamiento, 602
- Traza de una matriz, 318

t-student, 176, 178, 179, 207, 211, 238, 243, 244, 245, 247, 249, 250, 252, 259, 269

U

Unidades de prueba, 647

V

Valor

- de beta, 92
- de cada nivel, 682
- de la correlación, 689
- de la intersección, 233
- de la pendiente, 233
- de lambda, 665
- del eigenvalor, 501
- esperado de los errores, 259
- F*, 665
- p*, 68, 577
- propio, 499

Valoración predictiva del modelo, 516

Valores

- atípicos, 160, 162, 183
- de la función discriminante, 508
- de las constantes, 508
- de los residuales, 161, 162
- propios, 74, 75, 506

Variabilidad, 116

- de la variable dependiente, 106
- del resultado, 600
- dentro de los grupos, 488
- en los datos, 487
- entre grupos, 488

Variable

- categorica, 47, 603
- dependiente, 48, 486, 564, 566, 577, 578, 603, 625, 682
- de carácter categórico, 480
- no métrica, 479, 484
- ordinal, 682
- dummy*, 47
- independiente, 48, 603, 682
- no métrica, 47
- nominal, 479
- pronosticada, 564
- rezagada en el primer tiempo, 169
- tipo *dummy*, 42

Variables

- binarias, 404
- bloque, 603
- cualitativas, 1, 4, 27
- cuantitativas, 7, 689
- dependientes métricas, 600
- dicotómicas, 440
- discriminantes, 480, 483, 484, 486, 487, 488, 491, 507, 512
- dummy*, 396, 404
- explicatorias, 42

- independientes, 479, 602, 606
- independientes métricas, 484
- independientes no métricas, 600
- métricas, 43
- no asociadas, 61

Variación

- atribuida a la relación lineal, 86
- de la interacción, 627
- de los datos, 482
- de los efectos principales, 626
- explicada, 234, 236, 238, 240, 607, 609, 626, 640, 650
- media, 88
- por la regresión, 86
- media captada por regresión, 91
- no atribuida a la relación lineal, 86
- no explicada, 234, 236, 238, 240, 506, 608, 627, 650
- media, 88
- por la regresión, 86
- total, 83, 86, 89, 106, 107, 109, 234, 236, 256, 352, 355, 495, 607, 626, 640, 649

Varianza, 569

- de los errores, 87, 91, 113, 116, 156, 242, 244, 249, 259
- de los residuales, 116
- disimilar, 407
- estimada de los errores, 90, 205, 208

Varianzas

- constantes, 179
- homogéneas, 160
- promediadas, 510, 550

Vecino

- más cercano, 430, 440, 445
- más lejano, 412, 430, 433, 440, 455, 458
- más próximo, 411

Vector, 314

- cero, 315
- columna de orden *N*, 314
- de ceros, 508
- de constantes, 508
- de los errores, 54
- de pronósticos, 54
- renglón de orden *N*, 314

Vectores propios, 74, 75

Vinculación, 421

W

Wilks lambda, 543

Withing-groups linkage. Véase Promedios intragrupos

Z

Z crítica, 519, 520, 521

Z promedio, 485, 512, 519, 520

Zona(s) de

- confusión, 481, 483
- indecisión, 169, 172, 267, 269
- rechazo, 92, 100, 106, 134, 160, 241, 246, 251, 576
- traslape, 518